10 Datenanalyse und Interpretation

Heute

- eine Summe, die vorher feststand
- Daten, Befund, Schlussfolgerung
- Over-Interpretation, p-Hacking, HARKing
- der Garten der sich verzweigenden Wege
- Gegenmittel: Triangulation und Präregistrierung

10.1 Staunmoment: Die unveränderliche Summe

★ Staunmoment: Vier freie Zahlen

Am Pult liegt seit Beginn der Stunde ein versiegelter Umschlag. Eine Person nennt: (1) ihr Geburtsjahr, (2) das Alter, das sie in diesem Jahr erreicht, (3) das Jahr eines Ereignisses, das ihr wichtig ist, (4) wie viele Silvester seitdem vergangen sind.

Jemand addiert. Dann öffnen wir den Umschlag.

Wo war hier die Freiheit?

- alle vier Zahlen waren frei gewählt
- das Ergebnis stand trotzdem vorher fest
- welche Erklärungen haben Sie?
- was hätte die Vorhersage scheitern lassen können?

10.2 Auflösung: der Force

Die Rechnung

$$\underbrace{\text{Geburtsjahr} + \text{Alter}}_{=J} + \underbrace{\text{Ereignisjahr} + \text{vergangene Jahre}}_{=J} = 2J$$

- jede Eingabe war frei, die **Struktur** der Rechnung nicht
- die Freiheit hat das Ergebnis nie berührt
- scheitern kann die Vorhersage nur an Messfehlern: falsches Alter, falsch gezählte Jahre

Force

Definition 10.1 *Ein **Force** ist ein Verfahren, das einer Person eine freie Wahl lässt und trotzdem ein vorab festgelegtes Ergebnis herbeiführt.*

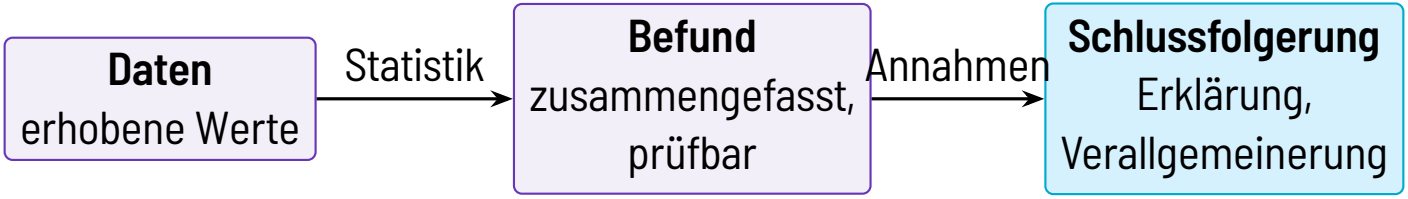
- Zauberkunst: Die versiegelte Vorhersage stimmt, weil das Verfahren sie erzwingt
- Newcomb: Der Prädiktor hat entschieden, bevor die Person wählt (Nozick 1969)
- Forschung: Eine Auswertung, die nur ein Ergebnis zulassen kann, prüft nichts

Forces in der Forschung

- Stichprobe nur aus Freiwilligen, die das Thema mögen
- Fragebogen nur mit zustimmend formulierten Items
- „Erfolg“ wird erst nach Sicht der Daten definiert
- Auswertung so lange variieren, bis sie passt
- Frage: Hätte meine Auswertung meine Hypothese überhaupt widerlegen können?

10.3 Daten, Befund, Schlussfolgerung

Drei Ebenen



- Beispiel Monty Hall: 97 von 150 Wechselrunden gewonnen – Wechseln gewann in 64,7 % – Wechseln ist im Spiel überlegen
- jede Stufe braucht etwas, das in der vorigen nicht steht

Over-Interpretation

- Zusammenhang als Ursache lesen
- über die Stichprobe hinaus verallgemeinern
- „signifikant“ als „groß“ oder „wichtig“ lesen
- einen Einzelbefund als gesichert darstellen
- aus dem Fehlen eines Befunds auf das Fehlen eines Effekts schließen

Interpretation oder Spekulation?

- **Interpretation**: bleibt an den Befund gebunden, nennt ihre Annahmen, lässt Alternativen zu
- **Spekulation**: geht über das hinaus, was die Daten tragen können – erlaubt, wenn sie so heißt
- Prüffrage: Welcher Befund würde meine Deutung widerlegen?
- Pflicht: zu jeder Deutung mindestens eine Gegenhypothese

10.4 p-Hacking erleben: der Vorhersage-Trick

Vier Vorhersagen, alle falsch

Runde	genannte Zahl a_i	Vorhersage p_i	Abweichung $p_i - a_i$
1	5	8	**3**
2	9	10	**1**
3	2	6	**4**
4	7	8	**1**

- keine Vorhersage trifft – aber die Fehler lauten 3, 1, 4, 1

Die Methode ist der Fehlschluss

- jede Vorhersage wurde **nach** der genannten Zahl geschrieben: $p_i = a_i + r_i$
- das Muster war garantiert, egal welche Zahlen kamen
- genau das ist **p-Hacking**: Bedeutung wird nachträglich in Daten hineingerechnet
- dafür braucht es keinen bösen Willen, nur Auswahl nach Sicht der Daten

10.5 Viele Wege, ein Treffer

Begriffe

- **p-Hacking**: Auswertung variieren, bis $p < 0{,}05$ (Simmons u. a. 2011)
- **HARKing**: Hypothese nach den Ergebnissen bilden und als vorab ausgeben (Kerr 1998)
- **Garden of Forking Paths**: viele Gabelungen, auch ohne bewusstes Probieren (Gelman und Loken 2014)
- **Data Dredging**: in großen Datensätzen ohne Hypothese nach Mustern graben

Die Tafel-Auflösung

$$P(\text{mindestens ein Treffer}) \;=\; 1-(1-\alpha)^m$$

m	1	2	5	10	14	20	50	100
$\alpha = 0{,}05$	5 %	9,8 %	22,6 %	40,1 %	51,2 %	64,2 %	92,3 %	99,4 %

- m: Zahl der Versuche (Auswertungen, Hypothesen, Zwischenstände)
- ab $m = 14$ ist ein Zufallstreffer wahrscheinlicher als keiner
- m ist die „Magier-Freiheit“ des Tricks

Die Bayes-Pointe

- viele Hypothesen teilen sich den Vorab-Glauben, jede bekommt nur wenig
- ein Treffer unter vielen war ohnehin zu erwarten
- also bleibt die Posteriori nahe der Priori
- 100 versiegelte Vorhersagen, eine trifft: Erwartung, kein Wunder

Ein Lehrstück aus dem Buch

- Monty-Hall-Feldstudie, Teilnehmende **ohne** Vorwissen
- Trefferquote U1: 25 %, U2: 60 %, U3: 83 %
- Differenz U3 gegen U1: $+58$ Prozentpunkte $[+6;\ +81]$
- aber: sechs gegen acht Personen, Analyse erst nach Sichtung der Daten gerechnet

10.6 Gegenmittel

Präregistrierung

- **vor** der Erhebung festlegen: Hypothesen, n, Ausschlüsse, Auswertung
- öffentlich und mit Zeitstempel hinterlegen
- Abweichungen sind erlaubt, müssen aber berichtet werden
- trennt Vorhersage von Nachhersage (Nosek u. a. 2018)
- das Gegenteil des One-Ahead: Die Vorhersage liegt wirklich vorher im Umschlag

Triangulation

- **Daten**: verschiedene Quellen, Zeitpunkte, Orte
- **Forschende**: mehrere Personen werten unabhängig aus (LE 9)
- **Methoden**: Zahlen und Interviews, Experiment und Beobachtung
- **Theorien**: denselben Befund aus mehreren Perspektiven deuten (Denzin 1970)

Prüffragen an die eigene Auswertung

- Stand meine Auswertung fest, bevor ich die Daten sah?
- Wie viele Wege habe ich ausprobiert, wie viele berichte ich?
- Was ist die beste Gegenhypothese?
- Welche Zusatzdaten würden zwischen beiden entscheiden?
- Hätte meine Auswertung meine Hypothese widerlegen können?

Merke

Ein Muster, das jede Datenlage hervorbringen würde, sagt nichts über die konkrete Datenlage. Wer erst nach dem Blick auf die Daten entscheidet, wonach er sucht, hat keinen Befund, sondern eine Hypothese für die nächste Studie.

10.7 Übung in der Stunde

Befund-Übung (Kleingruppen, 20 Min.)

- fiktive Studie: Tagebuch des Staunens und Klausurpunkte (Übungsblatt Teil A)
- (a) Formulieren Sie die deskriptiven Befunde
- (b) Formulieren Sie zwei konkurrierende Interpretationen
- (c) Welche Zusatzdaten würden zwischen ihnen entscheiden?
- (d) Wie viele Wege hätte man auswerten können?

Selbstbezug (Einzelarbeit, 10 Min.)

- Notieren Sie Ihr bisher wichtigstes Ergebnis im Semesterprojekt
- Haben Sie gezielt nach Bestätigung gesucht?
- Welcher Befund würde Ihre Hypothese herausfordern?
- Wo liegen Ihre eigenen Weggabelungen?

10.8 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- Daten, Befund und Schlussfolgerung unterscheiden
- zu einem Befund konkurrierende Interpretationen formulieren und entscheidende Zusatzdaten benennen
- p-Hacking, HARKing und den Garden of Forking Paths erklären
- die Wahrscheinlichkeit von Zufallstreffern bei m Tests berechnen
- Präregistrierung und Triangulation als Gegenmittel einsetzen

Bis zur nächsten Woche

- **Befund-Übung** fertigstellen (Übungsblatt Teil A, Aufgabe 1)
- **Reflexion** zum Semesterprojekt: Haben Sie Ergebnisse gesucht, die Ihre Hypothese **bestätigen**? Welche Befunde könnten sie **herausfordern**? (Teil B, Aufgabe 3)
- **Tagebuch des Staunens**: eine Entscheidung, die sich frei anfühlte und es vielleicht nicht war
- für LE 11: einen Absatz aus Ihrem Projekt mitbringen, in dem Sie ein Ergebnis deuten