6 Statistik: Signifikanztest und Bayes

Bis hierher hat das Semester gefragt, wie man eine Frage stellt, wie man Quellen prüft und wie man aus einer Vermutung eine Hypothese macht, die scheitern kann. Bevor in LE 7 das Forschungsdesign gebaut wird, führt diese Einheit das Werkzeug ein, mit dem man Daten befragt: die Statistik. Sie kommt bewusst vor dem Design, denn wer weiß, welche Fragen sich mit zwanzig oder dreißig Versuchspersonen überhaupt beantworten lassen, plant anders. Weil die Grundbegriffe sorgfältig eingeführt werden sollen, umfasst die Einheit **zwei Doppelstunden**.

Die *erste Sitzung* beginnt mit drei Bechern und einer Abstimmung, bei der die Mehrheit fast immer danebenliegt. Das ist der eigentliche Grund, warum es Statistik gibt: Unser Gefühl für Wahrscheinlichkeiten ist schlecht geeicht, und zwar nicht zufällig, sondern systematisch. Von dort baut die Sitzung das Handwerkszeug auf: Lage und Streuung, Standardabweichung, den Unterschied zwischen Stichprobe und Grundgesamtheit, den Standardfehler, den Zentralen Grenzwertsatz, der erklärt, warum Mittelwerte so verlässlich normalverteilt sind, das Konfidenzintervall und schließlich den Signifikanztest mit p-Wert und t-Test. Die Studierenden würfeln den Grenzwertsatz selbst an die Tafel.

Die *zweite Sitzung* stellt der frequentistischen Frage (Wie überraschend wären die Daten, wenn nichts dahintersteckt?) die bayesianische gegenüber (Wie stark unterscheiden die Daten zwischen zwei Hypothesen, und was sollte man danach glauben?). Durch alle Beispiele zieht sich die *Basisrate*: Wie häufig ist das Gesuchte überhaupt? Ohne sie lässt sich weder ein positiver Test noch ein signifikanter Befund deuten. Die Studierenden rechnen selbst, als Würfel-Detektive und beim Glaubwürdigkeits-Check einer Behauptung aus dem Netz. Zum Schluss lernen sie eine Arbeitsabfolge, mit der man eine eigene Idee in Gegenhypothesen zerlegt (die Diamond-Technik aus dem Coaching, übersetzt in Forschungsfragen), und halten das Ergebnis auf einer Landkarte fest, die direkt in die Design-Skizze von LE 7 führt.

Die Grafiken der Einheit sind mit Python erzeugt (`tools/le06_figuren.py`); die Simulationen haben feste Startwerte und lassen sich für eigene Varianten leicht abwandeln.

Vorbereitung vor der Stunde: Monty Hall mit drei Bechern (optional: Chop Cup), Würfel-Experimente

Eine Woche vor Sitzung 1

- ☐ Für die Vorführung: drei *undurchsichtige*, gleich aussehende Becher und eine gut sichtbare Kugel (Schaumstoffball, Walnuss). Die Becher müssen von hinten im Saal zu sehen sein; bei großen Räumen eine Dokumentenkamera einplanen.
- ☐ Für das Nachspielen in Paaren: je Paar drei undurchsichtige Pappbecher, eine Kugel (Papierkugel, Erbse, Münze) und ein Würfel. Bei 30 Studierenden 15 Sets plus drei Reserve. Pappbecher und Würfel gibt es im Haushalts- bzw. Spielwarenhandel. Würfel und Becher werden für das Grenzwertsatz-Experiment (Sitzung 1) und die Würfel-Detektive (Sitzung 2) wiederverwendet.
- ☐ Die drei Fälle und die Gegenprobe mit dem blinden Moderator (Buch, Kap. 12d, Beats 2–6) so oft mit echten Bechern durchspielen, dass sie ohne Folie frei erklärt werden können.
- ☐ Optional als Staunmoment des Vortragenden: eine *Chop-Cup-Routine* (ca. 2 Min.). Das Requisit gibt es im Zauberfachhandel. Methode und Einstudierung nach der Anleitung des Herstellers bzw. der Standardliteratur; hier bewusst nicht beschrieben. Die Routine muss sitzen, bevor sie vor Publikum gezeigt wird: mindestens zehn Durchläufe vor dem Spiegel und einer vor einer Testperson.
- ☐ Für das Grenzwertsatz-Experiment an der Tafel eine Zahlengerade von 1 bis 6 in Schritten von 0,2 vorzeichnen (Plan B: Flipchart oder eine geteilte Tabelle, in die alle ihre Mittelwerte eintragen).
- ☐ Rechenbeispiele der Folien einmal selbst mit dem Taschenrechner durchrechnen, damit sie live an der Tafel gelingen.

Eine Woche vor Sitzung 2

- ☐ Für die Würfel-Detektive je Paar einen verschlossenen Umschlag mit einer Rollenkarte vorbereiten. Auf vier von fünf Karten steht „*fair*: Treffer ist nur die 6", auf jeder fünften „*gezinkt*: Treffer sind 5 und 6". Bei 15 Paaren also 12 faire und 3 gezinkte Karten. Die Umschläge mischen; welches Paar welche Karte hat, weiß auch die Lehrperson nicht. So ist die Trefferwahrscheinlichkeit genau $\frac{1}{6}$ bzw. $\frac{1}{3}$, und die Basisrate (ein Fünftel) ist bekannt. Echte Mogelwürfel aus dem Scherzartikelhandel gehen auch, ihre Schieflage ist aber unbekannt; dann fehlt dem Bayes-Faktor die konkrete Alternativhypothese.
- ☐ Für den Glaubwürdigkeits-Check fünf bis sechs Behauptungen auf Karten schreiben (Vorschläge im Hinweis zum Glaubwürdigkeits-Check), darunter mindestens zwei zutreffende. Die Studierenden per Mail bitten, ein Smartphone oder Notebook mitzubringen; WLAN prüfen.
- ☐ Für die Landkarten-Hausaufgabe A3-Blätter bereitlegen (je Person eins) oder in der Ankündigung darum bitten.

Handout und Übungsblatt

- ☐ Handout „Statistik: Signifikanztest und Bayes" sowie Übungsblatt LE 6 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 6). **Teil A** liegt zu Beginn von Sitzung 1 aus: Strichliste für das Monty-Hall-Spiel, das Grenzwertsatz-Experiment und der fiktive Datensatz ($n = 50$) für die Hausaufgabe. **Teil B** liegt zu Beginn von Sitzung 2 aus: Würfel-Detektive mit Rechentabelle, Basisrate, Glaubwürdigkeits-Check, Zeitungsmeldung, Diamant und Auswertungsplan. Das Handout gibt es nach Sitzung 2.
- ☐ Taschenrechner bzw. Smartphone-Rechner erlauben; die Rechnungen auf den Folien brauchen nur Grundrechenarten, Wurzeln und Potenzen.

Am Tag selbst

- ☐ Sitzung 1: Tafel in vier Felder teilen: *Abstimmung* (wechseln / bleiben / egal), *Kursdaten Becher*, *Würfel-Mittelwerte* (Zahlengerade), *Fragen*.
- ☐ Sitzung 2: Feld für die Vierfeldertafel der Würfel-Detektive (fair/gezinkt $\times$ signifikant/nicht signifikant) und eine Spalte „Bayes-Urteil".
- ☐ Becher-Sets vor Beginn auf die Tische verteilen, aber gestapelt lassen, damit niemand vorher experimentiert. Die Umschläge erst zu Beginn der Würfelübung austeilen.
- ☐ Falls die Chop-Cup-Routine gezeigt wird: das präparierte Requisit danach sichtbar wegräumen und das

Monty-Hall-Spiel mit gewöhnlichen Bechern spielen, die man den Studierenden in die Hand gibt. Ein Spiel, dessen Requisiten man misstraut, liefert keine brauchbaren Daten.

Risiken und Plan B. Ein Teil des Kurses kennt das Ziegenproblem. Das schadet nicht, es ist ein Datum: Vor der Abstimmung fragen, wer das Rätsel schon kennt, und beide Gruppen getrennt auszählen. Die Feldstudie des Buchs zeigt, wie stark Vorwissen wirkt (Kap. 12f; siehe Abschnitt „Effektgröße und Power"). Laufen die Paarspiele schleppend, nach 15 Durchgängen abbrechen; der Kurs-Pool reicht dann immer noch für die Rechnung. In Sitzung 2 gilt: Wird die Zeit knapp, wird der Glaubwürdigkeits-Check im Plenum an einer einzigen Behauptung vorgeführt und als Hausaufgabe (Teil B, Aufgabe 6) zu Ende gebracht; die Würfel-Detektive sollten dagegen nicht ausfallen, weil sie Fehler 1. Art, Power und Basisrate in einer einzigen Vierfeldertafel erlebbar machen. Die Münzwurf-„Hellseher"-Demo ist optional; sie kehrt in LE 10 ausführlich wieder.

Ablauf der ersten Doppelstunde (90 Min.)

0–10 · Staunmoment. Optional die Chop-Cup-Routine. Dann Monty Hall live mit drei Bechern; Abstimmung wechseln / bleiben / egal. Ergebnis an die Tafel, ohne Kommentar.

10–20 · Nachspielen. 20–24 Durchgänge in Paaren nach festen Regeln (Würfel legt die Kugel, Strategie wechselt jede Runde), Strichliste auf dem Übungsblatt Teil A (Aufgabe 1). Summen an die Tafel.

20–30 · Auflösung. Die drei Fälle, der blinde Moderator, bedingte Wahrscheinlichkeit. Beschreiben und Schließen, Skalenniveaus.

30–42 · Lage und Streuung. Mittelwert und Median, die Standardabweichung Schritt für Schritt an der Tafel, Boxplot und Ausreißer.

42–62 · Von der Stichprobe zur Grundgesamtheit. Parameter und Kennwerte, Standardfehler, Grenzwertsatz-Experiment mit Würfeln (Teil A, Aufgabe 2), Normalverteilung und z-Wert, Konfidenzintervall.

62–85 · Der Signifikanztest. Logik; der Kurs-Pool Schritt für Schritt mit den echten Kursdaten; t-Test von Hand; zwei Arten, sich zu irren; was der p-Wert nicht sagt.

85–90 · Ausblick. Hausaufgabe Datensatz-Analyse (Teil A, Aufgabe 3); Vorschau auf Sitzung 2: Was fehlt dem p-Wert?

Ablauf der zweiten Doppelstunde (90 Min.)

0–5 · Rückblick. Teil B austeilen. Eine Frage an den Kurs: „$p = 0{,}02$ – wie wahrscheinlich ist H_0?" Antworten sammeln, nicht auflösen.

5–15 · Zwei Arten, Daten zu befragen. Würfeltest frequentistisch; der Medizintest als Baum mit natürlichen Häufigkeiten.

15–32 · Basisrate und Bayes. Wie viele signifikante Befunde stimmen; Bayes in Chancenform; derselbe Würfel bayesianisch; der Posterior wandert mit den Daten; Bayes-Faktor zum t-Test; Vergleich der beiden Schulen.

32–47 · Würfel-Detektive. Spielregeln erklären, Paare, 30 Würfe, beide Auswertungen (Teil B, Aufgabe 4), Auflösung, Vierfeldertafel an der Tafel.

47–60 · Glaubwürdigkeits-Check. Das Schokoladen-Beispiel vorrechnen, dann Kleingruppen mit je einer Behauptung und einer Suchmaschine (Aufgabe 6); zwei Gruppen berichten.

60–68 · Was kann Ihr Projekt beantworten? Effektgröße, Power, Folgerungen für das Design.

68–88 · Diamant und Landkarte. Den Diamanten zum Zaubertrick-Beispiel gemeinsam an der Tafel füllen, Ta-

belle „Welche Beobachtung trennt?“, Beispielkarte zeigen; Beginn des eigenen Diamanten in Paaren (Aufgabe 8).

88–90 · Hausaufgaben. Handout austeilen.

6.1 Staunmoment: Drei Becher

★ Staunmoment: Wechseln oder bleiben?

Unter einem von drei Bechern liegt eine Kugel. Sie zeigen auf einen. Ich weiß, wo die Kugel ist, und hebe einen *anderen*, leeren Becher hoch.
Bleiben Sie bei Ihrem Becher – oder wechseln Sie zum anderen? Oder ist es egal?

Abstimmung

- Hand hoch: **bleiben** – **wechseln** – **egal**
- Wer kennt das Rätsel schon? (getrennt zählen)
- Wie sicher sind Sie? Schätzen Sie in Prozent.

Die Abstimmung wird an der Tafel festgehalten und vorerst nicht kommentiert. In der Regel stimmt die Mehrheit für „egal“, oft mit hoher Sicherheit. Das Rätsel ist als *Ziegenproblem* bekannt geworden; es geht auf Selvin (1975) zurück und wurde durch die Kolumne von vos Savant (1990) berühmt, auf die zahlreiche Leserbriefe mit der Behauptung antworteten, die Lösung sei falsch. Krauss und Wang (2003) zeigen, wie hartnäckig die Fehlintuition ist und welche Darstellungen helfen.

Nachspielen: die Regeln

- in Paaren: eine Person ist *Spielleitung*, eine spielt
- Spielleitung würfelt verdeckt: 1–2 Becher A, 3–4 B, 5–6 C
- Spielleitung kennt die Lage und öffnet immer einen *leeren* Becher, nie den gewählten
- ungerade Runden: **bleiben**, gerade Runden: **wechseln**
- 20–30 Runden, Strichliste auf dem Übungsblatt Teil A

Die Regeln sind bereits ein kleines Forschungsdesign. Der Würfel sorgt für eine zufällige Lage der Kugel, damit die Spielleitung nicht unbewusst Lieblingsbecher bevorzugt. Die feste Abfolge von Bleiben und Wechseln verhindert, dass die spielende Person ihre Strategie nach Gefühl wählt und damit die Vergleichbarkeit der beiden Strategien zerstört. Hat die spielende Person zufällig den Becher mit der Kugel gewählt, entscheidet ein zweiter Wurf (gerade oder ungerade), welchen der beiden leeren Becher die Spielleitung öffnet.

Was sagen die Daten?

- Kursdaten an der Tafel: Gewinne beim **Bleiben** und beim **Wechseln**
- Passt das zu „egal“?
- Was müsste herauskommen, wenn es egal wäre?
- Wie groß darf die Abweichung sein, bevor wir „egal“ aufgeben?

Mit der letzten Frage ist die Einheit beim Kern der schließenden Statistik angekommen, noch bevor das Wort fällt. Die Gruppe hat eine Hypothese („egal“, also Gewinnchance $\frac{1}{2}$ beim Wechseln), eine Stichprobe (die Strichlisten) und eine Abweichung, deren Gewicht sie beurteilen muss.

6.2 Auflösung: bedingte Wahrscheinlichkeit

Die Auflösung folgt der Becher-Erklärung aus dem Buch (Kap. 12d, Beats 2–6). Der Vorgang hat zwei Stufen: Zuerst liegt die Kugel zufällig unter einem von drei Bechern, jeder mit Wahrscheinlichkeit $\frac{1}{3}$. Dann öffnet die Spielleitung einen Becher, aber nicht irgendeinen: nie den gewählten und nie den mit der Kugel. Die Fehlintuition „zwei Becher, also fifty-fifty" beruht auf der stillen Annahme, die beiden übrigen Becher seien gleichberechtigt. Das sind sie nicht. Der gewählte Becher wurde nie angefasst; der andere ist der Überlebende einer Auswahl, die mit Wissen getroffen wurde.

Die drei Fälle

Kugel liegt …	Wahrsch.	Spielleitung öffnet	Wechseln
unter Ihrem Becher 1	$\frac{1}{3}$	Becher 2 oder 3	verliert
unter Becher 2	$\frac{1}{3}$	zwingend Becher 3	gewinnt
unter Becher 3	$\frac{1}{3}$	zwingend Becher 2	gewinnt

- in zwei von drei Fällen *zwingt* die Lage der Kugel die Spielleitung, den richtigen Becher übrig zu lassen
- Wechseln gewinnt mit $\frac{2}{3}$, Bleiben mit $\frac{1}{3}$

Versteckte Information

- Ihr Becher hatte $\frac{1}{3}$ und behält es: Die Spielleitung hätte ihn ohnehin nie geöffnet
- die $\frac{2}{3}$ der beiden anderen Becher sammeln sich auf dem einen, der übrig bleibt
- die Spielleitung sagt kein Wort über die Kugel, aber die *Art ihrer Auswahl* trägt Information

Gegenprobe: der blinde Moderator

- die Spielleitung weiß *nicht*, wo die Kugel ist, und öffnet zufällig einen anderen Becher
- zufällig ist er leer: Das Bild ist exakt dasselbe wie vorher
- jetzt, und nur jetzt, ist es tatsächlich egal
- **dasselbe Sichtbare, zwei verschiedene Prozesse, zwei verschiedene Wahrscheinlichkeiten**

Die Präzisierung aus dem Buch gehört dazu: Beim blinden Moderator gilt fifty-fifty *unter der Bedingung*, dass er zufällig einen leeren Becher erwischt hat; deckt er die Kugel auf, ist die Runde hinfällig. Der Unterschied zwischen beiden Spielvarianten liegt allein darin, ob der zweite Schritt an die Lage der Kugel gekoppelt ist. Für die Statistik ist das die wichtigste Lehre des Rätsels: Wer nur auf das Ergebnis schaut, kann die beiden Fälle nicht unterscheiden. Wer fragt, wie die Daten zustande gekommen sind, kann es.

Bedingte Wahrscheinlichkeit

Definition 6.1 Die **bedingte Wahrscheinlichkeit** $P(A \mid B)$ ist die Wahrscheinlichkeit von A unter der Voraussetzung, dass B eingetreten ist: $P(A \mid B) = P(A \cap B) \,/\, P(B)$.

- Monty Hall: $P(\text{Kugel unter dem anderen Becher} \mid \text{ein leerer wurde geöffnet})$
- wissende und blinde Spielleitung erzeugen *verschiedene* Bedingungen, obwohl das Bild gleich ist

Merke

Wahrscheinlichkeiten hängen nicht am Bild, sondern am Prozess, der das Bild erzeugt hat. Vor jeder Auswertung steht deshalb die Frage: Wie sind diese Daten zustande gekommen?

6.3 Beschreiben und Schließen

Die Strichlisten der Paare sind ein kleiner Datensatz. Mit ihm lassen sich zwei grundverschiedene Dinge tun. Man kann ihn *beschreiben*: Wie oft hat Wechseln in unserem Kurs gewonnen? Das ist deskriptive Statistik; sie fasst vorliegende Daten zusammen und sagt nichts über Fälle, die nicht erhoben wurden. Man kann aber auch über den Kurs hinaus *schließen*: Ist die Gewinnchance beim Wechseln in diesem Spiel überhaupt, also in allen denkbaren Runden, größer als ein Halb? Das ist Inferenzstatistik. Sie behandelt die erhobenen Daten als Stichprobe aus einer Grundgesamtheit und muss deshalb mit Zufallsschwankungen rechnen. Ein Standardlehrbuch für beide Teile ist Döring und Bortz (2016b).

Zwei Aufgaben der Statistik

Deskriptive Statistik	Inferenzstatistik
beschreibt die vorliegenden Daten	schließt von der Stichprobe auf die Grundgesamtheit
Kennwerte, Tabellen, Grafiken	Tests, Konfidenzintervalle, Modelle
„In unserem Kurs gewann Wechseln in 64 % der Runden.“	„Wechseln gewinnt häufiger als in der Hälfte der Fälle.“

Die 64 % in der Tabelle sind ein Rechenbeispiel, kein Befund.

Skalenniveaus

Skala	sinnvoll ist …	Beispiel	Lagemaß
nominal	gleich / ungleich	Strategie (bleiben, wechseln)	Modus
ordinal	zusätzlich größer / kleiner	Staunen 1–5	Median
intervall	zusätzlich Abstände	Temperatur in °C	Mittelwert
verhältnis	zusätzlich echter Nullpunkt	Ausschlag in mm	Mittelwert

- das Skalenniveau entscheidet, welche Rechnungen erlaubt sind

Der häufigste Fehler betrifft Ratingskalen. Eine Antwort von 4 auf einer Skala von 1 bis 5 ist nicht „doppelt so viel“ wie eine 2, und ob die Abstände zwischen den Stufen gleich groß sind, weiß niemand. In der Praxis werden Mittelwerte aus Likert-Items trotzdem oft berichtet; wer das tut, sollte es begründen und den Median mit angeben.

6.4 Lage, Streuung und Ausreißer

Ein Datensatz lässt sich durch zwei Fragen grob erfassen: Wo liegt seine Mitte, und wie weit streuen die Werte um sie herum? Für die Mitte stehen Modus, Median und arithmetisches Mittel zur Verfügung. Der Median ist der Wert, unter und über dem jeweils die Hälfte der Daten liegt; das Mittel ist die Summe geteilt durch die Anzahl. Bei symmetrischen Verteilungen liegen beide nahe beieinander. Bei schiefen Verteilungen oder einzelnen Extremwerten wird das Mittel in Richtung der Ausreißer gezogen, der Median bleibt stabil. Für die Streuung sind Spannweite, Quartilsabstand und Standardabweichung gebräuchlich. Die Standardabweichung misst die typische Entfernung der Werte vom Mittelwert und ist ebenso ausreißerempfindlich wie dieser.

Lage: Wo liegt die Mitte?

- **Modus**: der häufigste Wert
- **Median** $\tilde{x}$: die Hälfte liegt darunter, die Hälfte darüber
- **Mittelwert** $\bar{x} = \frac{1}{n} \sum x_i$

- Gedankenexperiment: zehn Gäste in einer Kneipe, ihr mittleres Einkommen – dann kommt eine Milliardärin herein

Durch eine einzige Person steigt der Mittelwert ins Absurde, der Median ändert sich kaum. Welcher Kennwert „richtig" ist, hängt von der Frage ab. Wer wissen will, was eine typische Person verdient, nimmt den Median; wer wissen will, wie viel Geld insgesamt im Raum ist, braucht den Mittelwert.

Streuung: Wie verschieden sind die Werte?

- **Spannweite**: Maximum minus Minimum
- **Quartile** Q_1, Q_3: ein bzw. drei Viertel der Werte liegen darunter
- **Quartilsabstand** *IQR* $= Q_3 - Q_1$: Breite der mittleren Hälfte
- **Varianz** s^2: mittlere quadrierte Abweichung vom Mittelwert
- **Standardabweichung** $s = \sqrt{s^2}$: typischer Abstand eines Werts vom Mittelwert, in der Einheit der Daten

Die Standardabweichung Schritt für Schritt

Acht Personen, behaltene Begriffe (von 20) nach einem Lehrvideo mit Zaubertrick:

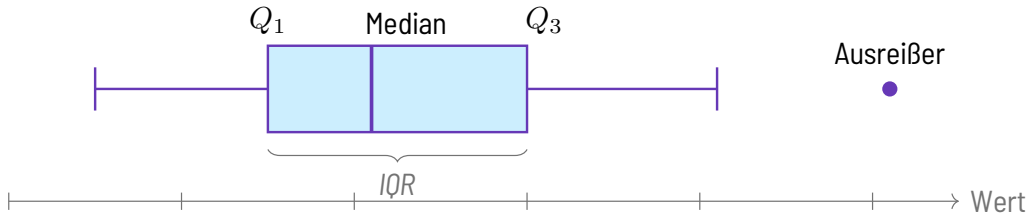
Fiktives Beispiel, angelehnt an die Videostudie aus dem Buch (Kap. 12d, Fallbeispiel in LE 7); die Zahlen sind erfunden.

Wert x_i	13	10	15	11	14	11	15	11	$\Sigma = 100$
Abweichung $x_i - \bar{x}$	0,5	$-2{,}5$	2,5	$-1{,}5$	1,5	$-1{,}5$	2,5	$-1{,}5$	0
Quadrat $(x_i - \bar{x})^2$	0,25	6,25	6,25	2,25	2,25	2,25	6,25	2,25	28

- Mittelwert $\bar{x} = 100/8 = 12{,}5$
- Abweichungen summieren sich immer zu 0 $\Rightarrow$ erst quadrieren, dann mitteln
- Varianz $s^2 = 28 \,/\, (8-1) = 4$, Standardabweichung $s = \sqrt{4} = 2$
- Probe: 5 von 8 Werten liegen in $\bar{x} \pm s$, also zwischen 10,5 und 14,5

Das Lehrvideo-Beispiel ist erfunden. Es lehnt sich an die Becher-Monty-Hall-Videostudie des Buchs an (*WuZ-Buch*, Kap. 12d): ein rund 13-minütiges Erklärvideo, das die Treatment-Gruppe mit, die Kontrollgruppe ohne einen zweiminütigen Zaubertrick sieht. Die echte Studie misst Verständnis und Transfer zum Monty-Hall-Problem, nicht „behaltene Begriffe"; Zielgröße und Zahlen sind hier frei gewählt, damit sich alles im Kopf rechnen lässt. Das sollte man in der Stunde einmal ausdrücklich sagen, weil die Studie in LE 7 als echtes Fallbeispiel wiederkehrt. Die Daten sind dieselben wie im t-Test-Beispiel weiter unten (Gruppe mit Zaubertrick); wer die Standardabweichung hier an der Tafel gerechnet hat, kennt beim t-Test schon die Hälfte. Geteilt wird durch $n - 1$ statt durch n, weil die Abweichungen vom *Stichproben*mittel gemessen werden, das selbst aus den Daten geschätzt ist und deshalb immer etwas näher an den Werten liegt als das wahre Mittel; ohne die Korrektur würde die Streuung der Grundgesamtheit systematisch unterschätzt. Bei normalverteilten Daten liegen etwa zwei Drittel der Werte innerhalb von $\bar{x} \pm s$; die Probe auf der Folie (5 von 8) passt dazu.

Boxplot und Ausreißerregel



- Box = mittlere Hälfte, Strich = Median, Antennen bis zum letzten unauffälligen Wert
- Ausreißer nach Tukey (1977): mehr als $1{,}5 \cdot$ *IQR* unter Q_1 oder über Q_3

Was tun mit Ausreißern?

- zuerst prüfen: Messfehler, Tippfehler – oder ein echter Fall?
- **nie** still löschen, weil er „stört"
- Regel *vor* der Auswertung festlegen und berichten
- im Zweifel beide Auswertungen zeigen: mit und ohne

Ausreißer sind die erste Stelle, an der die Freiheit der Auswertung beginnt. Wer erst nach dem Blick auf das Ergebnis entscheidet, ob ein Extremwert drin bleibt, hat bereits einen Pfad im „Garten der sich verzweigenden Wege" gewählt (Gelman und Loken 2014). Darauf kommt LE 10 ausführlich zurück.

Daten zeigen, nicht verstecken

- Histogramm und Boxplot für metrische Daten, Balken für Häufigkeiten
- Achsen beschriften, Einheit angeben, n nennen
- Fallstricke: abgeschnittene y-Achse, 3D-Effekte, Mittelwertbalken ohne Streuung
- wenn möglich: die einzelnen Datenpunkte zeigen

Eine abgeschnittene Achse ist nicht in jedem Fall unzulässig, sie muss aber erkennbar sein. Ein Balkendiagramm, das nur zwei Mittelwerte zeigt, verschweigt, wie stark sich die Gruppen überlappen. Je kleiner der Datensatz, desto eher sollte man alle Punkte zeigen.

6.5 Von der Stichprobe zur Grundgesamtheit

Die Strichlisten des Kurses sind eine *Stichprobe*. Was uns eigentlich interessiert, ist die *Grundgesamtheit*: alle denkbaren Runden dieses Spiels, alle Studierenden, die ein Lehrvideo sehen könnten. Deren Kennzahlen heißen *Parameter* und werden mit griechischen Buchstaben geschrieben (μ, σ, π); sie sind unbekannt. Aus der Stichprobe berechnen wir *Kennwerte* ($\bar{x}$, s, $\hat{p}$) und schätzen damit die Parameter. Jede neue Stichprobe liefert etwas andere Kennwerte. Wie stark sie von Stichprobe zu Stichprobe schwanken, misst der *Standardfehler*. Er ist die wichtigste Zahl der schließenden Statistik, und er wird oft mit der Standardabweichung verwechselt: Die Standardabweichung beschreibt, wie verschieden die *einzelnen Werte* sind; der Standardfehler beschreibt, wie genau der *Mittelwert* bestimmt ist. Die Standardabweichung bleibt bei wachsendem n ungefähr gleich, der Standardfehler schrumpft mit $1/\sqrt{n}$.

Dass man mit Mittelwerten so bequem rechnen kann, verdankt sich dem *Zentralen Grenzwertsatz*: Mittelwerte (und Summen, und Anteile) aus hinreichend großen Stichproben unabhängiger Werte sind annähernd normalverteilt, mit dem Mittelwert der Grundgesamtheit als Zentrum und dem Standardfehler als Breite, und zwar weitgehend unabhängig davon, wie die einzelnen Werte verteilt sind. Wie groß „hinreichend" ist, hängt von der Schiefe der Grundverteilung ab: Bei Würfeln genügen fünf Werte, bei stark schiefen Verteilungen braucht es dreißig und mehr. Der Satz ist der Grund, warum Konfidenzintervalle und t-Tests auch dann funktionieren, wenn die Rohdaten nicht glockenförmig aussehen.

Stichprobe und Grundgesamtheit

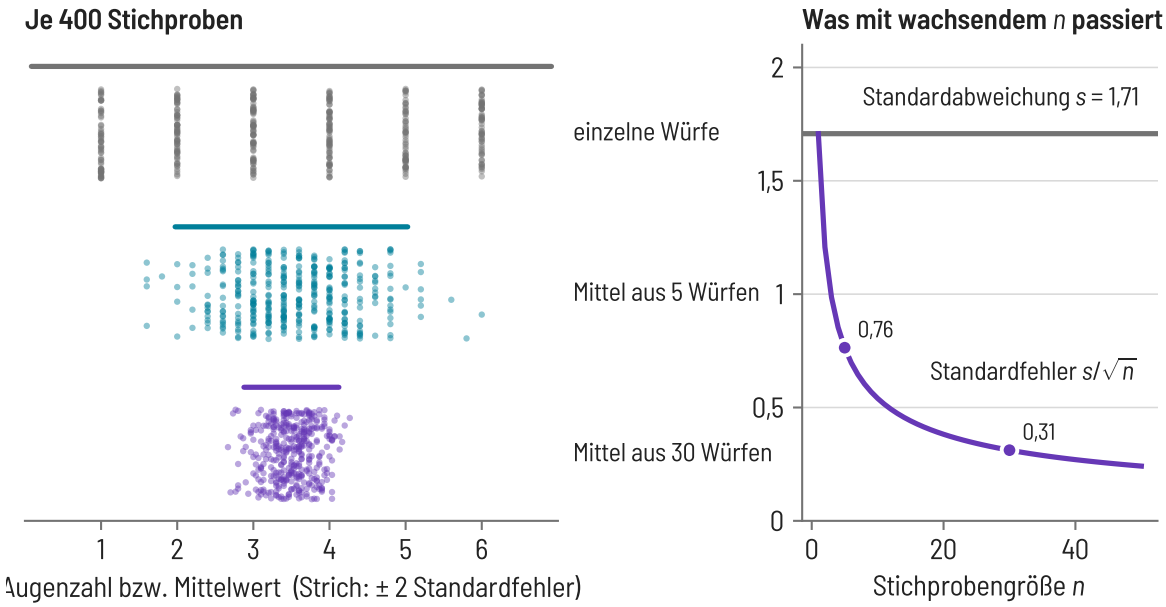
	Grundgesamtheit (Parameter) unbekannt, fest	**Stichprobe (Kennwert)** bekannt, schwankt
Mittelwert	μ	$\bar{x}$
Standardabweichung	σ	s
Anteil (z. B. Gewinnquote)	π	$\hat{p}$

- Monty Hall: π = Gewinnquote beim Wechseln in *allen* denkbaren Runden, $\hat{p}$ = Quote in unseren Runden
- Kernfrage: Wie weit kann $\hat{p}$ *zufällig* von π abweichen?

Der Standardfehler

- **Standardabweichung** s: Wie verschieden sind die *einzelnen Werte*?
- **Standardfehler** *SE*: Wie stark würde der *Mittelwert* schwanken, wenn man die Studie wiederholt?
- für einen Mittelwert: $SE = s \,/\, \sqrt{n}$; für einen Anteil: $SE = \sqrt{\hat{p}\,(1-\hat{p})\,/\,n}$
- Beispiel: $s = 2, n = 8 \Rightarrow SE = 2/\sqrt{8} \approx 0{,}71$
- viermal so viele Personen $\Rightarrow$ halber Standardfehler

Standardabweichung und Standardfehler im Bild



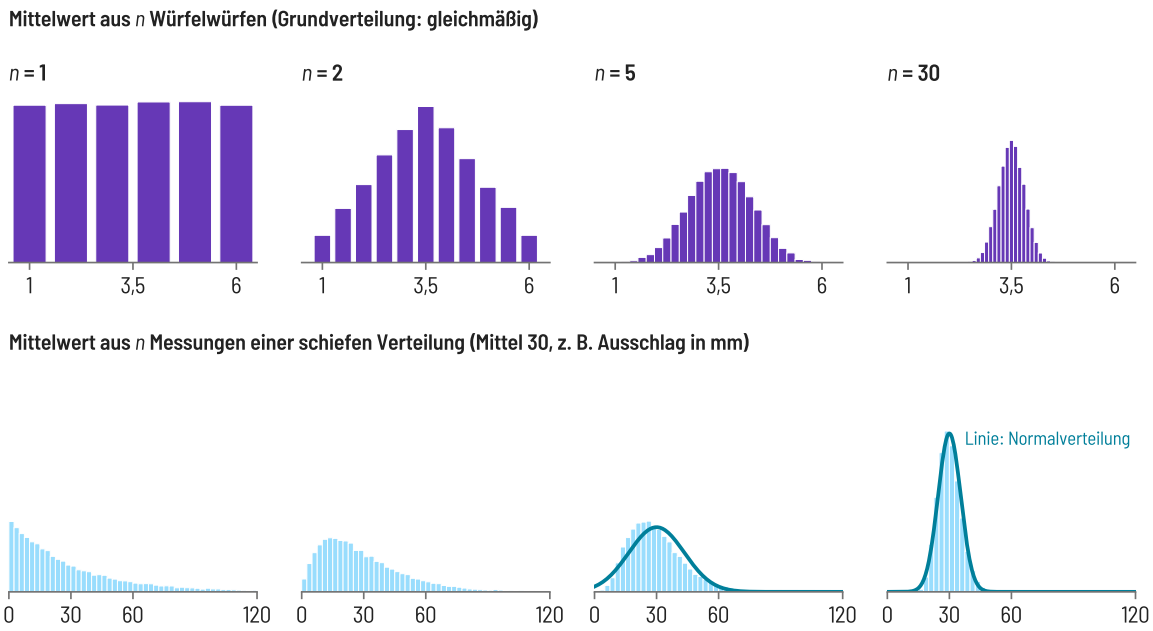
- einzelne Würfe streuen immer gleich stark ($s = 1{,}71$), Mittelwerte umso weniger, je mehr Würfe sie zusammenfassen

Die Grafik zeigt je 400 simulierte Stichproben. Links: einzelne Würfe (oben), Mittelwerte aus 5 Würfen (Mitte) und aus 30 Würfen (unten); der Strich darüber markiert jeweils $3{,}5 \pm 2\,SE$. Rechts: Die Standardabweichung eines Wurfs bleibt bei 1,71, ganz gleich, wie viele Würfe man macht; der Standardfehler des Mittelwerts fällt von 1,71 über 0,76 ($n = 5$) auf 0,31 ($n = 30$).

Der Zentrale Grenzwertsatz

- Mittelwerte aus n unabhängigen Werten sind für großes n annähernd **normalverteilt**
- Zentrum: μ, Breite: der Standardfehler $\sigma/\sqrt{n}$
- **egal, wie die einzelnen Werte verteilt sind** – gleichmäßig, schief, mit Ausreißern
- deshalb funktionieren Konfidenzintervall und t-Test auch bei nicht glockenförmigen Daten
- „großes n“: bei Würfeln ab etwa 5, bei sehr schiefen Daten ab 30 und mehr

Der Grenzwertsatz im Bild



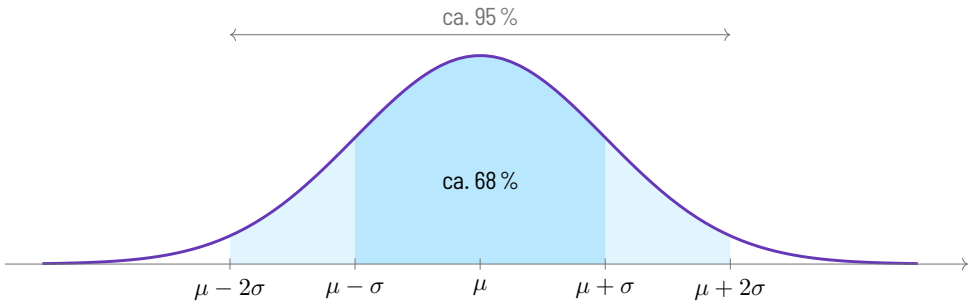
Je 20 000 simulierte Stichproben. Oben die Würfel: Ein einzelner Wurf ist gleichverteilt, schon der Mittelwert aus zwei Würfen ist dreieckig, ab fünf Würfen glockenförmig. Unten eine stark rechtsschiefe Verteilung mit Mittelwert 30, wie sie bei Pendelausschlägen in Millimetern vorkommt (Exponentialverteilung): Hier braucht der Mittelwert deutlich mehr Werte, bis er der eingezeichneten Normalverteilung folgt.

Selbst würfeln: Mittelwerte an der Tafel

- jede Person würfelt **fünfmal** und berechnet den Mittelwert (Teil A, Aufgabe 2)
- das viermal, dann alle vier Mittelwerte als Punkte auf die Zahlengerade an der Tafel
- Vorhersage vorher: Zentrum 3,5, Standardfehler $1{,}71/\sqrt{5} \approx 0{,}76$
- also liegen etwa 95 % der Punkte zwischen $3{,}5 \pm 2 \cdot 0{,}76$, d. h. zwischen 2,0 und 5,0
- stimmt die Vorhersage? Wie sähe das Bild mit 20 Würfen aus?

Das Experiment dauert etwa acht Minuten. Mit 30 Personen entstehen 120 Punkte, genug für eine erkennbare Glocke. Die Standardabweichung eines einzelnen Wurfs ist $\sqrt{35/12} \approx 1{,}71$. Mit 20 Würfen wäre der Standardfehler $1{,}71/\sqrt{20} \approx 0{,}38$, die Glocke also halb so breit. Wer mag, lässt die Hälfte des Kurses mit zwei Würfen pro Mittelwert arbeiten und vergleicht die beiden Bilder.

Die Normalverteilung



Der z-Wert: Abstand in Standardfehlern

- $z =$ (Kennwert − Erwartung) / *SE*
- misst, wie viele Standardfehler ein Ergebnis von dem entfernt ist, was man erwartet hat

- bei Normalverteilung: $|z| > 1{,}96$ kommt nur in 5 % der Fälle vor, $|z| > 3$ in 0,3 %
- Beispiel Würfel: Mittelwert aus 5 Würfen ist 5,2; $z = (5{,}2 - 3{,}5)/0{,}76 \approx 2{,}2$ – auffällig

Das Konfidenzintervall

- **Schätzwert $\pm$ 1,96 Standardfehler** (bei kleinem n: t statt 1,96)
- fiktive Lehrvideo-Gruppe (Folie zur Standardabweichung): $12{,}5 \pm 2{,}36 \cdot 0{,}71$, also etwa 10,8 bis 14,2 Begriffe
- Bedeutung: Das *Verfahren* fängt den wahren Wert in 95 % aller Wiederholungen ein
- *nicht*: „Mit 95 % liegt μ in diesem Intervall" – das wäre eine bayesianische Aussage (Sitzung 2)
- ein Intervall sagt mehr als ein p-Wert: Es zeigt, welche Werte mit den Daten verträglich sind

Für $n = 8$ ist der kritische Wert der t-Verteilung mit 7 Freiheitsgraden 2,36 statt 1,96; die t-Verteilung hat breitere Ränder, weil auch die Standardabweichung nur geschätzt ist. Ab etwa 30 Werten ist der Unterschied klein. Die Deutung des Konfidenzintervalls ist eine der häufigsten Fehlerquellen: Für ein *einzelnes* berechnetes Intervall ist der wahre Wert entweder drin oder nicht. Die 95 % beschreiben das Verfahren über viele Wiederholungen, wie die nächste Folie zeigt.

Rechenweg: Konfidenzintervall für einen Mittelwert

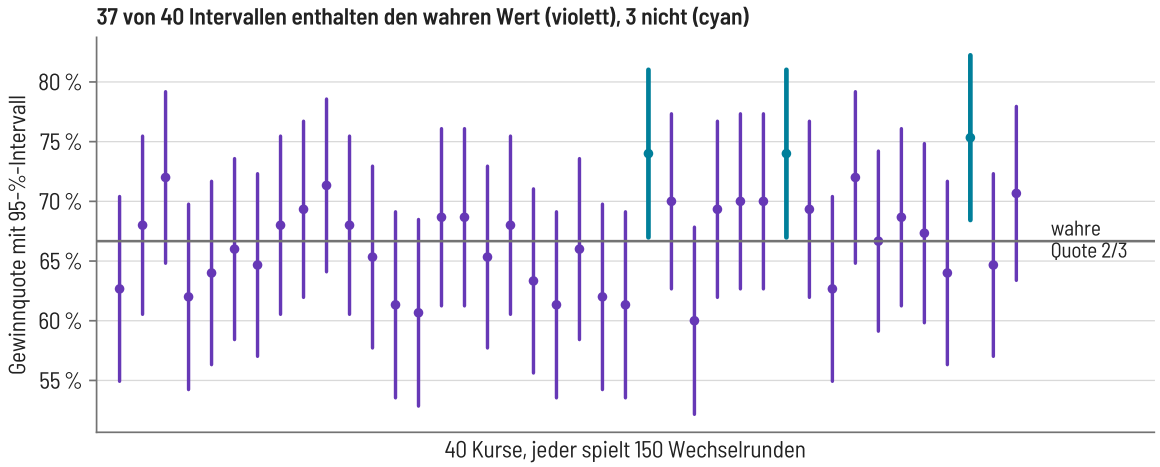
Fiktive Lehrvideo-Gruppe: $n = 8$, $\bar{x} = 12{,}5$, $s = 2$

Schritt	Was	Rechnung
1	Standardfehler	$SE = s/\sqrt{n} = 2/\sqrt{8} = 2/2{,}83 \approx 0{,}71$
2	Freiheitsgrade	$df = n - 1 = 7$
3	kritischer Wert (t-Tabelle, 95 %, zweiseitig)	$t_7 = 2{,}36$ (bei großem n: 1,96)
4	halbe Breite des Intervalls	$2{,}36 \cdot 0{,}71 \approx 1{,}67$
5	untere Grenze	$12{,}5 - 1{,}67 = 10{,}83$
6	obere Grenze	$12{,}5 + 1{,}67 = 14{,}17$

- Ergebnis: 95-%-Intervall von etwa **10,8 bis 14,2** behaltenen Begriffen
- doppelt so viele Personen ($n = 16$): $SE = 0{,}5$, Intervall etwa 11,4 bis 13,6

Für $n = 16$ ist $t_{15} = 2{,}13$, die halbe Breite also $2{,}13 \cdot 0{,}5 \approx 1{,}07$. Den kritischen Wert 2,36 liefert in Tabellenkalkulationen die Formel `T.INV.2T(0,05;7)`.

Was „95 %" bedeutet



Simulation: 40 Kurse spielen je 150 Wechselrunden, die wahre Gewinnquote ist $\frac{2}{3}$. Jeder Kurs berechnet sein 95-%-Intervall ($\hat{p} \pm 1{,}96\,SE$). Im Mittel verfehlen 2 von 40 Intervallen den wahren Wert; in dieser Simulation sind es 3. Kein einzelner Kurs kann wissen, ob er zu den Pechvögeln gehört.

6.6 Der Signifikanztest

Der Signifikanztest dreht die Frage des Konfidenzintervalls um. Statt zu fragen, welche Werte mit den Daten verträglich sind, nimmt er einen bestimmten Wert an, die Nullhypothese, und fragt, wie überraschend die Daten wären, wenn dieser Wert stimmt. Das Maß dafür ist der p-Wert. Die Rechnung folgt immer demselben Muster: Erwartung unter H_0, Standardfehler unter H_0, Abstand in Standardfehlern, Wahrscheinlichkeit für einen mindestens so großen Abstand. Am Kurs-Pool lässt sich jeder Schritt mit dem Taschenrechner nachvollziehen.

Die Logik des Signifikanztests

- **Nullhypothese** H_0: Es gibt keinen Effekt („Wechseln gewinnt mit $\frac{1}{2}$“)
- Frage: Wie wahrscheinlich wären Daten, die *mindestens so extrem* sind wie unsere, *wenn* H_0 *stimmt*?
- diese Wahrscheinlichkeit ist der **p-Wert**
- ist p kleiner als eine vorab gewählte Schwelle α (meist $0{,}05$), verwirft man H_0

Der Kurs-Pool: Was haben wir gemessen?

- jedes Paar hat etwa 12 Wechselrunden gespielt – zu wenig für ein Urteil (siehe die Streuung an der Tafel)
- darum legen wir **alle Wechselrunden des Kurses zusammen**: der Kurs-Pool
- Rechenbeispiel: 15 Paare $\times$ 10 Wechselrunden = **150 Runden**, davon **97 gewonnen**
- Quote $\hat{p} = 97/150 = 64{,}7\,\%$
- Frage: Kann das Zufall sein, wenn Wechseln in Wahrheit egal ist ($\pi = \frac{1}{2}$)?

In der Stunde werden die echten Summen von der Tafel eingesetzt; die Folien rechnen mit konstruierten Zahlen, damit die Rechnung vorbereitet ist. Zehn Wechselrunden pro Paar sind realistisch, wenn nach 20 Runden abgebrochen wird. Die Pointe des Pools: Kein einzelnes Paar kann mit seinen 10 bis 12 Runden zwischen $\frac{1}{2}$ und $\frac{2}{3}$ sicher unterscheiden, der Kurs zusammen sehr wohl. Das ist der Standardfehler in Aktion.

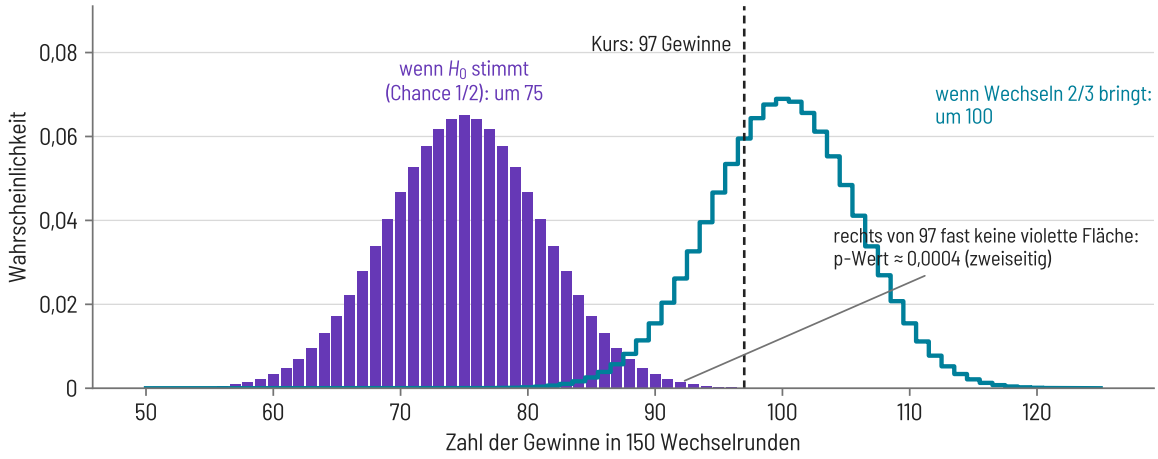
Der Kurs-Pool Schritt für Schritt

Schritt	Frage	Rechnung
1	Was erwarten wir, wenn H_0 stimmt?	$150 \cdot \frac{1}{2} = 75$ Gewinne
2	Wie stark schwankt die Gewinnzahl unter H_0?	$\sqrt{150 \cdot \frac{1}{2} \cdot \frac{1}{2}} \approx 6{,}1$
3	Wie weit liegen wir daneben?	$z = (97 - 75)/6{,}1 \approx 3{,}6$
4	Wie oft käme das unter H_0 vor?	$p \approx 0{,}0004$ (zweiseitig)
5	Urteil bei $\alpha = 0{,}05$?	$p < 0{,}05$: H_0 verwerfen
6	Welche Quoten passen zu den Daten?	$0{,}647 \pm 1{,}96\sqrt{\frac{0{,}647 \cdot 0{,}353}{150}}$ $= 0{,}647 \pm 0{,}077$: **57 % bis 72 %**

- $\frac{2}{3}$ liegt im Intervall, $\frac{1}{2}$ nicht

Schritt 2 ist die Standardabweichung der Binomialverteilung, $\sqrt{n\,\pi\,(1-\pi)}$; in Anteilen ausgedrückt ist das der Standardfehler $\sqrt{0{,}25/150} \approx 0{,}041$. Ein Abstand von 3,6 Standardfehlern ist nach der Normalverteilung sehr selten ($p \approx 0{,}0003$); der exakte Binomialtest liefert $p \approx 0{,}0004$. Beides genügt; in der Stunde reicht der Hinweis, dass alles jenseits von etwa 2 Standardfehlern bei $\alpha = 0{,}05$ signifikant ist. Das Intervall in Schritt 6 ist das einfache Wald-Intervall; das genauere Wilson-Intervall ergibt praktisch dieselben Grenzen. Die Grafik auf der nächsten Folie zeigt Schritt 1 bis 4 auf einen Blick.

Der Kurs-Pool im Bild



- violett: so verteilen sich die Gewinne, wenn Wechseln egal ist; cyan: wenn Wechseln $\frac{2}{3}$ bringt
- 97 liegt fast außerhalb der violetten Verteilung, mitten in der cyanfarbenen

Der t-Test von Hand

Wie viele von 20 Begriffen behalten Studierende nach einem Lehrvideo? (fiktives Beispiel wie bei der Standardabweichung, je $n = 8$)

	Werte	$\bar{x}$	s
mit Zaubertrick	13, 10, 15, 11, 14, 11, 15, 11	12,5	2,0
ohne Zaubertrick	8, 12, 9, 11, 8, 13, 8, 11	10,0	2,0

- Standardfehler der Differenz: $SE = s \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} = 2 \cdot \sqrt{\frac{1}{4}} = 1{,}0$
- $t = (\bar{x}_1 - \bar{x}_2) \,/\, SE = 2{,}5 \,/\, 1{,}0 = 2{,}5$ mit $df = n_1 + n_2 - 2 = 14$
- kritischer Wert ($\alpha = 0{,}05$, zweiseitig) aus der t-Verteilung: $2{,}14 \Rightarrow$ signifikant, $p = 0{,}025$
- Effektgröße $d = 2{,}5 \,/\, 2{,}0 = 1{,}25$ (groß)

Die Daten sind konstruiert, damit sich alles im Kopf rechnen lässt: beide Gruppen haben dieselbe Standardabweichung $s = 2$, die gepoolte Standardabweichung ist deshalb ebenfalls 2. Allgemein gilt $s_p = \sqrt{((n_1 - 1)s_1^2 + (n_2 - 1)s_2^2)/(n$ Den kritischen Wert liefert jede t-Tabelle oder die Tabellenkalkulation (`T.INV.2T(0,05;14)`), den p-Wert `T.VERT.2S(2,5;` Der t-Test setzt voraus, dass die Werte unabhängig und in beiden Gruppen annähernd normalverteilt sind; bei acht Werten je Gruppe lässt sich das kaum prüfen. Wer ungleiche Streuungen erwartet, nimmt den Welch-Test. Der t-Test kehrt im Bayes-Abschnitt wieder: Dieselben Zahlen ergeben dort einen Bayes-Faktor, der deutlich vorsichtiger klingt als „$p = 0{,}025$“.

Rechenweg: der t-Test Schritt für Schritt

Schritt	Was	Rechnung
1	Mittelwerte	$\bar{x}_1 = 100/8 = 12{,}5$; $\bar{x}_2 = 80/8 = 10{,}0$
2	Quadratsummen	mit Trick: 28 (Folie zur Standardabweichung); ohne: $4+4+1+1+4+9+4+1 = 28$
3	gepoolte Varianz	$s_p^2 = (28+28)/(8+8-2) = 56/14 = 4$, also $s_p = 2$
4	Standardfehler der Differenz	$SE = s_p\sqrt{1/8 + 1/8} = 2 \cdot \sqrt{0{,}25} = 2 \cdot 0{,}5 = 1{,}0$
5	Teststatistik	$t = (12{,}5 - 10{,}0)/1{,}0 = 2{,}5$
6	Vergleich mit der Tabelle	$df = 14$: kritischer Wert $2{,}14$; $2{,}5 > 2{,}14$
7	p-Wert	$p = 0{,}025$ (`T.VERT.2S(2,5;14)`)
8	Effektgröße	$d = (12{,}5 - 10{,}0)/2 = 1{,}25$
9	95-%-Intervall der Differenz	$2{,}5 \pm 2{,}14 \cdot 1{,}0$: **0,4 bis 4,6** Begriffe

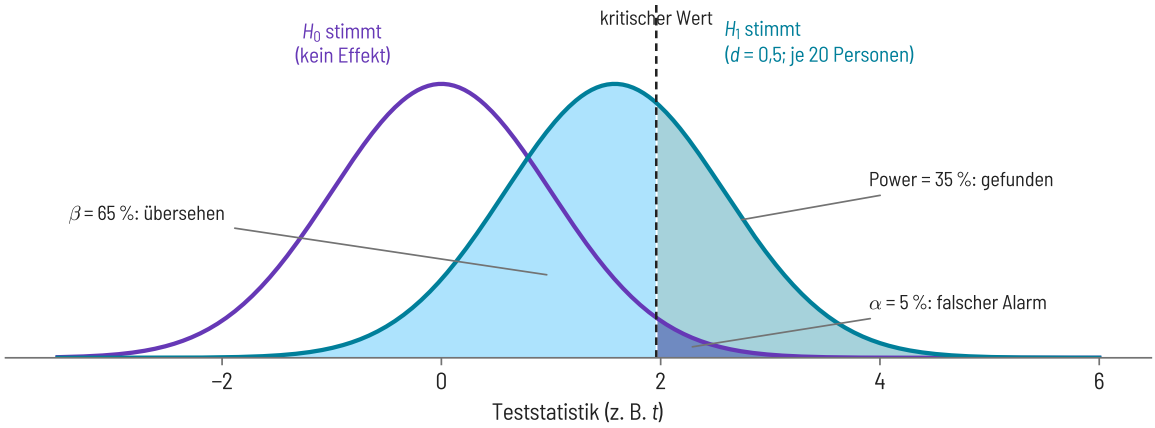
Die Abweichungen in der Gruppe ohne Trick (8, 12, 9, 11, 8, 13, 8, 11; Mittel 10) sind $-2, 2, -1, 1, -2, 3, -2, 1$; ihre Quadrate summieren sich wie in der Trick-Gruppe zu 28. Schritt 9 zeigt, was der p-Wert verschweigt: Mit den Daten verträglich ist ein Unterschied zwischen knapp einem halben und gut viereinhalb Begriffen, also alles von „praktisch nichts" bis „sehr groß".

Zwei Arten, sich zu irren

	H_0 **stimmt**	H_0 **stimmt nicht**
H_0 **verworfen**	Fehler 1. Art (α)	richtig (Power $1-\beta$)
H_0 **beibehalten**	richtig	Fehler 2. Art (β)

- $\alpha = 0{,}05$ heißt: In 5 % der Fälle ohne Effekt meldet der Test trotzdem einen
- ein nicht signifikantes Ergebnis ist kein Beleg für „kein Effekt"

Fehler 1. und 2. Art im Bild



- die Schwelle legt α fest; wie viel Power bleibt, hängt von Effekt und n ab
- mit $d = 0{,}5$ und je 20 Personen wird der Effekt in zwei von drei Studien übersehen

Normalnäherung für den Zwei-Gruppen-Test: Unter H_1 ist die Teststatistik um $d\sqrt{n/2} = 0{,}5 \cdot \sqrt{10} \approx 1{,}58$ verschoben. Die Power ist die Fläche der cyanfarbenen Kurve rechts vom kritischen Wert, hier etwa 35 % (exakt mit der t-Verteilung 34 %, siehe die Power-Tabelle in Sitzung 2).

6.7 Was der p-Wert nicht sagt

Kaum ein statistischer Begriff wird so oft missverstanden wie der p-Wert. Die American Statistical Association hat 2016 eine eigene Stellungnahme veröffentlicht, um die gängigsten Fehldeutungen richtigzustellen (Wasserstein und Lazar 2016). Der Kern: Ein p-Wert beschreibt, wie gut die Daten zu einem bestimmten Modell (der Nullhypothese mit allen Zusatzannahmen) passen. Er sagt nichts darüber, wie wahrscheinlich eine Hypothese ist, und nichts darüber, wie groß oder wichtig ein Effekt ist.

Der p-Wert ist *nicht* …

- die Wahrscheinlichkeit, dass H_0 wahr ist
- die Wahrscheinlichkeit, dass das Ergebnis „Zufall" ist
- ein Maß für die Größe oder Bedeutung eines Effekts

- ein Beweis, weder für noch gegen eine Hypothese
- unabhängig davon, wie viele Tests man gerechnet hat

Warum „p < 0,05“ kein Beweis ist

- p fragt nach $P(\text{Daten} \mid H_0)$
- wir wollen wissen: $P(H \mid \text{Daten})$
- das ist wieder bedingte Wahrscheinlichkeit, und die Richtung der Bedingung lässt sich nicht umdrehen
- was dazwischen fehlt, ist das Vorwissen über H (der Prior)

Die Verwechslung von $P(\text{Daten} \mid H_0)$ mit $P(H_0 \mid \text{Daten})$ ist ein naher Verwandter des Fehlers, den das Ziegenproblem sichtbar macht: Man liest eine Bedingung falsch. Wie man von der einen Wahrscheinlichkeit zur anderen kommt, regelt der Satz von Bayes; dafür braucht man aber eine Vorab-Einschätzung der Hypothese. Ist diese niedrig, bleibt die Hypothese auch nach einem kleinen p-Wert unsicher. Das erklärt, warum überraschende Einzelbefunde so oft nicht replizieren (Ioannidis 2005; Open Science Collaboration 2015).

Sitzung 1 in vier Sätzen

Die Standardabweichung beschreibt die Daten, der Standardfehler die Genauigkeit eines Mittelwerts; er schrumpft mit $\sqrt{n}$. Dank des Zentralen Grenzwertsatzes sind Mittelwerte annähernd normalverteilt. Ein Konfidenzintervall zeigt, welche Werte mit den Daten verträglich sind. Ein p-Wert sagt, wie überraschend die Daten wären, wenn H_0 stimmt – und nicht, wie wahrscheinlich H_0 ist.

6.8 Zweite Sitzung: Testen mit Vorwissen

Die zweite Sitzung beginnt mit der Denkfrage vom Ende der ersten: Wenn $p = 0{,}02$ ist, wie wahrscheinlich ist dann die Nullhypothese? Die meisten Antworten lauten „2 %“, und sie sind falsch. Was zur richtigen Antwort fehlt, ist das Vorwissen: Wie plausibel war die Hypothese vorher, wie häufig ist das Gesuchte überhaupt? Die Sitzung führt deshalb die Basisrate und die bayesianische Statistik ein, lässt die Studierenden beide Denkweisen am Würfel gegeneinander rechnen und endet mit Werkzeugen für das eigene Projekt.

6.9 Zwei Arten, Daten zu befragen

Für den Schritt von der Stichprobe zur Aussage gibt es zwei große Denkschulen. Die *frequentistische* Statistik versteht Wahrscheinlichkeit als relative Häufigkeit in gedachten Wiederholungen. Sie fragt: Wie oft kämen Daten wie unsere heraus, wenn die Nullhypothese stimmt? Über Hypothesen selbst spricht sie keine Wahrscheinlichkeiten aus; eine Hypothese ist wahr oder falsch, nur die Daten schwanken. Die *bayesianische* Statistik versteht Wahrscheinlichkeit als Grad begründeter Überzeugung. Sie fragt: Wie viel besser sagt die eine Hypothese die Daten voraus als die andere, und was sollte ich danach glauben? Dafür braucht sie eine Ausgangseinschätzung, den Prior, und der ist oft nichts anderes als eine *Basisrate*. Beide Schulen rechnen mit denselben Daten. Sie beantworten aber verschiedene Fragen, und wer ein Projekt plant, sollte vorher wissen, welche davon ihn interessiert. Ein gut lesbarer Vergleich beider Schulen mit Rechenbeispielen steht bei Wagenmakers (2007).

Dieselben Daten, zwei Fragen

frequentistisch	bayesianisch
Wie überraschend wären diese Daten, *wenn* H_0 stimmt? $P(\text{Daten} \mid H_0)$ Ergebnis: p-Wert, Konfidenzintervall braucht: H_0, α, geplantes n	Welche Hypothese sagt diese Daten besser voraus? $P(H \mid \text{Daten})$ Ergebnis: Bayes-Faktor, Posterior braucht: H_0, H_1, Prior (Basisrate)

- Leitbeispiel für beide: Ist dieser Würfel gezinkt?

Ist dieser Würfel gezinkt? (frequentistisch)

- 30 Würfe, **10 Sechsen**; bei einem fairen Würfel erwartet man 5
- H_0: Der Würfel ist fair, $P(6) = \frac{1}{6}$
- p-Wert: $P(\text{10 oder mehr Sechsen} \mid H_0) = 0{,}020$ (Binomialverteilung, einseitig)
- $p < 0{,}05$: H_0 wird verworfen, „signifikant gezinkt"
- mit **9 Sechsen**: $p = 0{,}051$, nicht signifikant

Die Werte sind exakt mit der Binomialverteilung $B(30, \frac{1}{6})$ gerechnet; die Tabelle auf dem Übungsblatt (Teil B, Aufgabe 4) enthält $P(X \geq k)$ für alle relevanten k. Einseitig wird hier getestet, weil die Frage gerichtet ist (*zu viele* Sechsen). Zweiseitig ergäbe sich bei 10 Sechsen $p \approx 0{,}024$. Der Sprung von 9 auf 10 Sechsen zeigt, wie willkürlich die Schwelle ist: Eine einzige Sechs mehr oder weniger entscheidet über „signifikant". Die Frage, wie *wahrscheinlich* der Würfel gezinkt ist, beantwortet der Test nicht; dafür fehlt ihm die Information, wie viele gezinkte Würfel es überhaupt gibt.

Rechenweg: der Würfeltest

30 Würfe, 10 Sechsen; H_0: $P(6) = \frac{1}{6}$

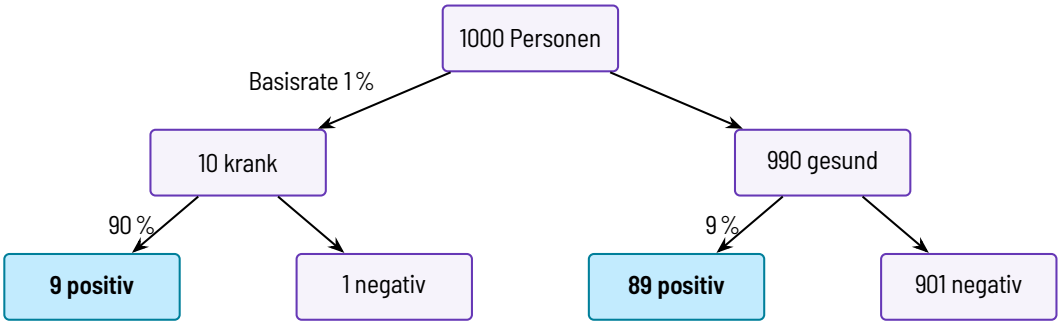
Schritt	Was	Rechnung
1	Erwartung unter H_0	$30 \cdot \frac{1}{6} = 5$ Sechsen
2	Streuung unter H_0	$\sqrt{30 \cdot \frac{1}{6} \cdot \frac{5}{6}} = \sqrt{4{,}17} \approx 2{,}04$
3	Abstand in Standardabweichungen	$z = (10 - 5)/2{,}04 \approx 2{,}45$
4	genau: $P(X = k) = \binom{30}{k}\left(\frac{1}{6}\right)^k\left(\frac{5}{6}\right)^{30-k}$	$P(X = 10) \approx 0{,}0130$, $P(X = 11) \approx 0{,}0047$, $P(X = 12) \approx 0{,}0015$, $P(X \geq 13) \approx 0{,}0005$
5	p-Wert (einseitig)	Summe: $P(X \geq 10) \approx 0{,}020$
6	Urteil	$0{,}020 < 0{,}05$: H_0 verwerfen

Schritt 4 ist mit dem Taschenrechner mühsam; $\binom{30}{10} = 30\,045\,015$, und der Rest ist Potenzrechnung. In der Tabellenkalkulation liefert `1-BINOM.VERT(9;30;1/6;WAHR)` den Wert direkt. Die Normalnäherung aus Schritt 3 ergibt $p \approx 0{,}007$, mit Stetigkeitskorrektur ($z = (9{,}5 - 5)/2{,}04 = 2{,}20$) $p \approx 0{,}014$; bei so kleinen Erwartungswerten ist die Näherung grob, darum der exakte Wert.

6.10 Die Basisrate: das vergessene Vorwissen

Die Lücke zwischen $P(\text{Daten} \mid H)$ und $P(H \mid \text{Daten})$ füllt die *Basisrate*: Wie häufig ist das Gesuchte, bevor man hinschaut? Menschen übergehen sie systematisch, sobald eine konkrete, anschauliche Information vorliegt (Tversky und Kahneman 1974; Tversky und Kahneman 1982). Am deutlichsten zeigt das ein medizinischer Test. Die Zahlen unten sind ein klassisches Lehrbeispiel (Prävalenz 1 %, Sensitivität 90 %, Falsch-positiv-Rate 9 %). Fragt man nach der Wahrscheinlichkeit, dass eine positiv getestete Person tatsächlich krank ist, liegen die Schätzungen, auch von Ärztinnen und Ärzten, oft weit zu hoch. Richtig sind etwa 9 %. Gigerenzer und Hoffrage (1995) haben gezeigt, dass solche Aufgaben viel öfter richtig gelöst werden, wenn man sie in *natürlichen Häufigkeiten* stellt („10 von 1000") statt in bedingten Wahrscheinlichkeiten. Darum rechnet die Folie mit 1000 Personen.

Positiv getestet – und jetzt?



- positiv sind $9 + 89 = 98$ Personen, krank davon nur 9
- $P(\text{krank} \mid \text{positiv}) = 9 / 98 \approx 9\,\%$
- der Test ist gut, die Krankheit ist selten: **die Basisrate gewinnt**

Wie viele signifikante Befunde stimmen?

- ein Signifikanztest ist ein Test wie der beim Arzt: „positiv" heißt $p < 0{,}05$
- 1000 geprüfte Hypothesen, **10 % davon wahr** (Basisrate)
- Power 0,80: von 100 wahren werden 80 signifikant
- $\alpha = 0{,}05$: von 900 falschen werden 45 signifikant
- von $80 + 45 = 125$ signifikanten Befunden stimmen 80, also **64 %**

Basisrate wahrer Hypothesen	50 %	10 %	1 %
Power 0,80	94 %	64 %	14 %
Power 0,35 (typisch kleine Studie)	88 %	44 %	7 %

Der Anteil wahrer unter den signifikanten Befunden heißt in der Diagnostik *positiver Vorhersagewert*. Er beträgt Power $\cdot\, b \,/\, (\text{Power} \cdot b + \alpha \cdot (1 - b))$ mit der Basisrate b. Das ist das Argument von Ioannidis (2005): In Feldern, die viele unwahrscheinliche Hypothesen mit kleinen Studien prüfen, ist ein großer Teil der signifikanten Befunde falsch, auch ohne jedes Fehlverhalten. Kommen p-Hacking und Publikationsbias hinzu, wird es schlimmer. Eine Basisrate von 1 % ist nicht absurd; sie passt zu Forschung, die sehr überraschende Effekte sucht, etwa Hellsehen. Für die eigene Projektplanung folgt daraus: Eine Hypothese mit niedriger Basisrate braucht mehr als einen einzigen signifikanten Befund.

Merke

Ein positiver Test, ein signifikanter Befund, ein Treffer in der Suche: Was er bedeutet, hängt davon ab, wie häufig das Gesuchte überhaupt ist. Wer die Basisrate nicht kennt, sollte sie schätzen und die Schätzung offenlegen, statt sie zu ignorieren.

6.11 Bayes: Was beweist ein Befund?

Der Satz von Bayes beschreibt, wie sich die Glaubwürdigkeit einer Hypothese H durch eine Beobachtung E verändert. Paul Horwich hat daraus eine Theorie der Evidenz entwickelt, die das Buch ausführlich darstellt (Kap. 5b): Eine Beobachtung bestätigt eine Hypothese, wenn sie sie wahrscheinlicher macht, als sie vorher war (Horwich 1982). Folgt die Beobachtung aus der Hypothese, so ist der Zuwachs umso größer, je unwahrscheinlicher die Beobachtung ohne Kenntnis der Hypothese war. Riskante Vorhersagen, die eintreffen, sind deshalb starke Evidenz; Vorhersagen, die ohnehin eingetroffen wären, sind schwache.

Der Satz von Bayes

$$P(H \mid E) \;=\; \frac{P(E \mid H) \cdot P(H)}{P(E)}$$

- $P(H)$: Prior – was ich vorher für plausibel hielt
- $P(E \mid H)$: Likelihood – wie gut erwartet H die Daten?
- $P(H \mid E)$: Posterior – was ich nachher glauben sollte

Bayes zum Rechnen: die Chancenform

$$\underbrace{\frac{P(H_1 \mid E)}{P(H_0 \mid E)}}_{\text{Chance nachher}} = \underbrace{\frac{P(H_1)}{P(H_0)}}_{\text{Chance vorher (Basisrate)}} \times \underbrace{\frac{P(E \mid H_1)}{P(E \mid H_0)}}_{\text{Bayes-Faktor } BF_{10}}$$

- Chance $a : b$ heißt Wahrscheinlichkeit $a \,/\, (a+b)$, etwa $1 : 4 \mathrel{\hat{=}} 20\,\%$
- der **Bayes-Faktor** misst allein die Daten: Wie viel besser sagt H_1 sie voraus als H_0?
- mehrere unabhängige Befunde: Bayes-Faktoren einfach **multiplizieren**
- Medizintest: $1 : 99 \times (90\,\% \,/\, 9\,\%) = 1 : 99 \times 10 = 10 : 99 \approx 9\,\%$

Die Chancenform (*odds form*) ist die Fassung des Satzes von Bayes, mit der man im Kopf rechnen kann. Sie trennt sauber, was man vorher wusste (Prior-Chance), von dem, was die Daten beitragen (Bayes-Faktor). Das hat einen praktischen Vorteil: Zwei Personen mit verschiedenen Ausgangseinschätzungen können sich auf den Bayes-Faktor einigen, auch wenn sie am Ende Verschiedenes glauben. Für die Deutung des Bayes-Faktors ist die grobe Skala von Kass und Raftery (1995) verbreitet: 1 bis 3 kaum der Rede wert, 3 bis 20 positive, 20 bis 150 starke, über 150 sehr starke Evidenz. Werte unter 1 sprechen für H_0; dann liest man den Kehrwert $BF_{01} = 1/BF_{10}$.

Derselbe Würfel, bayesianisch

- H_1 muss konkret sein: „gezinkt" heißt hier $P(6) = \frac{1}{3}$
- jede Sechs: $\frac{1/3}{1/6} = \times 2$ jede andere Zahl: $\frac{2/3}{5/6} = \times 0{,}8$
- 10 Sechsen, 20 andere: $BF_{10} = 2^{10} \cdot 0{,}8^{20} \approx 1024 \cdot 0{,}0115 \approx 11{,}8$

Woher stammt der Würfel?	Basisrate	Chance nachher	$P(\text{gezinkt})$
Spieleabend bei Freunden	$1 : 999$	$11{,}8 : 999$	$1\,\%$
heute im Kurs (jeder fünfte Umschlag)	$1 : 4$	$11{,}8 : 4$	$75\,\%$
Grabbelkiste im Scherzartikelladen	$1 : 1$	$11{,}8 : 1$	$92\,\%$

- gleiche Daten, gleicher p-Wert $(0{,}020)$, **drei verschiedene Antworten**

Die Rechnung zeigt den Kern der Einheit in einer Tabelle. Der p-Wert ist in allen drei Zeilen derselbe, weil er nur fragt, wie überraschend die Daten unter H_0 wären. Ob man deshalb glauben sollte, dass der Würfel gezinkt ist, hängt aber entscheidend davon ab, wie viele gezinkte Würfel es dort gibt, wo er herkommt. Beim Spieleabend wäre es nach wie vor viel wahrscheinlicher, dass ein fairer Würfel zufällig viele Sechsen gezeigt hat. Bei 9 Sechsen, wo der Test „nicht signifikant" meldet, ist $BF_{10} = 4{,}7$; mit der Kurs-Basisrate $1 : 4$ ergibt das eine Chance von $4{,}7 : 4$, also 54 %. Der Bayes-Faktor verlangt dafür eine konkrete Alternative: Wie stark ist der Würfel gezinkt? Bei den Umschlägen im Kurs ist das bekannt, bei einem echten Mogelwürfel nicht. Dann setzt man eine Verteilung möglicher Schieflagen an, und der Bayes-Faktor hängt von dieser Wahl ab. Das ist der ehrliche Preis der bayesianischen Antwort.

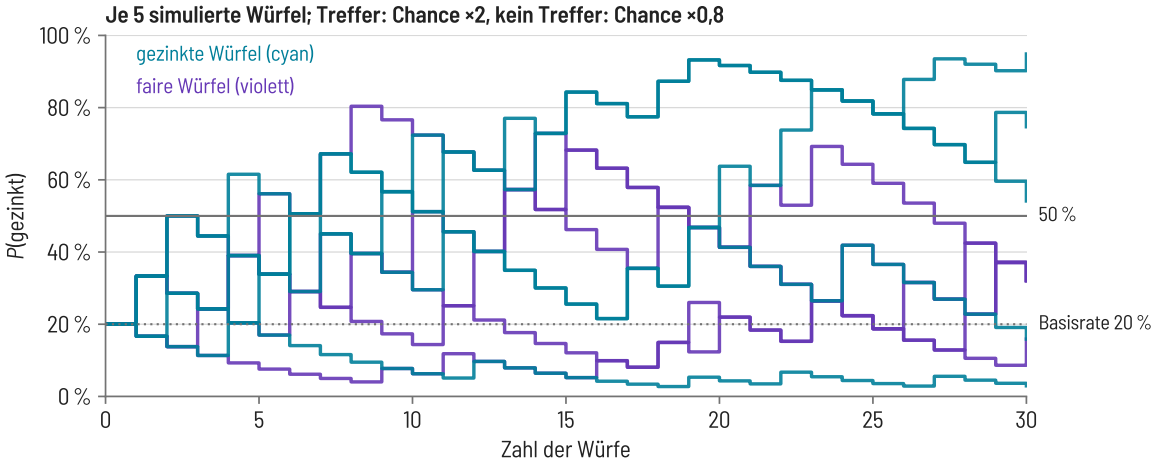
Rechenweg: derselbe Würfel mit Bayes

Schritt	Was	Rechnung
1	Daten unter „gezinkt“	$\left(\frac{1}{3}\right)^{10}\left(\frac{2}{3}\right)^{20}$
2	Daten unter „fair“	$\left(\frac{1}{6}\right)^{10}\left(\frac{5}{6}\right)^{20}$
3	Bayes-Faktor = Quotient	$\left(\frac{1/3}{1/6}\right)^{10} \cdot \left(\frac{2/3}{5/6}\right)^{20} = 2^{10} \cdot 0{,}8^{20}$
4	ausrechnen	$2^{10} = 1024;\quad 0{,}8^{20} \approx 0{,}0115;\quad BF_{10} \approx 11{,}8$
5	Prior-Chance (Kurs)	$1 : 4$
6	Posterior-Chance	$1 \cdot 11{,}8 : 4 = 11{,}8 : 4$
7	in Wahrscheinlichkeit	$11{,}8/(11{,}8+4) = 11{,}8/15{,}8 \approx$ **75 %**

- Spieleabend ($1 : 999$): $11{,}8/1010{,}8 \approx 1{,}2\,\%$ Scherzartikelladen ($1 : 1$): $11{,}8/12{,}8 \approx 92\,\%$

Der Trick in Schritt 3: Alle Faktoren, die in beiden Hypothesen gleich sind (etwa die Zahl der möglichen Reihenfolgen $\binom{30}{10}$), kürzen sich weg. Übrig bleibt pro Treffer der Faktor 2 und pro Nicht-Treffer der Faktor 0,8. $0{,}8^{20}$ rechnet man am bequemsten als $(0{,}8^2)^{10} = 0{,}64^{10}$ oder mit der Potenztaste.

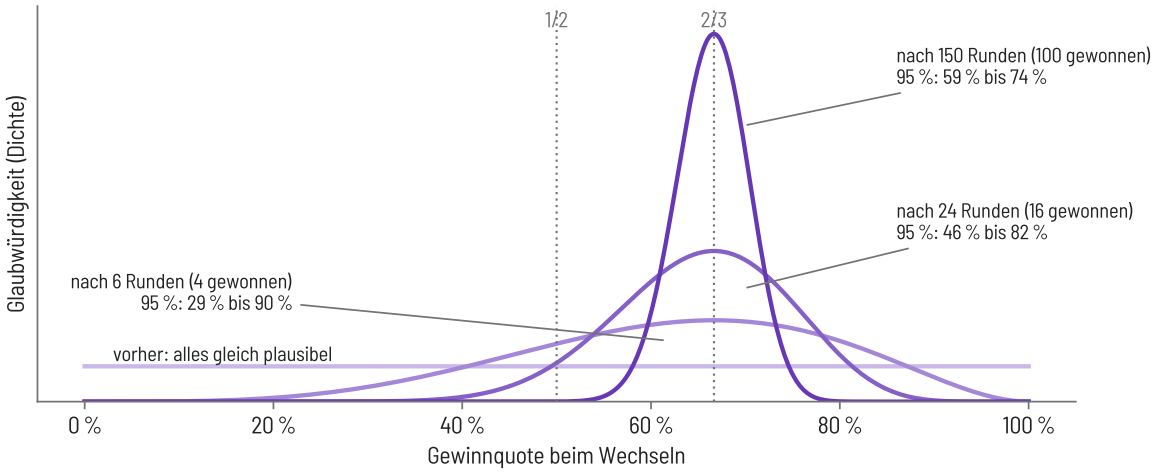
Der Posterior wandert mit jedem Wurf



- alle starten bei der Basisrate 20 %; jeder Wurf verschiebt die Überzeugung ein Stück
- nach 30 Würfen sind manche Würfel klar, andere noch unentschieden

Je fünf simulierte faire und gezinkte Würfel, Prior $1 : 4$. Die Kurven zeigen nach jedem Wurf $P(\text{gezinkt})$. Gut zu sehen: Faire Würfel sinken langsam, weil ein Nicht-Treffer die Chance nur mit 0,8 multipliziert; gezinkte steigen in Sprüngen, aber nicht jeder gezinkte Würfel ist nach 30 Würfen über 50 %. Der Bayes-Faktor hat keine feste Stichprobengröße: Man könnte weiterwürfeln, bis die Kurve eine vorher festgelegte Grenze erreicht (vgl. die Stoppregel bei Schönbrodt u. a. (2017)).

Bayes für eine Quote: Wie gut ist Wechseln?



- mit jeder Runde wird die Kurve schmaler: aus Vermutung wird Wissen
- nach 150 Runden: mit 95 % zwischen 59 % und 74 % – *diese* Aussage darf Bayes machen

Prior ist die Gleichverteilung (jede Quote gleich plausibel); nach k Gewinnen in n Runden ist der Posterior eine Beta-Verteilung mit den Parametern $k+1$ und $n-k+1$. Zum Rechnen genügt die Grafik: Wichtig ist, dass das bayesianische 95-%-Intervall („Glaubwürdigkeitsintervall") genau die Aussage macht, die man dem Konfidenzintervall oft fälschlich zuschreibt. Bei einem flachen Prior und vielen Daten liegen beide Intervalle zahlenmäßig nahe beieinander.

Bayes-Faktor zum t-Test

- Faustformel nach Wagenmakers (2007), mit N = alle Personen:

$$BF_{01} \approx \sqrt{N} \cdot \left(1 + \frac{t^2}{df}\right)^{-N/2}$$

- fiktives Lehrvideo-Beispiel: $t = 2{,}5$, $N = 16$, $df = 14$
- $(1 + 6{,}25/14)^8 = 1{,}446^8 \approx 19{,}1$, also $BF_{01} \approx 4 \,/\, 19{,}1 \approx 0{,}21$
- $BF_{10} \approx 4{,}8$: die Daten sind knapp fünfmal so gut mit einem Effekt vereinbar (JASP-Standard: 2,7)
- „$p = 0{,}025$" klingt nach mehr, als die Daten hergeben

Die Faustformel beruht auf der BIC-Näherung, die Wagenmakers (2007) für den t-Test ableitet. Sie entspricht einem recht breiten Prior für die Effektgröße und ist eine Größenordnungsschätzung. Statistikprogramme wie JASP rechnen standardmäßig den JZS-Bayes-Faktor nach Rouder u. a. (2009) (Cauchy-Prior mit Breite $r = \sqrt{2}/2$); für das Beispiel ergibt er $BF_{10} = 2{,}7$. Beide Werte liegen in derselben Kategorie: positive, aber keine starke Evidenz. Mit Prior-Chance $1:1$ ergäbe die Faustformel eine Posterior-Wahrscheinlichkeit von 83 %, mit $1:3$ noch 62 %. Das Beispiel zeigt eine allgemeine Regel: p-Werte knapp unter $0{,}05$ entsprechen meist nur schwacher Evidenz (Wagenmakers 2007).

Rechenweg: Bayes-Faktor zum t-Test

Lehrvideo-Beispiel: $t = 2{,}5$, $N = 16$, $df = 14$

Schritt	Was	Rechnung
1	t^2/df	$6{,}25/14 \approx 0{,}446$
2	Klammer	$1 + 0{,}446 = 1{,}446$
3	hoch $N/2 = 8$ (dreimal quadrieren)	$1{,}446^2 = 2{,}09$; $2{,}09^2 = 4{,}38$; $4{,}38^2 \approx 19{,}2$
4	$\sqrt{N}$	$\sqrt{16} = 4$
5	BF_{01}	$4/19{,}2 \approx 0{,}21$
6	Kehrwert: BF_{10}	$1/0{,}21 \approx 4{,}8$
7	Posterior bei Prior $1:1$	$4{,}8:1$, also $4{,}8/5{,}8 \approx 83\,\%$
8	Posterior bei Prior $1:3$	$4{,}8:3$, also $4{,}8/7{,}8 \approx 62\,\%$

Hoch 8 ist dasselbe wie dreimal hintereinander quadrieren; so geht es auch ohne Potenztaste. Zur Erinnerung: Die Faustformel ist eine Näherung; JASP liefert für dieselben Daten $BF_{10} = 2{,}7$, mit Prior $1:1$ also 73 %.

Was nur der Bayes-Faktor kann

- **Signifikant, aber Evidenz für H_0:** je 1000 Personen, $t = 2{,}0$, $p = 0{,}046$, $d = 0{,}09$
- $BF_{01} \approx \sqrt{2000} \cdot (1 + 4/1998)^{-1000} \approx 44{,}7 \cdot e^{-2} \approx 6$: die Daten sprechen eher *gegen* einen nennenswerten Effekt
- **Evidenz für „kein Effekt“:** je 20 Personen, $t = 0$: $BF_{01} \approx \sqrt{40} \approx 6{,}3$
- ein p-Wert kann H_0 nie stützen, nur nicht verwerfen

Der erste Fall ist als Lindley-Paradox bekannt: Bei sehr großen Stichproben wird ein winziger Unterschied signifikant, obwohl die Daten die Nullhypothese besser vorhersagen als eine Alternative, die nennenswerte Effekte erwartet. Mit dem JZS-Bayes-Faktor ergibt sich $BF_{01} = 2{,}7$ statt 6; die Richtung bleibt gleich. Im zweiten Fall liefert JASP $BF_{01} = 3{,}2$. Für kleine Studierendenprojekte ist der zweite Punkt wichtig: Ein nicht signifikantes Ergebnis ist frequentistisch nur „kein Befund“. Ein Bayes-Faktor kann dagegen zeigen, ob die Daten für die Nullhypothese sprechen oder schlicht zu dünn sind, um irgendetwas zu sagen.

Rechenweg: signifikant, aber Evidenz für H_0

Je 1000 Personen, $t = 2{,}0$, $N = 2000$, $df = 1998$

Schritt	Was	Rechnung
1	p-Wert	$p = 0{,}046$: signifikant
2	Effektgröße	$d = t \cdot \sqrt{1/1000 + 1/1000} = 2 \cdot 0{,}045 \approx 0{,}09$: winzig
3	t^2/df	$4/1998 \approx 0{,}002$
4	$(1 + 0{,}002)^{1000}$	$\approx e^{1000 \cdot 0{,}002} = e^2 \approx 7{,}4$
5	$\sqrt{N}$	$\sqrt{2000} \approx 44{,}7$
6	BF_{01}	$44{,}7/7{,}4 \approx 6$: **6:1 für H_0**

- der Test meldet „Effekt“, der Bayes-Faktor „eher keiner von nennenswerter Größe“

Schritt 4 nutzt die Näherung $(1+x)^m \approx e^{mx}$ für kleines x. Der Grund für den Widerspruch: Bei 2000 Personen ist schon ein winziger Unterschied signifikant. Die Alternativhypothese des Bayes-Faktors erwartet dagegen Effekte in der Größenordnung, die man in der Forschung üblicherweise sucht, und sagt einen so kleinen Unterschied schlechter voraus als H_0.

Der Beweiswert riskanter Vorhersagen

- folgt E aus H, gilt $P(H \mid E) \,/\, P(H) = 1 \,/\, P(E)$
- **je unwahrscheinlicher die Vorhersage, desto stärker die Bestätigung**, wenn sie eintrifft
- „Morgen geht die Sonne auf“ trifft ein und beweist fast nichts
- „Wechseln gewinnt doppelt so oft“ war riskant: Die Strichliste hätte sie widerlegen können

Horwich zeigt außerdem, dass nur Beobachtungen, die ein Widerlegungsrisiko eingehen, vollen Beweiswert haben (Horwich 1982). Das schlägt die Brücke zu LE 5 (Falsifizierbarkeit) und zu LE 10: Ein Verfahren, das jedes Ergebnis liefern kann, geht kein Risiko ein und beweist deshalb nichts.

6.12 Frequentistisch oder bayesianisch?

Keine der beiden Schulen ist „die richtige“. In der empirischen Forschung dominieren Signifikanztests, und wer Fachliteratur liest, muss sie verstehen. Bayesianische Verfahren gewinnen an Boden, weil sie Fragen beantworten, die Forschende tatsächlich stellen, und weil sie Evidenz für die Nullhypothese ausweisen können. Für die Planung einer eigenen

Studie zählt vor allem ein Unterschied: Der Signifikanztest verlangt, dass die Stichprobengröße vorher feststeht. Wer nach jeder Versuchsperson nachschaut und aufhört, sobald $p < 0{,}05$ ist, treibt die Fehlerquote weit über 5 % (Simmons u. a. 2011). Beim Bayes-Faktor darf man dagegen laufend nachsehen und aufhören, wenn die Evidenz eine vorab festgelegte Grenze erreicht (Schönbrodt u. a. 2017). Das ist für kleine Projekte attraktiv, bei denen niemand weiß, wie viele Personen am Ende mitmachen.

Die beiden Schulen im Vergleich

	Signifikanztest	**Bayes-Faktor**
Frage	Sind die Daten mit H_0 verträglich?	Welche Hypothese sagt die Daten besser voraus?
Vorwissen	bleibt draußen	geht offen als Prior ein
Alternative H_1	muss nicht genau angegeben werden	muss konkret sein
Evidenz für H_0	nicht möglich	möglich
Zwischenauswertung	verfälscht p; n vorab festlegen	erlaubt, Stoppregel vorab festlegen
typischer Fehler	p als $P(H_0 \mid \text{Daten})$ lesen	Prior verschweigen oder passend wählen

Merke

Der p-Wert fragt, wie überraschend die Daten unter H_0 wären. Der Bayes-Faktor fragt, um wie viel die Daten eine Hypothese gegenüber einer anderen stützen. Was man danach glauben sollte, bestimmen die Daten *und* die Basisrate.

6.13 Übung: Würfel-Detektive

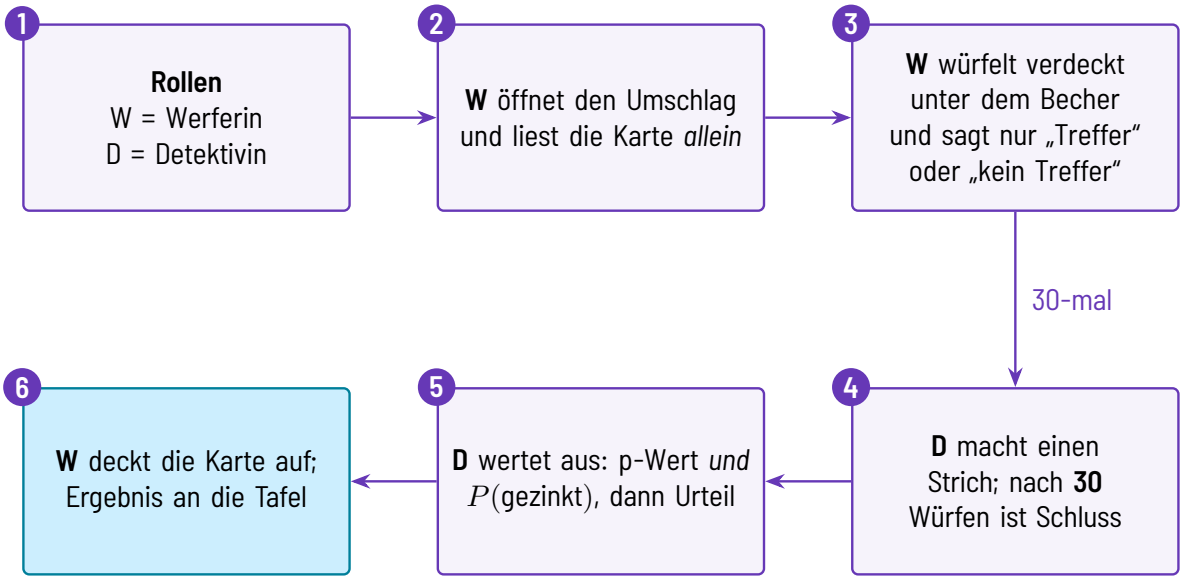
Die Übung macht in einer Viertelstunde erlebbar, was die Folien behauptet haben: dass ein Test mit $\alpha = 0{,}05$ manchmal falschen Alarm gibt, dass er bei kleinem n viele echte Effekte übersieht und dass man ohne Basisrate nicht sagen kann, wie viele seiner Alarme stimmen.

Das Spiel braucht keine präparierten Würfel. Ob ein Würfel „gezinkt" ist, entscheidet eine Karte im Umschlag, die nur die werfende Person kennt: Bei „fair" zählt nur die 6 als Treffer (Wahrscheinlichkeit $\frac{1}{6}$), bei „gezinkt" zählen 5 und 6 (Wahrscheinlichkeit $\frac{1}{3}$). Für die Detektivin ist das von einem echten gezinkten Würfel nicht zu unterscheiden, denn sie sieht den Würfel nicht, sondern hört nur „Treffer" oder „kein Treffer". Damit sind beide Hypothesen exakt bekannt, und die Basisrate (jeder fünfte Umschlag) ebenfalls. Die Regeln auf der dritten Folie sind wichtig: Wer nach 15 Würfen aufhört, weil es „schon klar" ist, verändert die Fehlerrate des Tests; genau das ist Optional Stopping aus dem Vergleich der beiden Schulen.

Würfel-Detektive: das Spiel

- jedes Paar bekommt einen Würfel, der **vielleicht gezinkt** ist
- „gezinkt" heißt hier: ein **Treffer** kommt doppelt so oft (Chance $\frac{1}{3}$ statt $\frac{1}{6}$)
- ob Ihr Würfel gezinkt ist, steht auf einer Karte im Umschlag
- **bekannt**: 3 von 15 Umschlägen sind gezinkt, also jeder fünfte (Basisrate $1:4$)
- Ihre Aufgabe: aus 30 Würfen herausfinden, ob Ihr Würfel gezinkt ist – einmal mit Test, einmal mit Bayes

Ablauf in sechs Schritten



- **Treffer** bei Karte „fair": nur die 6 bei Karte „gezinkt": 5 oder 6

Spielregeln, damit der Test ehrlich bleibt

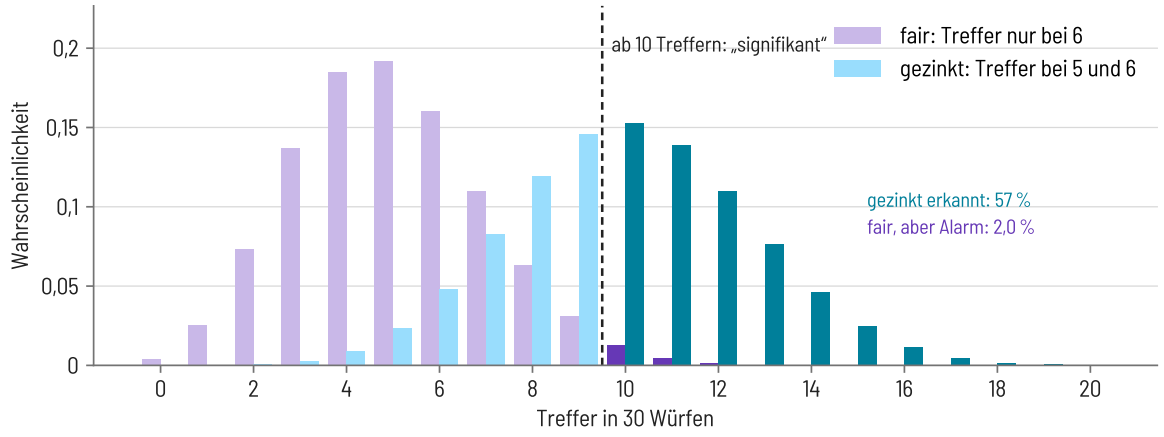
- W zeigt die Karte erst nach dem Urteil – auch kein Grinsen, kein Zögern
- W meldet jeden Wurf wahrheitsgemäß, D sieht den Würfel nie
- **immer genau 30 Würfe**, auch wenn es „schon klar" ist: Die Stichprobengröße steht vorher fest
- D entscheidet *vor* dem Aufdecken und schreibt beide Urteile auf (Teil B, Aufgabe 4)
- dauert etwa 5 Minuten Würfeln und 5 Minuten Rechnen

Auswertung am Beispiel: 9 Treffer in 30 Würfen

(a) Test	(b) Bayes
H_0: fair, Treffer mit $\frac{1}{6}$; erwartet 5	Faktor je Treffer $\times 2$, je Nicht-Treffer $\times 0{,}8$
aus der Tabelle: $P(X \geq 9 \mid \text{fair}) = 0{,}051$	$BF_{10} = 2^9 \cdot 0{,}8^{21} = 512 \cdot 0{,}0092 \approx 4{,}7$
$0{,}051 > 0{,}05$: **nicht signifikant**	Chance $1 : 4 \times 4{,}7 = 4{,}7 : 4 \Rightarrow P \approx$ **54 %**
Urteil: „kein Befund"	Urteil: „eher gezinkt, aber unsicher"

- dieselben Daten, zwei verschiedene Fragen, zwei verschiedene Antworten
- mit 10 Treffern: Test signifikant ($p = 0{,}020$), Bayes 75 %

Was der Kurs erwarten kann



- die Verteilungen überlappen stark: 30 Würfe sind wenig
- der Test erkennt nur gut die Hälfte der gezinkten Würfel

Auszählung im Kurs

	Karte: fair	**Karte: gezinkt**
signifikant ($k \geq 10$)	falscher Alarm (α)	Treffer (Power)
nicht signifikant	richtig	übersehen (β)

- erwartet bei 12 fairen und 3 gezinkten Paaren: 0–1 falscher Alarm, aber nur 1–2 der 3 gezinkten erkannt (Power 0,57)
- Wie viele der signifikanten Würfel waren wirklich gezinkt?
- Wer lag mit dem Bayes-Urteil ($P > 50\,\%$) richtig, wer mit dem Test?

Die Erwartungswerte sind exakt gerechnet: Bei einem fairen Würfel ist $P(X \geq 10) = 0{,}020$, bei 12 fairen Paaren erwartet man also 0,24 falsche Alarme. Bei einem gezinkten Würfel ($P(\text{Treffer}) = \frac{1}{3}$) ist $P(X \geq 10) = 0{,}57$; von drei gezinkten werden im Mittel 1,7 erkannt. Der Anteil wirklich gezinkter unter den signifikanten Würfeln liegt bei dieser Basisrate rechnerisch bei 88 %; mit einer Basisrate von 1 in 100 läge er bei 23 %. Die Bayes-Regel „gezinkt, wenn $P(\text{gezinkt}) > 50\,\%$“ schlägt ab 9 Treffern an ($BF_{10} = 4{,}7 > 4$). Sie erkennt gezinkte Würfel etwas öfter (71 %) und gibt bei fairen etwas öfter falschen Alarm (5 %). Bei so wenigen Paaren streut die Auszählung stark; genau das ist ein Gesprächsanlass: Mit 30 Würfen lässt sich ein deutlich gezinkter Würfel nur in gut der Hälfte der Fälle nachweisen. Welche Konsequenz hätte das für eine Studie mit 30 Personen?

6.14 Glaubwürdigkeits-Check mit der Suchmaschine

Bayes in Chancenform ist auch ein Werkzeug für den Alltag der Quellenkritik. Es knüpft an SIFT aus LE 4 an (*Find better coverage*, *Trace claims*) und macht aus dem Bauchgefühl eine nachvollziehbare Rechnung. Vor der Suche setzt man eine Basisrate an: Von 100 Behauptungen dieser Art, wie viele stimmen? Dann prüft man jeden Fund mit einer einzigen Frage: Wie viel wahrscheinlicher wäre dieser Fund, wenn die Behauptung stimmt, als wenn sie nicht stimmt? Die Antwort ist ein grober Bayes-Faktor. Die Zahlen sind Schätzungen, und das ist gewollt: Sie zwingen dazu, die Einschätzung offenzulegen und mit anderen zu vergleichen. Die wichtigste Lehre steckt in der zweiten Zeile des Beispiels: Zehn Portale, die dieselbe Pressemitteilung abschreiben, sind *ein* Fund, nicht zehn. Multiplizieren darf man nur unabhängige Befunde.

Das Beispiel ist echt. Der Wissenschaftsjournalist John Bohannon hat 2015 mit Absicht eine methodisch schwache Studie zu Schokolade und Gewichtsverlust durchgeführt (wenige Versuchspersonen, viele Messgrößen) und in einer Zeitschrift veröffentlicht, die gegen Gebühr publiziert. Die Pressemitteilung wurde weltweit aufgegriffen, die *Bild* titelte „Schlank durch Schokolade!“. Danach legte Bohannon offen, wie und warum er den Fake gebaut hatte (Bohannon 2015).

Glaubwürdigkeit in vier Schritten

- **Behauptung** genau notieren: Wer sagt was über wen?
- **Basisrate**: Von 100 Behauptungen dieser Art, wie viele stimmen? ⇒ Prior-Chance
- **Suchen** (SIFT, LE 4), für jeden Fund fragen: Wie viel wahrscheinlicher wäre er, wenn die Behauptung *stimmt*, als wenn sie *nicht* stimmt?
- Faktoren grob wählen: $\times 10$, $\times 3$, $\times 1$, $\times \frac{1}{3}$, $\times \frac{1}{10}$; nur **unabhängige** Funde multiplizieren

Beispiel: „Schokolade hilft beim Abnehmen“

Schritt	Faktor	Chance
Basisrate: Diät-Wunder aus einer Einzelstudie, etwa 1 von 10 hält		$1:9$
viele Portale berichten, alle mit derselben Pressemitteilung	$\times 1$	$1:9$
Originalstudie: sehr wenige Personen, viele Messgrößen, Zeitschrift publiziert gegen Gebühr	$\times \frac{1}{3}$	$1:27$
der Autor erklärt öffentlich, die Studie sei ein absichtlicher Fake	$\times \frac{1}{100}$	$1:2700$

- am Ende: $P(\text{stimmt}) \approx 0{,}04\,\%$
- der Fund, der die meisten Klicks hat, trägt den kleinsten Faktor

Ihr Glaubwürdigkeits-Check (Kleingruppen, 12 Min.)

- jede Gruppe zieht eine Behauptungskarte
- Basisrate *vor* der Suche festlegen und begründen
- 8 Minuten suchen, jeden Fund mit Faktor in die Tabelle (Teil B, Aufgabe 6)
- Ergebnis: $P(\text{stimmt})$ – und welcher Fund hat am meisten bewegt?
- Vergleich: Wo lagen zwei Gruppen mit denselben Funden verschieden, weil ihre Basisrate verschieden war?

Behauptungskarten für den Glaubwürdigkeits-Check

Bewährt haben sich Behauptungen, zu denen eine kurze Suche gute Quellen findet. Vorschläge, davon mindestens zwei zutreffende auswählen:

- „Wir nutzen nur 10 % unseres Gehirns." (falsch, verbreiteter Mythos)
- „Die Chinesische Mauer ist das einzige Bauwerk, das man vom Mond aus mit bloßem Auge sieht." (falsch)
- „Ein Blitz schlägt nie zweimal an derselben Stelle ein." (falsch; hohe Gebäude werden regelmäßig mehrfach getroffen)
- „Mozart hören macht Babys klüger." (in dieser Form falsch; die Ausgangsstudie fand einen kurzen Effekt bei Erwachsenen, der sich kaum replizieren ließ)
- „Ausschläge von Wünschelruten und Pendeln entstehen durch unbewusste Muskelbewegungen." (zutreffend, Ideomotor-Effekt aus LE 1)
- „In europäischen Ländern hängt die Zahl der Storchenpaare mit der Geburtenzahl zusammen." (zutreffend als Korrelation, Matthews (2000); ein schönes Beispiel dafür, dass eine wahre Behauptung nicht die kausale Deutung trägt, die sie nahelegt)

Erwartet wird kein „richtiger" Zahlenwert. Gute Gruppen begründen ihre Basisrate, erkennen abgeschriebene Meldungen als einen einzigen Fund und geben den größten Faktoren den Funden, die nur bei einer wahren (bzw. falschen) Behauptung zu erwarten sind: Übersichtsarbeiten, Faktenchecks mit Quellenangaben, die Originalstudie selbst. Lohnend ist die Frage, ob eine Gruppe ihre Basisrate nach der Suche nachträglich „angepasst" hat; das wäre Doppelzählung.

6.15 Effektgröße und Power

Ob ein Effekt „signifikant" ist, hängt nicht nur von seiner Größe ab, sondern auch von der Stichprobengröße. Mit sehr vielen Personen wird jeder noch so kleine Unterschied signifikant, mit sehr wenigen bleibt selbst ein großer unentdeckt. Deshalb gehört zu jedem Befund eine *Effektgröße*, die unabhängig von n angibt, wie groß der Unterschied ist. Für Mittelwertunterschiede ist Cohens d üblich, der Abstand der Mittelwerte in Einheiten der Standardabweichung (Cohen

1988). Die *Power* (Teststärke) ist die Wahrscheinlichkeit, einen tatsächlich vorhandenen Effekt bestimmter Größe auch zu finden. Sie wird *vor* der Studie über eine Poweranalyse festgelegt; daraus ergibt sich die nötige Stichprobengröße.

Effektgröße: Wie groß ist der Unterschied?

- Cohens $d = (\bar{x}_1 - \bar{x}_2) \,/\, s$: Abstand in Standardabweichungen
- grobe Orientierung: $0{,}2$ klein, $0{,}5$ mittel, $0{,}8$ groß (Cohen 1988)
- immer mit Konfidenzintervall berichten
- signifikant ist nicht dasselbe wie groß, nicht signifikant nicht dasselbe wie null

Power: Wie viele Personen brauche ich?

erwarteter Effekt	$d = 0{,}2$	$d = 0{,}5$	$d = 0{,}8$
n pro Gruppe	394	64	26

- t-Test, zwei Gruppen, $\alpha = 0{,}05$ zweiseitig, Power $0{,}80$
- mit 13 Personen pro Gruppe findet man einen mittleren Effekt nur in etwa einem von vier Versuchen

Die Werte der Tabelle sind mit der nichtzentralen t-Verteilung nachgerechnet; sie stimmen mit den Tafeln bei Cohen (1988) überein. Die Power bei 13 Personen pro Gruppe und $d = 0{,}5$ beträgt nach derselben Rechnung etwa 0,23. Kleine Studien haben nicht nur ein hohes Risiko, echte Effekte zu übersehen. Wenn sie doch einmal „signifikant“ werden, überschätzen sie die Effektgröße typischerweise deutlich (Button u. a. 2013).

Ein Lehrstück aus dem Buch

- Feldstudie zum Becher-Monty-Hall-Video: 32 auswertbare Fälle in drei Armen (13 / 9 / 10)
- am 16. Juli zeigte das Staunen eine schöne Abstufung: 3,83 / 4,08 / 4,28
- am Ende lagen die Arme gleichauf: 3,89 / 3,76 / 3,87
- stärkster Zusammenhang: **Vorwissen** – wer das Problem kannte, lag zu 92 % richtig

Die Zahlen stammen aus der Feldstudie im Buch (Kap. 12f). Der anfängliche Staunen-Gradient war ein Artefakt kleiner Zwischenstände: Hätte die Erhebung früher geendet, stünde ein schöner, falscher Befund in der Welt. Das Buch zieht daraus die Konsequenz, Fallzahlen vorab zu planen („ohne mindestens 60 Personen pro Arm lohnt der Aufwand nicht“) und nach Vorwissen geschichtet zu randomisieren. Die Studie berichtet bewusst keine p-Werte, sondern Effektgrößen (Hedges’ g) mit Bootstrap-Intervallen. Für die Stunde ist das ein Beispiel, das nah an den Studierenden liegt: Das Spiel, das sie gerade gespielt haben, war Gegenstand einer echten Studie mit echten Schwächen.

Welche Fragen kann Ihr Projekt beantworten?

Personen pro Gruppe	10	15	20	30
zwei Gruppen, $d = 0{,}5$	0,19	0,26	0,34	0,48
zwei Gruppen, $d = 0{,}8$	0,40	0,56	0,69	0,86
Messwiederholung, $d = 0{,}5$	0,29	0,44	0,56	0,75

- Power des t-Tests, $\alpha = 0{,}05$ zweiseitig; bei Messwiederholung zählt jede Person einmal
- mit 20 Personen pro Gruppe findet man einen mittleren Effekt in einem von drei Versuchen
- Ja/Nein-Zielgrößen brauchen mehr: 50 % gegen 70 % Erfolg verlangt etwa 47 Personen pro Gruppe

Die Werte sind mit der nichtzentralen t-Verteilung gerechnet. Bei Messwiederholung (dieselben Personen in beiden Bedingungen) ist d auf die Streuung der Differenzen bezogen; für $d = 0{,}5$ und Power 0,80 genügen dann 34 Personen, für $d = 0{,}8$ 15. Der Wert für Anteile ist mit der Arkussinus-Näherung (Cohens h) gerechnet (Cohen 1988). Die Tabelle ist die wichtigste Brücke zu LE 7: Sie zeigt, welche Fragen ein Semesterprojekt mit realistischen Fallzahlen überhaupt beantworten kann.

Was daraus für Ihr Design folgt (LE 7)

- Fragen wählen, bei denen ein **großer** Effekt plausibel ist, oder dieselben Personen mehrfach messen
- metrische Zielgrößen statt Ja/Nein, wo es geht
- den kleinsten Effekt festlegen, der Sie interessieren würde, und daraus n bestimmen
- Schätzen statt Testen: „Wie groß ist der Unterschied?" mit Konfidenzintervall ist auch bei kleinem n eine ehrliche Antwort
- Bayes-Faktor mit Stoppregel (etwa $BF > 6$ oder $< \frac{1}{6}$, höchstens 40 Personen), wenn n unsicher ist
- Basisrate Ihrer Hypothese ehrlich einschätzen: Wie überraschend wäre es, wenn sie stimmt?

Diese Liste greift die Design-Skizze in LE 7 auf; dort wird der Auswertungsplan Teil der Vorlage. Die Stoppregel im vorletzten Punkt folgt dem sequentiellen Bayes-Faktor-Design von Schönbrodt u. a. (2017): Man erhebt, bis die Evidenz eine vorab festgelegte Grenze in eine der beiden Richtungen erreicht oder die Höchstzahl erreicht ist, und berichtet in jedem Fall den erreichten Bayes-Faktor. Die Grenzen und die Höchstzahl gehören, wie beim Signifikanztest das n, vor Beginn der Erhebung schriftlich fest.

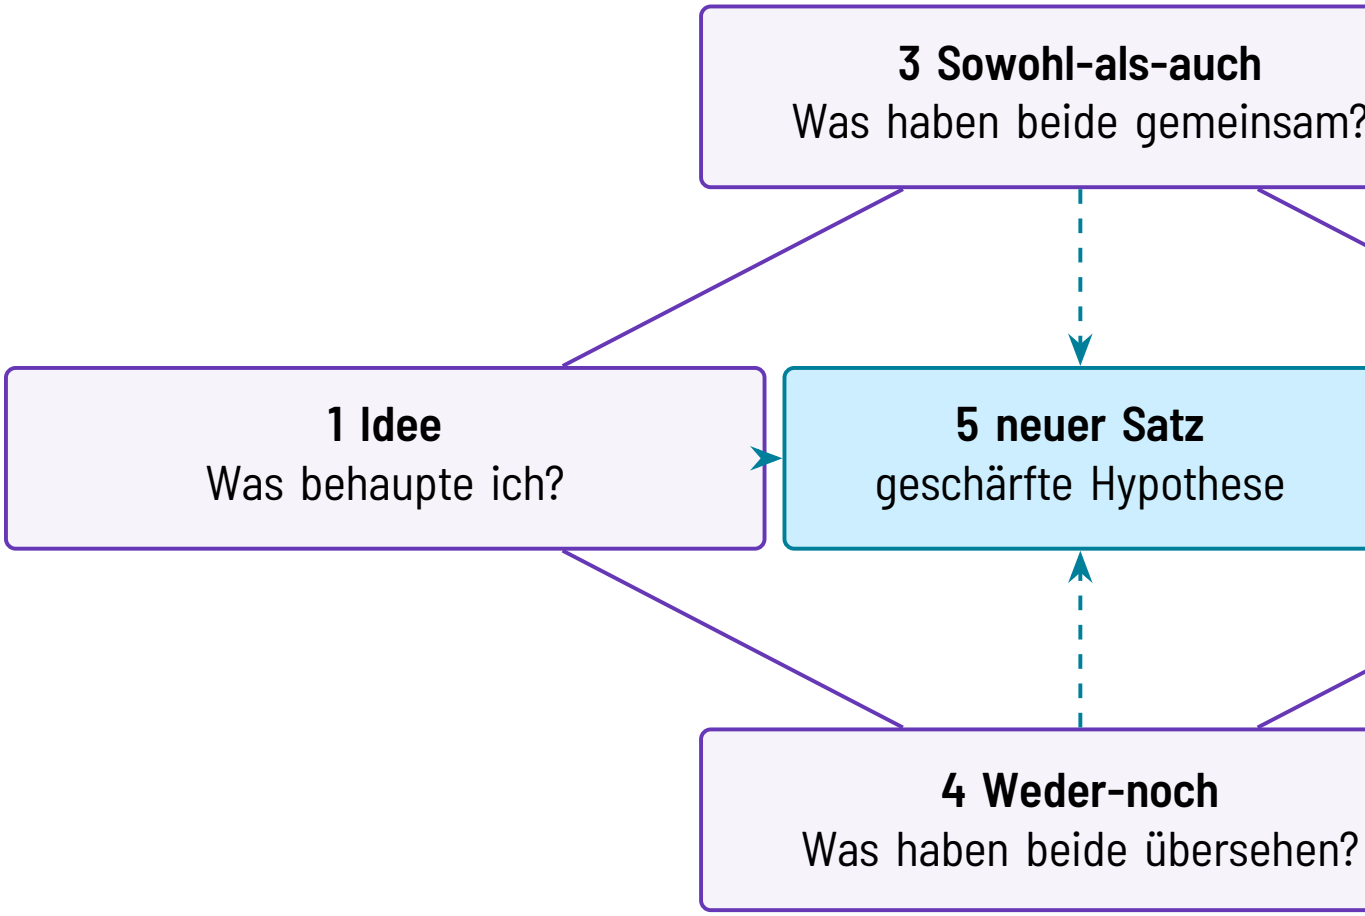
6.16 Schwierige Fragen zerlegen: Diamant und Landkarte

Wer eine Idee prüfen will, sucht fast immer zuerst nach dem, was sie bestätigt (LE 5, LE 8). Für den Bayes-Faktor ist das doppelt schädlich: Er braucht eine *Alternative*, und die Qualität der Prüfung hängt davon ab, wie gut diese Alternative ist. Eine einfache Arbeitsabfolge, um systematisch Alternativen zu erzeugen, ist die *Diamond-Technik* aus dem NLP-Coaching (Fellehner 2026). Sie stellt einer Ausgangsidee ihr Gegenteil, ein *Sowohl-als-auch* und ein *Weder-noch* gegenüber und fragt für jede Position, was sie ermöglicht und was sie verhindert. Die Figur ist älter als das NLP: Sie entspricht dem Tetralemma der indischen Logik, das Varga von Kibéd und Sparrer (2000) für die systemische Beratung aufbereitet haben.

Zur Einordnung, wie es sich in einem Methodenkurs gehört: Als Coaching-Methode ist die Diamond-Technik kaum empirisch geprüft; das sagt auch die Quelle selbst. Hier wird sie nicht als Intervention eingesetzt, sondern als *Denkgerüst* zum Erzeugen von Gegenhypothesen. Dafür wird jeder Schritt in eine Forschungsfrage übersetzt. Aus „ermöglicht / verhindert" wird „erlaubt / verbietet": Welche Beobachtungen sagt diese Position voraus, welche schließt sie aus? Das ist Poppers Frage aus LE 5, und es ist zugleich die Frage nach den Likelihoods, aus denen der Bayes-Faktor entsteht. Beobachtungen, die alle Positionen gleich gut erwarten, haben einen Bayes-Faktor nahe 1 und entscheiden nichts; das *Sowohl-als-auch* macht diese Beobachtungen sichtbar. Das *Weder-noch* ist der Ort der dritten Erklärung, also der Störvariablen, die in LE 7 kontrolliert werden müssen.

Was beim Zerlegen herauskommt, wird auf einer Landkarte festgehalten: ein Weg von der Ausgangsidee zur geschärften Hypothese, mit allem, was unterwegs geklärt wurde, und mit den Hindernissen, die noch im Weg liegen. Die Karte ist bewusst spielerisch, aber sie hat eine strenge Regel: Jedes Element trägt einen Beleg oder eine Zahl. So wird sie zur Vorlage für die Design-Skizze in LE 7 und später für den Limitationen-Abschnitt der Seminararbeit: Die Drachen, die am Ende noch auf der Karte stehen, sind genau die Einschränkungen, die man berichten muss.

Der Diamant: vier Positionen

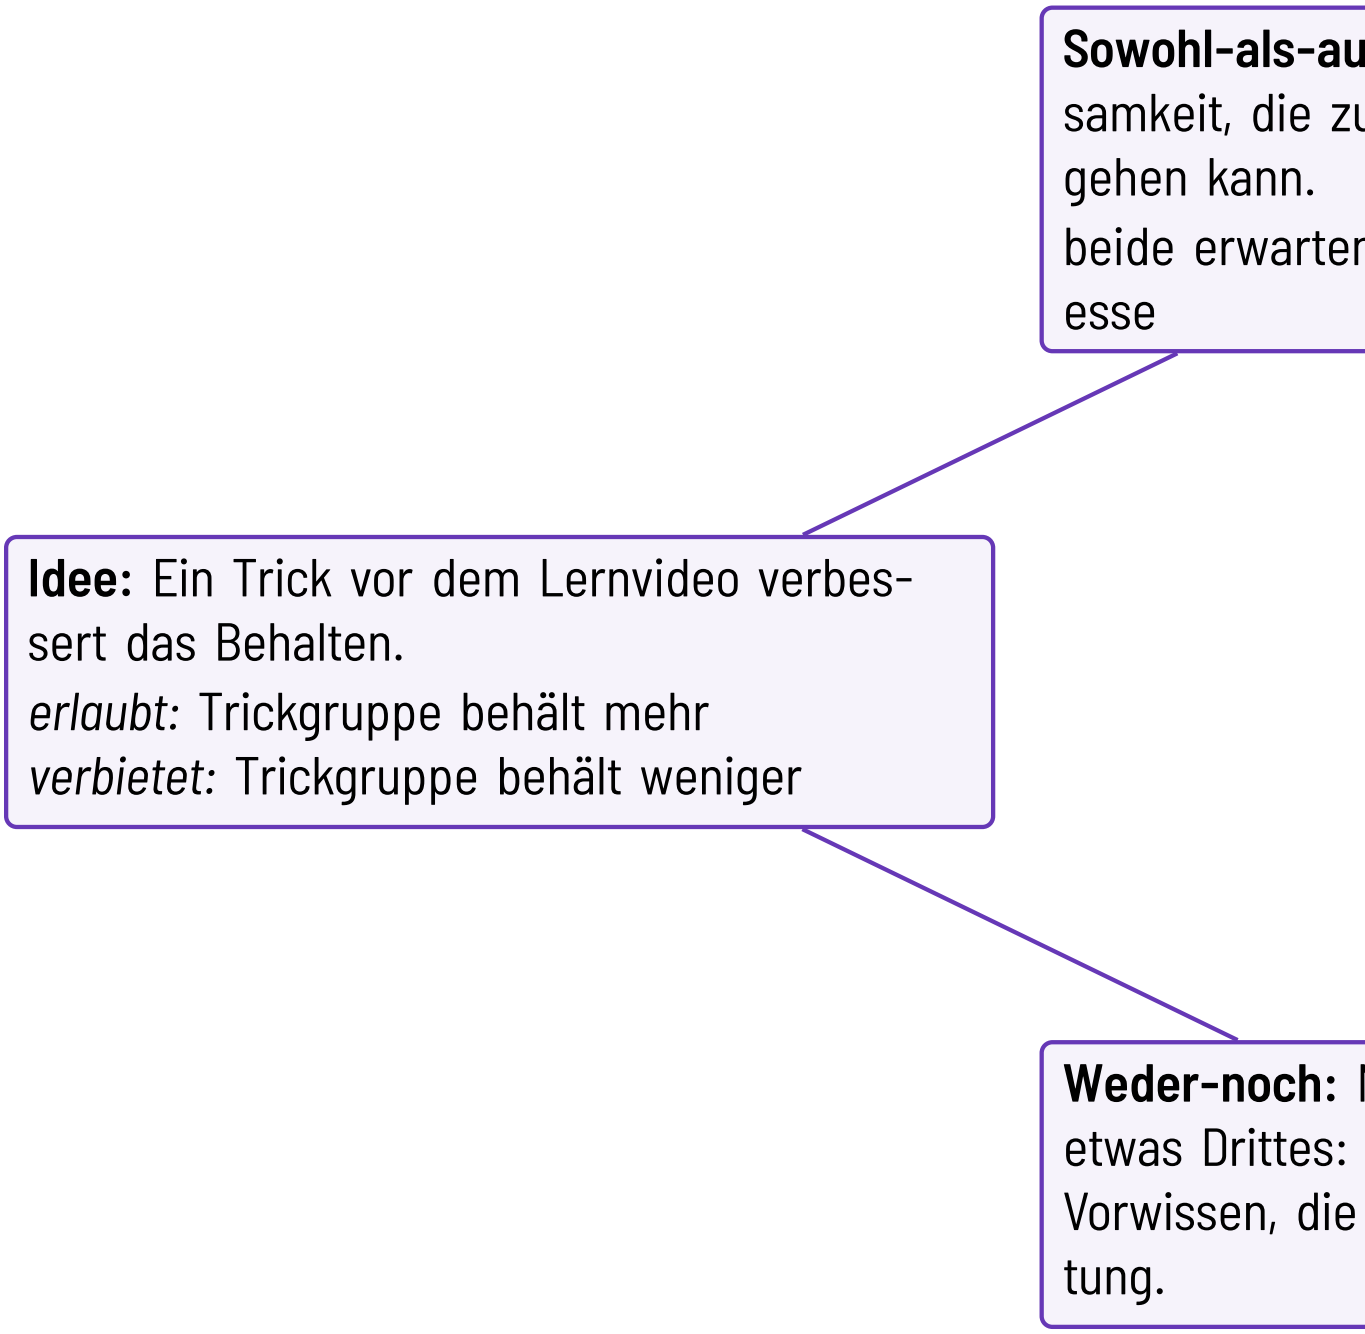


- an jeder Position: Was **erlaubt** sie, was **verbietet** sie? (welche Daten?)
- zum Schluss: Prüfplan und Ökocheck – kann mein n das klären?

Vom Coaching zur Forschungsfrage

Schritt im Diamanten	Frage in der Forschung
Idee	H_1: Was genau behaupte ich, über wen?
Gegenteil	Gegenhypothese: nicht nur „kein Effekt", sondern „der Effekt geht in die andere Richtung"
Sowohl-als-auch	Was sagen Idee *und* Gegenteil voraus? Solche Daten haben $BF \approx 1$ und entscheiden nichts
Weder-noch	dritte Erklärung: Störvariable, andere Ursache, falsch gestellte Frage
ermöglicht / verhindert	welche Beobachtung jede Position erlaubt bzw. verbietet $\Rightarrow$ Likelihoods
neuer Satz	geschärfte Hypothese, die zwischen den Positionen trennt
Future Pace, Ökocheck	Prüfplan: Power, Basisrate, Stoppregel; was würde mich umstimmen?

Beispiel: „Ein Zaubertrick hilft beim Lernen"



Das Beispiel ist die Leitthese des Buchs, an der auch der t-Test dieser Einheit gerechnet wurde, und es führt direkt zu dem Störfaktor, den die Becher-Monty-Hall-Studie selbst benennt: Die Kontrollfassung ist rund zwei Minuten kürzer (*WuZ-Buch*, Kap. 12d; ausführlich in LE 7). Das Gegenteil ist hier keine bloße Verneinung, sondern eine ernstzunehmende Gegenhypothese: Ein verblüffender Einstieg kann Arbeitsgedächtnis binden, das dann für den Inhalt fehlt. In der Stunde wird der Diamant gemeinsam an der Tafel gefüllt; die Folie dient als Lösung.

Welche Beobachtung trennt die Positionen?

Beobachtung	Idee	Gegenteil	Weder-noch (Länge)
Trickgruppe staunt mehr (Manipulationscheck)	0,9	0,9	0,5
Trickgruppe behält mehr als die kürzere Kontrolle	0,7	0,1	0,7
Trickgruppe behält mehr als eine *gleich lange* Kontrolle ohne Staunen	0,7	0,1	0,2

- Zahlen: grob geschätzte Wahrscheinlichkeit der Beobachtung unter jeder Position

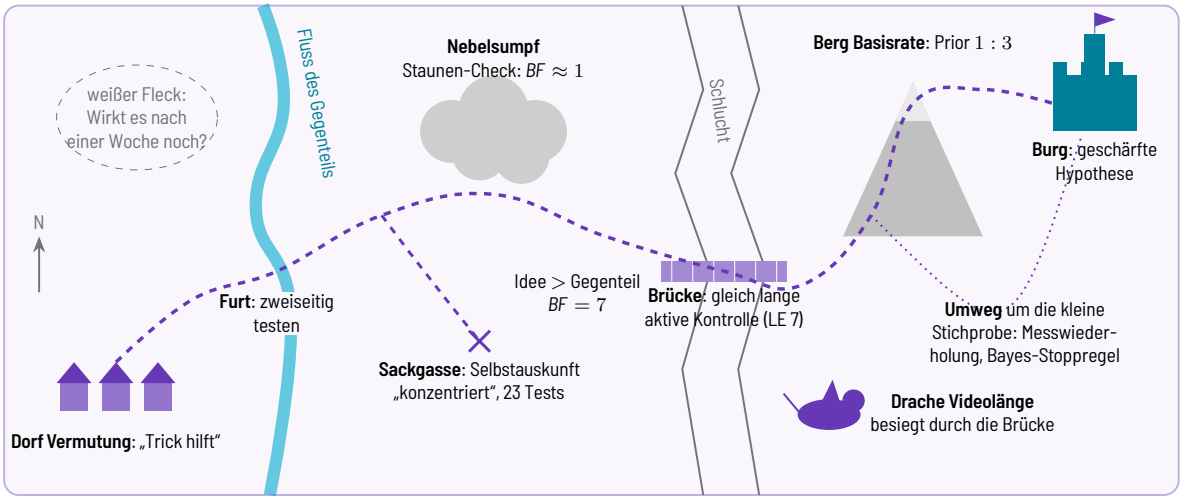
- Zeile 1: Idee gegen Gegenteil $BF = 0{,}9/0{,}9 = 1$ – **Nebel**, entscheidet nichts
- Zeile 2: trennt Idee von Gegenteil ($BF = 7$), aber nicht von der Länge ($BF = 1$)
- Zeile 3: trennt beides ($BF = 7$ bzw. $3{,}5$) – **das ist die Studie, die man bauen muss**

Die Wahrscheinlichkeiten sind Schätzungen, und sie sollen es sein: Es geht nicht um die dritte Nachkommastelle, sondern darum, welche Beobachtung überhaupt zwischen den Positionen unterscheidet. Die Tabelle zeigt in drei Zeilen, warum ein Manipulationscheck zwar nötig, aber kein Beleg für die Idee ist, und warum die längengleiche aktive Kontrolle, die das Buch als Abhilfe vorschlägt, den Unterschied macht. Wer so eine Tabelle vor der Studie aufschreibt, hat seinen Auswertungsplan im Kern schon fertig.

Neuer Satz, Prüfplan, Ökocheck

- **neuer Satz:** „Ein staunenswerter Einstieg verbessert das Behalten gegenüber einem gleich langen Einstieg ohne Staunen, vor allem bei Personen ohne Vorwissen."
- **Basisrate:** offen, eher skeptisch: Prior-Chance $1:3$
- **Power:** erwartet $d \approx 0{,}5$; mit 20 Personen pro Gruppe nur 0,34 $\Rightarrow$ Messwiederholung (zwei Videos je Person) oder Bayes-Faktor mit Stoppregel
- **was mich umstimmt:** $BF_{01} > 6 \Rightarrow$ Idee aufgeben oder neu fassen
- **Ökocheck:** Ist das ethisch und organisatorisch machbar? Täuschen wir jemanden? (LE 13)

Die Landkarte der Untersuchung



Ihre eigene Karte: die Legende

Kartenelement	bedeutet
Dorf (Start)	Ausgangsidee, so naiv, wie sie war
Weg	ein geklärter Schritt, beschriftet mit Beleg oder Bayes-Faktor
Fluss, Furt	das Gegenteil; die Furt ist der Ort, an dem es geprüft wurde
Nebel	Befunde, die zu Idee *und* Gegenteil passen ($BF \approx 1$)
Drache	offene dritte Erklärung (Störvariable)
Brücke	Designentscheidung, die einen Drachen besiegt
Berg	niedrige Basisrate: mehr Evidenz nötig
Sackgasse	verworfene Idee, mit Grund
weißer Fleck	was niemand weiß, auch Sie nicht
Burg (Ziel)	geschärfte Hypothese oder Befund

- Regel: **jedes** Element trägt eine Quelle oder eine Zahl
- Drachen, die am Ende noch stehen, gehören in die Limitationen

Merke

Eine Idee prüft man am besten gegen ihre stärkste Alternative. Der Diamant erzeugt Alternativen, die Tabelle „Welche Beobachtung trennt?“ zeigt, welche Daten sich lohnen, und die Landkarte hält fest, was geklärt ist und was noch im Weg liegt.

Diamant und Landkarte in der Stunde

Den Diamanten am Zaubertrick-Beispiel gemeinsam füllen: vier Felder an der Tafel, Zurufe sammeln, dann erst die Folie zeigen. Erfahrungsgemäß formulieren Studierende das Gegenteil zunächst als bloße Verneinung („Der Trick hilft nicht“); die Rückfrage „Und wenn er schadet, warum?“ führt zur stärkeren Gegenhypothese. Das *Weder-noch* ist der schwierigste Schritt; hilfreich ist die Frage „Was müsste passieren, damit Idee und Gegenteil *beide* falsch sind?“. Für die Landkarte reicht in der Stunde das Zeigen des Beispiels; die eigene Karte entsteht als Hausaufgabe (Teil B, Aufgabe 8) auf einem A3-Blatt und wird in LE 7 zur Design-Skizze mitgebracht. Wer mag, darf zeichnen; bewertet wird nicht die Grafik, sondern ob jedes Element einen Beleg trägt. Eine Grenze sollte man offen ansprechen: Der Diamant stammt aus dem Coaching, wo er Glaubenssätze lockern soll. In der Forschung ist er ein Werkzeug zum Erzeugen von Hypothesen, kein Beleg für irgendetwas.

6.17 Warnung: Bedeutung aus Zufall

Optional, wenn Zeit bleibt (sonst ausführlich in LE 10): eine kurze Demonstration, die zeigt, wie leicht ein „auffälliger“ Befund entsteht, wenn man nur oft genug testet. Jede Person sagt zehn Münzwürfe ihres Nachbarn vorher. Wer acht oder mehr Treffer hat, gilt als „auffällig“: Die Wahrscheinlichkeit dafür beträgt bei reinem Raten $56/1024 \approx 5{,}5\,\%$, liegt also etwa an der üblichen Signifikanzschwelle. Bei 30 Personen ist die Wahrscheinlichkeit, dass mindestens eine Person „auffällig“ wird, $1 - (1 - 0{,}0547)^{30} \approx 81\,\%$; im Mittel sind es 1,6 Personen. Wird jemand „hellsichtig“, ist die Demonstration gelungen. Wird niemand hellsichtig, gelingt sie auch, weil man dann ausrechnet, wie selten das ist. Die ausführliche Fassung mit dem Vorhersage-Trick aus dem Buch (Abschnitt 10d) folgt in LE 10. Dass solche Freiheiten in echten Studien die Fehlerquote weit über die nominellen 5 % treiben, haben Simmons u. a. (2011) gezeigt.

Wer von Ihnen ist hellsichtig?

- sagen Sie zehn Münzwürfe Ihres Nachbarn vorher, notieren Sie die Treffer
- 8 oder mehr Treffer gelten als „auffällig“ (bei Raten: 5,5 %)
- wer hat 8 oder mehr?
- bei 30 Personen gibt es mit etwa 81 % mindestens eine „Hellseherin“

Was ist hier passiert?

- viele Tests: Ein „Treffer“ ist fast garantiert
- wer nur den Treffer berichtet, macht aus Zufall einen Befund
- das ist der Kern von **p-Hacking**
- Gegenprobe: Die „Hellseherin“ sagt noch einmal zehn Würfe vorher
- mehr dazu in LE 10: der Vorhersage-Trick

Die Gegenprobe ist die eigentliche Pointe und sollte nach Möglichkeit live gemacht werden. Die „auffällige“ Person rät beim zweiten Durchgang mit hoher Wahrscheinlichkeit nur noch durchschnittlich. Das ist Regression zur Mitte und zugleich die Logik der Replikation.

Merke

Ein kleiner p-Wert sagt, dass die Daten schlecht zur Nullhypothese passen. Er sagt nicht, dass die eigene Hypothese stimmt, nicht, wie groß der Effekt ist, und gar nichts mehr, wenn man ihn unter vielen Versuchen ausgesucht hat.

6.18 Zeitungsstatistik lesen

Zeitungsstatistik lesen

- Übungsblatt Teil B, Aufgabe 7, oder eine aktuelle Meldung
- Was wurde gemessen, an wem, an wie vielen?
- Was wird behauptet: Beschreibung, Unterschied, Ursache?
- Wird eine Effektgröße genannt oder nur „signifikant“?
- Wie viele Vergleiche wurden vermutlich gerechnet?
- Wie hoch ist die Basisrate für eine solche Behauptung?

Hinweis für Lehrende

Die vollständig nachgerechneten Lösungen stehen im Erwartungshorizont am Ende von Teil B des Übungsblatts. Bei der Datensatz-Analyse (Hausaufgabe nach Sitzung 1) sollte man in der Besprechung (zu Beginn von Sitzung 2 oder in der Sprechstunde) drei Stellen gezielt aufgreifen: (1) Quartile hängen vom Berechnungsverfahren ab; Taschenrechner, Tabellenkalkulation und Handrechnung liefern leicht verschiedene Werte. Das ist kein Fehler, muss aber angegeben werden. (2) Der Vergleich der Vorwissensgruppen kippt je nach Kennwert: Der Mittelwert spricht für einen Unterschied, der Median nicht. Ursache sind der Ausreißer und die größere Streuung in der Gruppe ohne Vorwissen. Der t-Test ist nicht signifikant; das Konfidenzintervall des Unterschieds reicht weit über null hinaus. Der Bayes-Faktor (Sitzung 2) spricht leicht für „kein Unterschied“, ist aber zu klein, um das zu belegen. (3) Die Staunen-Werte sind ordinal; ein Mittelwert wird oft trotzdem berechnet. Bei der Zeitungsstatistik genügt es, wenn die Gruppe mindestens zwei der Fragen auf der Folie beantworten kann und benennt, welche Information fehlt.

6.19 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- das Monty-Hall-Problem mit bedingter Wahrscheinlichkeit erklären
- deskriptive und schließende Statistik unterscheiden
- Standardabweichung und Standardfehler berechnen und unterscheiden
- den Zentralen Grenzwertsatz erklären und ein Konfidenzintervall richtig deuten
- einen Binomialtest und einen t-Test von Hand rechnen und typische Fehldeutungen des p-Werts benennen
- mit Basisrate und Bayes-Faktor in Chancenform rechnen und erklären, warum derselbe Befund je nach Basisrate Verschiedenes bedeutet
- frequentistische und bayesianische Fragen unterscheiden
- Effektgröße, Power und Stichprobengröße in Beziehung setzen und abschätzen, welche Frage Ihr Projekt beantworten kann
- eine Idee mit dem Diamanten in Gegenhypothesen zerlegen und die Beobachtungen benennen, die zwischen ihnen trennen

Bis zur nächsten Woche

- **Basisrate** (Teil B, Aufgabe 5): Taxi und Zeuge
- **Zeitungsmeldung** methodisch lesen (Teil B, Aufgabe 7)
- **Diamant und Landkarte** für Ihre eigene Idee (Teil B, Aufgabe 8), auf A3, mitbringen zu LE 7
- **Auswertungsplan** für Ihr Projekt (Teil B, Aufgabe 9): Zielgröße, kleinster interessanter Effekt, realistisches n, Power – Sie brauchen ihn für die Design-Skizze in LE 7
- **Tagebuch des Staunens**: Wann hat Ihr Gefühl für Wahrscheinlichkeit Sie zuletzt getäuscht?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 6**

Handout: Statistik: Signifikanztest und Bayes

Worum es heute ging. Drei Becher, eine Kugel: Die Spielleitung öffnet wissentlich einen leeren Becher, Wechseln gewinnt in zwei von drei Fällen. Öffnet sie blind, ist es egal. Dasselbe Bild, zwei Prozesse, zwei Wahrscheinlichkeiten. Statistik prüft solche Täuschungen der Intuition, und zwar auf zwei Arten.

	frequentistisch	**bayesianisch**
Frage	Wie überraschend wären die Daten, wenn H_0 stimmt?	Welche Hypothese sagt die Daten besser voraus?
Ergebnis	p-Wert, Konfidenzintervall	Bayes-Faktor, Posterior
braucht	H_0, α, n vorab festgelegt	H_0, konkrete H_1, Prior (Basisrate)
kann nicht	H_0 stützen; sagen, wie wahrscheinlich H ist	ohne offen gelegten Prior auskommen

Kernbegriffe

Standardabweichung, Standardfehler s: typischer Abstand der *Werte* vom Mittelwert. $SE = s/\sqrt{n}$: wie genau der *Mittelwert* bestimmt ist; schrumpft mit wachsendem n.

Zentraler Grenzwertsatz Mittelwerte vieler unabhängiger Werte sind annähernd normalverteilt, egal wie die Einzelwerte verteilt sind.

Konfidenzintervall Schätzwert $\pm 1{,}96\,SE$; das Verfahren fängt den wahren Wert in 95 % der Wiederholungen ein.

Bedingte Wahrscheinlichkeit $P(A \mid B)$. Die Richtung zählt: $P(\text{Daten} \mid H) \neq P(H \mid \text{Daten})$.

p-Wert Wahrscheinlichkeit für mindestens so extreme Daten, *falls* H_0 stimmt. Kein Maß für die Wahrheit einer Hypothese und keins für die Größe eines Effekts (Wasserstein und Lazar 2016).

Basisrate Wie häufig ist das Gesuchte, bevor man hinschaut? Ohne sie lässt sich kein positiver Test und kein signifikanter Befund deuten.

Bayes-Faktor $BF_{10} = P(\text{Daten} \mid H_1)/P(\text{Daten} \mid H_0)$: 1–3 kaum der Rede wert, 3–20 positiv, über 20 stark (Kass und Raftery 1995); unter 1 spricht für H_0.

Effektgröße, Power Cohens d (0,2 klein, 0,5 mittel, 0,8 groß); Power = Chance, einen vorhandenen Effekt zu finden. Für $d = 0{,}5$ und Power 0,80: 64 Personen pro Gruppe.

Rechnen in drei Zeilen

- Chancenform: *Chance nachher* = *Chance vorher* $\times$ BF_{10}; Chance $a : b$ = Wahrscheinlichkeit $a/(a+b)$. Würfel, 10 Sechsen in 30 Würfen, „gezinkt" = $P(6) = \frac{1}{3}$: $BF_{10} = 2^{10} \cdot 0{,}8^{20} \approx 12$; bei Basisrate $1:4$ also $12:4$, rund 75 %.
- t-Test, zwei Gruppen: $t = (\bar{x}_1 - \bar{x}_2) \,/\, (s_p\sqrt{1/n_1 + 1/n_2})$, $df = n_1 + n_2 - 2$; $d = (\bar{x}_1 - \bar{x}_2)/s_p$.
- Faustformel (Wagenmakers 2007): $BF_{01} \approx \sqrt{N}\,(1 + t^2/df)^{-N/2}$, N = alle Personen. Genauer: JASP.

Skalen: nominal (Modus), ordinal (Median, Quartile), metrisch (Mittelwert, s). Ausreißer nach Tukey (1977): mehr als $1{,}5 \cdot IQR$ unter Q_1 oder über Q_3.

Merke

Erst fragen, wie die Daten zustande kamen, dann rechnen. Ein kleiner p-Wert ist kein Beweis; was man glauben sollte, bestimmen die Daten *und* die Basisrate. Und vor jeder Studie: Kann mein n die Frage überhaupt beantworten?

Zum Weiterlesen: Döring und Bortz (2016b), Kap. 12; Wagenmakers (2007); Gigerenzer und Hoffrage (1995); zum Ziegenproblem Krauss und Wang (2003).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 6**

Übungsblatt A: Becher, Würfel und Daten

Name: _____ Datum: _____

Aufgabe 1: Monty Hall in Paaren

in der Stunde, Paare, 10 Min.

Die Spielleitung würfelt verdeckt die Lage der Kugel (1–2: A, 3–4: B, 5–6: C), die spielende Person zeigt auf einen Becher, die Spielleitung öffnet einen *leeren*, nicht gewählten Becher. Ungerade Runden: bleiben, gerade Runden: wechseln. Kreuzen Sie an, ob gewonnen wurde.

Rd.	Strategie	Kugel	gewonnen	Rd.	Strategie	Kugel	gewonnen
1	bleiben			13	bleiben		
2	wechseln			14	wechseln		
3	bleiben			15	bleiben		
4	wechseln			16	wechseln		
5	bleiben			17	bleiben		
6	wechseln			18	wechseln		
7	bleiben			19	bleiben		
8	wechseln			20	wechseln		
9	bleiben			21	bleiben		
10	wechseln			22	wechseln		
11	bleiben			23	bleiben		
12	wechseln			24	wechseln		

Summe: **bleiben** _____ von _____ gewonnen **wechseln** _____ von _____ gewonnen Kurs gesamt (Tafel): _____

Aufgabe 2: Würfel-Mittelwerte: der Zentrale Grenzwertsatz

in der Stunde, einzeln, 8 Min.

Würfeln Sie fünfmal und notieren Sie die Augenzahlen. Berechnen Sie den Mittelwert. Wiederholen Sie das viermal und tragen Sie alle vier Mittelwerte als Punkte auf der Zahlengerade an der Tafel ein.

Serie	1.	2.	3.	4.	5.	Mittelwert
1						
2						
3						
4						

1. *Vor* dem Würfeln: Ein einzelner Wurf hat Mittelwert 3,5 und Standardabweichung 1,71. Wie groß ist der Standardfehler eines Mittelwerts aus 5 Würfen? Zwischen welchen Werten sollten etwa 95 % der Punkte an der Tafel liegen?
2. Stimmt Ihre Vorhersage mit dem Bild an der Tafel überein? Welche Form hat es?
3. Wie würde das Bild aussehen, wenn jeder Punkt der Mittelwert aus 20 Würfen wäre?

Aufgabe 3: Datensatz-Analyse

Hausaufgabe, Kleingruppe

Fiktiver Datensatz (konstruiert für diese Übung, keine echte Erhebung): 50 Personen haben ein Ideomotor-Pendel gehalten (vgl. LE 1). Gemessen wurde der größte Ausschlag in Millimetern (**mm**), danach gaben die Personen an, wie stark sie gestaunt haben (**St**, 1 = gar nicht bis 5 = sehr), und ob sie den Pendeleffekt vorher kannten (**VW**, 1 = ja, 0 = nein).

Nr	mm	St	VW	Nr	mm	St	VW	Nr	mm	St	VW	Nr	mm	St	VW	Nr	mm	St	VW
1	11	3	0	11	9	3	0	21	10	2	1	31	43	3	1	41	47	4	0
2	5	2	0	12	24	2	0	22	26	4	1	32	57	4	0	42	59	3	0
3	15	3	1	13	24	4	1	23	39	4	0	33	21	3	0	43	26	3	0
4	41	4	1	14	8	2	0	24	15	4	0	34	96	5	0	44	31	4	1
5	37	3	0	15	16	2	1	25	13	3	0	35	49	4	0	45	23	2	0
6	39	5	0	16	25	4	0	26	13	3	0	36	30	4	0	46	20	3	1
7	18	3	0	17	19	5	0	27	66	5	0	37	23	4	0	47	12	1	1
8	0	1	0	18	53	4	1	28	35	3	1	38	53	4	0	48	36	4	1
9	16	2	1	19	5	2	1	29	38	5	0	39	18	2	0	49	18	3	0
10	31	4	1	20	45	5	0	30	26	3	1	40	73	5	0	50	40	4	0

1. Bestimmen Sie für jede Variable das Skalenniveau.
2. Berechnen Sie für **mm**: Minimum, Maximum, Spannweite, Median, Q_1, Q_3, *IQR* und Mittelwert. Geben Sie an, wie Sie die Quartile bestimmt haben.
3. Zeichnen Sie ein Histogramm (Klassenbreite 10 mm) und einen Boxplot. Gibt es Ausreißer nach der $1{,}5 \cdot IQR$-Regel (Werte mehr als $1{,}5 \cdot IQR$ unter Q_1 oder über Q_3)? Was würden Sie mit ihnen tun?
4. Berechnen Sie Mittelwert und Median von **mm** ohne den Ausreißer. Welcher Kennwert reagiert stärker, und warum?
5. Fassen Sie **St** sinnvoll zusammen. Ist ein Mittelwert zulässig?
6. Berechnen Sie den Standardfehler des Mittelwerts von **mm** und ein 95-%-Konfidenzintervall. Was sagt das Intervall, was nicht?
7. Vergleichen Sie **mm** zwischen Personen mit und ohne Vorwissen mit Mittelwert *und* Median. Was fällt auf?
8. Rechnen Sie für denselben Vergleich einen t-Test von Hand (gepoolte Standardabweichung). Nach Sitzung 2: Ergänzen Sie den Bayes-Faktor nach der Faustformel. Was sagen beide Ergebnisse, und was sagen sie nicht?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 6**

Übungsblatt B: Würfel-Detektive, Basisrate, Glaubwürdigkeit, Projekt

Name: _____ Datum: _____

Aufgabe 4: Würfel-Detektive

in der Stunde, Paare, 10 Min.

Rollen: W = Werferin, D = Detektivin. **1.** W öffnet den Umschlag und liest die Karte *allein*: „fair" (Treffer ist nur die 6) oder „gezinkt" (Treffer sind 5 und 6). **2.** W würfelt verdeckt unter einem Becher und sagt nur „Treffer" oder „kein Treffer". **3.** D macht einen Strich, nach genau **30** Würfen ist Schluss. **4.** D wertet beide Wege aus und entscheidet. **5.** Erst dann deckt W die Karte auf. Bekannt ist: Jeder fünfte Umschlag ist gezinkt (Basisrate $1:4$).

Treffer (Strichliste)	
Kein Treffer (Strichliste)	

Treffer k	3	4	5	6	7	8	9	10	11	12	13	14
$p = P(X \geq k \mid \text{fair})$	0,90	0,76	0,58	0,38	0,22	0,11	0,051	0,020	0,007	0,002	0,0005	0,0001
$BF_{10} = 2^k \cdot 0{,}8^{30-k}$	0,02	0,05	0,12	0,30	0,76	1,9	4,7	11,8	30	74	184	461
$P(\text{gezinkt})$ bei $1:4$	0,5 %	1 %	3 %	7 %	16 %	32 %	54 %	75 %	88 %	95 %	98 %	99 %

1. **Frequentistisch:** H_0: fair. p-Wert für Ihr k: _____. Bei $\alpha = 0{,}05$ ist der Würfel ☐ signifikant gezinkt ☐ nicht auffällig.
2. **Bayesianisch:** BF_{10} = _____; Chance vorher $1:4$, Chance nachher _____; $P(\text{gezinkt})$ = _____. Rechnen Sie einmal selbst nach, ohne die letzte Zeile der Tabelle.
3. Umschlag öffnen. Wer hatte recht? Tragen Sie Ihr Paar an der Tafel in die Vierfeldertafel ein.
4. Wie sähe Ihr Bayes-Urteil aus, wenn nur einer von 100 Würfeln gezinkt wäre? Und Ihr Testurteil?

Aufgabe 5: Basisrate: Taxi und Test

Hausaufgabe

In einer Stadt fahren 85 % grüne und 15 % blaue Taxis. Nach einem Unfall mit Fahrerflucht sagt ein Zeuge, das Taxi sei blau gewesen. Tests zeigen: Unter den Sichtbedingungen jener Nacht erkennt er die Farbe in 80 % der Fälle richtig (Tversky und Kahneman 1982).

1. Schätzen Sie zuerst aus dem Bauch: Wie wahrscheinlich war das Taxi blau?
2. Rechnen Sie mit natürlichen Häufigkeiten (100 Unfälle) und zeichnen Sie den Baum wie auf der Folie zum Medizintest.
3. Rechnen Sie dasselbe in Chancenform: Prior-Chance, Bayes-Faktor des Zeugen, Posterior-Chance.
4. Ein zweiter, unabhängiger Zeuge mit derselben Treffsicherheit sagt ebenfalls „blau". Wie wahrscheinlich ist es jetzt?
5. In einer anderen Stadt sind die Hälfte der Taxis blau. Was ändert sich bei einem Zeugen, was nicht?

Aufgabe 6: Glaubwürdigkeits-Check mit der Suchmaschine

in der Stunde, Kleingruppe, 12 Min.

Behauptung (Karte): _____

Basisrate *vor* der Suche: Von 100 Behauptungen dieser Art stimmen etwa _____, weil

Fund (Quelle, was steht dort?)	**erwartbar, wenn wahr? wenn falsch?**	**Faktor**	**Chance**
Start: Basisrate		–	

Faktoren grob: $\times 10$, $\times 3$, $\times 1$, $\times \frac{1}{3}$, $\times \frac{1}{10}$. Nur unabhängige Funde multiplizieren; zehn Seiten mit derselben Pressemitteilung sind *ein* Fund. Ergebnis: $P(\text{stimmt}) \approx$ _____. Welcher Fund hat am meisten bewegt?

Aufgabe 7: Eine Zeitungsmeldung lesen

Hausaufgabe

Fiktive Meldung (konstruiert für diese Übung):

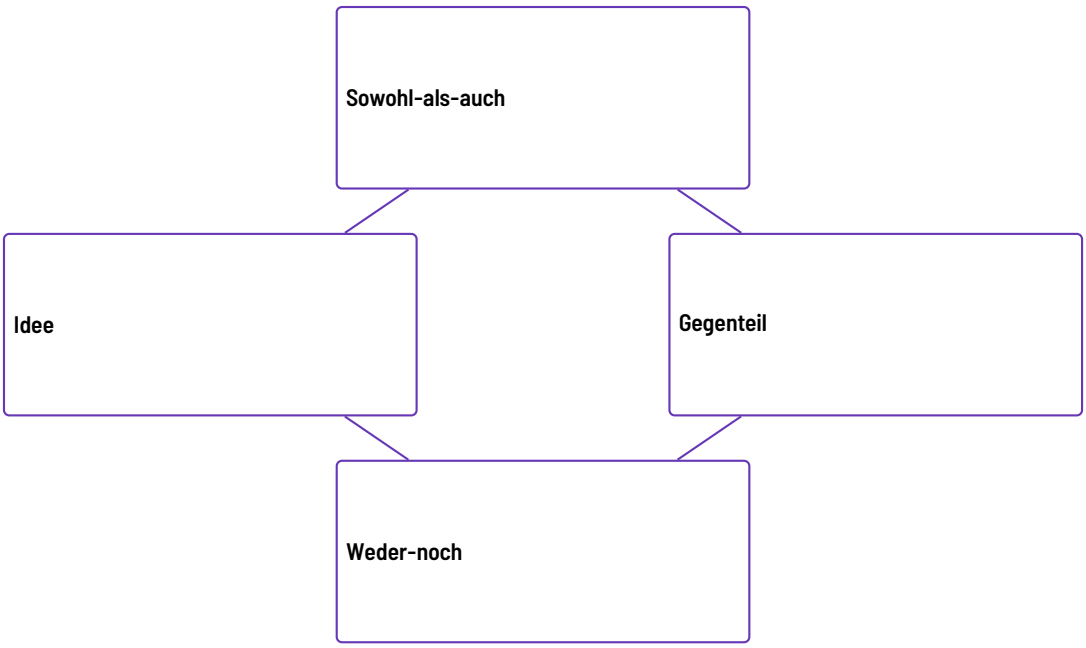
> *Zaubertricks machen klüger – jetzt bewiesen.* Wer vor dem Lernen einen Zaubertrick sieht, behält mehr. Das zeigt eine Online-Befragung unter 112 Studierenden. Die Forschenden erhoben 23 Merkmale des Lernverhaltens. Bei der Frage „Ich konnte mich gut konzentrieren" lag die Gruppe mit Zaubertrick signifikant vorn ($p = 0{,}04$). „Damit ist der Nutzen von Magie im Hörsaal wissenschaftlich belegt", sagt die Studienleiterin.

Beantworten Sie: Was wurde gemessen, an wem? Was wird behauptet? Wird eine Effektgröße genannt? Wie viele Vergleiche wurden gerechnet, und was folgt daraus für den einen signifikanten Befund? Welche Basisrate würden Sie für die Behauptung ansetzen? Wer mag, wendet dieselben Fragen auf einen echten Artikel an, der eine Studie mit $p < 0{,}05$ als „Beweis" darstellt.

Aufgabe 8: Diamant und Landkarte für Ihre Idee

Hausaufgabe, A3, mitbringen zu LE 7

Nehmen Sie Ihre Hypothese aus LE 5 als *Idee* und füllen Sie den Diamanten. Notieren Sie an jeder Position, welche Beobachtung sie *erlaubt* und welche sie *verbietet*.



1. Welche Beobachtung trennt Idee und Gegenteil? Welche trennt die Idee vom Weder-noch? Schätzen Sie grob, wie wahrscheinlich die Beobachtung unter jeder Position ist, und berechnen Sie den Bayes-Faktor.

2. Formulieren Sie den neuen, geschärften Satz.

3. Zeichnen Sie auf A3 die Landkarte Ihrer Untersuchung (Legende auf der Folie): Startdorf, Wege, Nebel, Drachen, Brücken, Sackgassen, weiße Flecken, Ziel. Jedes Element trägt eine Quelle oder eine Zahl.

Aufgabe 9: Auswertungsplan für Ihr Projekt

Hausaufgabe, Grundlage der Design-Skizze in LE 7

H_1 (aus LE 5)	
Zielgröße und Skalenniveau	
Vergleich: zwei Gruppen, Messwiederholung oder Anteile?	
kleinster Effekt, der Sie interessieren würde	
realistisches n (wer, wie viele?)	
Power laut Tabelle auf der Folie	
Auswertung: Test, Schätzung mit Intervall oder Bayes-Faktor mit Stoppregel?	
Basisrate Ihrer Hypothese: Wie überraschend wäre es, wenn sie stimmt?	
Folgerung: Passt die Frage zum n, oder ändern Sie Frage oder Design?	

Aufgabe 10: Tagebuch des Staunens

Hausaufgabe

Wann hat Ihr Gefühl für Wahrscheinlichkeit Sie zuletzt getäuscht? Notieren Sie Erwartung, Ereignis und den passenden Begriff aus dieser Einheit.

Erwartungshorizont

Aufgabe 1. Erwartet sind pro Paar etwa 8 von 12 Gewinnen beim Wechseln und 4 von 12 beim Bleiben. Einzelne Paare streuen stark (die Standardabweichung der Gewinnzahl bei 12 Wechselrunden beträgt etwa 1,6), manche Paare finden sogar das Gegenteil. Erst der Kurs-Pool zeigt das Muster stabil. Das ist der Anlass, über Stichprobengröße zu sprechen.
Aufgabe 2. (1) $SE = 1{,}71/\sqrt{5} \approx 0{,}76$; etwa 95 % der Mittelwerte zwischen $3{,}5 \pm 2 \cdot 0{,}76$, also 2,0 und 5,0. (2) Das Bild ist eine Glocke um 3,5, obwohl einzelne Würfe gleichverteilt sind; von 120 Punkten liegen im Mittel etwa vier außerhalb von 2,0 bis 5,0 (exakt 3,2 % je Punkt; die Normalnäherung sagt 5 %). (3) Mit 20 Würfen: $SE \approx 0{,}38$, die Glocke wäre halb so breit (etwa 2,7 bis 4,3).
Aufgabe 3 (Werte mit Python nachgerechnet). (1) Nr: nominal (Kennung); mm: Verhältnisskala; St: ordinal; VW: nominal (dichotom). (2) $n = 50$; Minimum 0, Maximum 96, Spannweite 96 mm; Median 25,5 mm; Mittelwert 29,94 mm; Standardabweichung $s = 19{,}32$ mm. Quartile als Median der unteren bzw. oberen Hälfte: $Q_1 = 16$, $Q_3 = 40$, $IQR = 24$. Mit linearer Interpolation (z. B. Excel `QUARTILE.INKL`) ergibt sich $Q_3 = 39{,}75$ und $IQR = 23{,}75$; beides ist richtig, wenn das Verfahren genannt wird. Modus: 18 und 26 (je dreimal). (3) Klassenhäufigkeiten 0–9: 5; 10–19: 13; 20–29: 10; 30–39: 9; 40–49: 6; 50–59: 4; 60–69: 1; 70–79: 1; 80–89: 0; 90–99: 1. Die Verteilung ist rechtsschief. Zäune: $16 - 36 = -20$ und $40 + 36 = 76$. Einziger Ausreißer ist Nr. 34 mit 96 mm; 73 mm (Nr. 40) liegt knapp innerhalb. Mit Interpolation liegen die Zäune bei $-19{,}6$ und $75{,}4$; Ergebnis gleich. Gute Antworten löschen den Wert nicht stillschweigend, sondern prüfen ihn (Messfehler? jemand hat bewusst geschwungen?) und berichten beide Auswertungen. (4) Ohne Nr. 34: Mittelwert 28,59 mm, Median 25,0 mm, $s = 16{,}98$ mm. Der Mittelwert sinkt um 1,35 mm, der Median um 0,5 mm, die Standardabweichung um 2,3 mm. (5) Häufigkeiten St: 1: 2; 2: 9; 3: 15; 4: 17; 5: 7. Median 3, Modus 4. Ein Mittelwert (3,36) ist streng genommen nicht zulässig, weil die Abstände der Stufen unbekannt sind; wer ihn angibt, sollte das begründen. Optional: Spearmans Rangkorrelation zwischen mm und St beträgt $\rho = 0{,}71$. (6) Mit Vorwissen ($n = 17$): Mittelwert 25,88 mm, Median 26 mm, $s = 13{,}06$. Ohne Vorwissen ($n = 33$): Mittelwert 32,03 mm, Median 25 mm, $s = 21{,}75$. Der Mittelwert legt einen Unterschied von gut 6 mm nahe, der Median fast keinen; die Gruppe ohne Vorwissen streut stärker und enthält die beiden größten Werte (73 und 96 mm). Die erwartete Antwort: Aus

diesen Daten folgt kein belastbarer Gruppenunterschied, und die Wahl des Kennwerts bestimmt die Geschichte, die man erzählen könnte. (7) $SE = 19{,}32/\sqrt{50} \approx 2{,}73$ mm; 95-%-Intervall $29{,}94 \pm 1{,}96 \cdot 2{,}73$, also 24,6 bis 35,3 mm (mit $t_{49} = 2{,}01$: 24,4 bis 35,4 mm). Das Intervall beschreibt die Unsicherheit des *Mittelwerts*, nicht die Streuung der Personen: Die meisten Einzelwerte liegen außerhalb. Wegen der schiefen Verteilung trägt hier der Zentrale Grenzwertsatz; bei $n = 50$ ist das vertretbar. (8) Gepoolte Standardabweichung $s_p = 19{,}3$ mm, $SE = s_p\sqrt{1/33 + 1/17} = 5{,}76$ mm, $t = (32{,}03 - 25{,}88)/5{,}76 = 1{,}07$, $df = 48$, $p = 0{,}29$; $d = 0{,}32$. 95-%-Intervall des Unterschieds: $6{,}15 \pm 2{,}01 \cdot 5{,}76$, also $-5{,}4$ bis $17{,}7$ mm, es schließt null deutlich ein. Welch-Test: $t = 1{,}25$, $p = 0{,}22$. Nach Sitzung 2, Faustformel: $BF_{01} \approx \sqrt{50}\,(1 + 1{,}14/48)^{-25} \approx 7{,}07 \cdot 0{,}56 \approx 3{,}9$; JASP (JZS, $r = \sqrt{2}/2$) liefert $BF_{01} = 2{,}1$. Erwartete Deutung: kein signifikanter Unterschied; die Daten sprechen leicht für „kein Unterschied", belegen ihn aber nicht. Der Ausreißer (Nr. 34) treibt den Mittelwertunterschied; der t-Test vergleicht Mittelwerte und erbt diese Empfindlichkeit.

Aufgabe 4. Tabellenwerte exakt mit $B(30, \frac{1}{6})$ bzw. $B(30, \frac{1}{3})$ gerechnet. Signifikant ($\alpha = 0{,}05$, einseitig) ist ein Würfel ab 10 Treffern. Ein fairer Würfel erreicht das mit 2,0 %, ein gezinkter mit 57 %. Die Bayes-Regel „gezinkt, wenn $P(\text{gezinkt}) > 50\,\%$" greift bei Basisrate $1 : 4$ ab 9 Treffern (fair: 5,1 %, gezinkt: 71 %). Nachrechnen für $k = 10$: $2^{10} = 1024$, $0{,}8^{20} = 0{,}0115$, $BF_{10} = 11{,}8$; Chance $11{,}8 : 4$, also $11{,}8/15{,}8 = 75\,\%$. (4) Bei Basisrate $1 : 99$ und $k = 10$: $11{,}8 : 99$, also 11 %. Der Würfel ist dann trotz „signifikant" wahrscheinlich fair; das Testurteil ändert sich nicht, weil der Test die Basisrate nicht kennt. Bei 15 Paaren streut die Vierfeldertafel stark; erwartet sind 0–1 falsche Alarme und 1–2 erkannte von 3 gezinkten Würfeln.

Aufgabe 5. (1) Die meisten schätzen 80 %. (2) Von 100 Unfällen sind 15 mit blauen Taxis, davon erkennt der Zeuge 12 als blau; von 85 grünen hält er 17 für blau. $P(\text{blau} \mid \text{„blau"}) = 12/29 \approx 41\,\%$. (3) Prior-Chance $15 : 85$, $BF = 0{,}8/0{,}2 = 4$, Posterior $60 : 85$, also 41 %. (4) $60 : 85 \times 4 = 240 : 85$, also 74 %. (5) Prior $1 : 1$, Posterior $4 : 1$, also 80 %: Nur bei gleicher Basisrate stimmt das Bauchgefühl. Der Bayes-Faktor des Zeugen bleibt 4; er beschreibt den Zeugen, nicht die Stadt.

Aufgabe 6. Siehe den Hinweis zu den Behauptungskarten im Abschnitt „Glaubwürdigkeits-Check".

Aufgabe 7. Gemessen: Selbstauskunft, keine Lernleistung; Online-Befragung, unklar, ob die Gruppen zufällig gebildet wurden. 23 Merkmale: Bei $\alpha = 0{,}05$ erwartet man unter reinem Zufall gut einen „signifikanten" Befund ($23 \cdot 0{,}05 \approx 1{,}2$); die Wahrscheinlichkeit für mindestens einen liegt bei $1 - 0{,}95^{23} \approx 69\,\%$. Keine Effektgröße. Die Basisrate für „ein Zaubertrick verbessert das Lernen" ist offen, für „er verbessert genau die Konzentrations-Selbstauskunft, sonst nichts" niedrig. „Bewiesen" ist nichts; allenfalls liegt eine Hypothese für eine präregistrierte Folgestudie vor (Brücke zu LE 10).

Aufgabe 8. Ein gutes Gegenteil ist eine eigene Hypothese mit eigener Begründung, keine bloße Verneinung. Das Weder-noch sollte mindestens eine Störvariable enthalten, die in LE 7 kontrolliert werden kann. Entscheidend ist (1): Eine Beobachtung, die alle Positionen gleich gut erwarten, ist als Beleg wertlos; gute Lösungen erkennen das selbst. Bei der Karte wird nicht die Zeichnung bewertet, sondern ob jedes Element einen Beleg oder eine Zahl trägt und ob offene Drachen ehrlich stehen bleiben.

Aufgabe 9. Gute Pläne nennen eine konkrete Zielgröße, einen begründeten kleinsten Effekt und ein n, das sich wirklich rekrutieren lässt. Häufigste Einsicht: Mit 15–20 Personen pro Gruppe ist nur ein großer Effekt zu finden; sinnvolle Antworten sind Messwiederholung, eine metrische statt einer Ja/Nein-Zielgröße, eine Schätzfrage statt eines Tests oder ein sequentieller Bayes-Faktor mit Höchstzahl.