7 Forschungsdesign

In LE 5 wurde aus der Forschungsfrage eine Hypothese mit Widerlegungsbedingung, in LE 6 kam das Werkzeug dazu, mit dem man Daten befragt: Signifikanztest, Bayes-Faktor, Basisrate und Power. Damit ist klar, welche Fragen eine kleine Studie überhaupt beantworten kann. Jetzt geht es um den Plan, mit dem man die eigene Hypothese prüft. Ein Forschungsdesign legt fest, wer was wann unter welchen Bedingungen misst und womit verglichen wird. Die Einheit beginnt mit drei Seilen unterschiedlicher Länge, die gleich lang werden. Die Gruppe sieht das Kunststück zweimal: einmal so, wie es auf der Bühne gezeigt wird, und einmal unter Bedingungen, die sie selbst festlegt. Der Unterschied zwischen beiden Durchgängen ist der Unterschied zwischen einer Behauptung und einem Experiment. Daraus entwickelt die Einheit Designtypen, interne und externe Validität, Konfundierung und Kontrolle sowie die Gütekriterien von Messungen. Als Fallbeispiel dient die Becher-Monty-Hall-Studie aus dem Buch, mit einem sauberen Idealentwurf und einer Feldstudie, die zeigt, was in der Praxis davon übrig bleibt.

Vorbereitung vor der Stunde: Kontrollierte Seilroutine

Eine Woche vorher

- ☐ Seil-Set für eine Routine, in der drei Seile unterschiedlicher Länge gleich lang werden (klassischer Effekt, im Fachhandel als fertiges Set erhältlich oder nach der Standardliteratur selbst zusammengestellt). Zwei vollständige Sets einpacken; Seile werden schnell unansehnlich.
- ☐ **Methode und Einstudierung nach der Anleitung des Herstellers bzw. der Standardliteratur; hier bewusst nicht beschrieben.** Das Skript wird öffentlich gespiegelt.
- ☐ Zwei Präsentationen proben. *Variante A* wie auf der Bühne: Seile zeigen, Längen behaupten, Effekt, Seile ins Publikum. Dauer etwa drei Minuten. *Variante B* mit Kontrollbedingung: Die Gruppe legt vorab fest, wie Ausgangs- und Endlängen geprüft werden.
- ☐ Vor der Probe von Variante B entscheiden, welche Prüfungen Sie zulassen und welche Sie ausdrücklich verweigern. Faustregel: Alles, was die Methode gefährden könnte, wird freundlich und offen abgelehnt („Diese Kontrolle lasse ich nicht zu."). Die Ablehnung ist kein Notbehelf, sondern der didaktische Kern der Variante.
- ☐ Für Variante B ein Maßband oder einen Zollstock (2 m) und einen Flipchart-Bogen für das Messprotokoll bereitlegen.
- ☐ Das Fallbeispiel vorbereiten: *WuZ-Buch*, Kap. 12d (Studienlogik, Beat-Plan, Längendifferenz) und *WuZ-Buch*, Kap. 12f (Feldstudie, Ergebnisse). Zahlen nur so verwenden, wie sie dort stehen.

Handout und Übungsblatt

- ☐ Handout „Forschungsdesign" sowie Übungsblatt LE 7 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 7). Teil A enthält die fiktive Studienbeschreibung für die Design-Analyse und die Vorlage für die Design-Skizze vollständig und liegt zu Beginn aus; Teil B (Peer-Feedback, Tagebuch) wird zur Sicherung ausgeteilt.
- ☐ Die H_0/H_1-Blätter aus LE 5 (Aufgabe 3) zurückgeben bzw. mitbringen lassen; sie sind die Grundlage der eigenen Design-Skizze.
- ☐ Optional statt des fiktiven Falls einen echten, kurzen empirischen Artikel aus dem Fach der Gruppe auswählen (Methodenteil höchstens zwei Seiten, klare Gruppenvergleiche). Dann den Methodenteil pro Zweiergruppe einmal kopieren.

Am Tag selbst

- ☐ Seile vor der Stunde vorbereiten; das Ersatzset griffbereit, aber außer Sicht.
- ☐ Tafel in zwei Spalten teilen: „Variante A: Was haben wir gesehen?" und „Variante B: Was haben wir gemessen?".
- ☐ Für die Design-Werkstatt Zweiergruppen einteilen, die sich in der Feedback-Phase gegenseitig die Skizzen vorstellen.

Risiken und Plan B. Die Seilroutine ist bekannt; es kann sein, dass jemand sie schon gesehen hat oder die Methode kennt. Diese Person bitten, ihr Wissen für sich zu behalten, und den Umstand selbst nutzen: Vorwissen ist eine Störvariable, und genau sie hat in der Monty-Hall-Feldstudie alle Armunterschiede überstrahlt (siehe Fallbeispiel). Misslingt der Effekt, wird er nicht wiederholt; dann trägt Variante B die Stunde allein, indem die Gruppe ein Messprotokoll für eine Behauptung entwirft, die die Lehrperson nur ankündigt. Ohne Seile lässt sich der Einstieg mit einer bekannten Längentäuschung (Müller-Lyer-Figur) erst ohne, dann mit Lineal ersetzen.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Von der Hypothese (LE 5) und dem Auswertungsplan (LE 6, Hausaufgabe) zum Prüfplan: „Wie würden Sie Ihre Hypothese testen, und wie viele Personen brauchen Sie dafür?" Zwei, drei Antworten sammeln. Die Landkarten aus LE 6 liegen aus; ihre Drachen sind die Störvariablen, die das Design besiegen muss.

5–15 · Staunmoment. Seilroutine erst als Variante A ohne Vergleich, dann als Variante B mit Kontrollbedingung, die die Gruppe festlegt. Die Gruppe erlebt, wie die Kontrolle die Täuschung entlarvt oder ihre Verweigerung

die Behauptung entwertet.

15–45 · Theorie-Input. Designtypen; interne und externe Validität; Konfundierung; Gütekriterien. Fallbeispiel: das Design der Becher-Monty-Hall-Videostudie und ihr Störfaktor, dann die Feldstudie.

45–75 · Design-Werkstatt. Analyse der fiktiven Studie (UV, AV, Kontrollgruppe, Konfounder; Übungsblatt Teil A, Aufgabe 1); dann Skizze eines eigenen Designs zur eigenen Hypothese (Aufgabe 2); Messgüte-Check mit dem Vokabular aus *WuZ-Buch*, Kap. 10b.

75–90 · Sicherung. Übungsblatt Teil B austeilen; Peer-Feedback auf die Design-Skizzen in Zweiergruppen (Aufgabe 3); Abgabe der Skizze als benotete Teilleistung terminieren.

7.1 Staunmoment: Drei Seile

★ Staunmoment: Kontrollierte Seilroutine

Drei Seile: kurz, mittel, lang. *Ich mache sie gleich lang.*

Variante A: Schauen Sie zu.
Variante B: Diesmal bestimmen Sie, wie wir prüfen. Was wollen Sie vorher messen, was nachher, und womit vergleichen?

Variante A: ohne Vergleich

- Was haben Sie gesehen?
- Woher wissen Sie, dass die Seile vorher verschieden lang waren?
- Woher wissen Sie, dass sie nachher gleich lang sind?
- Wer hat gemessen – und womit?

Variante B: mit Kontrollbedingung

- Ihr Prüfplan: Was messen wir vorher, was nachher?
- Wer misst? Wer darf die Seile halten?
- Womit vergleichen wir: Maßband, ein unbeteiligtes Seil, eine zweite Person?
- Welche Prüfung lässt die Vorführende *nicht* zu – und was folgt daraus?

In Variante A ist die einzige Evidenz die Vorführung selbst. Die Längen vorher und nachher werden behauptet und durch Zeigen „belegt"; gemessen hat niemand, verglichen wurde nichts. In Variante B formuliert die Gruppe einen Prüfplan, bevor das Kunststück beginnt. Lässt die Lehrperson eine Prüfung zu, wird der Effekt an einem unabhängigen Maßstab gemessen. Verweigert sie eine Prüfung, wird sichtbar, dass die Behauptung nur unter Bedingungen gilt, die der Behauptende selbst kontrolliert. Für ein Kunststück ist das legitim, denn es behauptet nichts über die Welt. Für eine Studie wäre es ein K.-o.-Kriterium. Dieselbe Figur kennt das Buch vom Muskeltest der Applied Kinesiology: Solange der Anwender den Test kontrolliert, scheint er zu funktionieren; in einer Doppelblindstudie lag die Trefferquote kaum über dem Zufall (*WuZ-Buch*, Kap. 10b).

Was ist der Unterschied?

- A: Behauptung plus Vorführung – der Behauptende kontrolliert alles
- B: Prüfplan vorab, unabhängiger Maßstab, Vergleich vorher/nachher
- eine verweigerte Kontrolle ist selbst ein Befund
- ohne Kontrollbedingung bleiben selbst grobe Täuschungen unentdeckt

7.2 Was ein Forschungsdesign leistet

Ein Forschungsdesign ist der Plan, mit dem eine Forschungsfrage beantwortet werden soll. Es legt fest, welche Variablen erhoben oder verändert werden, an wem, zu welchen Zeitpunkten und unter welchen Bedingungen, und vor allem, womit verglichen wird (Döring und Bortz 2016a). Die *unabhängige Variable* (UV) ist die vermutete Ursache; im Experiment wird sie gezielt variiert. Die *abhängige Variable* (AV) ist die gemessene Wirkung. *Störvariablen* beeinflussen die AV ebenfalls, ohne Gegenstand der Untersuchung zu sein. Will man aus einem Zusammenhang auf Kausalität schließen, müssen drei Bedingungen erfüllt sein: Ursache und Wirkung variieren gemeinsam, die Ursache geht der Wirkung zeitlich voraus, und plausible Alternativerklärungen sind ausgeschlossen (Shadish u. a. 2002). Die dritte Bedingung ist die schwierigste, und an ihr entscheidet sich die Qualität eines Designs.

Forschungsdesign

Definition 7.1 Ein **Forschungsdesign** ist der Plan einer Untersuchung: welche Variablen an wem, wann und unter welchen Bedingungen erhoben oder verändert werden und womit die Ergebnisse verglichen werden.

- **UV:** vermutete Ursache (im Experiment gezielt variiert)
- **AV:** gemessene Wirkung
- **Störvariable:** wirkt ebenfalls auf die AV

Wann darf man auf Kausalität schließen?

- **Kovariation:** Ursache und Wirkung treten gemeinsam auf
- **zeitliche Folge:** die Ursache geht der Wirkung voraus
- **keine Alternativerklärung:** nichts anderes erklärt den Zusammenhang ebenso gut
- die dritte Bedingung ist die schwierigste – sie ist der Zweck des Designs

Seile als Design

- UV: das Kunststück (durchgeführt / nicht durchgeführt)
- AV: die Seillängen
- Variante A: eine Messung, nachher, durch den Behauptenden
- Variante B: Vorher- und Nachher-Messung, unabhängiger Maßstab
- Welche Alternativerklärungen schließt B aus, A nicht?

7.3 Designtypen

Designs lassen sich danach ordnen, ob die UV aktiv variiert wird und ob die Zuteilung zu den Bedingungen zufällig erfolgt (Shadish u. a. 2002; Döring und Bortz 2016a). Im *Experiment* variieren die Forschenden die UV und teilen die Teilnehmenden zufällig den Bedingungen zu (Randomisierung). Zufall verteilt bekannte und unbekannte Störvariablen im Mittel gleich auf die Gruppen; das macht das Experiment zum stärksten Design für Kausalaussagen. Im *Quasi-Experiment* wird die UV variiert, aber vorhandene Gruppen werden verglichen (zwei Kurse, zwei Standorte); die Gruppen können sich schon vorher unterschieden haben. Im *nicht-experimentellen* Design wird nichts verändert, nur erhoben; es zeigt Zusammenhänge, aber kaum Ursachen. Quer dazu liegt die Frage nach der Zeit: Ein *Querschnitt* misst einmal und vergleicht Personen, ein *Längsschnitt* misst dieselben Personen mehrfach und kann Veränderungen verfolgen. Die Notation von Campbell kürzt Designs ab: R steht für zufällige Zuteilung, X für die Intervention, O für eine Messung (*observation*).

Drei Grundtypen

	UV variiert?	Zufall?	Kausalaussage
Experiment	ja	ja	stark
Quasi-Experiment	ja	nein	eingeschränkt
nicht-experimentell	nein	–	schwach (Zusammenhang)

- quer dazu: **Querschnitt** (einmal messen) oder **Längsschnitt** (dieselben Personen mehrfach)

Designs in Kurzschrift

Design				Zeit →
One-Shot (Variante A)			X	O
Vorher-Nachher, eine Gruppe (Variante B)		O	X	O
Experiment mit Kontrollgruppe	R		X	O
	R			O
Experiment mit Vortest	R	O	X	O
	R	O		O

- R = Zufallszuteilung, X = Intervention, O = Messung

7.4 Interne Validität

Ein Design ist *intern valide*, wenn sich die Veränderung der AV eindeutig auf die UV zurückführen lässt. Shadish, Cook und Campbell haben die typischen Bedrohungen zusammengestellt (Shadish u. a. 2002). Die Liste ist ein Werkzeug: Wer ein Design plant oder liest, geht sie Punkt für Punkt durch und fragt, welche Bedrohung das Design ausschließt und welche nicht. Ein Vorher-Nachher-Vergleich ohne Kontrollgruppe ist anfällig für fast alle; die zufällig zugeteilte Kontrollgruppe neutralisiert die meisten, weil Geschichte, Reifung und Testeffekte beide Gruppen gleich treffen.

Bedrohungen der internen Validität

Bedrohung	Beispiel: Lernvideo mit Vorher-Nachher-Test
Geschichte	in der Woche dazwischen läuft eine Doku zum Thema
Reifung	die Teilnehmenden lernen ohnehin dazu
Testeffekt	der Vortest übt schon für den Nachtest
Instrumentierung	Nachtest ist leichter als Vortest
Regression zur Mitte	nur die Schwächsten im Vortest werden ausgewählt
Selektion	Freiwillige mit Interesse gegen Pflichtgruppe
Ausfall	die Frustrierten brechen vor dem Nachtest ab

Eine eigene Bedrohung entsteht durch die Forschenden selbst. Wenn die Person, die das Ergebnis erhofft, auch misst oder bewertet, können ihre Erwartungen die Daten verschieben, ohne dass sie es bemerkt. Der „Kluge Hans", ein Pferd, das angeblich rechnen konnte, antwortete nur dann richtig, wenn die Fragenden die Antwort kannten und sichtbar waren; es las ihre unwillkürlichen Bewegungen (Pfungst 1907). Dieselbe Logik steckt im ideomotorischen Pendel aus LE 1. Gegenmittel ist das *Blind-Design*: Wer misst, weiß nicht, in welcher Bedingung die gemessene Person war. LE 8 vertieft diesen Versuchsleitereffekt.

Die Forschenden als Störvariable

- Der Kluge Hans (1907): ein Pferd „rechnet" – solange die Fragenden die Antwort kennen und sichtbar sind
- es reagierte auf unwillkürliche Bewegungen der Fragenden
- Seile: wer vorführt, darf nicht auch messen
- Gegenmittel: **Blind-Design** – die Messenden kennen die Bedingung nicht

7.5 Konfundierung und Kontrolle

Von *Konfundierung* spricht man, wenn eine Störvariable systematisch mit der UV variiert. Dann lassen sich ihre Wirkungen nicht mehr trennen. Wer eine Lern-App freiwillig nutzt, ist im Mittel vermutlich motivierter als wer sie nicht nutzt; ein Notenunterschied kann von der App oder von der Motivation kommen. Gegen Konfundierung gibt es fünf Werkzeuge: Randomisierung, Konstanthalten (alle Bedingungen gleich bis auf die UV), Parallelisieren oder Schichten (Gruppen nach einem bekannten Störmerkmal ausbalancieren), eine geeignete Kontrollgruppe und Blindbedingungen. Die Kontrollgruppe ist dabei nicht einfach „die anderen". Eine *aktive Kontrolle* erhält eine gleich lange, gleich aufwendige Bedingung ohne den vermuteten Wirkstoff, damit sich die Gruppen nur in dem unterscheiden, was untersucht wird.

Konfundierung

Definition 7.2 Konfundierung liegt vor, wenn eine Störvariable systematisch mit der unabhängigen Variablen variiert. Ihre Wirkung auf die abhängige Variable ist dann von der Wirkung der UV nicht mehr zu trennen.

- Beispiel: freiwillige App-Nutzer sind motivierter – App oder Motivation?
- die Täuschung in Variante A: Längen und Messung lagen beim Vorführenden

Fünf Werkzeuge der Kontrolle

- **Randomisierung:** Zufall verteilt auch unbekannte Störvariablen
- **Konstanthalten:** alles gleich bis auf die UV
- **Schichten / Parallelisieren:** Gruppen nach bekanntem Störmerkmal ausbalancieren
- **Kontrollgruppe**, möglichst *aktiv*: gleich lang, gleich aufwendig, ohne Wirkstoff
- **Blindbedingungen:** Teilnehmende und Messende kennen die Bedingung nicht

7.6 Externe Validität

Ein intern valides Ergebnis gilt zunächst nur für die untersuchten Personen, unter den untersuchten Bedingungen, zum untersuchten Zeitpunkt. *Externe Validität* fragt, wie weit es sich auf andere Personen, Situationen und Zeiten übertragen lässt (Shadish u. a. 2002). Zwischen beiden besteht ein Zielkonflikt: Je strenger ein Labor alles konstant hält, desto künstlicher wird die Situation. Das Buch nennt eine besonders tückische Form dieses Problems: den *Hot-Cold-Empathy-Gap* (Loewenstein 1996). Wer im ruhigen Labor vorhersagen soll, wie er unter Stress, Zeitdruck oder Erregung entscheiden würde, beschreibt sein rationalisiertes Selbstbild. Umfragen zu zustandsabhängigem Verhalten sind deshalb strukturell unzuverlässig, solange dieser Abstand nicht methodisch adressiert wird (*WuZ-Buch*, Kap. 4, HCEG).

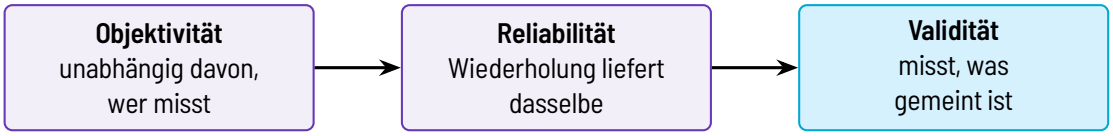
Externe Validität

- gilt das Ergebnis auch für andere Personen, Orte, Zeiten?
- Zielkonflikt: je kontrollierter das Labor, desto künstlicher die Situation
- Gelegenheitsstichproben (Freunde, Kommilitonen) sagen wenig über die Allgemeinbevölkerung
- **Hot-Cold-Empathy-Gap**: im ruhigen Labor sagt man falsch voraus, wie man unter Stress handelt

7.7 Gütekriterien der Messung

Auch das beste Design hilft nicht, wenn die AV schlecht gemessen wird. Die klassische Testtheorie nennt drei Hauptgütekriterien (Döring und Bortz 2016a). *Objektivität*: Das Ergebnis hängt nicht davon ab, wer die Messung durchführt, auswertet und interpretiert. *Reliabilität*: Die Messung ist zuverlässig, eine Wiederholung unter gleichen Bedingungen liefert dasselbe Ergebnis. *Validität*: Die Messung erfasst tatsächlich das gemeinte Konstrukt. Die Kriterien bauen aufeinander auf: Ohne Objektivität keine Reliabilität, ohne Reliabilität keine Validität. Das Buch ergänzt diese Begriffe in *WuZ-Buch*, Kap. 10b um ein praktisches Vokabular, das bei schwer messbaren Konstrukten wie Staunen oder Stress hilft: Ein *Blind-Design* schaltet Erwartungen der Messenden aus. Ein *Prozessindikator* ist ein Relativmaß für Veränderung innerhalb einer Person und einer Sitzung, kein Wahrheitsdetektor. Eine *Parallelmessung* erhebt dasselbe Konstrukt mit mehreren, unabhängigen Verfahren (etwa Selbstbericht und Herzratenvariabilität), damit ein Befund nicht an einem einzigen Instrument hängt. Auf der Ebene des ganzen Designs heißt dieselbe Idee *Triangulation*.

Drei Gütekriterien



- jedes Kriterium setzt das vorige voraus
- Seile: Maßband (objektiv, reliabel) gegen Augenmaß des Vorführenden

Messgüte-Vokabular aus dem Buch

- **Blind-Design:** wer misst, kennt die Bedingung nicht
- **Prozessindikator:** Relativmaß für Veränderung in einer Person und Sitzung – kein Wahrheitsdetektor
- **Parallelmessung:** dasselbe Konstrukt mit mehreren Verfahren (Selbstbericht, Verhalten, Physiologie)
- **Triangulation:** dieselbe Idee für das ganze Design – mehrere Methoden, Datenquellen, Perspektiven

7.8 Fallbeispiel: die Becher-Monty-Hall-Studie

Das Buch enthält ein vollständig ausgearbeitetes Forschungsdesign zu seiner eigenen Leitthese, dass Staunen das Lernen begünstigt (*WuZ-Buch*, Kap. 12d). Der Lerngegenstand ist das Monty-Hall-Problem, der Staunmoment ein Becher-Zauberkunststück. Die Studie ist als Zwischensubjekt-Design mit zufälliger Zuteilung angelegt. Beide Gruppen sehen dasselbe, rund 13-minütige Erklärvideo; die Treatment-Gruppe sieht zusätzlich, direkt nach dem Einstieg, einen rund zweiminütigen Becher-Zaubertrick. Bei der Kontrollgruppe ist genau dieser Block herausgeschnitten, alles Übrige ist identisch. Der Lehrteil nimmt mit keinem Satz Bezug auf den Trick, damit er in beiden Fassungen wortgleich und vollständig bleibt. Ein Manipulationscheck prüft, ob der Trick überhaupt Staunen ausgelöst hat; gemessen werden außerdem Verständnis, Transfer auf eine neu eingekleidete Aufgabe und Kalibrierung des eigenen Urteils.

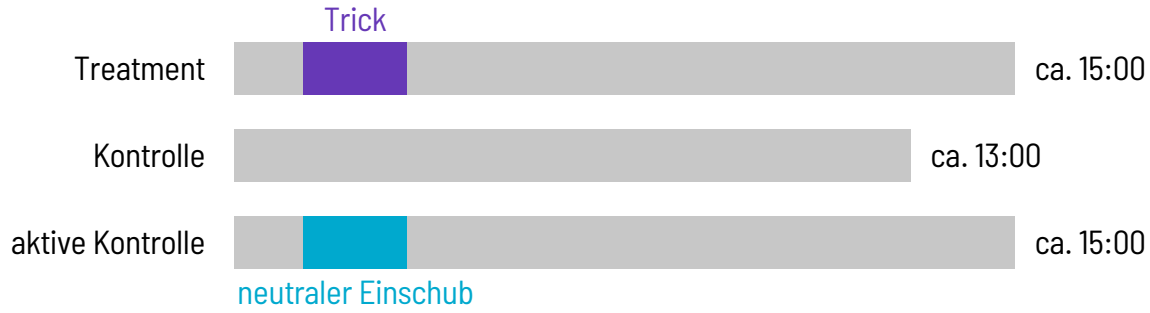
Der Entwurf benennt seinen Störfaktor selbst: Durch den reinen Herausschnitt ist die Kontrollfassung rund zwei Minuten kürzer (Treatment ca. 15:00, Kontrolle ca. 13:00). Länge und gemeinsame Aufmerksamkeitszeit sind damit konfundiert. Die Abhilfe ist eine längengleiche *aktive Kontrolle*: An die Stelle des Tricks tritt ein gleich langer, bewusst nicht staunenswerter Becher-Einschub, etwa ein nüchternes Umstapeln mit sachlichem Kommentar (*WuZ-Buch*, Abschnitt 12d, Studienlogik).

Der Idealentwurf (Kap. 12d)

- Zwischensubjekt-Design, zufällige Zuteilung
- UV: Staunmoment (Becher-Zaubertrick) ja / nein

- derselbe Film, ein Block herausgeschnitten – sonst alles identisch
- AV: Verständnis, Transfer, Kalibrierung
- Manipulationscheck: Hat der Trick überhaupt Staunen ausgelöst?

Der Störfaktor



- Herausschneiden macht die Kontrolle *kürzer*: Länge ist konfundiert
- Abhilfe: gleich langer, nicht staunenswerter Einschub

Umgesetzt wurde der Entwurf als Online-Feldstudie mit drei Armen (*WuZ-Buch*, Kap. 12f): U1 als Kontrolle ohne Zaubertrick, U2 mit dem Becher-Zaubertrick als Spiel auf der Landingpage vor dem Fragebogen und U3 mit dem in das Video integrierten, unaufgelösten Trick. Gegenüber dem Idealentwurf ersetzt U2 die empfohlene längengleiche aktive Kontrolle durch eine Platzierungsvariante. Die Zuteilung erfolgte zufällig über eine Landingpage, die Feldzeit lief vom 3. bis 31. Juli 2026. Am Ende lagen 32 auswertbare Fälle vor (13/9/10).

Die Befunde sind für eine Einheit über Forschungsdesign lehrreicher, als es ein Erfolg gewesen wäre. Erstens ist der Manipulationscheck gescheitert: Das Staunen liegt in den drei Armen bei 3,89 / 3,76 / 3,87, also praktisch gleichauf. Wenn die Intervention die vermutete Ursache nicht messbar bewegt, sind alle nachgelagerten Fragen nach ihrer Wirkung unbeantwortbar. Zweitens zeigte ein Zwischenstand am 16. Juli noch genau die erhoffte Abstufung (3,83 / 4,08 / 4,28), die sich danach einebnete; hätte die Erhebung früher geendet, stünde ein schöner, falscher Befund in der Welt. Drittens war der stärkste Zusammenhang einer, den die Studie gar nicht untersuchen wollte: Wer das Monty-Hall-Problem schon kannte, lag zu 92 Prozent richtig, wer es nicht kannte, zu rund der Hälfte. Bei $n = 32$ genügen wenige ungleich verteilte Vorwissensträger, um jeden Armunterschied zu erzeugen oder zu tilgen. Viertens war die Teststärke von Anfang an unzureichend: Für einen mittleren Effekt ($d = 0{,}5$) hätte es rund 64 Personen pro Arm gebraucht, erreicht wurden 9 bis 13. Das Buch zieht daraus selbst die Konsequenzen für eine Folgestudie: Fallzahl vorab planen, nach Vorwissen geschichtet randomisieren und den Manipulationscheck reparieren.

Die Feldstudie (Kap. 12f)

- drei Arme: U1 Kontrolle, U2 Trick vorab, U3 Trick im Video
- U2 statt der aktiven Kontrolle: eine Platzierungsvariante
- 32 auswertbare Fälle (13 / 9 / 10)
- Manipulationscheck gescheitert: Staunen 3,89 / 3,76 / 3,87
- Zwischenstand 16. Juli: 3,83 / 4,08 / 4,28 – danach eingeebnet

Was das Design daraus lernt

- **Vorwissen** überstrahlt alles: 92 % richtig mit, rund die Hälfte ohne Vorwissen
- **Teststärke**: für $d = 0{,}5$ rund 64 pro Arm nötig, erreicht 9 bis 13
- Folgestudie: Fallzahl vorab planen
- nach Vorwissen *geschichtet* randomisieren
- Manipulationscheck reparieren (z. B. Verweildauer, verhaltensnahe Maße)

Merke

Ohne Vergleich ist jede Beobachtung eine Vorführung. Ein Design ist so gut wie die Alternativerklärungen, die es ausschließt – und eine Intervention ist erst dann geprüft, wenn der Manipulationscheck zeigt, dass sie überhaupt gewirkt hat.

7.9 Design-Werkstatt

Teil 1: Ein Design analysieren (Zweiergruppen, 15 Min.)

- Übungsblatt Teil A, Aufgabe 1: die (fiktive) Lern-App-Studie
- Was sind UV und AV? Welcher Designtyp?
- Gibt es eine Kontrollgruppe – und taugt sie?
- Welche Konfounder sehen Sie? Welche Bedrohungen der internen Validität?
- Wie müsste das Design aussehen, damit die Schlussfolgerung trägt?

Teil 2: Ihr eigenes Design (Einzelarbeit, 15 Min.)

- Ausgangspunkt: Ihre H_1 aus LE 5
- Übungsblatt Teil A, Aufgabe 2: Design-Skizze ausfüllen
- Messgüte-Check: objektiv? reliabel? valide? blind? parallel gemessen?
- Welche Bedrohung der internen Validität bleibt – und warum nehmen Sie sie in Kauf?

Peer-Feedback (Zweiergruppen, 10 Min.)

- stellen Sie Ihr Design in drei Minuten vor
- die Partnerin sucht *eine* Alternativerklärung, die Ihr Design nicht ausschließt
- gemeinsam: Welche Änderung würde sie ausschließen?

Hinweis für Lehrende

Bei der Analyse der fiktiven Studie finden die meisten Gruppen die Selbstselektion schnell. Lohnend ist es, nach den weniger offensichtlichen Konfoundern zu fragen: das Tutorium, das nur die App-Gruppe besucht hat, und die nicht blinde Korrektur durch den App-Entwickler. Bei den eigenen Designs ist der häufigste Fehler eine Kontrollgruppe, die sich in mehr als einer Hinsicht von der Experimentalgruppe unterscheidet; hier hilft die Frage „Was genau ist bei der Kontrollgruppe anders, und ist das *nur* Ihre UV?". Wer ein nicht-experimentelles Design wählt, muss das nicht ändern, sollte aber in der Begründung zeigen, dass ihm die Grenzen der Kausalaussage klar sind. Statt der fiktiven Studie kann auch der Methodenteil eines echten Artikels analysiert werden; als realer Fall aus dem Buch eignet sich die Feldstudie aus *WuZ-Buch*, Kap. 12f, die ihre Abweichungen vom Idealentwurf selbst offenlegt.

7.10 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- UV, AV und Störvariablen in einem Design benennen
- experimentelle, quasi-experimentelle und nicht-experimentelle Designs unterscheiden
- Bedrohungen der internen Validität erkennen und Gegenmittel benennen

- Objektivität, Reliabilität und Validität einer Messung prüfen
- ein angemessenes Design für Ihre Fragestellung auswählen und begründen

Bis zur nächsten Woche

- **Fallstudie** (Aufgabe 1) fertigstellen
- **Design-Skizze** (Aufgabe 2): Design für Ihre eigene Hypothese, Begründung auf höchstens einer Seite – benotete Teilleistung
- Feedback Ihrer Partnerin einarbeiten
- **Tagebuch des Staunens:** eine Behauptung aus Werbung oder Nachrichten, der ein Vergleich fehlt

Handout: Forschungsdesign

Worum es heute ging. Drei Seile wurden gleich lang, zweimal. Beim ersten Mal gab es nur die Vorführung: Wer behauptete, zeigte auch, und niemand maß. Beim zweiten Mal legten Sie vorher fest, wie geprüft wird. Ohne Vergleich bleiben selbst grobe Täuschungen unentdeckt; eine verweigerte Kontrolle ist selbst ein Befund.

Kernbegriffe

Forschungsdesign Plan einer Untersuchung: welche Variablen an wem, wann und unter welchen Bedingungen erhoben oder verändert werden und womit verglichen wird.

UV / AV / Störvariable vermutete Ursache / gemessene Wirkung / weiterer Einfluss auf die AV.

Konfundierung eine Störvariable variiert systematisch mit der UV; ihre Wirkung ist nicht mehr abtrennbar.

Interne Validität die Veränderung der AV ist eindeutig auf die UV zurückzuführen (Shadish u. a. 2002).

Externe Validität das Ergebnis lässt sich auf andere Personen, Situationen und Zeiten übertragen.

Objektivität, Reliabilität, Validität unabhängig von der messenden Person; bei Wiederholung gleich; misst das Gemeinte.

Blind-Design, Parallelmessung Messende kennen die Bedingung nicht; dasselbe Konstrukt wird mit mehreren Verfahren erhoben.

Designtypen

	UV variiert	Zufall	Kurzschrift (R, X, O)
Experiment	ja	ja	R X O / R O
Quasi-Experiment	ja	nein	X O / O
nicht-experimentell	nein	–	nur O (Zusammenhänge)

Bedrohungen der internen Validität: Geschichte, Reifung, Testeffekt, Instrumentierung, Regression zur Mitte, Selektion, Ausfall – und die Erwartungen der Forschenden.

Fünf Werkzeuge der Kontrolle: Randomisierung, Konstanthalten, Schichten/Parallelisieren, (aktive) Kontrollgruppe, Blindbedingungen.

Merke

Ein Design ist so gut wie die Alternativerklärungen, die es ausschließt. Fragen Sie bei jeder Kontrollgruppe: Unterscheidet sie sich *nur* in der UV?

Zum Weiterlesen: Döring und Bortz (2016a), Kapitel zu Untersuchungsdesign und Gütekriterien; Shadish u. a. (2002), Kap. 1–2.

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 7**

Übungsblatt A: Forschungsdesign

Name: _____ Datum: _____

Aufgabe 1: Fallstudie: Ein Design analysieren

in der Stunde, Zweiergruppe, 15 Min.

Die folgende Studie ist fiktiv und für diese Übung konstruiert; alle Zahlen sind erfunden.

„Lern-App verbessert Mathematiknoten um 0,7“

Im Wintersemester bietet eine Hochschule zur Vorlesung Mathematik 1 eine neue Übungs-App an, die der Dozent der Vorlesung selbst entwickelt hat. Die Nutzung ist freiwillig; 64 von 212 Studierenden melden sich an. Zur Einführung der App bietet der Dozent für die Angemeldeten ein wöchentliches Tutorium an, in dem mit der App geübt wird. Am Semesterende schreiben alle 212 Studierenden dieselbe Klausur, die der Dozent selbst korrigiert; auf den Bögen stehen Name und Matrikelnummer. Die App-Gruppe erreicht im Mittel die Note 2,3, die übrigen 148 Studierenden die Note 3,0. Im Pressetext der Hochschule heißt es: „Die App verbessert die Note um 0,7. Sie wird ab dem nächsten Semester für alle Erstsemester verpflichtend.“

1. Benennen Sie UV und AV (unabhängige und abhängige Variable). Wie ist die AV gemessen worden?
2. Welcher Designtyp liegt vor? Schreiben Sie das Design in der Kurzschrift R/X/O (eine Zeile je Gruppe; R = zufällige Zuteilung, X = Behandlung, O = Messung).
3. Gibt es eine Kontrollgruppe? In welchen Merkmalen unterscheidet sie sich von der App-Gruppe außer in der App-Nutzung?
4. Nennen Sie mindestens drei Konfounder bzw. Bedrohungen der internen Validität und ordnen Sie sie Fachbegriffen zu (etwa Selektion, Geschichte, Reifung, Testeffekt, Instrumentierung, Ausfall, Erwartungen der Forschenden).
5. Ist die Messung objektiv? Was wäre ein Blind-Design?
6. Skizzieren Sie ein verbessertes Design, das die Aussage des Pressetexts prüfen könnte.

Aufgabe 2: Design-Skizze zu Ihrer Hypothese

Beginn in der Stunde, Abgabe bis LE 8, benotet

Füllen Sie die Vorlage aus und begründen Sie Ihre Wahl auf höchstens einer weiteren Seite.

H_1 (aus LE 5)	
UV und ihre Stufen	
AV und Messinstrument	
Designtyp (experimentell / quasi / nicht-experimentell; Quer- oder Längsschnitt)	
Design in Kurzschrift (R / X / O)	
Stichprobe: wer, wie viele, wie rekrutiert?	
Auswertungsplan (aus LE 6): Test oder Bayes-Faktor, kleinster interessanter Effekt, n aus der Power-Tabelle	
Zuteilung zu den Bedingungen	
Kontrollbedingung (aktiv?)	
Wichtigste Störvariablen (Drachen auf Ihrer Landkarte aus LE 6) und wie ich sie kontrolliere	
Messgüte: objektiv? reliabel? valide? blind? Parallelmessung?	
Verbleibende Bedrohung, die ich in Kauf nehme	

Übungsblatt B: Feedback und Transfer

Name: _____ Datum: _____

Aufgabe 3: Peer-Feedback

in der Stunde, Zweiergruppe, 10 Min.

Notieren Sie für die Skizze Ihrer Partnerin bzw. Ihres Partners:

Eine Alternativerklärung, die das Design nicht ausschließt	
Eine Änderung, die sie ausschließen würde	
Was an dem Design überzeugt	

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Finden Sie in Werbung, Nachrichten oder sozialen Medien eine Wirkungsbehauptung, der ein Vergleich fehlt. Welche Kontrollbedingung bräuchte man, um sie zu prüfen?

Erwartungshorizont

Aufgabe 1. UV: App-Nutzung (ja/nein, selbst gewählt); AV: Klausurnote, korrigiert vom Entwickler der App, nicht anonymisiert. Design: quasi-experimentell bzw. nicht-experimenteller Gruppenvergleich ohne Vortest (X O / O), keine Randomisierung. Die „Kontrollgruppe" unterscheidet sich in Motivation und vermutlich Vorkenntnissen (Selbstselektion), im zusätzlichen Tutorium (Konfundierung der UV mit Übungszeit und Betreuung) und darin, wie der Korrektor sie wahrnimmt (Versuchsleitereffekt, fehlende Objektivität). Weitere Punkte: kein Vortest, also keine Aussage über Veränderung; mögliche Neuheitseffekte; Übertragung von Freiwilligen auf eine Pflichtnutzung ist fraglich (externe Validität). Verbessertes Design: zufällige Zuteilung (ggf. geschichtet nach Vorkenntnissen aus einem Eingangstest), Tutorium für beide Gruppen gleich lang mit herkömmlichen Übungen (aktive Kontrolle), anonymisierte Klausur, Korrektur durch eine Person, die die Gruppenzugehörigkeit nicht kennt (Blind-Design).
Aufgabe 2. Bewertet werden: Passung von Design und Hypothese (Kausalbehauptung erfordert experimentelles oder gut begründetes quasi-experimentelles Design), eine Kontrollbedingung, die sich nur in der UV unterscheidet, ein konkretes Messinstrument, mindestens zwei benannte und kontrollierte Störvariablen, eine ehrlich benannte Restbedrohung.