10 Datenanalyse und Interpretation

In LE 6 und LE 9 haben die Studierenden Daten erhoben und beschrieben. Diese Einheit fragt, was man aus ihnen schließen darf. Sie beginnt mit einer Vorhersage, die versiegelt im Raum liegt, und mit vier Zahlen, die Freiwillige frei wählen. Die Summe trifft die Vorhersage. Die Wahl war frei, das Ergebnis trotzdem festgelegt: durch die Struktur der Rechnung. Dieselbe Struktur steckt in vielen Datenauswertungen, die scheinbar offen beginnen und doch nur zu einem Ergebnis führen können. Die Einheit unterscheidet deshalb sauber zwischen Daten, Befund und Schlussfolgerung, zeigt mit dem Vorhersage-Trick aus dem Buch, wie p-Hacking garantierte Muster erzeugt, und stellt die Gegenmittel vor: Gegenhypothesen, Triangulation und Präregistrierung.

Vorbereitung vor der Stunde: Die unveränderliche Summe und der Vorhersage-Trick

Hinweis. Kap. 15 des Buchs nennt den Effekt „Die unveränderliche Summe (Datum-Force)", beschreibt aber keine Methode. Die folgende selbstarbeitende Variante ist ein *Vorschlag* für die Umsetzung. Sie beruht auf reiner Arithmetik und braucht keine Fingerfertigkeit.

Das Prinzip. Eine Person nennt (1) ihr Geburtsjahr, (2) das Alter, das sie im laufenden Kalenderjahr erreicht, (3) das Jahr eines persönlich wichtigen Ereignisses und (4) die Anzahl der Jahre, die seitdem bis zum laufenden Jahr vergangen sind. Geburtsjahr plus erreichtes Alter ergibt das laufende Jahr J, Ereignisjahr plus vergangene Jahre ebenfalls. Die Summe aller vier Zahlen ist deshalb immer $2J$.

Eine Woche vorher

- ☐ **Termin prüfen!** LE 10 liegt im Dezember oder Januar. Die Vorhersage hängt am Kalenderjahr des Vorlesungstags: im Dezember 2026 lautet sie 4052, im Januar 2027 lautet sie 4054. Wird der Termin über den Jahreswechsel verschoben, Vorhersage neu schreiben.
- ☐ Vorhersage auf eine Karte schreiben, in einen Umschlag stecken, zukleben und unterschreiben lassen (z. B. von einer Kollegin). Der Umschlag liegt ab Beginn der Stunde sichtbar am Pult oder klebt an der Tafel.
- ☐ Sprechtext üben, vor allem die Fragen 2 und 4 (siehe Fallstricke). Zwei Probeläufe mit Personen, die den Effekt nicht kennen; dabei auf Missverständnisse achten.
- ☐ Für den Vorhersage-Trick (Buch, Abschnitt 10d) die geheime Botschaft der Abweichungen festlegen, z. B. $r = (3, 1, 4, 1)$ für die ersten Ziffern von π. Die letzte Zahl der Runde wird geforct. Das Buch nennt dafür Force-Bag, Force-Deck, einen Rechen-Force oder Equivoque (Paillès und Kuhn 2020); Wahl und Einstudierung des Forces nach der Standardliteratur, hier bewusst nicht beschrieben. Die Master-Vorhersage $p_n = F + r_n$ vorab auf eine Karte schreiben und versiegeln.
- ☐ Plan B ohne Force aus dem Buch bereithalten: der 1089-Trick oder Kaprekars Konstante 6174 (Buch, Abschnitt 10d).

Fallstricke der unveränderlichen Summe

- ☐ **Alter:** Es muss das im laufenden Jahr *erreichte* Alter sein, egal ob der Geburtstag schon war. Wer noch nicht Geburtstag hatte und das aktuelle Alter nennt, liegt um eins zu niedrig. Formulierung: „Wie alt werden Sie dieses Jahr an Ihrem Geburtstag – oder sind es schon geworden?"
- ☐ **Vergangene Jahre:** gezählt wird nach Jahreszahlen, nicht nach Jahrestagen. Formulierung: „Wie viele Silvester liegen seit diesem Ereignis hinter Ihnen?" Ein Ereignis im laufenden Jahr ergibt null.
- ☐ **Jahreswechsel:** Im Januar denken viele noch im alten Jahr. Dann „in diesem Jahr" durch „im neuen Jahr" ersetzen und bei der Silvester-Frage „das letzte mitgezählt" ergänzen. Im Dezember besteht die Gefahr nicht.
- ☐ **Paare gehören zusammen:** Geburtsjahr und Alter müssen von derselben Person stammen, Ereignisjahr und vergangene Jahre vom selben Ereignis. Mehrere Personen sind möglich, wenn jede ein vollständiges Paar liefert.
- ☐ **Rechnen:** eine dritte Person addiert mit dem Taschenrechner, eine vierte kontrolliert. Kopfrechnen vor Publikum erzeugt Fehler.

Handout und Übungsblatt

- ☐ Handout „Datenanalyse und Interpretation" sowie Übungsblatt LE 10 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 10). Teil A enthält die vollständigen Rohdaten der fiktiven Studie (Aufgabe 1) und liegt zu Beginn aus. Teil B enthält die Tabelle zur Formel $1 - (1 - \alpha)^m$ (Aufgabe 2), die Reflexion und das Tagebuch; er wird erst nach der Tafel-Auflösung des Vorhersage-Tricks ausgeteilt, weil Aufgabe 2 diese Auflösung und das Tagebuch den Force der ersten Vorführung vorwegnähmen.
- ☐ Taschenrechner zulassen; wer einen Laptop hat, darf die Rohdaten in eine Tabellenkalkulation übernehmen.

Am Tag selbst

- ☐ Umschlag mit der Vorhersage vor Beginn sichtbar aufhängen; nicht kommentieren.
- ☐ Tafel: rechts oben Platz für die vier Zahlen und die Summe, links Platz für die Tabelle des Vorhersage-Tricks (Runde, a_i, p_i, $p_i - a_i$) und die Formel.
- ☐ Für den Vorhersage-Trick: fünf Karten, einen Umschlag, die versiegelte Master-Karte, das Force-Requisit.

Risiken und Plan B. Stimmt die Summe nicht, zuerst die beiden Fallstricke prüfen (Alter, Silvester), und zwar offen: Das ist dann selbst ein Lehrstück über Messfehler und Operationalisierung. Der Effekt ist danach nicht verloren, sondern wird sofort aufgelöst. Kennt jemand den Effekt, wird die Person zur Komplizin gemacht („Verraten Sie es bitte noch nicht"). Misslingt der Force im Vorhersage-Trick, auf den 1089-Trick ausweichen; die Lektion bleibt dieselbe.

Ablauf der Doppelstunde (90 Min.)

0–10 · Staunmoment. „Die unveränderliche Summe": vier frei genannte Zahlen, die Summe trifft die versiegelte Vorhersage. Frage: Wo war hier die Freiheit?

10–20 · Auflösung und Force-Begriff. Die Rechnung an der Tafel; Einordnung als Force; Determinismus und Freiheits-Illusion (Newcomb-Paradoxon, Buch, Kap. 5b).

20–45 · Theorie-Input. Daten – Befund – Schlussfolgerung; Over-Interpretation, p-Hacking, HARKing, Garden of Forking Paths; Triangulation.

45–60 · p-Hacking erleben. Der Vorhersage-Trick (Buch, Abschnitt 10d); Tafel-Auflösung $1-(1-\alpha)^m$. Danach Übungsblatt Teil B austeilen; die Tabelle in Aufgabe 2 vertieft die Formel (in der Stunde oder zu Hause).

60–80 · Befund-Übung. Rohdaten einer fiktiven Studie (Übungsblatt Teil A, Aufgabe 1): deskriptive Befunde, zwei konkurrierende Interpretationen, entscheidende Zusatzdaten.

80–90 · Selbstbezug. Prüfung der eigenen bisherigen Ergebnisse: Habe ich nach Bestätigung gesucht? Was würde meine Hypothese herausfordern? (Übungsblatt Teil B, Aufgabe 3)

10.1 Staunmoment: Die unveränderliche Summe

★ Staunmoment: Vier freie Zahlen

Am Pult liegt seit Beginn der Stunde ein versiegelter Umschlag. Eine Person nennt: (1) ihr Geburtsjahr, (2) das Alter, das sie in diesem Jahr erreicht, (3) das Jahr eines Ereignisses, das ihr wichtig ist, (4) wie viele Silvester seitdem vergangen sind.
Jemand addiert. Dann öffnen wir den Umschlag.

Sprechtext (Vorschlag)

In diesem Umschlag liegt eine Zahl, die ich heute Morgen aufgeschrieben habe. Ich brauche jemanden, der mir vier Zahlen über sich verrät, die ich nicht kennen kann. Sagen Sie uns zuerst Ihr Geburtsjahr. … Und wie alt werden Sie dieses Jahr an Ihrem Geburtstag – oder sind es schon geworden? … Jetzt denken Sie an ein Ereignis, das Ihnen wichtig war. Sie müssen nicht sagen, was es war. Nur das Jahr. … Und wie viele Silvester haben Sie seitdem gefeiert? … Das sind vier Zahlen, die nur Sie kennen. Bitte addieren Sie sie (an eine zweite Person gewandt), und Sie kontrollieren. … Lesen Sie die Summe laut vor. … Öffnen Sie den Umschlag.

Wo war hier die Freiheit?

- alle vier Zahlen waren frei gewählt
- das Ergebnis stand trotzdem vorher fest
- welche Erklärungen haben Sie?
- was hätte die Vorhersage scheitern lassen können?

10.2 Auflösung: der Force

Die Auflösung ist eine Zeile Arithmetik. Geburtsjahr plus das im laufenden Jahr erreichte Alter ergibt das laufende Jahr. Ereignisjahr plus die seitdem vergangenen Jahre ergibt ebenfalls das laufende Jahr. Die Summe ist also das Doppelte der Jahreszahl, gleichgültig, welche Person und welches Ereignis gewählt wurden. In der Sprache der Zauberkunst ist das ein *Force*: Die Wahl ist frei, ihr Ergebnis ist es nicht. Das Buch behandelt dasselbe Muster unter dem Stichwort Determinismus und Freiheits-Illusion am Newcomb-Paradoxon (Nozick 1969): Ein Prädiktor füllt Boxen nach einer Vorhersage über eine Wahl, die erst danach getroffen wird. Zum Zeitpunkt der Wahl liegt der Inhalt längst fest.

Die Rechnung

$$\underbrace{\text{Geburtsjahr} + \text{Alter}}_{=J} + \underbrace{\text{Ereignisjahr} + \text{vergangene Jahre}}_{=J} = 2J$$

- jede Eingabe war frei, die *Struktur* der Rechnung nicht
- die Freiheit hat das Ergebnis nie berührt
- scheitern kann die Vorhersage nur an Messfehlern: falsches Alter, falsch gezählte Jahre

Force

Definition 10.1 Ein **Force** ist ein Verfahren, das einer Person eine freie Wahl lässt und trotzdem ein vorab festgelegtes Ergebnis herbeiführt.

- Zauberkunst: Die versiegelte Vorhersage stimmt, weil das Verfahren sie erzwingt
- Newcomb: Der Prädiktor hat entschieden, bevor die Person wählt (Nozick 1969)
- Forschung: Eine Auswertung, die nur ein Ergebnis zulassen kann, prüft nichts

Forces in der Forschung

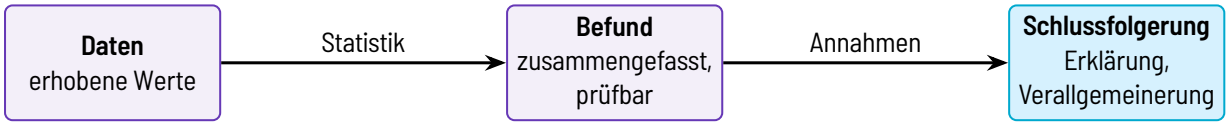
- Stichprobe nur aus Freiwilligen, die das Thema mögen
- Fragebogen nur mit zustimmend formulierten Items
- „Erfolg“ wird erst nach Sicht der Daten definiert
- Auswertung so lange variieren, bis sie passt
- Frage: Hätte meine Auswertung meine Hypothese überhaupt widerlegen können?

Die letzte Frage verbindet die Einheit mit Horwichs Analyse des Beweiswerts (LE 5 und LE 6): Nur Beobachtungen, die ein Widerlegungsrisiko eingehen, haben vollen Beweiswert (Horwich 1982). Eine Auswertung, die strukturell nur ein Ergebnis liefern kann, ist ein Force, kein Test.

10.3 Daten, Befund, Schlussfolgerung

Der häufigste Fehler beim Interpretieren ist kein Rechenfehler, sondern ein Ebenenwechsel. *Daten* sind die erhobenen Werte. Ein *Befund* ist eine Aussage, die die Daten zusammenfasst und an ihnen geprüft werden kann: Mittelwerte, Unterschiede, Zusammenhänge mit ihrer Unsicherheit. Eine *Schlussfolgerung* geht darüber hinaus; sie erklärt den Befund, verallgemeinert ihn oder leitet eine Empfehlung ab. Schlussfolgerungen sind notwendig, aber sie brauchen Annahmen, die man offenlegen muss. Over-Interpretation entsteht, wenn eine Schlussfolgerung wie ein Befund formuliert wird.

Drei Ebenen



- Beispiel Monty Hall: 97 von 150 Wechselrunden gewonnen – Wechseln gewann in 64,7 % – Wechseln ist im Spiel überlegen
- jede Stufe braucht etwas, das in der vorigen nicht steht

Das Monty-Hall-Beispiel ist das konstruierte Rechenbeispiel aus LE 6.

Over-Interpretation

- Zusammenhang als Ursache lesen
- über die Stichprobe hinaus verallgemeinern
- „signifikant" als „groß" oder „wichtig" lesen
- einen Einzelbefund als gesichert darstellen
- aus dem Fehlen eines Befunds auf das Fehlen eines Effekts schließen

Interpretation oder Spekulation?

- **Interpretation**: bleibt an den Befund gebunden, nennt ihre Annahmen, lässt Alternativen zu
- **Spekulation**: geht über das hinaus, was die Daten tragen können – erlaubt, wenn sie so heißt
- Prüffrage: Welcher Befund würde meine Deutung widerlegen?
- Pflicht: zu jeder Deutung mindestens eine Gegenhypothese

10.4 p-Hacking erleben: der Vorhersage-Trick

Für das p-Hacking hat das Buch eine Demonstration, in der die Methode des Tricks und der zu vermittelnde Fehlschluss identisch sind (Abschnitt 10d). Die Vorführende macht mehrere Vorhersagen über Zahlen, die Freiwillige frei nennen. Beim Öffnen sind *alle* Vorhersagen falsch. Dann der Vorschlag, nicht auf die Treffer zu schauen, sondern auf die Fehler: Die Abweichungen zwischen Vorhersage und Wirklichkeit ergeben die Ziffern von π. Die Methode ist ein *One-Ahead*: Die Vorführende schreibt jede „Vorhersage für die nächste Runde" in Wahrheit aus der gerade genannten Zahl plus der geplanten Abweichung; die letzte Zahl ist geforct und die passende Karte vorab versiegelt. Das Muster war also garantiert, weil jede Vorhersage nach dem Blick auf die Daten konstruiert wurde.

Vier Vorhersagen, alle falsch

Runde	genannte Zahl a_i	Vorhersage p_i	Abweichung $p_i - a_i$
1	5	8	**3**
2	9	10	**1**
3	2	6	**4**
4	7	8	**1**

- keine Vorhersage trifft – aber die Fehler lauten 3, 1, 4, 1

Die Tabelle ist das durchgerechnete Beispiel aus dem Buch; in der Stunde stehen dort die tatsächlich genannten Zahlen.

Die Methode ist der Fehlschluss

- jede Vorhersage wurde *nach* der genannten Zahl geschrieben: $p_i = a_i + r_i$
- das Muster war garantiert, egal welche Zahlen kamen
- genau das ist **p-Hacking**: Bedeutung wird nachträglich in Daten hineingerechnet
- dafür braucht es keinen bösen Willen, nur Auswahl nach Sicht der Daten

10.5 Viele Wege, ein Treffer

In der Forschung braucht es für p-Hacking keinen Trick. Es genügt, nach Sicht der Daten unter vielen plausiblen Auswertungen die eine zu wählen, die „funktioniert". Gelman und Loken (2014) nennen das den *Garden of Forking Paths*: Jede Entscheidung über Ausreißer, Teilgruppen, Kovariaten, Messzeitpunkte oder Abbruchkriterien ist eine Weggabelung, und wer erst am Ende des Gartens entscheidet, welchen Weg er gegangen sein will, findet fast immer einen Treffer. Simmons u. a. (2011) haben gezeigt, dass solche „researcher degrees of freedom" die Falsch-Positiv-Rate weit über die nominellen 5 % treiben. Kerr (1998) hat den verwandten Fall benannt, dass eine Hypothese erst nach den Ergebnissen gebildet und dann als vorab aufgestellt präsentiert wird (HARKing). Und Ioannidis (2005) hat argumentiert, dass bei kleinen Studien, kleinen Effekten und vielen getesteten Beziehungen ein großer Teil der veröffentlichten positiven Befunde falsch sein dürfte.

Begriffe

- **p-Hacking**: Auswertung variieren, bis $p < 0{,}05$ (Simmons u. a. 2011)
- **HARKing**: Hypothese nach den Ergebnissen bilden und als vorab ausgeben (Kerr 1998)
- **Garden of Forking Paths**: viele Gabelungen, auch ohne bewusstes Probieren (Gelman und Loken 2014)
- **Data Dredging**: in großen Datensätzen ohne Hypothese nach Mustern graben

Die Tafel-Auflösung

$$P(\text{mindestens ein Treffer}) \;=\; 1 - (1 - \alpha)^m$$

m	1	2	5	10	14	20	50	100
$\alpha = 0{,}05$	5 %	9,8 %	22,6 %	40,1 %	51,2 %	64,2 %	92,3 %	99,4 %

- m: Zahl der Versuche (Auswertungen, Hypothesen, Zwischenstände)
- ab $m = 14$ ist ein Zufallstreffer wahrscheinlicher als keiner
- m ist die „Magier-Freiheit" des Tricks

Die Werte sind nachgerechnet; der Wert für $m = 14$ steht so auch im Buch. Eine strengere Schwelle wie $p < 0{,}005$ verschiebt das Problem nur (Benjamin u. a. 2018): Bei $m = 100$ liegt die Wahrscheinlichkeit für mindestens einen Zufallstreffer dann immer noch bei 39,4 %.

Die Bayes-Pointe

- viele Hypothesen teilen sich den Vorab-Glauben, jede bekommt nur wenig
- ein Treffer unter vielen war ohnehin zu erwarten
- also bleibt die Posteriori nahe der Priori
- 100 versiegelte Vorhersagen, eine trifft: Erwartung, kein Wunder

Ein Verfahren, das *immer* ein hübsches Ergebnis liefert, ist so wenig Evidenz wie ein Test, der die Nullhypothese stets ablehnt (Buch, Abschnitt 10d; Ioannidis (2005)).

Ein Lehrstück aus dem Buch

- Monty-Hall-Feldstudie, Teilnehmende *ohne* Vorwissen
- Trefferquote U1: 25 %, U2: 60 %, U3: 83 %
- Differenz U3 gegen U1: $+58$ Prozentpunkte $[+6;\ +81]$
- aber: sechs gegen acht Personen, Analyse erst nach Sichtung der Daten gerechnet

Das Buch kommentiert diesen Befund selbst als den, dem man am wenigsten trauen darf, und ergänzt: „Genau so entstehen Ergebnisse, die in der Replikation verschwinden" (Kap. 12f). Die Schichtung nach Vorwissen war nicht vorab geplant und ist im Buch ausdrücklich als explorativ markiert. Das ist ein Beispiel für saubere Praxis: Der Befund wird berichtet, aber als Hypothese für eine Folgestudie, nicht als Ergebnis.

10.6 Gegenmittel

Gegen die Freiheiten der Auswertung helfen drei Dinge. Erstens die *Präregistrierung*: Hypothesen, Stichprobengröße und Auswertungsplan werden vor der Datenerhebung öffentlich festgelegt. Damit wird sichtbar, was vorhergesagt und was nachträglich gefunden wurde; beides ist legitim, solange man es unterscheidet (Nosek u. a. 2018). Die Präregistrierung ist das Gegenteil des One-Ahead: Die Vorhersage liegt tatsächlich vorher im Umschlag. Zweitens die *Triangulation*: Derselbe Gegenstand wird mit verschiedenen Daten, Methoden oder Personen untersucht (Denzin 1970). Ein Befund, der nur in einer Auswertung auftaucht, ist verdächtig; einer, den verschiedene Zugänge unabhängig stützen, ist robuster. Drittens die *Gegenhypothese*: Wer zu jeder Deutung aktiv nach der besten Alternative sucht, schützt sich gegen den Bestätigungsfehler (LE 8).

Präregistrierung

- *vor* der Erhebung festlegen: Hypothesen, n, Ausschlüsse, Auswertung
- öffentlich und mit Zeitstempel hinterlegen
- Abweichungen sind erlaubt, müssen aber berichtet werden
- trennt Vorhersage von Nachhersage (Nosek u. a. 2018)
- das Gegenteil des One-Ahead: Die Vorhersage liegt wirklich vorher im Umschlag

Triangulation

- **Daten**: verschiedene Quellen, Zeitpunkte, Orte
- **Forschende**: mehrere Personen werten unabhängig aus (LE 9)
- **Methoden**: Zahlen und Interviews, Experiment und Beobachtung
- **Theorien**: denselben Befund aus mehreren Perspektiven deuten (Denzin 1970)

Prüffragen an die eigene Auswertung

- Stand meine Auswertung fest, bevor ich die Daten sah?
- Wie viele Wege habe ich ausprobiert, wie viele berichte ich?
- Was ist die beste Gegenhypothese?
- Welche Zusatzdaten würden zwischen beiden entscheiden?
- Hätte meine Auswertung meine Hypothese widerlegen können?

Merke

Ein Muster, das jede Datenlage hervorbringen würde, sagt nichts über die konkrete Datenlage. Wer erst nach dem Blick auf die Daten entscheidet, wonach er sucht, hat keinen Befund, sondern eine Hypothese für die nächste Studie.

10.7 Übung in der Stunde

Befund-Übung (Kleingruppen, 20 Min.)

- fiktive Studie: Tagebuch des Staunens und Klausurpunkte (Übungsblatt Teil A)
- (a) Formulieren Sie die deskriptiven Befunde
- (b) Formulieren Sie zwei konkurrierende Interpretationen
- (c) Welche Zusatzdaten würden zwischen ihnen entscheiden?
- (d) Wie viele Wege hätte man auswerten können?

Selbstbezug (Einzelarbeit, 10 Min.)

- Notieren Sie Ihr bisher wichtigstes Ergebnis im Semesterprojekt
- Haben Sie gezielt nach Bestätigung gesucht?
- Welcher Befund würde Ihre Hypothese herausfordern?
- Wo liegen Ihre eigenen Weggabelungen?

Hinweis für Lehrende

Die nachgerechneten Kennwerte der fiktiven Studie stehen im Erwartungshorizont am Ende von Übungsblatt Teil B. Der Datensatz ist so konstruiert, dass der Unterschied zwischen den Tagebuch-Gruppen groß und „hochsignifikant" ist, Tagebuch und Anwesenheit aber so eng zusammenhängen, dass sich ihre Wirkungen mit diesen Daten nicht trennen lassen. Die zentrale Einsicht: Die konkurrierende Interpretation (Engagement als Drittvariable) ist mit den Daten genauso verträglich, und nur ein anderes Design, etwa die zufällige Zuteilung zum Tagebuch, könnte entscheiden. Im Selbstbezug genügt es, wenn jede Person eine eigene Weggabelung konkret benennt.

10.8 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- Daten, Befund und Schlussfolgerung unterscheiden
- zu einem Befund konkurrierende Interpretationen formulieren und entscheidende Zusatzdaten benennen
- p-Hacking, HARKing und den Garden of Forking Paths erklären
- die Wahrscheinlichkeit von Zufallstreffern bei m Tests berechnen
- Präregistrierung und Triangulation als Gegenmittel einsetzen

Bis zur nächsten Woche

- **Befund-Übung** fertigstellen (Übungsblatt Teil A, Aufgabe 1)
- **Reflexion** zum Semesterprojekt: Haben Sie Ergebnisse gesucht, die Ihre Hypothese *bestätigen*? Welche Befunde könnten sie *herausfordern*? (Teil B, Aufgabe 3)
- **Tagebuch des Staunens**: eine Entscheidung, die sich frei anfühlte und es vielleicht nicht war
- für LE 11: einen Absatz aus Ihrem Projekt mitbringen, in dem Sie ein Ergebnis deuten

Handout: Datenanalyse und Interpretation

Worum es heute ging. Vier frei gewählte Zahlen ergaben die Summe, die vorher im Umschlag lag: Geburtsjahr plus erreichtes Alter und Ereignisjahr plus vergangene Jahre ergeben jeweils das laufende Jahr. Die Wahl war frei, das Ergebnis erzwungen – ein *Force*. Beim Vorhersage-Trick waren alle Vorhersagen falsch, und doch ergaben die Fehler die Ziffern von π, weil jede Vorhersage nach dem Blick auf die Daten geschrieben wurde. Beides zeigt: Ein Muster, das jede Datenlage hervorbringt, beweist nichts.

Kernbegriffe

Daten, Befund, Schluss erhobene Werte; prüfbare Zusammenfassung; Deutung mit Annahmen (Schlussfolgerung). Over-Interpretation heißt, eine Schlussfolgerung wie einen Befund zu formulieren.

p-Hacking Auswertung variieren, bis ein Ergebnis signifikant wird (Simmons u. a. 2011).

HARKing Hypothesizing After the Results are Known: eine nachträglich gebildete Hypothese als vorab aufgestellt ausgeben (Kerr 1998).

Garden of Forking Paths viele Entscheidungen der Auswertung erzeugen Zufallstreffer, auch ohne bewusstes Probieren (Gelman und Loken 2014).

Präregistrierung Hypothesen und Auswertungsplan vor der Erhebung öffentlich festlegen (Nosek u. a. 2018).

Triangulation einen Gegenstand mit verschiedenen Daten, Methoden, Personen oder Theorien untersuchen (Denzin 1970).

Zufallstreffer bei m unabhängigen Tests ($\alpha = 0{,}05$)

m	1	2	5	10	14	20	50
$1-(1-\alpha)^m$	5 %	9,8 %	22,6 %	40,1 %	51,2 %	64,2 %	92,3 %

Merke

Wer erst nach dem Blick auf die Daten entscheidet, wonach er sucht, hat keinen Befund, sondern eine Hypothese für die nächste Studie. Zu jeder Deutung gehört eine Gegenhypothese.

Prüffragen: Stand meine Auswertung vorher fest? Wie viele Wege habe ich probiert, wie viele berichte ich? Was ist die beste Gegenhypothese, und welche Daten würden entscheiden?

Zum Weiterlesen: Gelman und Loken (2014); Nosek u. a. (2018); Ioannidis (2005).

Übungsblatt A: Befund und Deutung

Name: _____ Datum: _____

Aufgabe 1: Befund-Übung

in der Stunde, Kleingruppe, 20 Min.

Fiktive Studie (konstruiert für diese Übung, keine echte Erhebung): In einem Kurs mit 13 Terminen wurde für 24 Studierende festgehalten, an wie vielen Terminen sie anwesend waren (**Anw**), wie viele Einträge sie im Tagebuch des Staunens gemacht haben (**Tgb**, höchstens 13) und wie viele Punkte sie in der Klausur erreicht haben (**Pkt**, höchstens 60). **SG** ist der Studiengang (T = Technik, W = Wirtschaft).

Nr	SG	Anw	Tgb	Pkt	Nr	SG	Anw	Tgb	Pkt
1	W	8	6	38	13	T	9	7	32
2	W	8	3	34	14	T	10	8	35
3	W	7	4	28	15	T	6	3	24
4	T	11	11	45	16	T	8	6	38
5	W	9	9	36	17	W	11	8	35
6	T	10	9	38	18	W	5	2	19
7	T	12	10	48	19	T	10	9	39
8	T	13	12	51	20	W	12	11	46
9	W	11	9	36	21	T	8	5	30
10	T	9	7	35	22	T	9	8	40
11	W	8	6	36	23	W	7	4	31
12	T	7	5	27	24	W	13	12	47

Die Studienleitung schreibt: „Wer regelmäßig Tagebuch führt (mindestens 8 Einträge), erreicht deutlich mehr Punkte. Das Tagebuch des Staunens verbessert also den Lernerfolg."

(a) Formulieren Sie die *deskriptiven Befunde*: Mittelwerte der Punkte in den Gruppen mit mindestens 8 und mit weniger als 8 Einträgen; wenn möglich auch der Zusammenhang zwischen Tgb und Pkt.

(b) Formulieren Sie *zwei konkurrierende Interpretationen* dieser Befunde. Welche Rolle spielt Anw?

(c) Welche *Zusatzdaten* oder welches andere Design würde zwischen Ihren Interpretationen entscheiden?

(d) Notieren Sie mindestens fünf Entscheidungen, die man bei der Auswertung anders hätte treffen können (Weggabelungen).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 10**

Übungsblatt B: Zufallstreffer und Selbstbezug

Name: _____ Datum: _____

Aufgabe 2: Zufallstreffer berechnen

in der Stunde, Einzelarbeit

Berechnen Sie die Wahrscheinlichkeit, bei m unabhängigen Tests mindestens einen Zufallstreffer zu erhalten, für zwei Schwellen.

m	1	3	5	10	20	100
$\alpha = 0{,}05$						
$\alpha = 0{,}005$						

Bei wie vielen Tests ist ein Zufallstreffer mit $\alpha = 0{,}05$ wahrscheinlicher als keiner? _____

Aufgabe 3: Reflexion zum Semesterprojekt

Hausaufgabe

Prüfen Sie Ihre bisherigen Ergebnisse: Haben Sie Ergebnisse gesucht, die Ihre Hypothese *bestätigen*? Welche Befunde könnten Ihre Hypothese *herausfordern*? Nennen Sie mindestens eine Weggabelung Ihrer eigenen Auswertung und legen Sie fest, wie Sie sich dort entscheiden – bevor Sie weitere Daten ansehen.

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Beschreiben Sie eine Entscheidung, die sich frei anfühlte und es vielleicht nicht war. Was hat sie strukturiert?

Erwartungshorizont

Aufgabe 1 (Werte mit Python nachgerechnet). (a) Alle 24: Pkt Mittelwert 36,17 ($s = 7{,}72$, Median 36, Spannweite 19–51); Tgb Mittelwert 7,25 ($s = 2{,}91$); Anw Mittelwert 9,21 ($s = 2{,}15$). Mindestens 8 Einträge ($n = 12$): Pkt Mittelwert 41,33 ($s = 5{,}73$, Median 39,5); weniger als 8 ($n = 12$): 31,00 ($s = 5{,}78$, Median 31,5). Differenz 10,3 Punkte, Cohens $d \approx 1{,}80$; t-Test $p \approx 0{,}0002$. Korrelation Tgb–Pkt $r = 0{,}89$. Aber auch Anw–Pkt $r = 0{,}90$ und Tgb–Anw $r = 0{,}95$. Die Gruppe mit mindestens 8 Einträgen war im Mittel an 10,92 Terminen anwesend, die andere an 7,50. (b) Interpretation 1: Das Tagebuch fördert das Lernen (kausale Lesart der Studienleitung). Interpretation 2: Eine Drittvariable wie Engagement oder Motivation führt sowohl zu mehr Anwesenheit und mehr Tagebucheinträgen als auch zu mehr Punkten; denkbar ist auch, dass Anwesenheit selbst wirkt und Tagebucheinträge vor allem bei Anwesenheit entstehen. Die Daten können beides nicht trennen: Unter den zehn Personen mit höchstens 8 Terminen hat niemand 8 oder mehr Einträge, unter den sieben mit mindestens 11 Terminen haben alle 8 oder mehr. Rechnet man die Anwesenheit heraus, sinkt der Zusammenhang Tgb–Pkt auf eine Partialkorrelati-

on von 0,29 – bei $n = 24$ und dieser Kollinearität kein belastbarer Wert. (c) Zufällige Zuteilung zum Tagebuch (Experiment); Vorleistungen (z. B. Noten vor dem Kurs); Lernzeit außerhalb des Kurses; Inhalte der Tagebucheinträge (qualitativ, LE 9); Interviews zur Nutzung (Triangulation). Die Zeitfolge klären: Kamen die Einträge vor den Lernfortschritten? (d) Grenze der Tagebuchgruppen (8, 10, Median, kontinuierlich); Punkte oder nur „bestanden"; Ausschluss von Nr. 18 (niedrigster Wert); Teilgruppe nach Studiengang (in beiden Studiengängen ist der Unterschied vorhanden: T 42,29 gegen 31,00, W 40,00 gegen 31,00); Kontrolle für Anwesenheit ja/nein; Wahl des Tests; einseitig oder zweiseitig. Wer fünf Gabelungen mit je zwei Optionen hat, hat bereits $2^5 = 32$ mögliche Auswertungen.

Aufgabe 2. $\alpha = 0{,}05$: $m = 1$: 5,0 %; 3: 14,3 %; 5: 22,6 %; 10: 40,1 %; 20: 64,2 %; 100: 99,4 %. $\alpha = 0{,}005$: 0,5 %; 1,5 %; 2,5 %; 4,9 %; 9,5 %; 39,4 %. Ab $m = 14$ Tests ist bei $\alpha = 0{,}05$ ein Zufallstreffer wahrscheinlicher als keiner (51,2 %; bei $m = 13$ sind es 48,7 %).

Aufgabe 3. Erwartet ist eine konkrete, eigene Weggabelung mit einer vorab getroffenen Entscheidung, keine allgemeine Aussage.