HOCHSCHULE
RAVENSBURG-WEINGARTEN
UNIVERSITY
OF APPLIED SCIENCES

Wissenschaftliches Arbeiten

Wissenschaft und Zauberkunst

Skript mit Ablauf, Vorbereitung, Handouts und Übungen

Prof. Dr. Markus Pfeil

Wintersemester 2026/27

Inhaltsverzeichnis

0 Zum Modul **7**

0.1 Gebrauch von Skript, Folien und Handouts . . . 8
0.2 Das Modul . . . 8
0.3 Der didaktische Ansatz . . . 9
0.4 Semesterplan . . . 9
0.5 Semesterprojekt und Leistungsnachweise . . . 10

1 Staunen als Erkenntnishaltung **12**

1.1 Staunmoment: Das Pendel . . . 14
1.2 Was ist Wissenschaft? . . . 15
1.3 Prediction Error: warum Überraschung lernen lässt . . . 15
1.4 Belief und Alief . . . 16
1.5 Auflösung: der ideomotorische Effekt . . . 16
1.6 Der Dreiklang des Semesters . . . 17
1.7 Übung in der Stunde . . . 17
1.8 Lernziele und Aufgaben . . . 18

2 Die Forschungsfrage **22**

2.1 Staunmoment: Das geheime Objekt . . . 24
2.2 Vom Thema zur Forschungsfrage . . . 25
2.3 Neugier als Informationslücke . . . 26
2.4 Kriterien guter Forschungsfragen . . . 27
2.5 Implizite Prämissen . . . 28
2.6 Operationalisierung: vom Begriff zur Messung . . . 28
2.7 Eingrenzen und die Forschungslücke finden . . . 29
2.8 Übung in der Stunde . . . 30
2.9 Lernziele und Aufgaben . . . 31

3 Literaturrecherche **36**

3.1 Staunmoment: Der Zählweg . . . 38
3.2 Auflösung: das Kruskal-Prinzip . . . 38
3.3 Systematisch statt zufällig . . . 39
3.4 Wo man sucht: Kataloge und Datenbanken . . . 40
3.5 Suchbegriffe und Suchsprache . . . 41
3.6 Schneeball und Zitationsnetzwerke . . . 42
3.7 Graue Literatur . . . 43
3.8 Dokumentieren, verwalten, annotieren . . . 43
3.9 Die Kehrseite: suchen, was man schon glaubt . . . 44

3.10 Übung in der Stunde . . . 45
3.11 Lernziele und Aufgaben . . . 45

4 Quellenkritik 52
4.1 Staunmoment: Muster im Rauschen . . . 54
4.2 Apophänie und Bestätigungsfehler . . . 58
4.3 Kriterien der Quellenkritik . . . 59
4.4 Qualitätsstufen wissenschaftlicher Literatur . . . 60
4.5 Plausibilität und ihre Grenzen . . . 60
4.6 Impact Factor, h-Index und was sie nicht aussagen . . . 61
4.7 Laterales Lesen und SIFT . . . 62
4.8 Prebunking und Debunking . . . 63
4.9 Übung in der Stunde . . . 64
4.10 Lernziele und Aufgaben . . . 64

5 Hypothesen und Falsifizierbarkeit 72
5.1 Staunmoment: Das Schaltbrett . . . 74
5.2 Drei Arten zu schließen . . . 75
5.3 Popper: Falsifikation statt Verifikation . . . 76
5.4 Von der Vermutung zur Hypothese . . . 77
5.5 Null- und Alternativhypothese . . . 77
5.6 Horwich: Bestätigung hat Grade . . . 78
5.7 Grenzen der Falsifikation: Duhem-Quine . . . 79
5.8 Brücke zum Bias: der 2-4-6-Test . . . 79
5.9 Übung in der Stunde . . . 80
5.10 Sicherung: Was ist eine gute Hypothese? . . . 81
5.11 Lernziele und Aufgaben . . . 81

6 Statistik: Signifikanztest und Bayes 86
6.1 Staunmoment: Drei Becher . . . 89
6.2 Auflösung: bedingte Wahrscheinlichkeit . . . 90
6.3 Beschreiben und Schließen . . . 91
6.4 Lage, Streuung und Ausreißer . . . 91
6.5 Von der Stichprobe zur Grundgesamtheit . . . 93
6.6 Der Signifikanztest . . . 96
6.7 Was der p-Wert nicht sagt . . . 99
6.8 Zweite Sitzung: Testen mit Vorwissen . . . 99
6.9 Zwei Arten, Daten zu befragen . . . 100
6.10 Die Basisrate: das vergessene Vorwissen . . . 100
6.11 Bayes: Was beweist ein Befund? . . . 101
6.12 Frequentistisch oder bayesianisch? . . . 104
6.13 Übung: Würfel-Detektive . . . 105
6.14 Glaubwürdigkeits-Check mit der Suchmaschine . . . 107

6.15 Effektgröße und Power . . . 108
6.16 Schwierige Fragen zerlegen: Diamant und Landkarte . . . 110
6.17 Warnung: Bedeutung aus Zufall . . . 114
6.18 Zeitungsstatistik lesen . . . 115
6.19 Lernziele und Aufgaben . . . 115

7 Forschungsdesign 126
7.1 Staunmoment: Drei Seile . . . 128
7.2 Was ein Forschungsdesign leistet . . . 129
7.3 Designtypen . . . 129
7.4 Interne Validität . . . 130
7.5 Konfundierung und Kontrolle . . . 131
7.6 Externe Validität . . . 131
7.7 Gütekriterien der Messung . . . 132
7.8 Fallbeispiel: die Becher-Monty-Hall-Studie . . . 132
7.9 Design-Werkstatt . . . 134
7.10 Lernziele und Aufgaben . . . 134

8 Kognitive Verzerrungen 140
8.1 Staunmoment: Drei Schachteln . . . 142
8.2 Verzerrung als Normalbetrieb . . . 143
8.3 Verzerrungen im Forschungsprozess . . . 143
8.4 Der Bestätigungsfehler . . . 144
8.5 Der Hot-Cold-Empathy-Gap . . . 144
8.6 Misdirection . . . 145
8.7 Bias und Noise . . . 145
8.8 Gegenmittel: Methode statt guter Wille . . . 146
8.9 Die Replikationskrise . . . 146
8.10 Bias-Jagd . . . 147
8.11 Lernziele und Aufgaben . . . 147

9 Qualitative Methoden 153
9.1 Staunmoment: Zweimal dasselbe . . . 155
9.2 Verstehen statt Messen . . . 156
9.3 Konstruktivismus und Intersubjektivität . . . 156
9.4 Methoden im Überblick . . . 157
9.5 Das Leitfadeninterview . . . 157
9.6 Gütekriterien . . . 158
9.7 Qualitative Inhaltsanalyse nach Mayring . . . 158
9.8 Stärken und Grenzen . . . 159
9.9 Übung in der Stunde . . . 160
9.10 Lernziele und Aufgaben . . . 160

10 Datenanalyse und Interpretation **165**
10.1 Staunmoment: Die unveränderliche Summe . . . 167
10.2 Auflösung: der Force . . . 168
10.3 Daten, Befund, Schlussfolgerung . . . 168
10.4 p-Hacking erleben: der Vorhersage-Trick . . . 169
10.5 Viele Wege, ein Treffer . . . 170
10.6 Gegenmittel . . . 171
10.7 Übung in der Stunde . . . 172
10.8 Lernziele und Aufgaben . . . 172

11 Wissenschaftliches Schreiben **178**
11.1 Staunmoment: Das wachsende Seil . . . 180
11.2 Vom Patter zur Fachsprache: die Transformationsregeln . . . 181
11.3 Der Aufbau wissenschaftlicher Texte . . . 181
11.4 Akademischer Stil . . . 182
11.5 Argumentieren: These, Beleg, Schluss . . . 183
11.6 Zitieren . . . 184
11.7 Plagiat . . . 184
11.8 Einleitung und Fazit als Rahmen . . . 185
11.9 Überarbeiten als Methode . . . 186
11.10 Übung in der Stunde . . . 186
11.11 Lernziele und Aufgaben . . . 187

12 Präsentation und Glaubwürdigkeit **193**
12.1 Staunmoment: Zwei Vorträge . . . 195
12.2 Präsentieren heißt überzeugen . . . 195
12.3 CREDS: Werkzeug und Warnung . . . 196
12.4 Dramaturgie eines Kurzvortrags . . . 197
12.5 Folien gestalten . . . 197
12.6 Transparenz über Limitationen . . . 198
12.7 Umgang mit Fragen . . . 199
12.8 Poster und Laienpublikum . . . 199
12.9 Übung in der Stunde . . . 200
12.10 Lernziele und Aufgaben . . . 200

13 Wissenschaftsethik und Grenzarbeit **206**
13.1 Staunmoment: Was verrät man? . . . 208
13.2 Grenzarbeit: offenlegen oder schützen . . . 208
13.3 Forschung mit Menschen: Einwilligung . . . 209
13.4 Anonymisierung, Pseudonymisierung, DSGVO . . . 210
13.5 Wissenschaftliche Integrität . . . 211
13.6 Open Science . . . 212
13.7 Interessenkonflikte und Ethikkommissionen . . . 212

13.8 Grenzen der Wissenschaft . . . 213
13.9 Übung in der Stunde: Ethik-Werkstatt . . . 213
13.10 Verantwortung nach außen . . . 213
13.11 Rückblick: vom Staunen zur Verantwortung . . . 214
13.12 Lernziele und Aufgaben . . . 214

A Material und Requisiten im Semester **220**
A.1 Requisiten und Material je Lehreinheit . . . 220
A.2 Kopiervorlagen . . . 221
A.3 Offene Auswahlentscheidungen . . . 221

Literatur **222**

0 Zum Modul

Dieses Skript begleitet das Modul *Wissenschaftliches Arbeiten* in der Fassung *Wissenschaft und Zauberkunst* (WuZ). Es setzt das Curriculum aus Kapitel 15 des Buches *Wissenschaft und Zauberkunst – Wie wir uns ein besseres Bild von der Welt machen* in 13 Lehreinheiten um, verteilt auf 14 Semesterwochen: Jede Einheit füllt eine Woche, nur die Statistik (LE 6) umfasst zwei Doppelstunden. Jede Einheit beginnt mit einem Staunmoment, einer kurzen Zaubervorführung oder einem Selbstversuch, dessen Wirkung das Methodenthema der Woche vorwegnimmt. Die Hypothese, die dem Ansatz zugrunde liegt, lautet: Staunen führt zu besserem Lernverhalten, objektiverem Denken und weniger Verzerrung in Aussagen und Entscheidungen.

0.1 Gebrauch von Skript, Folien und Handouts

Skript, Folien und Handouts entstehen aus denselben Quelldateien. Das **Skript** (dieses Dokument) ist die vollständige Fassung für Lehrende: Es enthält Fließtext, Folieninhalte, die Vorbereitung jedes Kunststücks, den Ablauf der Doppelstunde, Hinweise zur Durchführung und die Erwartungshorizonte der Übungen. Die **Folien** enthalten nur, was in der Stunde gezeigt wird. Die **Handouts und Übungsblätter** sind eine eigene Druckvorlage für die Studierenden, ohne Regie- und Lösungshinweise.

Element	Skript	Folien	Handouts
Fließtext, Theorie	ja	–	–
Folieninhalte (Stichpunkte, Grafiken)	ja	ja	–
Staunmoment (violette Box)	ja	ja	–
Vorbereitung vor der Stunde (graue Box)	ja	–	–
Ablauf der Doppelstunde (cyanfarbene Box)	ja	–	–
Hinweis für Lehrende, Erwartungshorizont	ja	–	–
Handout (eine Seite je Einheit)	ja	–	ja
Übungsblatt	ja	–	ja

Die Vorbereitungsboxen sind als Checklisten angelegt: was eine Woche vorher zu besorgen und zu proben ist, was zu kopieren ist, was am Tag selbst im Raum vorbereitet werden muss und was zu tun ist, wenn ein Effekt nicht gelingt. Eine Gesamtliste aller Requisiten steht in Anhang A.

Zur Geheimhaltung

Dieses Skript ist öffentlich. Methoden kommerzieller und klassischer Kunststücke (Switchboard, Chop Cup, Seilroutine, Becherroutinen) sind darum nicht beschrieben; für sie gilt die Anleitung des Herstellers bzw. die Standardliteratur. Beschrieben ist alles, was das Begleitbuch selbst offenlegt: das Pendel, die Charpentier-Illusion, das Kruskal-Prinzip, die Monty-Hall-Mathematik und der Vorhersage-Trick zum p-Hacking. Gegenüber den Studierenden gilt die Haltung aus LE 13: Methoden werden nicht verraten, die Richtung, in der sie liegen, darf angedeutet werden.

0.2 Das Modul

Wissenschaftliches Arbeiten (WuZ)

- Grundstudium, Pflichtmodul, studiengangsübergreifend (Bachelor)
- 5 ECTS, 150 h Arbeitsaufwand (ca. 60 h Präsenz, 90 h Selbststudium und Projektarbeit)
- seminaristische Vorlesung mit Demonstrationen, Kurzexperimenten, Einzel- und Gruppenübungen
- semesterbegleitend: Tagebuch des Staunens und eigene Forschungsarbeit
- Prüfung: Portfolio, benotet

Was Sie am Ende können

- eine beantwortbare Forschungsfrage entwickeln und daraus prüfbare Hypothesen ableiten
- Literatur systematisch recherchieren und Quellen kritisch bewerten
- ein Forschungsdesign wählen, das ein echtes Widerlegungsrisiko eingeht
- quantitative und qualitative Daten auswerten und Befunde von Deutungen trennen
- Ergebnisse schreiben und präsentieren und dabei Unsicherheit offen benennen
- die Regeln guter wissenschaftlicher Praxis auf die eigene Arbeit anwenden

Die Qualifikationsziele folgen den Kompetenzfeldern des Qualifikationsrahmens für Deutsche Hochschulabschlüsse (Kultusministerkonferenz 2017): *Wissen und Verstehen* (Grundbegriffe und Ablauf wissenschaftlichen Arbeitens, wissenschaftstheoretische Positionen, Grundlogik des Signifikanztests und der bayesianischen Aktualisierung), *Einsatz, Anwendung und Erzeugung von Wissen* (eigene Forschungsfrage, Hypothesen, Design und eine kleine kontrollierte Untersuchung), *Nutzung und Transfer* (Belastbarkeit von Quellen und Statistiken beurteilen), *Kommunikation und Kooperation* (Präsentation, Peer-Review, Codier-Vergleich) sowie *wissenschaftliches Selbstverständnis und Professionalität* (reflexiv-selbstkritische Haltung, Normen wissenschaftlicher Integrität). Der vollständige Modulhandbucheintrag steht im Begleitbuch, Kapitel 15.

0.3 Der didaktische Ansatz

Jede Lehreinheit folgt dem Dreiklang *Staunen erzeugen – Erklärung suchen – Methode verstehen*. Der Staunmoment ist der epistemische Einstieg: Er erzeugt einen Prediction Error, also eine Abweichung zwischen Erwartung und Erleben, die das Gehirn auflösen will (Clark 2016). Die Staun-Interventionen sind so gewählt, dass sie das Methodenthema inhaltlich vorwegnehmen. Das Pendel in LE 1 zeigt, dass Wahrnehmung Konstruktion ist; die Becher in LE 6 zeigen, dass das Sichtbare und der Prozess dahinter auseinanderfallen können.

Jede Woche dasselbe Muster

- **Staunen**: ein Kunststück oder Selbstversuch, ohne Vorrede
- **Erklärung**: Hypothesen sammeln, noch ohne Bewertung
- **Methode**: das Werkzeug der Woche, mit dem man zwischen den Erklärungen entscheidet
- **Anwendung**: Übung am eigenen Semesterprojekt
- **Transfer**: Tagebuch und Aufgabe bis zur nächsten Woche

Für die Vorführung selbst gilt der *Goldene Ablauf* aus dem Begleitbuch (Kapitel 6): thematischer Einstieg, eine kleine Fertigkeit als Glaubwürdigkeitssignal, der Effekt kurz und knapp, eine Aha-Pause von etwa zehn Sekunden, dann der Transfer zum Thema. Zu vermeiden ist das „Nocebo der Lehre“: der Satz „Das war jetzt nur ein Trick“, der das Staunen entwertet, bevor es wirken konnte. Das Prinzip hinter dem Effekt wird erklärt, das Gefühl des Nicht-Wissens darf aber einen Moment stehen bleiben. Glaubwürdigkeit entsteht dabei aus Handlungen, nicht aus Behauptungen (Henrich 2009); wer ein Kunststück vorführt, sollte es deshalb so oft geübt haben, dass es sicher sitzt.

Goldener Ablauf einer Vorführung

1. Thematischer Einstieg (ein Satz, der das Thema der Woche anreißt)
2. eine kleine Fertigkeit oder ein besonderes Requisit
3. der Effekt, kurz und knapp
4. Aha-Pause: das Staunen etwa zehn Sekunden wirken lassen
5. Transfer zum Methodenthema

0.4 Semesterplan

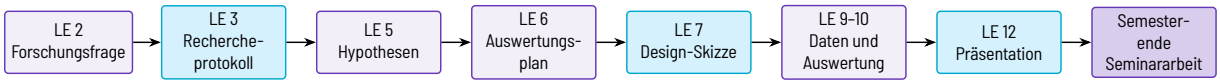
13 Lehreinheiten in 14 Wochen

LE	Thema	Staunmoment	Kernbegriff
1	Staunen als Erkenntnishaltung	Ideomotor-Pendel	Prediction Error
2	Die Forschungsfrage	Das geheime Objekt	Operationalisierung
3	Literaturrecherche	Kruskal Count	Suchstrategie
4	Quellenkritik	Apophenie / Das letzte Abendmahl	Apophenie / Bias
5	Hypothesen und Falsifizierbarkeit	Switchboard / Black Box	Falsifikation
6	Statistik: Signifikanztest und Bayes (2 Termine)	Monty Hall / Würfel	Standardfehler, Basisrate, Bayes-Faktor
7	Forschungsdesign	Kontrollierte Seilroutine	Experimentelle Kontrolle
8	Kognitive Verzerrungen	Charpentier-Illusion	Confirmation Bias
9	Qualitative Methoden	Das Patter	Intersubjektivität
10	Datenanalyse und Interpretation	Die unveränderliche Summe	Determinismus
11	Wissenschaftliches Schreiben	Patter-Umbau in Fachsprache	Präzision und Struktur
12	Präsentation und Glaubwürdigkeit	CRED-Strategien	Credibility Cues
13	Wissenschaftsethik und Grenzarbeit	Boundary Work: Was verrät man?	Forschungsethik

0.5 Semesterprojekt und Leistungsnachweise

Parallel zu den Lehreinheiten bearbeitet jede Person ein eigenes kleines Forschungsvorhaben. Die Teilleistungen bauen aufeinander auf: Wer Rechercheprotokoll, Design-Skizze und Präsentation sorgfältig erarbeitet hat, hat einen großen Teil der Seminararbeit bereits geschrieben. Die folgende Grafik zeigt, in welcher Einheit welcher Baustein entsteht.

Der rote Faden: Ihr Projekt



cyan: Teilleistung im Portfolio violett: Arbeitsschritt im Projekt

Portfolio

Leistung	Fällig	Beschreibung	Anteil
Tagebuch des Staunens	Semesterende	Reflexionsheft, 13 Einträge	20 %
Rechercheprotokoll	LE 3	dokumentierte Recherche mit Quellenliste	10 %
Forschungsdesign-Skizze	LE 7	1–2 Seiten, begründetes Studiendesign	10 %
5-Minuten-Präsentation	LE 12	Zwischenbericht zum Semesterprojekt	15 %
Seminararbeit	Semesterende	12–15 Seiten, vollständiger Forschungsbericht	45 %

Das Tagebuch des Staunens

- ein Heft, das Sie ab LE 1 führen: jede Woche ein Eintrag
- (1) Was habe ich erwartet? (2) Was ist passiert? (3) Welcher Begriff aus der Vorlesung passt dazu?
- Ziel: Staunen bemerken und mit einem wissenschaftlichen Begriff verknüpfen
- letzter Eintrag in LE 13: Was hat mich in diesem Semester am meisten überrascht?

Vor Semesterbeginn

- ☐ Anhang A durchgehen und Requisiten für das ganze Semester bestellen; Lieferzeiten für kommerzielle Requisiten (Switchboard, Seilset, Chop Cup) einplanen.
- ☐ Kunststücke mindestens zwei Wochen vor dem jeweiligen Termin proben; das Switchboard braucht die längste Einübung.
- ☐ `handouts.pdf` pro Woche kopieren; Anzahl nach Anmeldestand plus Reserve.
- ☐ A5-Hefte für das Tagebuch des Staunens bereitlegen oder in der Ankündigung um ein eigenes Heft bitten.
- ☐ Raum prüfen: Tafel oder Whiteboard, Beamer, Tische für Gruppenarbeit, Platz zum Herumreichen von Gegenständen.

1 Staunen als Erkenntnishaltung

Die erste Einheit führt nicht in eine Technik ein, sondern in eine Haltung. Bevor ein Wort über „Wissenschaft“ fällt, erleben die Studierenden an sich selbst, dass Wahrnehmung Konstruktion ist: Ein Pendel schwingt, und die haltende Hand hat „nichts getan“. Aus diesem Erlebnis entwickelt die Einheit den Begriff des Prediction Errors, die Unterscheidung von Belief und Alief und den didaktischen Dreiklang, der das ganze Semester trägt: *Staunen erzeugen – Erklärung suchen – Methode verstehen*.

Vorbereitung vor der Stunde: Ideomotor-Pendel

Eine Woche vorher

- ☐ Pendel für alle Teilnehmenden: je ein Faden von 40 cm mit Ring, Mutter (M8) oder kleinem Gewicht. 40 cm ist nach Cantergi u. a. (2021) die Länge mit der höchsten Erfolgsquote. Zehn Ersatzpendel einplanen.
- ☐ Optional Teil B (gemessenes Pendel): Pendel-App von der Website (`wissenschaftundzauberkunst.de/apps/ideomotor/`, für den Wettbewerb `/apps/ideomotor-online/`); die QR-Codes stehen auf der Folie „Dritte Kontrolle: messen". Die App braucht einmalig eine Sensorfreigabe auf dem Telefon, danach läuft sie offline.
- ☐ Selbst üben: Haltung (Ellbogen aufgestützt, Faden zwischen Daumen und Zeigefinger, Gewicht 1–2 cm über der offenen Handfläche) und den Sprechtext so lange, bis er ohne Blick auf Notizen sitzt.
- ☐ Hefte für das „Tagebuch des Staunens" beschaffen (A5, liniert) oder die Studierenden per Mail bitten, eines mitzubringen.

Handout und Übungsblatt

- ☐ Handout „Staunen als Erkenntnishaltung" sowie Übungsblatt LE 1 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 1). Teil A (Aufgaben 1 und 2) verrät die beiden Kontrollen nicht und liegt mit dem Pendel auf den Plätzen; Teil B (Hausaufgaben) wird erst in der Transferphase ausgeteilt.
- ☐ Für die Übung „Hypothesen sortieren" je Kleingruppe ein A3-Blatt mit drei Spalten *Staunen – Erklärung – Methode* vorbereiten.

Am Tag selbst

- ☐ Tische so stellen, dass jede Person den Ellbogen aufstützen kann.
- ☐ Tafel in zwei Felder teilen: links „Was ist passiert?" (Hypothesen), rechts bleibt frei für die Auflösung.
- ☐ Pendel *vor* der Begrüßung auf die Plätze legen – die Einheit beginnt ohne Vorrede.

Risiken und Plan B. Bei manchen Personen schwingt das Pendel kaum. Das ist kein Fehlschlag, sondern ein Datum: Diese Personen werden in der Hypothesenphase ausdrücklich gefragt, was bei ihnen anders war. Den Effekt *vor dem Debrief nicht auflösen*; die Beobachtungen mit geschlossenen Augen und aufgelegtem Unterarm sind Daten, die zuerst gesammelt und erst dann gedeutet werden.

Ablauf der Doppelstunde (90 Min.)

0–10 · Auftakt-Staunen. Ohne Vorrede das Pendel. Achsen wechseln (links–rechts, vor–zurück, Kreis). Die Aha-Pause von einigen Sekunden bewusst aushalten.

10–20 · Hypothesen sammeln. „Was ist gerade passiert?" Alle Erklärungen an die Tafel, noch ohne Bewertung. Danach die beiden Kontrollen nach Chevreul: Augen schließen, Unterarm auflegen. Die Beobachtungen notieren alle auf Übungsblatt Teil A, Aufgabe 2.

20–50 · Theorie-Input. Prediction Error und Predictive Processing; Belief und Alief; Staunen als epistemische Emotion; Auflösung des ideomotorischen Effekts und seine Aufklärungsgeschichte.

50–75 · Anwendung. Kleingruppen ordnen ihre Tafel-Hypothesen den Stufen *Staunen – Erklärung – Methode* zu und deuten die beiden Kontrollen (Übungsblatt Teil A, Aufgaben 1 und 2).

75–90 · Transfer und Semesterritual. Start des Tagebuchs des Staunens, Auftrag zum Kurzessay, Ausblick auf den Awe Walk. Übungsblatt Teil B (Aufgaben 3–5, Hausaufgaben) austeilen.

1.1 Staunmoment: Das Pendel

★ Staunmoment: Das Ideomotor-Pendel

Halten Sie den Faden zwischen Daumen und Zeigefinger, den Ellbogen auf dem Tisch. Das Gewicht hängt ruhig über Ihrer offenen Hand.
Bewegen Sie nichts. Denken Sie nur: links – rechts, links – rechts.

Nach 20–40 Sekunden: *Jetzt vor – zurück.* Dann: *Jetzt im Kreis.*

Was ist gerade passiert?

- sammeln Sie *alle* Erklärungen – ohne sie zu bewerten
- Wer hat das Pendel bewegt? Woher wissen Sie das?
- Bei wem hat es nicht funktioniert? Was war bei Ihnen anders?

Zwei Kontrollen

- **Augen schließen** und weitermachen: Was passiert mit dem Ausschlag?
- **Unterarm auflegen**, nur die Fingerspitzen bleiben frei: Was passiert jetzt?
- beide Beobachtungen sind *Daten* – erst sammeln, dann deuten

Die beiden Kontrollen gehen auf Michel-Eugène Chevreul zurück, der das angeblich „hellsichtige" Pendel 1833 auf genau diese Weise prüfte (Chevreul 1854). Bei den meisten Personen wird der Ausschlag mit geschlossenen Augen kleiner oder die Achse driftet, mit aufgelegtem Unterarm bricht der Effekt weitgehend zusammen. Damit liegen nach zehn Minuten zwei echte Befunde auf dem Tisch, die jede Erklärung erfüllen muss.

Dritte Kontrolle: messen

- die Pendel-App misst, wie viel *echte* Bewegung Ihr Telefon macht, während die Scheibe schwingt
- einmal „Sensoren freigeben", dann kalibrieren

Ideomotor-Pendel
wissenschaftundzauberkunst.de/apps/ideomotor/

Online-Wettbewerb
wissenschaftundzauberkunst.de/apps/ideomotor-online/

Die Einzelfassung misst getrennt nach Verschieben (Millimeter) und Kippen (Grad), wie viel reale Bewegung nötig war, um die Scheibe in Schwingung zu versetzen. In der Online-Fassung eröffnet die Lehrperson einen Raum; die Anzeigetafel für den Beamer zeigt einen eigenen QR-Code mit dem Raumcode, und es gewinnt, wer mit der geringsten echten Bewegung den größten Ausschlag erzielt.

1.2 Was ist Wissenschaft?

Die Frage, was Wissenschaft sei, wird in dieser Einheit nicht mit einer Definition eröffnet, sondern mit dem Erlebnis, das ihr historisch vorausgeht. Platon lässt Sokrates im *Theaitetos* sagen, das Staunen sei der Anfang der Philosophie (Platon 1994), und Aristoteles greift den Gedanken in der *Metaphysik* auf: Aus dem Staunen heraus hätten die Menschen zu philosophieren begonnen, weil sie ihre Unwissenheit bemerkten (Aristoteles 1989).

Staunen als Anfang

- *thaumazein*: Staunen ist der Anfang der Philosophie (Platon, Aristoteles)
- Staunen heißt: ich *bemerke*, dass mein Modell der Welt nicht passt
- Wissenschaft ist die geordnete Form, mit diesem Bemerken umzugehen

Arbeitsdefinition

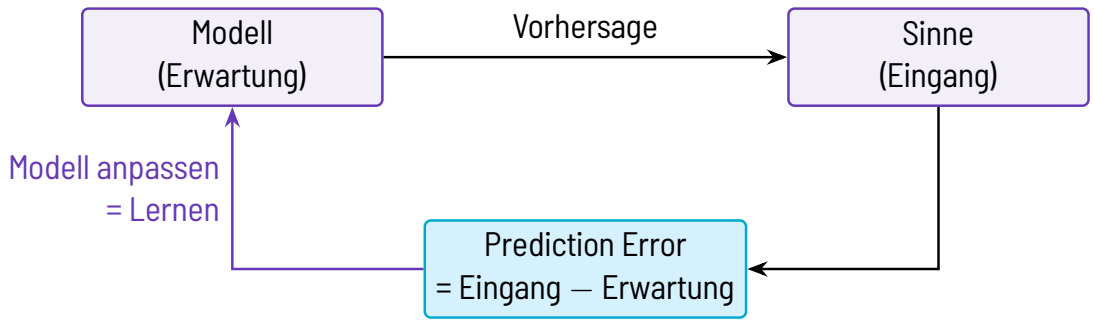
Definition 1.1 Wissenschaft ist ein methodisch geregeltes Verfahren, Behauptungen über die Welt so zu prüfen, dass andere die Prüfung nachvollziehen und wiederholen können – und dass die Behauptung an der Prüfung scheitern kann.

- *methodisch*: das Vorgehen ist offengelegt
- *intersubjektiv*: andere kommen mit derselben Methode zum selben Befund
- *fallibel*: jedes Ergebnis ist vorläufig

1.3 Prediction Error: warum Überraschung lernen lässt

Die Neurowissenschaft beschreibt das Gehirn heute weniger als Empfänger von Reizen denn als Vorhersagemaschine. Nach dem Ansatz des *Predictive Processing* erzeugt es fortlaufend Erwartungen darüber, was die Sinne als Nächstes melden werden, und verarbeitet vor allem die Abweichung zwischen Erwartung und Eingang, den *Prediction Error* (Clark 2016; Friston 2010). Wahrnehmung ist in diesem Bild eine „kontrollierte Halluzination", die von den Sinnesdaten laufend korrigiert wird (Seth 2021). Lernen findet dort statt, wo die Korrektur nötig wird.

Das Gehirn als Vorhersagemaschine



Was das für das Pendel heißt

- Erwartung: „Meine Hand steht still, also bewegt sich das Pendel nicht."
- Eingang: das Pendel schwingt deutlich
- der Fehler ist groß – und er *fühlt* sich an: das ist Staunen
- Lernen beginnt erst, wenn wir das Modell ändern, statt den Befund wegzuerklären

Staunen als epistemische Emotion

- Awe-Forschung: Staunen entsteht bei *Weite* (etwas übersteigt den Bezugsrahmen) und *Anpassungsbedarf* (das Modell muss geändert werden) (Keltner und Haidt 2003)
- Neugier entsteht aus einer bemerkten *Informationslücke* (Loewenstein 1994)
- Staunen ist damit kein Beiwerk, sondern der Moment, in dem Lernbereitschaft entsteht

Bayesianisch gelesen

- überraschend ist, was unter den eigenen Hintergrundannahmen unwahrscheinlich war
- eine Überraschung *entwertet* diese Hintergrundannahmen – sie zeigt, wo das Modell revidiert werden muss (Horwich 1982)
- Faustregel für das Semester: **Je größer die Überraschung, desto mehr lernt man über die eigenen Annahmen.**

1.4 Belief und Alief

Nach der Auflösung wissen alle, dass sie selbst das Pendel bewegt haben. Trotzdem schwingt es beim nächsten Versuch wieder, und es fühlt sich wieder so an, als täte es das von allein. Die Philosophin Tamar Gendler hat für diesen Zustand den Begriff *Alief* geprägt: eine automatische, körpernahe Reaktionsbereitschaft, die neben der bewussten Überzeugung (*Belief*) weiterläuft und ihr widersprechen kann (Gendler 2008). Für das wissenschaftliche Arbeiten ist der Unterschied zentral: Eine Überzeugung lässt sich durch ein Argument ändern, eine Alief nicht. Gegen Aliefs helfen nur Verfahren, die nicht vom eigenen Erleben abhängen.

Zwei Arten, etwas zu „glauben“

Belief	**Alief**
bewusste Überzeugung „Ich weiß, dass ich das Pendel bewege.“ durch Argumente änderbar	automatische Reaktionsbereitschaft „Es fühlt sich an, als schwinge es von allein.“ durch Argumente kaum änderbar

- Konsequenz: dem eigenen Erleben misstrauen heißt nicht, es zu leugnen – sondern es zu *messen*

1.5 Auflösung: der ideomotorische Effekt

Der Effekt heißt *ideomotorisch*: Die bloße Vorstellung einer Bewegung erzeugt minimale Innervationen in der Muskulatur, auch ohne Handlungsvorsatz und unterhalb der Wahrnehmungsschwelle. Die Bewegung ist real und messbar; nur ihre Urheberschaft wird nicht bewusst repräsentiert. Die Aufklärungsgeschichte dieses Effekts ist zugleich eine kleine Geschichte der experimentellen Methode.

Drei Schritte der Aufklärung

- **Chevreul (1833/1854):** Glasplatte, Stütze, Augenbinde – die Ursache liegt in der Hand, gesteuert über die Erwartung, rückgekoppelt über das Auge (Chevreul 1854)
- **Carpenter (1852):** Begriff des *ideomotorischen Prinzips* – Vorstellungen lösen Muskelaktivität aus (Carpenter 1852)
- **Faraday (1853):** ein Zeigerinstrument zum Tischrücken zeigt: die Hände schieben; sobald die Personen den Zeiger sehen, hört die Bewegung auf (Faraday 1853)

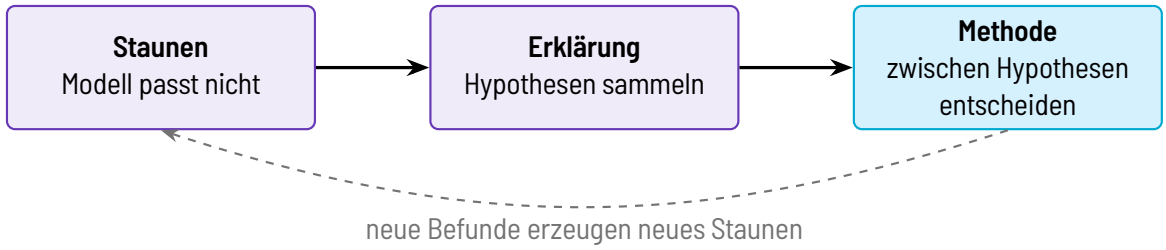
Was wir daraus lernen

- Faraday hat nicht besser argumentiert, er hat einen **besseren Apparat** gebaut
- Grundfigur wissenschaftlicher Kontrolle: eine Rückmeldung, die das Unbewusste sichtbar macht
- derselbe Mechanismus steckt in Wünschelruten, Muskeltests und „gestützter Kommunikation" – wir begegnen ihm in LE 4 und LE 5 wieder

1.6 Der Dreiklang des Semesters

Jede Lehreinheit dieses Moduls folgt demselben Muster. Ein Staunmoment erzeugt eine Informationslücke; die Gruppe sucht Erklärungen; aus der Frage, wie man zwischen den Erklärungen entscheiden könnte, wird eine Methode. Das Pendel hat diesen Weg heute einmal vollständig durchlaufen.

Staunen – Erklärung – Methode



- Pendel: *Staunen* (es schwingt) – *Erklärung* (Magnetfeld? Luftzug? ich selbst?) – *Methode* (Augen zu, Arm auflegen, messen)

Merke

Wissenschaft beginnt nicht mit der Antwort, sondern mit dem Bemerken, dass das eigene Modell nicht passt. Das Gefühl, recht zu haben, ist kein Befund – die Methode, es zu prüfen, schon.

1.7 Übung in der Stunde

Hypothesen sortieren (Kleingruppen, 20 Min.)

- Übertragen Sie die Tafel-Hypothesen auf Ihr A3-Blatt
- Ordnen Sie jede Aussage einer Stufe zu: Staunen, Erklärung oder Methode
- Für jede Erklärung: Mit welcher Beobachtung könnte man sie *widerlegen*?

Hinweis für Lehrende

Typische Hypothesen und ihre Prüfung: „Magnetismus" (Prüfung: Pendel aus Kunststoff, Glasplatte nach Chevreul), „Luftzug" (Prüfung: Pendel unter einer Glasglocke, Richtung wechselt mit dem *Gedanken*, nicht mit dem Raum), „ich selbst" (Prüfung: Unterarm auflegen, App-Messung). Die Gruppe soll sehen, dass jede Hypothese einen Test nahelegt, der sie scheitern lassen kann – das ist die Brücke zu LE 5.

1.8 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- den Begriff *Staunen* wissenschaftstheoretisch verorten
- erläutern, warum ein Prediction Error Lernen auslöst
- Belief und Alief unterscheiden und an einem Beispiel erklären
- eigene Vorannahmen als prüfbare Hypothesen formulieren

Bis zur nächsten Woche

- **Tagebuch des Staunens** beginnen: jede Woche ein Staunerlebnis, verknüpft mit einem wissenschaftlichen Begriff
- **Kurzessay** (500 Wörter): „Beschreiben Sie ein Erlebnis, das Sie zum ersten Mal an einer Überzeugung zweifeln ließ. Was hat das mit Wissenschaft zu tun?"
- optional: **Awe Walk** – ein Spaziergang pro Woche mit dem Auftrag, Dinge zu bemerken, als sähe man sie zum ersten Mal (Sturm u. a. 2022)
- eine Frage mitbringen, die Sie *wirklich* beschäftigt (für LE 2)

Handout: Staunen als Erkenntnishaltung

Worum es heute ging. Ein Pendel schwingt über Ihrer Hand, obwohl Sie „nichts tun". Mit geschlossenen Augen wird der Ausschlag kleiner, mit aufgelegtem Unterarm verschwindet er fast. Sie selbst bewegen das Pendel – mit Muskelimpulsen unterhalb Ihrer Wahrnehmungsschwelle (ideomotorischer Effekt).

Kernbegriffe

Prediction Error Abweichung zwischen dem, was das Gehirn erwartet, und dem, was die Sinne melden. Große Abweichungen erleben wir als Überraschung; sie sind der Anlass, ein Modell zu ändern, also zu lernen.

Predictive Processing Modell der Wahrnehmung, nach dem das Gehirn fortlaufend Vorhersagen erzeugt und vor allem die Abweichungen verarbeitet (Clark 2016).

Belief bewusste Überzeugung, durch Argumente änderbar.

Alief automatische, körpernahe Reaktionsbereitschaft, die neben dem Belief weiterläuft (Gendler 2008).

Ideomotorischer Effekt die Vorstellung einer Bewegung erzeugt minimale, unbemerkte Muskelbewegungen (Carpenter 1852).

Der Dreiklang des Semesters

Staunen	Erklärung	Methode
Das Modell passt nicht.	Hypothesen sammeln, noch ohne Bewertung.	Ein Verfahren finden, das zwischen den Hypothesen entscheidet.

Drei historische Kontrollen

- *Chevreul (1833):* Glasplatte, Armstütze, Augenbinde – die Ursache liegt in der Hand.
- *Carpenter (1852):* benennt das ideomotorische Prinzip.
- *Faraday (1853):* ein Zeiger macht das unbewusste Schieben beim Tischrücken sichtbar; wer den Zeiger sieht, schiebt nicht mehr.

Merke

Das Gefühl, recht zu haben, ist kein Befund. Wer dem eigenen Erleben misstraut, leugnet es nicht, sondern misst es.

Ihr Semesterritual: das Tagebuch des Staunens. Notieren Sie jede Woche ein Erlebnis, das Sie überrascht hat. Halten Sie fest: (1) Was habe ich erwartet? (2) Was ist passiert? (3) Welcher Begriff aus der Vorlesung passt dazu? Das Tagebuch ist Teil der Portfolioprüfung (20 %).

Zum Weiterlesen: Seth (2021), Kap. 1–4; Keltner und Haidt (2003).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 1**

Übungsblatt A: Staunen, Erklärung, Methode

Name: _____ Datum: _____

Aufgabe 1: Hypothesen sortieren

in der Stunde, Kleingruppe, 20 Min.

Übertragen Sie die Erklärungen von der Tafel in die Tabelle. Ordnen Sie jede einer Stufe zu und geben Sie für jede Erklärung eine Beobachtung an, die sie *widerlegen* würde. Die drei Stufen: *Staunen* (das eigene Modell passt nicht), *Erklärung* (eine Hypothese, noch ohne Bewertung), *Methode* (ein Verfahren, das zwischen Hypothesen entscheidet).

Aussage / Erklärung	Stufe	Was würde sie widerlegen?

Aufgabe 2: Zwei Bedingungen beobachten

in der Stunde, Einzelarbeit

Der Versuch wird in der Stunde unter zwei veränderten Bedingungen wiederholt.

1. Notieren Sie für jede Bedingung, was verändert wurde und was Sie beobachtet haben.
2. Welche Ihrer Erklärungen aus Aufgabe 1 wird dadurch gestützt, welche geschwächt?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 1**

Übungsblatt B: Belief, Alief und das eigene Zweifeln

Name: _____ Datum: _____

Aufgabe 3: Belief oder Alief?

Hausaufgabe

Ein *Belief* ist eine bewusste, durch Argumente änderbare Überzeugung, ein *Alief* eine automatische, körpernahe Reaktionsbereitschaft, die daneben weiterläuft. Nennen Sie zwei eigene Beispiele, in denen Ihr Wissen und Ihr Erleben auseinanderfallen (Beispiel: Sie wissen, dass eine Glasbrücke trägt, und trauen sich trotzdem nicht darauf). Welches Verfahren könnte Ihnen helfen, dem Wissen statt dem Erleben zu folgen?

Aufgabe 4: Kurzessay

Hausaufgabe, 500 Wörter, Abgabe bis LE 2

„Beschreiben Sie ein Erlebnis, das Sie zum ersten Mal an einer Überzeugung zweifeln ließ. Was hat das mit Wissenschaft zu tun?" Verwenden Sie mindestens zwei der Kernbegriffe dieser Einheit (Prediction Error, Predictive Processing, Belief, Alief, ideomotorischer Effekt).

Aufgabe 5: Vorbereitung auf LE 2

Hausaufgabe

Bringen Sie eine Frage mit, die Sie *wirklich* beschäftigt – aus Studium, Beruf oder Alltag. Sie wird in LE 2 zur Forschungsfrage geschärft.

Erwartungshorizont

Aufgabe 1: Mindestens eine Erklärung je Stufe; Widerlegungsbedingungen müssen beobachtbar sein („das Pendel schwingt auch bei aufgelegtem Arm" statt „es stimmt nicht"). Aufgabe 2: Bedingungen sind Augen schließen und Unterarm auflegen. Augen zu → visuelle Rückkopplung fehlt, Ausschlag sinkt; Arm auf → Muskelimpulse werden abgefangen. Beides spricht für die Hand als Ursache und schwächt alle Erklärungen, die eine Kraft außerhalb der Person annehmen. Aufgabe 3: Beispiele mit Höhenangst, Placebo, optischen Täuschungen; Verfahren = Messung, Protokoll, Blindbedingung.

2 Die Forschungsfrage

In der ersten Einheit stand das Staunen selbst im Mittelpunkt. Jetzt geht es darum, was man mit ihm anfängt. Ein Staunerlebnis erzeugt eine Frage, aber meist eine unscharfe: „Wie kann das sein?" Damit lässt sich keine Untersuchung planen. Diese Einheit zeigt, wie aus einer echten, oft vagen Frage eine Forschungsfrage wird, die man beantworten kann. Der Staunmoment ist diesmal kein Kunststück mit geheimer Methode, sondern ein Satz mit einer verborgenen Voraussetzung. An ihm lässt sich zeigen, dass jede Frage Annahmen mitbringt, die man prüfen muss, bevor man nach der Antwort sucht. Die zweite Hälfte der Stunde gehört den Fragen, die die Studierenden aus LE 1 mitgebracht haben.

Vorbereitung vor der Stunde: Das geheime Objekt

Eine Woche vorher

- ☐ **Allergien abfragen.** In der Mail zur Einheit (oder am Ende von LE 1) fragen, ob jemand eine Erdnussallergie hat, ohne zu verraten, wozu. Bei schweren Erdnussallergien können schon Schalenstaub und Hautkontakt Reaktionen auslösen. Gibt es auch nur eine Meldung, wird die Variante mit der Erbsenschote gespielt (siehe unten). Wer nicht sicher abfragen kann, nimmt gleich die Erbse.
- ☐ Einen **undurchsichtigen Becher** besorgen (Keramikbecher oder ein umgedrehter Pappbecher). Er sollte groß genug sein, dass die Form des Objekts nicht zu erraten ist, und auf einem Teller oder Brettchen stehen, damit man ihn durch die Reihen tragen kann.
- ☐ **Erdnüsse in der Schale** (ungesalzen, Supermarkt, eine kleine Tüte reicht). Eine Nuss mit unbeschädigter, geschlossener Schale aussuchen, zwei Ersatznüsse einpacken. Die Nuss bleibt bis zur Auflösung in einem verschließbaren Gefrierbeutel.
- ☐ **Variante ohne Allergierisiko:** eine frische, geschlossene Erbsenschote (Gemüseabteilung, Wochenmarkt); außerhalb der Saison eine Bohne in der Hülse oder eine Esskastanie. Die Pointe funktioniert mit jedem Samen in einer geschlossenen Hülle, deren Inneres noch niemand gesehen hat.
- ☐ Sprechtext üben, vor allem die Pausen. Der Satz muss wortgleich wiederholt werden können, weil die Studierenden später mit ihm arbeiten.

Handout und Übungsblatt

- ☐ Handout „Die Forschungsfrage" sowie Übungsblatt LE 2 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 2). Teil A (Aufgaben 1–3) enthält die Liste mit acht Beispielfragen für die Übung zu impliziten Prämissen und kann zu Beginn ausgeteilt werden; es nennt die Leitfrage des Staunmoments nicht. Wer ganz sichergehen will, teilt es erst nach dem Staunmoment aus. Teil B (Aufgaben 4 und 5, Hausaufgaben) folgt in der Sicherung.
- ☐ Den Satz der Behauptung groß auf ein A3-Blatt schreiben oder als Folie bereithalten („Unter diesem Becher liegt etwas, das noch kein Mensch je gesehen hat. Und nach dieser Stunde wird es auch niemand mehr sehen.").
- ☐ Die Studierenden in der Erinnerungsmail bitten, ihre Frage aus LE 1 schriftlich mitzubringen. Für Personen ohne eigene Frage stehen Ersatzthemen auf dem Übungsblatt Teil A (Aufgabe 2).
- ☐ Einen Stapel Karteikarten (A6) für die Sicherung am Ende.

Am Tag selbst

- ☐ Becher mit Objekt *vor* Beginn sichtbar auf das Pult stellen, ohne Kommentar. Fragt schon vorher jemand, was darunter ist: nicht antworten.
- ☐ Tafel zweiteilen: links „Was könnte es sein?", rechts „Was muss wahr sein, damit der Satz stimmt?" (rechte Hälfte zunächst leer lassen).
- ☐ Zweiergruppen für die Werkstatt so einteilen, dass möglichst Personen aus verschiedenen Fächern zusammensitzen; fremde Augen sehen Prämissen schneller.

Risiken und Plan B. Wer das Rätsel kennt, löst es sofort. Dann die Person bitten, die Lösung aufzuschreiben und für sich zu behalten, und sie in der Auflösung als Zeugin aufrufen: Was hat ihr geholfen, die Prämisse zu sehen? Rät niemand die Lösung, ist das kein Problem; der Staunmoment liegt in der Auflösung, nicht im Erraten. Nach der Stunde wird die Nuss weder im Raum gegessen noch verteilt; sie wandert in den Gefrierbeutel und wird draußen gegessen oder entsorgt. An der Pointe ändert das nichts: Ihr Inneres sieht danach niemand mehr.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Zwei bis drei Tagebuch-Staunmomente der Vorwoche teilen und sofort in Frageform bringen: „Was genau möchten Sie daran wissen?"

5–15 · Staunmoment. „Das geheime Objekt". Leitfrage: Welche unausgesprochene Voraussetzung steckt in der Behauptung? Erst Vermutungen sammeln, dann auflösen.

15–45 · Theorie-Input. Vom Thema zur Frage; Neugier als Informationslücke (Kap. 4 des Buchs); Kriterien guter Forschungsfragen (SMART, FINER); implizite Prämissen; Operationalisierung; Forschungslücke. Gegenüberstellung staunenswerte vs. beantwortbare Frage.

45–75 · Werkstatt am eigenen Thema. Zweiergruppen sezieren die mitgebrachte Frage: implizite Prämissen freilegen, messbare Größen benennen, nach SMART schärfen (Übungsblatt Teil A, Aufgaben 1–3).

75–90 · Sicherung. Jede Person schreibt eine erste eigene Forschungsfrage auf eine Karteikarte; drei bis vier Karten werden im Plenum auf Plausibilität geprüft; Auftrag zur schriftlichen Fassung (Übungsblatt Teil B austeilen).

2.1 Staunmoment: Das geheime Objekt

★ Staunmoment: Das geheime Objekt

Die Lehrperson hebt einen geschlossenen Becher hoch.

„Unter diesem Becher liegt etwas, das noch kein Mensch je gesehen hat. Und nach dieser Stunde wird es auch niemand mehr sehen."

Was könnte darunter liegen? Und wie könnte man prüfen, ob der Satz stimmt?

Der Effekt stammt aus der Effekttabelle des Buchs (Kap. 11), wo er für Biologie, Philosophie und alle diskursiven Fächer vorgeschlagen wird. Die Lehrperson sagt den Satz langsam und wiederholt ihn auf Nachfrage wörtlich. Fragen zum Objekt beantwortet sie in dieser Phase nicht, nimmt aber jede Vermutung auf und schreibt sie an die linke Tafelhälfte.

Was liegt unter dem Becher?

- sammeln Sie Vermutungen, auch unwahrscheinliche
- Welche Wörter im Satz lenken Ihre Vermutungen?
- Was *muss* wahr sein, damit der Satz stimmt?

Die Vermutungen gehen meist in Richtung des Seltenen und Wertvollen: ein Meteoritensplitter, ein versiegelter Brief, eine Zeichnung, etwas Verbotenes. Sie verraten, wie die Gruppe den Satz verstanden hat: als Aussage über eine *Art* von Ding, die noch niemand kennt. Wenn die Liste an der Tafel lang genug ist, wird die rechte Tafelhälfte eröffnet.

Auflösung

- unter dem Becher: **eine Erdnuss in ihrer Schale**
- die Schale wird geöffnet: diese Nuss hat noch nie jemand gesehen
- nach der Stunde ist sie gegessen, niemand wird sie wieder sehen
- der Satz war die ganze Zeit wahr

Bei der Variante ohne Allergierisiko öffnet die Lehrperson eine Erbsenschote. Botanisch ist das sogar die genauere Wahl: Die Erdnuss ist keine Nuss, sondern eine Hülsenfrucht wie die Erbse. Auch das lässt sich nutzen, denn schon der Name „Erdnuss" enthält eine Annahme, die sich bei näherem Hinsehen als falsch erweist.

Wo lag der Trick?

- „etwas, das noch kein Mensch gesehen hat": wir hören eine *Art* von Ding, die unbekannt ist
- gemeint war *dieses eine* Exemplar
- die verborgene Prämisse lag nicht im Becher, sondern in unserer Lesart des Satzes
- jede Frage, jede Behauptung bringt solche Prämissen mit

2.2 Vom Thema zur Forschungsfrage

Wer eine Arbeit beginnt, hat in der Regel zunächst ein Thema: „Zauberkunst im Unterricht", „Homeoffice", „Social Media und Jugendliche". Ein Thema ist ein Gebiet, keine Aufgabe. Man kann zu ihm unbegrenzt Material sammeln, ohne je fertig zu werden, weil nichts festlegt, wann man genug weiß. Erst die Forschungsfrage schneidet aus dem Gebiet ein Stück heraus, das sich bearbeiten lässt. Booth u. a. (2016) schlagen dafür eine einfache Probe vor: Man solle den Satz „Ich untersuche X, weil ich herausfinden will, Y, damit andere Z verstehen" vollständig ausfüllen können. X ist das Thema, Y die Frage, Z die Antwort auf das „Na und?". Wer bei Y oder Z ins Stocken kommt, hat noch keine Forschungsfrage.

Vier Begriffe, die oft verwechselt werden

Thema	das Gebiet: „Zauberkunst im Physikunterricht"
Erkenntnisinteresse	warum mich das angeht: „Ich möchte wissen, ob Staunen beim Lernen hilft."
Forschungsfrage	was genau geklärt werden soll: „Behalten Schüler:innen der 8. Klasse ein physikalisches Prinzip besser, wenn es mit einem Zaubereffekt eingeführt wird?"
Hypothese	die vermutete, prüfbare Antwort: „Sie behalten es besser." (→ LE 5)

Die Probe nach Booth u. a.

- Ich untersuche **X** …
- weil ich herausfinden will, **Y** …
- damit andere **Z** verstehen.
- wer Y nicht ausfüllen kann, hat erst ein Thema
- wer Z nicht ausfüllen kann, hat noch keine Relevanz (Booth u. a. 2016)

Arbeitsdefinition

Definition 2.1 Eine **Forschungsfrage** legt fest, welcher Sachverhalt bei welchem Gegenstand unter welchen Bedingungen geklärt werden soll, und zwar so genau, dass man angeben kann, welche Daten sie beantworten würden.

- sie bestimmt, wonach man sucht und was man weglassen darf
- sie ist kleiner als das Thema und größer als eine Ja-Nein-Auskunft

Arten von Forschungsfragen

- **beschreibend:** Wie verbreitet ist X? Wie sieht X aus?
- **erklärend:** Warum tritt X auf? Was bewirkt X?
- **vergleichend:** Unterscheiden sich A und B in X?
- **verstehend:** Wie erleben Betroffene X?
- **gestaltend:** Wie muss Y aussehen, damit X erreicht wird?

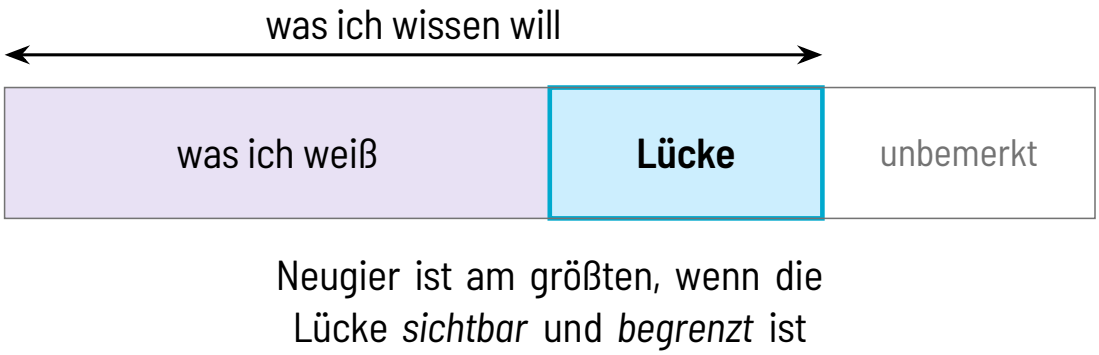
Die Fragetypen legen bereits eine Methodenrichtung nahe (Döring und Bortz 2016a). Beschreibende und vergleichende Fragen führen häufig zu Befragungen oder Beobachtungen mit Zählungen, erklärende Fragen zu Experimenten oder Längsschnittstudien, verstehende zu qualitativen Interviews (→ LE 9). Wer eine Frage formuliert, trifft also schon eine Vorentscheidung über das Design (→ LE 7).

2.3 Neugier als Informationslücke

Warum lohnt sich der Aufwand, aus einer vagen eine scharfe Frage zu machen? Das Buch gibt in Kapitel 4 eine kognitionspsychologische Antwort. George Loewenstein beschreibt Neugier als einen Zustand der Entbehrung, vergleichbar mit Hunger: Sie entsteht, wenn wir eine Lücke zwischen dem bemerken, was wir wissen, und dem, was wir wissen wollen (Loewenstein 1994). Man muss die Lücke allerdings *bemerken*. Wer gar nichts über ein Gebiet weiß, sieht keine Lücke; wer schon alles zu wissen glaubt, auch nicht. Neugier ist dort am stärksten, wo man schon etwas weiß und genau sieht, was fehlt.

Bereits Berlyne (1954) hatte zwischen *spezifischer* und *diversiver* Neugier unterschieden: dem gerichteten Wunsch nach einer bestimmten fehlenden Information und dem diffusen Bedürfnis nach Abwechslung. Ein Zaubertrick erzeugt nach der Überlegung im Buch (Kap. 7d) die erste Form, denn er stellt genau eine Frage: „Wie kann das sein?" Eine gute Forschungsfrage leistet dasselbe auf kontrollierte Weise. Sie macht aus diffusem Interesse eine scharf umrissene Lücke.

Neugier entsteht an der Lücke



Neugier ist am größten, wenn die Lücke *sichtbar* und *begrenzt* ist

- Neugier als Entbehrungszustand, wie Hunger (Loewenstein 1994)

Spezifisch statt diffus

- **diversive Neugier:** „Irgendwas über Social Media wäre interessant."
- **spezifische Neugier:** „Warum scrolle ich abends länger, als ich vorhatte?" (Berlyne 1954)
- eine Forschungsfrage verwandelt die erste in die zweite
- Faustregel: Wer nicht sagen kann, wann er die Antwort hätte, hat die Lücke noch nicht umrissen

Das wohldefinierte Problem

- Einstein fragte nicht „Wie funktioniert das Universum?"
- sondern: Warum beschreibt die Elektrodynamik bewegten Magneten und bewegten Leiter verschieden? (Einstein 1905)
- ein scharfes Problem verkleinert den Suchraum (Epstein 2026)
- „Lass eine Münze verschwinden" ist unlösbar; „unter diesen Bedingungen, für dieses Publikum" wird lösbar

Das Buch greift in Kapitel 7d eine These von Epstein (2026) auf: Wissenschaftliche Durchbrüche entstehen oft nicht aus freier Spekulation, sondern aus der hartnäckigen Arbeit an einem eng gestellten Problem. Das Lehrstück ist der Anfang der Arbeit von 1905, in der Einstein von einer Asymmetrie ausgeht, die „den Phänomenen nicht anzuhaften scheint" (Einstein 1905): Für die Theorie macht es einen Unterschied, ob sich der Magnet oder der Leiter bewegt, für den gemessenen Strom nicht. Ein solches Problem wirkt wie eine Begrenzung, die Energie bündelt. Für Studierende ist das entlastend. Eine kleine, genaue Frage zeugt nicht von fehlendem Ehrgeiz; sie ist die Voraussetzung dafür, überhaupt eine Antwort zu finden.

2.4 Kriterien guter Forschungsfragen

Für die Prüfung einer Forschungsfrage gibt es mehrere Kriterienlisten, die sich stark überschneiden. Das Curriculum nennt vier Grundkriterien: Relevanz, Präzision, Beantwortbarkeit und Originalität. Zwei Merkhilfen aus anderen Fachkulturen sind verbreitet. Das SMART-Schema stammt aus dem Management und beschreibt dort gut formulierte Ziele (Doran 1981); in der Hochschullehre wird es gern auf Forschungsvorhaben übertragen. Die FINER-Kriterien kommen aus der klinischen Forschung (Hulley u. a. 2013) und betonen zusätzlich Durchführbarkeit und Ethik. Keine der Listen ist ein Algorithmus. Es sind Prüffragen, die man an einen Entwurf richtet.

Vier Grundkriterien

- **Relevanz:** Wen interessiert die Antwort, und warum?
- **Präzision:** Sind Gegenstand, Personen, Ort und Zeit festgelegt?
- **Beantwortbarkeit:** Gibt es Daten, die die Frage entscheiden könnten?
- **Originalität:** Ist die Antwort nicht schon bekannt?

SMART auf Forschungsfragen übertragen

S spezifisch	ein Gegenstand, eine Population, ein Kontext
M messbar	es ist klar, welche Größe erhoben wird
A erreichbar	Zugang zu Daten, Personen, Material
R relevant	die Antwort verändert etwas (Wissen, Praxis)
T terminiert	im Semester (oder in der Arbeit) zu schaffen

- ursprünglich ein Schema für Managementziele (Doran 1981)

FINER: die Variante aus der Medizin

- **F**easible: durchführbar (Zeit, Geld, Fallzahl)
- **I**nteresting: für Sie und für andere interessant
- **N**ovel: bestätigt, widerlegt oder erweitert Bekanntes
- **E**thical: vertretbar für alle Beteiligten (→ LE 13)
- **R**elevant: folgenreich für Wissenschaft oder Praxis (Hulley u. a. 2013)

Typische Schwächen

- **zu weit:** „Wie wirkt Digitalisierung auf die Bildung?“
- **zu eng, trivial:** „Wie viele Hörsäle hat der Campus?“
- **normativ:** „Sollte man Handys an Schulen verbieten?“
- **nicht entscheidbar:** „Hat ein Zaubertrick eine Seele?“
- **Antwort eingebaut:** „Warum schadet TikTok der Konzentration?“

Normative Fragen sind nicht unwissenschaftlich, aber sie lassen sich nicht durch Daten allein entscheiden. Man kann sie in empirische Teilfragen zerlegen (Was ändert sich an Schulen nach einem Handyverbot?) und die Bewertung offen ausweisen. Die letzte Schwäche führt zum Staunmoment zurück: Die Frage setzt voraus, was sie eigentlich prüfen müsste.

2.5 Implizite Prämissen

Der Satz über den Becher war wahr, aber er ließ die Zuhörenden eine Voraussetzung ergänzen, die nicht dastand. Dasselbe geschieht in Fragen. Die Sprachphilosophie spricht von *Präsuppositionen*: Annahmen, die eine Äußerung voraussetzt, ohne sie zu behaupten. Die Frage „Warum schadet TikTok der Konzentration?" setzt voraus, dass es einen Schaden gibt; wer sie beantwortet, hat die Voraussetzung schon akzeptiert. In der Rhetorik heißt das die *suggestive* oder *komplexe Frage*.

Wie wenig harmlos solche Voraussetzungen sind, zeigt ein klassisches Experiment. Loftus und Palmer (1974a) ließen Versuchspersonen Filme von Autounfällen sehen und fragten danach, wie schnell die Wagen gefahren seien, als sie „zusammenstießen" (*hit*) oder „ineinanderkrachten" (*smashed*). Das stärkere Verb führte zu höheren Schätzungen, und eine Woche später berichteten mehr Personen von zerbrochenem Glas, das im Film gar nicht vorkam. Die Frage hat die Antwort mitgeformt. Für das wissenschaftliche Arbeiten folgt daraus: Eine Forschungsfrage muss so gebaut sein, dass auch die unerwartete Antwort möglich bleibt.

Was eine Frage voraussetzt

- **Existenz:** „Wie stark wirkt der Mondzyklus auf den Schlaf?" setzt voraus, dass er wirkt
- **Richtung:** „Warum macht Homeoffice produktiver?"
- **Messbarkeit:** „Wie kreativ sind Erstsemester?", als sei Kreativität eine Zahl
- **Gruppe:** „die Studierenden": welche, wo, wann?

Fragen formen Antworten

- Unfallfilm, dann die Frage: Wie schnell waren die Autos, als sie „zusammenstießen" oder „ineinanderkrachten"?
- stärkeres Verb → höhere Schätzungen
- eine Woche später: mehr Erinnerungen an Glassplitter, die es nicht gab (Loftus und Palmer 1974a)
- die Formulierung ist Teil der Messung

Prämissen freilegen: drei Prüffragen

- Was muss wahr sein, damit die Frage überhaupt Sinn ergibt?
- Welche Antwort ist *ausgeschlossen*, so wie die Frage gestellt ist?
- Welches Wort würde jemand anderes anders verstehen?

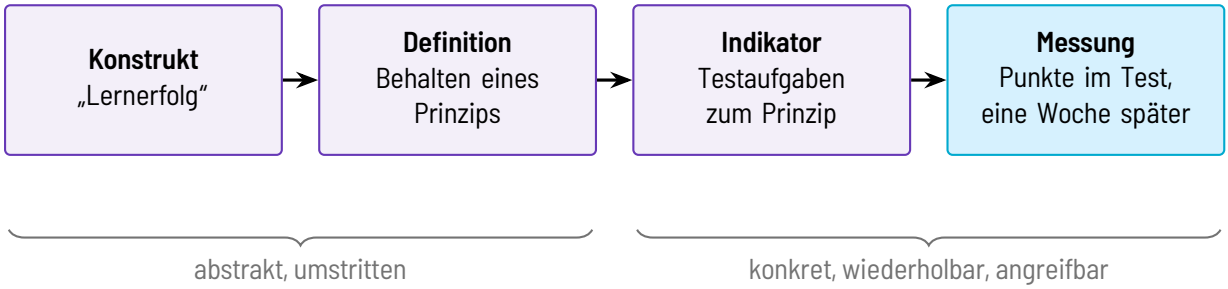
Die dritte Prüffrage ist die Brücke zur Operationalisierung. Im Staunmoment war es das Wort „etwas": Die Gruppe hat es als „eine Art von Ding" gelesen, gemeint war „ein einzelnes Exemplar". In Forschungsfragen sind es Wörter wie „Erfolg", „Stress", „Lernen" oder „besser", die jeder anders füllt.

2.6 Operationalisierung: vom Begriff zur Messung

Viele Forschungsfragen handeln von Dingen, die man nicht direkt sehen kann: Neugier, Lernerfolg, Vertrauen, Staunen. Solche Begriffe heißen in der Methodenlehre *Konstrukte*. Um sie zu untersuchen, braucht man beobachtbare *Indikatoren* und eine genaue *Messvorschrift*. Den Weg vom Konstrukt zur Messung nennt man Operationalisierung (Döring und Bortz 2016a). Der Begriff geht auf den Physiker Percy Bridgman zurück, für den ein Begriff durch die Operationen bestimmt war, mit denen man ihn misst (Bridgman 1927). In dieser strengen Form hat sich die Idee nicht gehalten, denn dann wäre jede neue Messmethode ein neuer Begriff. Die gemäßigte Fassung gehört aber zum Grundbestand jeder empirischen Arbeit: Wer nicht angibt, wie er misst, kann weder zeigen, dass er recht hat, noch dass er unrecht hat.

Operationalisierung ist Verlust und Gewinn zugleich. Ein Test über Fachbegriffe erfasst nicht „das Lernen", nur einen Ausschnitt davon. Dafür kann man ihn wiederholen, vergleichen und anfechten. Die Kunst liegt darin, den Kern der staunenswerten Frage zu bewahren und ihn trotzdem messbar zu machen.

Vom Konstrukt zur Messvorschrift



Was eine Messvorschrift festlegt

Definition 2.2 Operationalisierung heißt, für einen Begriff anzugeben, durch welche beobachtbaren Größen er erfasst wird und nach welcher Regel aus Beobachtungen ein Messwert entsteht.

- *was* beobachtet wird (Indikator)
- *wie* und *wann* (Instrument, Zeitpunkt)
- *wie* daraus ein Wert wird (Auswertungsregel)

Gewinn und Verlust

- gewonnen: Wiederholbarkeit, Vergleichbarkeit, Angreifbarkeit
- verloren: alles am Begriff, was der Indikator nicht erfasst
- darum wo möglich mehrere Indikatoren (→ Triangulation, LE 7)
- Prüffrage: Würde eine Kollegin bei dieser Messung dasselbe unter dem Begriff verstehen?

Die Prüffrage führt auf das Gütekriterium der Validität, das in LE 7 ausführlich behandelt wird. Für heute genügt die Einsicht, dass jede Operationalisierung eine Entscheidung ist, die man begründen und offenlegen muss.

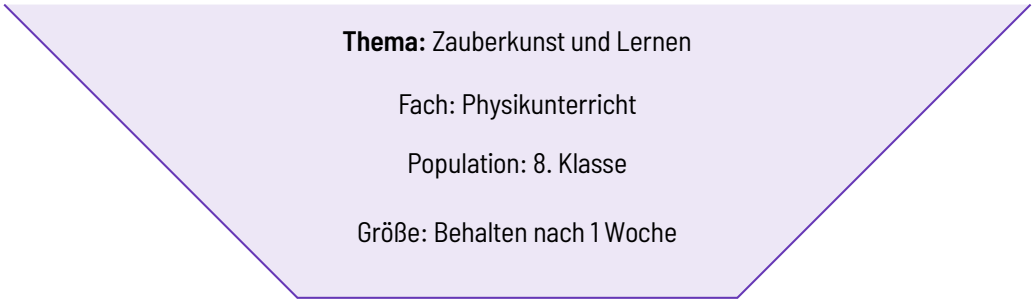
Das geheime Objekt, operationalisiert

- „noch kein Mensch gesehen“: Was zählt als „sehen“? Die Schale? Ein Röntgenbild?
- „etwas“: Exemplar oder Art?
- „nach dieser Stunde“: Wie würde man prüfen, dass niemand es mehr sieht?
- erst mit diesen Festlegungen wird der Satz prüfbar

2.7 Eingrenzen und die Forschungslücke finden

Eine Frage ist erst dann eine Forschungsfrage, wenn ihre Antwort nicht schon vorliegt. Die *Forschungslücke* ist der Teil des Gegenstands, zu dem es noch keine belastbare Antwort gibt: weil eine Gruppe noch nicht untersucht wurde, weil Befunde einander widersprechen, weil eine Methode noch nicht angewandt wurde oder weil ein bekannter Befund noch nie wiederholt wurde. Ob eine Lücke besteht, zeigt erst die Literaturrecherche (→ LE 3). Im Bachelorstudium muss die Lücke nicht groß sein. Eine Replikation unter anderen Bedingungen oder die Übertragung eines bekannten Befunds auf einen neuen Kontext ist eine legitime Lücke.

Der Trichter



Forschungsfrage: Behalten … besser, wenn …?

Woran man eine Forschungslücke erkennt

- Gruppe, Ort oder Zeitraum wurden noch nicht untersucht
- Befunde widersprechen einander
- eine Methode wurde noch nicht angewandt
- ein Befund wurde noch nie wiederholt (Replikation)
- die Belege kommen aus der Recherche, nicht aus dem Bauchgefühl

Staunenswerte und beantwortbare Fragen

staunenswert	beantwortbar
Warum staunen wir?	Stellen Studierende nach einem Zaubereffekt mehr Nachfragen als nach einem gleich langen Experiment ohne Überraschung?
Macht Musik klüger?	Lösen Studierende nach 10 Min. Musik mehr Aufgaben eines Konzentrationstests als nach 10 Min. Stille?
Was ist ein gutes Team?	Welche Merkmale nennen Mitglieder von Projektteams im 4. Semester als förderlich?

- die linke Spalte ist der Motor, die rechte der Plan

Merke

Eine Forschungsfrage ist eine Informationslücke mit Rand: Sie sagt, was man wissen will, welche Voraussetzungen man dabei macht und welche Beobachtung die Frage beantworten würde. Wer die Prämissen seiner Frage nicht kennt, findet am Ende die Antwort, die er hineingelegt hat.

2.8 Übung in der Stunde

Werkstatt: Fragen sezieren (Zweiergruppen, 30 Min.)

- Aufwärmen: zwei Fragen aus der Liste auf dem Übungsblatt Teil A. Welche Prämisse steckt darin?
- Dann Ihre eigene Frage: Was wird als selbstverständlich vorausgesetzt?
- Welche Wörter müssten Sie operationalisieren? Was würden Sie messen?
- Schärfen Sie die Frage nach SMART; Ihr Gegenüber prüft

Sicherung (15 Min.)

- Schreiben Sie Ihre Forschungsfrage auf eine Karteikarte
- Plenum: Ist sie beantwortbar? Was wäre die Datengrundlage?
- Welche Antwort würde Sie überraschen?

Hinweis für Lehrende

In der Werkstatt geht die Lehrperson von Paar zu Paar und stellt immer dieselben drei Fragen: „Was muss wahr sein, damit Ihre Frage Sinn ergibt?", „Welche Antwort würde Sie überraschen?" und „Woran würden Sie die Antwort erkennen?" Häufige Muster bei mitgebrachten Fragen sind normative Fragen („Sollte man …?"), Warum-Fragen mit eingebauter Richtung und Fragen ohne Population. Die Studierenden sollen ihre Frage nicht aufgeben, sondern umbauen. Aus „Warum macht Sport glücklicher?" wird zum Beispiel „Hängt bei Studierenden der RWU die Zahl der Sporteinheiten pro Woche mit der selbstberichteten Lebenszufriedenheit zusammen?" Am Ende der Sicherung darauf hinweisen, dass eine Zusammenhangsfrage noch keine Ursache klärt (Vorgriff auf LE 7). Für die Plenumsrunde drei bis vier Karten auswählen, die typische Schwächen zeigen, und die Verfasser:innen vorher fragen, ob sie einverstanden sind.

2.9 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- Thema, Erkenntnisinteresse, Forschungsfrage und Hypothese unterscheiden
- implizite Prämissen in Fragestellungen erkennen und benennen
- einen Begriff operationalisieren
- eine eigene Forschungsfrage entwickeln und nach SMART prüfen

Bis zur nächsten Woche

- **Forschungsfrage schriftlich:** Formulieren Sie Ihre Frage und begründen Sie in drei Sätzen, warum sie beantwortbar und nicht trivial ist
- **Probe nach Booth:** „Ich untersuche X, weil …, damit …" vollständig ausfüllen
- **Tagebuch des Staunens:** Formulieren Sie Ihr Staunerlebnis dieser Woche als Frage. Welche Prämisse steckt darin?
- Bringen Sie die Frage zu LE 3 mit: Mit ihr starten Sie die Recherche

Handout: Die Forschungsfrage

Worum es heute ging. „Unter diesem Becher liegt etwas, das noch kein Mensch je gesehen hat." Der Satz stimmt: Es ist eine Erdnuss in der Schale. Wir haben ihn aber als Aussage über eine unbekannte *Art* von Ding gelesen. Jede Frage bringt solche stillen Voraussetzungen mit. Eine Forschungsfrage legt sie offen und sagt, welche Beobachtung sie beantworten würde.

Kernbegriffe

Forschungsfrage legt fest, welcher Sachverhalt bei welchem Gegenstand unter welchen Bedingungen geklärt werden soll, so genau, dass man weiß, welche Daten sie beantworten.

Informationslücke Neugier entsteht, wenn man eine begrenzte Lücke zwischen Wissen und Wissenwollen bemerkt (Loewenstein 1994).

Implizite Prämisse Annahme, die eine Frage voraussetzt, ohne sie auszusprechen („Warum schadet X?" setzt einen Schaden voraus).

Operationalisierung Angabe, durch welche beobachtbaren Größen und nach welcher Regel ein Begriff gemessen wird (Döring und Bortz 2016a).

Forschungslücke Teil des Gegenstands, zu dem es noch keine belastbare Antwort gibt; man findet sie durch Recherche.

Vom Thema zur Frage: die Probe nach Booth u. a. (2016)
Ich untersuche *X*, weil ich herausfinden will, *Y*, damit andere *Z* verstehen.

SMART-Prüfung einer Forschungsfrage

Spezifisch	ein Gegenstand, eine Population, ein Kontext
Messbar	klar, welche Größe erhoben wird
Achievable (erreichbar)	Zugang zu Daten, Personen, Material
Relevant	die Antwort verändert Wissen oder Praxis
Terminiert	in der verfügbaren Zeit zu schaffen

Drei Prüffragen gegen versteckte Prämissen: (1) Was muss wahr sein, damit die Frage Sinn ergibt? (2) Welche Antwort schließt die Frage aus? (3) Welches Wort würde jemand anderes anders verstehen?

Merke

Eine Forschungsfrage ist eine Informationslücke mit Rand. Wer die Prämissen seiner Frage nicht kennt, findet am Ende die Antwort, die er hineingelegt hat.

Zum Weiterlesen: Döring und Bortz (2016a), Kapitel zu Forschungsproblem und Operationalisierung; Booth u. a. (2016), Teil I.

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 2**

Übungsblatt A: Fragen sezieren

Name: _____ Datum: _____

Aufgabe 1: Fragen auf den Prüfstand

in der Stunde, Zweiergruppe, 10 Min.

Die folgenden Fragen sind konstruiert. Wählen Sie zwei Fragen. Notieren Sie, was man bereits glauben muss, damit die Frage Sinn ergibt (Prämisse), und formulieren Sie eine Fassung, die auch eine unerwartete Antwort zulässt.

1. Warum lernen Studierende mit Laptop in der Vorlesung weniger als mit Papier und Stift?
2. Wie stark beeinflusst der Vollmond die Zahl der Notaufnahmen?
3. Welche Strategien nutzen erfolgreiche Gründer:innen, um Rückschläge zu verkraften?
4. Ab welchem Alter verlieren Kinder ihre Kreativität?
5. Wie viel Prozent ihres Gehirns nutzen Menschen im Alltag?
6. Warum sind Frauen die besseren Führungskräfte?
7. Wie kann die Hochschule verhindern, dass ChatGPT das eigenständige Denken zerstört?
8. Wie viele Stunden Schlaf braucht ein Mensch, um leistungsfähig zu sein?

Nr.	Prämisse(n)	offenere Fassung

Aufgabe 2: Die eigene Frage sezieren

in der Stunde, Zweiergruppe, 20 Min.

Schreiben Sie Ihre mitgebrachte Frage auf. Ihr Gegenüber stellt Ihnen die Fragen aus der Tabelle; Sie notieren die Antworten. Wer keine eigene Frage hat, wählt ein Ersatzthema: Mensaessen, Pendeln zur Hochschule, Lernen mit Karteikarten, Nebenjobs im Studium.

Meine Frage (Rohfassung):

Was wird vorausgesetzt?	
Welche Wörter sind unscharf?	
Was würde ich messen (Indikator)?	
Bei wem, wo, wann?	
Welche Antwort würde mich überraschen?	

Aufgabe 3: SMART-Check

in der Stunde, Zweiergruppe

Formulieren Sie die Frage neu und kreuzen Sie an, welche Kriterien sie erfüllt: *spezifisch* (ein Gegenstand, eine Population, ein Kontext), *messbar* (klar, welche Größe erhoben wird), *erreichbar* (Zugang zu Daten, Personen, Material), *relevant* (die Antwort verändert Wissen oder Praxis), *terminiert* (in der verfügbaren Zeit zu schaffen).

☐ spezifisch ☐ messbar ☐ erreichbar ☐ relevant ☐ terminiert

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 2**

Übungsblatt B: Die Forschungsfrage festhalten

Name: _____ Datum: _____

Aufgabe 4: Forschungsfrage schriftlich

Hausaufgabe, Abgabe bis LE 3

Formulieren Sie eine wissenschaftliche Forschungsfrage zu Ihrem Semesterthema. Begründen Sie in drei Sätzen, warum diese Frage beantwortbar und nicht trivial ist. Füllen Sie zusätzlich die Probe aus: „Ich untersuche …, weil ich herausfinden will, …, damit andere … verstehen."

Aufgabe 5: Tagebuch des Staunens

Hausaufgabe

Formulieren Sie Ihr Staunerlebnis dieser Woche als Frage und notieren Sie darunter die Prämisse, die in ihr steckt.

Erwartungshorizont

Aufgabe 1, mögliche Prämissen: (1) dass Laptop-Nutzer weniger lernen (Richtung vorausgesetzt) und dass „Lernen" klar gemessen ist; (2) dass es einen Einfluss gibt; (3) dass „erfolgreich" definiert ist und Erfolg mit den Strategien zusammenhängt (Überlebenden-Auswahl: die Gescheiterten fehlen); (4) dass Kinder Kreativität verlieren und dass sie sich als eine Größe messen lässt; (5) setzt einen festen Prozentsatz voraus, die bekannte Zehn-Prozent-Legende; (6) Richtung und Gruppenvergleich vorausgesetzt, „besser" undefiniert; (7) dass das Denken zerstört wird und dass die Hochschule das verhindern kann; (8) dass es eine Zahl für alle Menschen gibt und „leistungsfähig" klar ist. Offenere Fassungen fragen nach *ob* und *wie stark* statt nach *warum*, nennen Population und Messgröße. Aufgabe 2/3: Die Frage muss am Ende Population, Messgröße und Zeitraum enthalten; eine Warum-Frage darf bleiben, wenn die Prämisse vorher geprüft wird. Aufgabe 4: Begründung nennt Datenquelle und zeigt, dass die Antwort nicht offensichtlich ist.

3 Literaturrecherche

Mit einer Forschungsfrage aus LE 2 beginnt die Suche nach dem, was andere dazu schon herausgefunden haben. Die meisten Studierenden kennen dafür ein einziges Werkzeug: das Suchfeld einer Suchmaschine. Diese Einheit ersetzt es durch eine Strategie. Der Staunmoment, der Kruskal Count, lässt die ganze Gruppe von verschiedenen Startpunkten aus auf demselben Wort landen. Das Prinzip dahinter ist mathematisch und darf vollständig erklärt werden. Es liefert ein Bild für zwei Dinge zugleich: Eine gute Suchstrategie führt aus vielen Richtungen zu den zentralen Quellen. Eine einseitige Strategie führt aus vielen Richtungen zur eigenen Vorannahme. Der zweite Teil dieses Bildes verbindet die Einheit mit dem Bestätigungsfehler, den das Buch in Kapitel 5b am Wason-Test entfaltet.

Vorbereitung vor der Stunde: Kruskal Count

Eine Woche vorher

- ☐ Den Text auf dem Übungsblatt Teil A (Aufgabe 1) selbst dreimal mit verschiedenen Startzahlen durchzählen, bis die Regel sicher sitzt. Das Schlusswort für alle Startzahlen von 1 bis 10 ist **„Quelle“** (letztes Wort des Textes). Das Prüfskript `tools/kruskal_check.py` bestätigt das; wer den Text ändert, muss es erneut laufen lassen.
- ☐ Eine **Vorhersage** vorbereiten: „Quelle“ auf eine Karte schreiben, in einen Umschlag stecken, zukleben und mit Datum beschriften. Der Umschlag liegt von Beginn an sichtbar auf dem Pult.
- ☐ **Live-Demo planen:** bei der Hochschulbibliothek klären, welche Datenbanken lizenziert sind (Web of Science, Scopus, Fachdatenbanken) und ob sie im Hörsaal-WLAN ohne VPN erreichbar sind. Eine Beispielfrage festlegen (Vorschlag: „Fördert ein Zaubereffekt im Unterricht das Behalten?“) und die Suche einmal komplett durchspielen.
- ☐ Von der Probesuche Bildschirmfotos der Trefferlisten sichern (Plan B bei Netzproblemen). Trefferzahlen *nicht* auf Folien festschreiben; sie ändern sich laufend und werden in der Stunde live abgelesen.
- ☐ Optional: Fachreferent:in der Bibliothek für 10 Minuten in die Live-Demo einladen.

Handout und Übungsblatt

- ☐ Übungsblatt LE 3 Teil A und Teil B je einmal pro Person plus fünf Reserve kopieren. Teil A enthält nur Aufgabe 1 mit dem Text für den Staunmoment und wird zu Beginn *verdeckt* ausgeteilt. Den Text einseitig und gut lesbar drucken (nicht verkleinern). Teil B (Aufgaben 2–6) wird zusammen mit dem Handout nach der Auflösung ausgeteilt.
- ☐ Handout „Literaturrecherche“ je einmal pro Person; es wird erst nach der Auflösung ausgeteilt, weil es das Prinzip erklärt.
- ☐ Bleistifte bereitlegen; wer mitzählen will, tippt mit dem Stift von Wort zu Wort.

Am Tag selbst

- ☐ Beamer mit Browser und eingeloggtem Bibliothekszugang testen; Literaturverwaltung (Zotero) auf dem Dozierendenrechner geöffnet.
- ☐ Die Folie mit der Zählregel und dem Übungsbeispiel bereithalten; die Regel ist der kritische Punkt.
- ☐ Tafel: links „Wie ist das möglich?“, rechts später „Was heißt das für die Suche?“

Risiken und Plan B. Die häufigste Störung sind Zählfehler, besonders beim ersten Schritt (Wird das Startwort mitgezählt?) und bei Wörtern mit Umlauten. Deshalb die Regel an einem fremden Beispielsatz vorführen. Wer auf einem anderen Wort landet, ist kein Ausfall, sondern ein Datenpunkt: Zwei Personen mit verschiedenen Schlusswörtern zählen gemeinsam nach und finden den Fehler. Die Kopplung ist robust; ein einzelner Zählfehler führt oft wieder in den gemeinsamen Weg zurück. Das Prinzip ist öffentlich und wird vollständig aufgelöst. Fällt das Netz aus, läuft die Live-Demo mit den gesicherten Bildschirmfotos.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Kurzer Rückblick: Welche Frage haben wir letzte Woche geschärft? Danach richtet sich heute die Suche.

5–15 · Staunmoment. Kruskal Count mit der ganzen Gruppe; Vorhersage öffnen; Staunen über die Konvergenz; Erklärungsvermutungen sammeln, dann auflösen. Danach Handout und Übungsblatt Teil B austeilen.

15–45 · Theorie-Input und Live-Demo. Systematische Recherche, Datenbanken, boolesche Operatoren, Schneeball, Literaturverwaltung; Live-Recherche an der Beispielfrage. Einschub: Bestätigungsfehler in der Suche und die Pflicht zur Gegenrecherche (Buch, Kap. 5b).

45–75 · Rechercheprotokoll. Die Studierenden starten die dokumentierte Recherche zur eigenen Frage (Übungsblatt Teil B, Aufgaben 2–4).

75–90 · Sicherung und Transfer. Erste Treffer nach Stufen sortieren (Aufgabe 5); Auftrag zur annotierten Bibliographie als Brücke zu LE 4 (Quellenkritik).

3.1 Staunmoment: Der Zählweg

★ Staunmoment: Kruskal Count

Wählen Sie im Stillen eine Zahl von 1 bis 10. Zählen Sie im Text auf dem Übungsblatt so viele Wörter ab: Das ist Ihr Startwort.

Zählen Sie seine Buchstaben und gehen Sie so viele Wörter weiter. Wieder Buchstaben zählen, wieder weitergehen. Wenn der nächste Sprung über das Textende hinausführt, haben Sie Ihr **Schlusswort**.

Behalten Sie es für sich.

Die Regel an einem Beispiel

- Satz: „Der kleine Hund sprang über den breiten Graben und bellte laut."
- Startzahl 2 → Startwort „kleine" (6 Buchstaben)
- 6 Wörter weiter: Hund, sprang, über, den, breiten, **Graben**
- „Graben" hat 6 Buchstaben, es folgen nur noch 3 Wörter → Schlusswort „Graben"
- Satzzeichen zählen nicht; ä, ö, ü zählen als ein Buchstabe

Das Beispiel stammt nicht aus dem Übungstext, damit niemand vorab etwas über das Schlusswort erfährt. Wichtig ist der erste Sprung: Man zählt ab dem *nächsten* Wort. Nach dem Beispiel zählen alle still. Wer fertig ist, dreht das Blatt um. Nach etwa acht Minuten fragt die Lehrperson, wer ein Schlusswort hat, und lässt eine Person den Umschlag öffnen.

Was ist gerade passiert?

- Wer hat „Quelle" als Schlusswort? Wer nicht?
- Sie haben Ihre Zahl frei gewählt. Wie konnte die Vorhersage stimmen?
- sammeln Sie Erklärungen: Zufall? ein präparierter Text? etwas anderes?
- Wie könnte man die Erklärungen prüfen?

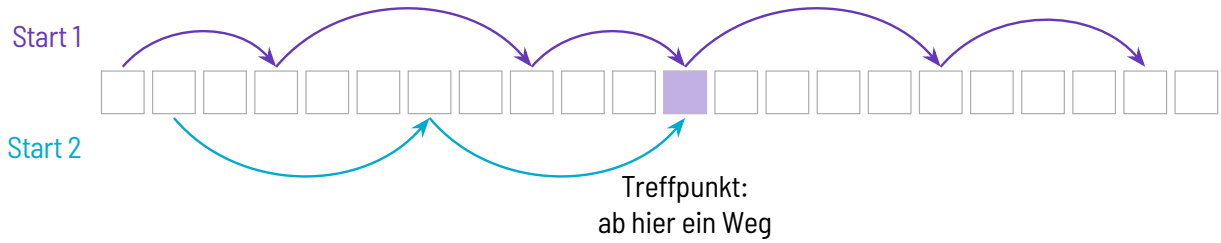
Typische Vermutungen: Der Text sei so gebaut, dass alle Wege konstruiert zusammenlaufen; es gebe nur ein einziges Wort, das man erreichen kann; die Lehrperson habe die Wahl beeinflusst. Die ersten beiden liegen nahe an der Wahrheit, die dritte ist hier falsch, aber eine gute Frage: Im Buch dient der Kruskal Count als Beispiel für eine scheinbar freie Wahl, deren Ergebnis feststeht (Kap. 15b). Prüfbar wird das, wenn zwei Personen mit verschiedenen Startzahlen ihre Wege nebeneinanderlegen und nachsehen, wo sie sich treffen.

3.2 Auflösung: das Kruskal-Prinzip

Der Effekt geht auf den Mathematiker und Physiker Martin Kruskal zurück und wurde durch Martin Gardner bekannt; eine mathematische Analyse geben Lagarias u. a. (2009). Die Erklärung beruht auf einer einfachen Beobachtung: Der Weg durch den Text hängt nur vom aktuellen Wort ab, nicht davon, wie man dorthin gekommen ist. Treffen zwei Wege einmal auf dasselbe Wort, gehen sie von da an denselben Weg bis zum Ende. In der Sprache der Wahrscheinlichkeitstheorie sind das zwei Markov-Ketten, die *koppeln*.

Wie wahrscheinlich ist ein solches Treffen? Deutsche Wörter haben im Mittel einige Buchstaben; jeder Weg trifft also ungefähr jedes vierte bis sechste Wort. Zwei Wege, die nebeneinander herlaufen, haben bei jedem Schritt eine gute Chance, auf dasselbe Wort zu fallen. Über viele Schritte wird es fast sicher, dass sie es irgendwann tun. Im Übungstext laufen alle zehn Startwege nach dem Prüfskript spätestens beim 47. Wort zusammen; die übrigen rund 260 Wörter legen sie gemeinsam zurück. Ein langer Text ist also kein Hindernis für den Effekt, er ist seine Voraussetzung.

Zwei Wege, die sich treffen



- der nächste Schritt hängt nur vom aktuellen Wort ab
- einmal getroffen, immer gemeinsam: Die Wege *koppeln*

Warum fast alle treffen

- jeder Weg berührt etwa jedes vierte bis sechste Wort
- bei jedem Schritt besteht eine Chance, auf ein Wort eines anderen Wegs zu fallen
- über viele Schritte wird das Treffen fast sicher
- im Übungstext: alle zehn Wege treffen sich spätestens bei Wort 47 von 312
- Analyse: Lagarias u. a. (2009)

Was der Trick über Suchen sagt

- **Konvergenz:** Eine gute Strategie führt von vielen Startpunkten zu den zentralen Quellen
- **Kehrseite:** Eine einseitige Strategie führt von vielen Startpunkten zur eigenen Vorannahme
- das Ergebnis kann feststehen, obwohl sich jeder Schritt frei anfühlt
- Prüffrage aus dem Buch: „Ist das gerade ein Kruskal Count?“

Die Prüffrage stammt aus Kapitel 15b des Buchs, das den Trick als gemeinsame Referenzerfahrung für Teams vorschlägt: Wer ihn erlebt hat, kann fragen, ob ein Ergebnis wirklich aus der Sache folgt oder aus der Regel, nach der man sucht. Dass ein Weg sich frei anfühlt, sagt wenig darüber, wohin er führt.

3.3 Systematisch statt zufällig

Eine unsystematische Recherche beginnt mit einem Suchbegriff, folgt dem ersten interessanten Treffer und endet, wenn die Zeit knapp wird oder man genug gefunden zu haben glaubt. Das Ergebnis hängt dann vom Startpunkt, von der Reihenfolge der Trefferliste und von der Laune des Tages ab. Niemand, auch man selbst nicht, kann es später nachvollziehen. Eine systematische Recherche legt dagegen vorher fest, mit welchen Begriffen, in welchen Quellen und nach welchen Kriterien gesucht wird, und protokolliert jeden Schritt (Döring und Bortz 2016a). In ihrer strengsten Form, der systematischen Übersichtsarbeit, wird sogar das Protokoll vorab veröffentlicht und die Auswahl in einem Flussdiagramm offengelegt (Page u. a. 2021). Für eine Seminar- oder Bachelorarbeit genügt eine einfachere Fassung. Der Grundsatz bleibt derselbe: Die Suche muss sich wiederholen lassen.

Zwei Arten zu suchen

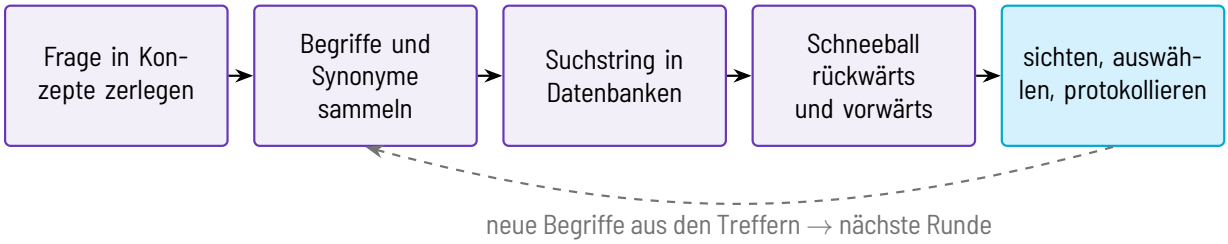
unsystematisch	systematisch
ein Suchbegriff, eine Suchmaschine	Begriffe pro Konzept, mehrere Datenbanken
dem ersten guten Treffer folgen	Ein- und Ausschlusskriterien vorab
aufhören, wenn es reicht	aufhören, wenn nichts Neues mehr kommt
nicht nachvollziehbar	Protokoll: wiederholbar

Arbeitsdefinition

Definition 3.1 Eine **systematische Literaturrecherche** ist eine geplante Suche, bei der Suchbegriffe, Quellen und Auswahlkriterien vorab festgelegt und alle Schritte so dokumentiert werden, dass eine andere Person die Suche wiederholen und zum selben Ergebnis kommen kann.

- *geplant*: Begriffe und Kriterien stehen vor der Suche fest
- *dokumentiert*: Rechercheprotokoll
- *reproduzierbar*: der Prüfstein jeder Recherche

Der Ablauf in fünf Schritten



3.4 Wo man sucht: Kataloge und Datenbanken

Ein Bibliothekskatalog verzeichnet, was eine Bibliothek besitzt, vor allem Bücher und Zeitschriftentitel, aber nicht die einzelnen Aufsätze darin. Für Aufsätze braucht man Datenbanken. Fachübergreifende Zitationsdatenbanken wie Web of Science und Scopus erfassen ausgewählte Zeitschriften mit ihren Literaturlisten und erlauben deshalb auch die Suche nach zitierenden Arbeiten. Fachdatenbanken (PubMed für Medizin, PsycInfo für Psychologie, ERIC und das Fachportal Pädagogik für Bildung, IEEE Xplore und die ACM Digital Library für Technik und Informatik) erschließen ein Fach tiefer, oft mit einem kontrollierten Schlagwortverzeichnis. Google Scholar findet sehr viel, ist aber für eine systematische Suche nur bedingt geeignet: Die Suchsyntax ist eingeschränkt, Trefferlisten lassen sich nicht exakt wiederholen, und es bleibt unklar, was überhaupt erfasst ist. Gusenbauer und Haddaway (2020) haben 28 Suchsysteme verglichen und empfehlen Google Scholar deshalb nur als Ergänzung, nicht als Hauptquelle einer systematischen Suche.

Werkzeuge und wofür sie taugen

Werkzeug	wofür
Bibliothekskatalog, KVK	Bücher, Zeitschriftentitel, Bestand vor Ort
Web of Science, Scopus	fachübergreifend, mit Zitationssuche
PubMed, PsycInfo, ERIC, IEEE Xplore …	Fachdatenbanken mit Schlagwörtern
Google Scholar	breiter Einstieg, Ergänzung, Volltexte finden
BASE, Repositorien	Open Access, graue Literatur

Google Scholar: ja, aber nicht allein

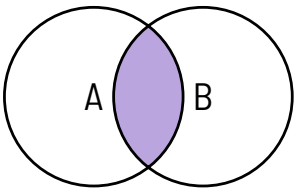
- findet viel, auch Volltexte und graue Literatur
- eingeschränkte Suchsyntax, keine Trunkierung
- Trefferlisten nicht exakt wiederholbar
- unklar, was erfasst ist und was nicht
- Empfehlung: Ergänzung, nicht Hauptquelle (Gusenbauer und Haddaway 2020)

3.5 Suchbegriffe und Suchsprache

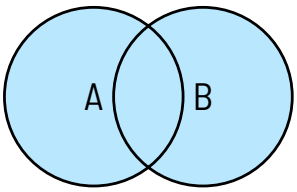
Datenbanken finden nur, was man ihnen sagt. Der erste Schritt ist deshalb, die Forschungsfrage in zwei bis drei Konzepte zu zerlegen und zu jedem Konzept die Begriffe zu sammeln, unter denen Fachleute darüber schreiben: Synonyme, englische Fachbegriffe, Ober- und Unterbegriffe. Viele Fachdatenbanken bieten dafür einen *Thesaurus*, ein kontrolliertes Schlagwortverzeichnis (in PubMed etwa die Medical Subject Headings). Wer nach dem Schlagwort sucht statt nach dem Wort im Titel, findet auch Arbeiten, die andere Formulierungen verwenden.

Die Suchbegriffe verbindet man mit booleschen Operatoren. Innerhalb eines Konzepts stehen die Synonyme mit `OR`, denn jedes genügt; zwischen den Konzepten steht `AND`, denn alle müssen vorkommen. `NOT` schließt aus und ist gefährlich, weil es auch relevante Arbeiten entfernt, in denen der ausgeschlossene Begriff nur am Rand vorkommt. Trunkierung (meist mit `*`) findet verschiedene Wortendungen, Anführungszeichen erzwingen eine feste Wortfolge.

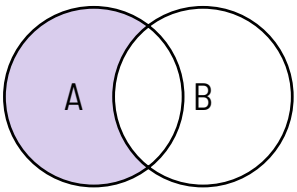
Boolesche Operatoren



`A AND B`
weniger, genauer



`A OR B`
mehr, breiter



`A NOT B`
Vorsicht: verliert Treffer

Werkzeuge der Suchsprache

- **Trunkierung:** `learn*` findet learn, learning, learner
- **Phrase:** `"magic trick"` nur als feste Wortfolge
- **Klammern:** `(magic OR conjuring) AND learn*`
- **Feldsuche:** nur in Titel, Abstract oder Schlagwort
- **Thesaurus:** kontrollierte Schlagwörter der Datenbank
- Syntax unterscheidet sich je Datenbank: Hilfeseite lesen

Live-Demo: eine Beispielfrage

- Frage: Fördert ein Zaubereffekt im Unterricht das Behalten?
- Konzepte: *Zauberkunst* – *Staunen/Neugier* – *Lernen*
- Suchstring:

```
(magic OR conjuring OR "magic trick*")
AND (wonder OR awe OR curiosity OR surprise)
AND (learn* OR memory OR retention)
```

- Was passiert mit der Trefferzahl, wenn wir ein Konzept weglassen?

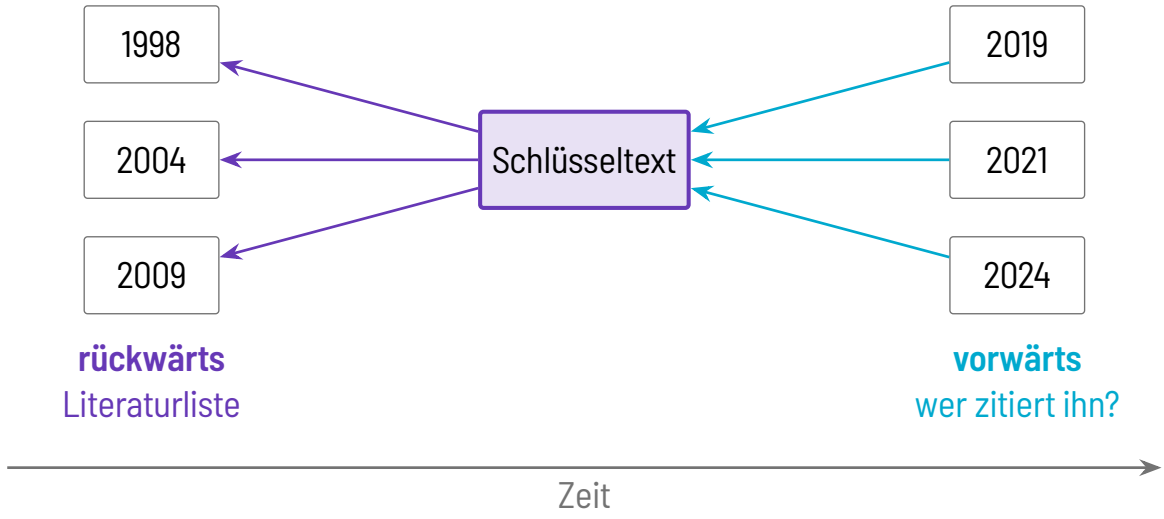
In der Live-Demo wird derselbe String in zwei Datenbanken und in Google Scholar eingegeben. Die Studierenden sollen sehen, dass die Trefferzahlen stark schwanken, dass AND die Menge verkleinert und OR sie vergrößert, und dass ein einziger zusätzlicher Begriff die Liste deutlich verändern kann. Die Zahlen werden live abgelesen und nicht vorab auf Folien geschrieben. Als Startpunkt für die Schneeballsuche eignen sich die Arbeiten, die das Buch selbst zitiert, etwa zur Neugier (Loewenstein 1994) oder zur Wahrnehmungspsychologie der Zauberkunst. Ein guter Moment für die Gegenfrage: Mit welchen Begriffen fänden wir Arbeiten, die *keinen* Lerneffekt zeigen?

3.6 Schneeball und Zitationsnetzwerke

Die Schlagwortsuche hat eine natürliche Grenze: Sie findet nur Arbeiten, deren Wortwahl man vorausgeahnt hat. Ein zweiter Weg führt über die Literaturlisten. Bei der *Rückwärtssuche* liest man die Literaturliste eines Schlüsseltexts und prüft die dort zitierten Arbeiten. Bei der *Vorwärtssuche* fragt man, welche späteren Arbeiten den Schlüsseltext zitieren. Die Vorwärtssuche wurde erst durch Zitationsindizes möglich, die Eugene Garfield in den 1950er-Jahren vorschlug (Garfield 1955) und auf die Web of Science zurückgeht. Wohlin (2014) hat daraus ein geregeltes Verfahren gemacht: Man beginnt mit einer kleinen Startmenge, sucht in Runden rückwärts und vorwärts und hört auf, wenn keine neuen relevanten Arbeiten mehr auftauchen.

Hier wird der Kruskal Count zum genauen Bild. Wer von verschiedenen Schlüsseltexten aus den Literaturlisten folgt, landet nach wenigen Schritten bei denselben häufig zitierten Arbeiten. Das ist nützlich, denn so findet man die Klassiker eines Gebiets. Es hat aber denselben Haken wie der Trick: Die Konvergenz sagt etwas über das Netz, nicht über die Wahrheit. Häufig zitiert wird auch, was in einer Gemeinschaft gern gelesen wird.

Rückwärts und vorwärts



Schneeball als Verfahren

- Startmenge: zwei bis fünf sicher relevante Texte
- Runde für Runde: rückwärts und vorwärts
- Einschlusskriterien wie bei der Schlagwortsuche
- Stopp, wenn keine neuen relevanten Treffer kommen (Wohlin 2014)
- Vorwärtssuche: Web of Science, Scopus, Google Scholar („Zitiert von“)

Konvergenz im Netz

- verschiedene Startpunkte führen zu denselben Klassikern
- gut: so findet man den Kern eines Gebiets

- aber: häufig zitiert heißt nicht richtig
- Zitiergemeinschaften können eine Lücke um sich herum haben
- darum Schneeball *und* Schlagwortsuche kombinieren

3.7 Graue Literatur

Als *graue Literatur* bezeichnet man Texte, die nicht über Verlage und begutachtete Zeitschriften erscheinen: Abschlussarbeiten, Preprints, Berichte von Behörden, Stiftungen und Verbänden, Konferenzfolien, Daten- und Projektberichte. Sie ist für eine Recherche aus zwei Gründen wichtig. Sie ist oft aktueller als begutachtete Literatur, und sie enthält häufiger Ergebnisse, die keine Zeitschrift drucken wollte, etwa Studien ohne signifikanten Effekt. Wer sie ganz weglässt, sieht ein zu günstiges Bild des Forschungsstands (→ Publikationsbias, LE 10). Ihr Nachteil ist die fehlende Begutachtung: Ihre Qualität muss man selbst prüfen. Damit beschäftigt sich LE 4.

Graue Literatur: Chancen und Grenzen

- Abschlussarbeiten, Preprints, Berichte, Konferenzbeiträge
- **Chance:** aktuell, enthält auch Nullbefunde
- **Grenze:** keine Begutachtung, oft schwer zu finden
- Fundorte: BASE, Repositorien, Preprint-Server, Websites von Institutionen
- Qualität selbst prüfen (→ LE 4)

3.8 Dokumentieren, verwalten, annotieren

Das Rechercheprotokoll ist das Laborbuch der Literaturarbeit. Es hält für jeden Suchvorgang Datum, Datenbank, genauen Suchstring, gesetzte Filter, Trefferzahl und die Zahl der gesichteten und ausgewählten Arbeiten fest, dazu die Ein- und Ausschlusskriterien. Die PRISMA-Leitlinie verlangt für systematische Übersichtsarbeiten zusätzlich ein Flussdiagramm, das zeigt, wie aus vielen Treffern wenige eingeschlossene Arbeiten wurden (Page u. a. 2021). Für Seminararbeiten ist das ein gutes Vorbild, auch wenn man es nicht vollständig übernimmt.

Für die gefundenen Quellen braucht man ein Literaturverwaltungsprogramm. Zotero und JabRef sind frei verfügbar, Citavi ist an vielen Hochschulen lizenziert. Sie speichern die bibliographischen Angaben, PDFs und Notizen und erzeugen Literaturverzeichnisse in jedem Zitierstil. Die annotierte Bibliographie geht einen Schritt weiter: Zu jeder Quelle steht ein kurzer Kommentar zu Kernaussage, Methode und Relevanz. Das Begleitbuch dieser Vorlesung ist selbst so gebaut. Sein Literaturverzeichnis druckt zu jeder Quelle ein Abstract, und das Skript übernimmt diese Form.

Das Rechercheprotokoll

Datum	Datenbank	Suchstring	Filter	Treffer	gewählt
…	Scopus	`(magic OR …) AND …`	ab 2000	…	…
…	PsycInfo	…	Englisch	…	…

- Prüfstein: Könnte jemand anderes die Suche wiederholen?
- Ein- und Ausschlusskriterien vorab festlegen
- Vorbild für große Arbeiten: PRISMA-Flussdiagramm (Page u. a. 2021)

Literaturverwaltung

- **Zotero**, **JabRef**: frei; **Citavi**: oft Hochschullizenz
- Angaben per Browser-Plugin oder DOI übernehmen, nie abtippen

- PDFs, Notizen und Schlagwörter an der Quelle ablegen
- Export nach BibTeX/biblatex oder Word
- ab der ersten Quelle verwenden, nicht erst beim Schreiben

Annotierte Bibliographie

- je Quelle zwei bis drei Sätze
- **Kernaussage:** Was wird behauptet oder gefunden?
- **Methode:** Wie wurde das gezeigt?
- **Relevanz:** Was bedeutet das für meine Frage?
- Vorbild: das Literaturverzeichnis des Begleitbuchs, mit Abstract zu jeder Quelle

3.9 Die Kehrseite: suchen, was man schon glaubt

Der Kruskal Count hat gezeigt, dass eine feste Regel aus vielen Startpunkten zum selben Ziel führt. Bei der Recherche ist die Regel oft die eigene Erwartung. Wer überzeugt ist, dass Zauberkunst das Lernen fördert, sucht nach `magic AND learning AND benefit`, liest die passenden Treffer zuerst und folgt deren Literaturlisten. So entsteht ein Netz von Bestätigungen, das sich wie Forschungsstand anfühlt.

Das Buch beschreibt in Kapitel 5b den psychologischen Kern dieses Musters am 2-4-6-Test von Wason (1960). Die Versuchspersonen sollten eine Regel hinter dem Tripel 2–4–6 erraten und durften dazu eigene Tripel testen. Die Regel war weit gefasst (drei aufsteigende Zahlen), doch die meisten legten sich auf eine engere Vermutung fest und prüften nur noch Tripel, die zu ihr passten. Nur sechs von 29 Personen fanden die Regel ohne falschen Zwischenschluss. Jonathan Baron nennt die Neigung, nur die eigene Hypothese direkt zu prüfen, den *Congruence Bias* und formuliert als Gegenmittel: an Alternativhypothesen denken und den Test wählen, der zwischen ihnen unterscheidet (Baron u. a. 1988; Baron 2008). Klayman und Ha (1987) haben gezeigt, dass diese positive Teststrategie in vielen Situationen vernünftig ist und erst dann in die Irre führt, wenn die Wahrheit breiter ist als die eigene Vermutung. Dass derselbe Mechanismus in Wissenschaft, Medizin und Justiz allgegenwärtig ist, dokumentiert Nickerson (1998). Für die Recherche folgt daraus eine Pflicht: Man sucht gezielt auch nach Arbeiten, die der eigenen These widersprechen könnten.

Der 2-4-6-Test

- Aufgabe: die Regel hinter 2–4–6 finden, eigene Tripel testen
- Regel: drei aufsteigende Zahlen
- die meisten testen nur Tripel, die zu *ihrer* Vermutung passen (8–10–12, 20–22–24 …)
- nur sechs von 29 fanden die Regel ohne falschen Zwischenschluss (Wason 1960)

Congruence Bias in der Recherche

- Suchbegriffe enthalten schon die erwartete Antwort
- passende Treffer werden zuerst gelesen
- Schneeball folgt den Literaturlisten der Bestätigungen
- Ergebnis: ein Netz, das sich wie Forschungsstand anfühlt
- Gegenmittel: Alternativen denken, unterscheidende Suche wählen (Baron 2008)

Gegenrecherche: so geht's

- die Gegenhypothese als eigenes Konzept suchen
- Begriffe für Nullbefunde und Kritik:
  `"no effect"`, `"null result*"`,
  `replicat*`, `critique`

- in der Vorwärtssuche gezielt kritische Repliken lesen
- im Protokoll festhalten, was die Gegenrecherche ergab

Merke

Eine Recherche ist erst dann wissenschaftlich, wenn jemand anderes sie mit Ihrem Protokoll wiederholen könnte und wenn Sie auch nach dem gesucht haben, was Ihnen widerspricht. Dass viele Wege zur selben Quelle führen, spricht für eine gute Suche, beweist aber noch nicht, dass die Quelle recht hat.

3.10 Übung in der Stunde

Rechercheprotokoll starten (30 Min.)

- Zerlegen Sie Ihre Forschungsfrage in Konzepte, sammeln Sie Begriffe (Aufgabe 2)
- Bauen Sie einen Suchstring und einen Gegen-Suchstring (Aufgabe 3)
- Suchen Sie in zwei Datenbanken, protokollieren Sie jede Suche (Aufgabe 4)
- Wählen Sie einen Schlüsseltext für die Schneeballsuche

Sicherung: Treffer sortieren (15 Min.)

- Ordnen Sie Ihre ersten fünf Treffer den Stufen A–E zu (Aufgabe 5)
- Welche Stufe dominiert? Woran liegt das?
- Hat die Gegenrecherche etwas Neues gebracht?

Hinweis für Lehrende

In der Protokollphase sind die häufigsten Fehler: nur Google Scholar, nur deutsche Begriffe, `AND` zwischen Synonymen, Suchstrings ohne Klammern und ein Protokoll, in dem der genaue String fehlt. Die Lehrperson geht herum und bittet einzelne Studierende, ihre Suche nach dem Protokoll eines Nachbarn zu wiederholen: Kommt dieselbe Trefferzahl heraus? Für die Sortierung gilt: Die Stufen A–E sind eine grobe Vorsortierung nach Publikationstyp. Ein begutachteter Artikel kann schwach sein und ein Behördenbericht stark. Diese Unterscheidung ist Gegenstand von LE 4 und sollte hier nur angekündigt werden. Hat jemand nach 30 Minuten keine passenden Treffer, ist die Frage oft zu eng oder zu ungewöhnlich formuliert; dann ein Konzept weglassen oder einen Oberbegriff wählen.

3.11 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- das Kruskal-Prinzip erklären und auf Suchstrategien übertragen
- eine systematische Recherche planen und dokumentieren
- Suchstrings mit booleschen Operatoren und Trunkierung bauen
- die wichtigsten Datenbanken Ihres Fachs nennen
- Treffer nach Relevanz und Publikationstyp vorsortieren
- eine Gegenrecherche durchführen

Bis zur nächsten Woche

- **Rechercheprotokoll** vervollständigen: Suchbegriffe, Datenbanken, Treffermengen, Auswahlkriterien (10 % der Portfolionote)
- **Annotierte Bibliographie:** fünf Quellen mit je zwei bis drei Sätzen zu Kernaussage, Methode und Relevanz; mindestens eine aus der Gegenrecherche
- **Tagebuch des Staunens:** Welcher Fund hat Sie bei der Recherche überrascht?
- die fünf Quellen zu LE 4 mitbringen: Wir prüfen ihre Qualität

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 3**

Handout: Literaturrecherche

Worum es heute ging. Alle haben eine eigene Startzahl gewählt und sind nach derselben Zählregel durch einen Text gegangen, fast alle landeten auf demselben Wort. Das ist Mathematik: Sobald zwei Wege einmal auf dasselbe Wort treffen, laufen sie für immer gemeinsam weiter (Kruskal-Prinzip). Eine systematische Recherche funktioniert ähnlich: Mit guten Suchbegriffen und dem Weg über Literaturlisten landet man aus verschiedenen Richtungen bei den zentralen Quellen. Die Kehrseite: Wer nur nach Bestätigung sucht, landet zuverlässig bei der eigenen Vorannahme.

Kernbegriffe

Systematische Recherche geplante, dokumentierte und wiederholbare Suche mit festgelegten Begriffen, Datenbanken und Auswahlkriterien.

Boolesche Operatoren `AND` (beide Begriffe), `OR` (einer genügt, für Synonyme), `NOT` (ausschließen, sparsam!).

Trunkierung und Phrase `lern*` findet lernen, Lernende, Lernerfolg; `"magic trick"` sucht die genaue Wortfolge.

Schneeballsuche rückwärts: Literaturliste eines Schlüsseltexts; vorwärts: Arbeiten, die ihn später zitieren (Wohlin 2014).

Graue Literatur nicht verlagsmäßig publiziert: Abschlussarbeiten, Preprints, Berichte. Oft aktuell, aber ohne Begutachtung.

Gegenrecherche gezielte Suche nach Belegen, die der eigenen These widersprechen könnten (Congruence Bias, Wason (1960)).

Suchstring in drei Schritten

Konzept 1	Konzept 2	Konzept 3
`magic OR conjuring`	`wonder OR awe OR curiosity`	`learn* OR memory`

`(K1) AND (K2) AND (K3)`: Synonyme mit OR, Konzepte mit AND

Merke

Eine Recherche ist erst dann wissenschaftlich, wenn jemand anderes sie mit Ihrem Protokoll wiederholen könnte und wenn Sie auch nach dem gesucht haben, was Ihnen widerspricht.

Zum Weiterlesen: Döring und Bortz (2016a), Kapitel zur Literaturrecherche; Gusenbauer und Haddaway (2020) zur Frage, welche Suchsysteme sich für systematische Recherchen eignen.

Übungsblatt A: Der Zählweg

Name: _____ Datum: _____

Aufgabe 1: Der Zählweg

in der Stunde, Einzelarbeit, 8 Min.

Wählen Sie im Stillen eine Zahl zwischen 1 und 10. Zählen Sie vom Anfang des Textes so viele Wörter ab; das ist Ihr Startwort. Zählen Sie seine Buchstaben und gehen Sie genau so viele Wörter weiter. Wiederholen Sie das. Satzzeichen zählen nicht, ä, ö, ü zählen als ein Buchstabe. Wenn der nächste Sprung über das Textende hinausführen würde, ist Ihr aktuelles Wort Ihr **Schlusswort**. Behalten Sie es für sich. *(Text selbst verfasst, fiktive Geschichte.)*

Als Hanna Berger zum ersten Mal die alte Bibliothek ihrer Stadt betrat, suchte sie nur ein einziges Buch. Ihre Tante hatte ihr erzählt, dass dort ein Bericht über den Winter stehe, in dem der See vollständig zugefroren war und die Menschen trocken bis zur anderen Seite gehen konnten. Hanna wollte wissen, ob diese Geschichte stimmte. Sie fragte den Bibliothekar, einen ruhigen Mann mit grauem Bart, wo sie anfangen solle. Er lächelte und gab ihr keinen Titel, sondern einen Rat: „Fang irgendwo an, aber schreib auf, wohin dich jedes Buch schickt." Also begann sie bei einer Chronik der Fischerei. Darin fand sie einen Hinweis auf alte Kirchenbücher, die jede Taufe und jede Beerdigung festhielten. In den Kirchenbüchern stand am Rand eine Notiz über ungewöhnliche Kälte, mit einem Verweis auf die Wetterbeobachtungen eines Lehrers. Der Lehrer hatte jeden Morgen die Temperatur gemessen und in kleine Hefte geschrieben. Diese Hefte lagen im Keller, in einer Kiste mit der Aufschrift „Verschiedenes". Hanna arbeitete drei Wochen lang an einem langen Tisch unter einem hohen Fenster. Sie las, verglich und notierte, und manchmal fand sie Angaben, die einander widersprachen. Ein Kaufmann schrieb, das Eis sei dünn gewesen, ein Pfarrer meinte, man habe darauf getanzt. Hanna lernte, dass jeder Zeuge seine eigenen Gründe hatte, etwas zu behaupten. Sie ordnete die Berichte nach Datum, nach Herkunft und nach der Frage, wer was gesehen haben konnte. Am Ende führten fast alle Spuren, gleich wo sie begonnen hatte, zu demselben Ort. Es war ein dünnes Heft des Lehrers, in dem für einen Februar viele Nächte mit strengem Frost standen und daneben ein Satz in sauberer Schrift: „Heute ging ich mit meinen Schülern über das Eis bis zum anderen Ufer." Hanna legte den Stift hin. Sie wusste jetzt, dass die Erzählung ihrer Tante einen wahren Kern hatte, und sie wusste noch etwas anderes: Wer lange und gründlich sucht, landet oft bei derselben Quelle.

Meine Startzahl: _____ Mein Schlusswort: _____ Zahl der Sprünge: _____

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 3**

Übungsblatt B: Recherchieren und dokumentieren

Name: _____ Datum: _____

Aufgabe 2: Suchbegriffe sammeln

in der Stunde, Einzelarbeit, 10 Min.

Zerlegen Sie Ihre Forschungsfrage aus LE 2 in zwei bis drei Konzepte. Sammeln Sie zu jedem deutsche und englische Begriffe, Synonyme, Ober- und Unterbegriffe. Markieren Sie, wo Trunkierung (`*`) sinnvoll ist: `learn*` findet *learn*, *learning*, *learner*.

Meine Forschungsfrage:

	Konzept 1	**Konzept 2**	**Konzept 3**
Begriff deutsch			
Synonyme			
englisch			
Ober-/Unterbegriffe			

Aufgabe 3: Suchstring und Gegenrecherche

in der Stunde, 5 Min.

1. Bauen Sie aus der Tabelle einen Suchstring: Synonyme mit `OR`, Konzepte mit `AND`.
2. Formulieren Sie einen zweiten Suchstring, der gezielt Arbeiten findet, die Ihrer erwarteten Antwort *widersprechen* könnten (Begriffe wie `no effect`, `null result`, `failed replication`, `critique`, oder die Gegenhypothese selbst).

Suchstring 1:

Suchstring 2 (Gegenrecherche):

Aufgabe 4: Rechercheprotokoll

in der Stunde beginnen, Hausaufgabe, 10 % der Portfolionote

Führen Sie eine dokumentierte Recherche in mindestens zwei Datenbanken durch. Eine Zeile pro Suchvorgang. Notieren Sie Suchbegriffe, Datenbanken, Treffermengen und Auswahlkriterien so genau, dass eine andere Person Ihre Suche wiederholen kann.

Datum	Datenbank	Suchstring	Filter	Treffer	gesich-tet	ausge-wählt

Ein- und Ausschlusskriterien (z. B. Sprache, Zeitraum, Publikationstyp, Population):

Schneeball: Welche zwei Schlüsseltexte haben Sie rückwärts und vorwärts verfolgt? Was kam dabei neu hinzu?

Aufgabe 5: Treffer sortieren

in der Stunde, 10 Min.

Ordnen Sie Ihre ersten fünf Treffer einer Stufe zu. Die Stufen sind eine Arbeitshilfe für die erste Sichtung, kein Qualitätsurteil im Einzelfall; das folgt in LE 4.

Stufe	Publikationstyp
A	systematische Übersichtsarbeit, Metaanalyse, begutachteter Zeitschriftenartikel
B	Fachbuch, Handbuchkapitel, begutachteter Konferenzbeitrag
C	graue Literatur: Preprint, Abschlussarbeit, Bericht einer Behörde oder Stiftung
D	Fachpresse, Wissenschaftsjournalismus, Lehrbuchwissen ohne Belege
E	Blog, Video, Werbung, Quelle ohne erkennbare Autorschaft

Aufgabe 6: Annotierte Bibliographie

Hausaufgabe, Abgabe bis LE 4

Kommentieren Sie fünf gefundene Quellen mit je zwei bis drei Sätzen zu *Kernaussage*, *Methode* und *Relevanz für Ihre Frage*. Mindestens eine Quelle soll aus der Gegenrecherche stammen. Verwalten Sie die Quellen in einem Literaturverwaltungsprogramm (Zotero, Citavi oder JabRef).

Beispiel einer Annotation:

Nickerson, R. S. (1998). Confirmation bias: A ubiquitous phenomenon in many guises. *Review of General Psychology, 2*(2), 175–220. https://doi.org/10.1037/1089-2680.2.2.175

Kernaussage: Menschen suchen, deuten und erinnern bevorzugt Informationen, die eine bestehende Überzeugung stützen; der Effekt zeigt sich in Wissenschaft, Medizin, Justiz, Politik und Alltag. *Methode:* Übersichtsarbeit über experimentelle und historische Befunde, keine eigene Datenerhebung. *Relevanz:* Begründet, warum meine Recherche auch nach widersprechenden Befunden suchen muss.

Erwartungshorizont

Aufgabe 1: Schlusswort ist **„Quelle“** (letztes Wort des Textes) für jede Startzahl von 1 bis 10; nach dem Prüfskript `tools/kruskal_check.py` laufen alle zehn Wege spätestens beim 47. Wort („gehen“) zusammen, insgesamt sind es je nach Start 59 bis 66 Sprünge. Wer woanders landet, hat sich verzählt; das gemeinsame Nachzählen ist eine kleine Lektion in Reproduzierbarkeit. Aufgabe 2/3: mindestens zwei Konzepte, englische Begriffe vorhanden, Synonyme mit OR innerhalb der Klammer, AND zwischen Konzepten; Gegenrecherche enthält die Gegenhypothese oder Begriffe für Nullbefunde und Kritik. Aufgabe 4: Protokoll ist wiederholbar, wenn Datum, Datenbank, exakter String, Filter und Trefferzahl dastehen; mindestens zwei Datenbanken, davon eine Fachdatenbank, Google Scholar allenfalls ergänzend. Aufgabe 6: Annotationen trennen Kernaussage, Methode und Relevanz; keine bloße Wiedergabe des Abstracts.

4 Quellenkritik

In der dritten Einheit haben die Studierenden Literatur gefunden. Jetzt müssen sie entscheiden, welcher sie trauen. Die Einheit beginnt mit einer Erfahrung, die unangenehm ist und gerade deshalb hängen bleibt: Das eigene Gehirn findet in reinem Zufall Muster, und es hält einen gut gestalteten Text für glaubwürdiger als einen schlecht gesetzten, ohne den Inhalt geprüft zu haben. Quellenkritik ist die Methode, die gegen beides hilft. Sie wird hier als angewandte Skepsis gegen die eigene Mustererkennung eingeführt: Kriterien und Qualitätsstufen wissenschaftlicher Literatur, die Grenzen von Plausibilitätsurteilen und Zitationsmetriken, und als Werkzeug für den Alltag das laterale Lesen nach dem SIFT-Schema.

Vorbereitung vor der Stunde: Punktwolken und zwei Artikel

Eine Woche vorher

- ☐ Die Punktwolken liegen als Folien vor (sie werden beim Übersetzen aus festen Zufallszahlen erzeugt und sehen jedes Mal gleich aus). Die Folien einmal durchklicken und die Lösung (Lehrhinweis nach dem Staunmoment) nicht auf den Beamer legen.
- ☐ **Die „schöne Fälschung" selbst bauen.** Ein fiktiver Nachrichtenartikel zu einem *harmlosen* Thema (Beispiel: „Wer morgens zehn Minuten jongliert, merkt sich Vokabeln besser"). Er soll alle Merkmale tragen, die Glaubwürdigkeit *erzeugen*, ohne sie zu belegen: saubere Typographie, Foto, Diagramm, ein Experte mit Titel, eine präzise Zahl („um 23,7 %"), der Satz „wie eine neue Studie zeigt" ohne nachprüfbaren Verweis. Keine Logos, Namen oder Domains realer Medien und keine realen Personen verwenden. In der Fußzeile klein, aber lesbar: „Fiktives Lehrmaterial, LE 4".
- ☐ **Das „hässliche Original" auswählen.** Ein echter, begutachteter Fachartikel mit unattraktivem Layout: eingescannte Schreibmaschinenseiten, zweispaltiger Satz ohne Abbildungen, lange Tabellen. Kriterien: frei zugänglich, Befund seither nicht zurückgezogen, Thema für Erstsemester verständlich, Abstract auf einer Folie lesbar. Gut geeignet sind ältere psychologische Klassiker, die im Begleitbuch ausgewertet werden, etwa Forer (1949) oder Wason (1960); die Rechte für die Projektion im Hörsaal vorher klären.
- ☐ Beide Artikel als Bildschirmfoto auf je eine Folie legen, gleich groß, ohne Quellenangabe. Die Quellenangabe des echten Artikels liegt auf einer dritten Folie für die Auflösung.
- ☐ **Drei Quellen für die SIFT-Übung prüfen.** Ein Vorschlag steht auf Übungsblatt C (deutsch: SPIEGEL, englisch: Guardian; die Studie von White u. a. (2019) zu 120 Minuten Natur pro Woche), mit Erwartungshorizont. Vor der Stunde alle Links aufrufen; wer eigene Quellen wählt, braucht eine Peer-Review-Studie, einen Zeitungsartikel, der über eine Studie berichtet, und einen Wikipedia-Eintrag. Am ergiebigsten ist eine *Kette*: Zeitungsartikel und Wikipedia-Eintrag berufen sich auf dieselbe Studie, sodass die Gruppe in Schritt T die Behauptung bis zum Original verfolgen kann. Bei der Auswahl darauf achten, dass der Zeitungsartikel die Studie zuspitzt (eine Zahl, die im Original vorsichtiger formuliert ist), und den Wikipedia-Eintrag als Versionslink („Permanenter Link") ausgeben, damit alle Gruppen dieselbe Fassung prüfen.

Handout und Übungsblatt

- ☐ Handout „Quellenkritik" sowie Übungsblatt LE 4 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 4). Teil A (SIFT-Raster) liegt zu Beginn aus; Teil B enthält eine fiktive Meldung nach dem Muster der schönen Fälschung und wird erst nach der Auflösung ausgeteilt.
- ☐ Übungsblatt C (die drei SIFT-Quellen mit QR-Codes) je Person kopieren und auf das Lernportal legen; zusätzlich je Kleingruppe einen Ausdruck der drei Quellen (Bibliothekszugang für die Studie prüfen).
- ☐ Für die Sicherung ein A3-Blatt oder eine Tafelhälfte mit der Überschrift „Quellenkritik in fünf Schritten".

Am Tag selbst

- ☐ WLAN prüfen: Die SIFT-Übung braucht in jeder Gruppe mindestens ein Gerät mit Internetzugang.
- ☐ Tafel teilen: links „Muster, die wir gesehen haben", rechts „Woran wir Glaubwürdigkeit festgemacht haben".
- ☐ Zwei Studierende vorab bitten, im Blitzlicht je eine annotierte Quelle aus LE 3 vorzustellen.

Optionale Erweiterung: „Das letzte Abendmahl". Wer das Kunststück aus dem Begleitbuch beherrscht, kann es direkt an die Punktwolken anschließen; die drei Folien dazu (Kartenspiel, Abendmahl, Mona Lisa) stehen dort (*WuZ-Buch*, Anhang K; Kunststück nach Master Payne (o. D.)). Ein gefaltetes Blatt zeigt nacheinander mehrere Bilder, zuletzt Leonardos Abendmahl und die Mona Lisa mit der gewählten Karte. Die augenzwinkernde „Symbolanalyse" des Gemäldes ist eine Miniatur über Apophänie, motiviertes Sehen und Verschwörungsdenken und überträgt die Pointe der Punktwolken vom Rauschen auf Bilder und Geschichten. Methode und Einstudierung nach der Vorlage im Begleitbuch; hier bewusst nicht beschrieben.

Risiken und Plan B. Manche Studierende ahnen bei den Punktwolken die Pointe und sagen „das ist Zufall". Das ist willkommen: Dann die Frage verschärfen („Welche der drei ist *am wenigsten* zufällig?") und die zweite Folie zeigen; dort irren erfahrungsgemäß auch die Vorsichtigen. Wenn beim Artikelvergleich die Mehrheit sofort das Original wählt, nachfragen, *woran* sie es erkannt hat. Meist sind es wieder Oberflächenmerkmale („wirkt zu glatt"),

also ebenfalls eine Heuristik und keine Prüfung. Die fiktive Fälschung nach der Stunde nicht digital weitergeben.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Zwei annotierte Quellen aus LE 3 werden vorgestellt: „Woran habe ich Qualität festgemacht?" Antworten an die rechte Tafelhälfte.

5–20 · Staunmoment. Punktwolken: „Welche Muster sehen Sie?", dann „Welche ist Zufall?" Danach der Vergleich „schöne Fälschung" und „hässliches Original" mit Handabstimmung. Auflösung beider Teile; Staunen über die eigene Fehlleistung. Danach Übungsblatt Teil B austeilen: Aufgabe 2 (Anatomie der schönen Fälschung, 10 Min.; geht von der Zeit des Theorie-Inputs ab).

20–50 · Theorie-Input. Kriterien und Qualitätsstufen der Quellenkritik; Apophänie und Bestätigungsfehler; Plausibilitätsheuristiken und ihre Grenzen; Metriken; laterale Recherche und Prebunking.

50–80 · Anwendung (SIFT). Kleingruppen prüfen die drei vorgegebenen Quellen nach dem SIFT-Schema (Übungsblatt Teil A, Aufgabe 1).

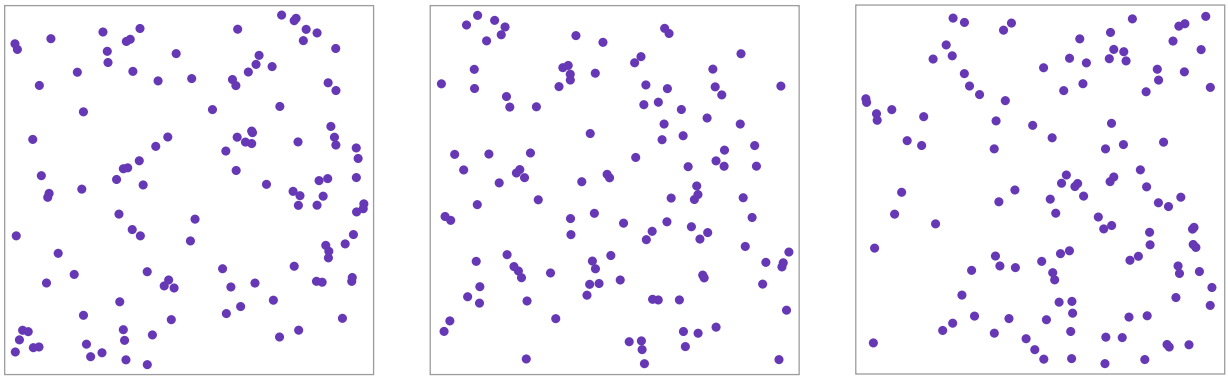
80–90 · Sicherung. Gemeinsame Checkliste „Quellenkritik in fünf Schritten" (Eintrag in Teil B, Aufgabe 3); Diskussionsauftrag zur Zitierhäufigkeit als Qualitätsindikator.

4.1 Staunmoment: Muster im Rauschen

★ Staunmoment: Welche Muster sehen Sie?

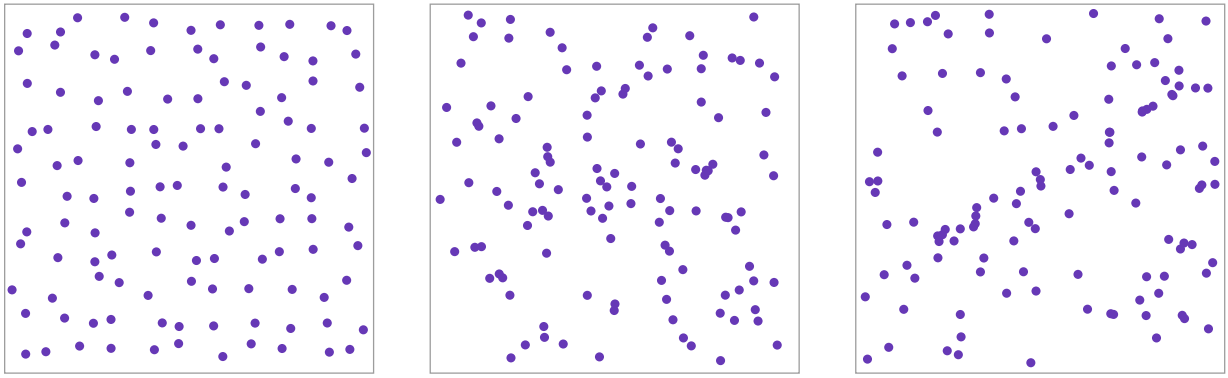
Drei Punktwolken, je 120 Punkte. Sehen Sie sich jede zehn Sekunden lang an.
Notieren Sie alles, was Ihnen auffällt: Häufungen, Linien, Lücken, Figuren.

Welche Muster sehen Sie?



A B C

Und jetzt: Welche ist Zufall?



D E F

- eine Wolke ist reiner Zufall, eine ist geordnet, eine enthält ein echtes Muster

Auflösung der Punktwolken

A, B und C sind gleichverteilte Zufallspunkte (feste Startwerte, damit die Bilder reproduzierbar sind). Jede Häufung, Lücke oder „Linie", die die Gruppe findet, ist Rauschen. Auf der zweiten Folie ist E reiner Zufall; D ist ein regelmäßiges Gitter mit leichtem Zittern, F enthält 25 Punkte nahe einer schrägen Geraden. Häufig wird D für den Zufall gehalten, weil die Punkte so „gleichmäßig verstreut" wirken, und E für geordnet, weil echter Zufall Klumpen bildet. Das Ergebnis vor der Auflösung per Handzeichen festhalten. Die Pointe: Unser Gefühl für „zufällig" ist falsch kalibriert, und ein schwaches echtes Muster (F) ist mit bloßem Auge kaum von den Scheinmustern in A–C zu unterscheiden. Ob ein Muster echt ist, entscheidet nicht der Blick, sondern ein Verfahren (Statistik, Replikation, LE 6).

Ein Kartenspiel



Optionale Erweiterung „Das letzte Abendmahl" (siehe Vorbereitung; *WuZ-Buch*, Anhang K). Bilder aus dem Bühnenprogramm „Wissenschaft und Zauberkunst" (Explore Science). Wer das Kunststück nicht vorführt, überspringt diese drei Folien.

Das letzte Abendmahl



Leonardo da Vinci, *Il Cenacolo*, Mailand, 1495–1498. Hier folgt die augenzwinkernde „Symbolanalyse": Zahlen, Farben und Figuren werden gedeutet, bis das Gemälde scheinbar auf die gewählte Karte zeigt. Die Pointe für die Stunde ist dieselbe wie bei den Punktwolken: Wer ein Muster sucht, findet eines.

Und die Mona Lisa?



Zwei Artikel

- Sie sehen zwei Ausschnitte, beide 30 Sekunden lang
- Welcher ist glaubwürdiger? Handzeichen
- Woran haben Sie das festgemacht? Drei Merkmale notieren

Die beiden Folien mit den Artikeln folgen hier (siehe Vorbereitung). Erst nach der Abstimmung wird aufgelöst: Der elegante Artikel ist frei erfunden und von der Lehrperson für diese Stunde gebaut, der unscheinbare ist eine begutachtete Originalarbeit. Die notierten Merkmale gehen an die rechte Tafelhälfte und werden im Theorieteil geordnet: Fast alle betreffen die Form (Layout, Bild, Zahl, Titel), kaum eines die Herkunft oder die Methode.

Was ist gerade passiert?

- in reinem Rauschen haben wir Muster gesehen

- Ordnung hielten wir für Zufall
- einen erfundenen Text hielten viele für glaubwürdiger als eine echte Studie
- unsere Kriterien betrafen die *Form*, nicht die *Herkunft*

4.2 Apophänie und Bestätigungsfehler

Die Neigung, in zufälligen Daten bedeutungsvolle Zusammenhänge zu erleben, hat der Psychiater Klaus Conrad *Apophänie* genannt. Er beschrieb damit ursprünglich eine Phase beginnender Psychosen, in der den Betroffenen alles bedeutsam und auf sie bezogen erscheint (Conrad 1958). Heute bezeichnet der Begriff eine allgemeine Eigenschaft der Wahrnehmung. Sie verstärkt sich unter Kontrollverlust: In den Experimenten von Whitson und Galinsky (2008) sahen Versuchspersonen, deren Kontrollgefühl man zuvor geschwächt hatte, häufiger Bilder in Rauschmustern und häufiger Verschwörungen.

Das passt zu dem, was das Begleitbuch über Wahrnehmung als Hypothesenbildung sagt (*WuZ-Buch*, Kap. 5). Bei der *Vanishing Ball Illusion* gaben zwei Drittel der Versuchspersonen an, einen Ball hochfliegen und verschwinden gesehen zu haben, der die Hand nie verlassen hatte (Kuhn und Rensink 2016). Das Gehirn ergänzt, was es erwartet. In Rauschdaten ergänzt es Muster, in Texten ergänzt es Glaubwürdigkeit.

Der *Bestätigungsfehler* setzt eine Stufe später an: Er filtert die Bewertung der Evidenz, die wir bereits gesehen haben (Nickerson 1998). Wason zeigte das mit einer Zahlenfolge, deren Regel die Versuchspersonen erraten sollten; sie testeten fast nur Beispiele, die ihre Vermutung bestätigen konnten (Wason 1960). Für die Literaturarbeit heißt das: Wir finden Quellen besonders überzeugend, die bestätigen, was wir schon glauben, und prüfen die anderen strenger.

Apophänie

Definition 4.1 Apophänie ist die Neigung, in zufälligen oder bedeutungslosen Daten Muster und Zusammenhänge zu erleben (Conrad 1958).

- die Wahrnehmung bildet Hypothesen, ergänzt Fehlendes (*WuZ-Buch*, Kap. 5)
- Vanishing Ball: zwei Drittel „sehen" einen Ball, der nie geworfen wurde (Kuhn und Rensink 2016)
- unter Kontrollverlust sehen Menschen mehr Scheinmuster (Whitson und Galinsky 2008)

Der Bestätigungsfehler

- wir prüfen Belege, die uns recht geben, weniger streng (Nickerson 1998)
- Probe: Die Folge 8 – 10 – 12 folgt einer Regel. Welche?
- fast alle testen nur Beispiele, die ihre Vermutung *bestätigen* könnten (Wason 1960)
- für die Recherche: Wer nach Bestätigung sucht, findet sie

Die Probe mit 8 – 10 – 12 ist im Begleitbuch als Hörsaalexperiment beschrieben (*WuZ-Buch*, Kap. 4): Die meisten vermuten „gerade Zahlen" oder „immer plus zwei" und nennen 14. Die Regel lautet „aufsteigende Zahlen". Sie hätten sie nur gefunden, wenn sie eine Folge getestet hätten, die ihrer Vermutung widerspricht. Wer in LE 3 eine Suchanfrage formuliert hat, die nur die erwartete Antwort finden kann, hat denselben Fehler gemacht.

Quellenkritik als Gegenmittel

- gegen Apophänie: Muster erst glauben, wenn ein *Verfahren* sie bestätigt
- gegen den Bestätigungsfehler: dieselben Kriterien an *alle* Quellen legen, auch an die bequemen
- gezielt nach der stärksten Gegenposition suchen

Merke

Das Gefühl, ein Muster zu sehen, ist kein Beleg dafür, dass es da ist. Das Gefühl, einer Quelle trauen zu können, ist kein Beleg für ihre Qualität. Beides wird geprüft, nicht empfunden.

4.3 Kriterien der Quellenkritik

Die Geschichtswissenschaft hat die Quellenkritik als Methode entwickelt; die empirischen Wissenschaften haben sie um die Frage nach der Methode erweitert. Für wissenschaftliches Arbeiten genügen fünf Kriterien, die sich in jeder Disziplin anwenden lassen. Keines entscheidet allein, und keines ist mit einem Blick auf das Layout zu beantworten.

Was ist Quellenkritik?

Definition 4.2 Quellenkritik ist die methodische Prüfung, wer eine Information mit welcher Absicht, auf welchem Weg und mit welcher Prüfung erzeugt hat, um zu entscheiden, wie viel Gewicht sie in der eigenen Argumentation tragen darf.

- das Ergebnis ist ein *Gewicht*, kein Ja oder Nein
- geprüft wird die Quelle, nicht ihr Aussehen

Fünf Kriterien

Kriterium	Prüffrage	Warnsignal
Herkunft	Wer spricht? Welche Expertise, welche Institution?	kein Autor, kein Impressum
Intention	Wozu wurde der Text geschrieben? Wer bezahlt?	verkauft etwas, Interessenkonflikt verschwiegen
Methode	Wie wurde das Ergebnis gewonnen?	„Studien zeigen“ ohne Angabe welcher
Peer Review	Haben unabhängige Fachleute geprüft?	Selbstverlag, Raubverlag
Aktualität	Ist das noch Stand der Forschung?	widerrufen, überholt, nie repliziert

Herkunft. Gefragt wird nach der Person und der Institution, nach deren Fachkompetenz für *genau diese* Frage und nach der Nachprüfbarkeit dieser Angaben. Ein Nobelpreis in Chemie macht nicht zum Fachmann für Ernährung. **Intention.** Informieren, überzeugen, verkaufen und unterhalten sind legitime Absichten, aber sie verändern das Gewicht einer Aussage. Eine Pressemitteilung eines Herstellers über das eigene Produkt ist eine Quelle, aber eine parteiische. **Methode.** Hier liegt der Kern der wissenschaftlichen Quellenkritik: Wie viele Personen wurden untersucht, gab es eine Kontrollgruppe, sind die Daten offengelegt? Die Frage wird in LE 6 und LE 7 ausgebaut. **Peer Review.** Die Begutachtung vor der Veröffentlichung ist eine wichtige, aber begrenzte Prüfung (siehe unten). **Aktualität.** Ein alter Text ist nicht schlechter als ein neuer; aber man muss wissen, ob sein Befund inzwischen widerrufen, bestätigt oder überholt ist.

Was Peer Review leistet – und was nicht

- Gutachter prüfen Logik, Methode, Einordnung, Darstellung
- sie sehen in der Regel *nicht* die Rohdaten
- Stapel: mindestens 55 Publikationen mit erfundenen Daten, entdeckt von Mitarbeitern, nicht von Gutachtern (Levelt u. a. 2012)
- Bik: problematische Bildduplikate in 3,8 % von 20.621 Aufsätzen (Bik u. a. 2016)
- Peer Review ist eine Mindestprüfung, kein Wahrheitssiegel

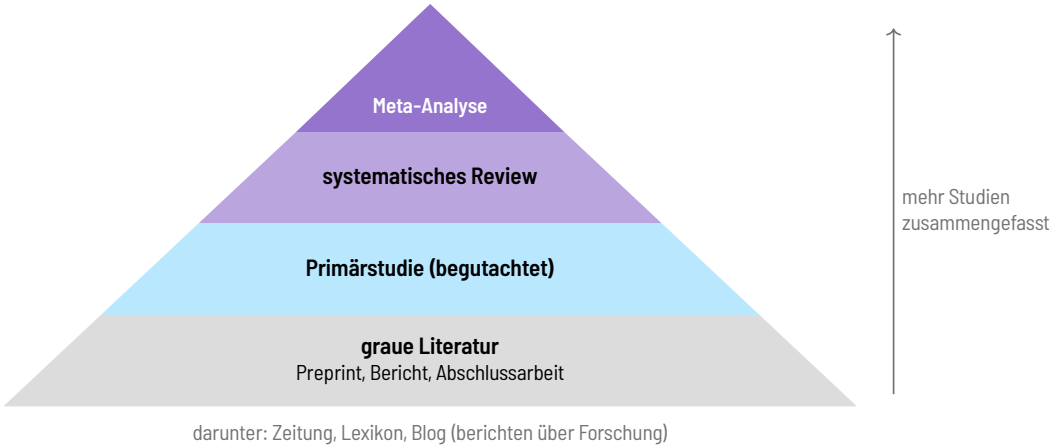
Beide Fälle sind im Begleitbuch ausführlich dargestellt (*WuZ-Buch*, Kap. 15b). Bemerkenswert ist der zweite Teil der Geschichte: Die Fehler wurden *innerhalb* der Wissenschaft aufgedeckt, durch nachträgliche Prüfung. Das ist kein Argument gegen Peer Review, sondern eines dafür, Begutachtung als laufenden Prozess zu verstehen, der mit der Veröffentlichung nicht endet. Für die Quellenkritik folgt daraus, dass *nach* der Veröffentlichung geprüft werden muss: Gibt es Korrekturen, Kommentare, einen Widerruf?

4.4 Qualitätsstufen wissenschaftlicher Literatur

Neben den Kriterien für die einzelne Quelle braucht man eine Vorstellung davon, welche *Art* von Text man vor sich hat. Eine *Primärstudie* berichtet eigene Daten. Ein *Review* fasst den Stand mehrerer Studien zusammen, entweder erzählend (narrativ) oder nach einem vorab festgelegten, offengelegten Suchprotokoll (systematisch). Eine *Meta-Analyse* fasst die Effektgrößen vieler Studien statistisch zusammen. *Graue Literatur* umfasst alles, was außerhalb der Verlagswege erscheint: Preprints, Berichte von Behörden und Verbänden, Abschlussarbeiten, Tagungsbeiträge. Zeitungsartikel und Lexikoneinträge sind Tertiärquellen: Sie berichten über Forschung, sie sind keine.

Für Fragen nach der Wirksamkeit einer Maßnahme wird diese Rangfolge häufig als Pyramide dargestellt. Die Pyramide ist eine Faustregel. Eine Meta-Analyse aus schwachen Einzelstudien bleibt schwach, und eine qualitative Studie ist für eine Frage nach Erleben und Bedeutung die angemessene Primärquelle, auch wenn sie in der Pyramide weit unten stünde (LE 9). Ioannidis (2005) hat gezeigt, warum sich gerade in Feldern mit kleinen Stichproben, kleinen Effekten und vielen getesteten Hypothesen viele publizierte Einzelbefunde nicht halten. Daraus folgt: Einer einzelnen Studie gibt man weniger Gewicht als einem Befund, der unabhängig repliziert wurde.

Vier Qualitätsstufen



darunter: Zeitung, Lexikon, Blog (berichten über Forschung)

Grenzen der Pyramide

- gilt vor allem für Fragen nach Wirksamkeit
- eine Meta-Analyse schwacher Studien bleibt schwach
- für Fragen nach Erleben ist die qualitative Studie die richtige Primärquelle (LE 9)
- viele Einzelbefunde halten nicht (Ioannidis 2005)
- Faustregel: repliziert vor einzeln, Original vor Bericht

4.5 Plausibilität und ihre Grenzen

Im Alltag entscheiden wir über Glaubwürdigkeit fast immer mit Heuristiken: Klingt das plausibel? Sieht das seriös aus? Habe ich das schon öfter gehört? Solche Faustregeln sind nicht dumm. Sie funktionieren dort, wo die Umwelt ehrlich

ist, wo also Professionalität, Wiederholung und Plausibilität tatsächlich mit Wahrheit zusammenhängen (Gigerenzer u. a. 1999). Sie versagen dort, wo jemand die Hinweisreize kennt und gezielt erzeugt. Genau das tut der Zauberkünstler auf der Bühne, deklariert und zur Unterhaltung, und genau das tut die Desinformation, undeklariert (*WuZ-Buch*, Kap. 15b).

Drei Befunde zeigen, wie wenig die Hinweisreize mit dem Inhalt zu tun haben müssen. Aussagen werden häufiger für wahr gehalten, wenn sie leicht lesbar dargeboten werden (Reber und Schwarz 1999). Sie werden für wahrer gehalten, wenn man sie schon einmal gehört hat, unabhängig davon, ob sie stimmen (Hasher u. a. 1977). Und ein mitreißender Vortrag ohne sinnvollen Inhalt kann von einem Fachpublikum glänzend bewertet werden, der sogenannte Dr.-Fox-Effekt (Naftulin u. a. 1973; Peer und Babad 2014). Die schöne Fälschung im Staunmoment hat alle drei Hebel benutzt.

Woran wir Glaubwürdigkeit festmachen

- **Lesbarkeit**: leicht Lesbares wirkt wahrer (Reber und Schwarz 1999)
- **Wiederholung**: schon Gehörtes wirkt wahrer (Hasher u. a. 1977)
- **Auftreten**: ein guter Vortrag wirkt kompetent, auch ohne Inhalt (Naftulin u. a. 1973)
- **Präzision**: eine genaue Zahl wirkt gemessen

Die präzise Zahl

- „Die Tischdecke in Leonardos *Abendmahl* enthält 52 Rechtecke."
- klingt gezählt, ist aber erfunden
- belegbar sind andere Angaben: 13 Figuren, Jesus in der Mitte, drei Fenster, entstanden 1495–1498
- Quellenkritik fragt: **Wer hat das gezählt? Wo steht das?**

Das Beispiel stammt aus dem Umfeld des Kunststücks „Das letzte Abendmahl" (*WuZ-Buch*, Anhang K). Die Zahl 52 passt verführerisch zu einem Kartenspiel und wird deshalb gern weitererzählt. Präzision ist ein Oberflächenmerkmal wie gutes Layout: Sie kostet den Erzeuger nichts und signalisiert dem Leser Messung. Prüfen lässt sich eine solche Zahl nur, indem man ihre Spur bis zu jemandem zurückverfolgt, der sie erhoben hat. Endet die Spur bei einer Behauptung ohne Quelle, trägt die Zahl kein Gewicht, gleich wie oft sie wiederholt wird.

Wann Heuristiken taugen

- Faustregeln sind schnell und oft gut (Gigerenzer u. a. 1999)
- sie versagen, wo jemand die Hinweisreize gezielt erzeugt
- Zauberkunst und Desinformation nutzen dieselben Hebel, nur der Vertrag mit dem Publikum ist verschieden (*WuZ-Buch*, Kap. 15b)
- Konsequenz: Plausibilität ist ein Anlass zu prüfen, kein Ersatz dafür

4.6 Impact Factor, h-Index und was sie nicht aussagen

In der Wissenschaft selbst gibt es ein Gegenstück zur Plausibilitätsheuristik: die Zitationsmetrik. Der *Impact Factor* einer Zeitschrift ist die Zahl der Zitate, die ihre Artikel aus den beiden Vorjahren in einem Jahr erhalten, geteilt durch die Zahl dieser Artikel. Eugene Garfield hat ihn als Hilfsmittel entwickelt, um Zeitschriften für den Science Citation Index auszuwählen, und selbst davor gewarnt, damit einzelne Forschende zu bewerten (Garfield 2006). Der *h-Index* einer Person ist die größte Zahl h, für die sie h Arbeiten mit je mindestens h Zitaten hat (Hirsch 2005).

Beide Zahlen messen Aufmerksamkeit, nicht Richtigkeit. Seglen (1997) hat gezeigt, dass die Zitate innerhalb einer Zeitschrift stark ungleich verteilt sind: Wenige Artikel bringen den Großteil, die meisten liegen weit unter dem Mittelwert. Der Impact Factor sagt deshalb wenig über den einzelnen Artikel. Zitate folgen außerdem der Reputation: Bekannte Namen werden für vergleichbare Arbeit häufiger zitiert, ein Effekt, den Merton nach dem Matthäus-Evangelium benannt hat (Merton 1968). Und zitiert wird auch, was man widerlegt. Stapels *Science*-Artikel von 2011 (Stapel und Lindenberg 2011) ist seit dem Auffliegen der Fälschung vor allem als Beispiel für Betrug von Interesse; jede solche Erwähnung zählt als

Zitat. Die *San Francisco Declaration on Research Assessment* (San Francisco Declaration on Research Assessment 2012) und das *Leiden Manifesto* (Hicks u. a. 2015) fordern deshalb, Forschung nach ihrem Inhalt zu bewerten und Metriken nur ergänzend zu nutzen.

Zwei Kennzahlen

- **Impact Factor** (Zeitschrift): Zitate eines Jahres auf die Artikel der zwei Vorjahre, geteilt durch deren Zahl (Garfield 2006)
- **h-Index** (Person): h Arbeiten mit je mindestens h Zitaten (Hirsch 2005)
- beide zählen Zitate, also *Aufmerksamkeit*

Was Zitate nicht messen

- wenige Artikel tragen den Impact Factor einer Zeitschrift (Seglen 1997)
- Bekannte werden häufiger zitiert: Matthäus-Effekt (Merton 1968)
- zitiert wird auch, was widerlegt oder zurückgezogen wurde
- Fachkulturen zitieren unterschiedlich viel
- DORA und Leiden Manifesto: Inhalt vor Kennzahl (San Francisco Declaration on Research Assessment 2012; Hicks u. a. 2015)

Merke: Zitate

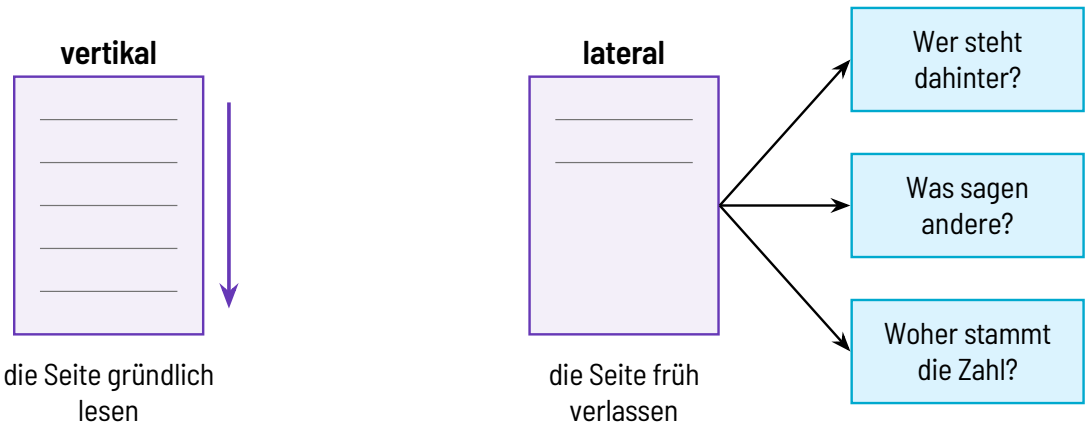
Eine Zitation sagt: „Diese Arbeit wurde zur Kenntnis genommen." Ob sie zustimmend, kritisch oder als abschreckendes Beispiel zitiert wurde, steht nicht in der Zahl.

4.7 Laterales Lesen und SIFT

Wie prüfen Profis eine unbekannte Quelle? Wineburg und McGrew (2019) haben Historiker, Studierende einer Elite-Universität und professionelle Faktenprüfer dieselben Websites bewerten lassen. Die Faktenprüfer waren schneller und lagen häufiger richtig, obwohl sie weniger auf den Seiten selbst lasen. Sie verließen die Seite fast sofort und schlugen in neuen Tabs nach, wer hinter ihr steht. Wineburg und McGrew nennen das *laterales Lesen*, im Unterschied zum *vertikalen* Lesen, bei dem man die Seite von oben nach unten prüft und dabei den Gestaltungsmitteln des Absenders ausgeliefert bleibt. Im Begleitbuch heißt es dazu: Die Website ist die Bühne des Absenders, und wer auf der Bühne nach der Wahrheit sucht, sucht dort, wo die Ablenkung am stärksten ist (*WuZ-Buch*, Kap. 15b).

Mike Caulfield hat das Vorgehen der Faktenprüfer zu vier Schritten verdichtet, die er SIFT nennt (Caulfield und Wineburg 2023). Sie eignen sich für Zeitungsartikel und Websites ebenso wie als erste Stufe der Prüfung wissenschaftlicher Quellen.

Vertikal oder lateral?



- Faktenprüfer lesen weniger und urteilen besser (Wineburg und McGrew 2019)

SIFT in vier Schritten

Stop	innehalten: Kenne ich die Quelle? Was will ich wissen?
Investigate the source	außerhalb der Quelle nachlesen, wer sie ist
Find better coverage	bessere oder unabhängige Berichte zur selben Behauptung suchen
Trace claims	Behauptung, Zitat, Bild zum Ursprung zurückverfolgen

- nach Caulfield und Wineburg (2023)

Stop heißt zweierlei: den Impuls bremsen, eine Information sofort zu glauben oder weiterzugeben, und sich klarmachen, wozu man sie braucht. Für eine Hausarbeit genügt nicht, was für ein Gespräch in der Mensa genügt. **Investigate the source** heißt nicht, die „Über uns"-Seite der Quelle zu lesen, sondern in einem neuen Tab nachzuschlagen, was *andere* über sie sagen; Wikipedia ist dafür ein brauchbarer erster Halt. **Find better coverage** heißt: Wenn die Quelle unklar bleibt, eine bessere zur selben Behauptung suchen, statt die schlechte weiter zu analysieren. **Trace claims** heißt, eine Zahl, ein Zitat oder ein Bild bis zum ursprünglichen Kontext zu verfolgen. Bei Wissenschaftsmeldungen endet diese Spur im Idealfall bei der Studie selbst. Dort zeigt sich oft, dass die Studie etwas Vorsichtigeres behauptet als die Schlagzeile.

4.8 Prebunking und Debunking

Quellenkritik ist eine Fähigkeit. Sie wirkt aber nur, wenn man sie anwendet, bevor sich eine Falschinformation festgesetzt hat. Die Desinformationsforschung zeigt, dass widerlegte Behauptungen weiter auf das Denken abfärben, selbst wenn die Korrektur verstanden und akzeptiert wurde (Lewandowsky u. a. 2012). Das Begleitbuch deutet diesen *Continued Influence Effect* mit dem Begriffspaar aus LE 1: Die Korrektur erreicht den Belief, die Falschmeldung sitzt als Alief (*WuZ-Buch*, Kap. 15b).

Daraus folgen zwei Strategien. Beim *Debunking* wird eine bereits verbreitete Falschbehauptung widerlegt; wirksam ist das vor allem, wenn die Korrektur die Lücke mit einer Erklärung füllt, statt nur „falsch" zu sagen (Lewandowsky u. a. 2020). Beim *Prebunking* werden Menschen vorab mit einer abgeschwächten Form der Manipulationstechnik konfrontiert. Die Idee geht auf McGuires Inokulationstheorie zurück (McGuire 1964) und wurde in Experimenten mit kurzen Videos, darunter einem Feldexperiment auf YouTube, bestätigt (Roozenbeek u. a. 2022). Schon die bloße Frage „Stimmt das eigentlich?" verbessert, was Menschen teilen (Pennycook u. a. 2021). Der Staunmoment dieser Stunde war eine solche Impfung: Sie haben die Wirkung der schönen Fälschung an sich selbst erlebt.

Korrigieren reicht nicht

- widerlegte Behauptungen wirken weiter (Lewandowsky u. a. 2012)
- die Korrektur erreicht den Belief, die Falschmeldung sitzt als Alief (*WuZ-Buch*, Kap. 15b)
- **Debunking**: die Lücke mit einer Erklärung füllen, nicht nur „falsch" sagen (Lewandowsky u. a. 2020)

Impfen statt heilen

- **Prebunking**: die Technik in schwacher Dosis vorab erleben (McGuire 1964)
- wirkt gegen *Techniken*, nicht nur gegen einzelne Behauptungen (Roozenbeek u. a. 2022)
- schon die Frage „Stimmt das?" hilft (Pennycook u. a. 2021)
- der Zaubertrick ist Prebunking: Täuschung erleben, dann auflösen

Skepsis ohne Zynismus

- Ziel ist *kalibriertes* Vertrauen, nicht Misstrauen gegen alles
- wer alles für inszeniert hält, landet bei Expertenverachtung (Mede und Schäfer 2020)

- dass Betrug aufgedeckt wird, spricht *für* die Wissenschaft
- offen bleiben und prüfen (Sagan 1995)

Diese Folie ist wichtig, weil Quellenkritik eine Nebenwirkung hat. Wer gelernt hat, dass alles gefälscht sein *kann*, schließt leicht, dass alles gefälscht *ist*. Das Begleitbuch setzt dagegen eine Dosierungsregel: hohes Vertrauen dort, wo Herkunft, Methode und unabhängige Bestätigung es rechtfertigen, und Zurückhaltung dort, wo sie fehlen (*WuZ-Buch*, Kap. 15b). Carl Sagan hat diese Balance als Verbindung von Offenheit und Skepsis beschrieben (Sagan 1995).

4.9 Übung in der Stunde

SIFT in Kleingruppen (30 Min.)

- drei Quellen: eine Studie, ein Zeitungsartikel, ein Wikipedia-Eintrag (Links auf dem Lernportal)
- füllen Sie das SIFT-Raster aus (Übungsblatt Teil A, Aufgabe 1)
- verfolgen Sie mindestens eine Zahl bis zur Originalstudie
- Ergebnis: ein Gewicht je Quelle (hoch / mittel / gering) mit Begründung

Quellenkritik in fünf Schritten

- **1 Innehalten**: Was will ich wissen, was löst die Quelle in mir aus?
- **2 Herkunft und Absicht**: wer, mit welchem Interesse?
- **3 Art und Methode**: Primärstudie, Review, Bericht? Wie gewonnen?
- **4 Spur zum Original**: Zahlen und Zitate zurückverfolgen
- **5 Gegenprobe**: unabhängige Bestätigung, Widerruf, Gegenposition

Hinweis für Lehrende

Die fünf Schritte entstehen in der Sicherung gemeinsam an der Tafel; die Folie dient als Abgleich. Die Studierenden tragen sie in Übungsblatt Teil B, Aufgabe 3, ein, das deshalb keine vorgedruckten Schritte enthält. Erwartungshorizont für die SIFT-Übung (abhängig von den gewählten Quellen): *Studie* – Herkunft über Zeitschrift und Institution prüfbar, Methode im Text offengelegt, Gewicht hoch bis mittel je nach Design und Replikation; die Gruppe soll nachsehen, ob es Korrekturen oder einen Widerruf gibt. *Zeitungsartikel* – Herkunft über das Medium bestimmbar, aber Tertiärquelle; in Schritt T zeigt sich meist die Zuspitzung gegenüber der Studie. Gewicht: als Hinweis brauchbar, als Beleg in einer Hausarbeit nicht. *Wikipedia* – Autorenschaft anonym, aber Versionsgeschichte und Diskussionsseite einsehbar; Einzelnachweise sind der Weg zur Primärquelle. Gewicht: guter Ausgangspunkt für laterales Lesen, kein zitierfähiger Beleg für Fachaussagen. Häufiger Fehler: Gruppen bewerten vertikal („die Seite wirkt seriös"). Dann nachfragen: „Was sagen *andere* über diese Quelle?"

4.10 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- Apophänie und Bestätigungsfehler erklären und an Beispielen zeigen
- Quellen nach Herkunft, Intention, Methode, Peer Review und Aktualität bewerten
- Primärstudie, Review, Meta-Analyse und graue Literatur unterscheiden
- die Grenzen von Plausibilitätsurteilen und Zitationsmetriken benennen
- eine Quelle lateral nach dem SIFT-Schema prüfen

Bis zur nächsten Woche

- **SIFT-Raster** für die drei Quellen fertigstellen (Übungsblatt Teil A, Aufgabe 1)
- **Diskussion** (max. 1 Seite): „Eine Studie hat 500 Zitierungen. Was sagt das über ihre Qualität?" Strukturierte Gegenargumentation
- **Tagebuch des Staunens**: ein Muster, das Sie diese Woche gesehen haben, und wie Sie geprüft haben, ob es echt ist
- die eigene annotierte Bibliographie aus LE 3 mit den fünf Schritten nachprüfen

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 4**

Handout: Quellenkritik

Worum es heute ging. In reinen Zufallspunkten haben Sie Muster gesehen, und ein erfundener, gut gestalteter Artikel wirkte glaubwürdiger als eine echte, unscheinbare Studie. Das Gehirn ergänzt Muster und Glaubwürdigkeit aus Oberflächenmerkmalen. Quellenkritik setzt an die Stelle des Eindrucks eine Prüfung.

Kernbegriffe

Apophänie die Neigung, in Zufall Muster zu sehen (Conrad 1958).

Bestätigungsfehler Belege, die uns recht geben, werden weniger streng geprüft (Nickerson 1998).

Primärstudie / Review / Meta-Analyse eigene Daten / Zusammenfassung mehrerer Studien / statistische Zusammenfassung ihrer Effektgrößen. **Graue Literatur**: Preprints, Berichte, Abschlussarbeiten.

Impact Factor, h-Index zählen Zitate, also Aufmerksamkeit, nicht Richtigkeit (Seglen 1997; Hirsch 2005).

Laterales Lesen die Quelle früh verlassen und nachschlagen, was andere über sie sagen (Wineburg und McGrew 2019).

Prebunking Manipulationstechniken vorab in schwacher Dosis kennenlernen (Roozenbeek u. a. 2022).

Fünf Kriterien und SIFT

Kriterien der Quellenkritik	**SIFT** (Caulfield und Wineburg 2023)
Herkunft: Wer spricht, mit welcher Expertise?	**S**top: innehalten, Ziel klären
Intention: Wozu, wer bezahlt?	**I**nvestigate: außerhalb nachlesen, wer die Quelle ist
Methode: Wie gewonnen?	**F**ind better coverage: bessere Berichte suchen
Peer Review: Wer hat geprüft?	**T**race claims: zum Original zurückverfolgen
Aktualität: widerrufen, überholt, repliziert?	

Merke

Gutes Layout, eine präzise Zahl und häufige Wiederholung machen eine Aussage glaubwürdiger, aber nicht wahrer. Fragen Sie bei jeder Zahl: Wer hat das gezählt, und wo steht das?

Quellenkritik in fünf Schritten: (1) innehalten, (2) Herkunft und Absicht klären, (3) Art und Methode bestimmen, (4) Spur zum Original verfolgen, (5) Gegenprobe: unabhängige Bestätigung, Widerruf, Gegenposition.

Zum Weiterlesen: Wineburg und McGrew (2019); Caulfield und Wineburg (2023); Seglen (1997).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 4**

Übungsblatt A: Quellenkritik und SIFT

Name: _____ Datum: _____

Aufgabe 1: SIFT-Raster für drei Quellen

in der Stunde, Kleingruppe, 30 Min.; Fertigstellung als Hausaufgabe

Die Lehrperson gibt drei Quellen vor (Übungsblatt C): (1) eine Peer-Review-Studie, (2) einen Zeitungsartikel, (3) einen Wikipedia-Eintrag. Tragen Sie zuerst die genauen Angaben ein, dann Ihre Befunde zu jedem Schritt. Verfolgen Sie in Schritt T mindestens eine Zahl bis zur Originalstudie. Zur Art der Quelle: *primär* = eigene Daten (Studie), *sekundär* = fasst Studien zusammen (Review, Meta-Analyse), *tertiär* = berichtet darüber (Presse, Lexikon), *grau* = ohne Verlag oder Begutachtung veröffentlicht (Preprint, Bericht, Abschlussarbeit).

	(1) Studie	**(2) Zeitungsartikel**	**(3) Wikipedia**
Angaben (Autor, Titel, Datum, Link)			
Stop: Was will ich wissen? Erster Eindruck?			
Investigate: Wer ist die Quelle? Was sagen andere?			
Find: Bessere oder unabhängige Berichte?			
Trace: Woher stammt die zentrale Zahl/Aussage?			
Art der Quelle (primär, sekundär, tertiär, grau)			
Gewicht (hoch/mittel/gering) und Begründung			

Übungsblatt B: Schöne Fälschung und Quellenkritik

Name: _____ Datum: _____

Aufgabe 2: Anatomie einer schönen Fälschung

in der Stunde nach der Auflösung, Einzelarbeit, 10 Min.

Die folgende Meldung ist **fiktiv** und für diese Übung konstruiert, nach dem Muster der „schönen Fälschung" aus dem Staunmoment. Markieren Sie alle Merkmale, die Glaubwürdigkeit *erzeugen*, und notieren Sie zu jedem, ob es etwas *belegt*.

Jonglieren macht schlau: Zehn Minuten am Morgen steigern die Merkfähigkeit um 23,7 Prozent

Wer den Tag mit Jonglierbällen beginnt, lernt schneller. Das zeigt eine neue Studie, über die Fachleute seit Wochen diskutieren. „Die Effekte sind beeindruckend", sagt Prof. Dr. H. Lindner, Lernforscher und Autor mehrerer Ratgeber. Die Teilnehmenden, die vor dem Vokabellernen jonglierten, behielten im Schnitt 23,7 % mehr Wörter. Immer mehr Schulen denken bereits über Jonglierpausen nach. Das passt zu dem, was Pädagogen schon lange vermuten: Bewegung und Denken gehören zusammen.

(Fiktives Lehrmaterial, LE 4. Person, Studie und Zahlen sind erfunden.)

Merkmal	Belegt es etwas? Was fehlt?

Aufgabe 3: Quellenkritik in fünf Schritten

Hausaufgabe

Tragen Sie in der Sicherung die fünf Schritte, die die Gruppe an der Tafel erarbeitet, in die linke Spalte ein (zum Abgleich: Handout). Wenden Sie die Checkliste dann auf zwei Einträge Ihrer annotierten Bibliographie aus LE 3 an. Haken Sie ab, was Sie geprüft haben, und notieren Sie, ob sich Ihr Urteil geändert hat.

Schritt	Quelle A	Quelle B
1	☐	☐
2	☐	☐
3	☐	☐
4	☐	☐
5	☐	☐

Hat sich Ihr Urteil geändert? Warum?

Aufgabe 4: Diskussion: 500 Zitierungen

Hausaufgabe, max. 1 Seite

„Eine Studie hat 500 Zitierungen. Was sagt das über ihre Qualität?" Schreiben Sie eine strukturierte Gegenargumentation gegen die Annahme, viele Zitate bedeuteten hohe Qualität. Gliederung: (a) die These in ihrer stärksten Form, (b) mindestens drei Gegenargumente mit je einem Beleg oder Beispiel, (c) was Zitate *doch* aussagen, (d) Ihr Fazit: Wie würden Sie die Qualität stattdessen prüfen?

Aufgabe 5: Tagebuch des Staunens

Hausaufgabe

Beschreiben Sie ein Muster, das Ihnen diese Woche aufgefallen ist (Zufall, Statistik, Nachrichten, Alltag). Was haben Sie erwartet, was haben Sie gesehen, und wie könnten Sie prüfen, ob das Muster echt ist?

Erwartungshorizont

Aufgabe 1: siehe Lehrhinweis in der Stunde; gute Lösungen nennen in Schritt I eine *externe* Quelle und in Schritt T die Stelle der Studie, aus der die Zahl stammt. Aufgabe 2: Glaubwürdigkeitsmerkmale sind die präzise Zahl (23,7 %), der Professorentitel, das Zitat, „eine neue Studie" ohne Angabe, „Fachleute diskutieren", „immer mehr Schulen", die Anknüpfung an Bekanntes („was Pädagogen schon lange vermuten"). Keines belegt etwas: Es fehlen Studie, Stichprobe, Kontrollgruppe, Messverfahren, Fachgebiet des Experten (Ratgeberautor: Interessenkonflikt). Aufgabe 3: In die linke Spalte gehören die fünf Schritte der Sicherung (innehalten; Herkunft und Absicht; Art und Methode; Spur zum Original; Gegenprobe), wie im Handout. Aufgabe 4: Erwartete Gegenargumente: Zitate messen Aufmerksamkeit, nicht Richtigkeit; auch Kritik und Widerlegung zählen als Zitat; Matthäus-Effekt (Merton 1968); Fach- und Alterseffekte (ältere Arbeiten und große Fächer sammeln mehr Zitate); Selbstzitate; Zitate werden oft ungelesen übernommen. Zugestanden werden sollte: Eine viel zitierte Arbeit ist in der Fachdiskussion präsent und meist ein guter Einstieg. Stärkere Lösungen schlagen Prüfwege vor: Methode lesen, Replikationen und Widerrufe suchen, in welchem Sinn zitiert wird (San Francisco Declaration on Research Assessment 2012; Hicks u. a. 2015).

Übungsblatt C: Drei Quellen für die SIFT-Übung

Diese drei Quellen bearbeiten Sie mit dem SIFT-Raster (Übungsblatt A, Aufgabe 1). Sie hängen zusammen: Zeitungsartikel und Wikipedia-Eintrag berufen sich auf dieselbe Studie. Öffnen Sie die Links über die QR-Codes und tragen Sie die Angaben selbst ins Raster ein.

(1) Die Studie

White, M. P., Alcock, I., Grellier, J., Wheeler, B. W., Hartig, T., Warber, S. L., Bone, A., Depledge, M. H. & Fleming, L. E. (2019). Spending at least 120 minutes a week in nature is associated with good health and wellbeing. *Scientific Reports, 9*, Artikel 7730. Frei zugänglich (Open Access); Volltext unverändert im Anhang dieses Blatts (Lizenz CC BY 4.0).

`https://doi.org/10.1038/s41598-019-44097-3`

(2) Der Zeitungsartikel

DER SPIEGEL (13. 6. 2019). Waldbaden und Spazierengehen: Ab zwei Stunden pro Woche macht die Natur gesund, sagen Forscher. Ressort Gesundheit. Der Ausdruck wird in der Stunde getrennt ausgeteilt.

`https://www.spiegel.de/gesundheit/ernaehrung/120-minuten-natur-pro-woche-sind-gesund-a-1272293.html`

(3) Der Wikipedia-Eintrag

„Health", englischsprachige Wikipedia, Fassung vom 26. 9. 2026 (permanenter Link, damit alle Gruppen dieselbe Fassung prüfen). Suchen Sie den Satz, der die Studie zitiert (Abschnitt zur Umwelt als Gesundheitsfaktor). Der Abschnitt „Determinants" steht im Anhang (Lizenz CC BY-SA 4.0).

`https://en.wikipedia.org/w/index.php?title=Health&oldid=1376907986`

Zusatz für Schritt T: die Pressemitteilung

University of Exeter (Juni 2019). Two hours a week is key dose of nature for health and wellbeing. Pressemitteilung der Hochschule, an der die Studie entstand.

`https://news-archive.exeter.ac.uk/2019/june/title_720059_en.html`

Für schnelle Gruppen: Gibt es in der deutschsprachigen Wikipedia einen Eintrag, der diese Studie zitiert? Was folgt daraus für Ihre Suche in Schritt F?

Erwartungshorizont zu den drei Quellen

Die Volltexte der beiden Zeitungsartikel (SPIEGEL und Guardian) liegen aus urheberrechtlichen Gründen nicht im öffentlichen Repository, sondern nur in der WuZ-Dropbox (`Wissenschaft_und_Zauberkunst/WissArbeiten_LE04_Quellen`); nur für die Teilnehmenden kopieren. Studie und Wikipedia-Abschnitt stehen unter freier Lizenz und sind in der Druckvorlage enthalten. Die Kette ist geprüft (Oktober 2026): Der SPIEGEL nennt die University of Exeter und *Scientific Reports*, verlinkt die Studie aber nicht; die Wikipedia zitiert sie mit DOI. **S:** Die Überschrift ist kausal und nennt eine genaue Dosis („ab zwei Stunden"); das klingt gemessen und passt zu Bekanntem (150 Minuten Bewegung, „5 am Tag"), also Vorsicht vor dem Bestätigungsfehler. **I:** Der Artikel ist nicht namentlich gezeichnet und folgt eng der Pressemitteilung; die Hochschule hat ein Interesse an Aufmerksamkeit. **F:** Im SPIEGEL-Text selbst steht es vorsichtiger als in der Überschrift („relativ klein", umgekehrte Wirkrichtung nicht ausgeschlossen). Die deutschsprachige Wikipedia zitiert die Studie nicht; der englische Eintrag „Health" schreibt „It has been demonstrated" und „positive health

benefits“, also stärker als die Studie. **T:** Die Studie schreibt „associated“, nicht „macht gesund“: Querschnittsbefragung, Selbstauskunft, $n = 19\,806$. Die Autoren können nicht ausschließen, dass gesündere Menschen mehr Zeit in der Natur verbringen; die Zeit in der Natur erklärt nur rund 1 % der Varianz. Die Zahl 120 ist zum Teil ein Artefakt: Die Zeit wurde in 60-Minuten-Blöcke eingeteilt, und 78 % der Angaben im Block 120–179 Minuten lauten genau 120 (runde Stunden). Brücke zur Apophänie: Eine „Schwelle“ wird in kategorisierte Daten hineingelesen. **Gewicht:** Studie mittel (groß, begutachtet, aber korrelativ, von den Autoren selbst als vorläufig bezeichnet), Zeitung gering bis mittel, Wikipedia gering (tertiär, überzeichnet).

5 Hypothesen und Falsifizierbarkeit

In LE 2 wurde aus einem Staunen eine Forschungsfrage. Jetzt wird aus der Frage eine Behauptung, die an der Wirklichkeit scheitern kann. Die Einheit beginnt mit einem Gerät, das jede Ingenieurstudentin nach zehn Minuten verstanden zu haben glaubt: vier Schalter, vier Lampen, sichtbare Leiterbahnen. Die Gruppe bildet ein Modell, sammelt Bestätigungen und erlebt dann, dass beliebig viele Bestätigungen ein falsches Modell nicht retten. Daraus entwickelt die Einheit die Unterscheidung von Induktion, Deduktion und Abduktion, Poppers Falsifikationsprinzip, die Formulierung von Null- und Alternativhypothese, Horwichs graduellen Bestätigungsbegriff und die Grenzen der Falsifikation (Duhem-Quine). Der Wason-2-4-6-Test zeigt anschließend, dass der Hang zum Bestätigen eine feste Gewohnheit ist, gegen die man sich methodisch schützen muss.

Vorbereitung vor der Stunde: Switchboard / Black Box

Eine Woche vorher

- ☐ Das *Switchboard* ist ein kommerzielles Kunststück (Andersen 2020): eine offene Platine mit vier Schaltern mit farbigen Hülsen und vier Lampen in denselben Farben, sichtbar über Leiterbahnen verbunden. Gerät rechtzeitig beim Fachhandel für Zauberbedarf beschaffen bzw. aus dem Bestand holen.
- ☐ **Methode und Einstudierung nach der Anleitung des Herstellers; hier bewusst nicht beschrieben.** Das Skript wird öffentlich gespiegelt. Assistenzen, die das Gerät mit bedienen, werden persönlich eingewiesen und zur Verschwiegenheit verpflichtet.
- ☐ Batterien prüfen und einen vollständigen Satz Ersatzbatterien einpacken; alle Leuchtmittel einzeln testen, Ersatzleuchtmittel bereitlegen, falls der Hersteller sie liefert.
- ☐ Den Ablauf mindestens zweimal vollständig proben, einmal davon vor einer Testperson: Exploration durch die Gruppe, eigene Behauptung „Die Farbe der Hülsen ist entscheidend", Umstecken der Hülsen, erneute Exploration, zweiter und dritter Modellwechsel. Die Übergänge zwischen den Phasen so einüben, dass sie ohne Blick auf Notizen sitzen.
- ☐ Sprechtext für den Abschluss festlegen (siehe „Am Tag selbst"). Die Haltung dazu steht in Markus Pfeils Kommentar zu Exposure und Grenzarbeit (*WuZ-Buch*, Anhang E): Methode nicht verraten, aber die *Richtung* andeuten.
- ☐ Für den 2-4-6-Test genügt Tafel oder Flipchart. Die Regel („drei aufsteigende Zahlen") nur im Kopf haben, nicht auf einem Zettel am Pult.

Handout und Übungsblatt

- ☐ Handout „Hypothesen und Falsifizierbarkeit" sowie Übungsblatt LE 5 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 5). Teil A enthält die fünf Aussagen für die Klassifikationsübung und liegt zu Beginn aus. Teil B (Rückblick auf das Schaltbrett, H_0/H_1-Vorlage) setzt mehrere Modellwechsel voraus und wird erst in der Anwendungsphase ausgeteilt.
- ☐ Pro Kleingruppe (4–5 Personen) ein A4-Blatt „Protokoll Schaltbrett" mit zwei Spalten *Eingabe* und *Beobachtung*; die Gruppen protokollieren ihre Versuche dort.
- ☐ Kleine Zettel (ca. A7) für die stille Regel-Notiz im 2-4-6-Test, einer pro Person.
- ☐ Die Forschungsfragen aus LE 2 bereithalten (Rücklauf aus der Hausaufgabe); jede Person braucht ihre eigene Frage für Aufgabe 3 (Übungsblatt Teil B).

Am Tag selbst

- ☐ Batterietest unmittelbar vor der Stunde, nicht am Vorabend.
- ☐ Das Brett auf einen Tisch stellen, um den die Gruppe stehen kann. Bei großen Gruppen eine Dokumentenkamera auf das Brett richten und die Exploration reihum an drei bis vier Personen delegieren.
- ☐ Tafel in drei Felder teilen: „Unser Modell", „Bestätigt durch", „Was würde es widerlegen?". Das dritte Feld bleibt in der ersten Runde absichtlich leer.
- ☐ Abschluss-Sprechtext (Grenzarbeit, sinngemäß): „Ich verrate Ihnen nicht, wie es funktioniert. Aber ich verrate Ihnen, wo Sie suchen müssten: Die Lösung liegt im Gerät. Es ist einfacher gebaut, als Sie denken, und komplizierter, als Ihr Modell erlaubt." Keine weitere Andeutung; Nachfragen nach der Stunde freundlich abweisen.

Risiken und Plan B. Fällt eine Lampe aus, wird das nicht überspielt: Ein Defekt ist eine echte Beobachtung, die jedes Modell erklären muss, und die Gruppe darf sie protokollieren. Ist das Gerät ganz unbrauchbar, beginnt die Einheit mit dem 2-4-6-Test als Staunmoment; die Zeit der Exploration (15 Min.) geht dann in einen ausführlicheren 2-4-6-Test und die Klassifikationsübung. Kommt jemand der Methode erkennbar nahe, weder bestätigen noch dementieren, sondern die Vermutung wie jede andere an die Tafel schreiben und fragen, wie man sie prüfen würde.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Aufgreifen von LE 2: „Ihre Forschungsfrage ist eine Frage. Heute wird daraus eine Behauptung, die sich irren kann."

5–20 · Staunmoment. Switchboard: Die Gruppe exploriert das Brett, protokolliert Eingaben und Beobachtungen und formuliert ein Modell. Dann die Behauptung der Lehrperson zur Farbe der Hülsen, Umstecken, neue Exploration; zwei bis drei Modellwechsel. Schlüsselfrage: „Welche Eingabe hätte Ihr Modell widerlegen können?"

20–50 · Theorie-Input. Induktion, Deduktion, Abduktion; Popper und die Falsifikation; Null- und Alternativhypothese; Horwichs graduelle Bestätigung und das Widerlegungsrisiko; Grenzen (Duhem-Quine).

50–60 · Brücke zum Bias. Wason-2-4-6 als Kurzübung: Die Gruppe bestätigt, statt zu prüfen.

60–80 · Anwendung. Klassifikationsübung mit fünf Aussagen (Übungsblatt Teil A, Aufgabe 1); dann Übungsblatt Teil B austeilen; jede Person formuliert für die eigene Frage H_0 und H_1 samt Widerlegungsbedingung (Aufgabe 3, Beginn in der Stunde).

80–90 · Sicherung. Kriterienraster „gute Hypothese"; Ausblick auf Testbarkeit und Forschungsdesign (LE 7).

5.1 Staunmoment: Das Schaltbrett

★ Staunmoment: Switchboard

Vier Schalter mit farbigen Hülsen, vier Lampen in denselben Farben. Die Leiterbahnen sind sichtbar.
Finden Sie heraus, wie das Brett funktioniert. Protokollieren Sie jede Eingabe und jede Beobachtung. Formulieren Sie ein Modell.

Danach: *Ich behaupte, die Leiterbahnen sind Dekoration. Entscheidend ist allein die Farbe der Hülse.*

Runde 1: Ihr Modell

- Welches Modell haben Sie gebildet?
- Wie viele Versuche haben es bestätigt?
- Hat irgendjemand eine Eingabe gewählt, von der er *erwartet* hat, dass sie das Modell bricht?
- Tafel: *Modell – Bestätigt durch – Was würde es widerlegen?*

Runde 2 und 3: neue Modelle

- nach dem Umstecken ist Ihr altes Modell widerlegt – durch *eine* Beobachtung
- das neue Modell („Farbe entscheidet") wird ebenso oft bestätigt wie das alte
- und hält ebenfalls nicht
- Was wissen Sie jetzt *sicher* über dieses Brett?

Der Ablauf folgt der Beschreibung, die Markus Pfeil in seinem Kommentar zu Exposure und Grenzarbeit gibt (*WuZ-Buch*, Anhang E): Die Studierenden explorieren das Brett, bilden eine Hypothese, testen sie und ziehen ein Fazit. Danach erklärt die Lehrperson, die Verdrahtung habe mit dem Schalten nichts zu tun, entscheidend seien die Farben von Hülse und Lampe, und steckt die Hülsen um: Nun schaltet jeder Schalter nicht mehr die Lampe, mit der er sichtbar verbunden ist, sondern die gleichfarbige. Dieser Wechsel wird einige Male wiederholt. Was bleibt, ist die Erfahrung, dass schon ein einfaches Schaltbrett zu kompliziert ist, um seine Funktionsweise aus Bestätigungen zu erraten, und dass sich nichts davon beweisen lässt.

Wichtig ist der Abschluss. Bleibt der Effekt ganz unkommentiert, schreiben Studierende ihn erfahrungsgemäß der Person zu, nicht dem Gerät, und verlieren damit die eigentliche Lehre: dass Systeme meist komplexer sind, als wir ihnen zugestehen. Der Hinweis, dass die Lösung im Gerät liegt, verschiebt die Wahrnehmung vom Mysterium zum Rätsel, ohne die Methode preiszugeben.

Wo liegt die Lösung?

- ich verrate die Methode nicht
- aber die Richtung: **die Lösung liegt im Gerät**
- Ihr Modell war zu einfach für ein Brett mit vier Schaltern
- Wie sicher sind Sie bei Systemen, die komplizierter sind als dieses?

5.2 Drei Arten zu schließen

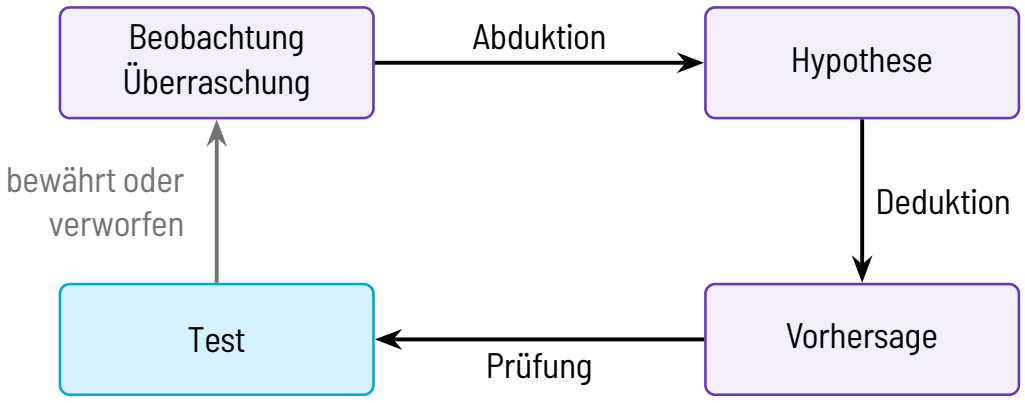
Beim Explorieren des Bretts haben die Gruppen drei verschiedene Schlussformen benutzt, meist ohne es zu bemerken. Aus einzelnen Beobachtungen („Schalter Rot schaltet Lampe Rot“, mehrfach) wurde eine allgemeine Regel: das ist **Induktion**. Aus der Regel wurde vorhergesagt, was beim nächsten Versuch passieren muss: das ist **Deduktion**. Und als etwas Unerwartetes geschah, wurde eine Erklärung gesucht, die das Unerwartete verständlich machen würde („Vielleicht gibt es eine zweite Leiterbahn auf der Rückseite“): das ist **Abduktion**, der Schluss auf die beste Erklärung, wie ihn Charles S. Peirce beschrieben hat. Wissenschaftliches Arbeiten braucht alle drei. Abduktion erzeugt Hypothesen, Deduktion leitet aus ihnen prüfbare Vorhersagen ab, und die Prüfung entscheidet, ob die Hypothese bleibt. Logisch zwingend ist nur die Deduktion; Induktion und Abduktion können bei wahren Prämissen zu falschen Schlüssen führen.

Induktion – Deduktion – Abduktion

	Schema	am Schaltbrett
Induktion	viele Fälle → Regel	„Fünfmal schaltete Rot die rote Lampe, also immer.“
Deduktion	Regel → Vorhersage	„Gelten die Bahnen, muss Schalter 2 Lampe 2 schalten.“
Abduktion	Überraschung → beste Erklärung	„Es gibt wohl eine verborgene Verbindung.“

- logisch zwingend ist nur die Deduktion

Der Forschungszyklus



- Hypothesen *entstehen* durch Abduktion, sie *bewähren* sich in Tests

Das Induktionsproblem

- kein Stapel von Bestätigungen macht eine allgemeine Aussage *gewiss*
- tausend weiße Schwäne beweisen nicht, dass alle Schwäne weiß sind
- ein einziger schwarzer Schwan widerlegt es
- am Schaltbrett: viele Bestätigungen, dann ein Umstecken – und das Modell ist weg

5.3 Popper: Falsifikation statt Verifikation

Karl Popper zog aus dem Induktionsproblem in der *Logik der Forschung* eine radikale Konsequenz (Popper 1934): Wenn sich allgemeine Aussagen nicht verifizieren lassen, dann besteht ihre Prüfung im ernsthaften Versuch, sie zu widerlegen. Eine Aussage ist wissenschaftlich, wenn sie prinzipiell an der Erfahrung scheitern kann. Sie gilt als *bewährt*, solange sie strengen Widerlegungsversuchen standhält, und bleibt dabei vorläufig.

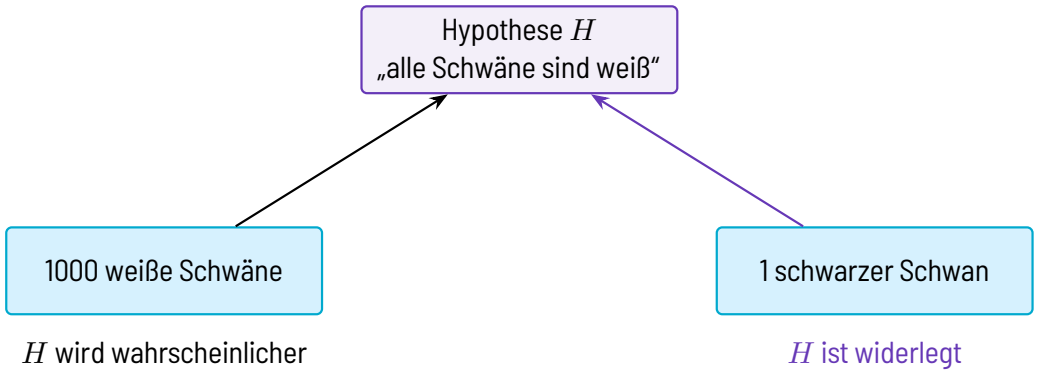
Für das Buch ist entscheidend, dass Popper damit weniger eine Eigenschaft von Sätzen als eine Haltung von Menschen beschreibt (*WuZ-Buch*, Kap. 5b). Eine Theorie wird nicht dadurch unwissenschaftlich, dass sie falsch ist; falsch sein darf jede. Unwissenschaftlich wird sie, wenn ihre Vertreter sie gegen jede Widerlegung abdichten. Popper nannte das *Immunisierung*. Sein Paradebeispiel war die Astrologie, deren Vertreter ihre Deutungen so vage hielten, dass nichts mehr als Widerlegung zählen konnte (Popper 1963). Dieses Beispiel steht übrigens nicht in der *Logik der Forschung*, sondern in *Conjectures and Refutations*. Die falsche Zuschreibung ist ein verbreiteter Zitierfehler und ein gutes Argument dafür, Primärquellen selbst zu lesen (LE 4).

Poppers Kriterium

Definition 5.1 Eine Aussage ist **falsifizierbar**, wenn sich mindestens eine mögliche Beobachtung angeben lässt, die ihr widerspräche. Sie gilt als **bewährt**, solange ernsthafte Widerlegungsversuche gescheitert sind. Bewiesen ist sie damit nicht.

- falsifizierbar heißt nicht falsch, sondern *prüfbar*
- Gegenbegriff: Immunisierung – die Aussage wird gegen jede Widerlegung abgedichtet

Die Asymmetrie



- Bestätigung ist graduell, Widerlegung kann schlagend sein

Riskante Vorhersagen

- eine Vorhersage, die auch bei falscher Theorie einträfe, prüft nichts

- je genauer und unwahrscheinlicher die Vorhersage, desto mehr ist ihr Eintreffen wert
- Beispiel: die Vorhersage der Position Neptuns 1846 – für einen Körper, den noch niemand gesehen hatte
- Gegenbeispiel: ein Horoskop, in dem sich jede Leserin wiederfindet

Immunisierung erkennen

- „Es wirkt, aber nicht unter Beobachtung."
- „Wenn es nicht klappt, war der Glaube zu schwach."
- Begriffe, die nachträglich so gedehnt werden, dass alles passt
- Test: *Welches Ergebnis würden Sie als Widerlegung akzeptieren?* Gibt es keins, ist die Aussage nicht prüfbar

5.4 Von der Vermutung zur Hypothese

Eine Vermutung ist ein Einfall. Eine Hypothese ist eine Vermutung, die so präzise gefasst ist, dass man sie prüfen kann. Drei Eigenschaften machen den Unterschied: *Präzision* (Was genau wird behauptet, über wen, unter welchen Bedingungen?), *Testbarkeit* (Welche Beobachtung würde widersprechen?) und *Reichweite* (Für welche Fälle soll die Aussage gelten?). Präzision entsteht durch *Operationalisierung*: Die Begriffe der Hypothese werden mit beobachtbaren Messvorschriften verbunden. Das Konzept ist aus LE 2 bekannt; hier wird es zur Bedingung der Falsifizierbarkeit. „Ehrliche Menschen schlafen besser" ist in dieser Form kaum prüfbar, weil weder „ehrlich" noch „besser schlafen" festgelegt ist. Erst mit einer Messvorschrift für beides, etwa einem etablierten Fragebogen zur Ehrlichkeit und der mit einem Aktivitätstracker gemessenen Schlafdauer über zwei Wochen, entsteht eine Aussage, die scheitern kann.

Vermutung oder Hypothese?

	Vermutung	**Hypothese**
Präzision	„Ehrliche schlafen besser."	Wer ist ehrlich? Was heißt besser? – festgelegt
Testbarkeit	offen	benannte Widerlegungsbedingung
Reichweite	unklar	Population, Bedingungen, Zeitraum

- Operationalisierung macht aus Begriffen Messvorschriften (LE 2)

Arten von Hypothesen

- **Unterschiedshypothese:** Gruppe A unterscheidet sich von Gruppe B in Merkmal Y
- **Zusammenhangshypothese:** X und Y hängen zusammen
- **Veränderungshypothese:** Y ändert sich zwischen Messzeitpunkt 1 und 2
- **gerichtet** („$A > B$") oder **ungerichtet** („$A \neq B$")

5.5 Null- und Alternativhypothese

In der empirischen Forschung, vor allem in der quantitativen, wird die eigene Vermutung als *Alternativhypothese* H_1 formuliert. Ihr gegenüber steht die *Nullhypothese* H_0, die behauptet, dass es den vermuteten Unterschied oder Zusammenhang nicht gibt. Geprüft wird formal die Nullhypothese: Die Daten werden daraufhin befragt, wie gut sie mit ihr vereinbar sind. Das wirkt umständlich, hat aber einen guten Grund. Die Nullhypothese ist präzise („Unterschied gleich null"), die Alternativhypothese meist nicht („irgendein Unterschied"), und präzise Aussagen lassen sich gezielt unter Druck setzen. Die Rechentechnik folgt in LE 6. Hier geht es darum, beide Hypothesen sauber zu formulieren und vorab festzulegen, welches Ergebnis zur Verwerfung der eigenen Hypothese führen würde (vgl. Döring und Bortz 2016a).

H_0 und H_1

- **H_1** (Alternativhypothese): Ihre Vermutung – es gibt einen Unterschied oder Zusammenhang
- **H_0** (Nullhypothese): es gibt ihn nicht
- beide schließen sich aus und decken zusammen alle Fälle ab
- geprüft wird H_0: Sind die Daten mit „kein Effekt" gut vereinbar?
- Rechnen kommt in LE 6 – heute: sauber formulieren

Beispiel

- Frage: Lernen Studierende mit Staunmoment mehr?
- H_1: Wer vor einem Lehrvideo einen Zaubertrick sieht, löst eine Transferaufgabe häufiger richtig als wer ihn nicht sieht
- H_0: Die Lösungsquoten unterscheiden sich nicht
- Widerlegungsbedingung (vorab festgelegt): gleiche oder niedrigere Quote in der Trickgruppe

Das Beispiel ist nicht erfunden: Es ist die Leitfrage der Becher-Monty-Hall-Studien aus dem Buch (*WuZ-Buch*, Kap. 12d und 12f), die in LE 7 als Fallbeispiel für Forschungsdesign wiederkehren. Dort zeigt sich auch, wie wichtig eine vorab festgelegte Widerlegungsbedingung ist: Ein Zwischenstand der Feldstudie wies in die erhoffte Richtung und verschwand mit wachsender Stichprobe.

5.6 Horwich: Bestätigung hat Grade

Poppers Asymmetrie lässt sich wahrscheinlichkeitstheoretisch genauer fassen. Paul Horwich hat in *Probability and Evidence* gezeigt, dass viele Rätsel der Wissenschaftstheorie verschwinden, sobald man Überzeugung als graduell behandelt (Horwich 1982). Folgt eine Beobachtung E logisch aus einer Hypothese H und tritt sie nicht ein, dann ist H widerlegt: $P(H \mid \neg E) = 0$. Tritt E dagegen ein, gilt nur $P(H \mid E) > P(H)$. Die Hypothese wird wahrscheinlicher, bewiesen ist sie nicht. Wie viel wahrscheinlicher, hängt davon ab, wie unwahrscheinlich E ohnehin war: Impliziert H die Beobachtung E, ist der Bestätigungsfaktor $P(H \mid E)/P(H) = 1/P(E)$. Eine Vorhersage, die sowieso jeder erwartet hätte, bringt also fast nichts.

Horwichs Auflösung des Rabenparadoxons führt das an einem Bild vor (*WuZ-Buch*, Kap. 5b, Horwichs Theorie der Evidenz): Wer einen Raben prüft und ihn schwarz findet, hat die Hypothese „alle Raben sind schwarz" einem Risiko ausgesetzt. Wer ein schwarzes Objekt prüft und feststellt, dass es ein Rabe ist, hat nichts riskiert. Nur Beobachtungen, die ein Widerlegungsrisiko eingehen, haben vollen Beweiswert.

Bestätigung ist graduell

- tritt die vorhergesagte Beobachtung *nicht* ein: $P(H \mid \neg E) = 0$ – widerlegt
- tritt sie ein: nur $P(H \mid E) > P(H)$ – wahrscheinlicher, nicht bewiesen
- Stärke der Bestätigung: $P(H \mid E) \,/\, P(H) = 1/P(E)$
- **je unwahrscheinlicher die Vorhersage, desto stärker die Bestätigung**

Das Widerlegungsrisiko

- einen *Raben* prüfen und schwarz finden: echter Test
- etwas *Schwarzes* prüfen und einen Raben finden: kein Test
- am Schaltbrett: „Rot schaltet Rot" zum zehnten Mal prüfen ist der schwarze Gegenstand
- Regel: *Wählen Sie den Versuch, dessen Ausgang Sie am wenigsten sicher vorhersagen können.*

Merke

Bestätigungen sammeln ist billig. Eine Beobachtung ist nur so viel wert wie das Risiko, das die Hypothese mit ihr eingegangen ist. Fragen Sie deshalb nicht „Was spricht für meine Hypothese?", sondern „Was würde mich umstimmen?"

5.7 Grenzen der Falsifikation: Duhem-Quine

Auch die Widerlegung ist weniger eindeutig, als Poppers Schwan suggeriert. Pierre Duhem hat für die Physik gezeigt, dass eine Hypothese nie allein geprüft wird, sondern immer zusammen mit Hilfsannahmen über Messgeräte, Versuchsaufbau und Randbedingungen (Duhem 1906). Widerspricht ein Experiment der Vorhersage, sagt die Logik nur, dass *irgendein* Glied der Kette falsch ist, nicht welches. Willard Van Orman Quine hat den Gedanken auf das gesamte Wissenssystem ausgeweitet (Quine 1951). Am Schaltbrett ist das unmittelbar zu sehen: Leuchtete eine Lampe nicht wie vorhergesagt, konnte man das Modell verwerfen oder eine Hilfsannahme („Lampe defekt", „Batterie schwach", „falsch geschaltet"). Daraus folgt nicht, dass Falsifikation wertlos ist. Es folgt, dass Hilfsannahmen offengelegt und, wo möglich, unabhängig geprüft werden müssen. Ad-hoc-Rettungen, die nur dazu dienen, eine Hypothese gegen ein unbequemes Ergebnis zu schützen, sind genau die Immunisierung, vor der Popper warnt. Imre Lakatos hat daraus ein Kriterium gemacht: Ein Forschungsprogramm schreitet fort, wenn seine Anpassungen neue, prüfbare Vorhersagen liefern, und degeneriert, wenn sie nur Löcher stopfen (Lakatos 1970).

Duhem-Quine-These

- geprüft wird nie H allein, sondern H *plus* Hilfsannahmen $A_1, A_2, \ldots$ (Messgerät, Aufbau, Randbedingungen)
- widerspricht das Ergebnis, ist *irgendetwas* falsch – aber was?
- Schaltbrett: Modell falsch – oder Lampe defekt? Batterie schwach?
- Konsequenz: Hilfsannahmen offenlegen und eigens prüfen

Rettung oder Ausrede?

- legitim: eine Hilfsannahme, die man *unabhängig* prüfen kann (Lampe tauschen, Versuch wiederholen)
- Ausrede: eine Zusatzannahme, die nur dazu dient, das Ergebnis wegzuerklären
- Lakatos: fortschreitende Forschungsprogramme sagen durch ihre Anpassungen *Neues* voraus, degenerierende nicht

5.8 Brücke zum Bias: der 2-4-6-Test

Dass die Gruppe am Schaltbrett fast nur bestätigende Eingaben gewählt hat, ist kein Zufall. Peter Wason hat diese Neigung 1960 mit einer einfachen Zahlenaufgabe sichtbar gemacht (Wason 1960): Die Versuchspersonen sollten die Regel hinter dem Tripel „2–4–6" finden, indem sie eigene Tripel vorschlugen. Die Regel war weit gefasst („drei aufsteigende Zahlen"); die meisten bildeten eine engere Hypothese und testeten nur Tripel, die dazu passten. Nur sechs von 29 Personen fanden die Regel ohne falschen Zwischenschluss. Jonathan Baron nennt die Neigung, eine Hypothese ausschließlich direkt zu prüfen, *Congruence Bias* (Baron u. a. 1988). Fair bleibt der Hinweis von Klayman und Ha (1987): Die *positive Teststrategie* ist in vielen Umgebungen eine gute Heuristik. Sie versagt dort, wo die wahre Regel weiter ist als die eigene Hypothese, und das kommt in der Forschung häufig vor. Der Ablauf unten folgt der Unterrichtsfassung des Buchs (*WuZ-Buch*, Kap. 10, Der 2-4-6-Test), auf zehn Minuten gekürzt.

Die Regel finden

2 4 6

- diese drei Zahlen folgen einer Regel, die ich mir ausgedacht habe
- schlagen Sie eigene Tripel vor – ich sage nur *Ja* oder *Nein*
- nennen Sie die Regel erst, wenn Sie ganz sicher sind

Ablauf 2-4-6-Test (10 Min.)

1 Min. „2–4–6" an die Tafel, Auftrag wie auf der Folie.

4 Min. Vorschläge aus dem Plenum, jeweils mit *Ja* oder *Nein* in zwei Spalten an der Tafel protokollieren. Typisch sind 8–10–12, 20–22–24, 100–102–104: alles *Ja*.

1 Min. Jede Person notiert still ihre vermutete Regel auf einem Zettel.

2 Min. Frage: „Hat jemand ein Tripel vorgeschlagen, bei dem er ein *Nein* erwartet hat?" Meist niemand. Dann gezielt widersprechende Tripel testen lassen: 1–2–3 (*Ja*), 3–2–1 (*Nein*), 2–4–5 (*Ja*).

2 Min. Auflösung: „drei aufsteigende Zahlen". Rückbezug auf das Schaltbrett und auf Horwichs Raben: Die bestätigenden Tripel waren schwarze Gegenstände.

Was ist passiert?

- die Regel war: **drei aufsteigende Zahlen**
- fast alle Vorschläge passten zur eigenen, engeren Hypothese – und bekamen ein *Ja*
- Wason 1960: nur 6 von 29 Personen fanden die Regel ohne falschen Zwischenschluss
- **Congruence Bias**: man testet nur die eigene Hypothese, nie die Alternativen
- Gegenmittel (Baron): Alternative benennen, dann den Test wählen, der zwischen beiden *unterscheidet*

5.9 Übung in der Stunde

Falsifizierbar oder nicht? (Kleingruppen, 10 Min.)

- Übungsblatt Teil A, Aufgabe 1: fünf Aussagen
- Welche sind falsifizierbar – so, wie sie dastehen?
- für jede prüfbare Aussage: eine konkrete Widerlegungsbedingung
- für jede vage Aussage: eine präzisierte, prüfbare Fassung

Ihre eigene Hypothese (Einzelarbeit, 10 Min.)

- nehmen Sie Ihre Forschungsfrage aus LE 2
- formulieren Sie H_1 und H_0
- Welche Begriffe müssen Sie operationalisieren?
- Bei welchem Ergebnis würden Sie H_1 verwerfen?
- Tausch mit der Nachbarin: Würde *sie* Ihre Widerlegungsbedingung akzeptieren?

Hinweis für Lehrende

Bei der Klassifikationsübung lohnt es, auf zwei Fehler zu achten. Erstens wird „falsifizierbar" oft mit „falsch" oder „unbewiesen" verwechselt; hier hilft die Frage, welche Beobachtung der Aussage widersprechen würde. Zweitens halten viele Gruppen vage Aussagen pauschal für nicht falsifizierbar. Die bessere Antwort ist meist: „In dieser Form nicht prüfbar, aber präzisierbar." Bei der eigenen Hypothese zeigt der Partnertausch schnell, ob

die Widerlegungsbedingung beobachtbar ist. Formulierungen wie „wenn es nicht stimmt“ oder „wenn kein Zusammenhang besteht“ ohne Messung und Kriterium reichen nicht. Der vollständige Erwartungshorizont steht am Ende von Teil B des Übungsblatts.

5.10 Sicherung: Was ist eine gute Hypothese?

Kriterienraster

Kriterium	Prüffrage
präzise	Sind alle Begriffe operationalisiert?
falsifizierbar	Welches Ergebnis würde ihr widersprechen?
riskant	Wäre das Ergebnis ohne die Hypothese unwahrscheinlich?
begrenzt	Für wen, wann, unter welchen Bedingungen gilt sie?
begründet	Woraus folgt sie (Theorie, Literatur, Beobachtung)?
offen	Sind die Hilfsannahmen benannt?

Merke

Eine Hypothese ist gut, wenn sie scheitern *kann* und Sie vorher sagen können, woran. Bewährt ist sie, wenn sie solche Versuche überstanden hat. Bewiesen ist sie nie.

5.11 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- Induktion, Deduktion und Abduktion unterscheiden
- Hypothesen nach dem Falsifikationskriterium bewerten
- empirisch prüfbare von nicht prüfbaren Aussagen unterscheiden
- eigene Hypothesen operationalisierbar formulieren, mit H_0, H_1 und Widerlegungsbedingung
- erklären, warum Bestätigung graduell ist und Widerlegung an Hilfsannahmen hängt

Bis zur nächsten Woche

- **Übungsblatt**, Aufgabe 1 (Teil A) und 2 (Teil B) fertigstellen
- **schriftlich** (Aufgabe 3): H_0 und H_1 zu Ihrer Forschungsfrage, mit den Bedingungen, unter denen Sie Ihre Hypothese verwerfen würden
- **Tagebuch des Staunens:** ein Erlebnis dieser Woche, bei dem Sie etwas nur bestätigt statt geprüft haben
- Vorbereitung LE 6: Welches Ergebnis würde Ihre Hypothese widerlegen, und wie viele Beobachtungen bräuchten Sie, um es zu sehen?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 5**

Handout: Hypothesen und Falsifizierbarkeit

Worum es heute ging. Ein Schaltbrett mit vier Schaltern und vier Lampen: Sie haben ein Modell gebildet und es oft bestätigt gesehen. Dann genügte ein Umstecken, und das Modell war widerlegt. Viele Bestätigungen machen eine allgemeine Aussage nicht gewiss; eine einzige Gegenbeobachtung kann sie zu Fall bringen. Die Lösung des Bretts liegt im Gerät, und es ist komplizierter, als Ihr Modell erlaubt hat.

Kernbegriffe

Induktion / Deduktion / Abduktion von Fällen auf eine Regel / von der Regel auf eine Vorhersage / von einer Überraschung auf die beste Erklärung. Logisch zwingend ist nur die Deduktion.

Falsifizierbarkeit Eine Aussage ist prüfbar, wenn sich eine Beobachtung angeben lässt, die ihr widerspräche (Popper 1934). Bewährt heißt: Widerlegungsversuche sind gescheitert. Bewiesen ist damit nichts.

Immunisierung eine Aussage wird so formuliert oder nachträglich angepasst, dass nichts sie widerlegen kann.

H_0 / H_1 Nullhypothese (kein Unterschied, kein Zusammenhang) und Alternativhypothese (Ihre Vermutung). Geprüft wird, ob die Daten mit H_0 vereinbar sind.

Graduelle Bestätigung Tritt eine vorhergesagte Beobachtung E ein, steigt nur die Wahrscheinlichkeit von H, und zwar umso mehr, je unwahrscheinlicher E vorher war (Horwich 1982).

Duhem-Quine Geprüft wird immer die Hypothese *samt* Hilfsannahmen; ein Widerspruch sagt nicht, welches Glied falsch ist.

Congruence Bias nur die eigene Hypothese direkt testen, nie die Alternativen (Wason-2-4-6-Test).

Raster: Ist meine Hypothese gut?

präzise	Sind alle Begriffe operationalisiert?
falsifizierbar	Welches Ergebnis würde ihr widersprechen?
riskant	Wäre das Ergebnis ohne die Hypothese unwahrscheinlich?
begrenzt	Für wen, wann, unter welchen Bedingungen gilt sie?
begründet	Woraus folgt sie: Theorie, Literatur, Beobachtung?
offen	Sind die Hilfsannahmen benannt?

Merke

Fragen Sie nicht „Was spricht für meine Hypothese?“, sondern „Was würde mich umstimmen?“ Eine Beobachtung ist nur so viel wert wie das Risiko, das die Hypothese mit ihr eingegangen ist.

Zum Weiterlesen: Popper (1934); Wason (1960); zur Vertiefung Horwich (1982).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 5**

Übungsblatt A: Hypothesen und Falsifizierbarkeit

Name: _____ Datum: _____

Aufgabe 1: Falsifizierbar oder nicht?

in der Stunde, Kleingruppe, 10 Min.

Entscheiden Sie für jede Aussage, ob sie *in der vorliegenden Form* falsifizierbar ist (ja / nein / erst nach Präzisierung). Falsifizierbar heißt: Es lässt sich eine Beobachtung angeben, die der Aussage widerspräche. Geben Sie für jede prüfbare Aussage eine konkrete Beobachtung an, die sie widerlegen würde. Formulieren Sie vage Aussagen so um, dass sie prüfbar werden. (Die Aussagen sind für diese Übung konstruiert.)

A1 „Ehrliche Menschen schlafen besser."

A2 „Studierende, die in der Woche vor der Klausur im Mittel mindestens sieben Stunden pro Nacht schlafen, erzielen in dieser Klausur im Mittel mehr Punkte als Studierende mit weniger als fünf Stunden."

A3 „Alles, was geschieht, geschieht aus einem Grund, auch wenn wir ihn nicht immer erkennen können."

A4 „Astrologinnen und Astrologen können einem Geburtshoroskop häufiger als zufällig das passende von drei Persönlichkeitsprofilen zuordnen."

A5 „Das Mittel wirkt bei allen, die offen dafür sind. Wer keine Wirkung spürt, war innerlich nicht bereit."

Nr.	**falsifizierbar?**	**Widerlegungsbedingung bzw. präzisierte Fassung**
A1		
A2		
A3		
A4		
A5		

Übungsblatt B: Schaltbrett und eigene Hypothese

Name: _____ Datum: _____

Aufgabe 2: Das Schaltbrett im Rückblick

in der Stunde oder Hausaufgabe

1. Notieren Sie das Modell, das Ihre Gruppe in Runde 1 gebildet hat, und die Zahl der Versuche, die es bestätigt haben.

2. Welche *eine* Eingabe hätte Ihr Modell am stärksten gefährdet? Begründen Sie mit Horwichs Widerlegungsrisiko: Ein Test bestätigt umso stärker, je unwahrscheinlicher sein Ausgang ohne das Modell wäre.

3. Nennen Sie zwei Hilfsannahmen, die Sie beim Explorieren stillschweigend gemacht haben (Duhem-Quine: Geprüft wird immer das Modell *samt* solcher Annahmen).

Aufgabe 3: Null- und Alternativhypothese für Ihre Forschungsfrage

Beginn in der Stunde, Abgabe bis LE 6

Meine Forschungsfrage (aus LE 2)	
Art der Hypothese (Unterschied / Zusammenhang / Veränderung; gerichtet?)	
H_1 (Alternativhypothese)	
H_0 (Nullhypothese)	
Operationalisierung: Begriff → Messvorschrift	
Population, Bedingungen, Zeitraum	
Ich verwerfe H_1, wenn …	
Hilfsannahmen, die ich dabei mache	

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Beschreiben Sie ein Erlebnis dieser Woche, in dem Sie (oder jemand anderes) eine Annahme nur bestätigt statt geprüft haben. Welcher Versuch hätte die Annahme wirklich gefährdet?

Erwartungshorizont

Aufgabe 1. A1: in dieser Form nicht prüfbar, weil „ehrlich" und „besser schlafen" unbestimmt sind; präzisierbar, z. B. „Erwachsene mit höheren Werten in einem validierten Fragebogen zur Ehrlichkeit haben über zwei Wochen eine längere, per Aktivitätstracker gemessene Schlafdauer"; widerlegt, wenn kein oder ein negativer Zusammenhang auftritt. A2: falsifizierbar; widerlegt, wenn die Gruppe mit mindestens sieben Stunden im Mittel gleich viele oder weniger Punkte erzielt. Gute Antworten bemerken, dass ein solcher Befund noch keine Kausalität zeigt (Brücke zu LE 7). A3: nicht falsifizierbar; der Zusatz „auch wenn wir ihn nicht erkennen" schließt jede Gegenbeobachtung aus. A4: falsifizierbar; widerlegt, wenn die Trefferquote im Doppelblindversuch nicht über einem Drittel liegt. So wurde die Aussage tatsächlich geprüft (Carlson 1985), mit einem Ergebnis auf Zufallsniveau. A5: immunisiert; jede ausbleibende Wirkung wird der Person zugeschrieben. Prüfbar wird die Aussage erst, wenn „offen dafür" unabhängig und *vor* der Einnahme gemessen wird. **Aufgabe 2.** Bewertet wird, ob die gewählte Eingabe einen Ausgang hat, den das Modell *nicht* sicher vorhersagt, und ob als Hilfsannahmen z. B. funktionierende Lampen, volle Batterien, Gleichheit von sichtbarer und tatsächlicher Verdrahtung genannt werden. **Aufgabe 3.** H_0 und H_1 schließen sich aus; die Verwerfungsbedingung nennt eine Messung und ein Kriterium; die Operationalisierung deckt alle Begriffe der Hypothese ab.

6 Statistik: Signifikanztest und Bayes

Bis hierher hat das Semester gefragt, wie man eine Frage stellt, wie man Quellen prüft und wie man aus einer Vermutung eine Hypothese macht, die scheitern kann. Bevor in LE 7 das Forschungsdesign gebaut wird, führt diese Einheit das Werkzeug ein, mit dem man Daten befragt: die Statistik. Sie kommt bewusst vor dem Design, denn wer weiß, welche Fragen sich mit zwanzig oder dreißig Versuchspersonen überhaupt beantworten lassen, plant anders. Weil die Grundbegriffe sorgfältig eingeführt werden sollen, umfasst die Einheit **zwei Doppelstunden**.

Die *erste Sitzung* beginnt mit drei Bechern und einer Abstimmung, bei der die Mehrheit fast immer danebenliegt. Das ist der eigentliche Grund, warum es Statistik gibt: Unser Gefühl für Wahrscheinlichkeiten ist schlecht geeicht, und zwar nicht zufällig, sondern systematisch. Von dort baut die Sitzung das Handwerkszeug auf: Lage und Streuung, Standardabweichung, den Unterschied zwischen Stichprobe und Grundgesamtheit, den Standardfehler, den Zentralen Grenzwertsatz, der erklärt, warum Mittelwerte so verlässlich normalverteilt sind, das Konfidenzintervall und schließlich den Signifikanztest mit p-Wert und t-Test. Die Studierenden würfeln den Grenzwertsatz selbst an die Tafel.

Die *zweite Sitzung* stellt der frequentistischen Frage (Wie überraschend wären die Daten, wenn nichts dahintersteckt?) die bayesianische gegenüber (Wie stark unterscheiden die Daten zwischen zwei Hypothesen, und was sollte man danach glauben?). Durch alle Beispiele zieht sich die *Basisrate*: Wie häufig ist das Gesuchte überhaupt? Ohne sie lässt sich weder ein positiver Test noch ein signifikanter Befund deuten. Die Studierenden rechnen selbst, als Würfel-Detektive und beim Glaubwürdigkeits-Check einer Behauptung aus dem Netz. Zum Schluss lernen sie eine Arbeitsabfolge, mit der man eine eigene Idee in Gegenhypothesen zerlegt (die Diamond-Technik aus dem Coaching, übersetzt in Forschungsfragen), und halten das Ergebnis auf einer Landkarte fest, die direkt in die Design-Skizze von LE 7 führt.

Die Grafiken der Einheit sind mit Python erzeugt (`tools/le06_figuren.py`); die Simulationen haben feste Startwerte und lassen sich für eigene Varianten leicht abwandeln.

Vorbereitung vor der Stunde: Monty Hall mit drei Bechern (optional: Chop Cup), Würfel-Experimente

Eine Woche vor Sitzung 1

- ☐ Für die Vorführung: drei *undurchsichtige*, gleich aussehende Becher und eine gut sichtbare Kugel (Schaumstoffball, Walnuss). Die Becher müssen von hinten im Saal zu sehen sein; bei großen Räumen eine Dokumentenkamera einplanen.
- ☐ Für das Nachspielen in Paaren: je Paar drei undurchsichtige Pappbecher, eine Kugel (Papierkugel, Erbse, Münze) und ein Würfel. Bei 30 Studierenden 15 Sets plus drei Reserve. Pappbecher und Würfel gibt es im Haushalts- bzw. Spielwarenhandel. Würfel und Becher werden für das Grenzwertsatz-Experiment (Sitzung 1) und die Würfel-Detektive (Sitzung 2) wiederverwendet.
- ☐ Die drei Fälle und die Gegenprobe mit dem blinden Moderator (Buch, Kap. 12d, Beats 2–6) so oft mit echten Bechern durchspielen, dass sie ohne Folie frei erklärt werden können.
- ☐ Optional als Staunmoment des Vortragenden: eine *Chop-Cup-Routine* (ca. 2 Min.). Das Requisit gibt es im Zauberfachhandel. Methode und Einstudierung nach der Anleitung des Herstellers bzw. der Standardliteratur; hier bewusst nicht beschrieben. Die Routine muss sitzen, bevor sie vor Publikum gezeigt wird: mindestens zehn Durchläufe vor dem Spiegel und einer vor einer Testperson.
- ☐ Für das Grenzwertsatz-Experiment an der Tafel eine Zahlengerade von 1 bis 6 in Schritten von 0,2 vorzeichnen (Plan B: Flipchart oder eine geteilte Tabelle, in die alle ihre Mittelwerte eintragen).
- ☐ Rechenbeispiele der Folien einmal selbst mit dem Taschenrechner durchrechnen, damit sie live an der Tafel gelingen.

Eine Woche vor Sitzung 2

- ☐ Für die Würfel-Detektive je Paar einen verschlossenen Umschlag mit einer Rollenkarte vorbereiten. Auf vier von fünf Karten steht „*fair*: Treffer ist nur die 6", auf jeder fünften „*gezinkt*: Treffer sind 5 und 6". Bei 15 Paaren also 12 faire und 3 gezinkte Karten. Die Umschläge mischen; welches Paar welche Karte hat, weiß auch die Lehrperson nicht. So ist die Trefferwahrscheinlichkeit genau $\frac{1}{6}$ bzw. $\frac{1}{3}$, und die Basisrate (ein Fünftel) ist bekannt. Echte Mogelwürfel aus dem Scherzartikelhandel gehen auch, ihre Schieflage ist aber unbekannt; dann fehlt dem Bayes-Faktor die konkrete Alternativhypothese.
- ☐ Für den Glaubwürdigkeits-Check fünf bis sechs Behauptungen auf Karten schreiben (Vorschläge im Hinweis zum Glaubwürdigkeits-Check), darunter mindestens zwei zutreffende. Die Studierenden per Mail bitten, ein Smartphone oder Notebook mitzubringen; WLAN prüfen.
- ☐ Für die Landkarten-Hausaufgabe A3-Blätter bereitlegen (je Person eins) oder in der Ankündigung darum bitten.

Handout und Übungsblatt

- ☐ Handout „Statistik: Signifikanztest und Bayes" sowie Übungsblatt LE 6 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 6). **Teil A** liegt zu Beginn von Sitzung 1 aus: Strichliste für das Monty-Hall-Spiel, das Grenzwertsatz-Experiment und der fiktive Datensatz ($n = 50$) für die Hausaufgabe. **Teil B** liegt zu Beginn von Sitzung 2 aus: Würfel-Detektive mit Rechentabelle, Basisrate, Glaubwürdigkeits-Check, Zeitungsmeldung, Diamant und Auswertungsplan. Das Handout gibt es nach Sitzung 2.
- ☐ Taschenrechner bzw. Smartphone-Rechner erlauben; die Rechnungen auf den Folien brauchen nur Grundrechenarten, Wurzeln und Potenzen.

Am Tag selbst

- ☐ Sitzung 1: Tafel in vier Felder teilen: *Abstimmung* (wechseln / bleiben / egal), *Kursdaten Becher*, *Würfel-Mittelwerte* (Zahlengerade), *Fragen*.
- ☐ Sitzung 2: Feld für die Vierfeldertafel der Würfel-Detektive (fair/gezinkt $\times$ signifikant/nicht signifikant) und eine Spalte „Bayes-Urteil".
- ☐ Becher-Sets vor Beginn auf die Tische verteilen, aber gestapelt lassen, damit niemand vorher experimentiert. Die Umschläge erst zu Beginn der Würfelübung austeilen.
- ☐ Falls die Chop-Cup-Routine gezeigt wird: das präparierte Requisit danach sichtbar wegräumen und das

Monty-Hall-Spiel mit gewöhnlichen Bechern spielen, die man den Studierenden in die Hand gibt. Ein Spiel, dessen Requisiten man misstraut, liefert keine brauchbaren Daten.

Risiken und Plan B. Ein Teil des Kurses kennt das Ziegenproblem. Das schadet nicht, es ist ein Datum: Vor der Abstimmung fragen, wer das Rätsel schon kennt, und beide Gruppen getrennt auszählen. Die Feldstudie des Buchs zeigt, wie stark Vorwissen wirkt (Kap. 12f; siehe Abschnitt „Effektgröße und Power"). Laufen die Paarspiele schleppend, nach 15 Durchgängen abbrechen; der Kurs-Pool reicht dann immer noch für die Rechnung. In Sitzung 2 gilt: Wird die Zeit knapp, wird der Glaubwürdigkeits-Check im Plenum an einer einzigen Behauptung vorgeführt und als Hausaufgabe (Teil B, Aufgabe 6) zu Ende gebracht; die Würfel-Detektive sollten dagegen nicht ausfallen, weil sie Fehler 1. Art, Power und Basisrate in einer einzigen Vierfeldertafel erlebbar machen. Die Münzwurf-„Hellseher"-Demo ist optional; sie kehrt in LE 10 ausführlich wieder.

Ablauf der ersten Doppelstunde (90 Min.)

0–10 · Staunmoment. Optional die Chop-Cup-Routine. Dann Monty Hall live mit drei Bechern; Abstimmung wechseln / bleiben / egal. Ergebnis an die Tafel, ohne Kommentar.

10–20 · Nachspielen. 20–24 Durchgänge in Paaren nach festen Regeln (Würfel legt die Kugel, Strategie wechselt jede Runde), Strichliste auf dem Übungsblatt Teil A (Aufgabe 1). Summen an die Tafel.

20–30 · Auflösung. Die drei Fälle, der blinde Moderator, bedingte Wahrscheinlichkeit. Beschreiben und Schließen, Skalenniveaus.

30–42 · Lage und Streuung. Mittelwert und Median, die Standardabweichung Schritt für Schritt an der Tafel, Boxplot und Ausreißer.

42–62 · Von der Stichprobe zur Grundgesamtheit. Parameter und Kennwerte, Standardfehler, Grenzwertsatz-Experiment mit Würfeln (Teil A, Aufgabe 2), Normalverteilung und z-Wert, Konfidenzintervall.

62–85 · Der Signifikanztest. Logik; der Kurs-Pool Schritt für Schritt mit den echten Kursdaten; t-Test von Hand; zwei Arten, sich zu irren; was der p-Wert nicht sagt.

85–90 · Ausblick. Hausaufgabe Datensatz-Analyse (Teil A, Aufgabe 3); Vorschau auf Sitzung 2: Was fehlt dem p-Wert?

Ablauf der zweiten Doppelstunde (90 Min.)

0–5 · Rückblick. Teil B austeilen. Eine Frage an den Kurs: „$p = 0{,}02$ – wie wahrscheinlich ist H_0?" Antworten sammeln, nicht auflösen.

5–15 · Zwei Arten, Daten zu befragen. Würfeltest frequentistisch; der Medizintest als Baum mit natürlichen Häufigkeiten.

15–32 · Basisrate und Bayes. Wie viele signifikante Befunde stimmen; Bayes in Chancenform; derselbe Würfel bayesianisch; der Posterior wandert mit den Daten; Bayes-Faktor zum t-Test; Vergleich der beiden Schulen.

32–47 · Würfel-Detektive. Spielregeln erklären, Paare, 30 Würfe, beide Auswertungen (Teil B, Aufgabe 4), Auflösung, Vierfeldertafel an der Tafel.

47–60 · Glaubwürdigkeits-Check. Das Schokoladen-Beispiel vorrechnen, dann Kleingruppen mit je einer Behauptung und einer Suchmaschine (Aufgabe 6); zwei Gruppen berichten.

60–68 · Was kann Ihr Projekt beantworten? Effektgröße, Power, Folgerungen für das Design.

68–88 · Diamant und Landkarte. Den Diamanten zum Zaubertrick-Beispiel gemeinsam an der Tafel füllen, Ta-

belle „Welche Beobachtung trennt?“, Beispielkarte zeigen; Beginn des eigenen Diamanten in Paaren (Aufgabe 8).

88–90 · Hausaufgaben. Handout austeilen.

6.1 Staunmoment: Drei Becher

★ Staunmoment: Wechseln oder bleiben?

Unter einem von drei Bechern liegt eine Kugel. Sie zeigen auf einen. Ich weiß, wo die Kugel ist, und hebe einen *anderen*, leeren Becher hoch.
Bleiben Sie bei Ihrem Becher – oder wechseln Sie zum anderen? Oder ist es egal?

Abstimmung

- Hand hoch: **bleiben** – **wechseln** – **egal**
- Wer kennt das Rätsel schon? (getrennt zählen)
- Wie sicher sind Sie? Schätzen Sie in Prozent.

Die Abstimmung wird an der Tafel festgehalten und vorerst nicht kommentiert. In der Regel stimmt die Mehrheit für „egal“, oft mit hoher Sicherheit. Das Rätsel ist als *Ziegenproblem* bekannt geworden; es geht auf Selvin (1975) zurück und wurde durch die Kolumne von vos Savant (1990) berühmt, auf die zahlreiche Leserbriefe mit der Behauptung antworteten, die Lösung sei falsch. Krauss und Wang (2003) zeigen, wie hartnäckig die Fehlintuition ist und welche Darstellungen helfen.

Nachspielen: die Regeln

- in Paaren: eine Person ist *Spielleitung*, eine spielt
- Spielleitung würfelt verdeckt: 1–2 Becher A, 3–4 B, 5–6 C
- Spielleitung kennt die Lage und öffnet immer einen *leeren* Becher, nie den gewählten
- ungerade Runden: **bleiben**, gerade Runden: **wechseln**
- 20–30 Runden, Strichliste auf dem Übungsblatt Teil A

Die Regeln sind bereits ein kleines Forschungsdesign. Der Würfel sorgt für eine zufällige Lage der Kugel, damit die Spielleitung nicht unbewusst Lieblingsbecher bevorzugt. Die feste Abfolge von Bleiben und Wechseln verhindert, dass die spielende Person ihre Strategie nach Gefühl wählt und damit die Vergleichbarkeit der beiden Strategien zerstört. Hat die spielende Person zufällig den Becher mit der Kugel gewählt, entscheidet ein zweiter Wurf (gerade oder ungerade), welchen der beiden leeren Becher die Spielleitung öffnet.

Was sagen die Daten?

- Kursdaten an der Tafel: Gewinne beim **Bleiben** und beim **Wechseln**
- Passt das zu „egal“?
- Was müsste herauskommen, wenn es egal wäre?
- Wie groß darf die Abweichung sein, bevor wir „egal“ aufgeben?

Mit der letzten Frage ist die Einheit beim Kern der schließenden Statistik angekommen, noch bevor das Wort fällt. Die Gruppe hat eine Hypothese („egal“, also Gewinnchance $\frac{1}{2}$ beim Wechseln), eine Stichprobe (die Strichlisten) und eine Abweichung, deren Gewicht sie beurteilen muss.

6.2 Auflösung: bedingte Wahrscheinlichkeit

Die Auflösung folgt der Becher-Erklärung aus dem Buch (Kap. 12d, Beats 2–6). Der Vorgang hat zwei Stufen: Zuerst liegt die Kugel zufällig unter einem von drei Bechern, jeder mit Wahrscheinlichkeit $\frac{1}{3}$. Dann öffnet die Spielleitung einen Becher, aber nicht irgendeinen: nie den gewählten und nie den mit der Kugel. Die Fehlintuition „zwei Becher, also fifty-fifty" beruht auf der stillen Annahme, die beiden übrigen Becher seien gleichberechtigt. Das sind sie nicht. Der gewählte Becher wurde nie angefasst; der andere ist der Überlebende einer Auswahl, die mit Wissen getroffen wurde.

Die drei Fälle

Kugel liegt …	Wahrsch.	Spielleitung öffnet	Wechseln
unter Ihrem Becher 1	$\frac{1}{3}$	Becher 2 oder 3	verliert
unter Becher 2	$\frac{1}{3}$	zwingend Becher 3	gewinnt
unter Becher 3	$\frac{1}{3}$	zwingend Becher 2	gewinnt

- in zwei von drei Fällen *zwingt* die Lage der Kugel die Spielleitung, den richtigen Becher übrig zu lassen
- Wechseln gewinnt mit $\frac{2}{3}$, Bleiben mit $\frac{1}{3}$

Versteckte Information

- Ihr Becher hatte $\frac{1}{3}$ und behält es: Die Spielleitung hätte ihn ohnehin nie geöffnet
- die $\frac{2}{3}$ der beiden anderen Becher sammeln sich auf dem einen, der übrig bleibt
- die Spielleitung sagt kein Wort über die Kugel, aber die *Art ihrer Auswahl* trägt Information

Gegenprobe: der blinde Moderator

- die Spielleitung weiß *nicht*, wo die Kugel ist, und öffnet zufällig einen anderen Becher
- zufällig ist er leer: Das Bild ist exakt dasselbe wie vorher
- jetzt, und nur jetzt, ist es tatsächlich egal
- **dasselbe Sichtbare, zwei verschiedene Prozesse, zwei verschiedene Wahrscheinlichkeiten**

Die Präzisierung aus dem Buch gehört dazu: Beim blinden Moderator gilt fifty-fifty *unter der Bedingung*, dass er zufällig einen leeren Becher erwischt hat; deckt er die Kugel auf, ist die Runde hinfällig. Der Unterschied zwischen beiden Spielvarianten liegt allein darin, ob der zweite Schritt an die Lage der Kugel gekoppelt ist. Für die Statistik ist das die wichtigste Lehre des Rätsels: Wer nur auf das Ergebnis schaut, kann die beiden Fälle nicht unterscheiden. Wer fragt, wie die Daten zustande gekommen sind, kann es.

Bedingte Wahrscheinlichkeit

Definition 6.1 Die **bedingte Wahrscheinlichkeit** $P(A \mid B)$ ist die Wahrscheinlichkeit von A unter der Voraussetzung, dass B eingetreten ist: $P(A \mid B) = P(A \cap B) \,/\, P(B)$.

- Monty Hall: $P(\text{Kugel unter dem anderen Becher} \mid \text{ein leerer wurde geöffnet})$
- wissende und blinde Spielleitung erzeugen *verschiedene* Bedingungen, obwohl das Bild gleich ist

Merke

Wahrscheinlichkeiten hängen nicht am Bild, sondern am Prozess, der das Bild erzeugt hat. Vor jeder Auswertung steht deshalb die Frage: Wie sind diese Daten zustande gekommen?

6.3 Beschreiben und Schließen

Die Strichlisten der Paare sind ein kleiner Datensatz. Mit ihm lassen sich zwei grundverschiedene Dinge tun. Man kann ihn *beschreiben*: Wie oft hat Wechseln in unserem Kurs gewonnen? Das ist deskriptive Statistik; sie fasst vorliegende Daten zusammen und sagt nichts über Fälle, die nicht erhoben wurden. Man kann aber auch über den Kurs hinaus *schließen*: Ist die Gewinnchance beim Wechseln in diesem Spiel überhaupt, also in allen denkbaren Runden, größer als ein Halb? Das ist Inferenzstatistik. Sie behandelt die erhobenen Daten als Stichprobe aus einer Grundgesamtheit und muss deshalb mit Zufallsschwankungen rechnen. Ein Standardlehrbuch für beide Teile ist Döring und Bortz (2016b).

Zwei Aufgaben der Statistik

Deskriptive Statistik	Inferenzstatistik
beschreibt die vorliegenden Daten	schließt von der Stichprobe auf die Grundgesamtheit
Kennwerte, Tabellen, Grafiken	Tests, Konfidenzintervalle, Modelle
„In unserem Kurs gewann Wechseln in 64 % der Runden.“	„Wechseln gewinnt häufiger als in der Hälfte der Fälle.“

Die 64 % in der Tabelle sind ein Rechenbeispiel, kein Befund.

Skalenniveaus

Skala	sinnvoll ist …	Beispiel	Lagemaß
nominal	gleich / ungleich	Strategie (bleiben, wechseln)	Modus
ordinal	zusätzlich größer / kleiner	Staunen 1–5	Median
intervall	zusätzlich Abstände	Temperatur in °C	Mittelwert
verhältnis	zusätzlich echter Nullpunkt	Ausschlag in mm	Mittelwert

- das Skalenniveau entscheidet, welche Rechnungen erlaubt sind

Der häufigste Fehler betrifft Ratingskalen. Eine Antwort von 4 auf einer Skala von 1 bis 5 ist nicht „doppelt so viel“ wie eine 2, und ob die Abstände zwischen den Stufen gleich groß sind, weiß niemand. In der Praxis werden Mittelwerte aus Likert-Items trotzdem oft berichtet; wer das tut, sollte es begründen und den Median mit angeben.

6.4 Lage, Streuung und Ausreißer

Ein Datensatz lässt sich durch zwei Fragen grob erfassen: Wo liegt seine Mitte, und wie weit streuen die Werte um sie herum? Für die Mitte stehen Modus, Median und arithmetisches Mittel zur Verfügung. Der Median ist der Wert, unter und über dem jeweils die Hälfte der Daten liegt; das Mittel ist die Summe geteilt durch die Anzahl. Bei symmetrischen Verteilungen liegen beide nahe beieinander. Bei schiefen Verteilungen oder einzelnen Extremwerten wird das Mittel in Richtung der Ausreißer gezogen, der Median bleibt stabil. Für die Streuung sind Spannweite, Quartilsabstand und Standardabweichung gebräuchlich. Die Standardabweichung misst die typische Entfernung der Werte vom Mittelwert und ist ebenso ausreißerempfindlich wie dieser.

Lage: Wo liegt die Mitte?

- **Modus**: der häufigste Wert
- **Median** $\tilde{x}$: die Hälfte liegt darunter, die Hälfte darüber
- **Mittelwert** $\bar{x} = \frac{1}{n} \sum x_i$

- Gedankenexperiment: zehn Gäste in einer Kneipe, ihr mittleres Einkommen – dann kommt eine Milliardärin herein

Durch eine einzige Person steigt der Mittelwert ins Absurde, der Median ändert sich kaum. Welcher Kennwert „richtig" ist, hängt von der Frage ab. Wer wissen will, was eine typische Person verdient, nimmt den Median; wer wissen will, wie viel Geld insgesamt im Raum ist, braucht den Mittelwert.

Streuung: Wie verschieden sind die Werte?

- **Spannweite**: Maximum minus Minimum
- **Quartile** Q_1, Q_3: ein bzw. drei Viertel der Werte liegen darunter
- **Quartilsabstand** $IQR = Q_3 - Q_1$: Breite der mittleren Hälfte
- **Varianz** s^2: mittlere quadrierte Abweichung vom Mittelwert
- **Standardabweichung** $s = \sqrt{s^2}$: typischer Abstand eines Werts vom Mittelwert, in der Einheit der Daten

Die Standardabweichung Schritt für Schritt

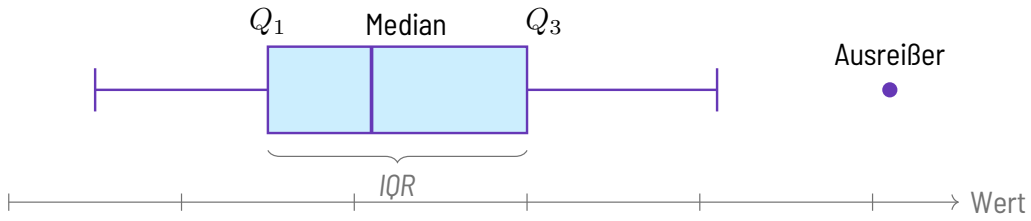
Acht Personen, behaltene Begriffe (von 20) nach einem Lehrvideo:

Wert x_i	13	10	15	11	14	11	15	11	$\Sigma = 100$
Abweichung $x_i - \bar{x}$	0,5	$-2{,}5$	2,5	$-1{,}5$	1,5	$-1{,}5$	2,5	$-1{,}5$	0
Quadrat $(x_i - \bar{x})^2$	0,25	6,25	6,25	2,25	2,25	2,25	6,25	2,25	28

- Mittelwert $\bar{x} = 100/8 = 12{,}5$
- Abweichungen summieren sich immer zu 0 $\Rightarrow$ erst quadrieren, dann mitteln
- Varianz $s^2 = 28 \,/\, (8-1) = 4$, Standardabweichung $s = \sqrt{4} = 2$
- Probe: 5 von 8 Werten liegen in $\bar{x} \pm s$, also zwischen 10,5 und 14,5

Die Daten sind dieselben wie im t-Test-Beispiel weiter unten (Gruppe mit Zaubertrick); wer die Standardabweichung hier an der Tafel gerechnet hat, kennt beim t-Test schon die Hälfte. Geteilt wird durch $n - 1$ statt durch n, weil die Abweichungen vom *Stichproben*mittel gemessen werden, das selbst aus den Daten geschätzt ist und deshalb immer etwas näher an den Werten liegt als das wahre Mittel; ohne die Korrektur würde die Streuung der Grundgesamtheit systematisch unterschätzt. Bei normalverteilten Daten liegen etwa zwei Drittel der Werte innerhalb von $\bar{x} \pm s$; die Probe auf der Folie (5 von 8) passt dazu.

Boxplot und Ausreißerregel



- Box = mittlere Hälfte, Strich = Median, Antennen bis zum letzten unauffälligen Wert
- Ausreißer nach Tukey (1977): mehr als $1{,}5 \cdot IQR$ unter Q_1 oder über Q_3

Was tun mit Ausreißern?

- zuerst prüfen: Messfehler, Tippfehler – oder ein echter Fall?
- **nie** still löschen, weil er „stört"
- Regel *vor* der Auswertung festlegen und berichten

- im Zweifel beide Auswertungen zeigen: mit und ohne

Ausreißer sind die erste Stelle, an der die Freiheit der Auswertung beginnt. Wer erst nach dem Blick auf das Ergebnis entscheidet, ob ein Extremwert drin bleibt, hat bereits einen Pfad im „Garten der sich verzweigenden Wege" gewählt (Gelman und Loken 2014). Darauf kommt LE 10 ausführlich zurück.

Daten zeigen, nicht verstecken

- Histogramm und Boxplot für metrische Daten, Balken für Häufigkeiten
- Achsen beschriften, Einheit angeben, n nennen
- Fallstricke: abgeschnittene y-Achse, 3D-Effekte, Mittelwertbalken ohne Streuung
- wenn möglich: die einzelnen Datenpunkte zeigen

Eine abgeschnittene Achse ist nicht in jedem Fall unzulässig, sie muss aber erkennbar sein. Ein Balkendiagramm, das nur zwei Mittelwerte zeigt, verschweigt, wie stark sich die Gruppen überlappen. Je kleiner der Datensatz, desto eher sollte man alle Punkte zeigen.

6.5 Von der Stichprobe zur Grundgesamtheit

Die Strichlisten des Kurses sind eine *Stichprobe*. Was uns eigentlich interessiert, ist die *Grundgesamtheit*: alle denkbaren Runden dieses Spiels, alle Studierenden, die ein Lehrvideo sehen könnten. Deren Kennzahlen heißen *Parameter* und werden mit griechischen Buchstaben geschrieben (μ, σ, π); sie sind unbekannt. Aus der Stichprobe berechnen wir *Kennwerte* ($\bar{x}, s, \hat{p}$) und schätzen damit die Parameter. Jede neue Stichprobe liefert etwas andere Kennwerte. Wie stark sie von Stichprobe zu Stichprobe schwanken, misst der *Standardfehler*. Er ist die wichtigste Zahl der schließenden Statistik, und er wird oft mit der Standardabweichung verwechselt: Die Standardabweichung beschreibt, wie verschieden die *einzelnen Werte* sind; der Standardfehler beschreibt, wie genau der *Mittelwert* bestimmt ist. Die Standardabweichung bleibt bei wachsendem n ungefähr gleich, der Standardfehler schrumpft mit $1/\sqrt{n}$.

Dass man mit Mittelwerten so bequem rechnen kann, verdankt sich dem *Zentralen Grenzwertsatz*: Mittelwerte (und Summen, und Anteile) aus hinreichend großen Stichproben unabhängiger Werte sind annähernd normalverteilt, mit dem Mittelwert der Grundgesamtheit als Zentrum und dem Standardfehler als Breite, und zwar weitgehend unabhängig davon, wie die einzelnen Werte verteilt sind. Wie groß „hinreichend" ist, hängt von der Schiefe der Grundverteilung ab: Bei Würfeln genügen fünf Werte, bei stark schiefen Verteilungen braucht es dreißig und mehr. Der Satz ist der Grund, warum Konfidenzintervalle und t-Tests auch dann funktionieren, wenn die Rohdaten nicht glockenförmig aussehen.

Stichprobe und Grundgesamtheit

	Grundgesamtheit (Parameter) unbekannt, fest	**Stichprobe (Kennwert)** bekannt, schwankt
Mittelwert	μ	$\bar{x}$
Standardabweichung	σ	s
Anteil (z. B. Gewinnquote)	π	$\hat{p}$

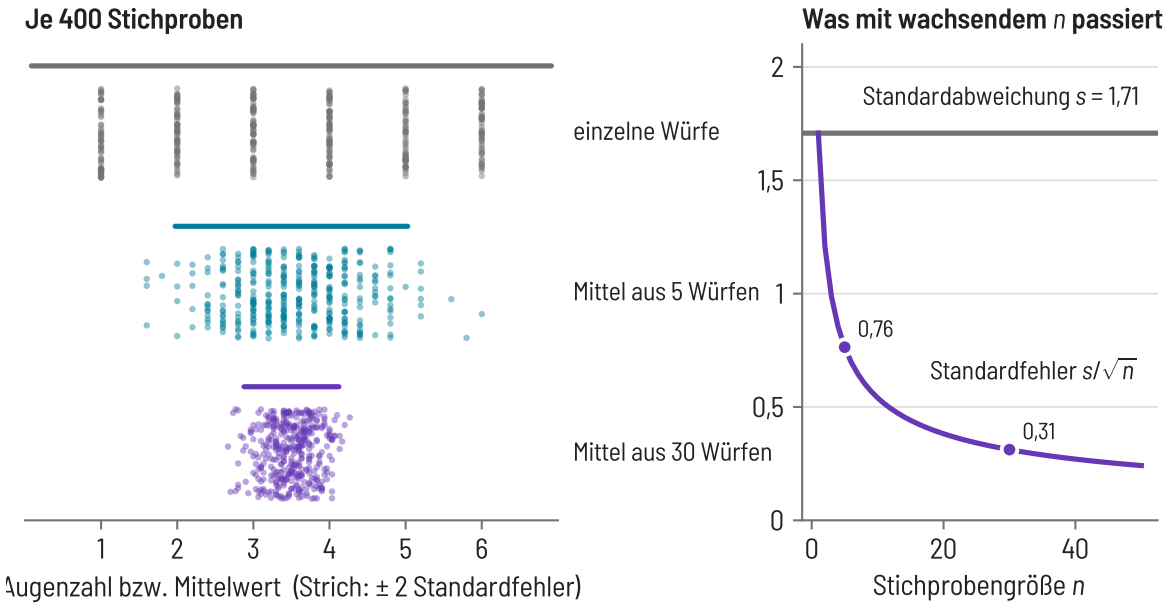
- Monty Hall: π = Gewinnquote beim Wechseln in *allen* denkbaren Runden, $\hat{p}$ = Quote in unseren Runden
- Kernfrage: Wie weit kann $\hat{p}$ *zufällig* von π abweichen?

Der Standardfehler

- **Standardabweichung** s: Wie verschieden sind die *einzelnen Werte*?
- **Standardfehler** *SE*: Wie stark würde der *Mittelwert* schwanken, wenn man die Studie wiederholt?
- für einen Mittelwert: $SE = s \,/\, \sqrt{n}$; für einen Anteil: $SE = \sqrt{\hat{p}\,(1-\hat{p})\,/\,n}$
- Beispiel: $s = 2, n = 8 \Rightarrow SE = 2/\sqrt{8} \approx 0{,}71$

- viermal so viele Personen ⇒ halber Standardfehler

Standardabweichung und Standardfehler im Bild



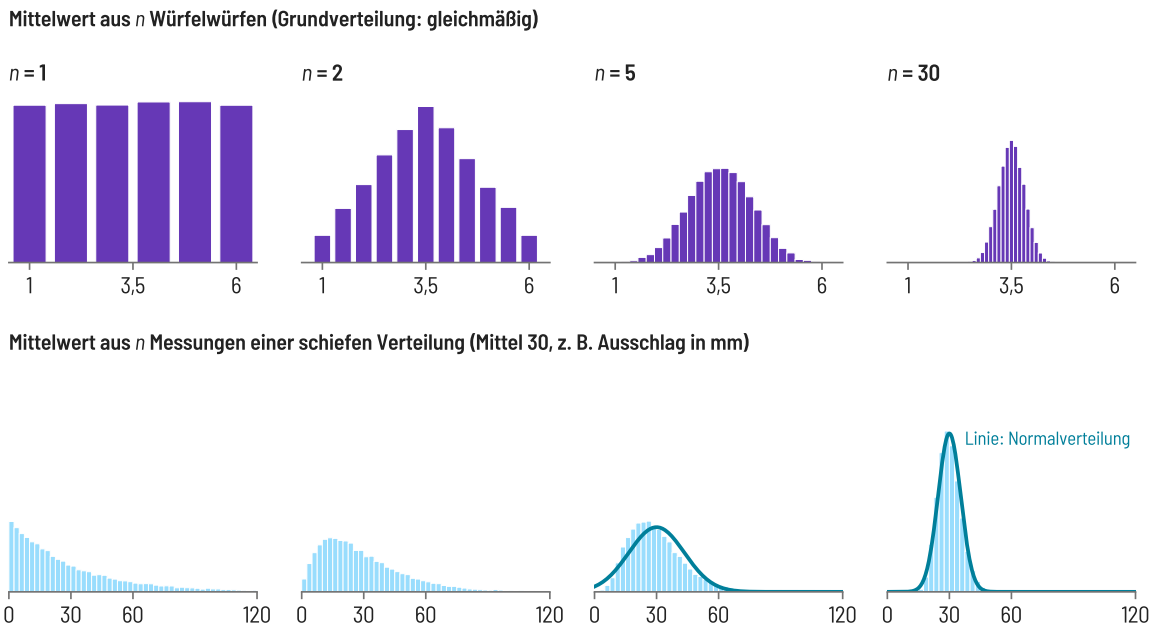
- einzelne Würfe streuen immer gleich stark ($s = 1{,}71$), Mittelwerte umso weniger, je mehr Würfe sie zusammenfassen

Die Grafik zeigt je 400 simulierte Stichproben. Links: einzelne Würfe (oben), Mittelwerte aus 5 Würfen (Mitte) und aus 30 Würfen (unten); der Strich darüber markiert jeweils $3{,}5 \pm 2\,SE$. Rechts: Die Standardabweichung eines Wurfs bleibt bei 1,71, ganz gleich, wie viele Würfe man macht; der Standardfehler des Mittelwerts fällt von 1,71 über 0,76 ($n = 5$) auf 0,31 ($n = 30$).

Der Zentrale Grenzwertsatz

- Mittelwerte aus n unabhängigen Werten sind für großes n annähernd **normalverteilt**
- Zentrum: μ, Breite: der Standardfehler $\sigma/\sqrt{n}$
- **egal, wie die einzelnen Werte verteilt sind** – gleichmäßig, schief, mit Ausreißern
- deshalb funktionieren Konfidenzintervall und t-Test auch bei nicht glockenförmigen Daten
- „großes n“: bei Würfeln ab etwa 5, bei sehr schiefen Daten ab 30 und mehr

Der Grenzwertsatz im Bild



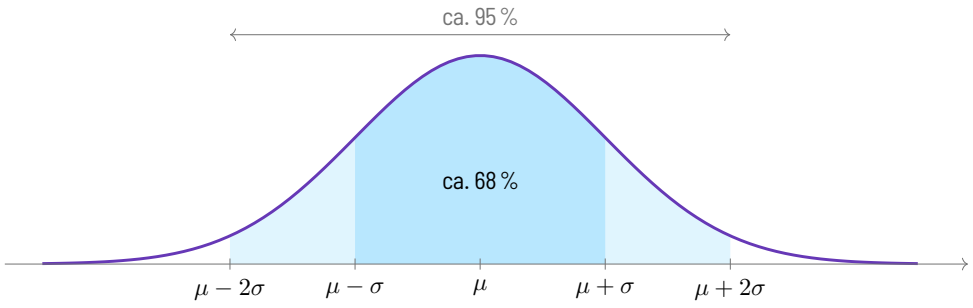
Je 20 000 simulierte Stichproben. Oben die Würfel: Ein einzelner Wurf ist gleichverteilt, schon der Mittelwert aus zwei Würfen ist dreieckig, ab fünf Würfen glockenförmig. Unten eine stark rechtsschiefe Verteilung mit Mittelwert 30, wie sie bei Pendelausschlägen in Millimetern vorkommt (Exponentialverteilung): Hier braucht der Mittelwert deutlich mehr Werte, bis er der eingezeichneten Normalverteilung folgt.

Selbst würfeln: Mittelwerte an der Tafel

- jede Person würfelt **fünfmal** und berechnet den Mittelwert (Teil A, Aufgabe 2)
- das viermal, dann alle vier Mittelwerte als Punkte auf die Zahlengerade an der Tafel
- Vorhersage vorher: Zentrum 3,5, Standardfehler $1{,}71/\sqrt{5} \approx 0{,}76$
- also liegen etwa 95 % der Punkte zwischen $3{,}5 \pm 2 \cdot 0{,}76$, d. h. zwischen 2,0 und 5,0
- stimmt die Vorhersage? Wie sähe das Bild mit 20 Würfen aus?

Das Experiment dauert etwa acht Minuten. Mit 30 Personen entstehen 120 Punkte, genug für eine erkennbare Glocke. Die Standardabweichung eines einzelnen Wurfs ist $\sqrt{35/12} \approx 1{,}71$. Mit 20 Würfen wäre der Standardfehler $1{,}71/\sqrt{20} \approx 0{,}38$, die Glocke also halb so breit. Wer mag, lässt die Hälfte des Kurses mit zwei Würfen pro Mittelwert arbeiten und vergleicht die beiden Bilder.

Die Normalverteilung



Der z-Wert: Abstand in Standardfehlern

- $z =$ (Kennwert − Erwartung) / *SE*
- misst, wie viele Standardfehler ein Ergebnis von dem entfernt ist, was man erwartet hat

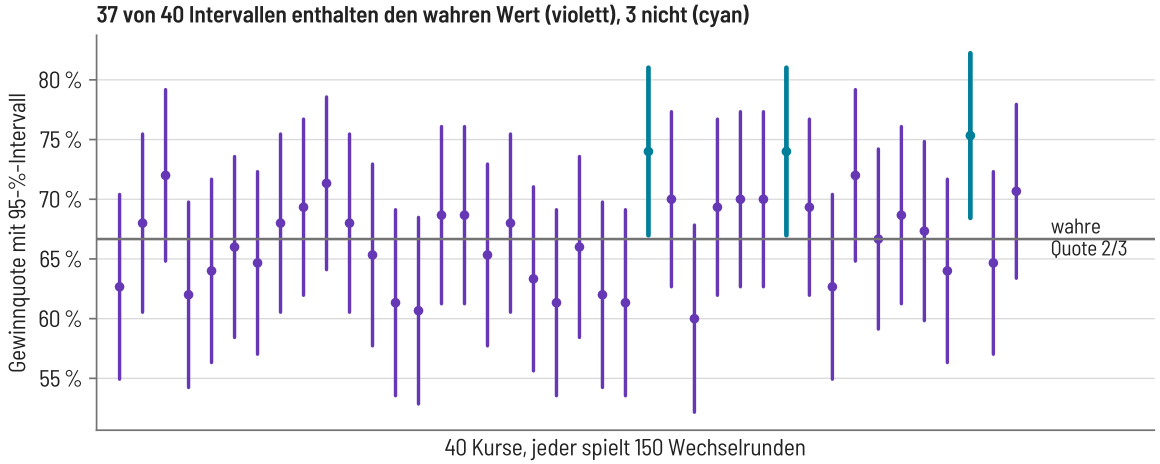
- bei Normalverteilung: $|z| > 1{,}96$ kommt nur in 5 % der Fälle vor, $|z| > 3$ in 0,3 %
- Beispiel Würfel: Mittelwert aus 5 Würfen ist 5,2; $z = (5{,}2 - 3{,}5)/0{,}76 \approx 2{,}2$ – auffällig

Das Konfidenzintervall

- **Schätzwert $\pm$ 1,96 Standardfehler** (bei kleinem n: t statt 1,96)
- Lehrvideo-Gruppe: $12{,}5 \pm 2{,}36 \cdot 0{,}71$, also etwa 10,8 bis 14,2 Begriffe
- Bedeutung: Das *Verfahren* fängt den wahren Wert in 95 % aller Wiederholungen ein
- *nicht*: „Mit 95 % liegt μ in diesem Intervall" – das wäre eine bayesianische Aussage (Sitzung 2)
- ein Intervall sagt mehr als ein p-Wert: Es zeigt, welche Werte mit den Daten verträglich sind

Für $n = 8$ ist der kritische Wert der t-Verteilung mit 7 Freiheitsgraden 2,36 statt 1,96; die t-Verteilung hat breitere Ränder, weil auch die Standardabweichung nur geschätzt ist. Ab etwa 30 Werten ist der Unterschied klein. Die Deutung des Konfidenzintervalls ist eine der häufigsten Fehlerquellen: Für ein *einzelnes* berechnetes Intervall ist der wahre Wert entweder drin oder nicht. Die 95 % beschreiben das Verfahren über viele Wiederholungen, wie die nächste Folie zeigt.

Was „95 %" bedeutet



Simulation: 40 Kurse spielen je 150 Wechselrunden, die wahre Gewinnquote ist $\frac{2}{3}$. Jeder Kurs berechnet sein 95-%-Intervall ($\hat{p} \pm 1{,}96\,SE$). Im Mittel verfehlen 2 von 40 Intervallen den wahren Wert; in dieser Simulation sind es 3. Kein einzelner Kurs kann wissen, ob er zu den Pechvögeln gehört.

6.6 Der Signifikanztest

Der Signifikanztest dreht die Frage des Konfidenzintervalls um. Statt zu fragen, welche Werte mit den Daten verträglich sind, nimmt er einen bestimmten Wert an, die Nullhypothese, und fragt, wie überraschend die Daten wären, wenn dieser Wert stimmt. Das Maß dafür ist der p-Wert. Die Rechnung folgt immer demselben Muster: Erwartung unter H_0, Standardfehler unter H_0, Abstand in Standardfehlern, Wahrscheinlichkeit für einen mindestens so großen Abstand. Am Kurs-Pool lässt sich jeder Schritt mit dem Taschenrechner nachvollziehen.

Die Logik des Signifikanztests

- **Nullhypothese** H_0: Es gibt keinen Effekt („Wechseln gewinnt mit $\frac{1}{2}$")
- Frage: Wie wahrscheinlich wären Daten, die *mindestens so extrem* sind wie unsere, *wenn* H_0 *stimmt*?

- diese Wahrscheinlichkeit ist der **p-Wert**
- ist p kleiner als eine vorab gewählte Schwelle α (meist $0{,}05$), verwirft man H_0

Der Kurs-Pool: Was haben wir gemessen?

- jedes Paar hat etwa 12 Wechselrunden gespielt – zu wenig für ein Urteil (siehe die Streuung an der Tafel)
- darum legen wir **alle Wechselrunden des Kurses zusammen**: der Kurs-Pool
- Rechenbeispiel: 15 Paare $\times$ 10 Wechselrunden = **150 Runden**, davon **97 gewonnen**
- Quote $\hat{p} = 97/150 = 64{,}7\,\%$
- Frage: Kann das Zufall sein, wenn Wechseln in Wahrheit egal ist ($\pi = \frac{1}{2}$)?

In der Stunde werden die echten Summen von der Tafel eingesetzt; die Folien rechnen mit konstruierten Zahlen, damit die Rechnung vorbereitet ist. Zehn Wechselrunden pro Paar sind realistisch, wenn nach 20 Runden abgebrochen wird. Die Pointe des Pools: Kein einzelnes Paar kann mit seinen 10 bis 12 Runden zwischen $\frac{1}{2}$ und $\frac{2}{3}$ sicher unterscheiden, der Kurs zusammen sehr wohl. Das ist der Standardfehler in Aktion.

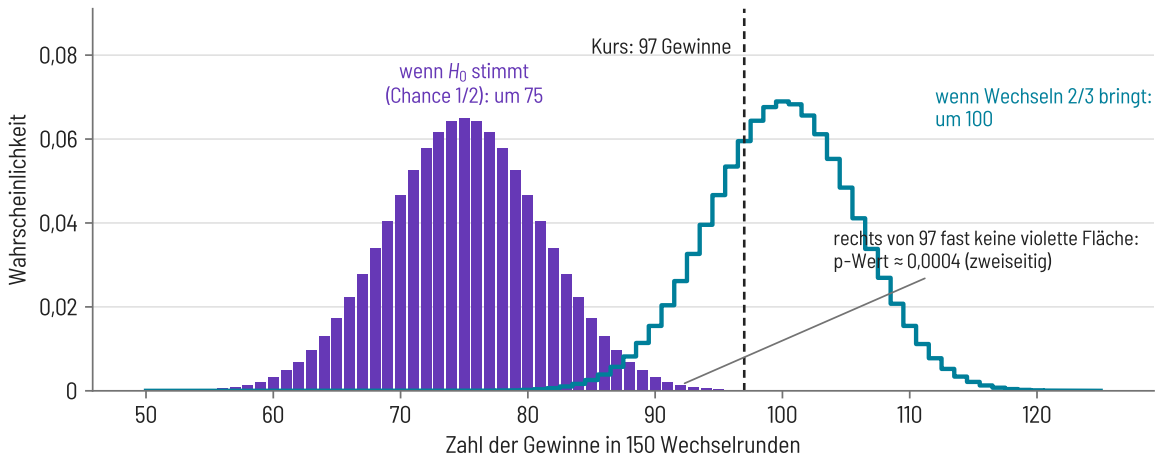
Der Kurs-Pool Schritt für Schritt

Schritt	Frage	Rechnung
1	Was erwarten wir, wenn H_0 stimmt?	$150 \cdot \frac{1}{2} = 75$ Gewinne
2	Wie stark schwankt die Gewinnzahl unter H_0?	$\sqrt{150 \cdot \frac{1}{2} \cdot \frac{1}{2}} \approx 6{,}1$
3	Wie weit liegen wir daneben?	$z = (97 - 75)/6{,}1 \approx 3{,}6$
4	Wie oft käme das unter H_0 vor?	$p \approx 0{,}0004$ (zweiseitig)
5	Urteil bei $\alpha = 0{,}05$?	$p < 0{,}05$: H_0 verwerfen
6	Welche Quoten passen zu den Daten?	$0{,}647 \pm 1{,}96\sqrt{\frac{0{,}647 \cdot 0{,}353}{150}}$ $= 0{,}647 \pm 0{,}077$: **57 % bis 72 %**

- $\frac{2}{3}$ liegt im Intervall, $\frac{1}{2}$ nicht

Schritt 2 ist die Standardabweichung der Binomialverteilung, $\sqrt{n\,\pi\,(1-\pi)}$; in Anteilen ausgedrückt ist das der Standardfehler $\sqrt{0{,}25/150} \approx 0{,}041$. Ein Abstand von 3,6 Standardfehlern ist nach der Normalverteilung sehr selten ($p \approx 0{,}0003$); der exakte Binomialtest liefert $p \approx 0{,}0004$. Beides genügt; in der Stunde reicht der Hinweis, dass alles jenseits von etwa 2 Standardfehlern bei $\alpha = 0{,}05$ signifikant ist. Das Intervall in Schritt 6 ist das einfache Wald-Intervall; das genauere Wilson-Intervall ergibt praktisch dieselben Grenzen. Die Grafik auf der nächsten Folie zeigt Schritt 1 bis 4 auf einen Blick.

Der Kurs-Pool im Bild



- violett: so verteilen sich die Gewinne, wenn Wechseln egal ist; cyan: wenn Wechseln $\frac{2}{3}$ bringt
- 97 liegt fast außerhalb der violetten Verteilung, mitten in der cyanfarbenen

Der t-Test von Hand

Wie viele von 20 Begriffen behalten Studierende nach einem Lehrvideo? (fiktiv, je $n = 8$)

	Werte	$\bar{x}$	s
mit Zaubertrick	13, 10, 15, 11, 14, 11, 15, 11	12,5	2,0
ohne Zaubertrick	8, 12, 9, 11, 8, 13, 8, 11	10,0	2,0

- Standardfehler der Differenz: $SE = s \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} = 2 \cdot \sqrt{\frac{1}{4}} = 1{,}0$
- $t = (\bar{x}_1 - \bar{x}_2) \,/\, SE = 2{,}5 \,/\, 1{,}0 = 2{,}5$ mit $df = n_1 + n_2 - 2 = 14$
- kritischer Wert ($\alpha = 0{,}05$, zweiseitig) aus der t-Verteilung: $2{,}14 \Rightarrow$ signifikant, $p = 0{,}025$
- Effektgröße $d = 2{,}5 \,/\, 2{,}0 = 1{,}25$ (groß)

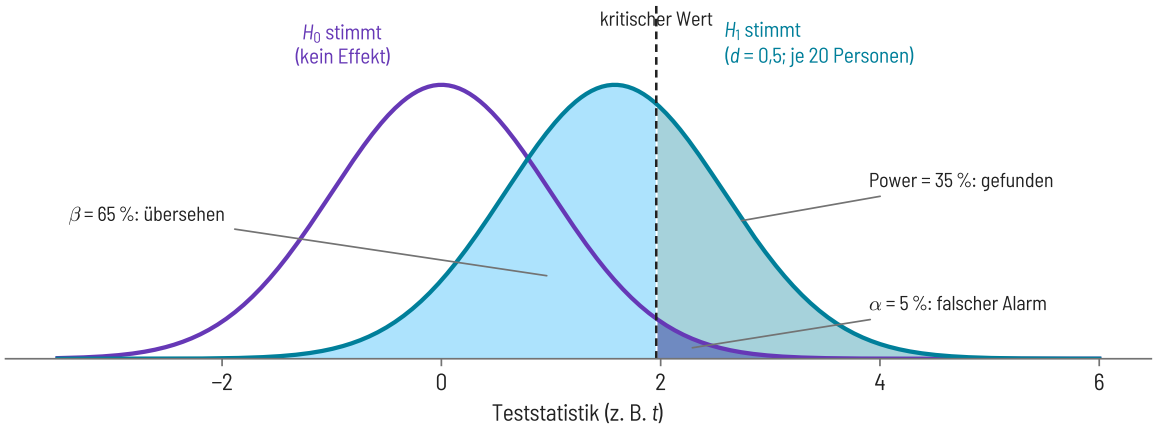
Die Daten sind konstruiert, damit sich alles im Kopf rechnen lässt: beide Gruppen haben dieselbe Standardabweichung $s = 2$, die gepoolte Standardabweichung ist deshalb ebenfalls 2. Allgemein gilt $s_p = \sqrt{((n_1 - 1)s_1^2 + (n_2 - 1)s_2^2)/(n$ Den kritischen Wert liefert jede t-Tabelle oder die Tabellenkalkulation (`T.INV.2T(0,05;14)`), den p-Wert `T.VERT.2S(2,5;` Der t-Test setzt voraus, dass die Werte unabhängig und in beiden Gruppen annähernd normalverteilt sind; bei acht Werten je Gruppe lässt sich das kaum prüfen. Wer ungleiche Streuungen erwartet, nimmt den Welch-Test. Der t-Test kehrt im Bayes-Abschnitt wieder: Dieselben Zahlen ergeben dort einen Bayes-Faktor, der deutlich vorsichtiger klingt als „$p = 0{,}025$“.

Zwei Arten, sich zu irren

	H_0 **stimmt**	H_0 **stimmt nicht**
H_0 **verworfen**	Fehler 1. Art (α)	richtig (Power $1 - \beta$)
H_0 **beibehalten**	richtig	Fehler 2. Art (β)

- $\alpha = 0{,}05$ heißt: In 5 % der Fälle ohne Effekt meldet der Test trotzdem einen
- ein nicht signifikantes Ergebnis ist kein Beleg für „kein Effekt“

Fehler 1. und 2. Art im Bild



- die Schwelle legt α fest; wie viel Power bleibt, hängt von Effekt und n ab

- mit $d = 0{,}5$ und je 20 Personen wird der Effekt in zwei von drei Studien übersehen

Normalnäherung für den Zwei-Gruppen-Test: Unter H_1 ist die Teststatistik um $d\sqrt{n/2} = 0{,}5 \cdot \sqrt{10} \approx 1{,}58$ verschoben. Die Power ist die Fläche der cyanfarbenen Kurve rechts vom kritischen Wert, hier etwa 35 % (exakt mit der t-Verteilung 34 %, siehe die Power-Tabelle in Sitzung 2).

6.7 Was der p-Wert nicht sagt

Kaum ein statistischer Begriff wird so oft missverstanden wie der p-Wert. Die American Statistical Association hat 2016 eine eigene Stellungnahme veröffentlicht, um die gängigsten Fehldeutungen richtigzustellen (Wasserstein und Lazar 2016). Der Kern: Ein p-Wert beschreibt, wie gut die Daten zu einem bestimmten Modell (der Nullhypothese mit allen Zusatzannahmen) passen. Er sagt nichts darüber, wie wahrscheinlich eine Hypothese ist, und nichts darüber, wie groß oder wichtig ein Effekt ist.

Der p-Wert ist *nicht* …

- die Wahrscheinlichkeit, dass H_0 wahr ist
- die Wahrscheinlichkeit, dass das Ergebnis „Zufall" ist
- ein Maß für die Größe oder Bedeutung eines Effekts
- ein Beweis, weder für noch gegen eine Hypothese
- unabhängig davon, wie viele Tests man gerechnet hat

Warum „p < 0,05" kein Beweis ist

- p fragt nach $P(\text{Daten} \mid H_0)$
- wir wollen wissen: $P(H \mid \text{Daten})$
- das ist wieder bedingte Wahrscheinlichkeit, und die Richtung der Bedingung lässt sich nicht umdrehen
- was dazwischen fehlt, ist das Vorwissen über H (der Prior)

Die Verwechslung von $P(\text{Daten} \mid H_0)$ mit $P(H_0 \mid \text{Daten})$ ist ein naher Verwandter des Fehlers, den das Ziegenproblem sichtbar macht: Man liest eine Bedingung falsch. Wie man von der einen Wahrscheinlichkeit zur anderen kommt, regelt der Satz von Bayes; dafür braucht man aber eine Vorab-Einschätzung der Hypothese. Ist diese niedrig, bleibt die Hypothese auch nach einem kleinen p-Wert unsicher. Das erklärt, warum überraschende Einzelbefunde so oft nicht replizieren (Ioannidis 2005; Open Science Collaboration 2015).

Sitzung 1 in vier Sätzen

Die Standardabweichung beschreibt die Daten, der Standardfehler die Genauigkeit eines Mittelwerts; er schrumpft mit $\sqrt{n}$. Dank des Zentralen Grenzwertsatzes sind Mittelwerte annähernd normalverteilt. Ein Konfidenzintervall zeigt, welche Werte mit den Daten verträglich sind. Ein p-Wert sagt, wie überraschend die Daten wären, wenn H_0 stimmt – und nicht, wie wahrscheinlich H_0 ist.

6.8 Zweite Sitzung: Testen mit Vorwissen

Die zweite Sitzung beginnt mit der Denkfrage vom Ende der ersten: Wenn $p = 0{,}02$ ist, wie wahrscheinlich ist dann die Nullhypothese? Die meisten Antworten lauten „2 %", und sie sind falsch. Was zur richtigen Antwort fehlt, ist das Vorwissen: Wie plausibel war die Hypothese vorher, wie häufig ist das Gesuchte überhaupt? Die Sitzung führt deshalb die Basisrate und die bayesianische Statistik ein, lässt die Studierenden beide Denkweisen am Würfel gegeneinander rechnen und endet mit Werkzeugen für das eigene Projekt.

6.9 Zwei Arten, Daten zu befragen

Für den Schritt von der Stichprobe zur Aussage gibt es zwei große Denkschulen. Die *frequentistische* Statistik versteht Wahrscheinlichkeit als relative Häufigkeit in gedachten Wiederholungen. Sie fragt: Wie oft kämen Daten wie unsere heraus, wenn die Nullhypothese stimmt? Über Hypothesen selbst spricht sie keine Wahrscheinlichkeiten aus; eine Hypothese ist wahr oder falsch, nur die Daten schwanken. Die *bayesianische* Statistik versteht Wahrscheinlichkeit als Grad begründeter Überzeugung. Sie fragt: Wie viel besser sagt die eine Hypothese die Daten voraus als die andere, und was sollte ich danach glauben? Dafür braucht sie eine Ausgangseinschätzung, den Prior, und der ist oft nichts anderes als eine *Basisrate*. Beide Schulen rechnen mit denselben Daten. Sie beantworten aber verschiedene Fragen, und wer ein Projekt plant, sollte vorher wissen, welche davon ihn interessiert. Ein gut lesbarer Vergleich beider Schulen mit Rechenbeispielen steht bei Wagenmakers (2007).

Dieselben Daten, zwei Fragen

frequentistisch	**bayesianisch**
Wie überraschend wären diese Daten, *wenn* H_0 stimmt? $P(\text{Daten} \mid H_0)$ Ergebnis: p-Wert, Konfidenzintervall braucht: H_0, α, geplantes n	Welche Hypothese sagt diese Daten besser voraus? $P(H \mid \text{Daten})$ Ergebnis: Bayes-Faktor, Posterior braucht: H_0, H_1, Prior (Basisrate)

- Leitbeispiel für beide: Ist dieser Würfel gezinkt?

Ist dieser Würfel gezinkt? (frequentistisch)

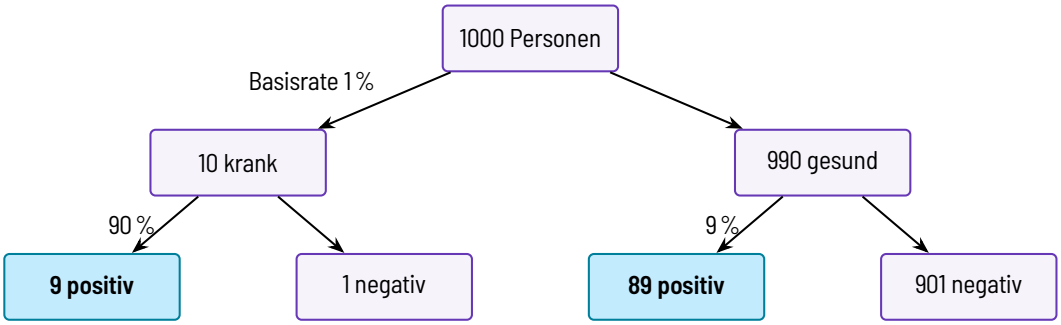
- 30 Würfe, **10 Sechsen**; bei einem fairen Würfel erwartet man 5
- H_0: Der Würfel ist fair, $P(6) = \frac{1}{6}$
- p-Wert: $P(\text{10 oder mehr Sechsen} \mid H_0) = 0{,}020$ (Binomialverteilung, einseitig)
- $p < 0{,}05$: H_0 wird verworfen, „signifikant gezinkt“
- mit **9 Sechsen**: $p = 0{,}051$, nicht signifikant

Die Werte sind exakt mit der Binomialverteilung $B(30, \frac{1}{6})$ gerechnet; die Tabelle auf dem Übungsblatt (Teil B, Aufgabe 4) enthält $P(X \geq k)$ für alle relevanten k. Einseitig wird hier getestet, weil die Frage gerichtet ist (*zu viele* Sechsen). Zweiseitig ergäbe sich bei 10 Sechsen $p \approx 0{,}024$. Der Sprung von 9 auf 10 Sechsen zeigt, wie willkürlich die Schwelle ist: Eine einzige Sechs mehr oder weniger entscheidet über „signifikant“. Die Frage, wie *wahrscheinlich* der Würfel gezinkt ist, beantwortet der Test nicht; dafür fehlt ihm die Information, wie viele gezinkte Würfel es überhaupt gibt.

6.10 Die Basisrate: das vergessene Vorwissen

Die Lücke zwischen $P(\text{Daten} \mid H)$ und $P(H \mid \text{Daten})$ füllt die *Basisrate*: Wie häufig ist das Gesuchte, bevor man hinschaut? Menschen übergehen sie systematisch, sobald eine konkrete, anschauliche Information vorliegt (Tversky und Kahneman 1974; Tversky und Kahneman 1982). Am deutlichsten zeigt das ein medizinischer Test. Die Zahlen unten sind ein klassisches Lehrbeispiel (Prävalenz 1 %, Sensitivität 90 %, Falsch-positiv-Rate 9 %). Fragt man nach der Wahrscheinlichkeit, dass eine positiv getestete Person tatsächlich krank ist, liegen die Schätzungen, auch von Ärztinnen und Ärzten, oft weit zu hoch. Richtig sind etwa 9 %. Gigerenzer und Hoffrage (1995) haben gezeigt, dass solche Aufgaben viel öfter richtig gelöst werden, wenn man sie in *natürlichen Häufigkeiten* stellt („10 von 1000“) statt in bedingten Wahrscheinlichkeiten. Darum rechnet die Folie mit 1000 Personen.

Positiv getestet – und jetzt?



- positiv sind $9 + 89 = 98$ Personen, krank davon nur 9
- $P(\text{krank} \mid \text{positiv}) = 9 / 98 \approx 9\,\%$
- der Test ist gut, die Krankheit ist selten: **die Basisrate gewinnt**

Wie viele signifikante Befunde stimmen?

- ein Signifikanztest ist ein Test wie der beim Arzt: „positiv" heißt $p < 0{,}05$
- 1000 geprüfte Hypothesen, **10 % davon wahr** (Basisrate)
- Power 0,80: von 100 wahren werden 80 signifikant
- $\alpha = 0{,}05$: von 900 falschen werden 45 signifikant
- von $80 + 45 = 125$ signifikanten Befunden stimmen 80, also **64 %**

Basisrate wahrer Hypothesen	50 %	10 %	1 %
Power 0,80	94 %	64 %	14 %
Power 0,35 (typisch kleine Studie)	88 %	44 %	7 %

Der Anteil wahrer unter den signifikanten Befunden heißt in der Diagnostik *positiver Vorhersagewert*. Er beträgt Power $\cdot\, b \,/\, (\text{Power} \cdot b + \alpha \cdot (1 - b))$ mit der Basisrate b. Das ist das Argument von Ioannidis (2005): In Feldern, die viele unwahrscheinliche Hypothesen mit kleinen Studien prüfen, ist ein großer Teil der signifikanten Befunde falsch, auch ohne jedes Fehlverhalten. Kommen p-Hacking und Publikationsbias hinzu, wird es schlimmer. Eine Basisrate von 1 % ist nicht absurd; sie passt zu Forschung, die sehr überraschende Effekte sucht, etwa Hellsehen. Für die eigene Projektplanung folgt daraus: Eine Hypothese mit niedriger Basisrate braucht mehr als einen einzigen signifikanten Befund.

Merke

Ein positiver Test, ein signifikanter Befund, ein Treffer in der Suche: Was er bedeutet, hängt davon ab, wie häufig das Gesuchte überhaupt ist. Wer die Basisrate nicht kennt, sollte sie schätzen und die Schätzung offenlegen, statt sie zu ignorieren.

6.11 Bayes: Was beweist ein Befund?

Der Satz von Bayes beschreibt, wie sich die Glaubwürdigkeit einer Hypothese H durch eine Beobachtung E verändert. Paul Horwich hat daraus eine Theorie der Evidenz entwickelt, die das Buch ausführlich darstellt (Kap. 5b): Eine Beobachtung bestätigt eine Hypothese, wenn sie sie wahrscheinlicher macht, als sie vorher war (Horwich 1982). Folgt die Beobachtung aus der Hypothese, so ist der Zuwachs umso größer, je unwahrscheinlicher die Beobachtung ohne Kenntnis der Hypothese war. Riskante Vorhersagen, die eintreffen, sind deshalb starke Evidenz; Vorhersagen, die ohnehin eingetroffen wären, sind schwache.

Der Satz von Bayes

$$P(H \mid E) \;=\; \frac{P(E \mid H) \cdot P(H)}{P(E)}$$

- $P(H)$: Prior – was ich vorher für plausibel hielt
- $P(E \mid H)$: Likelihood – wie gut erwartet H die Daten?
- $P(H \mid E)$: Posterior – was ich nachher glauben sollte

Bayes zum Rechnen: die Chancenform

$$\underbrace{\frac{P(H_1 \mid E)}{P(H_0 \mid E)}}_{\text{Chance nachher}} = \underbrace{\frac{P(H_1)}{P(H_0)}}_{\text{Chance vorher (Basisrate)}} \times \underbrace{\frac{P(E \mid H_1)}{P(E \mid H_0)}}_{\text{Bayes-Faktor } BF_{10}}$$

- Chance $a : b$ heißt Wahrscheinlichkeit $a \,/\, (a+b)$, etwa $1 : 4 \mathrel{\hat{=}} 20\,\%$
- der **Bayes-Faktor** misst allein die Daten: Wie viel besser sagt H_1 sie voraus als H_0?
- mehrere unabhängige Befunde: Bayes-Faktoren einfach **multiplizieren**
- Medizintest: $1 : 99 \times (90\,\% \,/\, 9\,\%) = 1 : 99 \times 10 = 10 : 99 \approx 9\,\%$

Die Chancenform (*odds form*) ist die Fassung des Satzes von Bayes, mit der man im Kopf rechnen kann. Sie trennt sauber, was man vorher wusste (Prior-Chance), von dem, was die Daten beitragen (Bayes-Faktor). Das hat einen praktischen Vorteil: Zwei Personen mit verschiedenen Ausgangseinschätzungen können sich auf den Bayes-Faktor einigen, auch wenn sie am Ende Verschiedenes glauben. Für die Deutung des Bayes-Faktors ist die grobe Skala von Kass und Raftery (1995) verbreitet: 1 bis 3 kaum der Rede wert, 3 bis 20 positive, 20 bis 150 starke, über 150 sehr starke Evidenz. Werte unter 1 sprechen für H_0; dann liest man den Kehrwert $BF_{01} = 1/BF_{10}$.

Derselbe Würfel, bayesianisch

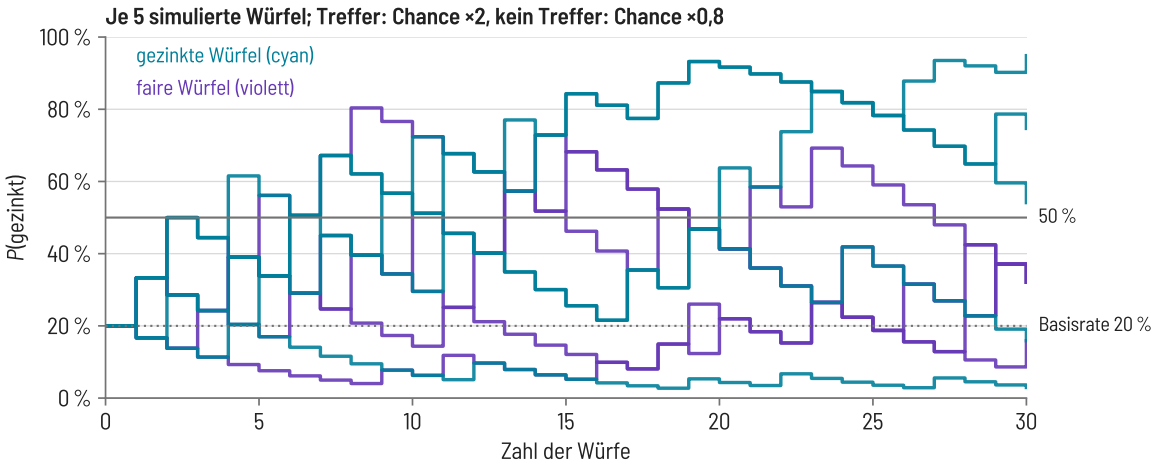
- H_1 muss konkret sein: „gezinkt" heißt hier $P(6) = \frac{1}{3}$
- jede Sechs: $\frac{1/3}{1/6} = \times 2$ jede andere Zahl: $\frac{2/3}{5/6} = \times 0{,}8$
- 10 Sechsen, 20 andere: $BF_{10} = 2^{10} \cdot 0{,}8^{20} \approx 1024 \cdot 0{,}0115 \approx 11{,}8$

Woher stammt der Würfel?	Basisrate	Chance nachher	$P(\textbf{gezinkt})$
Spieleabend bei Freunden	$1 : 999$	$11{,}8 : 999$	$1\,\%$
heute im Kurs (jeder fünfte Umschlag)	$1 : 4$	$11{,}8 : 4$	$75\,\%$
Grabbelkiste im Scherzartikelladen	$1 : 1$	$11{,}8 : 1$	$92\,\%$

- gleiche Daten, gleicher p-Wert $(0{,}020)$, **drei verschiedene Antworten**

Die Rechnung zeigt den Kern der Einheit in einer Tabelle. Der p-Wert ist in allen drei Zeilen derselbe, weil er nur fragt, wie überraschend die Daten unter H_0 wären. Ob man deshalb glauben sollte, dass der Würfel gezinkt ist, hängt aber entscheidend davon ab, wie viele gezinkte Würfel es dort gibt, wo er herkommt. Beim Spieleabend wäre es nach wie vor viel wahrscheinlicher, dass ein fairer Würfel zufällig viele Sechsen gezeigt hat. Bei 9 Sechsen, wo der Test „nicht signifikant" meldet, ist $BF_{10} = 4{,}7$; mit der Kurs-Basisrate $1 : 4$ ergibt das eine Chance von $4{,}7 : 4$, also 54 %. Der Bayes-Faktor verlangt dafür eine konkrete Alternative: Wie stark ist der Würfel gezinkt? Bei den Umschlägen im Kurs ist das bekannt, bei einem echten Mogelwürfel nicht. Dann setzt man eine Verteilung möglicher Schieflagen an, und der Bayes-Faktor hängt von dieser Wahl ab. Das ist der ehrliche Preis der bayesianischen Antwort.

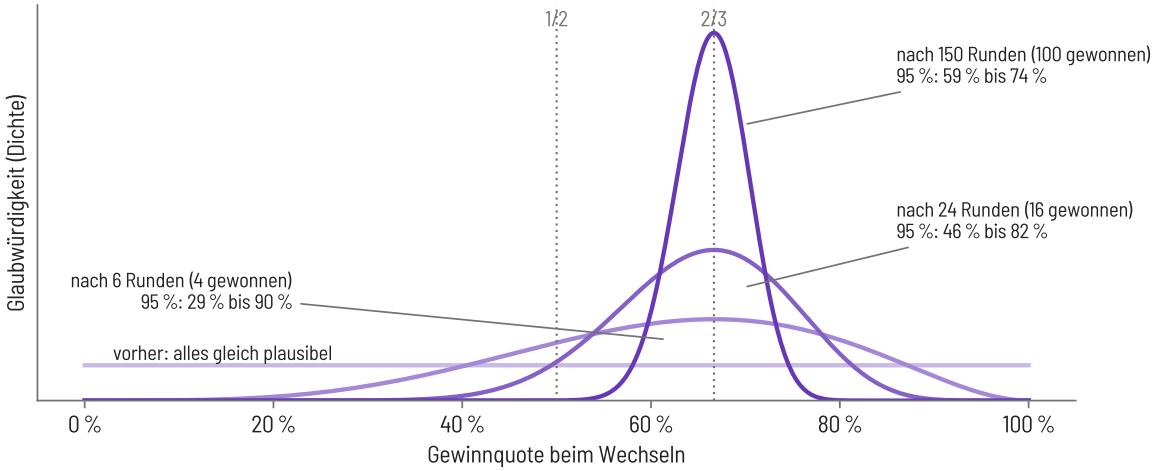
Der Posterior wandert mit jedem Wurf



- alle starten bei der Basisrate 20 %; jeder Wurf verschiebt die Überzeugung ein Stück
- nach 30 Würfen sind manche Würfel klar, andere noch unentschieden

Je fünf simulierte faire und gezinkte Würfel, Prior $1:4$. Die Kurven zeigen nach jedem Wurf $P(\text{gezinkt})$. Gut zu sehen: Faire Würfel sinken langsam, weil ein Nicht-Treffer die Chance nur mit 0,8 multipliziert; gezinkte steigen in Sprüngen, aber nicht jeder gezinkte Würfel ist nach 30 Würfen über 50 %. Der Bayes-Faktor hat keine feste Stichprobengröße: Man könnte weiterwürfeln, bis die Kurve eine vorher festgelegte Grenze erreicht (vgl. die Stoppregel bei Schönbrodt u. a. (2017)).

Bayes für eine Quote: Wie gut ist Wechseln?



- mit jeder Runde wird die Kurve schmaler: aus Vermutung wird Wissen
- nach 150 Runden: mit 95 % zwischen 59 % und 74 % – *diese* Aussage darf Bayes machen

Prior ist die Gleichverteilung (jede Quote gleich plausibel); nach k Gewinnen in n Runden ist der Posterior eine Beta-Verteilung mit den Parametern $k+1$ und $n-k+1$. Zum Rechnen genügt die Grafik: Wichtig ist, dass das bayesianische 95-%-Intervall („Glaubwürdigkeitsintervall“) genau die Aussage macht, die man dem Konfidenzintervall oft fälschlich zuschreibt. Bei einem flachen Prior und vielen Daten liegen beide Intervalle zahlenmäßig nahe beieinander.

Bayes-Faktor zum t-Test

- Faustformel nach Wagenmakers (2007), mit N = alle Personen:

$$BF_{01} \approx \sqrt{N} \cdot \left(1 + \frac{t^2}{df}\right)^{-N/2}$$

- Lehrvideo-Beispiel: $t = 2{,}5$, $N = 16$, $df = 14$
- $(1 + 6{,}25/14)^8 = 1{,}446^8 \approx 19{,}1$, also $BF_{01} \approx 4 \,/\, 19{,}1 \approx 0{,}21$
- $BF_{10} \approx 4{,}8$: die Daten sind knapp fünfmal so gut mit einem Effekt vereinbar (JASP-Standard: 2,7)
- „$p = 0{,}025$“ klingt nach mehr, als die Daten hergeben

Die Faustformel beruht auf der BIC-Näherung, die Wagenmakers (2007) für den t-Test ableitet. Sie entspricht einem recht breiten Prior für die Effektgröße und ist eine Größenordnungsschätzung. Statistikprogramme wie JASP rechnen standardmäßig den JZS-Bayes-Faktor nach Rouder u. a. (2009) (Cauchy-Prior mit Breite $r = \sqrt{2}/2$); für das Beispiel ergibt er $BF_{10} = 2{,}7$. Beide Werte liegen in derselben Kategorie: positive, aber keine starke Evidenz. Mit Prior-Chance $1 : 1$ ergäbe die Faustformel eine Posterior-Wahrscheinlichkeit von 83 %, mit $1 : 3$ noch 62 %. Das Beispiel zeigt eine allgemeine Regel: p-Werte knapp unter $0{,}05$ entsprechen meist nur schwacher Evidenz (Wagenmakers 2007).

Was nur der Bayes-Faktor kann

- **Signifikant, aber Evidenz für H_0:** je 1000 Personen, $t = 2{,}0$, $p = 0{,}046$, $d = 0{,}09$
- $BF_{01} \approx \sqrt{2000} \cdot (1 + 4/1998)^{-1000} \approx 44{,}7 \cdot e^{-2} \approx 6$: die Daten sprechen eher *gegen* einen nennenswerten Effekt
- **Evidenz für „kein Effekt“:** je 20 Personen, $t = 0$: $BF_{01} \approx \sqrt{40} \approx 6{,}3$
- ein p-Wert kann H_0 nie stützen, nur nicht verwerfen

Der erste Fall ist als Lindley-Paradox bekannt: Bei sehr großen Stichproben wird ein winziger Unterschied signifikant, obwohl die Daten die Nullhypothese besser vorhersagen als eine Alternative, die nennenswerte Effekte erwartet. Mit dem JZS-Bayes-Faktor ergibt sich $BF_{01} = 2{,}7$ statt 6; die Richtung bleibt gleich. Im zweiten Fall liefert JASP $BF_{01} = 3{,}2$. Für kleine Studierendenprojekte ist der zweite Punkt wichtig: Ein nicht signifikantes Ergebnis ist frequentistisch nur „kein Befund“. Ein Bayes-Faktor kann dagegen zeigen, ob die Daten für die Nullhypothese sprechen oder schlicht zu dünn sind, um irgendetwas zu sagen.

Der Beweiswert riskanter Vorhersagen

- folgt E aus H, gilt $P(H \mid E) \,/\, P(H) = 1 \,/\, P(E)$
- **je unwahrscheinlicher die Vorhersage, desto stärker die Bestätigung**, wenn sie eintrifft
- „Morgen geht die Sonne auf“ trifft ein und beweist fast nichts
- „Wechseln gewinnt doppelt so oft“ war riskant: Die Strichliste hätte sie widerlegen können

Horwich zeigt außerdem, dass nur Beobachtungen, die ein Widerlegungsrisiko eingehen, vollen Beweiswert haben (Horwich 1982). Das schlägt die Brücke zu LE 5 (Falsifizierbarkeit) und zu LE 10: Ein Verfahren, das jedes Ergebnis liefern kann, geht kein Risiko ein und beweist deshalb nichts.

6.12 Frequentistisch oder bayesianisch?

Keine der beiden Schulen ist „die richtige“. In der empirischen Forschung dominieren Signifikanztests, und wer Fachliteratur liest, muss sie verstehen. Bayesianische Verfahren gewinnen an Boden, weil sie Fragen beantworten, die Forschende tatsächlich stellen, und weil sie Evidenz für die Nullhypothese ausweisen können. Für die Planung einer eigenen Studie zählt vor allem ein Unterschied: Der Signifikanztest verlangt, dass die Stichprobengröße vorher feststeht. Wer nach jeder Versuchsperson nachschaut und aufhört, sobald $p < 0{,}05$ ist, treibt die Fehlerquote weit über 5 % (Simmons u. a. 2011). Beim Bayes-Faktor darf man dagegen laufend nachsehen und aufhören, wenn die Evidenz eine vorab festgelegte Grenze erreicht (Schönbrodt u. a. 2017). Das ist für kleine Projekte attraktiv, bei denen niemand weiß, wie viele Personen am Ende mitmachen.

Die beiden Schulen im Vergleich

	Signifikanztest	**Bayes-Faktor**
Frage	Sind die Daten mit H_0 verträglich?	Welche Hypothese sagt die Daten besser voraus?
Vorwissen	bleibt draußen	geht offen als Prior ein
Alternative H_1	muss nicht genau angegeben werden	muss konkret sein
Evidenz für H_0	nicht möglich	möglich
Zwischenauswertung	verfälscht p; n vorab festlegen	erlaubt, Stoppregel vorab festlegen
typischer Fehler	p als $P(H_0 \mid \text{Daten})$ lesen	Prior verschweigen oder passend wählen

Merke

Der p-Wert fragt, wie überraschend die Daten unter H_0 wären. Der Bayes-Faktor fragt, um wie viel die Daten eine Hypothese gegenüber einer anderen stützen. Was man danach glauben sollte, bestimmen die Daten *und* die Basisrate.

6.13 Übung: Würfel-Detektive

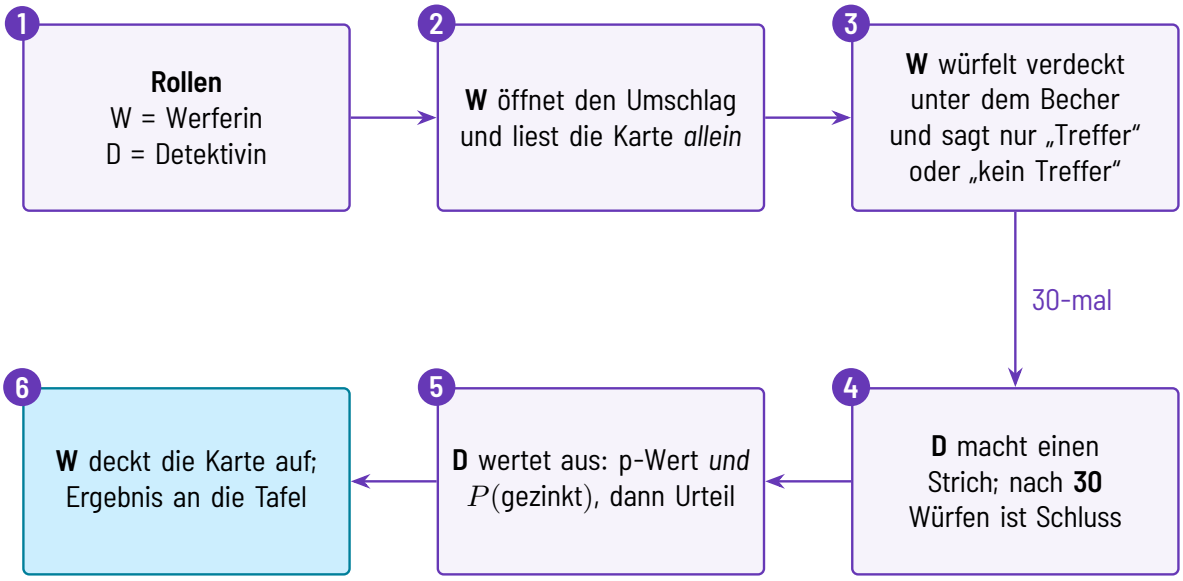
Die Übung macht in einer Viertelstunde erlebbar, was die Folien behauptet haben: dass ein Test mit $\alpha = 0{,}05$ manchmal falschen Alarm gibt, dass er bei kleinem n viele echte Effekte übersieht und dass man ohne Basisrate nicht sagen kann, wie viele seiner Alarme stimmen.

Das Spiel braucht keine präparierten Würfel. Ob ein Würfel „gezinkt" ist, entscheidet eine Karte im Umschlag, die nur die werfende Person kennt: Bei „fair" zählt nur die 6 als Treffer (Wahrscheinlichkeit $\frac{1}{6}$), bei „gezinkt" zählen 5 und 6 (Wahrscheinlichkeit $\frac{1}{3}$). Für die Detektivin ist das von einem echten gezinkten Würfel nicht zu unterscheiden, denn sie sieht den Würfel nicht, sondern hört nur „Treffer" oder „kein Treffer". Damit sind beide Hypothesen exakt bekannt, und die Basisrate (jeder fünfte Umschlag) ebenfalls. Die Regeln auf der dritten Folie sind wichtig: Wer nach 15 Würfen aufhört, weil es „schon klar" ist, verändert die Fehlerrate des Tests; genau das ist Optional Stopping aus dem Vergleich der beiden Schulen.

Würfel-Detektive: das Spiel

- jedes Paar bekommt einen Würfel, der **vielleicht gezinkt** ist
- „gezinkt" heißt hier: ein **Treffer** kommt doppelt so oft (Chance $\frac{1}{3}$ statt $\frac{1}{6}$)
- ob Ihr Würfel gezinkt ist, steht auf einer Karte im Umschlag
- **bekannt**: 3 von 15 Umschlägen sind gezinkt, also jeder fünfte (Basisrate $1:4$)
- Ihre Aufgabe: aus 30 Würfen herausfinden, ob Ihr Würfel gezinkt ist – einmal mit Test, einmal mit Bayes

Ablauf in sechs Schritten



- **Treffer** bei Karte „fair": nur die 6 bei Karte „gezinkt": 5 oder 6

Spielregeln, damit der Test ehrlich bleibt

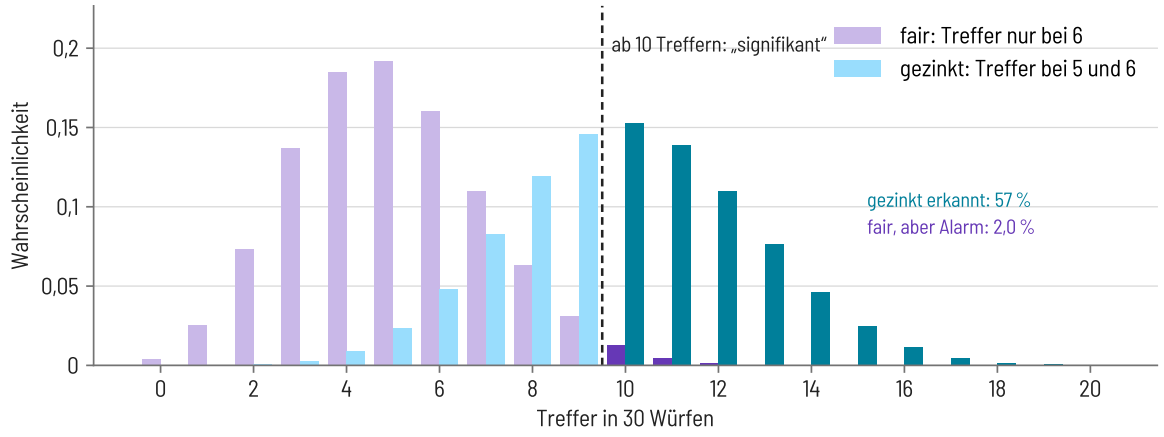
- W zeigt die Karte erst nach dem Urteil – auch kein Grinsen, kein Zögern
- W meldet jeden Wurf wahrheitsgemäß, D sieht den Würfel nie
- **immer genau 30 Würfe**, auch wenn es „schon klar" ist: Die Stichprobengröße steht vorher fest
- D entscheidet *vor* dem Aufdecken und schreibt beide Urteile auf (Teil B, Aufgabe 4)
- dauert etwa 5 Minuten Würfeln und 5 Minuten Rechnen

Auswertung am Beispiel: 9 Treffer in 30 Würfen

(a) Test	(b) Bayes
H_0: fair, Treffer mit $\frac{1}{6}$; erwartet 5	Faktor je Treffer $\times 2$, je Nicht-Treffer $\times 0{,}8$
aus der Tabelle: $P(X \geq 9 \mid \text{fair}) = 0{,}051$	$BF_{10} = 2^9 \cdot 0{,}8^{21} = 512 \cdot 0{,}0092 \approx 4{,}7$
$0{,}051 > 0{,}05$: **nicht signifikant**	Chance $1 : 4 \times 4{,}7 = 4{,}7 : 4 \Rightarrow P \approx$ **54 %**
Urteil: „kein Befund"	Urteil: „eher gezinkt, aber unsicher"

- dieselben Daten, zwei verschiedene Fragen, zwei verschiedene Antworten
- mit 10 Treffern: Test signifikant ($p = 0{,}020$), Bayes 75 %

Was der Kurs erwarten kann



- die Verteilungen überlappen stark: 30 Würfe sind wenig
- der Test erkennt nur gut die Hälfte der gezinkten Würfel

Auszählung im Kurs

	Karte: fair	**Karte: gezinkt**
signifikant ($k \geq 10$)	falscher Alarm (α)	Treffer (Power)
nicht signifikant	richtig	übersehen (β)

- erwartet bei 12 fairen und 3 gezinkten Paaren: 0–1 falscher Alarm, aber nur 1–2 der 3 gezinkten erkannt (Power 0,57)
- Wie viele der signifikanten Würfel waren wirklich gezinkt?
- Wer lag mit dem Bayes-Urteil ($P > 50\,\%$) richtig, wer mit dem Test?

Die Erwartungswerte sind exakt gerechnet: Bei einem fairen Würfel ist $P(X \geq 10) = 0{,}020$, bei 12 fairen Paaren erwartet man also 0,24 falsche Alarme. Bei einem gezinkten Würfel ($P(\text{Treffer}) = \frac{1}{3}$) ist $P(X \geq 10) = 0{,}57$; von drei gezinkten werden im Mittel 1,7 erkannt. Der Anteil wirklich gezinkter unter den signifikanten Würfeln liegt bei dieser Basisrate rechnerisch bei 88 %; mit einer Basisrate von 1 in 100 läge er bei 23 %. Die Bayes-Regel „gezinkt, wenn $P(\text{gezinkt}) > 50\,\%$“ schlägt ab 9 Treffern an ($BF_{10} = 4{,}7 > 4$). Sie erkennt gezinkte Würfel etwas öfter (71 %) und gibt bei fairen etwas öfter falschen Alarm (5 %). Bei so wenigen Paaren streut die Auszählung stark; genau das ist ein Gesprächsanlass: Mit 30 Würfen lässt sich ein deutlich gezinkter Würfel nur in gut der Hälfte der Fälle nachweisen. Welche Konsequenz hätte das für eine Studie mit 30 Personen?

6.14 Glaubwürdigkeits-Check mit der Suchmaschine

Bayes in Chancenform ist auch ein Werkzeug für den Alltag der Quellenkritik. Es knüpft an SIFT aus LE 4 an (*Find better coverage*, *Trace claims*) und macht aus dem Bauchgefühl eine nachvollziehbare Rechnung. Vor der Suche setzt man eine Basisrate an: Von 100 Behauptungen dieser Art, wie viele stimmen? Dann prüft man jeden Fund mit einer einzigen Frage: Wie viel wahrscheinlicher wäre dieser Fund, wenn die Behauptung stimmt, als wenn sie nicht stimmt? Die Antwort ist ein grober Bayes-Faktor. Die Zahlen sind Schätzungen, und das ist gewollt: Sie zwingen dazu, die Einschätzung offenzulegen und mit anderen zu vergleichen. Die wichtigste Lehre steckt in der zweiten Zeile des Beispiels: Zehn Portale, die dieselbe Pressemitteilung abschreiben, sind *ein* Fund, nicht zehn. Multiplizieren darf man nur unabhängige Befunde.

Das Beispiel ist echt. Der Wissenschaftsjournalist John Bohannon hat 2015 mit Absicht eine methodisch schwache Studie zu Schokolade und Gewichtsverlust durchgeführt (wenige Versuchspersonen, viele Messgrößen) und in einer Zeitschrift veröffentlicht, die gegen Gebühr publiziert. Die Pressemitteilung wurde weltweit aufgegriffen, die *Bild* titelte „Schlank durch Schokolade!“. Danach legte Bohannon offen, wie und warum er den Fake gebaut hatte (Bohannon 2015).

Glaubwürdigkeit in vier Schritten

- **Behauptung** genau notieren: Wer sagt was über wen?
- **Basisrate**: Von 100 Behauptungen dieser Art, wie viele stimmen? ⇒ Prior-Chance
- **Suchen** (SIFT, LE 4), für jeden Fund fragen: Wie viel wahrscheinlicher wäre er, wenn die Behauptung *stimmt*, als wenn sie *nicht* stimmt?
- Faktoren grob wählen: $\times 10$, $\times 3$, $\times 1$, $\times \frac{1}{3}$, $\times \frac{1}{10}$; nur **unabhängige** Funde multiplizieren

Beispiel: „Schokolade hilft beim Abnehmen“

Schritt	Faktor	Chance
Basisrate: Diät-Wunder aus einer Einzelstudie, etwa 1 von 10 hält		$1:9$
viele Portale berichten, alle mit derselben Pressemitteilung	$\times 1$	$1:9$
Originalstudie: sehr wenige Personen, viele Messgrößen, Zeitschrift publiziert gegen Gebühr	$\times \frac{1}{3}$	$1:27$
der Autor erklärt öffentlich, die Studie sei ein absichtlicher Fake	$\times \frac{1}{100}$	$1:2700$

- am Ende: $P(\text{stimmt}) \approx 0{,}04\,\%$
- der Fund, der die meisten Klicks hat, trägt den kleinsten Faktor

Ihr Glaubwürdigkeits-Check (Kleingruppen, 12 Min.)

- jede Gruppe zieht eine Behauptungskarte
- Basisrate *vor* der Suche festlegen und begründen
- 8 Minuten suchen, jeden Fund mit Faktor in die Tabelle (Teil B, Aufgabe 6)
- Ergebnis: $P(\text{stimmt})$ – und welcher Fund hat am meisten bewegt?
- Vergleich: Wo lagen zwei Gruppen mit denselben Funden verschieden, weil ihre Basisrate verschieden war?

Behauptungskarten für den Glaubwürdigkeits-Check

Bewährt haben sich Behauptungen, zu denen eine kurze Suche gute Quellen findet. Vorschläge, davon mindestens zwei zutreffende auswählen:

- „Wir nutzen nur 10 % unseres Gehirns." (falsch, verbreiteter Mythos)
- „Die Chinesische Mauer ist das einzige Bauwerk, das man vom Mond aus mit bloßem Auge sieht." (falsch)
- „Ein Blitz schlägt nie zweimal an derselben Stelle ein." (falsch; hohe Gebäude werden regelmäßig mehrfach getroffen)
- „Mozart hören macht Babys klüger." (in dieser Form falsch; die Ausgangsstudie fand einen kurzen Effekt bei Erwachsenen, der sich kaum replizieren ließ)
- „Ausschläge von Wünschelruten und Pendeln entstehen durch unbewusste Muskelbewegungen." (zutreffend, Ideomotor-Effekt aus LE 1)
- „In europäischen Ländern hängt die Zahl der Storchenpaare mit der Geburtenzahl zusammen." (zutreffend als Korrelation, Matthews (2000); ein schönes Beispiel dafür, dass eine wahre Behauptung nicht die kausale Deutung trägt, die sie nahelegt)

Erwartet wird kein „richtiger" Zahlenwert. Gute Gruppen begründen ihre Basisrate, erkennen abgeschriebene Meldungen als einen einzigen Fund und geben den größten Faktoren den Funden, die nur bei einer wahren (bzw. falschen) Behauptung zu erwarten sind: Übersichtsarbeiten, Faktenchecks mit Quellenangaben, die Originalstudie selbst. Lohnend ist die Frage, ob eine Gruppe ihre Basisrate nach der Suche nachträglich „angepasst" hat; das wäre Doppelzählung.

6.15 Effektgröße und Power

Ob ein Effekt „signifikant" ist, hängt nicht nur von seiner Größe ab, sondern auch von der Stichprobengröße. Mit sehr vielen Personen wird jeder noch so kleine Unterschied signifikant, mit sehr wenigen bleibt selbst ein großer unentdeckt. Deshalb gehört zu jedem Befund eine *Effektgröße*, die unabhängig von n angibt, wie groß der Unterschied ist. Für Mittelwertunterschiede ist Cohens d üblich, der Abstand der Mittelwerte in Einheiten der Standardabweichung (Cohen

1988). Die *Power* (Teststärke) ist die Wahrscheinlichkeit, einen tatsächlich vorhandenen Effekt bestimmter Größe auch zu finden. Sie wird *vor* der Studie über eine Poweranalyse festgelegt; daraus ergibt sich die nötige Stichprobengröße.

Effektgröße: Wie groß ist der Unterschied?

- Cohens $d = (\bar{x}_1 - \bar{x}_2) \,/\, s$: Abstand in Standardabweichungen
- grobe Orientierung: $0{,}2$ klein, $0{,}5$ mittel, $0{,}8$ groß (Cohen 1988)
- immer mit Konfidenzintervall berichten
- signifikant ist nicht dasselbe wie groß, nicht signifikant nicht dasselbe wie null

Power: Wie viele Personen brauche ich?

erwarteter Effekt	$d = 0{,}2$	$d = 0{,}5$	$d = 0{,}8$
n pro Gruppe	394	64	26

- t-Test, zwei Gruppen, $\alpha = 0{,}05$ zweiseitig, Power $0{,}80$
- mit 13 Personen pro Gruppe findet man einen mittleren Effekt nur in etwa einem von vier Versuchen

Die Werte der Tabelle sind mit der nichtzentralen t-Verteilung nachgerechnet; sie stimmen mit den Tafeln bei Cohen (1988) überein. Die Power bei 13 Personen pro Gruppe und $d = 0{,}5$ beträgt nach derselben Rechnung etwa 0,23. Kleine Studien haben nicht nur ein hohes Risiko, echte Effekte zu übersehen. Wenn sie doch einmal „signifikant“ werden, überschätzen sie die Effektgröße typischerweise deutlich (Button u. a. 2013).

Ein Lehrstück aus dem Buch

- Feldstudie zum Becher-Monty-Hall-Video: 32 auswertbare Fälle in drei Armen (13 / 9 / 10)
- am 16. Juli zeigte das Staunen eine schöne Abstufung: 3,83 / 4,08 / 4,28
- am Ende lagen die Arme gleichauf: 3,89 / 3,76 / 3,87
- stärkster Zusammenhang: **Vorwissen** – wer das Problem kannte, lag zu 92 % richtig

Die Zahlen stammen aus der Feldstudie im Buch (Kap. 12f). Der anfängliche Staunen-Gradient war ein Artefakt kleiner Zwischenstände: Hätte die Erhebung früher geendet, stünde ein schöner, falscher Befund in der Welt. Das Buch zieht daraus die Konsequenz, Fallzahlen vorab zu planen („ohne mindestens 60 Personen pro Arm lohnt der Aufwand nicht“) und nach Vorwissen geschichtet zu randomisieren. Die Studie berichtet bewusst keine p-Werte, sondern Effektgrößen (Hedges’ g) mit Bootstrap-Intervallen. Für die Stunde ist das ein Beispiel, das nah an den Studierenden liegt: Das Spiel, das sie gerade gespielt haben, war Gegenstand einer echten Studie mit echten Schwächen.

Welche Fragen kann Ihr Projekt beantworten?

Personen pro Gruppe	10	15	20	30
zwei Gruppen, $d = 0{,}5$	0,19	0,26	0,34	0,48
zwei Gruppen, $d = 0{,}8$	0,40	0,56	0,69	0,86
Messwiederholung, $d = 0{,}5$	0,29	0,44	0,56	0,75

- Power des t-Tests, $\alpha = 0{,}05$ zweiseitig; bei Messwiederholung zählt jede Person einmal
- mit 20 Personen pro Gruppe findet man einen mittleren Effekt in einem von drei Versuchen
- Ja/Nein-Zielgrößen brauchen mehr: 50 % gegen 70 % Erfolg verlangt etwa 47 Personen pro Gruppe

Die Werte sind mit der nichtzentralen t-Verteilung gerechnet. Bei Messwiederholung (dieselben Personen in beiden Bedingungen) ist d auf die Streuung der Differenzen bezogen; für $d = 0{,}5$ und Power 0,80 genügen dann 34 Personen, für $d = 0{,}8$ 15. Der Wert für Anteile ist mit der Arkussinus-Näherung (Cohens h) gerechnet (Cohen 1988). Die Tabelle ist die wichtigste Brücke zu LE 7: Sie zeigt, welche Fragen ein Semesterprojekt mit realistischen Fallzahlen überhaupt beantworten kann.

Was daraus für Ihr Design folgt (LE 7)

- Fragen wählen, bei denen ein **großer** Effekt plausibel ist, oder dieselben Personen mehrfach messen
- metrische Zielgrößen statt Ja/Nein, wo es geht
- den kleinsten Effekt festlegen, der Sie interessieren würde, und daraus n bestimmen
- Schätzen statt Testen: „Wie groß ist der Unterschied?" mit Konfidenzintervall ist auch bei kleinem n eine ehrliche Antwort
- Bayes-Faktor mit Stoppregel (etwa *BF* > 6 oder $< \frac{1}{6}$, höchstens 40 Personen), wenn n unsicher ist
- Basisrate Ihrer Hypothese ehrlich einschätzen: Wie überraschend wäre es, wenn sie stimmt?

Diese Liste greift die Design-Skizze in LE 7 auf; dort wird der Auswertungsplan Teil der Vorlage. Die Stoppregel im vorletzten Punkt folgt dem sequentiellen Bayes-Faktor-Design von Schönbrodt u. a. (2017): Man erhebt, bis die Evidenz eine vorab festgelegte Grenze in eine der beiden Richtungen erreicht oder die Höchstzahl erreicht ist, und berichtet in jedem Fall den erreichten Bayes-Faktor. Die Grenzen und die Höchstzahl gehören, wie beim Signifikanztest das n, vor Beginn der Erhebung schriftlich fest.

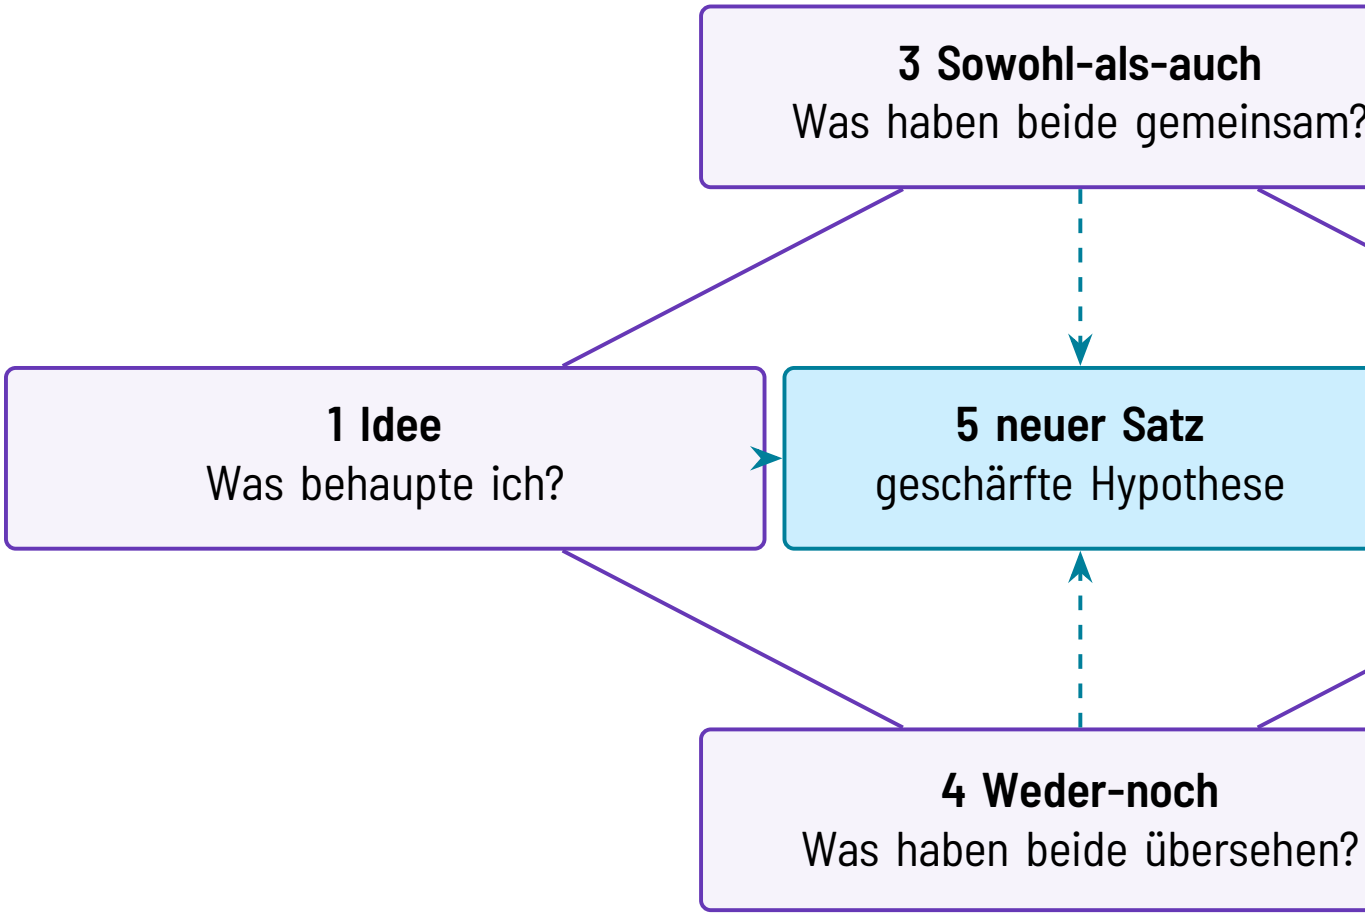
6.16 Schwierige Fragen zerlegen: Diamant und Landkarte

Wer eine Idee prüfen will, sucht fast immer zuerst nach dem, was sie bestätigt (LE 5, LE 8). Für den Bayes-Faktor ist das doppelt schädlich: Er braucht eine *Alternative*, und die Qualität der Prüfung hängt davon ab, wie gut diese Alternative ist. Eine einfache Arbeitsabfolge, um systematisch Alternativen zu erzeugen, ist die *Diamond-Technik* aus dem NLP-Coaching (Fellehner 2026). Sie stellt einer Ausgangsidee ihr Gegenteil, ein *Sowohl-als-auch* und ein *Weder-noch* gegenüber und fragt für jede Position, was sie ermöglicht und was sie verhindert. Die Figur ist älter als das NLP: Sie entspricht dem Tetralemma der indischen Logik, das Varga von Kibéd und Sparrer (2000) für die systemische Beratung aufbereitet haben.

Zur Einordnung, wie es sich in einem Methodenkurs gehört: Als Coaching-Methode ist die Diamond-Technik kaum empirisch geprüft; das sagt auch die Quelle selbst. Hier wird sie nicht als Intervention eingesetzt, sondern als *Denkgerüst* zum Erzeugen von Gegenhypothesen. Dafür wird jeder Schritt in eine Forschungsfrage übersetzt. Aus „ermöglicht / verhindert" wird „erlaubt / verbietet": Welche Beobachtungen sagt diese Position voraus, welche schließt sie aus? Das ist Poppers Frage aus LE 5, und es ist zugleich die Frage nach den Likelihoods, aus denen der Bayes-Faktor entsteht. Beobachtungen, die alle Positionen gleich gut erwarten, haben einen Bayes-Faktor nahe 1 und entscheiden nichts; das *Sowohl-als-auch* macht diese Beobachtungen sichtbar. Das *Weder-noch* ist der Ort der dritten Erklärung, also der Störvariablen, die in LE 7 kontrolliert werden müssen.

Was beim Zerlegen herauskommt, wird auf einer Landkarte festgehalten: ein Weg von der Ausgangsidee zur geschärften Hypothese, mit allem, was unterwegs geklärt wurde, und mit den Hindernissen, die noch im Weg liegen. Die Karte ist bewusst spielerisch, aber sie hat eine strenge Regel: Jedes Element trägt einen Beleg oder eine Zahl. So wird sie zur Vorlage für die Design-Skizze in LE 7 und später für den Limitationen-Abschnitt der Seminararbeit: Die Drachen, die am Ende noch auf der Karte stehen, sind genau die Einschränkungen, die man berichten muss.

Der Diamant: vier Positionen

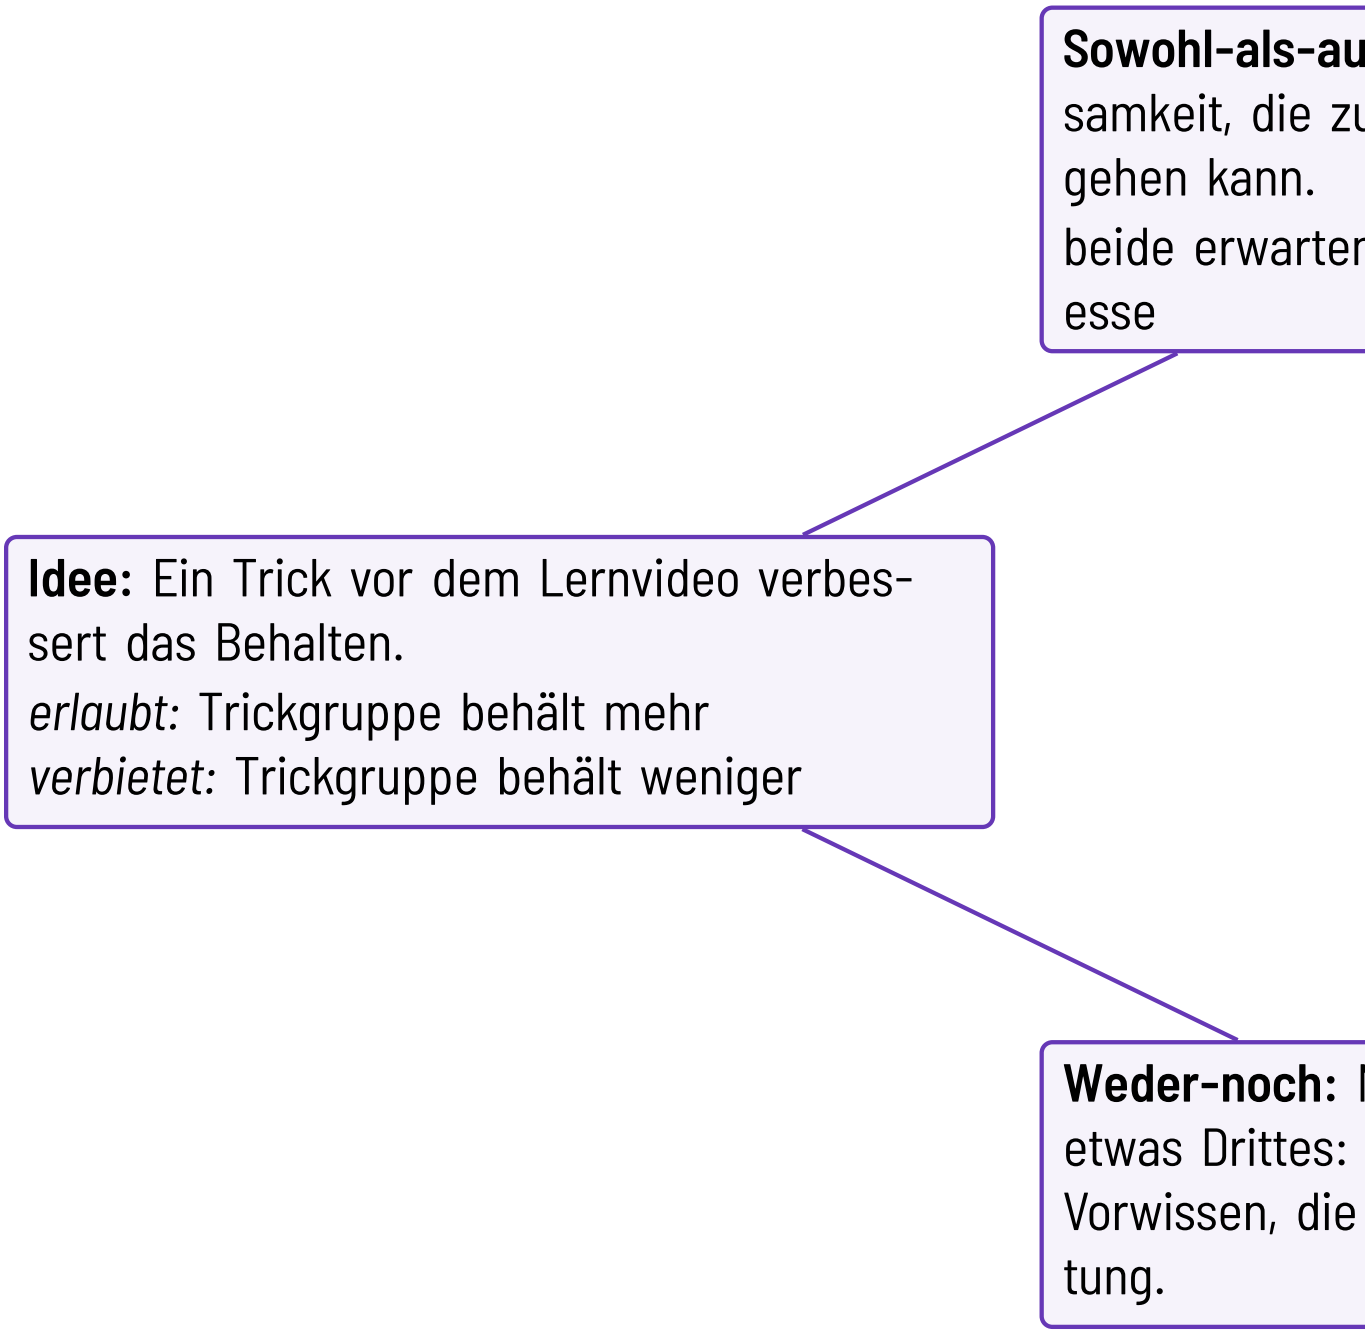


- an jeder Position: Was **erlaubt** sie, was **verbietet** sie? (welche Daten?)
- zum Schluss: Prüfplan und Ökocheck – kann mein n das klären?

Vom Coaching zur Forschungsfrage

Schritt im Diamanten	Frage in der Forschung
Idee	H_1: Was genau behaupte ich, über wen?
Gegenteil	Gegenhypothese: nicht nur „kein Effekt", sondern „der Effekt geht in die andere Richtung"
Sowohl-als-auch	Was sagen Idee *und* Gegenteil voraus? Solche Daten haben $BF \approx 1$ und entscheiden nichts
Weder-noch	dritte Erklärung: Störvariable, andere Ursache, falsch gestellte Frage
ermöglicht / verhindert	welche Beobachtung jede Position erlaubt bzw. verbietet $\Rightarrow$ Likelihoods
neuer Satz	geschärfte Hypothese, die zwischen den Positionen trennt
Future Pace, Ökocheck	Prüfplan: Power, Basisrate, Stoppregel; was würde mich umstimmen?

Beispiel: „Ein Zaubertrick hilft beim Lernen"



Das Beispiel ist die Leitthese des Buchs, an der auch der t-Test dieser Einheit gerechnet wurde, und es führt direkt zu dem Störfaktor, den die Becher-Monty-Hall-Studie selbst benennt: Die Kontrollfassung ist rund zwei Minuten kürzer (*WuZ-Buch*, Kap. 12d; ausführlich in LE 7). Das Gegenteil ist hier keine bloße Verneinung, sondern eine ernstzunehmende Gegenhypothese: Ein verblüffender Einstieg kann Arbeitsgedächtnis binden, das dann für den Inhalt fehlt. In der Stunde wird der Diamant gemeinsam an der Tafel gefüllt; die Folie dient als Lösung.

Welche Beobachtung trennt die Positionen?

Beobachtung	Idee	Gegenteil	Weder-noch (Länge)
Trickgruppe staunt mehr (Manipulationscheck)	0,9	0,9	0,5
Trickgruppe behält mehr als die kürzere Kontrolle	0,7	0,1	0,7
Trickgruppe behält mehr als eine *gleich lange* Kontrolle ohne Staunen	0,7	0,1	0,2

- Zahlen: grob geschätzte Wahrscheinlichkeit der Beobachtung unter jeder Position

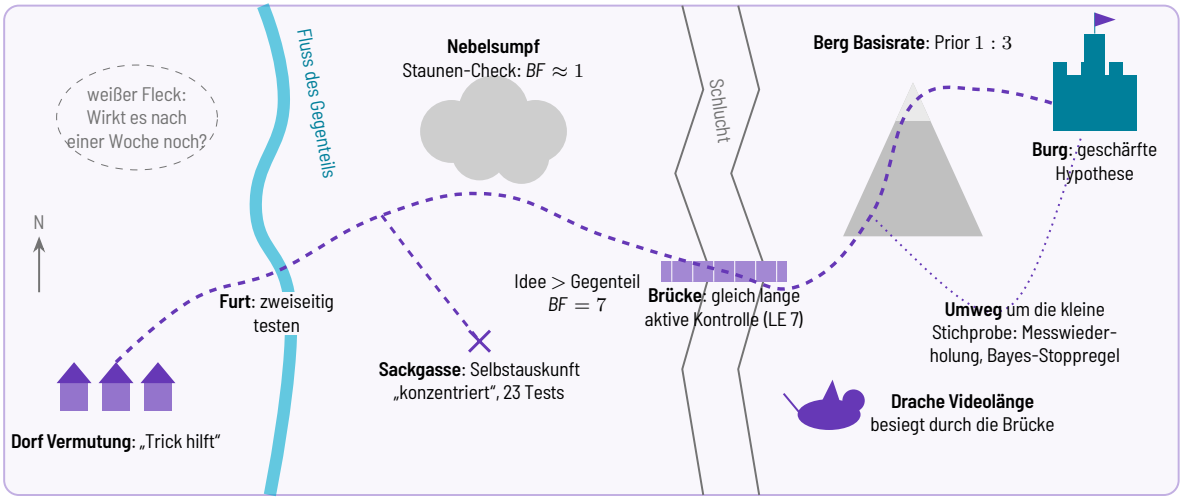
- Zeile 1: Idee gegen Gegenteil $BF = 0{,}9/0{,}9 = 1$ – **Nebel**, entscheidet nichts
- Zeile 2: trennt Idee von Gegenteil ($BF = 7$), aber nicht von der Länge ($BF = 1$)
- Zeile 3: trennt beides ($BF = 7$ bzw. $3{,}5$) – **das ist die Studie, die man bauen muss**

Die Wahrscheinlichkeiten sind Schätzungen, und sie sollen es sein: Es geht nicht um die dritte Nachkommastelle, sondern darum, welche Beobachtung überhaupt zwischen den Positionen unterscheidet. Die Tabelle zeigt in drei Zeilen, warum ein Manipulationscheck zwar nötig, aber kein Beleg für die Idee ist, und warum die längengleiche aktive Kontrolle, die das Buch als Abhilfe vorschlägt, den Unterschied macht. Wer so eine Tabelle vor der Studie aufschreibt, hat seinen Auswertungsplan im Kern schon fertig.

Neuer Satz, Prüfplan, Ökocheck

- **neuer Satz:** „Ein staunenswerter Einstieg verbessert das Behalten gegenüber einem gleich langen Einstieg ohne Staunen, vor allem bei Personen ohne Vorwissen."
- **Basisrate:** offen, eher skeptisch: Prior-Chance $1:3$
- **Power:** erwartet $d \approx 0{,}5$; mit 20 Personen pro Gruppe nur 0,34 $\Rightarrow$ Messwiederholung (zwei Videos je Person) oder Bayes-Faktor mit Stoppregel
- **was mich umstimmt:** $BF_{01} > 6 \Rightarrow$ Idee aufgeben oder neu fassen
- **Ökocheck:** Ist das ethisch und organisatorisch machbar? Täuschen wir jemanden? (LE 13)

Die Landkarte der Untersuchung



Ihre eigene Karte: die Legende

Kartenelement	bedeutet
Dorf (Start)	Ausgangsidee, so naiv, wie sie war
Weg	ein geklärter Schritt, beschriftet mit Beleg oder Bayes-Faktor
Fluss, Furt	das Gegenteil; die Furt ist der Ort, an dem es geprüft wurde
Nebel	Befunde, die zu Idee *und* Gegenteil passen ($BF \approx 1$)
Drache	offene dritte Erklärung (Störvariable)
Brücke	Designentscheidung, die einen Drachen besiegt
Berg	niedrige Basisrate: mehr Evidenz nötig
Sackgasse	verworfene Idee, mit Grund
weißer Fleck	was niemand weiß, auch Sie nicht
Burg (Ziel)	geschärfte Hypothese oder Befund

- Regel: **jedes** Element trägt eine Quelle oder eine Zahl
- Drachen, die am Ende noch stehen, gehören in die Limitationen

Merke

Eine Idee prüft man am besten gegen ihre stärkste Alternative. Der Diamant erzeugt Alternativen, die Tabelle „Welche Beobachtung trennt?“ zeigt, welche Daten sich lohnen, und die Landkarte hält fest, was geklärt ist und was noch im Weg liegt.

Diamant und Landkarte in der Stunde

Den Diamanten am Zaubertrick-Beispiel gemeinsam füllen: vier Felder an der Tafel, Zurufe sammeln, dann erst die Folie zeigen. Erfahrungsgemäß formulieren Studierende das Gegenteil zunächst als bloße Verneinung („Der Trick hilft nicht“); die Rückfrage „Und wenn er schadet, warum?“ führt zur stärkeren Gegenhypothese. Das *Weder-noch* ist der schwierigste Schritt; hilfreich ist die Frage „Was müsste passieren, damit Idee und Gegenteil *beide* falsch sind?“. Für die Landkarte reicht in der Stunde das Zeigen des Beispiels; die eigene Karte entsteht als Hausaufgabe (Teil B, Aufgabe 8) auf einem A3-Blatt und wird in LE 7 zur Design-Skizze mitgebracht. Wer mag, darf zeichnen; bewertet wird nicht die Grafik, sondern ob jedes Element einen Beleg trägt. Eine Grenze sollte man offen ansprechen: Der Diamant stammt aus dem Coaching, wo er Glaubenssätze lockern soll. In der Forschung ist er ein Werkzeug zum Erzeugen von Hypothesen, kein Beleg für irgendetwas.

6.17 Warnung: Bedeutung aus Zufall

Optional, wenn Zeit bleibt (sonst ausführlich in LE 10): eine kurze Demonstration, die zeigt, wie leicht ein „auffälliger“ Befund entsteht, wenn man nur oft genug testet. Jede Person sagt zehn Münzwürfe ihres Nachbarn vorher. Wer acht oder mehr Treffer hat, gilt als „auffällig“: Die Wahrscheinlichkeit dafür beträgt bei reinem Raten $56/1024 \approx 5{,}5\,\%$, liegt also etwa an der üblichen Signifikanzschwelle. Bei 30 Personen ist die Wahrscheinlichkeit, dass mindestens eine Person „auffällig“ wird, $1 - (1 - 0{,}0547)^{30} \approx 81\,\%$; im Mittel sind es 1,6 Personen. Wird jemand „hellsichtig“, ist die Demonstration gelungen. Wird niemand hellsichtig, gelingt sie auch, weil man dann ausrechnet, wie selten das ist. Die ausführliche Fassung mit dem Vorhersage-Trick aus dem Buch (Abschnitt 10d) folgt in LE 10. Dass solche Freiheiten in echten Studien die Fehlerquote weit über die nominellen 5 % treiben, haben Simmons u. a. (2011) gezeigt.

Wer von Ihnen ist hellsichtig?

- sagen Sie zehn Münzwürfe Ihres Nachbarn vorher, notieren Sie die Treffer
- 8 oder mehr Treffer gelten als „auffällig“ (bei Raten: 5,5 %)
- wer hat 8 oder mehr?
- bei 30 Personen gibt es mit etwa 81 % mindestens eine „Hellseherin“

Was ist hier passiert?

- viele Tests: Ein „Treffer“ ist fast garantiert
- wer nur den Treffer berichtet, macht aus Zufall einen Befund
- das ist der Kern von **p-Hacking**
- Gegenprobe: Die „Hellseherin“ sagt noch einmal zehn Würfe vorher
- mehr dazu in LE 10: der Vorhersage-Trick

Die Gegenprobe ist die eigentliche Pointe und sollte nach Möglichkeit live gemacht werden. Die „auffällige“ Person rät beim zweiten Durchgang mit hoher Wahrscheinlichkeit nur noch durchschnittlich. Das ist Regression zur Mitte und zugleich die Logik der Replikation.

Merke

Ein kleiner p-Wert sagt, dass die Daten schlecht zur Nullhypothese passen. Er sagt nicht, dass die eigene Hypothese stimmt, nicht, wie groß der Effekt ist, und gar nichts mehr, wenn man ihn unter vielen Versuchen ausgesucht hat.

6.18 Zeitungsstatistik lesen

Zeitungsstatistik lesen

- Übungsblatt Teil B, Aufgabe 7, oder eine aktuelle Meldung
- Was wurde gemessen, an wem, an wie vielen?
- Was wird behauptet: Beschreibung, Unterschied, Ursache?
- Wird eine Effektgröße genannt oder nur „signifikant“?
- Wie viele Vergleiche wurden vermutlich gerechnet?
- Wie hoch ist die Basisrate für eine solche Behauptung?

Hinweis für Lehrende

Die vollständig nachgerechneten Lösungen stehen im Erwartungshorizont am Ende von Teil B des Übungsblatts. Bei der Datensatz-Analyse (Hausaufgabe nach Sitzung 1) sollte man in der Besprechung (zu Beginn von Sitzung 2 oder in der Sprechstunde) drei Stellen gezielt aufgreifen: (1) Quartile hängen vom Berechnungsverfahren ab; Taschenrechner, Tabellenkalkulation und Handrechnung liefern leicht verschiedene Werte. Das ist kein Fehler, muss aber angegeben werden. (2) Der Vergleich der Vorwissensgruppen kippt je nach Kennwert: Der Mittelwert spricht für einen Unterschied, der Median nicht. Ursache sind der Ausreißer und die größere Streuung in der Gruppe ohne Vorwissen. Der t-Test ist nicht signifikant; das Konfidenzintervall des Unterschieds reicht weit über null hinaus. Der Bayes-Faktor (Sitzung 2) spricht leicht für „kein Unterschied“, ist aber zu klein, um das zu belegen. (3) Die Staunen-Werte sind ordinal; ein Mittelwert wird oft trotzdem berechnet. Bei der Zeitungsstatistik genügt es, wenn die Gruppe mindestens zwei der Fragen auf der Folie beantworten kann und benennt, welche Information fehlt.

6.19 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- das Monty-Hall-Problem mit bedingter Wahrscheinlichkeit erklären
- deskriptive und schließende Statistik unterscheiden
- Standardabweichung und Standardfehler berechnen und unterscheiden
- den Zentralen Grenzwertsatz erklären und ein Konfidenzintervall richtig deuten
- einen Binomialtest und einen t-Test von Hand rechnen und typische Fehldeutungen des p-Werts benennen
- mit Basisrate und Bayes-Faktor in Chancenform rechnen und erklären, warum derselbe Befund je nach Basisrate Verschiedenes bedeutet
- frequentistische und bayesianische Fragen unterscheiden
- Effektgröße, Power und Stichprobengröße in Beziehung setzen und abschätzen, welche Frage Ihr Projekt beantworten kann
- eine Idee mit dem Diamanten in Gegenhypothesen zerlegen und die Beobachtungen benennen, die zwischen ihnen trennen

Bis zur nächsten Woche

- **Basisrate** (Teil B, Aufgabe 5): Taxi und Zeuge
- **Zeitungsmeldung** methodisch lesen (Teil B, Aufgabe 7)
- **Diamant und Landkarte** für Ihre eigene Idee (Teil B, Aufgabe 8), auf A3, mitbringen zu LE 7
- **Auswertungsplan** für Ihr Projekt (Teil B, Aufgabe 9): Zielgröße, kleinster interessanter Effekt, realistisches n, Power – Sie brauchen ihn für die Design-Skizze in LE 7
- **Tagebuch des Staunens**: Wann hat Ihr Gefühl für Wahrscheinlichkeit Sie zuletzt getäuscht?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 6**

Handout: Statistik: Signifikanztest und Bayes

Worum es heute ging. Drei Becher, eine Kugel: Die Spielleitung öffnet wissentlich einen leeren Becher, Wechseln gewinnt in zwei von drei Fällen. Öffnet sie blind, ist es egal. Dasselbe Bild, zwei Prozesse, zwei Wahrscheinlichkeiten. Statistik prüft solche Täuschungen der Intuition, und zwar auf zwei Arten.

	frequentistisch	**bayesianisch**
Frage	Wie überraschend wären die Daten, wenn H_0 stimmt?	Welche Hypothese sagt die Daten besser voraus?
Ergebnis	p-Wert, Konfidenzintervall	Bayes-Faktor, Posterior
braucht	H_0, α, n vorab festgelegt	H_0, konkrete H_1, Prior (Basisrate)
kann nicht	H_0 stützen; sagen, wie wahrscheinlich H ist	ohne offen gelegten Prior auskommen

Kernbegriffe

Standardabweichung, Standardfehler s: typischer Abstand der *Werte* vom Mittelwert. *SE* $= s/\sqrt{n}$: wie genau der *Mittelwert* bestimmt ist; schrumpft mit wachsendem n.

Zentraler Grenzwertsatz Mittelwerte vieler unabhängiger Werte sind annähernd normalverteilt, egal wie die Einzelwerte verteilt sind.

Konfidenzintervall Schätzwert $\pm 1{,}96$ *SE*; das Verfahren fängt den wahren Wert in 95 % der Wiederholungen ein.

Bedingte Wahrscheinlichkeit $P(A \mid B)$. Die Richtung zählt: $P(\text{Daten} \mid H) \neq P(H \mid \text{Daten})$.

p-Wert Wahrscheinlichkeit für mindestens so extreme Daten, *falls* H_0 stimmt. Kein Maß für die Wahrheit einer Hypothese und keins für die Größe eines Effekts (Wasserstein und Lazar 2016).

Basisrate Wie häufig ist das Gesuchte, bevor man hinschaut? Ohne sie lässt sich kein positiver Test und kein signifikanter Befund deuten.

Bayes-Faktor $BF_{10} = P(\text{Daten} \mid H_1)/P(\text{Daten} \mid H_0)$: 1–3 kaum der Rede wert, 3–20 positiv, über 20 stark (Kass und Raftery 1995); unter 1 spricht für H_0.

Effektgröße, Power Cohens d (0,2 klein, 0,5 mittel, 0,8 groß); Power = Chance, einen vorhandenen Effekt zu finden. Für $d = 0{,}5$ und Power 0,80: 64 Personen pro Gruppe.

Rechnen in drei Zeilen

- Chancenform: *Chance nachher* = *Chance vorher* $\times$ BF_{10}; Chance $a : b$ = Wahrscheinlichkeit $a/(a+b)$. Würfel, 10 Sechsen in 30 Würfen, „gezinkt" = $P(6) = \frac{1}{3}$: $BF_{10} = 2^{10} \cdot 0{,}8^{20} \approx 12$; bei Basisrate $1:4$ also $12:4$, rund 75 %.
- t-Test, zwei Gruppen: $t = (\bar{x}_1 - \bar{x}_2) \,/\, (s_p\sqrt{1/n_1 + 1/n_2})$, $df = n_1 + n_2 - 2$; $d = (\bar{x}_1 - \bar{x}_2)/s_p$.
- Faustformel (Wagenmakers 2007): $BF_{01} \approx \sqrt{N}\,(1 + t^2/df)^{-N/2}$, N = alle Personen. Genauer: JASP.

Skalen: nominal (Modus), ordinal (Median, Quartile), metrisch (Mittelwert, s). Ausreißer nach Tukey (1977): mehr als $1{,}5 \cdot IQR$ unter Q_1 oder über Q_3.

Merke

Erst fragen, wie die Daten zustande kamen, dann rechnen. Ein kleiner p-Wert ist kein Beweis; was man glauben sollte, bestimmen die Daten *und* die Basisrate. Und vor jeder Studie: Kann mein n die Frage überhaupt beantworten?

Zum Weiterlesen: Döring und Bortz (2016b), Kap. 12; Wagenmakers (2007); Gigerenzer und Hoffrage (1995); zum Ziegenproblem Krauss und Wang (2003).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 6**

Übungsblatt A: Becher, Würfel und Daten

Name: _____ Datum: _____

Aufgabe 1: Monty Hall in Paaren

in der Stunde, Paare, 10 Min.

Die Spielleitung würfelt verdeckt die Lage der Kugel (1–2: A, 3–4: B, 5–6: C), die spielende Person zeigt auf einen Becher, die Spielleitung öffnet einen *leeren*, nicht gewählten Becher. Ungerade Runden: bleiben, gerade Runden: wechseln. Kreuzen Sie an, ob gewonnen wurde.

Rd.	Strategie	Kugel	gewonnen	Rd.	Strategie	Kugel	gewonnen
1	bleiben			13	bleiben		
2	wechseln			14	wechseln		
3	bleiben			15	bleiben		
4	wechseln			16	wechseln		
5	bleiben			17	bleiben		
6	wechseln			18	wechseln		
7	bleiben			19	bleiben		
8	wechseln			20	wechseln		
9	bleiben			21	bleiben		
10	wechseln			22	wechseln		
11	bleiben			23	bleiben		
12	wechseln			24	wechseln		

Summe: **bleiben** _____ von _____ gewonnen **wechseln** _____ von _____ gewonnen Kurs gesamt (Tafel): _____

Aufgabe 2: Würfel-Mittelwerte: der Zentrale Grenzwertsatz

in der Stunde, einzeln, 8 Min.

Würfeln Sie fünfmal und notieren Sie die Augenzahlen. Berechnen Sie den Mittelwert. Wiederholen Sie das viermal und tragen Sie alle vier Mittelwerte als Punkte auf der Zahlengerade an der Tafel ein.

Serie	1.	2.	3.	4.	5.	Mittelwert
1						
2						
3						
4						

1. *Vor* dem Würfeln: Ein einzelner Wurf hat Mittelwert 3,5 und Standardabweichung 1,71. Wie groß ist der Standardfehler eines Mittelwerts aus 5 Würfen? Zwischen welchen Werten sollten etwa 95 % der Punkte an der Tafel liegen?
2. Stimmt Ihre Vorhersage mit dem Bild an der Tafel überein? Welche Form hat es?
3. Wie würde das Bild aussehen, wenn jeder Punkt der Mittelwert aus 20 Würfen wäre?

Aufgabe 3: Datensatz-Analyse

Hausaufgabe, Kleingruppe

Fiktiver Datensatz (konstruiert für diese Übung, keine echte Erhebung): 50 Personen haben ein Ideomotor-Pendel gehalten (vgl. LE 1). Gemessen wurde der größte Ausschlag in Millimetern (**mm**), danach gaben die Personen an, wie stark sie gestaunt haben (**St**, 1 = gar nicht bis 5 = sehr), und ob sie den Pendeleffekt vorher kannten (**VW**, 1 = ja, 0 = nein).

Nr	mm	St	VW	Nr	mm	St	VW	Nr	mm	St	VW	Nr	mm	St	VW	Nr	mm	St	VW
1	11	3	0	11	9	3	0	21	10	2	1	31	43	3	1	41	47	4	0
2	5	2	0	12	24	2	0	22	26	4	1	32	57	4	0	42	59	3	0
3	15	3	1	13	24	4	1	23	39	4	0	33	21	3	0	43	26	3	0
4	41	4	1	14	8	2	0	24	15	4	0	34	96	5	0	44	31	4	1
5	37	3	0	15	16	2	1	25	13	3	0	35	49	4	0	45	23	2	0
6	39	5	0	16	25	4	0	26	13	3	0	36	30	4	0	46	20	3	1
7	18	3	0	17	19	5	0	27	66	5	0	37	23	4	0	47	12	1	1
8	0	1	0	18	53	4	1	28	35	3	1	38	53	4	0	48	36	4	1
9	16	2	1	19	5	2	1	29	38	5	0	39	18	2	0	49	18	3	0
10	31	4	1	20	45	5	0	30	26	3	1	40	73	5	0	50	40	4	0

1. Bestimmen Sie für jede Variable das Skalenniveau.
2. Berechnen Sie für **mm**: Minimum, Maximum, Spannweite, Median, Q_1, Q_3, *IQR* und Mittelwert. Geben Sie an, wie Sie die Quartile bestimmt haben.
3. Zeichnen Sie ein Histogramm (Klassenbreite 10 mm) und einen Boxplot. Gibt es Ausreißer nach der $1{,}5 \cdot IQR$-Regel (Werte mehr als $1{,}5 \cdot IQR$ unter Q_1 oder über Q_3)? Was würden Sie mit ihnen tun?
4. Berechnen Sie Mittelwert und Median von **mm** ohne den Ausreißer. Welcher Kennwert reagiert stärker, und warum?
5. Fassen Sie **St** sinnvoll zusammen. Ist ein Mittelwert zulässig?
6. Berechnen Sie den Standardfehler des Mittelwerts von **mm** und ein 95-%-Konfidenzintervall. Was sagt das Intervall, was nicht?
7. Vergleichen Sie **mm** zwischen Personen mit und ohne Vorwissen mit Mittelwert *und* Median. Was fällt auf?
8. Rechnen Sie für denselben Vergleich einen t-Test von Hand (gepoolte Standardabweichung). Nach Sitzung 2: Ergänzen Sie den Bayes-Faktor nach der Faustformel. Was sagen beide Ergebnisse, und was sagen sie nicht?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 6**

Übungsblatt B: Würfel-Detektive, Basisrate, Glaubwürdigkeit, Projekt

Name: _____ Datum: _____

Aufgabe 4: Würfel-Detektive

in der Stunde, Paare, 10 Min.

Rollen: W = Werferin, D = Detektivin. **1.** W öffnet den Umschlag und liest die Karte *allein*: „fair" (Treffer ist nur die 6) oder „gezinkt" (Treffer sind 5 und 6). **2.** W würfelt verdeckt unter einem Becher und sagt nur „Treffer" oder „kein Treffer". **3.** D macht einen Strich, nach genau **30** Würfen ist Schluss. **4.** D wertet beide Wege aus und entscheidet. **5.** Erst dann deckt W die Karte auf. Bekannt ist: Jeder fünfte Umschlag ist gezinkt (Basisrate $1:4$).

Treffer (Strichliste)	
Kein Treffer (Strichliste)	

Treffer k	3	4	5	6	7	8	9	10	11	12	13	14
$p = P(X \geq k \mid \text{fair})$	0,90	0,76	0,58	0,38	0,22	0,11	0,051	0,020	0,007	0,002	0,0005	0,0001
$BF_{10} = 2^k \cdot 0{,}8^{30-k}$	0,02	0,05	0,12	0,30	0,76	1,9	4,7	11,8	30	74	184	461
$P(\text{gezinkt})$ bei $1:4$	0,5 %	1 %	3 %	7 %	16 %	32 %	54 %	75 %	88 %	95 %	98 %	99 %

1. **Frequentistisch:** H_0: fair. p-Wert für Ihr k: _____. Bei $\alpha = 0{,}05$ ist der Würfel ☐ signifikant gezinkt ☐ nicht auffällig.
2. **Bayesianisch:** BF_{10} = _____; Chance vorher $1:4$, Chance nachher _____; $P(\text{gezinkt})$ = _____. Rechnen Sie einmal selbst nach, ohne die letzte Zeile der Tabelle.
3. Umschlag öffnen. Wer hatte recht? Tragen Sie Ihr Paar an der Tafel in die Vierfeldertafel ein.
4. Wie sähe Ihr Bayes-Urteil aus, wenn nur einer von 100 Würfeln gezinkt wäre? Und Ihr Testurteil?

Aufgabe 5: Basisrate: Taxi und Test

Hausaufgabe

In einer Stadt fahren 85 % grüne und 15 % blaue Taxis. Nach einem Unfall mit Fahrerflucht sagt ein Zeuge, das Taxi sei blau gewesen. Tests zeigen: Unter den Sichtbedingungen jener Nacht erkennt er die Farbe in 80 % der Fälle richtig (Tversky und Kahneman 1982).

1. Schätzen Sie zuerst aus dem Bauch: Wie wahrscheinlich war das Taxi blau?
2. Rechnen Sie mit natürlichen Häufigkeiten (100 Unfälle) und zeichnen Sie den Baum wie auf der Folie zum Medizintest.
3. Rechnen Sie dasselbe in Chancenform: Prior-Chance, Bayes-Faktor des Zeugen, Posterior-Chance.
4. Ein zweiter, unabhängiger Zeuge mit derselben Treffsicherheit sagt ebenfalls „blau". Wie wahrscheinlich ist es jetzt?
5. In einer anderen Stadt sind die Hälfte der Taxis blau. Was ändert sich bei einem Zeugen, was nicht?

Aufgabe 6: Glaubwürdigkeits-Check mit der Suchmaschine

in der Stunde, Kleingruppe, 12 Min.

Behauptung (Karte): _____

Basisrate *vor* der Suche: Von 100 Behauptungen dieser Art stimmen etwa _____, weil

Fund (Quelle, was steht dort?)	**erwartbar, wenn wahr? wenn falsch?**	**Faktor**	**Chance**
Start: Basisrate		–	

Faktoren grob: $\times 10$, $\times 3$, $\times 1$, $\times \frac{1}{3}$, $\times \frac{1}{10}$. Nur unabhängige Funde multiplizieren; zehn Seiten mit derselben Pressemitteilung sind *ein* Fund. Ergebnis: $P(\text{stimmt}) \approx$ _____. Welcher Fund hat am meisten bewegt?

Aufgabe 7: Eine Zeitungsmeldung lesen

Hausaufgabe

Fiktive Meldung (konstruiert für diese Übung):

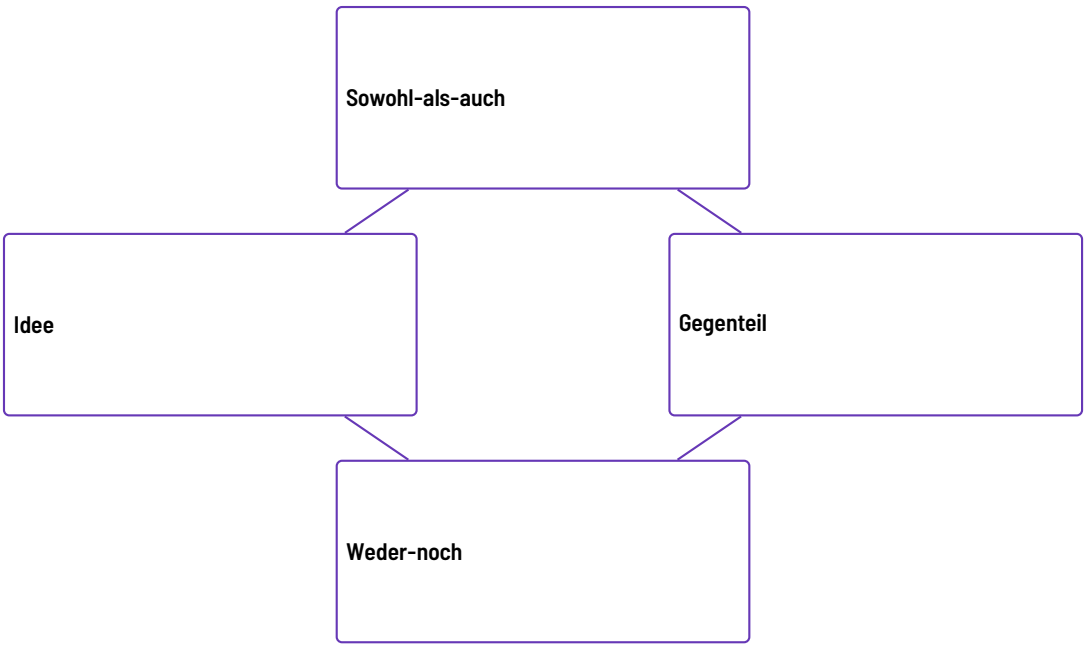
> *Zaubertricks machen klüger – jetzt bewiesen.* Wer vor dem Lernen einen Zaubertrick sieht, behält mehr. Das zeigt eine Online-Befragung unter 112 Studierenden. Die Forschenden erhoben 23 Merkmale des Lernverhaltens. Bei der Frage „Ich konnte mich gut konzentrieren" lag die Gruppe mit Zaubertrick signifikant vorn ($p = 0{,}04$). „Damit ist der Nutzen von Magie im Hörsaal wissenschaftlich belegt", sagt die Studienleiterin.

Beantworten Sie: Was wurde gemessen, an wem? Was wird behauptet? Wird eine Effektgröße genannt? Wie viele Vergleiche wurden gerechnet, und was folgt daraus für den einen signifikanten Befund? Welche Basisrate würden Sie für die Behauptung ansetzen? Wer mag, wendet dieselben Fragen auf einen echten Artikel an, der eine Studie mit $p < 0{,}05$ als „Beweis" darstellt.

Aufgabe 8: Diamant und Landkarte für Ihre Idee

Hausaufgabe, A3, mitbringen zu LE 7

Nehmen Sie Ihre Hypothese aus LE 5 als *Idee* und füllen Sie den Diamanten. Notieren Sie an jeder Position, welche Beobachtung sie *erlaubt* und welche sie *verbietet*.



1. Welche Beobachtung trennt Idee und Gegenteil? Welche trennt die Idee vom Weder-noch? Schätzen Sie grob, wie wahrscheinlich die Beobachtung unter jeder Position ist, und berechnen Sie den Bayes-Faktor.

2. Formulieren Sie den neuen, geschärften Satz.

3. Zeichnen Sie auf A3 die Landkarte Ihrer Untersuchung (Legende auf der Folie): Startdorf, Wege, Nebel, Drachen, Brücken, Sackgassen, weiße Flecken, Ziel. Jedes Element trägt eine Quelle oder eine Zahl.

Aufgabe 9: Auswertungsplan für Ihr Projekt

Hausaufgabe, Grundlage der Design-Skizze in LE 7

H_1 (aus LE 5)	
Zielgröße und Skalenniveau	
Vergleich: zwei Gruppen, Messwiederholung oder Anteile?	
kleinster Effekt, der Sie interessieren würde	
realistisches n (wer, wie viele?)	
Power laut Tabelle auf der Folie	
Auswertung: Test, Schätzung mit Intervall oder Bayes-Faktor mit Stoppregel?	
Basisrate Ihrer Hypothese: Wie überraschend wäre es, wenn sie stimmt?	
Folgerung: Passt die Frage zum n, oder ändern Sie Frage oder Design?	

Aufgabe 10: Tagebuch des Staunens

Hausaufgabe

Wann hat Ihr Gefühl für Wahrscheinlichkeit Sie zuletzt getäuscht? Notieren Sie Erwartung, Ereignis und den passenden Begriff aus dieser Einheit.

Erwartungshorizont

Aufgabe 1. Erwartet sind pro Paar etwa 8 von 12 Gewinnen beim Wechseln und 4 von 12 beim Bleiben. Einzelne Paare streuen stark (die Standardabweichung der Gewinnzahl bei 12 Wechselrunden beträgt etwa 1,6), manche Paare finden sogar das Gegenteil. Erst der Kurs-Pool zeigt das Muster stabil. Das ist der Anlass, über Stichprobengröße zu sprechen.
Aufgabe 2. (1) $SE = 1{,}71/\sqrt{5} \approx 0{,}76$; etwa 95 % der Mittelwerte zwischen $3{,}5 \pm 2 \cdot 0{,}76$, also 2,0 und 5,0. (2) Das Bild ist eine Glocke um 3,5, obwohl einzelne Würfe gleichverteilt sind; von 120 Punkten liegen im Mittel etwa vier außerhalb von 2,0 bis 5,0 (exakt 3,2 % je Punkt; die Normalnäherung sagt 5 %). (3) Mit 20 Würfen: $SE \approx 0{,}38$, die Glocke wäre halb so breit (etwa 2,7 bis 4,3).
Aufgabe 3 (Werte mit Python nachgerechnet). (1) Nr: nominal (Kennung); mm: Verhältnisskala; St: ordinal; VW: nominal (dichotom). (2) $n = 50$; Minimum 0, Maximum 96, Spannweite 96 mm; Median 25,5 mm; Mittelwert 29,94 mm; Standardabweichung $s = 19{,}32$ mm. Quartile als Median der unteren bzw. oberen Hälfte: $Q_1 = 16$, $Q_3 = 40$, $IQR = 24$. Mit linearer Interpolation (z. B. Excel `QUARTILE.INKL`) ergibt sich $Q_3 = 39{,}75$ und $IQR = 23{,}75$; beides ist richtig, wenn das Verfahren genannt wird. Modus: 18 und 26 (je dreimal). (3) Klassenhäufigkeiten 0–9: 5; 10–19: 13; 20–29: 10; 30–39: 9; 40–49: 6; 50–59: 4; 60–69: 1; 70–79: 1; 80–89: 0; 90–99: 1. Die Verteilung ist rechtsschief. Zäune: $16 - 36 = -20$ und $40 + 36 = 76$. Einziger Ausreißer ist Nr. 34 mit 96 mm; 73 mm (Nr. 40) liegt knapp innerhalb. Mit Interpolation liegen die Zäune bei $-19{,}6$ und $75{,}4$; Ergebnis gleich. Gute Antworten löschen den Wert nicht stillschweigend, sondern prüfen ihn (Messfehler? jemand hat bewusst geschwungen?) und berichten beide Auswertungen. (4) Ohne Nr. 34: Mittelwert 28,59 mm, Median 25,0 mm, $s = 16{,}98$ mm. Der Mittelwert sinkt um 1,35 mm, der Median um 0,5 mm, die Standardabweichung um 2,3 mm. (5) Häufigkeiten St: 1: 2; 2: 9; 3: 15; 4: 17; 5: 7. Median 3, Modus 4. Ein Mittelwert (3,36) ist streng genommen nicht zulässig, weil die Abstände der Stufen unbekannt sind; wer ihn angibt, sollte das begründen. Optional: Spearmans Rangkorrelation zwischen mm und St beträgt $\rho = 0{,}71$. (6) Mit Vorwissen ($n = 17$): Mittelwert 25,88 mm, Median 26 mm, $s = 13{,}06$. Ohne Vorwissen ($n = 33$): Mittelwert 32,03 mm, Median 25 mm, $s = 21{,}75$. Der Mittelwert legt einen Unterschied von gut 6 mm nahe, der Median fast keinen; die Gruppe ohne Vorwissen streut stärker und enthält die beiden größten Werte (73 und 96 mm). Die erwartete Antwort: Aus

diesen Daten folgt kein belastbarer Gruppenunterschied, und die Wahl des Kennwerts bestimmt die Geschichte, die man erzählen könnte. (7) $SE = 19{,}32/\sqrt{50} \approx 2{,}73$ mm; 95-%-Intervall $29{,}94 \pm 1{,}96 \cdot 2{,}73$, also 24,6 bis 35,3 mm (mit $t_{49} = 2{,}01$: 24,4 bis 35,4 mm). Das Intervall beschreibt die Unsicherheit des *Mittelwerts*, nicht die Streuung der Personen: Die meisten Einzelwerte liegen außerhalb. Wegen der schiefen Verteilung trägt hier der Zentrale Grenzwertsatz; bei $n = 50$ ist das vertretbar. (8) Gepoolte Standardabweichung $s_p = 19{,}3$ mm, $SE = s_p\sqrt{1/33 + 1/17} = 5{,}76$ mm, $t = (32{,}03 - 25{,}88)/5{,}76 = 1{,}07$, $df = 48$, $p = 0{,}29$; $d = 0{,}32$. 95-%-Intervall des Unterschieds: $6{,}15 \pm 2{,}01 \cdot 5{,}76$, also $-5{,}4$ bis $17{,}7$ mm, es schließt null deutlich ein. Welch-Test: $t = 1{,}25$, $p = 0{,}22$. Nach Sitzung 2, Faustformel: $BF_{01} \approx \sqrt{50}\,(1 + 1{,}14/48)^{-25} \approx 7{,}07 \cdot 0{,}56 \approx 3{,}9$; JASP (JZS, $r = \sqrt{2}/2$) liefert $BF_{01} = 2{,}1$. Erwartete Deutung: kein signifikanter Unterschied; die Daten sprechen leicht für „kein Unterschied", belegen ihn aber nicht. Der Ausreißer (Nr. 34) treibt den Mittelwertunterschied; der t-Test vergleicht Mittelwerte und erbt diese Empfindlichkeit.

Aufgabe 4. Tabellenwerte exakt mit $B(30, \frac{1}{6})$ bzw. $B(30, \frac{1}{3})$ gerechnet. Signifikant ($\alpha = 0{,}05$, einseitig) ist ein Würfel ab 10 Treffern. Ein fairer Würfel erreicht das mit 2,0 %, ein gezinkter mit 57 %. Die Bayes-Regel „gezinkt, wenn $P(\text{gezinkt}) > 50\,\%$" greift bei Basisrate $1 : 4$ ab 9 Treffern (fair: 5,1 %, gezinkt: 71 %). Nachrechnen für $k = 10$: $2^{10} = 1024$, $0{,}8^{20} = 0{,}0115$, $BF_{10} = 11{,}8$; Chance $11{,}8 : 4$, also $11{,}8/15{,}8 = 75\,\%$. (4) Bei Basisrate $1 : 99$ und $k = 10$: $11{,}8 : 99$, also 11 %. Der Würfel ist dann trotz „signifikant" wahrscheinlich fair; das Testurteil ändert sich nicht, weil der Test die Basisrate nicht kennt. Bei 15 Paaren streut die Vierfeldertafel stark; erwartet sind 0–1 falsche Alarme und 1–2 erkannte von 3 gezinkten Würfeln.

Aufgabe 5. (1) Die meisten schätzen 80 %. (2) Von 100 Unfällen sind 15 mit blauen Taxis, davon erkennt der Zeuge 12 als blau; von 85 grünen hält er 17 für blau. $P(\text{blau} \mid \text{„blau"}) = 12/29 \approx 41\,\%$. (3) Prior-Chance $15 : 85$, $BF = 0{,}8/0{,}2 = 4$, Posterior $60 : 85$, also 41 %. (4) $60 : 85 \times 4 = 240 : 85$, also 74 %. (5) Prior $1 : 1$, Posterior $4 : 1$, also 80 %: Nur bei gleicher Basisrate stimmt das Bauchgefühl. Der Bayes-Faktor des Zeugen bleibt 4; er beschreibt den Zeugen, nicht die Stadt.

Aufgabe 6. Siehe den Hinweis zu den Behauptungskarten im Abschnitt „Glaubwürdigkeits-Check".

Aufgabe 7. Gemessen: Selbstauskunft, keine Lernleistung; Online-Befragung, unklar, ob die Gruppen zufällig gebildet wurden. 23 Merkmale: Bei $\alpha = 0{,}05$ erwartet man unter reinem Zufall gut einen „signifikanten" Befund ($23 \cdot 0{,}05 \approx 1{,}2$); die Wahrscheinlichkeit für mindestens einen liegt bei $1 - 0{,}95^{23} \approx 69\,\%$. Keine Effektgröße. Die Basisrate für „ein Zaubertrick verbessert das Lernen" ist offen, für „er verbessert genau die Konzentrations-Selbstauskunft, sonst nichts" niedrig. „Bewiesen" ist nichts; allenfalls liegt eine Hypothese für eine präregistrierte Folgestudie vor (Brücke zu LE 10).

Aufgabe 8. Ein gutes Gegenteil ist eine eigene Hypothese mit eigener Begründung, keine bloße Verneinung. Das Weder-noch sollte mindestens eine Störvariable enthalten, die in LE 7 kontrolliert werden kann. Entscheidend ist (1): Eine Beobachtung, die alle Positionen gleich gut erwarten, ist als Beleg wertlos; gute Lösungen erkennen das selbst. Bei der Karte wird nicht die Zeichnung bewertet, sondern ob jedes Element einen Beleg oder eine Zahl trägt und ob offene Drachen ehrlich stehen bleiben.

Aufgabe 9. Gute Pläne nennen eine konkrete Zielgröße, einen begründeten kleinsten Effekt und ein n, das sich wirklich rekrutieren lässt. Häufigste Einsicht: Mit 15–20 Personen pro Gruppe ist nur ein großer Effekt zu finden; sinnvolle Antworten sind Messwiederholung, eine metrische statt einer Ja/Nein-Zielgröße, eine Schätzfrage statt eines Tests oder ein sequentieller Bayes-Faktor mit Höchstzahl.

7 Forschungsdesign

In LE 5 wurde aus der Forschungsfrage eine Hypothese mit Widerlegungsbedingung, in LE 6 kam das Werkzeug dazu, mit dem man Daten befragt: Signifikanztest, Bayes-Faktor, Basisrate und Power. Damit ist klar, welche Fragen eine kleine Studie überhaupt beantworten kann. Jetzt geht es um den Plan, mit dem man die eigene Hypothese prüft. Ein Forschungsdesign legt fest, wer was wann unter welchen Bedingungen misst und womit verglichen wird. Die Einheit beginnt mit drei Seilen unterschiedlicher Länge, die gleich lang werden. Die Gruppe sieht das Kunststück zweimal: einmal so, wie es auf der Bühne gezeigt wird, und einmal unter Bedingungen, die sie selbst festlegt. Der Unterschied zwischen beiden Durchgängen ist der Unterschied zwischen einer Behauptung und einem Experiment. Daraus entwickelt die Einheit Designtypen, interne und externe Validität, Konfundierung und Kontrolle sowie die Gütekriterien von Messungen. Als Fallbeispiel dient die Becher-Monty-Hall-Studie aus dem Buch, mit einem sauberen Idealentwurf und einer Feldstudie, die zeigt, was in der Praxis davon übrig bleibt.

Vorbereitung vor der Stunde: Kontrollierte Seilroutine

Eine Woche vorher

- ☐ Seil-Set für eine Routine, in der drei Seile unterschiedlicher Länge gleich lang werden (klassischer Effekt, im Fachhandel als fertiges Set erhältlich oder nach der Standardliteratur selbst zusammengestellt). Zwei vollständige Sets einpacken; Seile werden schnell unansehnlich.
- ☐ **Methode und Einstudierung nach der Anleitung des Herstellers bzw. der Standardliteratur; hier bewusst nicht beschrieben.** Das Skript wird öffentlich gespiegelt.
- ☐ Zwei Präsentationen proben. *Variante A* wie auf der Bühne: Seile zeigen, Längen behaupten, Effekt, Seile ins Publikum. Dauer etwa drei Minuten. *Variante B* mit Kontrollbedingung: Die Gruppe legt vorab fest, wie Ausgangs- und Endlängen geprüft werden.
- ☐ Vor der Probe von Variante B entscheiden, welche Prüfungen Sie zulassen und welche Sie ausdrücklich verweigern. Faustregel: Alles, was die Methode gefährden könnte, wird freundlich und offen abgelehnt („Diese Kontrolle lasse ich nicht zu."). Die Ablehnung ist kein Notbehelf, sondern der didaktische Kern der Variante.
- ☐ Für Variante B ein Maßband oder einen Zollstock (2 m) und einen Flipchart-Bogen für das Messprotokoll bereitlegen.
- ☐ Das Fallbeispiel vorbereiten: *WuZ-Buch*, Kap. 12d (Studienlogik, Beat-Plan, Längendifferenz) und *WuZ-Buch*, Kap. 12f (Feldstudie, Ergebnisse). Zahlen nur so verwenden, wie sie dort stehen.

Handout und Übungsblatt

- ☐ Handout „Forschungsdesign" sowie Übungsblatt LE 7 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 7). Teil A enthält die fiktive Studienbeschreibung für die Design-Analyse und die Vorlage für die Design-Skizze vollständig und liegt zu Beginn aus; Teil B (Peer-Feedback, Tagebuch) wird zur Sicherung ausgeteilt.
- ☐ Die H_0/H_1-Blätter aus LE 5 (Aufgabe 3) zurückgeben bzw. mitbringen lassen; sie sind die Grundlage der eigenen Design-Skizze.
- ☐ Optional statt des fiktiven Falls einen echten, kurzen empirischen Artikel aus dem Fach der Gruppe auswählen (Methodenteil höchstens zwei Seiten, klare Gruppenvergleiche). Dann den Methodenteil pro Zweiergruppe einmal kopieren.

Am Tag selbst

- ☐ Seile vor der Stunde vorbereiten; das Ersatzset griffbereit, aber außer Sicht.
- ☐ Tafel in zwei Spalten teilen: „Variante A: Was haben wir gesehen?" und „Variante B: Was haben wir gemessen?".
- ☐ Für die Design-Werkstatt Zweiergruppen einteilen, die sich in der Feedback-Phase gegenseitig die Skizzen vorstellen.

Risiken und Plan B. Die Seilroutine ist bekannt; es kann sein, dass jemand sie schon gesehen hat oder die Methode kennt. Diese Person bitten, ihr Wissen für sich zu behalten, und den Umstand selbst nutzen: Vorwissen ist eine Störvariable, und genau sie hat in der Monty-Hall-Feldstudie alle Armunterschiede überstrahlt (siehe Fallbeispiel). Misslingt der Effekt, wird er nicht wiederholt; dann trägt Variante B die Stunde allein, indem die Gruppe ein Messprotokoll für eine Behauptung entwirft, die die Lehrperson nur ankündigt. Ohne Seile lässt sich der Einstieg mit einer bekannten Längentäuschung (Müller-Lyer-Figur) erst ohne, dann mit Lineal ersetzen.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Von der Hypothese (LE 5) und dem Auswertungsplan (LE 6, Hausaufgabe) zum Prüfplan: „Wie würden Sie Ihre Hypothese testen, und wie viele Personen brauchen Sie dafür?" Zwei, drei Antworten sammeln. Die Landkarten aus LE 6 liegen aus; ihre Drachen sind die Störvariablen, die das Design besiegen muss.

5–15 · Staunmoment. Seilroutine erst als Variante A ohne Vergleich, dann als Variante B mit Kontrollbedingung, die die Gruppe festlegt. Die Gruppe erlebt, wie die Kontrolle die Täuschung entlarvt oder ihre Verweigerung

die Behauptung entwertet.

15–45 · Theorie-Input. Designtypen; interne und externe Validität; Konfundierung; Gütekriterien. Fallbeispiel: das Design der Becher-Monty-Hall-Videostudie und ihr Störfaktor, dann die Feldstudie.

45–75 · Design-Werkstatt. Analyse der fiktiven Studie (UV, AV, Kontrollgruppe, Konfounder; Übungsblatt Teil A, Aufgabe 1); dann Skizze eines eigenen Designs zur eigenen Hypothese (Aufgabe 2); Messgüte-Check mit dem Vokabular aus *WuZ-Buch*, Kap. 10b.

75–90 · Sicherung. Übungsblatt Teil B austeilen; Peer-Feedback auf die Design-Skizzen in Zweiergruppen (Aufgabe 3); Abgabe der Skizze als benotete Teilleistung terminieren.

7.1 Staunmoment: Drei Seile

★ Staunmoment: Kontrollierte Seilroutine

Drei Seile: kurz, mittel, lang. *Ich mache sie gleich lang.*

Variante A: Schauen Sie zu.
Variante B: Diesmal bestimmen Sie, wie wir prüfen. Was wollen Sie vorher messen, was nachher, und womit vergleichen?

Variante A: ohne Vergleich

- Was haben Sie gesehen?
- Woher wissen Sie, dass die Seile vorher verschieden lang waren?
- Woher wissen Sie, dass sie nachher gleich lang sind?
- Wer hat gemessen – und womit?

Variante B: mit Kontrollbedingung

- Ihr Prüfplan: Was messen wir vorher, was nachher?
- Wer misst? Wer darf die Seile halten?
- Womit vergleichen wir: Maßband, ein unbeteiligtes Seil, eine zweite Person?
- Welche Prüfung lässt die Vorführende *nicht* zu – und was folgt daraus?

In Variante A ist die einzige Evidenz die Vorführung selbst. Die Längen vorher und nachher werden behauptet und durch Zeigen „belegt"; gemessen hat niemand, verglichen wurde nichts. In Variante B formuliert die Gruppe einen Prüfplan, bevor das Kunststück beginnt. Lässt die Lehrperson eine Prüfung zu, wird der Effekt an einem unabhängigen Maßstab gemessen. Verweigert sie eine Prüfung, wird sichtbar, dass die Behauptung nur unter Bedingungen gilt, die der Behauptende selbst kontrolliert. Für ein Kunststück ist das legitim, denn es behauptet nichts über die Welt. Für eine Studie wäre es ein K.-o.-Kriterium. Dieselbe Figur kennt das Buch vom Muskeltest der Applied Kinesiology: Solange der Anwender den Test kontrolliert, scheint er zu funktionieren; in einer Doppelblindstudie lag die Trefferquote kaum über dem Zufall (*WuZ-Buch*, Kap. 10b).

Was ist der Unterschied?

- A: Behauptung plus Vorführung – der Behauptende kontrolliert alles
- B: Prüfplan vorab, unabhängiger Maßstab, Vergleich vorher/nachher
- eine verweigerte Kontrolle ist selbst ein Befund
- ohne Kontrollbedingung bleiben selbst grobe Täuschungen unentdeckt

7.2 Was ein Forschungsdesign leistet

Ein Forschungsdesign ist der Plan, mit dem eine Forschungsfrage beantwortet werden soll. Es legt fest, welche Variablen erhoben oder verändert werden, an wem, zu welchen Zeitpunkten und unter welchen Bedingungen, und vor allem, womit verglichen wird (Döring und Bortz 2016a). Die *unabhängige Variable* (UV) ist die vermutete Ursache; im Experiment wird sie gezielt variiert. Die *abhängige Variable* (AV) ist die gemessene Wirkung. *Störvariablen* beeinflussen die AV ebenfalls, ohne Gegenstand der Untersuchung zu sein. Will man aus einem Zusammenhang auf Kausalität schließen, müssen drei Bedingungen erfüllt sein: Ursache und Wirkung variieren gemeinsam, die Ursache geht der Wirkung zeitlich voraus, und plausible Alternativerklärungen sind ausgeschlossen (Shadish u. a. 2002). Die dritte Bedingung ist die schwierigste, und an ihr entscheidet sich die Qualität eines Designs.

Forschungsdesign

Definition 7.1 Ein **Forschungsdesign** ist der Plan einer Untersuchung: welche Variablen an wem, wann und unter welchen Bedingungen erhoben oder verändert werden und womit die Ergebnisse verglichen werden.

- **UV:** vermutete Ursache (im Experiment gezielt variiert)
- **AV:** gemessene Wirkung
- **Störvariable:** wirkt ebenfalls auf die AV

Wann darf man auf Kausalität schließen?

- **Kovariation:** Ursache und Wirkung treten gemeinsam auf
- **zeitliche Folge:** die Ursache geht der Wirkung voraus
- **keine Alternativerklärung:** nichts anderes erklärt den Zusammenhang ebenso gut
- die dritte Bedingung ist die schwierigste – sie ist der Zweck des Designs

Seile als Design

- UV: das Kunststück (durchgeführt / nicht durchgeführt)
- AV: die Seillängen
- Variante A: eine Messung, nachher, durch den Behauptenden
- Variante B: Vorher- und Nachher-Messung, unabhängiger Maßstab
- Welche Alternativerklärungen schließt B aus, A nicht?

7.3 Designtypen

Designs lassen sich danach ordnen, ob die UV aktiv variiert wird und ob die Zuteilung zu den Bedingungen zufällig erfolgt (Shadish u. a. 2002; Döring und Bortz 2016a). Im *Experiment* variieren die Forschenden die UV und teilen die Teilnehmenden zufällig den Bedingungen zu (Randomisierung). Zufall verteilt bekannte und unbekannte Störvariablen im Mittel gleich auf die Gruppen; das macht das Experiment zum stärksten Design für Kausalaussagen. Im *Quasi-Experiment* wird die UV variiert, aber vorhandene Gruppen werden verglichen (zwei Kurse, zwei Standorte); die Gruppen können sich schon vorher unterschieden haben. Im *nicht-experimentellen* Design wird nichts verändert, nur erhoben; es zeigt Zusammenhänge, aber kaum Ursachen. Quer dazu liegt die Frage nach der Zeit: Ein *Querschnitt* misst einmal und vergleicht Personen, ein *Längsschnitt* misst dieselben Personen mehrfach und kann Veränderungen verfolgen. Die Notation von Campbell kürzt Designs ab: R steht für zufällige Zuteilung, X für die Intervention, O für eine Messung (*observation*).

Drei Grundtypen

	UV variiert?	Zufall?	Kausalaussage
Experiment	ja	ja	stark
Quasi-Experiment	ja	nein	eingeschränkt
nicht-experimentell	nein	–	schwach (Zusammenhang)

- quer dazu: **Querschnitt** (einmal messen) oder **Längsschnitt** (dieselben Personen mehrfach)

Designs in Kurzschrift

Design				Zeit →
One-Shot (Variante A)			X	O
Vorher-Nachher, eine Gruppe (Variante B)		O	X	O
Experiment mit Kontrollgruppe	R		X	O
	R			O
Experiment mit Vortest	R	O	X	O
	R	O		O

- R = Zufallszuteilung, X = Intervention, O = Messung

7.4 Interne Validität

Ein Design ist *intern valide*, wenn sich die Veränderung der AV eindeutig auf die UV zurückführen lässt. Shadish, Cook und Campbell haben die typischen Bedrohungen zusammengestellt (Shadish u. a. 2002). Die Liste ist ein Werkzeug: Wer ein Design plant oder liest, geht sie Punkt für Punkt durch und fragt, welche Bedrohung das Design ausschließt und welche nicht. Ein Vorher-Nachher-Vergleich ohne Kontrollgruppe ist anfällig für fast alle; die zufällig zugeteilte Kontrollgruppe neutralisiert die meisten, weil Geschichte, Reifung und Testeffekte beide Gruppen gleich treffen.

Bedrohungen der internen Validität

Bedrohung	Beispiel: Lernvideo mit Vorher-Nachher-Test
Geschichte	in der Woche dazwischen läuft eine Doku zum Thema
Reifung	die Teilnehmenden lernen ohnehin dazu
Testeffekt	der Vortest übt schon für den Nachtest
Instrumentierung	Nachtest ist leichter als Vortest
Regression zur Mitte	nur die Schwächsten im Vortest werden ausgewählt
Selektion	Freiwillige mit Interesse gegen Pflichtgruppe
Ausfall	die Frustrierten brechen vor dem Nachtest ab

Eine eigene Bedrohung entsteht durch die Forschenden selbst. Wenn die Person, die das Ergebnis erhofft, auch misst oder bewertet, können ihre Erwartungen die Daten verschieben, ohne dass sie es bemerkt. Der „Kluge Hans", ein Pferd, das angeblich rechnen konnte, antwortete nur dann richtig, wenn die Fragenden die Antwort kannten und sichtbar waren; es las ihre unwillkürlichen Bewegungen (Pfungst 1907). Dieselbe Logik steckt im ideomotorischen Pendel aus LE 1. Gegenmittel ist das *Blind-Design*: Wer misst, weiß nicht, in welcher Bedingung die gemessene Person war. LE 8 vertieft diesen Versuchsleitereffekt.

Die Forschenden als Störvariable

- Der Kluge Hans (1907): ein Pferd „rechnet" – solange die Fragenden die Antwort kennen und sichtbar sind
- es reagierte auf unwillkürliche Bewegungen der Fragenden
- Seile: wer vorführt, darf nicht auch messen
- Gegenmittel: **Blind-Design** – die Messenden kennen die Bedingung nicht

7.5 Konfundierung und Kontrolle

Von *Konfundierung* spricht man, wenn eine Störvariable systematisch mit der UV variiert. Dann lassen sich ihre Wirkungen nicht mehr trennen. Wer eine Lern-App freiwillig nutzt, ist im Mittel vermutlich motivierter als wer sie nicht nutzt; ein Notenunterschied kann von der App oder von der Motivation kommen. Gegen Konfundierung gibt es fünf Werkzeuge: Randomisierung, Konstanthalten (alle Bedingungen gleich bis auf die UV), Parallelisieren oder Schichten (Gruppen nach einem bekannten Störmerkmal ausbalancieren), eine geeignete Kontrollgruppe und Blindbedingungen. Die Kontrollgruppe ist dabei nicht einfach „die anderen". Eine *aktive Kontrolle* erhält eine gleich lange, gleich aufwendige Bedingung ohne den vermuteten Wirkstoff, damit sich die Gruppen nur in dem unterscheiden, was untersucht wird.

Konfundierung

Definition 7.2 Konfundierung liegt vor, wenn eine Störvariable systematisch mit der unabhängigen Variablen variiert. Ihre Wirkung auf die abhängige Variable ist dann von der Wirkung der UV nicht mehr zu trennen.

- Beispiel: freiwillige App-Nutzer sind motivierter – App oder Motivation?
- die Täuschung in Variante A: Längen und Messung lagen beim Vorführenden

Fünf Werkzeuge der Kontrolle

- **Randomisierung:** Zufall verteilt auch unbekannte Störvariablen
- **Konstanthalten:** alles gleich bis auf die UV
- **Schichten / Parallelisieren:** Gruppen nach bekanntem Störmerkmal ausbalancieren
- **Kontrollgruppe**, möglichst *aktiv*: gleich lang, gleich aufwendig, ohne Wirkstoff
- **Blindbedingungen:** Teilnehmende und Messende kennen die Bedingung nicht

7.6 Externe Validität

Ein intern valides Ergebnis gilt zunächst nur für die untersuchten Personen, unter den untersuchten Bedingungen, zum untersuchten Zeitpunkt. *Externe Validität* fragt, wie weit es sich auf andere Personen, Situationen und Zeiten übertragen lässt (Shadish u. a. 2002). Zwischen beiden besteht ein Zielkonflikt: Je strenger ein Labor alles konstant hält, desto künstlicher wird die Situation. Das Buch nennt eine besonders tückische Form dieses Problems: den *Hot-Cold-Empathy-Gap* (Loewenstein 1996). Wer im ruhigen Labor vorhersagen soll, wie er unter Stress, Zeitdruck oder Erregung entscheiden würde, beschreibt sein rationalisiertes Selbstbild. Umfragen zu zustandsabhängigem Verhalten sind deshalb strukturell unzuverlässig, solange dieser Abstand nicht methodisch adressiert wird (*WuZ-Buch*, Kap. 4, HCEG).

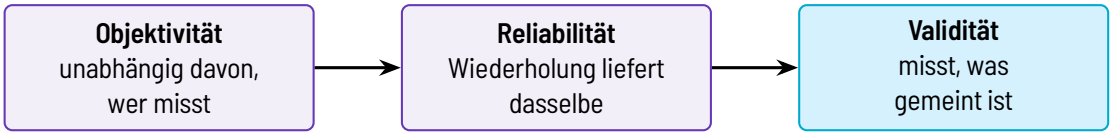
Externe Validität

- gilt das Ergebnis auch für andere Personen, Orte, Zeiten?
- Zielkonflikt: je kontrollierter das Labor, desto künstlicher die Situation
- Gelegenheitsstichproben (Freunde, Kommilitonen) sagen wenig über die Allgemeinbevölkerung
- **Hot-Cold-Empathy-Gap**: im ruhigen Labor sagt man falsch voraus, wie man unter Stress handelt

7.7 Gütekriterien der Messung

Auch das beste Design hilft nicht, wenn die AV schlecht gemessen wird. Die klassische Testtheorie nennt drei Hauptgütekriterien (Döring und Bortz 2016a). *Objektivität*: Das Ergebnis hängt nicht davon ab, wer die Messung durchführt, auswertet und interpretiert. *Reliabilität*: Die Messung ist zuverlässig, eine Wiederholung unter gleichen Bedingungen liefert dasselbe Ergebnis. *Validität*: Die Messung erfasst tatsächlich das gemeinte Konstrukt. Die Kriterien bauen aufeinander auf: Ohne Objektivität keine Reliabilität, ohne Reliabilität keine Validität. Das Buch ergänzt diese Begriffe in *WuZ-Buch*, Kap. 10b um ein praktisches Vokabular, das bei schwer messbaren Konstrukten wie Staunen oder Stress hilft: Ein *Blind-Design* schaltet Erwartungen der Messenden aus. Ein *Prozessindikator* ist ein Relativmaß für Veränderung innerhalb einer Person und einer Sitzung, kein Wahrheitsdetektor. Eine *Parallelmessung* erhebt dasselbe Konstrukt mit mehreren, unabhängigen Verfahren (etwa Selbstbericht und Herzratenvariabilität), damit ein Befund nicht an einem einzigen Instrument hängt. Auf der Ebene des ganzen Designs heißt dieselbe Idee *Triangulation*.

Drei Gütekriterien



- jedes Kriterium setzt das vorige voraus
- Seile: Maßband (objektiv, reliabel) gegen Augenmaß des Vorführenden

Messgüte-Vokabular aus dem Buch

- **Blind-Design:** wer misst, kennt die Bedingung nicht
- **Prozessindikator:** Relativmaß für Veränderung in einer Person und Sitzung – kein Wahrheitsdetektor
- **Parallelmessung:** dasselbe Konstrukt mit mehreren Verfahren (Selbstbericht, Verhalten, Physiologie)
- **Triangulation:** dieselbe Idee für das ganze Design – mehrere Methoden, Datenquellen, Perspektiven

7.8 Fallbeispiel: die Becher-Monty-Hall-Studie

Das Buch enthält ein vollständig ausgearbeitetes Forschungsdesign zu seiner eigenen Leitthese, dass Staunen das Lernen begünstigt (*WuZ-Buch*, Kap. 12d). Der Lerngegenstand ist das Monty-Hall-Problem, der Staunmoment ein Becher-Zauberkunststück. Die Studie ist als Zwischensubjekt-Design mit zufälliger Zuteilung angelegt. Beide Gruppen sehen dasselbe, rund 13-minütige Erklärvideo; die Treatment-Gruppe sieht zusätzlich, direkt nach dem Einstieg, einen rund zweiminütigen Becher-Zaubertrick. Bei der Kontrollgruppe ist genau dieser Block herausgeschnitten, alles Übrige ist identisch. Der Lehrteil nimmt mit keinem Satz Bezug auf den Trick, damit er in beiden Fassungen wortgleich und vollständig bleibt. Ein Manipulationscheck prüft, ob der Trick überhaupt Staunen ausgelöst hat; gemessen werden außerdem Verständnis, Transfer auf eine neu eingekleidete Aufgabe und Kalibrierung des eigenen Urteils.

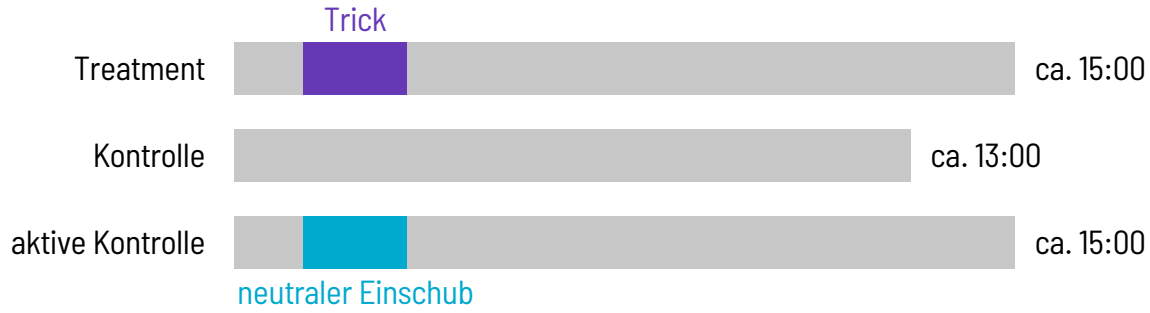
Der Entwurf benennt seinen Störfaktor selbst: Durch den reinen Herausschnitt ist die Kontrollfassung rund zwei Minuten kürzer (Treatment ca. 15:00, Kontrolle ca. 13:00). Länge und gemeinsame Aufmerksamkeitszeit sind damit konfundiert. Die Abhilfe ist eine längengleiche *aktive Kontrolle*: An die Stelle des Tricks tritt ein gleich langer, bewusst nicht staunenswerter Becher-Einschub, etwa ein nüchternes Umstapeln mit sachlichem Kommentar (*WuZ-Buch*, Abschnitt 12d, Studienlogik).

Der Idealentwurf (Kap. 12d)

- Zwischensubjekt-Design, zufällige Zuteilung
- UV: Staunmoment (Becher-Zaubertrick) ja / nein

- derselbe Film, ein Block herausgeschnitten – sonst alles identisch
- AV: Verständnis, Transfer, Kalibrierung
- Manipulationscheck: Hat der Trick überhaupt Staunen ausgelöst?

Der Störfaktor



- Herausschneiden macht die Kontrolle *kürzer*: Länge ist konfundiert
- Abhilfe: gleich langer, nicht staunenswerter Einschub

Umgesetzt wurde der Entwurf als Online-Feldstudie mit drei Armen (*WuZ-Buch*, Kap. 12f): U1 als Kontrolle ohne Zaubertrick, U2 mit dem Becher-Zaubertrick als Spiel auf der Landingpage vor dem Fragebogen und U3 mit dem in das Video integrierten, unaufgelösten Trick. Gegenüber dem Idealentwurf ersetzt U2 die empfohlene längengleiche aktive Kontrolle durch eine Platzierungsvariante. Die Zuteilung erfolgte zufällig über eine Landingpage, die Feldzeit lief vom 3. bis 31. Juli 2026. Am Ende lagen 32 auswertbare Fälle vor (13/9/10).

Die Befunde sind für eine Einheit über Forschungsdesign lehrreicher, als es ein Erfolg gewesen wäre. Erstens ist der Manipulationscheck gescheitert: Das Staunen liegt in den drei Armen bei 3,89 / 3,76 / 3,87, also praktisch gleichauf. Wenn die Intervention die vermutete Ursache nicht messbar bewegt, sind alle nachgelagerten Fragen nach ihrer Wirkung unbeantwortbar. Zweitens zeigte ein Zwischenstand am 16. Juli noch genau die erhoffte Abstufung (3,83 / 4,08 / 4,28), die sich danach einebnete; hätte die Erhebung früher geendet, stünde ein schöner, falscher Befund in der Welt. Drittens war der stärkste Zusammenhang einer, den die Studie gar nicht untersuchen wollte: Wer das Monty-Hall-Problem schon kannte, lag zu 92 Prozent richtig, wer es nicht kannte, zu rund der Hälfte. Bei $n = 32$ genügen wenige ungleich verteilte Vorwissensträger, um jeden Armunterschied zu erzeugen oder zu tilgen. Viertens war die Teststärke von Anfang an unzureichend: Für einen mittleren Effekt ($d = 0{,}5$) hätte es rund 64 Personen pro Arm gebraucht, erreicht wurden 9 bis 13. Das Buch zieht daraus selbst die Konsequenzen für eine Folgestudie: Fallzahl vorab planen, nach Vorwissen geschichtet randomisieren und den Manipulationscheck reparieren.

Die Feldstudie (Kap. 12f)

- drei Arme: U1 Kontrolle, U2 Trick vorab, U3 Trick im Video
- U2 statt der aktiven Kontrolle: eine Platzierungsvariante
- 32 auswertbare Fälle (13 / 9 / 10)
- Manipulationscheck gescheitert: Staunen 3,89 / 3,76 / 3,87
- Zwischenstand 16. Juli: 3,83 / 4,08 / 4,28 – danach eingeebnet

Was das Design daraus lernt

- **Vorwissen** überstrahlt alles: 92 % richtig mit, rund die Hälfte ohne Vorwissen
- **Teststärke**: für $d = 0{,}5$ rund 64 pro Arm nötig, erreicht 9 bis 13
- Folgestudie: Fallzahl vorab planen
- nach Vorwissen *geschichtet* randomisieren
- Manipulationscheck reparieren (z. B. Verweildauer, verhaltensnahe Maße)

Merke

Ohne Vergleich ist jede Beobachtung eine Vorführung. Ein Design ist so gut wie die Alternativerklärungen, die es ausschließt – und eine Intervention ist erst dann geprüft, wenn der Manipulationscheck zeigt, dass sie überhaupt gewirkt hat.

7.9 Design-Werkstatt

Teil 1: Ein Design analysieren (Zweiergruppen, 15 Min.)

- Übungsblatt Teil A, Aufgabe 1: die (fiktive) Lern-App-Studie
- Was sind UV und AV? Welcher Designtyp?
- Gibt es eine Kontrollgruppe – und taugt sie?
- Welche Konfounder sehen Sie? Welche Bedrohungen der internen Validität?
- Wie müsste das Design aussehen, damit die Schlussfolgerung trägt?

Teil 2: Ihr eigenes Design (Einzelarbeit, 15 Min.)

- Ausgangspunkt: Ihre H_1 aus LE 5
- Übungsblatt Teil A, Aufgabe 2: Design-Skizze ausfüllen
- Messgüte-Check: objektiv? reliabel? valide? blind? parallel gemessen?
- Welche Bedrohung der internen Validität bleibt – und warum nehmen Sie sie in Kauf?

Peer-Feedback (Zweiergruppen, 10 Min.)

- stellen Sie Ihr Design in drei Minuten vor
- die Partnerin sucht *eine* Alternativerklärung, die Ihr Design nicht ausschließt
- gemeinsam: Welche Änderung würde sie ausschließen?

Hinweis für Lehrende

Bei der Analyse der fiktiven Studie finden die meisten Gruppen die Selbstselektion schnell. Lohnend ist es, nach den weniger offensichtlichen Konfoundern zu fragen: das Tutorium, das nur die App-Gruppe besucht hat, und die nicht blinde Korrektur durch den App-Entwickler. Bei den eigenen Designs ist der häufigste Fehler eine Kontrollgruppe, die sich in mehr als einer Hinsicht von der Experimentalgruppe unterscheidet; hier hilft die Frage „Was genau ist bei der Kontrollgruppe anders, und ist das *nur* Ihre UV?". Wer ein nicht-experimentelles Design wählt, muss das nicht ändern, sollte aber in der Begründung zeigen, dass ihm die Grenzen der Kausalaussage klar sind. Statt der fiktiven Studie kann auch der Methodenteil eines echten Artikels analysiert werden; als realer Fall aus dem Buch eignet sich die Feldstudie aus *WuZ-Buch*, Kap. 12f, die ihre Abweichungen vom Idealentwurf selbst offenlegt.

7.10 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- UV, AV und Störvariablen in einem Design benennen
- experimentelle, quasi-experimentelle und nicht-experimentelle Designs unterscheiden
- Bedrohungen der internen Validität erkennen und Gegenmittel benennen

- Objektivität, Reliabilität und Validität einer Messung prüfen
- ein angemessenes Design für Ihre Fragestellung auswählen und begründen

Bis zur nächsten Woche

- **Fallstudie** (Aufgabe 1) fertigstellen
- **Design-Skizze** (Aufgabe 2): Design für Ihre eigene Hypothese, Begründung auf höchstens einer Seite – benotete Teilleistung
- Feedback Ihrer Partnerin einarbeiten
- **Tagebuch des Staunens:** eine Behauptung aus Werbung oder Nachrichten, der ein Vergleich fehlt

Handout: Forschungsdesign

Worum es heute ging. Drei Seile wurden gleich lang, zweimal. Beim ersten Mal gab es nur die Vorführung: Wer behauptete, zeigte auch, und niemand maß. Beim zweiten Mal legten Sie vorher fest, wie geprüft wird. Ohne Vergleich bleiben selbst grobe Täuschungen unentdeckt; eine verweigerte Kontrolle ist selbst ein Befund.

Kernbegriffe

Forschungsdesign Plan einer Untersuchung: welche Variablen an wem, wann und unter welchen Bedingungen erhoben oder verändert werden und womit verglichen wird.

UV / AV / Störvariable vermutete Ursache / gemessene Wirkung / weiterer Einfluss auf die AV.

Konfundierung eine Störvariable variiert systematisch mit der UV; ihre Wirkung ist nicht mehr abtrennbar.

Interne Validität die Veränderung der AV ist eindeutig auf die UV zurückzuführen (Shadish u. a. 2002).

Externe Validität das Ergebnis lässt sich auf andere Personen, Situationen und Zeiten übertragen.

Objektivität, Reliabilität, Validität unabhängig von der messenden Person; bei Wiederholung gleich; misst das Gemeinte.

Blind-Design, Parallelmessung Messende kennen die Bedingung nicht; dasselbe Konstrukt wird mit mehreren Verfahren erhoben.

Designtypen

	UV variiert	Zufall	Kurzschrift (R, X, O)
Experiment	ja	ja	R X O / R O
Quasi-Experiment	ja	nein	X O / O
nicht-experimentell	nein	–	nur O (Zusammenhänge)

Bedrohungen der internen Validität: Geschichte, Reifung, Testeffekt, Instrumentierung, Regression zur Mitte, Selektion, Ausfall – und die Erwartungen der Forschenden.

Fünf Werkzeuge der Kontrolle: Randomisierung, Konstanthalten, Schichten/Parallelisieren, (aktive) Kontrollgruppe, Blindbedingungen.

Merke

Ein Design ist so gut wie die Alternativerklärungen, die es ausschließt. Fragen Sie bei jeder Kontrollgruppe: Unterscheidet sie sich *nur* in der UV?

Zum Weiterlesen: Döring und Bortz (2016a), Kapitel zu Untersuchungsdesign und Gütekriterien; Shadish u. a. (2002), Kap. 1–2.

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 7**

Übungsblatt A: Forschungsdesign

Name: _____ Datum: _____

Aufgabe 1: Fallstudie: Ein Design analysieren

in der Stunde, Zweiergruppe, 15 Min.

Die folgende Studie ist fiktiv und für diese Übung konstruiert; alle Zahlen sind erfunden.

„Lern-App verbessert Mathematiknoten um 0,7“

Im Wintersemester bietet eine Hochschule zur Vorlesung Mathematik 1 eine neue Übungs-App an, die der Dozent der Vorlesung selbst entwickelt hat. Die Nutzung ist freiwillig; 64 von 212 Studierenden melden sich an. Zur Einführung der App bietet der Dozent für die Angemeldeten ein wöchentliches Tutorium an, in dem mit der App geübt wird. Am Semesterende schreiben alle 212 Studierenden dieselbe Klausur, die der Dozent selbst korrigiert; auf den Bögen stehen Name und Matrikelnummer. Die App-Gruppe erreicht im Mittel die Note 2,3, die übrigen 148 Studierenden die Note 3,0. Im Pressetext der Hochschule heißt es: „Die App verbessert die Note um 0,7. Sie wird ab dem nächsten Semester für alle Erstsemester verpflichtend.“

1. Benennen Sie UV und AV (unabhängige und abhängige Variable). Wie ist die AV gemessen worden?
2. Welcher Designtyp liegt vor? Schreiben Sie das Design in der Kurzschrift R/X/O (eine Zeile je Gruppe; R = zufällige Zuteilung, X = Behandlung, O = Messung).
3. Gibt es eine Kontrollgruppe? In welchen Merkmalen unterscheidet sie sich von der App-Gruppe außer in der App-Nutzung?
4. Nennen Sie mindestens drei Konfounder bzw. Bedrohungen der internen Validität und ordnen Sie sie Fachbegriffen zu (etwa Selektion, Geschichte, Reifung, Testeffekt, Instrumentierung, Ausfall, Erwartungen der Forschenden).
5. Ist die Messung objektiv? Was wäre ein Blind-Design?
6. Skizzieren Sie ein verbessertes Design, das die Aussage des Pressetexts prüfen könnte.

Aufgabe 2: Design-Skizze zu Ihrer Hypothese

Beginn in der Stunde, Abgabe bis LE 8, benotet

Füllen Sie die Vorlage aus und begründen Sie Ihre Wahl auf höchstens einer weiteren Seite.

H_1 (aus LE 5)	
UV und ihre Stufen	
AV und Messinstrument	
Designtyp (experimentell / quasi / nicht-experimentell; Quer- oder Längsschnitt)	
Design in Kurzschrift (R / X / O)	
Stichprobe: wer, wie viele, wie rekrutiert?	
Auswertungsplan (aus LE 6): Test oder Bayes-Faktor, kleinster interessanter Effekt, n aus der Power-Tabelle	
Zuteilung zu den Bedingungen	
Kontrollbedingung (aktiv?)	
Wichtigste Störvariablen (Drachen auf Ihrer Landkarte aus LE 6) und wie ich sie kontrolliere	
Messgüte: objektiv? reliabel? valide? blind? Parallelmessung?	
Verbleibende Bedrohung, die ich in Kauf nehme	

Übungsblatt B: Feedback und Transfer

Name: _____ Datum: _____

Aufgabe 3: Peer-Feedback

in der Stunde, Zweiergruppe, 10 Min.

Notieren Sie für die Skizze Ihrer Partnerin bzw. Ihres Partners:

Eine Alternativerklärung, die das Design nicht ausschließt	
Eine Änderung, die sie ausschließen würde	
Was an dem Design überzeugt	

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Finden Sie in Werbung, Nachrichten oder sozialen Medien eine Wirkungsbehauptung, der ein Vergleich fehlt. Welche Kontrollbedingung bräuchte man, um sie zu prüfen?

Erwartungshorizont

Aufgabe 1. UV: App-Nutzung (ja/nein, selbst gewählt); AV: Klausurnote, korrigiert vom Entwickler der App, nicht anonymisiert. Design: quasi-experimentell bzw. nicht-experimenteller Gruppenvergleich ohne Vortest (X O / O), keine Randomisierung. Die „Kontrollgruppe" unterscheidet sich in Motivation und vermutlich Vorkenntnissen (Selbstselektion), im zusätzlichen Tutorium (Konfundierung der UV mit Übungszeit und Betreuung) und darin, wie der Korrektor sie wahrnimmt (Versuchsleitereffekt, fehlende Objektivität). Weitere Punkte: kein Vortest, also keine Aussage über Veränderung; mögliche Neuheitseffekte; Übertragung von Freiwilligen auf eine Pflichtnutzung ist fraglich (externe Validität). Verbessertes Design: zufällige Zuteilung (ggf. geschichtet nach Vorkenntnissen aus einem Eingangstest), Tutorium für beide Gruppen gleich lang mit herkömmlichen Übungen (aktive Kontrolle), anonymisierte Klausur, Korrektur durch eine Person, die die Gruppenzugehörigkeit nicht kennt (Blind-Design).
Aufgabe 2. Bewertet werden: Passung von Design und Hypothese (Kausalbehauptung erfordert experimentelles oder gut begründetes quasi-experimentelles Design), eine Kontrollbedingung, die sich nur in der UV unterscheidet, ein konkretes Messinstrument, mindestens zwei benannte und kontrollierte Störvariablen, eine ehrlich benannte Restbedrohung.

8 Kognitive Verzerrungen

LE 5 hat gezeigt, dass wir lieber bestätigen als prüfen, LE 7, dass ohne Vergleich selbst grobe Täuschungen unentdeckt bleiben. Diese Einheit fragt, woher die Neigung zur Täuschung kommt und wie sie in die Forschung gelangt. Sie beginnt mit drei Streichholzschachteln, die jede Person selbst in die Hand nimmt. Die Täuschung, die dabei entsteht, verschwindet auch dann nicht, wenn man ihre Ursache kennt. Daraus entwickelt die Einheit ihre Leitthese: Verzerrung ist der Normalbetrieb eines vorhersagenden Gehirns, kein Zeichen von Dummheit. Bändigen lässt sie sich deshalb nur durch Methode, nicht durch guten Willen. Die Einheit ordnet die wichtigsten Verzerrungen den Phasen eines Forschungsprozesses zu, behandelt Bestätigungsfehler, Hot-Cold-Empathy-Gap und Misdirection, unterscheidet Bias von Noise und stellt die methodischen Gegenmittel vor. Die Replikationskrise zeigt, was geschieht, wenn eine ganze Disziplin diese Gegenmittel zu wenig nutzt.

Vorbereitung vor der Stunde: Charpentier-Illusion

Eine Woche vorher

- ☐ Sets bauen: je Set drei gleiche Streichholzschachteln derselben Marke, Hölzer entfernen. In die *oberste* Schachtel zwei AA-Batterien legen und mit etwas Papier oder Watte gegen Klappern sichern, sodass sie zusammen ca. 50 g wiegt. Die beiden anderen bleiben leer (je ca. 3 g). Die Schachteln mit einem Gummiband zum Stapel binden. Die beschwerte Schachtel unauffällig markieren (Punkt innen an der Lade), damit beim Zusammenbauen nichts vertauscht wird (*WuZ-Buch*, Kap. 10, Charpentier-Gewichtsillusion).
- ☐ Ein Set pro vier bis fünf Personen, plus zwei Ersatzsets; bei 30 Teilnehmenden also acht bis neun Sets.
- ☐ Eine Küchenwaage (1-g-Auflösung) für die Auflösung einpacken.
- ☐ Den Ablauf an einer Testperson ausprobieren: Erst den Stapel heben, dann das Gewicht in Gramm schätzen und notieren, dann Gummiband lösen und nur die oberste Schachtel heben.
- ☐ **Artikel für die Bias-Jagd auswählen** (siehe unten) und eine Woche vorher als PDF verschicken mit der Bitte, ihn einmal zu lesen.

Auswahlkriterien für den Artikel der Bias-Jagd

- ☐ empirische Originalarbeit (kein Review, keine Meta-Analyse), im Umfang von höchstens etwa zwölf Seiten;
- ☐ ohne Spezialwissen verständlich, möglichst aus dem Fach oder Interessengebiet der Gruppe; Englisch ist zumutbar;
- ☐ vollständiger Methodenteil mit Stichprobe, Zuteilung, Messinstrumenten und Auswertung, damit Bias-anfällige Stellen überhaupt erkennbar sind;
- ☐ mindestens zwei echte Angriffspunkte, z. B. kleine Stichprobe ohne Fallzahlplanung, viele abhängige Variablen, nicht blinde Beurteilung, fehlende Präregistrierung, Interpretation, die über die Daten hinausgeht;
- ☐ kein Artikel, der wegen Fälschung zurückgezogen wurde: Gesucht sind gewöhnliche Schwächen, keine Skandale;
- ☐ optional als Kontrast: ein präregistrierter Artikel oder ein *Registered Report* zur selben Frage.

Handout und Übungsblatt

- ☐ Handout „Kognitive Verzerrungen" sowie Übungsblatt LE 8 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 8). Teil A liegt zu Beginn aus und enthält einen fiktiven Kurztext zum Aufwärmen und das Raster für die Bias-Jagd. Teil B (Selbstbezug, Tagebuch) wird erst zum Selbstbezug ausgeteilt, weil die Tagebuchfrage auf den Staunmoment anspielt.
- ☐ Den gewählten Artikel einmal pro Zweiergruppe ausdrucken, falls nicht alle ein Gerät dabeihaben.
- ☐ Für jede Person einen Zettel für die Gewichtsschätzung.

Am Tag selbst

- ☐ Sets vor der Stunde auf die Tische verteilen, Stapel gebunden, beschwerte Schachtel oben.
- ☐ Tafel vorbereiten: links eine Strichliste „oberste Schachtel allein fühlt sich schwerer an: ja / nein", rechts Platz für die notierten Schätzungen des Stapelgewichts.

Risiken und Plan B. Wer die Illusion kennt, erlebt sie trotzdem. Auch das gehört zur Lektion. Wer nach dem Lösen des Gummibands versehentlich eine untere Schachtel hebt, erlebt nichts Besonderes; deshalb den Ablauf vorher einmal ansagen. Fehlt der Artikel oder hat die Gruppe ihn nicht gelesen, trägt der fiktive Kurztext auf dem Übungsblatt (Teil A) die Bias-Jagd in der Stunde, und der Artikel wird zur Hausaufgabe.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Tagebuch-Rückblick: „Wo haben Sie sich diese Woche selbst ertappt?"

5–15 · Staunmoment. Charpentier-Illusion durch Herumreichen; stille Gewichtsschätzung; Strichliste; Auflösung mit der Waage; zweiter Versuch mit Wissen. Staunen darüber, dass Wissen die Täuschung nicht auflöst (Alief, LE 1).

15–50 · Theorie-Input. Bias-Systematik; Confirmation Bias; HCEG; Misdirection; Noise und Entscheidungshygie-

ne; Gegenmittel (Blind-Design, Präregistrierung); Replikationskrise.

50–80 · Bias-Jagd. Aufwärmen am fiktiven Kurztext (5 Min.), dann identifizieren Zweiergruppen im ausgewählten Artikel mindestens zwei Bias-anfällige Stellen und begründen sie (Raster auf dem Übungsblatt Teil A, Aufgaben 1 und 2).

80–90 · Selbstbezug. Übungsblatt Teil B austeilen. Welcher Bias droht im *eigenen* geplanten Forschungsprozess, und wie begrenze ich ihn? (Aufgabe 3)

8.1 Staunmoment: Drei Schachteln

★ Staunmoment: Charpentier-Illusion

Heben Sie den Stapel aus drei Schachteln an. *Wie schwer ist er? Schreiben Sie eine Zahl in Gramm auf.*

Lösen Sie das Gummiband. Heben Sie *nur die oberste* Schachtel.

Was ist schwerer: die eine Schachtel oder alle drei?

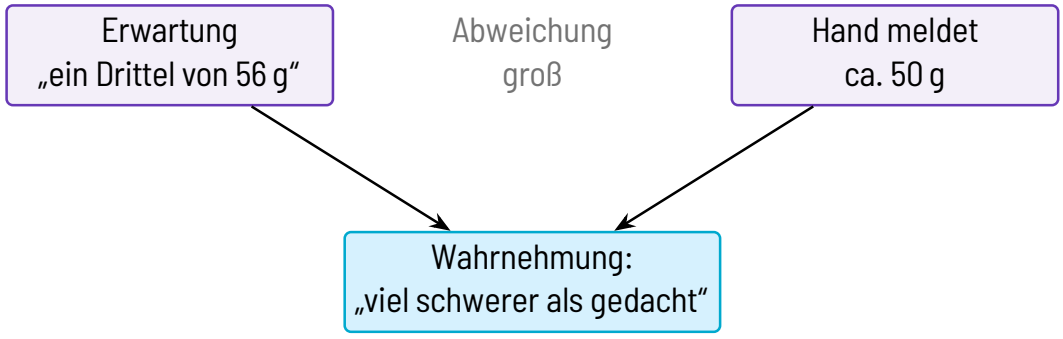
Was ist passiert?

- Strichliste: Bei wem fühlte sich die einzelne Schachtel schwerer an als der Stapel?
- Ihre Schätzungen des Stapelgewichts: Wie weit liegen sie auseinander?
- Die Waage: Stapel ca. 56 g, oberste Schachtel ca. 50 g
- Und jetzt, wo Sie es wissen: noch einmal heben

Die oberste Schachtel enthält zwei Batterien und wiegt etwa 50 g, die beiden anderen je etwa 3 g. Der Stapel ist also größer *und* schwerer als die einzelne Schachtel, und trotzdem fühlt sich die einzelne Schachtel schwerer an. Die Erklärung des Buchs (*WuZ-Buch*, Kap. 10, Charpentier-Gewichtsillusion): Beim Heben einer einzelnen von drei gleich aussehenden Schachteln erwartet das Gehirn etwa ein Drittel des Gesamtgewichts, bekommt aber fast das ganze. Die enttäuschte Erwartung erzeugt die Illusion. Augustin Charpentier hat diese Größe-Gewicht-Illusion 1891 beschrieben (Charpentier 1891); sie gehört zu den stabilsten Täuschungen der Wahrnehmungspsychologie. Eine einzige akzeptierte Erklärung gibt es bis heute nicht, die meisten Ansätze teilen aber den Kern, dass Erwartungen über das Gewicht die Wahrnehmung formen (Buckingham 2014).

Für diese Einheit ist ein zweiter Befund wichtiger. Flanagan und Beltzner ließen Versuchspersonen gleich schwere Würfel unterschiedlicher Größe immer wieder heben. Die Griffkräfte passten sich nach wenigen Versuchen dem tatsächlichen Gewicht an, die Illusion blieb in voller Stärke bestehen (Flanagan und Beltzner 2000). Die Hand lernt, die Wahrnehmung nicht. Das ist die Unterscheidung von Belief und Alief aus LE 1 (Gendler 2008): Sie *wissen* jetzt, dass die Schachtel leichter ist als der Stapel, und Sie *spüren* trotzdem das Gegenteil.

Erwartung formt Wahrnehmung



- die Hand passt sich an, die Wahrnehmung nicht (Flanagan & Beltzner 2000)
- Wissen löst die Täuschung nicht auf: Belief gegen Alief

8.2 Verzerrung als Normalbetrieb

Die Schachteln zeigen im Kleinen, was für das Urteilen allgemein gilt. Das Gehirn arbeitet mit Vorhersagen und Faustregeln, weil es sonst nie zu einem Urteil käme. Tversky und Kahneman haben 1974 gezeigt, dass diese Heuristiken meist gut funktionieren, aber zu systematischen, vorhersagbaren Fehlern führen, und zwar auch bei Fachleuten (Tversky und Kahneman 1974). Kahneman fasst das später in das Bild zweier Denkweisen: ein schnelles, automatisches System 1 und ein langsames, anstrengendes System 2 (Kahneman 2011). Verzerrungen entstehen vor allem dort, wo System 1 antwortet und System 2 nicht nachprüft. Eine Verzerrung ist damit kein Charakterfehler. Sie ist die Rückseite einer Arbeitsweise, die im Alltag meistens trägt. Daraus folgt die Leitthese der Einheit: Gegen Verzerrungen hilft ein Verfahren, das auch dann funktioniert, wenn man voreingenommen ist; der Vorsatz, unvoreingenommen zu sein, reicht nicht.

Bias

Definition 8.1 Eine **kognitive Verzerrung** (Bias) ist eine systematische, vorhersagbare Abweichung eines Urteils von einem angemessenen Maßstab. Sie zeigt sich bei vielen Personen in dieselbe Richtung.

- Heuristiken sparen Zeit und liegen meist richtig – aber systematisch daneben, wo ihre Voraussetzung nicht stimmt
- System 1 antwortet schnell, System 2 prüft (oder eben nicht)
- auch Fachleute sind nicht ausgenommen

Merke

Verzerrung ist kein Zeichen von Dummheit, sondern der Normalbetrieb eines vorhersagenden Gehirns. Bändigen lässt sie sich nur durch Methode, nicht durch guten Willen.

8.3 Verzerrungen im Forschungsprozess

Für das wissenschaftliche Arbeiten ist eine Ordnung nach den Phasen des Forschungsprozesses nützlicher als eine alphabetische Liste. In der *Planung* wirkt vor allem der Bestätigungsfehler: Man wählt Fragen, Methoden und Literatur so, dass die eigene Vermutung gute Chancen hat (LE 3 und 5). In der *Erhebung* verschieben Erwartungen der Forschenden die Daten: Studierende, denen man sagte, ihre Ratten seien besonders labyrinthklug, maßen bei zufällig zugeteilten Tieren bessere Leistungen (Rosenthal und Fode 1963). Auch die erste Zahl in einem Fragebogen kann als Anker alle weiteren Antworten prägen (Tversky und Kahneman 1974). In der *Auswertung* erlauben die vielen kleinen Entscheidungen (welche Fälle ausschließen, welche Variable kontrollieren, wann aufhören zu erheben) fast jedes gewünschte Ergebnis (Simmons u. a. 2011; Gelman und Loken 2014). In der *Interpretation* wirkt der Rückschaufehler: Wer das Ergebnis kennt, hält es für vorhersehbar und glaubt, es schon immer erwartet zu haben (Fischhoff 1975); nachträglich formulierte Hypothesen werden dann als vorab geplant ausgegeben (Kerr 1998). In der *Publikation* schließlich verschwinden Nullbefunde in der Schublade, und die veröffentlichte Literatur überschätzt Effekte (Rosenthal 1979). Die statistische Seite hat LE 6 vorbereitet; LE 10 vertieft sie.

Bias entlang des Forschungsprozesses

Phase	Verzerrung	so sieht es aus
Planung	Bestätigungsfehler	nur Literatur und Tests, die passen
Erhebung	Versuchsleitereffekt, Anker	Erwartung färbt Messung; erste Zahl prägt
Auswertung	p-Hacking, Forking Paths	so lange analysieren, bis es passt
Interpretation	Rückschaufehler, HARKing	„Das war doch klar."
Publikation	Publication Bias	Nullbefunde bleiben in der Schublade

8.4 Der Bestätigungsfehler

Der Bestätigungsfehler ist die am besten untersuchte und vermutlich folgenreichste Verzerrung (Nickerson 1998). Das Buch beschreibt ihn als Filter: Informationen werden so ausgewählt, gewichtet und erinnert, dass sie die bestehende Meinung bestätigen (*WuZ-Buch*, Kap. 4, Bestätigungsfehler). Er wirkt nicht nur beim Suchen (der Congruence Bias aus LE 5), sondern auch beim Bewerten: Ein unerwünschter Befund wird strenger geprüft als ein erwünschter. Das historische Lehrstück ist Ignaz Semmelweis. Er senkte 1847 die Müttersterblichkeit an der Ersten Geburtshilflichen Klinik in Wien durch Händewaschen mit Chlorkalklösung von zeitweise über 15 Prozent auf rund ein bis zwei Prozent (Semmelweis 1861). Sein Befund widersprach dem herrschenden Krankheitsverständnis und kränkte die Standesehre der Ärzte; statt die Evidenz anzuerkennen, suchte man Gründe, sie abzulehnen. Nicht das Fehlen von Daten war das Hindernis, sondern die Abwehr unbequemer Daten.

Bestätigungsfehler

- **Suchen:** nur Belege, die passen (2-4-6-Test, LE 5)
- **Bewerten:** unerwünschte Befunde werden strenger geprüft
- **Erinnern:** Treffer bleiben, Fehlschläge verblassen
- Semmelweis 1847: Händewaschen senkt die Müttersterblichkeit von zeitweise über 15 % auf rund 1–2 % – und wird abgelehnt

8.5 Der Hot-Cold-Empathy-Gap

Eine zweite Quelle von Verzerrung ist der eigene Zustand. George Loewenstein hat gezeigt, dass Menschen den Einfluss von Hunger, Schmerz, Wut, Erschöpfung oder Erregung auf ihr eigenes Urteilen systematisch unterschätzen (Loewenstein 1996). Wer ruhig ist (kalter Zustand), kann nicht verlässlich simulieren, wie er im erregten (heißen) Zustand entscheiden würde, und umgekehrt. Das Buch unterscheidet drei Richtungen dieser Lücke und leitet daraus zwei Folgen für die Forschung ab (*WuZ-Buch*, Kap. 4, HCEG): Erstens beschreiben Probanden, die im ruhigen Labor ihr Verhalten in emotionalen Situationen vorhersagen, eher ihr rationalisiertes Selbstbild als ihr tatsächliches Verhalten (*hypothetischer Bias*). Zweitens sind Forschende selbst nicht immer im kalten Zustand; Publikationsdruck ist ein institutioneller heißer Zustand, in dem Bestätigungsfehler und motiviertes Denken besonders leicht greifen.

Hot-Cold-Empathy-Gap

- **kalt → heiß:** im ruhigen Zustand unterschätzt man künftige Impulse
- **heiß → kalt:** im erregten Zustand hält man das Augenblicksziel für die stabile Präferenz
- **zwischenmenschlich:** wer ruhig ist, unterschätzt den Zustand anderer
- Forschung: hypothetischer Bias in Umfragen; Publikationsdruck als heißer Zustand der Forschenden

8.6 Misdirection

Die Zauberkunst nutzt dieselben Mechanismen gezielt. Taylor Hughes beschreibt drei Werkzeuge der Misdirection, die auf der Bühne ebenso wirken wie in Werbung und Politik (Hughes 2023): die Kontrolle des Gesprächs (wer die Fragen stellt, steuert das Denken), die Verdichtung der Zeit (wer keine Zeit zum Nachdenken hat, findet keine Alternativerklärung) und die Bestätigungsverstärkung (ein Publikum, das eine Deutung angenommen hat, verteidigt sie und vollendet die Illusion selbst). Das Buch liest Misdirection als gezielt falsch gefüttertes Vorhersagesystem: Der Zauberkünstler setzt einen falschen Prior und sorgt dafür, dass die Sinnesdaten ihn scheinbar bestätigen (*WuZ-Buch*, Kap. 4, Misdirection). Für die Forschung ist das unbequem, denn die Rolle des Zauberkünstlers übernimmt oft die eigene Fragestellung: Wie eine Frage gerahmt ist, bestimmt, welche Antworten überhaupt in den Blick kommen. Hughes' Gegenmittel ist schlicht: mehr Fragen stellen, und zwar vor allem die, die gerade nicht gestellt werden.

Misdirection – im Theater und in der Forschung

- **Gesprächskontrolle:** die erste Frage bestimmt den Denkraum – auch die eigene Forschungsfrage
- **Zeitdruck:** keine Zeit für Alternativerklärungen
- **Bestätigungsverstärkung:** wer eine Deutung hat, vollendet die Illusion selbst
- Gegenmittel: *Welche Frage wird hier nicht gestellt? Welche Optionen sehe ich nicht?*

8.7 Bias und Noise

Nicht jeder Urteilsfehler ist eine Verzerrung. Kahneman, Sibony und Sunstein unterscheiden *Bias*, die systematische Abweichung in eine Richtung, von *Noise*, der unsystematischen Streuung von Urteilen, die eigentlich gleich ausfallen sollten (Kahneman u. a. 2021). Zwei Gutachter bewerten dieselbe Arbeit unterschiedlich, dieselbe Person bewertet sie an zwei Tagen unterschiedlich. Die Schachteln haben beides gezeigt: Dass sich die einzelne Schachtel bei fast allen schwerer anfühlte, ist Bias; dass die notierten Schätzungen des Stapelgewichts weit auseinanderlagen, ist Noise. Gegen Noise empfehlen die Autoren *Entscheidungshygiene*: unabhängige Einschätzungen vor jeder Diskussion einholen, strukturierte Bewertungsraster verwenden, mehrere Urteile zusammenfassen, Informationssammlung und Bewertung trennen und die Rolle des Advocatus Diaboli fest zuweisen, statt sie dem Zufall zu überlassen (Schulz-Hardt u. a. 2002). Für das wissenschaftliche Arbeiten heißt das unter anderem: Kodierungen und Bewertungen von mindestens zwei Personen unabhängig vornehmen lassen und ihre Übereinstimmung prüfen.

Bias und Noise



Bias
systematisch daneben

Noise
unsystematisch gestreut

- Schachteln: „einzelne schwerer" bei fast allen = Bias; weit gestreute Schätzungen = Noise

Entscheidungshygiene

- unabhängige Einschätzungen *vor* der Diskussion einsammeln
- strukturierte Bewertungsraster statt Gesamteindruck
- mehrere Urteile zusammenfassen
- Informationssammlung und Bewertung trennen
- Advocatus Diaboli als zugewiesene Rolle
- in der Forschung: zwei unabhängige Kodierende, Übereinstimmung prüfen

8.8 Gegenmittel: Methode statt guter Wille

Weil Verzerrungen auch dann wirken, wenn man von ihnen weiß, setzen die wirksamen Gegenmittel beim Verfahren an. *Blind- und Doppelblind-Designs* nehmen Teilnehmenden und Messenden das Wissen, das ihre Erwartungen in die Daten tragen würde; so wurde etwa die Behauptung geprüft, Astrologen könnten Horoskope den passenden Persönlichkeitsprofilen zuordnen (Carlson 1985). Die *Präregistrierung* legt Hypothesen, Messgrößen und Auswertung fest, bevor die Daten erhoben sind, und trennt damit sichtbar zwischen geprüften und nachträglich gefundenen Ergebnissen (Nosek u. a. 2018). In der *adversariellen Kollaboration* planen Forschende mit gegensätzlichen Erwartungen eine Studie gemeinsam und einigen sich vorab, welches Ergebnis welche Position stützen würde. *Replikation* und offen geteilte Daten machen die Prüfung unabhängig von denen, die das Ergebnis erhofft haben. Die Feldstudie aus LE 7 ist ein kleines Beispiel für den Wert dieser Disziplin: Ihr Zwischenstand zeigte die erhoffte Abstufung, die mit wachsender Stichprobe verschwand, und das Buch hat den eigenen frühen Trend ausdrücklich widerrufen (*WuZ-Buch*, Kap. 12f).

Welches Mittel gegen welchen Bias?

Verzerrung	Gegenmittel
Versuchsleitereffekt	Blind- und Doppelblind-Design
p-Hacking, HARKing	Präregistrierung
Bestätigungsfehler	Alternativhypothese, adversarielle Kollaboration
Noise in Bewertungen	unabhängige Mehrfachbeurteilung, Raster
Publication Bias	Registered Reports, Nullbefunde veröffentlichen
Zufallsbefund	Replikation, Daten teilen

8.9 Die Replikationskrise

Was geschieht, wenn eine Disziplin diese Gegenmittel zu wenig nutzt, hat die Psychologie in den 2010er Jahren an sich selbst untersucht. Die *Open Science Collaboration* versuchte, 100 publizierte Studien aus führenden psychologischen Zeitschriften zu replizieren (Open Science Collaboration 2015). Während 97 Prozent der Originalstudien signifikante Effekte berichtet hatten, erreichten nur etwa 36 Prozent der Replikationen ebenfalls Signifikanz, und die Effektstärken halbierten sich im Mittel. Schon zehn Jahre vorher hatte John Ioannidis argumentiert, dass bei kleinen Studien, kleinen Effekten, flexiblen Designs und starkem Interesse an einem bestimmten Ergebnis die Mehrzahl publizierter Befunde falsch sein kann (Ioannidis 2005). Die Replikationskrise ist deshalb weniger eine Krise einzelner Forscher als ein institutionelles Bias-Problem: Wenn Zeitschriften vor allem positive, überraschende Ergebnisse drucken und Karrieren an Publikationen hängen, belohnt das System genau die Verzerrungen, die die Methode eigentlich ausschalten soll. Die Antwort der Open-Science-Bewegung sind die Gegenmittel aus dem vorigen Abschnitt, institutionell verankert.

Die Replikationskrise

- Open Science Collaboration 2015: 100 psychologische Studien repliziert
- Originale: 97 % signifikant – Replikationen: etwa 36 %

- Effektstärken im Mittel halbiert
- Ursache: kleine Stichproben, flexible Auswertung, Publikationsdruck
- ein *institutionelles* Bias-Problem – Antwort: Open Science

8.10 Bias-Jagd

Aufwärmen (Einzelarbeit, 5 Min.)

- Übungsblatt Teil A, Aufgabe 1: ein fiktiver Kurzbericht
- Markieren Sie jede Stelle, an der ein Bias das Ergebnis beeinflusst haben könnte
- Ordnen Sie sie einer Phase zu: Planung, Erhebung, Auswertung, Interpretation, Publikation

Bias-Jagd im Artikel (Zweiergruppen, 25 Min.)

- Übungsblatt Teil A, Aufgabe 2: Raster
- mindestens **zwei** Bias-anfällige Stellen finden
- Seite und Zitat angeben, Bias benennen, begründen
- Welches Gegenmittel hätte geholfen? Wurde es verwendet?
- fair bleiben: Was haben die Autorinnen *gut* gemacht?

Selbstbezug (Einzelarbeit, 10 Min.)

- Übungsblatt Teil B, Aufgabe 3; Ihre Design-Skizze aus LE 7 vor sich legen
- Welcher Bias droht in Ihrem eigenen Forschungsprozess am stärksten?
- In welcher Phase?
- Mit welchem *Verfahren* begrenzen Sie ihn?

Hinweis für Lehrende

Bei der Bias-Jagd neigen Gruppen dazu, jede Schwäche eines Artikels „Bias" zu nennen. Hilfreich ist die Rückfrage, in welche Richtung die Schwäche das Ergebnis verschieben würde: Eine kleine Stichprobe allein ist kein Bias, sondern eine Quelle von Unsicherheit; zum Bias wird sie erst zusammen mit flexibler Auswertung oder selektivem Berichten. Gute Antworten zitieren die Stelle im Artikel, benennen die Verzerrung, begründen die Richtung und schlagen ein konkretes Gegenmittel vor. Darauf achten, dass die Kritik fair bleibt: Ziel ist die Lesekompetenz, nicht das Vorführen der Autorinnen und Autoren. Beim Selbstbezug ist die häufigste schwache Antwort „Ich werde darauf achten, unvoreingenommen zu sein"; sie wird mit der Leitthese der Einheit zurückgegeben: Welches *Verfahren*?

8.11 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- erklären, warum Verzerrungen auch bei Wissen um sie bestehen bleiben
- die häufigsten Verzerrungen den Phasen des Forschungsprozesses zuordnen
- Bias und Noise unterscheiden
- Bias-anfällige Stellen in einem empirischen Artikel erkennen und begründen
- konkrete Gegenmittel für Ihren eigenen Forschungsprozess benennen

Bis zur nächsten Woche

- **Bias-Jagd** (Aufgabe 2) fertigstellen: mindestens zwei Stellen, begründet
- **Reflexion** (Aufgabe 3): Welcher Bias droht in Ihrem eigenen Forschungsprozess, und wie begrenzen Sie ihn?
- **Tagebuch des Staunens:** eine Situation, in der Sie etwas wussten und trotzdem anders wahrgenommen haben

Handout: Kognitive Verzerrungen

Worum es heute ging. Drei gleich aussehende Schachteln, die oberste mit ca. 50 g, die anderen mit je ca. 3 g. Allein gehoben fühlt sich die oberste schwerer an als der ganze Stapel. Das Gehirn erwartet ein Drittel des Gesamtgewichts und bekommt fast alles; die enttäuschte Erwartung erzeugt die Illusion (Charpentier 1891). Sie bleibt, auch wenn Sie es wissen (Flanagan und Beltzner 2000).

Kernbegriffe

Bias systematische, vorhersagbare Abweichung eines Urteils in eine Richtung (Tversky und Kahneman 1974).

Noise unsystematische Streuung von Urteilen, die gleich ausfallen sollten (Kahneman u. a. 2021).

Bestätigungsfehler Belege so suchen, bewerten und erinnern, dass sie die eigene Meinung stützen.

Versuchsleitereffekt Erwartungen der Forschenden verschieben die Daten (Rosenthal und Fode 1963).

Hot-Cold-Empathy-Gap im ruhigen Zustand unterschätzt man den Einfluss von Stress, Hunger, Erregung auf das eigene Urteil (Loewenstein 1996).

Rückschaufehler wer das Ergebnis kennt, hält es für vorhersehbar (Fischhoff 1975).

Publication Bias Nullbefunde werden seltener veröffentlicht; die Literatur überschätzt Effekte (Rosenthal 1979).

Verzerrung und Gegenmittel im Forschungsprozess

Phase	typische Verzerrung	Gegenmittel
Planung	Bestätigungsfehler	Alternativhypothese, adversarielle Kollaboration
Erhebung	Versuchsleitereffekt, Anker	Blind- und Doppelblind-Design
Auswertung	p-Hacking, Forking Paths	Präregistrierung
Interpretation	Rückschaufehler, HARKing	Präregistrierung, Trennung geplant/explorativ
Publikation	Publication Bias	Registered Reports, Replikation

Replikationskrise: Von 100 psychologischen Studien hatten 97 % signifikante Effekte berichtet, in der Replikation erreichten etwa 36 % Signifikanz (Open Science Collaboration 2015).

Merke

Verzerrung ist der Normalbetrieb eines vorhersagenden Gehirns. Sie verschwindet nicht, wenn man von ihr weiß. Bändigen lässt sie sich nur durch Verfahren: blind messen, vorab festlegen, unabhängig urteilen.

Zum Weiterlesen: Kahneman (2011); Nickerson (1998).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 8**

Übungsblatt A: Kognitive Verzerrungen

Name: _____ Datum: _____

Aufgabe 1: Aufwärmen: ein fiktiver Kurzbericht

in der Stunde, Einzelarbeit, 5 Min.

Der folgende Bericht ist fiktiv und für diese Übung konstruiert.

„Barockmusik steigert die Konzentration"

(1) Eine Dozentin, die seit Jahren Konzentrationstrainings mit Musik anbietet, will zeigen, dass Barockmusik die Konzentration verbessert. (2) Sie gewinnt 24 Studierende aus ihrem eigenen Seminar. (3) Alle lösen zuerst am Vormittag Aufgaben ohne Musik und am Nachmittag desselben Tages Aufgaben mit Musik. (4) Die Dozentin bewertet die Lösungen selbst; auf jedem Bogen ist vermerkt, ob er mit oder ohne Musik entstand. (5) Erhoben werden zwölf Konzentrationsmaße. Bei einem davon zeigt sich ein signifikanter Vorteil der Musikbedingung; über die übrigen elf wird nicht berichtet. (6) Weil das Ergebnis nach 24 Personen „knapp nicht signifikant" war, wurden zehn weitere Personen erhoben. (7) In der Diskussion heißt es, die Hypothese sei von Anfang an klar gewesen und bestätige die langjährige Praxiserfahrung der Autorin. (8) Eine frühere Studie der Autorin ohne Effekt wurde nicht eingereicht.

Notieren Sie zu jeder Nummer, ob dort ein Bias (eine systematische Verzerrung in eine bestimmte Richtung) wirken könnte, welcher und in welcher Phase des Forschungsprozesses: Planung, Erhebung, Auswertung, Interpretation oder Publikation.

Aufgabe 2: Bias-Jagd im Artikel

in der Stunde, Zweiergruppe, 25 Min.; Abschluss als Hausaufgabe

Artikel (von der Lehrperson ausgewählt): _____

Finden Sie mindestens zwei Stellen, an denen ein Bias das Ergebnis beeinflusst haben könnte. Prüfen Sie dafür nacheinander: Wer hat die Studie durchgeführt und mit welchem Interesse? Wie wurden die Teilnehmenden gewonnen und zugeteilt? Wer hat gemessen, und wusste diese Person die Bedingung? Wie viele Messgrößen und Auswertungsvarianten gab es, und wird über alle berichtet? Gab es eine Präregistrierung? Geht die Interpretation über die Daten hinaus?

Seite / Zitat	Phase	Bias	Begründung: in welche Richtung verschiebt er das Ergebnis?	Gegenmittel (verwendet?)

Was haben die Autorinnen und Autoren methodisch gut gemacht?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 8**

Übungsblatt B: Der Bias im eigenen Projekt

Name: _____ Datum: _____

Aufgabe 3: Reflexion: der Bias in meinem eigenen Forschungsprozess

Hausaufgabe

Legen Sie Ihre Design-Skizze aus LE 7 zugrunde.

Welcher Bias droht am stärksten?	
In welcher Phase?	
Woran würde ich merken, dass er gewirkt hat?	
Mit welchem *Verfahren* begrenze ich ihn?	

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Beschreiben Sie eine Situation, in der Sie etwas wussten und trotzdem anders wahrgenommen oder entschieden haben. Was hätte Ihnen geholfen, dem Wissen statt dem Erleben zu folgen?

Erwartungshorizont

Aufgabe 1. (1) Interessenkonflikt, Bestätigungsfehler in der Planung. (2) Selektion und Abhängigkeit: eigene Studierende, mögliche Gefälligkeitseffekte. (3) Konfundierung der Bedingung mit Reihenfolge und Tageszeit (Übung, Ermüdung); kein Bias im engeren Sinn, aber eine Bedrohung der internen Validität, die in Richtung des erhofften Effekts wirken kann. (4) Versuchsleitereffekt, keine Blindbewertung (Erhebung). (5) selektives Berichten, p-Hacking über zwölf Maße (Auswertung). (6) optionales Weitererheben bis zur Signifikanz (Auswertung). (7) Rückschaufehler bzw. HARKing, keine Präregistrierung (Interpretation). (8) Publication Bias (Publikation). **Aufgabe 2.** Mindestens zwei Stellen mit Fundort, benannter Verzerrung, begründeter Richtung und konkretem Gegenmittel. Bloße Schwächen (kleine Stichprobe, Gelegenheitsstichprobe) zählen als Unsicherheit oder Einschränkung der externen Validität; als Bias nur, wenn eine Richtung begründet wird. **Aufgabe 3.** Ein Verfahren ist gefordert (Blindbewertung, Präregistrierung, zweite Kodiererin, vorab festgelegtes Abbruchkriterium), kein Vorsatz.

9 Qualitative Methoden

LE 6 hat gezählt: Gewinne beim Wechseln, Ausschläge in Millimetern, Staunen auf einer Skala von 1 bis 5. Diese Einheit fragt, was dabei verloren geht. Sie beginnt mit einem Effekt, den die Studierenden schon kennen, und zeigt ihn zweimal mit identischen Handlungen. Nur die Sprache ändert sich: einmal sachlich, einmal mit dem „magischen" Sprechtext, den Zauberkünstler *Patter* nennen. Was sich dabei ändert, lässt sich zwar auf einer Skala ankreuzen, aber erst in den Worten der Beteiligten verstehen. Daraus entwickelt die Einheit die Grundlogik qualitativer Forschung: Verstehen statt Messen, Wirklichkeit als sprachlich mitkonstruiert, Objektivität als Intersubjektivität. Sie schließt mit zwei Werkzeugen, die die Studierenden sofort anwenden: dem Leitfadeninterview und der qualitativen Inhaltsanalyse.

Vorbereitung vor der Stunde: Das Patter: ein Effekt, zwei Sprechtexte

Eine Woche vorher

- ☐ **Effekt wählen.** Zwei Varianten sind vorbereitet, beide aus dem Buch und beide im Semester schon vorgekommen: das *Ideomotor-Pendel* (LE 1; Buch, Abschnitt 10f) oder die *Charpentier-Illusion* (LE 8; Buch, Kap. 10). Empfohlen ist das Pendel, weil alle gleichzeitig mitmachen und der Effekt stark auf Erwartung reagiert. Die Charpentier-Illusion eignet sich, wenn der Raum kein Aufstützen erlaubt; dann heben 6–8 Freiwillige vorn, der Rest beobachtet und notiert.
- ☐ Dass die Studierenden den Mechanismus kennen, ist Absicht: Das Wissen (Belief) bleibt in beiden Runden gleich, nur die Sprache ändert sich. Verändert sich das Erleben trotzdem, wirkt die Sprache auf der Ebene der Alief (LE 1).
- ☐ **Material Pendel:** die Pendel aus LE 1 (Faden 40 cm, Mutter M8 oder Ring), zehn Ersatzpendel. **Material Charpentier:** drei gleich aussehende Streichholzschachteln mit Gummiband, die oberste mit ca. 50 g beschwert (wie in LE 8); zwei Sets.
- ☐ **Beide Sprechtexte** (Abschnitt Staunmoment) so oft laut üben, bis sie ohne Ablesen sitzen. Der magische Text lebt von Pausen, leiser Stimme und Blickkontakt, der sachliche von gleichmäßigem Tempo und Laborton. Die Handlungen müssen in beiden Runden identisch sein: gleiche Haltung, gleiche Dauer (Stoppuhr, je 60 Sekunden Pendeln), gleiche Kommandos für die Richtung.
- ☐ Pro Person zwei Karteikarten (A7) vorbereiten, beschriftet mit „Runde 1" und „Runde 2". Darauf kommen nach jeder Runde eine Zahl (Stärke des Erlebens, 1–5) und drei Wörter.

Handout und Übungsblatt

- ☐ Handout „Qualitative Methoden" sowie Übungsblatt LE 9 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 9). Teil A liegt zu Beginn aus und enthält die Leitfaden-Vorlage (Aufgabe 1), das konstruierte Interviewtranskript und die Codiertabelle (Aufgabe 2). Teil B (Wörter von der Tafel ordnen, Tagebuch) verrät, dass sich zwischen den Runden der Rahmen ändert; es wird erst nach der Offenlegung ausgeteilt.
- ☐ Für den Codier-Vergleich das Transkript zusätzlich einmal pro Gruppe auf A3 kopieren, damit Gruppen Segmente markieren können; zwei Farben Textmarker pro Gruppe.

Am Tag selbst

- ☐ Tafel teilen: links „Runde 1", rechts „Runde 2"; darunter je ein Feld für die Zahlen und eines für die Wörter.
- ☐ Licht für Runde 2 etwas dimmen, falls möglich; das ist Teil des Patters und wird im Debrief offengelegt.
- ☐ Karten nach jeder Runde sofort einsammeln, damit die Antworten der zweiten Runde nicht an die der ersten angepasst werden.

Risiken und Plan B. Manche Studierende reagieren auf den magischen Text mit Ironie oder Abwehr. Das ist kein Störfall, sondern Material: Auch Abwehr ist eine Reaktion auf Sprache und gehört auf die Karte. Die Reihenfolge (erst sachlich, dann magisch) ist mit Übung und Ermüdung vermengt; das wird im Debrief als Designproblem besprochen (Brücke zu LE 7). Ethisch gilt, was das Buch für die Persona der Lehrenden festhält: keine falschen Überzeugungen pflanzen. Der magische Rahmen wird deshalb noch in derselben Viertelstunde als Rahmen offengelegt. Fällt der Effekt ganz aus (Pendel schwingt kaum), wird direkt mit den Karten gearbeitet: Auch „nichts gespürt" ist eine Beschreibung, deren Wortwahl sich zwischen den Runden unterscheiden kann.

Ablauf der Doppelstunde (90 Min.)

0–5 · Blitzlicht. Anknüpfen an LE 6: Nicht alles Wichtige ist zählbar. Was messen Zahlen *nicht*?

5–20 · Staunmoment. Derselbe Effekt zweimal, erst mit sachlichem, dann mit magischem Sprechtext. Nach jeder Runde Karte: eine Zahl, drei Wörter. Zahlen und Wörter an die Tafel; Offenlegung des Rahmens. Danach Übungsblatt Teil B austeilen.

20–50 · Theorie-Input. Verstehen statt Messen; Konstruktivismus und Intersubjektivität; Patter und Wahrheitspraktiken (Buch, Kap. 6 und 5b); Methodenüberblick; Leitfadeninterview; Gütekriterien; qualitative Inhalts-

analyse nach Mayring; dabei die Wörter von der Tafel induktiv zu Kategorien ordnen (Teil B, Aufgabe 3).

50–75 · Interview-Design. Leitfaden mit 8–12 Fragen zur eigenen Forschungsfrage (Übungsblatt Teil A, Aufgabe 1); Probe-Interview in Paaren; Reflexion suggestiver und offener Fragen.

75–90 · Codier-Vergleich. Zwei Gruppen codieren dasselbe kurze Transkript (Teil A, Aufgabe 2) und vergleichen ihre Codes.

9.1 Staunmoment: Zweimal dasselbe

★ Staunmoment: Das Patter

Sie erleben denselben Effekt zweimal. Die Handlungen sind identisch: gleiche Haltung, gleiche Dauer, gleiche Richtungen.
Nach jeder Runde notieren Sie auf Ihrer Karte: eine Zahl von 1 bis 5 (wie stark war Ihr Erleben?) und drei Wörter, die es beschreiben.

Sprechtext A: sachlich (Pendel, Runde 1)

Nehmen Sie das Pendel zur Hand. Ellbogen auf den Tisch, Faden zwischen Daumen und Zeigefinger, das Gewicht etwa zwei Zentimeter über der Handfläche. Wir machen eine Messung. Ich gebe eine Richtung vor, Sie stellen sich die Bewegung nur vor. Richtung eins: links – rechts. Ich stoppe nach sechzig Sekunden. … Danke. Richtung zwei: vor – zurück. … Danke. Legen Sie das Pendel ab und notieren Sie auf Karte eins eine Zahl und drei Wörter.

Sprechtext B: magisch (Pendel, Runde 2)

Nehmen Sie das Pendel noch einmal. Diesmal halten Sie es anders – nicht mit den Fingern, sondern mit Aufmerksamkeit. Seit Jahrhunderten haben Menschen Pendeln Fragen gestellt, deren Antwort sie nicht aussprechen wollten. Ihr Kopf weiß manches erst später als Ihre Hand. … Ellbogen auf den Tisch. Lassen Sie das Gewicht zur Ruhe kommen. Und jetzt fragen Sie es, ohne die Lippen zu bewegen: Wohin willst du? Wenn es nach links und rechts geht … lassen Sie es gehen. … Und jetzt bitten Sie es: vor – und zurück. Merken Sie, wie es zögert, bevor es Ihnen folgt? … Legen Sie es behutsam ab. Karte zwei: eine Zahl, drei Wörter.

Variante Charpentier-Illusion

Sachlich: *Drei Schachteln, mit Gummiband verbunden. Heben Sie den Stapel an, stellen Sie ihn ab. Nehmen Sie nur die oberste Schachtel und heben Sie sie an. Schätzen Sie: leichter, gleich oder schwerer als der Stapel?* **Magisch:** *Diese drei Schachteln habe ich aus dem Nachlass eines Uhrmachers. Er hat in die oberste etwas gelegt, das nie jemand gesehen hat. Man sagt, sie werde schwerer, sobald sie allein ist – als vermisse sie die anderen. Heben Sie den Stapel. Und jetzt nehmen Sie sie aus der Gemeinschaft heraus …* Der magische Text nutzt die drei Mechanismen, mit denen Objekte nach dem Buch „geladen" werden: Geschichte, Zeremonie der Einführung, Teilhabe des Publikums (Buch, Abschnitt Re-Enchantment; Taylor (2020)). Die Geschichte ist erfunden und wird im Debrief als erfunden benannt.

Was war anders?

- Zahlen an die Tafel: Runde 1 und Runde 2
- Wörter an die Tafel: Runde 1 und Runde 2
- die Handlungen waren identisch – was hat sich geändert?
- was sagen Ihnen die Zahlen, was sagen Ihnen die Wörter?

Die Zahlen zeigen bestenfalls, *dass* sich etwas geändert hat und in welche Richtung. Die Wörter zeigen, *wie*: Denkbar sind nach der sachlichen Runde Wörter wie „Messung" oder „gleichmäßig", nach der magischen eher „unheimlich", „albern" oder „als ob jemand zieht". Was die eigene Gruppe tatsächlich schreibt, zeigt erst die Tafel; Vorhersagen dazu sollte man im Raum nicht äußern. Wichtig ist der Hinweis, dass auch „albern" eine Wirkung der Sprache ist.

Offenlegung

- das Pendel hat in beiden Runden dasselbe getan: Ihre Hand bewegt es (LE 1)
- geändert haben sich Wortwahl, Tempo, Licht, Stimme – der *Rahmen*
- und: die Reihenfolge – Runde 2 war immer die geübtere
- Frage für heute: Wie erforscht man, was ein Rahmen mit Menschen macht?

9.2 Verstehen statt Messen

Quantitative Forschung fragt, wie viel und wie oft; sie zählt Merkmale, die vorab festgelegt und operationalisiert wurden (LE 2). Qualitative Forschung fragt, wie und warum; sie will verstehen, welche Bedeutung Menschen einer Situation geben, und entwickelt ihre Kategorien oft erst am Material. Die beiden Zugänge sind keine Konkurrenten. Die Zahlen auf den Karten haben gezeigt, dass sich das Erleben verschoben hat; die Wörter haben gezeigt, worin. Für die zweite Frage braucht man offene Daten und Verfahren, die mit Sprache umgehen können.

Zwei Zugänge

	quantitativ	**qualitativ**
Frage	wie viel, wie oft, ob	wie, warum, was bedeutet es
Daten	Zahlen, standardisiert	Texte, Bilder, Beobachtungen
Fälle	viele	wenige, gezielt ausgewählt
Kategorien	vorab festgelegt	oft am Material entwickelt
Ziel	prüfen, verallgemeinern	verstehen, Hypothesen bilden

Was Zahlen nicht messen

- „4" auf der Karte kann heißen: beeindruckt – oder beunruhigt
- eine Skala erfasst nur, was jemand vorher gefragt hat
- Bedeutungen, Begründungen, Widersprüche fallen durch das Raster
- qualitative Daten zeigen, *welche* Fragen man später zählen sollte

9.3 Konstruktivismus und Intersubjektivität

Der Patter-Versuch macht eine These erfahrbar, die die Sozialwissenschaften unter dem Stichwort *Konstruktivismus* diskutieren. Nach Berger und Luckmann (1966) bringen Menschen ihre gemeinsame Alltagswirklichkeit in Interaktion und Sprache hervor; was so entstanden ist, erscheint ihnen anschließend als objektiv gegeben. Die Zauberkunst arbeitet bewusst mit diesem Mechanismus. Das Buch beschreibt, wie Kontext und Persona darüber entscheiden, ob ein Effekt als Trick oder als Wunder erlebt wird (Kap. 6), und wie Objekte durch Geschichte, Zeremonie und Teilhabe „geladen" werden (Taylor 2020). Frieder Vogelmann fragt in diesem Sinn nicht nur, ob eine Aussage wahr ist, sondern wie sie *wirksam* geworden ist: durch welche Wahrheitspraktiken, Inszenierungen und Autoritäten (Vogelmann 2020). Das Buch folgert daraus, dass Wissenschaft sich von der inszenierten Wahrheit des Zauberkünstlers durch Transparenz und Intersubjektivität abheben muss: Sie legt ihr Verfahren offen, wo der Zauberkünstler es verbirgt.

Sprache konstruiert Erleben

- das Patter verändert nicht das Pendel, sondern das, was Sie erleben
- Kontext und Persona entscheiden, ob ein Effekt Trick oder Wunder ist (Buch, Kap. 6)
- Wahrheit wird *wirksam* durch Praktiken, Rollen, Inszenierung (Vogelmann 2020)
- Wissenschaft hält dagegen: Verfahren offenlegen statt verbergen

Jedes Interview ist auch ein Patter

- Unfallfilm, Frage nach der Geschwindigkeit: „smashed" statt „hit" führt zu höheren Schätzungen
- eine Woche später erinnern mehr Personen zerbrochenes Glas, das es nicht gab (Loftus und Palmer 1974b)
- Fragen erheben Wirklichkeit nicht nur, sie formen sie mit
- Konsequenz: die eigene Sprache als Teil der Daten behandeln

Intersubjektivität

Definition 9.1 Intersubjektivität heißt: Ein Befund hängt nicht an der Person, die ihn erhoben hat. Andere können das Vorgehen nachvollziehen und kommen mit demselben Material zu vergleichbaren Ergebnissen oder können begründen, warum nicht.

- in der quantitativen Forschung: standardisierte Messung
- in der qualitativen Forschung: offengelegte Regeln, mehrere Codierende, dokumentierte Entscheidungen

9.4 Methoden im Überblick

Qualitative Daten entstehen auf vier Hauptwegen. Im *Leitfadeninterview* spricht eine Person entlang vorbereiteter, aber offener Fragen; der Leitfaden sichert Vergleichbarkeit, ohne die Antworten vorzugeben. In der *Fokusgruppe* diskutieren sechs bis zehn Personen ein Thema; sichtbar werden dabei geteilte Deutungen und Konflikte, die im Einzelgespräch nicht entstünden. Die *Beobachtung* (teilnehmend oder nicht teilnehmend, offen oder verdeckt) erfasst, was Menschen tun, nicht nur, was sie darüber sagen. Die *Dokumentenanalyse* arbeitet mit vorhandenem Material wie Protokollen, Zeitungsartikeln, Lehrplänen oder Social-Media-Beiträgen. Eine ausführliche Darstellung aller vier Wege bietet Döring und Bortz (2016b).

Vier Wege zu qualitativen Daten

Methode	stark bei …	Vorsicht bei …
Leitfadeninterview	Deutungen, Begründungen	Suggestion, sozialer Erwünschtheit
Fokusgruppe	geteilten Sichtweisen, Konflikten	Meinungsführern, Gruppendruck
Beobachtung	tatsächlichem Verhalten	Beobachtereffekt, Deutung
Dokumentenanalyse	Prozessen, Diskursen	Auswahl der Dokumente

9.5 Das Leitfadeninterview

Ein Leitfaden ist kein Fragebogen. Er strukturiert das Gespräch in wenige Themenblöcke, beginnt jeden Block mit einer offenen, erzählgenerierenden Frage und hält Nachfragen bereit, die erst gestellt werden, wenn ein Aspekt nicht von selbst angesprochen wird. Helfferich (2011) empfiehlt, Leitfäden in vier Schritten zu bauen: zunächst alle Fragen sammeln, dann prüfen (Ist die Frage offen? Will ich das wirklich wissen? Setzt sie Wissen voraus?), sortieren und schließlich unter wenige erzählgenerierende Leitfragen subsumieren. Das Interview ist dabei immer eine gemeinsam hergestellte Kommunikationssituation; Neutralität ist nicht erreichbar, wohl aber Reflexion über die eigene Rolle.

Einen Leitfaden bauen

- **sammeln**: alle Fragen notieren, ohne zu filtern
- **prüfen**: offen? nötig? suggestiv? Fachwort?
- **sortieren**: nach Themenblöcken
- **subsumieren**: je Block eine offene Leitfrage, darunter Nachfragen (Helfferich 2011)
- 8–12 Fragen reichen für 30 Minuten

Offen oder suggestiv?

suggestiv / geschlossen	offen
„Fanden Sie den Trick auch so verblüffend?“	„Wie haben Sie den Moment erlebt?“
„Hat Ihnen das beim Lernen geholfen?“	„Was ist Ihnen davon im Kopf geblieben?“
„Warum mögen Sie Statistik nicht?“	„Erzählen Sie, wie es Ihnen mit Statistik geht.“

- Faustregel: Die Frage darf die Antwort nicht enthalten

9.6 Gütekriterien

Die klassischen Gütekriterien Objektivität, Reliabilität und Validität setzen standardisierte Messung voraus. Für interpretative Forschung haben Lincoln und Guba (1985) vier Entsprechungen vorgeschlagen, die bis heute verbreitet sind. *Credibility* fragt, ob die Rekonstruktion für die Beteiligten glaubwürdig ist; Mittel sind längeres Feldengagement, Triangulation und die Rückmeldung an die Befragten (*member checking*). *Transferability* fragt, ob Befunde auf andere Kontexte übertragbar sind; dazu muss der Kontext so genau beschrieben sein, dass Lesende selbst urteilen können. *Dependability* fragt nach der Nachvollziehbarkeit des Vorgehens, *Confirmability* danach, ob die Befunde aus den Daten folgen und nicht aus den Vorlieben der Forschenden; beides sichert ein dokumentierter Prüfpfad (*audit trail*).

Gütekriterien nach Lincoln und Guba

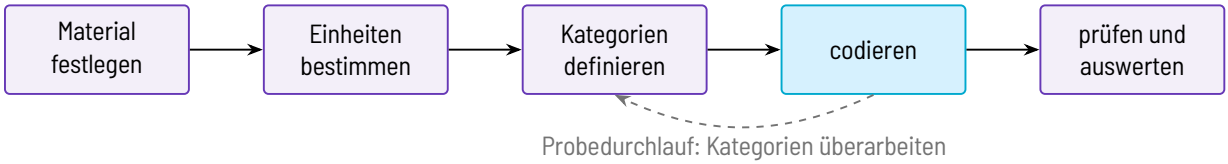
Kriterium	entspricht	gesichert durch
Credibility	interner Validität	Triangulation, member checking
Transferability	externer Validität	dichte Beschreibung des Kontexts
Dependability	Reliabilität	dokumentiertes Vorgehen
Confirmability	Objektivität	Audit Trail, Reflexion der eigenen Rolle

Quelle: Lincoln und Guba (1985).

9.7 Qualitative Inhaltsanalyse nach Mayring

Die qualitative Inhaltsanalyse ist im deutschsprachigen Raum das verbreitetste Verfahren, um Texte regelgeleitet auszuwerten (Mayring 2015). Sie zerlegt das Material in Analyseeinheiten und ordnet diese Kategorien zu. Die Kategorien können vorab aus der Theorie abgeleitet werden (deduktiv) oder am Material entstehen (induktiv); in der Praxis wird oft beides kombiniert. Jede Kategorie erhält eine Definition, ein Ankerbeispiel aus dem Material und eine Kodierregel für Abgrenzungsfälle. Die Regelgeleitetheit unterscheidet die Inhaltsanalyse vom bloßen Interpretieren: Eine zweite Person soll mit demselben Kategoriensystem zu vergleichbaren Zuordnungen kommen. Wie gut das gelingt, misst die Intercoder-Übereinstimmung.

Ablauf in fünf Schritten



- deduktiv: Kategorien aus Theorie oder Forschungsfrage
- induktiv: Kategorien aus dem Material

Eine Kategorie definieren

Kategorie	K1 „Staunen“
Definition	Äußerungen, in denen die Person beschreibt, dass etwas ihren Erwartungen widersprach und sie überrascht oder verblüfft war
Ankerbeispiel	„Ich hab wirklich gedacht, das geht nicht.“
Kodierregel	nur codieren, wenn die Überraschung erlebt wird; bloße Bewertung („war gut gemacht“) gehört zu K5

Das Beispiel stammt aus dem Kategoriensystem des Übungsblatts (Teil A, Aufgabe 2).

Codieren und vergleichen

- zwei Personen codieren dasselbe Material unabhängig
- einfache Übereinstimmung: übereinstimmende Segmente durch alle Segmente
- Abweichungen sind kein Fehler, sondern Hinweise: Definition unscharf? Segment mehrdeutig?
- Kategoriensystem überarbeiten, dokumentieren, neu codieren

Für Abschlussarbeiten genügt meist die prozentuale Übereinstimmung mit einer Diskussion der Abweichungen. Zufallskorrigierte Maße wie Cohens κ werden in Methodenlehrbüchern behandelt (Döring und Bortz 2016b).

9.8 Stärken und Grenzen

Was qualitative Forschung leisten kann

- **stark**: Neues entdecken, Bedeutungen und Abläufe verstehen, Hypothesen bilden
- **begrenzt**: Häufigkeiten schätzen, Ursachen prüfen, verallgemeinern
- **Risiko**: Die Forschenden finden, was sie erwartet haben (LE 8)
- **Gegenmittel**: offene Regeln, zweite Codierung, Triangulation

Viele Projekte verbinden beide Zugänge. Ein typischer Weg führt von Interviews, die Kategorien liefern, zu einem Fragebogen, der sie zählt. Wie sich verschiedene Datenquellen gegenseitig absichern, ist Thema der Triangulation in LE 10 (Denzin 1970).

Merke

Wer fragt, formt die Antwort mit. Qualitative Forschung leugnet das nicht, sondern macht es sichtbar: durch offene Fragen, offengelegte Regeln und eine zweite Person, die dasselbe Material unabhängig liest.

9.9 Übung in der Stunde

Interview-Design (Einzeln und Paare, 25 Min.)

- Leitfaden zu Ihrer Forschungsfrage: 8–12 Fragen in der Vorlage (Übungsblatt Teil A, Aufgabe 1)
- Probe-Interview in Paaren, 5 Minuten, dann Rollentausch
- welche Frage war suggestiv, welche zu offen?

Codier-Vergleich (zwei Gruppen, 15 Min.)

- beide Gruppen codieren dasselbe Transkript (Übungsblatt Teil A, Aufgabe 2)
- jedes Segment genau einer Kategorie K1–K5 zuordnen
- dann vergleichen: In wie vielen Segmenten stimmen Sie überein?
- wo nicht – und warum?

Hinweis für Lehrende

Beim Probe-Interview fallen fast immer dieselben Muster auf: Ja/Nein-Fragen, Doppelfragen und Fragen, die eine Bewertung vorgeben. Gute Reflexionen nennen ein konkretes Beispiel aus dem eigenen Leitfaden und eine Umformulierung. Beim Codier-Vergleich ist das Transkript so gebaut, dass einige Segmente eindeutig und einige absichtlich mehrdeutig sind (Musterlösung im Erwartungshorizont am Ende von Teil B des Übungsblatts). Volle Übereinstimmung ist deshalb nicht zu erwarten. Daran lässt sich zeigen, dass Intersubjektivität kein Zustand ist, sondern eine Arbeit: Abweichungen besprechen, Kodierregeln schärfen, dokumentieren. Lehrreich ist auch Segment 4: Dort stellt die interviewende Person eine suggestive Frage, und die Antwort übernimmt deren Wortwahl.

9.10 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- qualitative und quantitative Forschungslogik voneinander abgrenzen
- erklären, warum Sprache Daten mitformt
- Leitfadeninterview, Fokusgruppe, Beobachtung und Dokumentenanalyse einordnen
- einen offenen Interviewleitfaden entwerfen
- die Gütekriterien nach Lincoln und Guba benennen und eine Inhaltsanalyse in Grundzügen durchführen

Bis zur nächsten Woche

- **Interview-Design**: Leitfaden überarbeiten, ein Probe-Interview führen und kurz reflektieren (Aufgabe 1)
- **Mini-Inhaltsanalyse**: Codier-Vergleich abschließen (Aufgabe 2)
- **Tagebuch des Staunens**: Wann hat eine Formulierung Ihr Erleben verändert?
- für LE 10: Notieren Sie, was Sie in Ihrem Projekt bisher *gefunden* haben

Handout: Qualitative Methoden

Worum es heute ging. Sie haben denselben Effekt zweimal erlebt, mit identischen Handlungen. Nur der Sprechtext war anders: einmal sachlich, einmal „magisch". Die Zahl auf Ihrer Karte zeigt, ob sich Ihr Erleben verschoben hat; Ihre drei Wörter zeigen, worin. Genau dafür gibt es qualitative Forschung: Sie fragt, wie Menschen eine Situation deuten, und behandelt die eigene Sprache als Teil der Daten.

Kernbegriffe

Verstehen statt Messen Qualitative Forschung fragt nach Bedeutungen und Begründungen, arbeitet mit wenigen, gezielt gewählten Fällen und bildet Kategorien oft erst am Material.

Konstruktivismus Wirklichkeit wird in Interaktion und Sprache mit hervorgebracht (Berger und Luckmann 1966). Auch Interviewfragen formen die Antworten (Loftus und Palmer 1974b).

Intersubjektivität Ein Befund hängt nicht an der Person, die ihn erhoben hat: Verfahren offenlegen, zweite Codierung, Abweichungen begründen.

Leitfadeninterview offene Leitfragen je Themenblock, darunter Nachfragen; Bau nach „sammeln – prüfen – sortieren – subsumieren" (Helfferich 2011).

Qualitative Inhaltsanalyse regelgeleitetes Zuordnen von Textstellen zu Kategorien mit Definition, Ankerbeispiel und Kodierregel (Mayring 2015).

Gütekriterien nach Lincoln und Guba (1985)

Kriterium	Frage	Mittel
Credibility	Ist die Rekonstruktion glaubwürdig?	Triangulation, member checking
Transferability	Lässt sich übertragen?	dichte Beschreibung
Dependability	Ist das Vorgehen nachvollziehbar?	Dokumentation
Confirmability	Folgt der Befund aus den Daten?	Audit Trail, Selbstreflexion

Vier Wege zu qualitativen Daten: Leitfadeninterview, Fokusgruppe, Beobachtung, Dokumentenanalyse.

Merke

Wer fragt, formt die Antwort mit. Gute qualitative Forschung macht das sichtbar: offene Fragen, offengelegte Regeln, eine zweite Person, die unabhängig codiert.

Zum Weiterlesen: Helfferich (2011), Kap. 4; Mayring (2015), Kap. 5; Döring und Bortz (2016b), Kap. 10.

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 9**

Übungsblatt A: Leitfaden und Transkript

Name: _____ Datum: _____

Aufgabe 1: Interviewleitfaden

in der Stunde und Hausaufgabe

Entwickeln Sie einen Leitfaden mit 8–12 Fragen zu Ihrer Forschungsfrage. Jeder Block beginnt mit einer offenen Leitfrage; Nachfragen stellen Sie nur, wenn der Aspekt nicht von selbst kommt.

Meine Forschungsfrage: _____

Block	Leitfrage (offen, erzählauffordernd)	Nachfragen
Einstieg		
Thema A		
Thema B		
Thema C		
Abschluss	„Gibt es noch etwas, das Ihnen wichtig ist?“	

Prüfen Sie jede Frage: ☐ offen statt ja/nein ☐ keine Doppelfrage ☐ keine Bewertung vorgegeben ☐ kein Fachwort ☐ ich brauche die Antwort wirklich

Reflexion nach dem Probe-Interview: Welche Frage war suggestiv, welche zu offen? Wie würden Sie sie umformulieren?

Aufgabe 2: Mini-Inhaltsanalyse

in der Stunde, zwei Gruppen, 15 Min.

Konstruiertes Transkript (für diese Übung erfunden, keine echte Person). Kontext: Interview mit einer Studentin (B) eine Woche nach einer Vorlesung, in der der Dozent einen Becher-Zaubertrick gezeigt und nicht aufgelöst hat. I = interviewende Person.

[1] **I:** Erzählen Sie mal, wie Sie die Vorlesung am Dienstag erlebt haben. **B:** Ehrlich gesagt war ich am Anfang total müde, ich hatte vorher noch Labor. Dann hat er plötzlich diese Becher rausgeholt, und ich dachte: Was wird das jetzt?

[2] **B:** Und dann war die Kugel weg. Also wirklich weg. Ich hab wirklich gedacht, das geht nicht. Ich hab mich richtig aufgerichtet.

[3] **B:** Mein Nachbar hat sofort gesagt, die ist im Ärmel. Aber er hatte ja kurze Ärmel an. Wir haben die ganze Pause darüber geredet, wie das gehen könnte.

[4] **I:** Fanden Sie es auch unangenehm, dass Sie getäuscht wurden? **B:** Ja, unangenehm schon irgendwie. Also, nicht schlimm. Aber man fühlt sich halt ein bisschen vorgeführt.

[5] **I:** Was ist Ihnen von der Vorlesung im Kopf geblieben? **B:** Das mit den zwei Dritteln. Dass man wechseln soll. Das hab ich abends meiner Mitbewohnerin erklärt, und die hat's mir nicht geglaubt. Dann haben wir's mit Tassen ausprobiert.

[6] **B:** Ob ich das ohne den Trick auch behalten hätte? Keine Ahnung. Vielleicht. Ich war halt wach danach.

[7] **I:** Wie würden Sie den Dozenten beschreiben? **B:** Der ist schon gut. Man merkt, dass der das kann, das war sauber gemacht. Aber man weiß bei dem nie so richtig, ob er einen gerade reinlegt.

[8] **B:** Bei der Klausur frag ich mich jetzt manchmal, ob da auch irgendwo ein Trick drin ist. (lacht)

[9] **I:** Gibt es noch etwas, das Ihnen wichtig ist? **B:** Ich fand's gut, dass er's nicht aufgelöst hat. Sonst hätten wir nicht so lange drüber nachgedacht. Obwohl mich das schon nervt, ehrlich gesagt.

[10] **B:** Ich glaub, ich hab danach mehr mitgeschrieben als sonst. Aber das kann auch am Thema gelegen haben.

Kategoriensystem (deduktiv vorgegeben): **K1** Staunen: erlebte Überraschung, Widerspruch zur Erwartung. – **K2** Erklärungssuche: Vermutungen, Diskussion, Ausprobieren, wie etwas funktioniert. – **K3** Unbehagen: Misstrauen, Ärger, Gefühl, vorgeführt zu werden. – **K4** Lernen: Behalten, Aufmerksamkeit, Mitschreiben, Weitergeben von Inhalten. – **K5** Bewertung der Lehrperson oder Darbietung. – **K0** Sonstiges, Kontext. *Kodierregel:* jedes Segment genau einer Kategorie zuordnen; bei Zweifel die Kategorie des Satzes mit dem stärksten Gewicht wählen und den Zweifel notieren.

Segm.	Gr. 1	Gr. 2	gleich?	Begründung bei Abweichung
1				
2				
3				
4				
5				
6				
7				
8				
9				
10				

Übereinstimmung: _____ von 10 Segmenten = _____ %. Was sagt die Abweichung über Intersubjektivität, also darüber, ob der Befund unabhängig von der Person ist, die codiert? Was fällt Ihnen an Segment 4 auf?

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 9**

Übungsblatt B: Wörter, Kategorien, Rahmen

Name: _____ Datum: _____

Aufgabe 3: Die Wörter von der Tafel ordnen

in der Stunde, Plenum, 5 Min.

Fassen Sie die Wörter der beiden Runden zu drei bis fünf Gruppen zusammen und geben Sie jeder Gruppe einen Namen. Sie haben damit induktiv Kategorien gebildet.

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Wann hat eine Formulierung, ein Tonfall oder ein Rahmen Ihr Erleben verändert, obwohl sich an der Sache nichts geändert hat?

Erwartungshorizont

Aufgabe 1. Mindestens drei Blöcke mit je einer offenen Leitfrage; keine Ja/Nein-Fragen als Leitfragen; Nachfragen konkret. Typische Umformulierung: „Hat Ihnen das geholfen?" wird zu „Was hat sich danach für Sie verändert?"

Aufgabe 2 (Musterlösung; Abweichungen sind erwünscht, wenn sie begründet werden). *Eindeutig:* 2 K1 (Ankerbeispiel), 3 K2, 6 K4, 10 K4. *Mehrdeutig, absichtlich:* 1 K0 (Kontext; wer „Was wird das jetzt?" als Neugier liest, wählt K1, die Kodierregel spricht aber dagegen, weil noch keine Überraschung erlebt wird); 4 K3, aber die Frage gibt das Wort „unangenehm" vor, die Antwort übernimmt es und schwächt es gleich ab – das Segment ist methodisch belastet und sollte markiert werden; 5 K4 (Weitergeben des Inhalts), mit Anteil K2 (Ausprobieren mit Tassen); 7 K5, der zweite Satz gehört zu K3; 8 K3 (Misstrauen), wegen „(lacht)" auch als K5 lesbar; 9 K5 („fand's gut") gegen K3 („nervt"). Vier Segmente sind eindeutig; wie viele der übrigen sechs übereinstimmen, hängt an den Grenzfällen. Lernziel ist die Einsicht, dass die Abweichungen an den Kategoriengrenzen entstehen und dass eine schärfere Kodierregel (z. B. für Segmente mit zwei Gefühlslagen) die Übereinstimmung erhöht. Segment 4 zeigt außerdem, wie eine suggestive Frage Daten erzeugt, die man nicht mehr sauber deuten kann.

Aufgabe 3. Jede plausible Gruppierung ist richtig, wenn die Gruppennamen die enthaltenen Wörter tatsächlich abdecken. Hinweis an die Studierenden: Die Gruppennamen sind bereits eine Deutung.

10 Datenanalyse und Interpretation

In LE 6 und LE 9 haben die Studierenden Daten erhoben und beschrieben. Diese Einheit fragt, was man aus ihnen schließen darf. Sie beginnt mit einer Vorhersage, die versiegelt im Raum liegt, und mit vier Zahlen, die Freiwillige frei wählen. Die Summe trifft die Vorhersage. Die Wahl war frei, das Ergebnis trotzdem festgelegt: durch die Struktur der Rechnung. Dieselbe Struktur steckt in vielen Datenauswertungen, die scheinbar offen beginnen und doch nur zu einem Ergebnis führen können. Die Einheit unterscheidet deshalb sauber zwischen Daten, Befund und Schlussfolgerung, zeigt mit dem Vorhersage-Trick aus dem Buch, wie p-Hacking garantierte Muster erzeugt, und stellt die Gegenmittel vor: Gegenhypothesen, Triangulation und Präregistrierung.

Vorbereitung vor der Stunde: Die unveränderliche Summe und der Vorhersage-Trick

Hinweis. Kap. 15 des Buchs nennt den Effekt „Die unveränderliche Summe (Datum-Force)", beschreibt aber keine Methode. Die folgende selbstarbeitende Variante ist ein *Vorschlag* für die Umsetzung. Sie beruht auf reiner Arithmetik und braucht keine Fingerfertigkeit.

Das Prinzip. Eine Person nennt (1) ihr Geburtsjahr, (2) das Alter, das sie im laufenden Kalenderjahr erreicht, (3) das Jahr eines persönlich wichtigen Ereignisses und (4) die Anzahl der Jahre, die seitdem bis zum laufenden Jahr vergangen sind. Geburtsjahr plus erreichtes Alter ergibt das laufende Jahr J, Ereignisjahr plus vergangene Jahre ebenfalls. Die Summe aller vier Zahlen ist deshalb immer $2J$.

Eine Woche vorher

- ☐ **Termin prüfen!** LE 10 liegt im Dezember oder Januar. Die Vorhersage hängt am Kalenderjahr des Vorlesungstags: im Dezember 2026 lautet sie 4052, im Januar 2027 lautet sie 4054. Wird der Termin über den Jahreswechsel verschoben, Vorhersage neu schreiben.
- ☐ Vorhersage auf eine Karte schreiben, in einen Umschlag stecken, zukleben und unterschreiben lassen (z. B. von einer Kollegin). Der Umschlag liegt ab Beginn der Stunde sichtbar am Pult oder klebt an der Tafel.
- ☐ Sprechtext üben, vor allem die Fragen 2 und 4 (siehe Fallstricke). Zwei Probeläufe mit Personen, die den Effekt nicht kennen; dabei auf Missverständnisse achten.
- ☐ Für den Vorhersage-Trick (Buch, Abschnitt 10d) die geheime Botschaft der Abweichungen festlegen, z. B. $r = (3, 1, 4, 1)$ für die ersten Ziffern von π. Die letzte Zahl der Runde wird geforct. Das Buch nennt dafür Force-Bag, Force-Deck, einen Rechen-Force oder Equivoque (Paillès und Kuhn 2020); Wahl und Einstudierung des Forces nach der Standardliteratur, hier bewusst nicht beschrieben. Die Master-Vorhersage $p_n = F + r_n$ vorab auf eine Karte schreiben und versiegeln.
- ☐ Plan B ohne Force aus dem Buch bereithalten: der 1089-Trick oder Kaprekars Konstante 6174 (Buch, Abschnitt 10d).

Fallstricke der unveränderlichen Summe

- ☐ **Alter:** Es muss das im laufenden Jahr *erreichte* Alter sein, egal ob der Geburtstag schon war. Wer noch nicht Geburtstag hatte und das aktuelle Alter nennt, liegt um eins zu niedrig. Formulierung: „Wie alt werden Sie dieses Jahr an Ihrem Geburtstag – oder sind es schon geworden?"
- ☐ **Vergangene Jahre:** gezählt wird nach Jahreszahlen, nicht nach Jahrestagen. Formulierung: „Wie viele Silvester liegen seit diesem Ereignis hinter Ihnen?" Ein Ereignis im laufenden Jahr ergibt null.
- ☐ **Jahreswechsel:** Im Januar denken viele noch im alten Jahr. Dann „in diesem Jahr" durch „im neuen Jahr" ersetzen und bei der Silvester-Frage „das letzte mitgezählt" ergänzen. Im Dezember besteht die Gefahr nicht.
- ☐ **Paare gehören zusammen:** Geburtsjahr und Alter müssen von derselben Person stammen, Ereignisjahr und vergangene Jahre vom selben Ereignis. Mehrere Personen sind möglich, wenn jede ein vollständiges Paar liefert.
- ☐ **Rechnen:** eine dritte Person addiert mit dem Taschenrechner, eine vierte kontrolliert. Kopfrechnen vor Publikum erzeugt Fehler.

Handout und Übungsblatt

- ☐ Handout „Datenanalyse und Interpretation" sowie Übungsblatt LE 10 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 10). Teil A enthält die vollständigen Rohdaten der fiktiven Studie (Aufgabe 1) und liegt zu Beginn aus. Teil B enthält die Tabelle zur Formel $1 - (1 - \alpha)^m$ (Aufgabe 2), die Reflexion und das Tagebuch; er wird erst nach der Tafel-Auflösung des Vorhersage-Tricks ausgeteilt, weil Aufgabe 2 diese Auflösung und das Tagebuch den Force der ersten Vorführung vorwegnähmen.
- ☐ Taschenrechner zulassen; wer einen Laptop hat, darf die Rohdaten in eine Tabellenkalkulation übernehmen.

Am Tag selbst

- ☐ Umschlag mit der Vorhersage vor Beginn sichtbar aufhängen; nicht kommentieren.
- ☐ Tafel: rechts oben Platz für die vier Zahlen und die Summe, links Platz für die Tabelle des Vorhersage-Tricks (Runde, a_i, p_i, $p_i - a_i$) und die Formel.
- ☐ Für den Vorhersage-Trick: fünf Karten, einen Umschlag, die versiegelte Master-Karte, das Force-Requisit.

Risiken und Plan B. Stimmt die Summe nicht, zuerst die beiden Fallstricke prüfen (Alter, Silvester), und zwar offen: Das ist dann selbst ein Lehrstück über Messfehler und Operationalisierung. Der Effekt ist danach nicht verloren, sondern wird sofort aufgelöst. Kennt jemand den Effekt, wird die Person zur Komplizin gemacht („Verraten Sie es bitte noch nicht"). Misslingt der Force im Vorhersage-Trick, auf den 1089-Trick ausweichen; die Lektion bleibt dieselbe.

Ablauf der Doppelstunde (90 Min.)

0–10 · Staunmoment. „Die unveränderliche Summe": vier frei genannte Zahlen, die Summe trifft die versiegelte Vorhersage. Frage: Wo war hier die Freiheit?

10–20 · Auflösung und Force-Begriff. Die Rechnung an der Tafel; Einordnung als Force; Determinismus und Freiheits-Illusion (Newcomb-Paradoxon, Buch, Kap. 5b).

20–45 · Theorie-Input. Daten – Befund – Schlussfolgerung; Over-Interpretation, p-Hacking, HARKing, Garden of Forking Paths; Triangulation.

45–60 · p-Hacking erleben. Der Vorhersage-Trick (Buch, Abschnitt 10d); Tafel-Auflösung $1-(1-\alpha)^m$. Danach Übungsblatt Teil B austeilen; die Tabelle in Aufgabe 2 vertieft die Formel (in der Stunde oder zu Hause).

60–80 · Befund-Übung. Rohdaten einer fiktiven Studie (Übungsblatt Teil A, Aufgabe 1): deskriptive Befunde, zwei konkurrierende Interpretationen, entscheidende Zusatzdaten.

80–90 · Selbstbezug. Prüfung der eigenen bisherigen Ergebnisse: Habe ich nach Bestätigung gesucht? Was würde meine Hypothese herausfordern? (Übungsblatt Teil B, Aufgabe 3)

10.1 Staunmoment: Die unveränderliche Summe

★ Staunmoment: Vier freie Zahlen

Am Pult liegt seit Beginn der Stunde ein versiegelter Umschlag. Eine Person nennt: (1) ihr Geburtsjahr, (2) das Alter, das sie in diesem Jahr erreicht, (3) das Jahr eines Ereignisses, das ihr wichtig ist, (4) wie viele Silvester seitdem vergangen sind.
Jemand addiert. Dann öffnen wir den Umschlag.

Sprechtext (Vorschlag)

In diesem Umschlag liegt eine Zahl, die ich heute Morgen aufgeschrieben habe. Ich brauche jemanden, der mir vier Zahlen über sich verrät, die ich nicht kennen kann. Sagen Sie uns zuerst Ihr Geburtsjahr. … Und wie alt werden Sie dieses Jahr an Ihrem Geburtstag – oder sind es schon geworden? … Jetzt denken Sie an ein Ereignis, das Ihnen wichtig war. Sie müssen nicht sagen, was es war. Nur das Jahr. … Und wie viele Silvester haben Sie seitdem gefeiert? … Das sind vier Zahlen, die nur Sie kennen. Bitte addieren Sie sie (an eine zweite Person gewandt), und Sie kontrollieren. … Lesen Sie die Summe laut vor. … Öffnen Sie den Umschlag.

Wo war hier die Freiheit?

- alle vier Zahlen waren frei gewählt
- das Ergebnis stand trotzdem vorher fest
- welche Erklärungen haben Sie?
- was hätte die Vorhersage scheitern lassen können?

10.2 Auflösung: der Force

Die Auflösung ist eine Zeile Arithmetik. Geburtsjahr plus das im laufenden Jahr erreichte Alter ergibt das laufende Jahr. Ereignisjahr plus die seitdem vergangenen Jahre ergibt ebenfalls das laufende Jahr. Die Summe ist also das Doppelte der Jahreszahl, gleichgültig, welche Person und welches Ereignis gewählt wurden. In der Sprache der Zauberkunst ist das ein *Force*: Die Wahl ist frei, ihr Ergebnis ist es nicht. Das Buch behandelt dasselbe Muster unter dem Stichwort Determinismus und Freiheits-Illusion am Newcomb-Paradoxon (Nozick 1969): Ein Prädiktor füllt Boxen nach einer Vorhersage über eine Wahl, die erst danach getroffen wird. Zum Zeitpunkt der Wahl liegt der Inhalt längst fest.

Die Rechnung

$$\underbrace{\text{Geburtsjahr} + \text{Alter}}_{=J} + \underbrace{\text{Ereignisjahr} + \text{vergangene Jahre}}_{=J} = 2J$$

- jede Eingabe war frei, die *Struktur* der Rechnung nicht
- die Freiheit hat das Ergebnis nie berührt
- scheitern kann die Vorhersage nur an Messfehlern: falsches Alter, falsch gezählte Jahre

Force

Definition 10.1 Ein **Force** ist ein Verfahren, das einer Person eine freie Wahl lässt und trotzdem ein vorab festgelegtes Ergebnis herbeiführt.

- Zauberkunst: Die versiegelte Vorhersage stimmt, weil das Verfahren sie erzwingt
- Newcomb: Der Prädiktor hat entschieden, bevor die Person wählt (Nozick 1969)
- Forschung: Eine Auswertung, die nur ein Ergebnis zulassen kann, prüft nichts

Forces in der Forschung

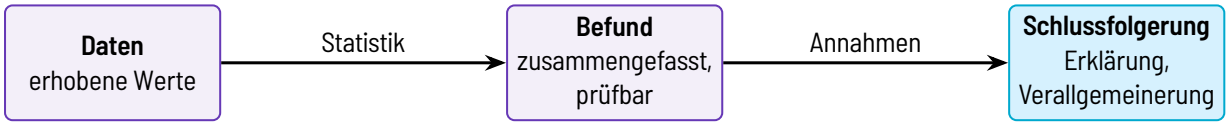
- Stichprobe nur aus Freiwilligen, die das Thema mögen
- Fragebogen nur mit zustimmend formulierten Items
- „Erfolg“ wird erst nach Sicht der Daten definiert
- Auswertung so lange variieren, bis sie passt
- Frage: Hätte meine Auswertung meine Hypothese überhaupt widerlegen können?

Die letzte Frage verbindet die Einheit mit Horwichs Analyse des Beweiswerts (LE 5 und LE 6): Nur Beobachtungen, die ein Widerlegungsrisiko eingehen, haben vollen Beweiswert (Horwich 1982). Eine Auswertung, die strukturell nur ein Ergebnis liefern kann, ist ein Force, kein Test.

10.3 Daten, Befund, Schlussfolgerung

Der häufigste Fehler beim Interpretieren ist kein Rechenfehler, sondern ein Ebenenwechsel. *Daten* sind die erhobenen Werte. Ein *Befund* ist eine Aussage, die die Daten zusammenfasst und an ihnen geprüft werden kann: Mittelwerte, Unterschiede, Zusammenhänge mit ihrer Unsicherheit. Eine *Schlussfolgerung* geht darüber hinaus; sie erklärt den Befund, verallgemeinert ihn oder leitet eine Empfehlung ab. Schlussfolgerungen sind notwendig, aber sie brauchen Annahmen, die man offenlegen muss. Over-Interpretation entsteht, wenn eine Schlussfolgerung wie ein Befund formuliert wird.

Drei Ebenen



- Beispiel Monty Hall: 97 von 150 Wechselrunden gewonnen – Wechseln gewann in 64,7 % – Wechseln ist im Spiel überlegen
- jede Stufe braucht etwas, das in der vorigen nicht steht

Das Monty-Hall-Beispiel ist das konstruierte Rechenbeispiel aus LE 6.

Over-Interpretation

- Zusammenhang als Ursache lesen
- über die Stichprobe hinaus verallgemeinern
- „signifikant" als „groß" oder „wichtig" lesen
- einen Einzelbefund als gesichert darstellen
- aus dem Fehlen eines Befunds auf das Fehlen eines Effekts schließen

Interpretation oder Spekulation?

- **Interpretation**: bleibt an den Befund gebunden, nennt ihre Annahmen, lässt Alternativen zu
- **Spekulation**: geht über das hinaus, was die Daten tragen können – erlaubt, wenn sie so heißt
- Prüffrage: Welcher Befund würde meine Deutung widerlegen?
- Pflicht: zu jeder Deutung mindestens eine Gegenhypothese

10.4 p-Hacking erleben: der Vorhersage-Trick

Für das p-Hacking hat das Buch eine Demonstration, in der die Methode des Tricks und der zu vermittelnde Fehlschluss identisch sind (Abschnitt 10d). Die Vorführende macht mehrere Vorhersagen über Zahlen, die Freiwillige frei nennen. Beim Öffnen sind *alle* Vorhersagen falsch. Dann der Vorschlag, nicht auf die Treffer zu schauen, sondern auf die Fehler: Die Abweichungen zwischen Vorhersage und Wirklichkeit ergeben die Ziffern von π. Die Methode ist ein *One-Ahead*: Die Vorführende schreibt jede „Vorhersage für die nächste Runde" in Wahrheit aus der gerade genannten Zahl plus der geplanten Abweichung; die letzte Zahl ist geforct und die passende Karte vorab versiegelt. Das Muster war also garantiert, weil jede Vorhersage nach dem Blick auf die Daten konstruiert wurde.

Vier Vorhersagen, alle falsch

Runde	genannte Zahl a_i	Vorhersage p_i	Abweichung $p_i - a_i$
1	5	8	**3**
2	9	10	**1**
3	2	6	**4**
4	7	8	**1**

- keine Vorhersage trifft – aber die Fehler lauten 3, 1, 4, 1

Die Tabelle ist das durchgerechnete Beispiel aus dem Buch; in der Stunde stehen dort die tatsächlich genannten Zahlen.

Die Methode ist der Fehlschluss

- jede Vorhersage wurde *nach* der genannten Zahl geschrieben: $p_i = a_i + r_i$
- das Muster war garantiert, egal welche Zahlen kamen
- genau das ist **p-Hacking**: Bedeutung wird nachträglich in Daten hineingerechnet
- dafür braucht es keinen bösen Willen, nur Auswahl nach Sicht der Daten

10.5 Viele Wege, ein Treffer

In der Forschung braucht es für p-Hacking keinen Trick. Es genügt, nach Sicht der Daten unter vielen plausiblen Auswertungen die eine zu wählen, die „funktioniert". Gelman und Loken (2014) nennen das den *Garden of Forking Paths*: Jede Entscheidung über Ausreißer, Teilgruppen, Kovariaten, Messzeitpunkte oder Abbruchkriterien ist eine Weggabelung, und wer erst am Ende des Gartens entscheidet, welchen Weg er gegangen sein will, findet fast immer einen Treffer. Simmons u. a. (2011) haben gezeigt, dass solche „researcher degrees of freedom" die Falsch-Positiv-Rate weit über die nominellen 5 % treiben. Kerr (1998) hat den verwandten Fall benannt, dass eine Hypothese erst nach den Ergebnissen gebildet und dann als vorab aufgestellt präsentiert wird (HARKing). Und Ioannidis (2005) hat argumentiert, dass bei kleinen Studien, kleinen Effekten und vielen getesteten Beziehungen ein großer Teil der veröffentlichten positiven Befunde falsch sein dürfte.

Begriffe

- **p-Hacking**: Auswertung variieren, bis $p < 0{,}05$ (Simmons u. a. 2011)
- **HARKing**: Hypothese nach den Ergebnissen bilden und als vorab ausgeben (Kerr 1998)
- **Garden of Forking Paths**: viele Gabelungen, auch ohne bewusstes Probieren (Gelman und Loken 2014)
- **Data Dredging**: in großen Datensätzen ohne Hypothese nach Mustern graben

Die Tafel-Auflösung

$$P(\text{mindestens ein Treffer}) \;=\; 1 - (1 - \alpha)^m$$

m	1	2	5	10	14	20	50	100
$\alpha = 0{,}05$	5 %	9,8 %	22,6 %	40,1 %	51,2 %	64,2 %	92,3 %	99,4 %

- m: Zahl der Versuche (Auswertungen, Hypothesen, Zwischenstände)
- ab $m = 14$ ist ein Zufallstreffer wahrscheinlicher als keiner
- m ist die „Magier-Freiheit" des Tricks

Die Werte sind nachgerechnet; der Wert für $m = 14$ steht so auch im Buch. Eine strengere Schwelle wie $p < 0{,}005$ verschiebt das Problem nur (Benjamin u. a. 2018): Bei $m = 100$ liegt die Wahrscheinlichkeit für mindestens einen Zufallstreffer dann immer noch bei 39,4 %.

Die Bayes-Pointe

- viele Hypothesen teilen sich den Vorab-Glauben, jede bekommt nur wenig
- ein Treffer unter vielen war ohnehin zu erwarten
- also bleibt die Posteriori nahe der Priori
- 100 versiegelte Vorhersagen, eine trifft: Erwartung, kein Wunder

Ein Verfahren, das *immer* ein hübsches Ergebnis liefert, ist so wenig Evidenz wie ein Test, der die Nullhypothese stets ablehnt (Buch, Abschnitt 10d; Ioannidis (2005)).

Ein Lehrstück aus dem Buch

- Monty-Hall-Feldstudie, Teilnehmende *ohne* Vorwissen
- Trefferquote U1: 25 %, U2: 60 %, U3: 83 %
- Differenz U3 gegen U1: $+58$ Prozentpunkte $[+6;\ +81]$
- aber: sechs gegen acht Personen, Analyse erst nach Sichtung der Daten gerechnet

Das Buch kommentiert diesen Befund selbst als den, dem man am wenigsten trauen darf, und ergänzt: „Genau so entstehen Ergebnisse, die in der Replikation verschwinden" (Kap. 12f). Die Schichtung nach Vorwissen war nicht vorab geplant und ist im Buch ausdrücklich als explorativ markiert. Das ist ein Beispiel für saubere Praxis: Der Befund wird berichtet, aber als Hypothese für eine Folgestudie, nicht als Ergebnis.

10.6 Gegenmittel

Gegen die Freiheiten der Auswertung helfen drei Dinge. Erstens die *Präregistrierung*: Hypothesen, Stichprobengröße und Auswertungsplan werden vor der Datenerhebung öffentlich festgelegt. Damit wird sichtbar, was vorhergesagt und was nachträglich gefunden wurde; beides ist legitim, solange man es unterscheidet (Nosek u. a. 2018). Die Präregistrierung ist das Gegenteil des One-Ahead: Die Vorhersage liegt tatsächlich vorher im Umschlag. Zweitens die *Triangulation*: Derselbe Gegenstand wird mit verschiedenen Daten, Methoden oder Personen untersucht (Denzin 1970). Ein Befund, der nur in einer Auswertung auftaucht, ist verdächtig; einer, den verschiedene Zugänge unabhängig stützen, ist robuster. Drittens die *Gegenhypothese*: Wer zu jeder Deutung aktiv nach der besten Alternative sucht, schützt sich gegen den Bestätigungsfehler (LE 8).

Präregistrierung

- *vor* der Erhebung festlegen: Hypothesen, n, Ausschlüsse, Auswertung
- öffentlich und mit Zeitstempel hinterlegen
- Abweichungen sind erlaubt, müssen aber berichtet werden
- trennt Vorhersage von Nachhersage (Nosek u. a. 2018)
- das Gegenteil des One-Ahead: Die Vorhersage liegt wirklich vorher im Umschlag

Triangulation

- **Daten**: verschiedene Quellen, Zeitpunkte, Orte
- **Forschende**: mehrere Personen werten unabhängig aus (LE 9)
- **Methoden**: Zahlen und Interviews, Experiment und Beobachtung
- **Theorien**: denselben Befund aus mehreren Perspektiven deuten (Denzin 1970)

Prüffragen an die eigene Auswertung

- Stand meine Auswertung fest, bevor ich die Daten sah?
- Wie viele Wege habe ich ausprobiert, wie viele berichte ich?
- Was ist die beste Gegenhypothese?
- Welche Zusatzdaten würden zwischen beiden entscheiden?
- Hätte meine Auswertung meine Hypothese widerlegen können?

Merke

Ein Muster, das jede Datenlage hervorbringen würde, sagt nichts über die konkrete Datenlage. Wer erst nach dem Blick auf die Daten entscheidet, wonach er sucht, hat keinen Befund, sondern eine Hypothese für die nächste Studie.

10.7 Übung in der Stunde

Befund-Übung (Kleingruppen, 20 Min.)

- fiktive Studie: Tagebuch des Staunens und Klausurpunkte (Übungsblatt Teil A)
- (a) Formulieren Sie die deskriptiven Befunde
- (b) Formulieren Sie zwei konkurrierende Interpretationen
- (c) Welche Zusatzdaten würden zwischen ihnen entscheiden?
- (d) Wie viele Wege hätte man auswerten können?

Selbstbezug (Einzelarbeit, 10 Min.)

- Notieren Sie Ihr bisher wichtigstes Ergebnis im Semesterprojekt
- Haben Sie gezielt nach Bestätigung gesucht?
- Welcher Befund würde Ihre Hypothese herausfordern?
- Wo liegen Ihre eigenen Weggabelungen?

Hinweis für Lehrende

Die nachgerechneten Kennwerte der fiktiven Studie stehen im Erwartungshorizont am Ende von Übungsblatt Teil B. Der Datensatz ist so konstruiert, dass der Unterschied zwischen den Tagebuch-Gruppen groß und „hochsignifikant" ist, Tagebuch und Anwesenheit aber so eng zusammenhängen, dass sich ihre Wirkungen mit diesen Daten nicht trennen lassen. Die zentrale Einsicht: Die konkurrierende Interpretation (Engagement als Drittvariable) ist mit den Daten genauso verträglich, und nur ein anderes Design, etwa die zufällige Zuteilung zum Tagebuch, könnte entscheiden. Im Selbstbezug genügt es, wenn jede Person eine eigene Weggabelung konkret benennt.

10.8 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- Daten, Befund und Schlussfolgerung unterscheiden
- zu einem Befund konkurrierende Interpretationen formulieren und entscheidende Zusatzdaten benennen
- p-Hacking, HARKing und den Garden of Forking Paths erklären
- die Wahrscheinlichkeit von Zufallstreffern bei m Tests berechnen
- Präregistrierung und Triangulation als Gegenmittel einsetzen

Bis zur nächsten Woche

- **Befund-Übung** fertigstellen (Übungsblatt Teil A, Aufgabe 1)
- **Reflexion** zum Semesterprojekt: Haben Sie Ergebnisse gesucht, die Ihre Hypothese *bestätigen*? Welche Befunde könnten sie *herausfordern*? (Teil B, Aufgabe 3)
- **Tagebuch des Staunens**: eine Entscheidung, die sich frei anfühlte und es vielleicht nicht war
- für LE 11: einen Absatz aus Ihrem Projekt mitbringen, in dem Sie ein Ergebnis deuten

Handout: Datenanalyse und Interpretation

Worum es heute ging. Vier frei gewählte Zahlen ergaben die Summe, die vorher im Umschlag lag: Geburtsjahr plus erreichtes Alter und Ereignisjahr plus vergangene Jahre ergeben jeweils das laufende Jahr. Die Wahl war frei, das Ergebnis erzwungen – ein *Force*. Beim Vorhersage-Trick waren alle Vorhersagen falsch, und doch ergaben die Fehler die Ziffern von π, weil jede Vorhersage nach dem Blick auf die Daten geschrieben wurde. Beides zeigt: Ein Muster, das jede Datenlage hervorbringt, beweist nichts.

Kernbegriffe

Daten, Befund, Schluss erhobene Werte; prüfbare Zusammenfassung; Deutung mit Annahmen (Schlussfolgerung). Over-Interpretation heißt, eine Schlussfolgerung wie einen Befund zu formulieren.

p-Hacking Auswertung variieren, bis ein Ergebnis signifikant wird (Simmons u. a. 2011).

HARKing Hypothesizing After the Results are Known: eine nachträglich gebildete Hypothese als vorab aufgestellt ausgeben (Kerr 1998).

Garden of Forking Paths viele Entscheidungen der Auswertung erzeugen Zufallstreffer, auch ohne bewusstes Probieren (Gelman und Loken 2014).

Präregistrierung Hypothesen und Auswertungsplan vor der Erhebung öffentlich festlegen (Nosek u. a. 2018).

Triangulation einen Gegenstand mit verschiedenen Daten, Methoden, Personen oder Theorien untersuchen (Denzin 1970).

Zufallstreffer bei m unabhängigen Tests ($\alpha = 0{,}05$)

m	1	2	5	10	14	20	50
$1-(1-\alpha)^m$	5 %	9,8 %	22,6 %	40,1 %	51,2 %	64,2 %	92,3 %

Merke

Wer erst nach dem Blick auf die Daten entscheidet, wonach er sucht, hat keinen Befund, sondern eine Hypothese für die nächste Studie. Zu jeder Deutung gehört eine Gegenhypothese.

Prüffragen: Stand meine Auswertung vorher fest? Wie viele Wege habe ich probiert, wie viele berichte ich? Was ist die beste Gegenhypothese, und welche Daten würden entscheiden?

Zum Weiterlesen: Gelman und Loken (2014); Nosek u. a. (2018); Ioannidis (2005).

Übungsblatt A: Befund und Deutung

Name: _____ Datum: _____

Aufgabe 1: Befund-Übung

in der Stunde, Kleingruppe, 20 Min.

Fiktive Studie (konstruiert für diese Übung, keine echte Erhebung): In einem Kurs mit 13 Terminen wurde für 24 Studierende festgehalten, an wie vielen Terminen sie anwesend waren (**Anw**), wie viele Einträge sie im Tagebuch des Staunens gemacht haben (**Tgb**, höchstens 13) und wie viele Punkte sie in der Klausur erreicht haben (**Pkt**, höchstens 60). **SG** ist der Studiengang (T = Technik, W = Wirtschaft).

Nr	SG	Anw	Tgb	Pkt	Nr	SG	Anw	Tgb	Pkt
1	W	8	6	38	13	T	9	7	32
2	W	8	3	34	14	T	10	8	35
3	W	7	4	28	15	T	6	3	24
4	T	11	11	45	16	T	8	6	38
5	W	9	9	36	17	W	11	8	35
6	T	10	9	38	18	W	5	2	19
7	T	12	10	48	19	T	10	9	39
8	T	13	12	51	20	W	12	11	46
9	W	11	9	36	21	T	8	5	30
10	T	9	7	35	22	T	9	8	40
11	W	8	6	36	23	W	7	4	31
12	T	7	5	27	24	W	13	12	47

Die Studienleitung schreibt: „Wer regelmäßig Tagebuch führt (mindestens 8 Einträge), erreicht deutlich mehr Punkte. Das Tagebuch des Staunens verbessert also den Lernerfolg."

(a) Formulieren Sie die *deskriptiven Befunde*: Mittelwerte der Punkte in den Gruppen mit mindestens 8 und mit weniger als 8 Einträgen; wenn möglich auch der Zusammenhang zwischen Tgb und Pkt.

(b) Formulieren Sie *zwei konkurrierende Interpretationen* dieser Befunde. Welche Rolle spielt Anw?

(c) Welche *Zusatzdaten* oder welches andere Design würde zwischen Ihren Interpretationen entscheiden?

(d) Notieren Sie mindestens fünf Entscheidungen, die man bei der Auswertung anders hätte treffen können (Weggabelungen).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 10**

Übungsblatt B: Zufallstreffer und Selbstbezug

Name: _____ Datum: _____

Aufgabe 2: Zufallstreffer berechnen

in der Stunde, Einzelarbeit

Berechnen Sie die Wahrscheinlichkeit, bei m unabhängigen Tests mindestens einen Zufallstreffer zu erhalten, für zwei Schwellen.

m	1	3	5	10	20	100
$\alpha = 0{,}05$						
$\alpha = 0{,}005$						

Bei wie vielen Tests ist ein Zufallstreffer mit $\alpha = 0{,}05$ wahrscheinlicher als keiner? _____

Aufgabe 3: Reflexion zum Semesterprojekt

Hausaufgabe

Prüfen Sie Ihre bisherigen Ergebnisse: Haben Sie Ergebnisse gesucht, die Ihre Hypothese *bestätigen*? Welche Befunde könnten Ihre Hypothese *herausfordern*? Nennen Sie mindestens eine Weggabelung Ihrer eigenen Auswertung und legen Sie fest, wie Sie sich dort entscheiden – bevor Sie weitere Daten ansehen.

Aufgabe 4: Tagebuch des Staunens

Hausaufgabe

Beschreiben Sie eine Entscheidung, die sich frei anfühlte und es vielleicht nicht war. Was hat sie strukturiert?

Erwartungshorizont

Aufgabe 1 (Werte mit Python nachgerechnet). (a) Alle 24: Pkt Mittelwert 36,17 ($s = 7{,}72$, Median 36, Spannweite 19–51); Tgb Mittelwert 7,25 ($s = 2{,}91$); Anw Mittelwert 9,21 ($s = 2{,}15$). Mindestens 8 Einträge ($n = 12$): Pkt Mittelwert 41,33 ($s = 5{,}73$, Median 39,5); weniger als 8 ($n = 12$): 31,00 ($s = 5{,}78$, Median 31,5). Differenz 10,3 Punkte, Cohens $d \approx 1{,}80$; t-Test $p \approx 0{,}0002$. Korrelation Tgb–Pkt $r = 0{,}89$. Aber auch Anw–Pkt $r = 0{,}90$ und Tgb–Anw $r = 0{,}95$. Die Gruppe mit mindestens 8 Einträgen war im Mittel an 10,92 Terminen anwesend, die andere an 7,50. (b) Interpretation 1: Das Tagebuch fördert das Lernen (kausale Lesart der Studienleitung). Interpretation 2: Eine Drittvariable wie Engagement oder Motivation führt sowohl zu mehr Anwesenheit und mehr Tagebucheinträgen als auch zu mehr Punkten; denkbar ist auch, dass Anwesenheit selbst wirkt und Tagebucheinträge vor allem bei Anwesenheit entstehen. Die Daten können beides nicht trennen: Unter den zehn Personen mit höchstens 8 Terminen hat niemand 8 oder mehr Einträge, unter den sieben mit mindestens 11 Terminen haben alle 8 oder mehr. Rechnet man die Anwesenheit heraus, sinkt der Zusammenhang Tgb–Pkt auf eine Partialkorrelati-

on von 0,29 – bei $n = 24$ und dieser Kollinearität kein belastbarer Wert. (c) Zufällige Zuteilung zum Tagebuch (Experiment); Vorleistungen (z. B. Noten vor dem Kurs); Lernzeit außerhalb des Kurses; Inhalte der Tagebucheinträge (qualitativ, LE 9); Interviews zur Nutzung (Triangulation). Die Zeitfolge klären: Kamen die Einträge vor den Lernfortschritten? (d) Grenze der Tagebuchgruppen (8, 10, Median, kontinuierlich); Punkte oder nur „bestanden"; Ausschluss von Nr. 18 (niedrigster Wert); Teilgruppe nach Studiengang (in beiden Studiengängen ist der Unterschied vorhanden: T 42,29 gegen 31,00, W 40,00 gegen 31,00); Kontrolle für Anwesenheit ja/nein; Wahl des Tests; einseitig oder zweiseitig. Wer fünf Gabelungen mit je zwei Optionen hat, hat bereits $2^5 = 32$ mögliche Auswertungen.

Aufgabe 2. $\alpha = 0{,}05$: $m = 1$: 5,0 %; 3: 14,3 %; 5: 22,6 %; 10: 40,1 %; 20: 64,2 %; 100: 99,4 %. $\alpha = 0{,}005$: 0,5 %; 1,5 %; 2,5 %; 4,9 %; 9,5 %; 39,4 %. Ab $m = 14$ Tests ist bei $\alpha = 0{,}05$ ein Zufallstreffer wahrscheinlicher als keiner (51,2 %; bei $m = 13$ sind es 48,7 %).

Aufgabe 3. Erwartet ist eine konkrete, eigene Weggabelung mit einer vorab getroffenen Entscheidung, keine allgemeine Aussage.

11 Wissenschaftliches Schreiben

Bis hierher hat das Semester Fragen gestellt, Quellen geprüft, Daten erhoben und gedeutet. In dieser Einheit geht es darum, das alles so aufzuschreiben, dass andere es prüfen können. Der Einstieg ist ein Sprechtext, wie ihn Zauberkünstler verwenden: blumig, suggestiv, voller Behauptungen, die niemand belegt. Die Gruppe übersetzt ihn gemeinsam in Fachsprache und merkt dabei, dass diese Übersetzung Regeln folgt. Aus den Regeln entwickelt die Einheit die Grundlagen wissenschaftlichen Schreibens: den Aufbau eines Textes (IMRaD), den akademischen Stil, die Argumentationsstruktur, das Zitieren und die Grenze zum Plagiat. Den Abschluss bilden zwei Werkzeuge für die Seminararbeit: die Einleitung im Vierschritt und die Überarbeitung als Methode.

Vorbereitung vor der Stunde: Patter-Umbau in Fachsprache

Eine Woche vorher

- ☐ Einen Seileffekt auswählen, bei dem ein kurzes Seil sichtbar länger wird (handelsübliche Seil-Effekte aus dem Zauberfachhandel). Methode und Einstudierung nach der Anleitung des Herstellers bzw. der Standardliteratur; hier bewusst nicht beschrieben.
- ☐ Den Effekt mindestens fünfmal mit dem Sprechtext unten proben, davon einmal vor einer Testperson. Der Sprechtext ist absichtlich übertrieben; er soll ernst, aber nicht ironisch vorgetragen werden, sonst nimmt die Gruppe die Analyse vorweg.
- ☐ Den Ausgangs-Patter (Abschnitt 11.1) auf eine Folie legen. Auf dem Übungsblatt steht er bewusst nicht: Teil A liegt schon vor der Vorführung aus und enthält zu Aufgabe 1 nur Auftrag und Tabelle.
- ☐ Die Studierenden per Mail bitten, den aktuellen Stand ihrer Seminararbeit (Forschungsfrage, Gliederung, Literaturliste aus LE 3) mitzubringen. Ohne diesen Stand ist die Einleitungsübung kaum möglich.

Handout und Übungsblatt

- ☐ Handout „Wissenschaftliches Schreiben" sowie Übungsblatt LE 11 Teil A und Teil B je einmal pro Person kopieren (Druckvorlage `handouts.pdf`, Seiten zu LE 11). Teil A (Aufgaben 1–4, alles für die Stunde) ist länger als üblich; doppelseitig drucken. Teil B (Plagiats-Grenzfälle, Tagebuch) wird am Ende der Stunde ausgeteilt.
- ☐ Für den Patter-Umbau je Kleingruppe ein A3-Blatt mit zwei Spalten *Sprechtext* – *Fachsprache* und einer schmalen dritten Spalte *Regel*.
- ☐ Den schlechten Absatz (Aufgabe 2) zusätzlich je Gruppe einmal in großer Schrift (A3) ausdrucken, damit die Gruppe darin markieren kann.
- ☐ Zwei Farben Marker je Gruppe: Rot für Runde 1 (Inhalt), Blau für Runde 2 (Sprache und Form).

Am Tag selbst

- ☐ Seil griffbereit, aber verdeckt; die Einheit beginnt mit der Vorführung, nicht mit der Begrüßung.
- ☐ Tafel in zwei Felder teilen: links „Was sagt der Text?", rechts „Was wissen wir tatsächlich?". Rechts entstehen die Transformationsregeln.
- ☐ Uhr sichtbar stellen: Die Überarbeitungsübung hat zwei Runden von je zehn Minuten, die strikt getrennt bleiben sollen.

Risiken und Plan B. Misslingt der Effekt, hilft der Satz aus dem Skript-Gerüst des Buchs: „Genau deshalb ist es ein Experiment." Für diese Einheit ist der Trick ohnehin nur Anlass; der Umbau funktioniert auch, wenn der Text nur vorgelesen wird. Wer fragt, wie das Seil wächst, bekommt die Gegenfrage, die zur Übung führt: „Was genau haben Sie gesehen – und was davon können Sie belegen?" Die Methode wird nicht verraten (vgl. LE 13).

Ablauf der Doppelstunde (90 Min.)

0–10 · Staunmoment. Vorführung mit dem blumigen Sprechtext. Danach liegt der Text auf der Folie; die Gruppe übersetzt ihn Satz für Satz in Fachsprache (Übungsblatt Teil A, Aufgabe 1). Die Regeln, nach denen sie das tut, werden rechts an der Tafel gesammelt.

10–40 · Theorie-Input. IMRaD und Varianten; akademischer Stil und häufige Stilfehler; Argumentationsstruktur (These – Beleg – Schluss); Begriffspräzision am Beispiel NLP → evidenzbasiert; Zitieren; Plagiat, Paraphrase, Zitat.

40–65 · Überarbeitungsübung. Ein bewusst schlechter Absatz wird in zwei Runden überarbeitet: erst inhaltlich, dann sprachlich-formal (Übungsblatt Teil A, Aufgabe 2).

65–85 · Eigene Einleitung. Studierende schreiben die Einleitung ihrer Seminararbeit nach dem Vierschritt Thema – Lücke – Frage – Aufbau (Aufgabe 3).

85–90 · Peer-Blick. Partner-Feedback nach festem Raster (Aufgabe 4); Hinweis auf den Überarbeitungsprozess als Methode; Übungsblatt Teil B (Hausaufgaben) austeilen.

11.1 Staunmoment: Das wachsende Seil

★ Staunmoment: Patter-Umbau

Ein kurzes Seil, ein Sprechtext – und am Ende ist das Seil deutlich länger.

Hören Sie genau zu. Danach bekommen Sie den Text, und wir machen daraus gemeinsam einen wissenschaftlichen Bericht.

Der folgende Sprechtext ist für diese Einheit geschrieben. Er sammelt absichtlich die typischen Mittel eines Zauber-Patters: eine erfundene Herkunftsgeschichte, vage Mengenangaben, eine unbelegte Ursache, einen Appell an das Gefühl und eine Immunisierung gegen Zweifel.

Der Sprechtext (1/2)

> „Dieses kleine Seil hat mir ein alter Seemann in Lissabon geschenkt. Er sagte, es habe ein Gedächtnis: Es erinnere sich an jede Länge, die es je hatte. Sehen Sie, im Moment ist es kaum länger als meine Hand. Aber wenn ich es behutsam durch die Finger gleiten lasse und ihm Zeit gebe, dann erinnert es sich. Spüren Sie das?“

Der Sprechtext (2/2)

> „Es wächst, Zentimeter um Zentimeter, als würde es atmen. Kein Mensch kann erklären, woher die Länge kommt; selbst die Wissenschaft steht davor und staunt. Vielleicht ist es die Energie dieses Raumes, vielleicht die Kraft Ihrer Aufmerksamkeit. Eines ist sicher: Je mehr Sie daran glauben, desto länger wird es. Und jetzt schauen Sie – so lang wie ein Arm, und es hört nicht auf zu wachsen!“

Ihr Auftrag: übersetzen Sie

- Satz für Satz: Was *behauptet* der Text?
- Was davon haben Sie *beobachtet*, was nur gehört?
- Wie hieße der Satz in einem Beobachtungsbericht?
- Notieren Sie zu jeder Änderung die *Regel*, nach der Sie vorgegangen sind

Nach etwa fünf Minuten liegen an der Tafel die ersten Übersetzungen. Eine mögliche Zielfassung, die die Lehrperson am Ende zeigt, lautet:

Eine mögliche Zielfassung

> Der Vortragende zeigte ein weißes Seil, dessen sichtbare Länge zu Beginn auf etwa 15 cm geschätzt wurde. Er ließ es etwa 30 s lang durch beide Hände laufen; danach war ein Seilstück von geschätzt 70 cm sichtbar. Gemessen wurde nicht; die Werte beruhen auf Schätzungen aus etwa 5 m Abstand. Ob die Materiallänge oder nur die sichtbare Länge zugenommen hat, lässt sich aus diesen Beobachtungen nicht entscheiden. Die Herkunft des Seils ist nicht belegt und für den Befund ohne Belang. Die vom Vortragenden genannten Ursachen („Energie des Raumes“, Aufmerksamkeit) wurden nicht geprüft.

Hinweis für Lehrende

Die Zahlen der Zielfassung sind Beispielwerte; die Gruppe soll die *eigenen* Schätzungen eintragen und merkt dabei, wie unterschiedlich sie ausfallen. Das ist eine Brücke zu LE 9 (Intersubjektivität). Der wichtigste Satz ist der über sichtbare Länge und Materiallänge: Er trennt die Messgröße vom Konstrukt (LE 2) und deutet nur eine Richtung an, ohne die Methode zu verraten. Das Buch nennt in der Praxis-Werkstatt eine Fach-Variante („Durch Zellteilung verlängert sich der DNA-Strang“); sie zeigt den Registerwechsel, ist aber fachlich ungenau, denn bei der Zellteilung wird die DNA verdoppelt, nicht verlängert. Wenn Biologie-Studierende im Raum sind, lohnt der Hinweis: Fachsprache muss auch fachlich stimmen.

11.2 Vom Patter zur Fachsprache: die Transformationsregeln

Der Patter-Umbau zeigt, dass wissenschaftliche Sprache keine Frage des Talents ist. Sie folgt Regeln, die man benennen und üben kann. Im Buch geschieht dasselbe mit Begriffen aus dem Neuro-Linguistischen Programmieren (NLP): Wo ein suggestiver Sammelbegriff wie „Anker" mehrere getrennte Phänomene vermischt, setzt das Buch je einen Fachbegriff mit Forschungsgrundlage ein; die Evidenzlage des NLP selbst ist dünn (Witkowski 2010). Präzision ist dabei eine Form epistemischer Ehrlichkeit. Sie zwingt dazu, Behauptung und Beleg zu trennen und Unsicherheit auszuweisen, statt sie rhetorisch zu überspielen.

Sieben Regeln des Umbaus

Patter	Fachsprache
Erzählung („ein Seemann sagte")	Beobachtung: wer, was, wann, unter welchen Bedingungen
vage Menge („Zentimeter um Zentimeter")	Wert mit Einheit und Messverfahren
Behauptung ohne Beleg	Beleg angeben oder als ungeprüft kennzeichnen
Ursache („Energie des Raumes")	Hypothese mit Prüfbedingung

Sieben Regeln des Umbaus (Forts.)

Patter	Fachsprache
Gefühlsappell („Spüren Sie das?")	Wirkung als Befund beschreiben („Mehrere Zuschauende reagierten mit …")
Absolutheit („kein Mensch", „sicher")	Geltungsbereich und Unsicherheit angeben
Immunisierung („wenn Sie glauben")	Bedingung nennen, unter der die Aussage scheitert

- Leitfrage für jeden Satz: *Woher weiß ich das?*

Begriffe ersetzen: das NLP-Beispiel

statt (NLP)	besser (evidenzbasiert)
Anker setzen	Retrieval Cue (Godden und Baddeley 1975); Implementation Intention (Gollwitzer und Sheeran 2006)
Reframing	Cognitive Reappraisal (Gross 1998)
Rapport aufbauen	psychologische Sicherheit (Edmondson 1999)

- ein Sammelbegriff verdeckt, *welches* Phänomen gemeint ist
- ein Fachbegriff verweist auf Befunde, die man nachlesen kann

Präzision

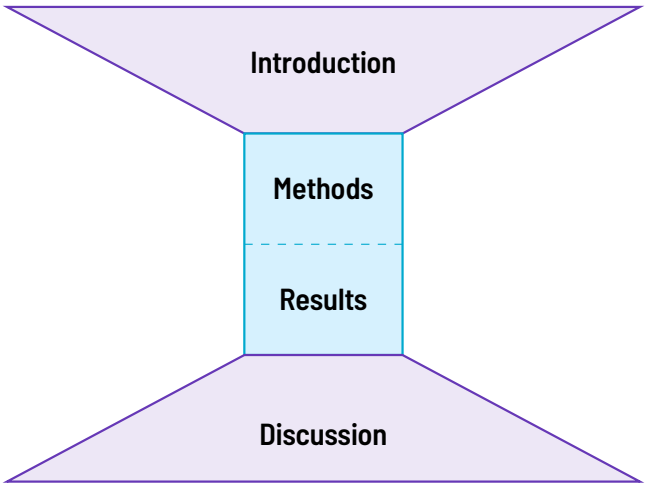
Präzise schreiben heißt nicht, kompliziert zu schreiben. Es heißt, bei jedem Satz angeben zu können, woher man ihn weiß – und kenntlich zu machen, wo man es nicht weiß.

11.3 Der Aufbau wissenschaftlicher Texte

Empirische Fachartikel folgen in den meisten Natur-, Ingenieur- und Sozialwissenschaften dem Schema *IMRaD*: Introduction, Methods, Results and Discussion. Das Schema ist mehr als eine Konvention. Es trennt die Teile eines Forschungsberichts nach ihrer Funktion: Was wollte ich wissen? Wie habe ich es geprüft? Was kam heraus? Was bedeutet

das? Wer Ergebnis und Deutung in getrennten Kapiteln führt, kann die Deutung nicht unbemerkt als Ergebnis ausgeben. Die Publikationsrichtlinien der American Psychological Association legen dieses Schema für empirische Berichte zugrunde (American Psychological Association 2020).

IMRaD: vier Fragen, vier Teile



Was wollte ich wissen? *(allgemein → speziell)*

Wie habe ich es geprüft?

Was kam heraus? *(ohne Deutung)*

Was bedeutet das? *(speziell → allgemein)*

Varianten

- **empirische Seminararbeit**: IMRaD, ergänzt um Abstract, Fazit, Literaturverzeichnis, Anhang (Material, Daten)
- **Literatur- oder Theoriearbeit**: Einleitung – thematisch gegliederter Hauptteil – Diskussion – Fazit
- **technischer Bericht**: Anforderungen – Entwurf – Umsetzung – Test – Bewertung
- gemeinsam ist allen: Frage vorne, Antwort hinten, der Weg dazwischen nachvollziehbar

Wohin gehört was?

- „Wir befragten 24 Studierende." → Methode
- „17 von 24 wählten Tür B." → Ergebnis
- „Das deutet darauf hin, dass …" → Diskussion
- „Bisher ist unklar, ob …" → Einleitung
- häufigster Fehler: Deutung im Ergebnisteil

Die Zahlen in diesen Beispielsätzen sind erfunden und dienen nur der Zuordnung.

11.4 Akademischer Stil

Akademischer Stil wird oft mit Unverständlichkeit verwechselt. Die drei Anforderungen, auf die es ankommt, sind schlicht: *Präzision* (jeder Begriff hat eine Bedeutung, und zwar dieselbe im ganzen Text), *Sachlichkeit* (die Aussage stützt sich auf Belege, nicht auf Begeisterung) und *Transparenz* (Leserinnen und Leser können sehen, woher eine Aussage stammt und wie sicher sie ist). Wer mit Fachvokabular Eindruck machen will, erreicht oft das Gegenteil: In einer Reihe von Experimenten beurteilten Versuchspersonen die Verfasser von Texten mit unnötig komplizierten Wörtern als weniger intelligent als die Verfasser einfacherer Fassungen desselben Inhalts (Oppenheimer 2006).

Drei Anforderungen

- **Präzision**: ein Begriff, eine Bedeutung – im ganzen Text

- **Sachlichkeit**: Belege statt Begeisterung
- **Transparenz**: Herkunft und Sicherheit jeder Aussage sind erkennbar
- einfach schreiben ist erlaubt: Imponiervokabular wirkt eher *weniger* kompetent (Oppenheimer 2006)

Häufige Stilfehler

Fehler	Beispiel
Nominalstil	„Die Durchführung der Befragung erfolgte …“
Füllwörter	„eigentlich“, „quasi“, „ja“, „total“
Absolutheit	„Studien beweisen, dass …“
Synonymwechsel	erst „Staunen“, dann „Verblüffung“, dann „Wonder“
unklarer Bezug	„Dies zeigt, dass …“ (was genau?)

Woher die Fehler kommen

- **inhaltliche Unsicherheit**: wer nicht weiß, was er behauptet, schreibt vage
- **Imitation**: man kopiert den Klang von Fachtexten statt ihrer Logik
- **kein Leserbild**: man schreibt für sich, nicht für jemanden, der prüfen will
- Konsequenz: Stilprobleme sind oft Denkprobleme; man löst sie in Runde 1 der Überarbeitung

Unsicherheit richtig dosieren

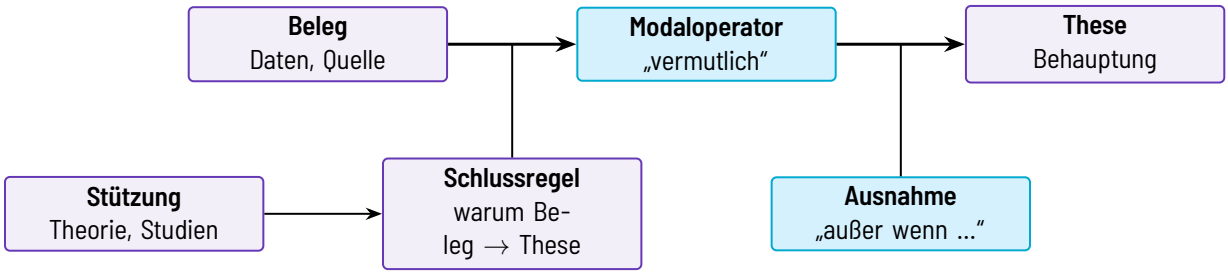
- zu sicher: „Staunen verbessert das Lernen.“
- zu vorsichtig: „Es könnte möglicherweise eventuell sein, dass …“
- angemessen: „In der vorliegenden Stichprobe erinnerten Teilnehmende nach dem Staunmoment mehr Begriffe; ob der Effekt anhält, wurde nicht geprüft.“
- Regel: so sicher formulieren, wie die Daten es tragen

Auch der letzte Beispielsatz ist konstruiert und berichtet keinen realen Befund.

11.5 Argumentieren: These, Beleg, Schluss

Ein wissenschaftlicher Text ist eine Kette von Argumenten. Die Grundform hat drei Teile: eine *These* (was behauptet wird), einen *Beleg* (Daten, Quellen, Beobachtungen) und einen *Schluss*, der zeigt, warum der Beleg die These stützt. Stephen Toulmin hat dieses Schema verfeinert. Zwischen Beleg und These steht bei ihm eine *Schlussregel* (warrant), die ihrerseits gestützt werden kann (backing); die These wird durch einen *Modaloperator* eingeschränkt („vermutlich“, „in dieser Stichprobe“) und nennt die *Ausnahmebedingungen*, unter denen sie nicht gilt (Toulmin 1958). Die letzten beiden Elemente sind genau das, was dem Patter fehlte.

Das Toulmin-Schema



Der Absatz als Argument

- **ein** Absatz = **ein** Gedanke
- erster Satz: die These des Absatzes (Themensatz)
- dann: Beleg mit Quelle, Erläuterung, ggf. Einschränkung
- letzter Satz: was folgt daraus für die Frage der Arbeit?
- Test: Lesen Sie nur die ersten Sätze aller Absätze. Ergibt sich der rote Faden?

11.6 Zitieren

Zitieren erfüllt drei Aufgaben: Es *belegt* eine Aussage, es *würdigt* die Arbeit anderer, und es macht die Quelle *auffindbar*. Welche Form man wählt, ist zweitrangig, solange sie vollständig und im ganzen Text einheitlich ist. Verbreitet sind drei Familien: das Autor-Jahr-System (z. B. APA, 7. Auflage (American Psychological Association 2020); auch dieses Skript zitiert so), das numerische System (in Technik und Medizin verbreitet, z. B. IEEE oder Vancouver) und das Fußnotensystem (Geisteswissenschaften, z. B. Chicago-Notes). Maßgeblich ist, was Ihr Fach oder Ihre Prüferin vorgibt. Literaturverwaltungsprogramme wie Zotero, Citavi oder JabRef nehmen die Formatierung ab, die Verantwortung für die Richtigkeit der Angaben aber nicht.

Wozu zitieren?

- **belegen**: Woher weiß ich das?
- **würdigen**: Wessen Arbeit nutze ich?
- **auffindbar machen**: Wo kann man nachprüfen?
- Zitate sind die Fußspuren im Vertrauensspiel der Wissenschaft (*WuZ-Buch*, Kap. „Offenheit und Geheimnis")

Drei Zitierfamilien

System	im Text	verbreitet in
Autor-Jahr	(Toulmin, 1958, S. xx)	Psychologie, Sozial-, Wirtschaftswiss.
numerisch	[12]	Technik, Informatik, Medizin
Fußnote	[12] mit Vollangabe unten	Geschichte, Jura, Philosophie

- einheitlich bleiben – und die Fachnorm erfragen

Zitat und Paraphrase

- **direktes Zitat**: wörtlich, in Anführungszeichen, mit Seitenangabe; sparsam (Definitionen, prägnante Stellen)
- **Paraphrase**: Gedanke in eigenen Worten *und* eigener Satzstruktur – braucht trotzdem einen Beleg
- **Sekundärzitat** („zit. nach"): nur, wenn das Original nicht erreichbar ist
- Allgemeinwissen des Fachs braucht keinen Beleg – im Zweifel belegen

11.7 Plagiat

Ein Plagiat liegt vor, wenn fremde Texte, Daten oder Ideen ohne ausreichende Kennzeichnung als eigene ausgegeben werden. Die Absicht ist für die Feststellung nicht entscheidend; auch nachlässiges Plagiieren ist Plagiieren. Zusammen mit dem Erfinden und dem Verfälschen von Daten gehört das Plagiat zu den drei Kerntatbeständen wissenschaftlichen Fehlverhaltens (Fabrication, Falsification, Plagiarism, kurz FFP), die in LE 13 ausführlich behandelt werden. Für Prüfungsleistungen regelt die jeweilige Prüfungsordnung die Folgen; in der Regel wird die Arbeit als Täuschungsversuch gewertet. Ob und wie Texte aus KI-Werkzeugen verwendet und gekennzeichnet werden dürfen, legen Hochschule und Prüfende fest; das sollte vor Beginn der Arbeit geklärt sein.

Definition

Definition 11.1 Ein **Plagiat** ist die Übernahme fremder Texte, Daten, Abbildungen oder Ideen ohne ausreichende Kennzeichnung, sodass sie als eigene Leistung erscheinen.

- entscheidend ist die *Kennzeichnung*, nicht die Absicht
- Plagiat ist eins von drei Kerndelikten (FFP → LE 13)

Formen des Plagiats

- **Vollplagiat**: ganzer Text übernommen
- **Copy & Paste**: Passagen wörtlich ohne Anführungszeichen, auch wenn die Quelle irgendwo genannt ist
- **verschleiernde Paraphrase**: Wörter ausgetauscht, Struktur und Gedanke übernommen, kein Beleg
- **Übersetzungsplagiat**: fremdsprachige Quelle übersetzt, nicht belegt
- **Selbstplagiat**: eigene, bereits bewertete Arbeit erneut eingereicht, ohne Hinweis

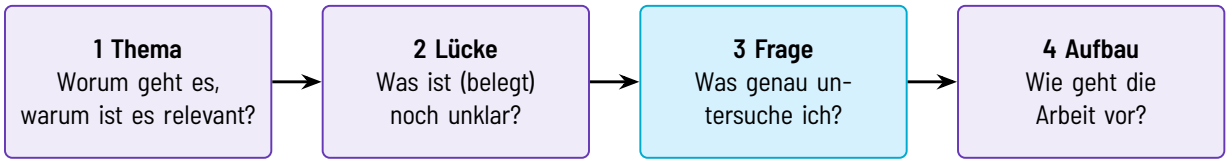
Paraphrase oder Plagiat?

- Test 1: Könnte ich den Gedanken erklären, *ohne* auf die Quelle zu schauen?
- Test 2: Ist die Satzstruktur meine eigene?
- Test 3: Steht der Beleg dort, wo der Gedanke steht – nicht nur im Literaturverzeichnis?
- dreimal „ja" → Paraphrase; sonst nachbessern

11.8 Einleitung und Fazit als Rahmen

Einleitung und Fazit sind die Teile, die am häufigsten gelesen werden, oft als einzige. Für die Einleitung hat John Swales aus der Analyse vieler Fachartikel ein Muster aus drei „Zügen" herausgearbeitet: das Forschungsfeld abstecken, eine Lücke darin aufzeigen und die eigene Arbeit in diese Lücke stellen (Swales 1990). Der Vierschritt dieser Einheit ist eine Lehrfassung dieses Musters. Das Fazit spiegelt die Einleitung: Es beantwortet die Frage, die dort gestellt wurde, nennt die Grenzen der Antwort und zeigt, welche Frage offen bleibt.

Die Einleitung im Vierschritt



- Schritte 1–3: Feld abstecken, Lücke zeigen, Lücke besetzen (Swales 1990)
- die Lücke braucht Belege – sonst ist sie eine Behauptung

Das Fazit spiegelt die Einleitung

- Frage aus der Einleitung wörtlich aufgreifen
- Antwort in zwei, drei Sätzen – ohne neue Daten
- Grenzen der Antwort (Stichprobe, Methode, Geltungsbereich)
- was offen bleibt: die nächste Frage

11.9 Überarbeiten als Methode

Kaum ein guter Fachtext entsteht in einem Durchgang. Erfahrene Schreibende trennen das Schreiben vom Überarbeiten, und sie überarbeiten in Runden mit unterschiedlichem Fokus. Die erste Runde fragt nach dem Inhalt: Stimmt das Argument, tragen die Belege, ist die Reihenfolge sinnvoll? Erst die zweite Runde gilt der Sprache und der Form. Wer beides vermischt, poliert Sätze, die er danach streicht. Die Überarbeitung ist damit das schriftliche Gegenstück zur Methode: Ein erster Entwurf ist eine Hypothese über den Text, und die Überarbeitung prüft sie.

Zwei Runden

Runde 1: Inhalt	Runde 2: Sprache und Form
Was ist die These?	Füllwörter und Absolutheiten streichen
Welche Belege fehlen?	Nominalstil auflösen
Was gehört nicht hierher?	Begriffe vereinheitlichen
Stimmt die Reihenfolge?	Zitate und Belege formal prüfen

- erst Runde 1 abschließen, dann Runde 2 beginnen

Werkzeuge

- **Rückwärtsgliederung**: zu jedem Absatz einen Satz an den Rand schreiben – ergibt die Satzfolge ein Argument?
- **Abstand**: mindestens eine Nacht zwischen Schreiben und Überarbeiten
- **laut lesen**: wo man stolpert, stolpert auch der Leser
- **fremde Augen**: Peer-Feedback nach festem Raster

Merke

Ein erster Entwurf ist eine Hypothese über den eigenen Text. Die Überarbeitung prüft sie: erst den Inhalt, dann die Sprache.

11.10 Übung in der Stunde

Überarbeitungsübung (Kleingruppen, 25 Min.)

- Absatz auf dem Übungsblatt Teil A (Aufgabe 2) lesen
- **Runde 1** (rot, 10 Min.): Thesen, fehlende Belege, Überflüssiges markieren; neu ordnen
- **Runde 2** (blau, 10 Min.): Sprache und Form
- 5 Min.: Vergleich mit einer Nachbargruppe

Ihre Einleitung (Einzelarbeit, 20 Min.)

- Vierschritt: Thema – Lücke – Frage – Aufbau
- Vorlage auf dem Übungsblatt (Aufgabe 3); heute ein Entwurf, als Hausaufgabe ca. 400 Wörter
- danach 5 Min. Partner-Feedback nach Raster (Aufgabe 4)

Hinweis für Lehrende

Bei der Überarbeitungsübung neigen Gruppen dazu, sofort Sätze schöner zu machen. Nach fünf Minuten von Runde 1 kurz durch die Gruppen gehen und fragen: „Was ist die These dieses Absatzes?“ Die meisten Gruppen stellen fest, dass der Absatz mehrere Thesen hat und für keine einen Beleg. Der Erwartungshorizont mit einer möglichen Endfassung steht am Ende des Übungsblatts Teil B. Beim Peer-Feedback auf Ich-Botschaften achten („Mir war nach Schritt 2 nicht klar, …“) und darauf, dass Feedback beschreibt statt bewertet.

11.11 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- einen wissenschaftlichen Text nach IMRaD oder einer passenden Variante gliedern
- Alltagssprache nach benennbaren Regeln in Fachsprache übertragen
- ein Argument aus These, Beleg und Schluss aufbauen
- Plagiat, Paraphrase und korrektes Zitat unterscheiden
- einen Text in zwei Runden überarbeiten

Bis zur nächsten Woche

- **Überarbeitung** des Absatzes abschließen (Aufgabe 2)
- **Einleitung** Ihrer Seminararbeit, ca. 400 Wörter, nach dem Vierschritt (Aufgabe 3)
- **Plagiats-Grenzfälle** einordnen (Teil B, Aufgabe 5)
- **Tagebuch des Staunens**: Welcher Ihrer Sätze hielt der Frage „Woher weiß ich das?“ nicht stand?
- für LE 12: 5-Minuten-Präsentation zum Semesterprojekt vorbereiten

Handout: Wissenschaftliches Schreiben

Worum es heute ging. Ein Zauber-Sprechtext ließ ein Seil „wachsen" – mit einem Seemann, einer „Energie des Raumes" und dem Satz „Je mehr Sie glauben, desto länger wird es". Beim Übersetzen in Fachsprache blieb davon wenig übrig: geschätzte Längen, eine offene Frage und der Hinweis, was nicht geprüft wurde. Diese Übersetzung folgt Regeln. Wissenschaftliches Schreiben lässt sich lernen.

Kernbegriffe

IMRaD Introduction, Methods, Results, Discussion: Gliederung empirischer Berichte nach Funktion; Ergebnis und Deutung stehen getrennt.

These – Beleg – Schluss Grundform des Arguments; nach Toulmin ergänzt um Schlussregel, Einschränkung und Ausnahme (Toulmin 1958).

Paraphrase fremder Gedanke in eigenen Worten und eigener Satzstruktur, *mit* Beleg.

Plagiat fremde Texte, Daten oder Ideen ohne ausreichende Kennzeichnung; die Absicht spielt keine Rolle.

Vierschritt Einleitung aus Thema – Lücke – Frage – Aufbau, nach dem Muster von Swales (1990).

Vom Patter zur Fachsprache

statt …	schreiben Sie …
Erzählung, Anekdote	Beobachtung mit Bedingungen
vage Menge („viel", „total")	Wert mit Einheit und Messverfahren
„Studien zeigen"	die Studie, mit Beleg
Ursache als Gewissheit	Hypothese mit Prüfbedingung
„immer", „jeder", „sicher"	Geltungsbereich und Unsicherheit
Sammelbegriff („Anker")	Fachbegriff mit Forschungsgrundlage

Überarbeiten in zwei Runden. Runde 1 (Inhalt): These? Belege? Überflüssiges? Reihenfolge? Runde 2 (Sprache und Form): Füllwörter, Nominalstil, einheitliche Begriffe, Zitierform. Erst Runde 1 abschließen.

Merke

Präzise schreiben heißt, bei jedem Satz angeben zu können, woher man ihn weiß, und kenntlich zu machen, wo man es nicht weiß.

Zum Weiterlesen: American Psychological Association (2020), Kap. 3 (Aufbau empirischer Berichte) und Kap. 8–9 (Zitieren); Oppenheimer (2006) zur Wirkung von Imponiervokabular.

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 11**

Übungsblatt A: Präzision und Struktur

Name: _____ Datum: _____

Aufgabe 1: Patter-Umbau

in der Stunde, Kleingruppe, 10 Min.

Den Sprechtext hören Sie gleich bei einer Vorführung; danach steht er auf der Folie. Übersetzen Sie ihn Satz für Satz in die Sprache eines Beobachtungsberichts. Notieren Sie zu jeder Änderung die Regel, nach der Sie vorgegangen sind, in einem Halbsatz (etwa „Beobachtung von Deutung trennen").

Sprechtext (Satz)	Fachsprache	Regel

Aufgabe 2: Ein schlechter Absatz, zwei Runden

in der Stunde, Kleingruppe, 25 Min.; Abschluss als Hausaufgabe

Der folgende Absatz ist *konstruiert*, um möglichst viele Fehler zu enthalten. Er stammt aus keiner realen Arbeit.

> „Heutzutage weiß ja eigentlich jeder, dass Zaubertricks im Unterricht total viel bringen. Die Schüler passen einfach viel besser auf und merken sich alles, das sieht man ja schon, wenn man selbst mal in so einer Stunde war. Studien haben das auch bewiesen. Manche Lehrer sind aber dagegen, weil sie denken, es ist nur Show, was aber eigentlich nicht stimmt, weil Staunen ja nachweislich das Gehirn aktiviert. Man sollte also in jedem Fach zaubern. Außerdem macht es Spaß, und Spaß ist beim Lernen das Wichtigste. Natürlich klappt nicht jeder Trick immer, aber das ist ja egal. Ein Freund von mir ist Lehrer, und der sagt auch, dass seine Klasse seitdem viel besser geworden ist."

1. **Runde 1 – Inhalt** (rot): Welche Thesen stecken im Absatz? Welche davon bräuchten einen Beleg? Was gehört nicht in einen wissenschaftlichen Text? Legen Sie fest, welche *eine* These der überarbeitete Absatz vertreten soll, und ordnen Sie die Sätze neu.
2. **Runde 2 – Sprache und Form** (blau): Streichen Sie Füllwörter und Absolutheiten, vereinheitlichen Sie Begriffe, formulieren Sie die Unsicherheit angemessen. Setzen Sie mindestens zwei Belege aus der Literatur dieser Vorlesung ein.

Aufgabe 3: Einleitung im Vierschritt

in der Stunde Entwurf; Hausaufgabe ca. 400 Wörter

Schreiben Sie die Einleitung Ihrer Seminararbeit. Die Satzanfänge sind Vorschläge, keine Pflicht.

1 Thema	*„Wenn …, dann …“* – *„In … spielt … eine zentrale Rolle, weil …“*
2 Lücke	*„Untersucht wurde bisher vor allem … (Beleg). Offen ist dagegen, ob …“*
3 Frage	*„Diese Arbeit geht der Frage nach, ob/wie …“* – als echte Frage mit Fragezeichen
4 Aufbau	*„Kapitel 2 stellt … dar. Kapitel 3 beschreibt …“*

Aufgabe 4: Peer-Feedback zur Einleitung

in der Stunde, Partnerarbeit, 5 Min.

Lesen Sie die Einleitung Ihrer Partnerin oder Ihres Partners. Beschreiben Sie, statt zu bewerten („Mir war nach Satz 3 nicht klar, …“).

Kriterium	ja	teils	nein	Hinweis
Ich weiß nach dem ersten Absatz, worum es geht.				
Die Lücke ist benannt *und* belegt.				
Die Forschungsfrage steht als Frage da und ist beantwortbar.				
Der Aufbau der Arbeit wird genannt.				
Begriffe werden einheitlich verwendet.				

Ein Satz, der mir hängen geblieben ist: _____

Eine Frage, die ich an die Arbeit habe: _____

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 11**

Übungsblatt B: Belegen und Nachschärfen

Name: _____ Datum: _____

Aufgabe 5: Plagiat, Paraphrase oder korrektes Zitat?

Hausaufgabe

Die Quelle ist *fiktiv*: Berger, L. (2021). *Staunen im Hörsaal*. Auf Seite 42 steht:

> „Wer staunt, bemerkt eine Lücke im eigenen Wissen. Diese Lücke erzeugt Spannung, und Spannung sucht nach Auflösung. Lehrende können diese Spannung nutzen, wenn sie die Auflösung nicht sofort liefern."

Ordnen Sie jede Fassung ein: **Z** korrektes Zitat, **P** korrekte Paraphrase, **X** Plagiat, **G** Grenzfall (dann: wovon hängt es ab?).

	Fassung in einer Seminararbeit	**Z/P/X/G**
A	„Wer staunt, bemerkt eine Lücke im eigenen Wissen" (Berger, 2021, S. 42).	
B	Wer staunt, bemerkt eine Lücke im eigenen Wissen. Diese Lücke erzeugt Spannung (vgl. Berger, 2021).	
C	Staunen macht eine Wissenslücke bewusst; die entstehende Spannung können Lehrende nutzen, indem sie mit der Erklärung warten (Berger, 2021, S. 42).	
D	Wer sich wundert, merkt eine Lücke im eigenen Wissen. Diese Lücke ruft Spannung hervor, und Spannung strebt nach Lösung.	
E	Dass Neugier aus einer bemerkten Informationslücke entsteht, hat Loewenstein (1994) in einer Übersichtsarbeit begründet.	
F	Eine Studentin übernimmt einen eigenen Absatz aus einer bereits benoteten Hausarbeit eines anderen Kurses, ohne Hinweis.	
G	„Das Gehirn arbeitet als Vorhersagemaschine." – ohne Beleg, in einer Arbeit über Predictive Processing.	
H	Ein Student lässt Bergers Absatz von einem KI-Werkzeug umformulieren und fügt das Ergebnis ohne Beleg ein.	

Aufgabe 6: Tagebuch des Staunens

Hausaufgabe

Suchen Sie in einem eigenen Text (Seminararbeit, Essay aus LE 1) einen Satz, den Sie für sicher hielten und der der Frage „Woher weiß ich das?" nicht standhält. Notieren Sie ihn, die bessere Fassung und was Sie dabei überrascht hat.

Erwartungshorizont

Aufgabe 1: Mindestens fünf der sieben Regeln aus dem Skript sollten auftauchen. Gute Gruppen bemerken, dass der Satz „Je mehr Sie daran glauben …" eine Immunisierung ist: Wenn das Seil nicht wächst, hat man eben nicht genug geglaubt.
Aufgabe 2, Runde 1: Der Absatz enthält mindestens fünf Thesen (Zaubern fördert Aufmerksamkeit; fördert Behalten; ist bewiesen; Staunen aktiviert das Gehirn; Spaß ist das Wichtigste) und keinen einzigen Beleg; die Anekdote vom Freund ist kein Beleg, der Satz über misslingende Tricks gehört nicht zum Argument. Eine sinnvolle Entscheidung ist, nur die These „Zaubertricks können Lernen fördern" zu vertreten und den Gegeneinwand („nur Show") ernst zu nehmen. **Runde 2**, eine mögliche Endfassung: „Ob Zaubertricks im Unterricht das Lernen fördern, ist bislang wenig untersucht. Theoretisch ist ein Effekt plausibel: Neugier entsteht, wenn Lernende eine Lücke in ihrem Wissen bemerken (Loewenstein 1994), und in einem Experiment erinnerten Versuchspersonen die Antworten auf Wissensfragen besser, wenn die Fragen sie zuvor neugierig gemacht hatten (Gruber u. a. 2014). Ein Zaubertrick könnte eine solche Lücke erzeugen. Dem steht entgegen, dass eine mitreißende Darbietung die gefühlte Lern-

leistung erhöhen kann, ohne dass mehr gelernt wird (Naftulin u. a. 1973; Peer und Babad 2014). Ob Zaubertricks mehr bewirken als Begeisterung, müsste daher mit Lerntests geprüft werden, nicht mit Zufriedenheitsurteilen."
Aufgabe 3/4: Häufigster Mangel ist eine unbelegte Lücke („Dazu gibt es noch keine Forschung"); zweithäufigster eine Frage, die keine Frage ist („Diese Arbeit befasst sich mit …").
Aufgabe 5: A = Z. B = X (wörtliche Übernahme ohne Anführungszeichen; die Quellenangabe heilt das nicht). C = P. D = X (verschleiernde Paraphrase ohne Beleg). E = kein Bezug zu Berger, eigenständig belegt, also unproblematisch. F = G, in der Regel X: Ob Selbstplagiat vorliegt, regelt die Prüfungsordnung; ohne Hinweis und Absprache ist es unzulässig. G = G: In einer Arbeit über Predictive Processing ist der Satz Kernthese einer bestimmten Theorie und braucht einen Beleg (z. B. Clark (2016)). H = X: Das Werkzeug ändert nichts daran, dass Bergers Gedanke ohne Beleg übernommen wird; ob die KI-Nutzung zusätzlich zu kennzeichnen ist, regeln Hochschule und Prüfende.

12 Präsentation und Glaubwürdigkeit

Wer Forschungsergebnisse vorträgt, betreibt Überzeugungsarbeit, ob er will oder nicht. Diese Einheit beginnt mit zwei kurzen Vortragsausschnitten: Der eine wirkt überzeugend, der andere ist fachlich stärker. Die Gruppe sammelt, was den Eindruck macht, und trennt dabei Auftreten von Substanz. Das Werkzeug dafür liefert das Buch: Credibility Enhancing Displays (CREDS), also Handlungen und Signale, die Glaubwürdigkeit erzeugen. Die Einheit verwendet sie als Analyseinstrument und warnt zugleich vor ihnen, denn dieselben Signale erzeugen auch Scheinsicherheit. Danach geht es um das Handwerk: Dramaturgie eines Kurzvortrags, Foliengestaltung, Transparenz über Grenzen, Umgang mit Fragen, Poster. In der zweiten Hälfte halten die Studierenden ihre 5-Minuten-Präsentation zum Semesterprojekt.

Vorbereitung vor der Stunde: CRED-Strategien des Zauberkünstlers

Eine Woche vorher

- ☐ **Zwei Vortragsausschnitte auswählen** (je 2–3 Minuten). Kriterien: (a) Ausschnitt A wirkt überzeugend (flüssig, sicher, anschaulich), ist aber fachlich schwach: Er verallgemeinert, nennt keine Grenzen oder vertritt einen Befund, der sich später nicht bestätigt hat. (b) Ausschnitt B ist fachlich stärker (Daten, Einschränkungen, saubere Begriffe), wirkt aber weniger gewinnend. (c) Beide behandeln möglichst dasselbe oder ein verwandtes Thema, damit sich nur Auftreten und Substanz unterscheiden. (d) Sie selbst kennen den fachlichen Stand zu beiden Ausschnitten und haben Belege dafür bereit. (e) Niemand wird vorgeführt: Personen in öffentlicher, beruflicher Rolle, Analyse des Vortrags, nicht der Person.
- ☐ **Alternative ohne Rechtefragen:** beide Ausschnitte selbst aufnehmen, mit identischem Inhaltskern – einmal mit starker Performance und überzogenen Aussagen, einmal mit vorsichtigen Aussagen und Limitationen, aber flachem Vortrag. Das ist die Logik des Dr.-Fox-Experiments (Naftulin u. a. 1973) und zugleich ein sauberes Ein-Stimulus-Design (LE 7).
- ☐ **Rechtliches** (keine Rechtsberatung; im Zweifel die Rechtsabteilung der Hochschule fragen): Das Zitatrecht (§ 51 UrhG) deckt kurze Ausschnitte, wenn sie belegt und inhaltlich analysiert werden und die Quelle genannt wird. § 60a UrhG erlaubt für Lehrveranstaltungen die Nutzung von Teilen veröffentlichter Werke (bis 15 %) im Kreis der Teilnehmenden. Frei zugängliche Videos am besten direkt von der Originalplattform abspielen statt herunterladen und weiterverbreiten. Bei Videos unter Creative-Commons-Lizenz die Lizenzbedingungen prüfen (z. B. Namensnennung, keine Bearbeitung); Ausschnitte nicht in eine öffentlich zugängliche Folienfassung einbetten, sondern dort nur verlinken.
- ☐ Studierende erinnern: Präsentation höchstens 5 Minuten, Folien als PDF bis zum Vortag hochladen (ein Laptop für alle spart Wechselzeit).
- ☐ Zeitplan für die Präsentationsrunde festlegen (siehe Lehrhinweis in Abschnitt 12.9) und die Reihenfolge vorab bekanntgeben.

Handout und Übungsblatt

- ☐ Handout „Präsentation und Glaubwürdigkeit" sowie Übungsblatt LE 12 Teil A und Teil B je einmal pro Person kopieren. Teil A (Vergleichsbogen, Feedbackbogen) liegt zu Beginn aus; Teil B (Bewertungsraster, Folienkritik, Tagebuch) erst nach der Auflösung des Staunmoments austeilen, weil das Raster den Dr.-Fox-Effekt nennt.
- ☐ Feedbackbogen (Teil A, Aufgabe 2) in ausreichender Zahl: ein Bogen pro Person reicht für fünf Vorträge; bei mehr Vorträgen die Seite mit Aufgabe 2 zusätzlich kopieren.
- ☐ Bewertungsraster (Teil B, Aufgabe 3) für die Lehrperson: ein Exemplar pro Vortrag.
- ☐ Die drei Beispielfolien für die Folienkritik (Teil B, Aufgabe 4) zusätzlich als Folien bereitlegen, damit sie groß gezeigt werden können.

Am Tag selbst

- ☐ Beide Videos vorher am Hörsaalrechner testen (Ton!); Plan B: lokale Kopie für den Notfall nur, wenn die Rechte das erlauben.
- ☐ Gut sichtbare Uhr oder Timer für die Vortragenden; Signal bei 4:00 Minuten, Schluss bei 5:00.
- ☐ Tafel für den Vergleich vorbereiten: zwei Spalten *wirkt überzeugend, weil …* und *ist belastbar, weil …*.

Risiken und Plan B. Die Gruppe hält oft den Vortrag für fachlich stärker, der besser wirkt; das ist der erwünschte Befund und sollte nicht vorzeitig korrigiert werden. Erst die Bewertungen einsammeln, dann die Auflösung. Wenn Studierende aufgeregt sind: Die Präsentation ist ein Zwischenbericht, offene Punkte sind ausdrücklich erlaubt. Den Nocebo-Satz „Das ist für viele hier schwer" vermeiden.

Ablauf der Doppelstunde (90 Min.)

0–15 · Staunmoment/Analyse. Zwei Vortragsausschnitte im Vergleich. Alle bewerten jeden Ausschnitt auf zwei Skalen (*überzeugend*, *fachlich belastbar*) und notieren, woran sie das festmachen. Danach Auflösung und Sammlung an der Tafel: Was ist Performance, was Substanz? (Übungsblatt Teil A, Aufgabe 1.) Danach Übungsblatt Teil B austeilen; das Bewertungsraster (Aufgabe 3) kurz zeigen.

15–40 · Theorie-Input. CREDS als Analysewerkzeug und ihre Scheinsicherheit; Vortragsdramaturgie und Goldener Ablauf; Foliengestaltung (Signal-Rausch, Dual Coding, Arbeitsgedächtnis); Transparenz über Limitationen und das Nocebo der Lehre; Umgang mit Fragen; Poster.

40–75 · Kurzpräsentationen. 5-Minuten-Vorträge zum Semesterprojekt mit Feedback nach dem Raster *klar – überzeugt – offen* (Aufgabe 2).

75–90 · Folienkritik. Drei Beispielfolien werden nach Klarheit, Arbeitsgedächtnis-Last und Botschaftskonsistenz überarbeitet (Aufgabe 4).

12.1 Staunmoment: Zwei Vorträge

★ Staunmoment: Wem glauben Sie?

Sie sehen zwei kurze Ausschnitte aus Vorträgen.

Bewerten Sie jeden Ausschnitt sofort danach auf zwei Skalen von 1 bis 5: Wie überzeugend wirkt er? Wie belastbar ist das Gesagte fachlich? Notieren Sie zu jeder Zahl einen Grund.

Was ist gerade passiert?

- Welcher Ausschnitt hat Sie mehr überzeugt? Woran lag das?
- Welcher ist fachlich belastbarer? Woher wissen Sie das?
- Liegen Ihre beiden Bewertungen nah beieinander – oder weit auseinander?

Performance oder Substanz?

wirkt überzeugend, weil …	ist belastbar, weil …
sicherer Blick, feste Stimme	Daten werden gezeigt
flüssige Sprache, keine Pausen	Quelle und Methode sind genannt
anschauliche Geschichte	Grenzen werden benannt
Gewissheit („immer", „nachweislich")	Gewissheit passt zu den Daten

- die linke Spalte sagt etwas über den Vortrag, die rechte über die Aussage

Hinweis für Lehrende

Die Bewertungen per Handzeichen oder Zettel einsammeln, bevor Sie etwas auflösen, und den Mittelwert beider Skalen für beide Ausschnitte an die Tafel schreiben. Der typische Befund – A wird auf beiden Skalen besser bewertet, obwohl B fachlich stärker ist – ist der Dr.-Fox-Effekt im Kleinen. Die Tabelle oben ist eine erwartbare Sammlung; die Gruppe wird eigene Punkte finden. Danach den Satz aus dem Buch anschreiben: „Wir verwechseln Auftreten mit Wahrheit und Bühne mit Beweis."

12.2 Präsentieren heißt überzeugen

Eine wissenschaftliche Präsentation ist ein kommunikativer Akt mit Publikum, Kontext und Rolle. Markus Pfeil beschreibt für die Zauberkunst, wie stark die Wirkung einer Vorführung davon abhängt, ob die *Persona* des Vortragenden zum *Kontext* passt, in dem das Publikum ihn sieht (Pfeil 2019). Für Vortragende in der Wissenschaft gilt dasselbe: Eine Studentin im Seminar, eine Professorin auf einer Tagung und ein Experte in einer Talkshow werden mit unterschiedlichen Erwartungen gehört. Frieder Vogelmann beschreibt, wie Wissen nicht allein durch seinen Gehalt wirksam wird, sondern durch

institutionelle Einbettung und Inszenierung (Vogelmann 2020). Der Zauberkünstler erzeugt im Extremfall eine Wahrheit allein durch Inszenierung. Die Wissenschaft muss sich von dieser Form abheben, indem sie ihr Verfahren offenlegt.

Der Vortrag als Bühne

- **Kontext**: Wo spreche ich, was weiß das Publikum über mich?
- **Persona**: Welche Rolle nehme ich ein – und passt sie? (Pfeil 2019)
- Wissen wird auch durch Inszenierung wirksam (Vogelmann 2020)
- Unterschied zur Bühne: Die Wissenschaft legt ihr Verfahren offen

Der Dr.-Fox-Effekt

- 1973: ein Schauspieler als „Dr. Myron L. Fox", Vortrag mitreißend, Inhalt bewusst sinnlos (Naftulin u. a. 1973)
- das Fachpublikum bewertete ihn glänzend
- verschärfte Replikation: Charisma hebt Zufriedenheit und *gefühlte* Lernleistung, nicht das Gelernte (Peer und Babad 2014)
- Folgerung: Ihr Publikum ist gegen gute Performance nicht immun – Sie auch nicht

12.3 CREDS: Werkzeug und Warnung

Der Anthropologe Joseph Henrich hat beschrieben, warum Menschen nicht einfach glauben, was jemand sagt, sondern darauf achten, was er *tut*: Worte sind billig, Handlungen mit Kosten oder Risiko sind schwer zu fälschen (Henrich 2009). Solche *Credibility Enhancing Displays* (CREDS) nutzt die Zauberkunst systematisch, etwa durch erschwerende Bedingungen, das Untersuchenlassen der Requisiten oder eine sichtbar geübte, flüssige Handhabung. Auch ein Vortrag ist voller solcher Signale. Sie zu benennen hilft bei der Analyse fremder und eigener Vorträge. Die Warnung gehört dazu: Ein Signal kann Glaubwürdigkeit erzeugen, ohne dass die Aussage sie verdient. Schon die leichte Lesbarkeit einer Aussage lässt sie wahrer erscheinen (Reber und Schwarz 1999).

Was sind CREDS?

Definition 12.1 Ein **Credibility Cue** ist ein Signal, an dem ein Publikum die Glaubwürdigkeit einer Person oder Aussage abliest. **CREDS** (Credibility Enhancing Displays) sind solche Signale in Form von Handlungen, die Kosten oder Risiko tragen (Henrich 2009).

- Worte sind billig, Handlungen nicht

CREDS im Vortrag

Signal	wirkt als	belegt tatsächlich
flüssiger, freier Vortrag	Kompetenz	Übung
Fachbegriffe, Titel	Expertise	Zugehörigkeit
eigene Rohdaten gezeigt	Offenheit	prüfbares Material
Grenzen benannt	Ehrlichkeit	Kenntnis der Methode

- nur die unteren beiden sind *kostspielig* – sie machen angreifbar

Die Warnung: Scheinsicherheit

- leicht Lesbares wird eher für wahr gehalten (Reber und Schwarz 1999)
- charismatischer Vortrag $\neq$ mehr Gelerntes (Peer und Babad 2014)
- CREDS sagen, wie *überzeugt* jemand ist – nicht, ob er *recht* hat
- Prüffrage für jeden Cue: Was würde ich sehen, wenn die Aussage falsch wäre?

Credibility Cues

Glaubwürdigkeit entsteht im Publikum; Belastbarkeit liegt in der Aussage. Gute Wissenschaftskommunikation sorgt dafür, dass beides zusammenpasst – und wer zuhört, prüft, ob es das tut.

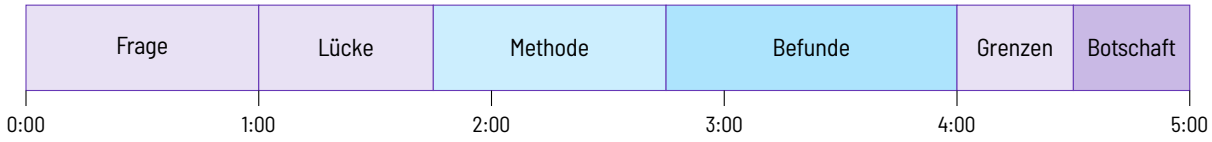
12.4 Dramaturgie eines Kurzvortrags

Das Buch beschreibt für den Einsatz eines Zauberkunststücks im Unterricht einen „Goldenen Ablauf": thematischer Einstieg, ein glaubwürdigkeitsstiftendes Signal, der Effekt, eine Pause von etwa zehn Sekunden, dann der Transfer zum Thema. Das Skript-Gerüst des Buchs ordnet dieselben Schritte in vier Phasen: Framing, CRED, Vorführung, Brücke. Ein wissenschaftlicher Kurzvortrag lässt sich nach demselben Muster bauen. An die Stelle des Effekts tritt der zentrale Befund, an die Stelle des Requisits die Methode. Die Pause nach dem Befund ist kein Zufall: Nach dem Buch entsteht Lernbereitschaft gerade in dem Moment, in dem eine offene Frage im Raum steht.

Vom Goldenen Ablauf zum Kurzvortrag

Goldener Ablauf (Buch)	5-Minuten-Vortrag
thematischer Einstieg	Frage und warum sie zählt
das CRED	Methode: wie ich es geprüft habe
der Effekt	der zentrale Befund
die Aha-Pause	Pause, Befund wirken lassen
der Transfer	Bedeutung, Grenzen, nächste Frage

Fünf Minuten, eine Botschaft



- eine Botschaft, die man in einem Satz sagen kann
- etwa eine Folie pro Minute; keine Folie ohne Aufgabe
- den ersten und den letzten Satz auswendig können

Der rote Faden

- jede Folie beantwortet eine Frage, die die vorige aufgeworfen hat
- Überleitungen laut aussprechen: „Wie haben wir das gemessen?"
- eine Pause nach dem Befund – nicht sofort erklären
- Ende = Botschaft, nicht „Danke für die Aufmerksamkeit"

12.5 Folien gestalten

Folien muss das Publikum gleichzeitig mit dem gesprochenen Wort verarbeiten. Drei Befunde der Lernpsychologie sind dafür maßgeblich. Erstens ist das Arbeitsgedächtnis eng begrenzt; wenn Gruppierung und Wiederholung ausgeschlossen sind, hält es nur etwa drei bis fünf Einheiten zugleich (Cowan 2001). Was es unnötig belastet, fehlt für das Verstehen (Sweller 1988). Zweitens werden sprachliche und bildhafte Information in getrennten, aber verbundenen Systemen

verarbeitet; was in beiden kodiert ist, bleibt besser haften (Paivio 1986). Drittens hat Richard Mayer daraus Gestaltungsprinzipien abgeleitet, etwa Unwesentliches wegzulassen, Wesentliches hervorzuheben und gesprochenen Text nicht zusätzlich vollständig einzublenden (Mayer 2009). Edward Tufte hat für Diagramme das Verhältnis von Daten-Tinte zu Dekoration als Gütemaß vorgeschlagen (Tufte 2001), und Michael Alley empfiehlt, die Folienüberschrift als vollständige Aussage zu formulieren und darunter den Beleg zu zeigen (Alley 2013).

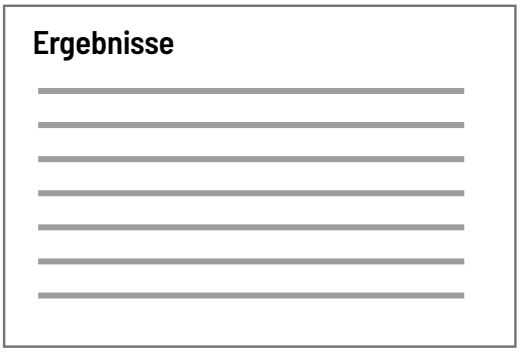
Drei Grundlagen

- **Arbeitsgedächtnis**: etwa 3–5 Einheiten zugleich (Cowan 2001); jede überflüssige Information kostet (Sweller 1988)
- **Dual Coding**: Wort *und* Bild werden getrennt verarbeitet und gemeinsam besser behalten (Paivio 1986)
- **Signal-Rausch**: so viel Tinte wie möglich für Daten, so wenig wie möglich für Dekoration (Tufte 2001)

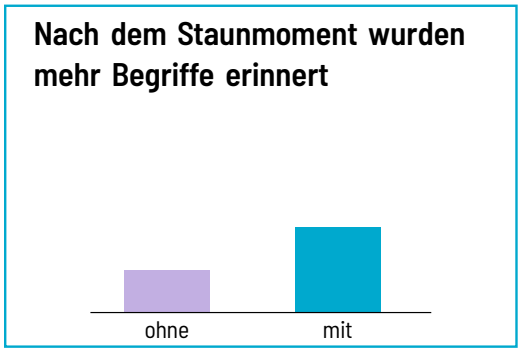
Gestaltungsregeln

- **Kohärenz**: alles weg, was nicht zur Botschaft gehört
- **Signalisierung**: das Wichtige hervorheben, nur das
- **Redundanz**: nicht vorlesen, was auf der Folie steht
- **Nähe**: Beschriftung an die Kurve, nicht in die Legende
- (Mayer 2009)

Überschrift als Aussage



Thema als Titel



Aussage als Titel, Beleg darunter

- Assertion-Evidence-Prinzip (Alley 2013); die Daten im Beispiel sind fiktiv

12.6 Transparenz über Limitationen

Eine wissenschaftliche Präsentation unterscheidet sich von einer Zaubervorführung an einem Punkt grundsätzlich: Sie legt ihre Grenzen offen. Das kostet scheinbar Überzeugungskraft. Tatsächlich ist das offene Benennen von Einschränkungen selbst ein kostspieliges Signal im Sinne Henrichs, denn es macht angreifbar, und gerade deshalb erhöht es die Glaubwürdigkeit bei einem Publikum, das prüfen kann. Davon zu unterscheiden ist die Selbstabwertung. Das Buch beschreibt das „Nocebo der Lehre“: Negative Ankündigungen über die Lernfähigkeit von Studierenden setzen Erwartungen, die sich auf Aufmerksamkeit und Arbeitsgedächtnis auswirken können. Im Vortrag wirkt die entschuldigende Einleitung („Das ist jetzt vermutlich langweilig …“) ähnlich. Grenzen benennt man sachlich und an der richtigen Stelle, nämlich nach dem Befund.

Grenzen zeigen, ohne sich klein zu machen

Nocebo (vermeiden)	Limitation (benennen)
„Das ist sicher langweilig.“ „Ich bin da nicht so sicher …“ „Das kriegen Sie eh nicht mit.“	„Die Stichprobe umfasst 18 Personen aus einem Kurs.“ „Ob der Effekt anhält, haben wir nicht gemessen.“ „Eine Alternativerklärung wäre …“

Die Zahl im Beispielsatz ist erfunden.

Warum Limitationen überzeugen

- sie sind *kostspielig*: sie liefern dem Publikum Angriffspunkte
- sie zeigen, dass Sie Ihre Methode kennen
- sie halten die Frage offen – das Publikum denkt weiter
- Mara im Buch: Die leise Vortragende, die „wir wissen es noch nicht“ sagte, behielt am Ende recht

12.7 Umgang mit Fragen

Fragen nach dem Vortrag sind organisierte Skepsis im Kleinen. Das Buch bietet für den Unterricht einen „Notfall-Satz“ an, wenn jemand ruft, er wisse, wie der Trick funktioniere: den Einwurf als Hypothese würdigen und gemeinsam prüfen, ob er die Beobachtung vollständig erklärt. Dieselbe Haltung trägt im wissenschaftlichen Vortrag. Hilfreich ist es, Fragen zu sortieren: Verständnisfragen beantwortet man kurz, Einwände nimmt man als Hypothese ernst, und Ko-Referate, die eigentlich eigene Positionen vortragen, darf man freundlich begrenzen.

Vier Regeln für die Fragerunde

- Frage wiederholen oder umformulieren – alle sollen sie hören
- Einwand als Hypothese behandeln: „Prüfen wir, ob das die Daten erklärt.“
- „Das weiß ich nicht“ ist eine zulässige Antwort, mit „das wäre zu prüfen durch …“
- eine Backup-Folie mit Details für die wahrscheinlichste Frage

12.8 Poster und Laienpublikum

Das wissenschaftliche Poster ist ein eigenes Format. Es wird im Vorbeigehen gelesen, meist in wenigen Sekunden entschieden, ob man stehen bleibt, und dann im Gespräch erschlossen. Daraus folgen andere Regeln als für Folien: eine Überschrift, die den Befund nennt; ein klarer Leseweg (IMRaD in Spalten); große Abbildungen; wenig Fließtext. Der Posterautor hält eine Zwei-Minuten-Fassung seines Vortrags bereit. Für ein Laienpublikum gelten die Regeln dieser Einheit verschärft: Fachbegriffe erklären oder weglassen, Unsicherheit trotzdem nicht verschweigen.

Poster

- Titel = Befund: aus 2 m Entfernung lesbar
- Leseweg in Spalten: Frage – Methode – Ergebnis – Bedeutung
- eine zentrale Abbildung, wenig Text
- Zwei-Minuten-Fassung für das Gespräch bereithalten

Für Laien sprechen

- ein Beispiel vor jeder Abstraktion
- Fachbegriffe erklären oder ersetzen – nicht weglassen, was sie bedeuten
- Unsicherheit in Alltagssprache: „Das spricht dafür, ist aber noch nicht gesichert.“
- Vorsicht vor dem Dr.-Fox-Effekt: Begeisterung ist kein Verstehen

12.9 Übung in der Stunde

Ihre 5-Minuten-Präsentation

- Forschungsfrage, Methode, bisherige Befunde, offene Punkte
- höchstens 5 Minuten; Signal bei 4:00
- danach 2 Minuten Feedback: Was war **klar**? Was hat **überzeugt**? Was blieb **offen**?
- alle anderen füllen den Feedbackbogen aus (Teil A, Aufgabe 2)

Folienkritik (15 Min.)

- drei Beispielfolien auf dem Übungsblatt Teil B (Aufgabe 4)
- Kriterien: Klarheit, Last für das Arbeitsgedächtnis, konsistente Botschaft
- für jede Folie: Was ist das Problem? Wie sähe die bessere Fassung aus?

Zeitplan der Präsentationsrunde

Pro Vortrag sind realistisch 5 Minuten Vortrag, 2 Minuten mündliches Feedback und eine halbe Minute Wechsel zu rechnen, also 7,5 Minuten. In das 35-Minuten-Fenster passen damit **vier, knapp fünf Vorträge**. Das reicht nur für sehr kleine Gruppen. Möglichkeiten:

Vorträge	Organisation
bis 5	Plenum, wie im Ablauf vorgesehen.
6–7	Folienkritik als Hausaufgabe auslagern; das Fenster wächst auf 50 Minuten (40–90), das reicht für 6–7 Vorträge.
8–15	Semesterprojekte in Zweier- oder Dreierteams präsentieren lassen (ein Vortrag pro Team), oder zwei parallele Gruppen in getrennten Räumen mit studentischer Moderation und Zeitnahme; die Lehrperson wechselt.
mehr als 15	Zusätzlichen Präsentationstermin ansetzen oder parallele Gruppen; zur Bewertung Aufzeichnung nur mit schriftlicher Einwilligung der Vortragenden (vgl. LE 13).

Da die Präsentation 15 % der Modulnote ausmacht, muss die Lehrperson jeden Vortrag sehen oder hören können. Bei parallelen Gruppen ist das ohne Aufzeichnung oder zweiten Termin nicht gewährleistet. Die Reihenfolge vorab festlegen, alle Folien auf einem Rechner sammeln, einen Zeitnehmer bestimmen. Das mündliche Feedback auf je einen Punkt pro Kategorie (klar, überzeugt, offen) begrenzen; ausführlicher wird es auf den Bögen, die die Vortragenden mitnehmen.

Merke

Ein guter wissenschaftlicher Vortrag überzeugt mit Mitteln, die er selbst offenlegt: Frage, Methode, Befund und Grenzen. Was darüber hinaus überzeugt, verdient einen zweiten Blick.

12.10 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- einen Forschungsbefund in fünf Minuten strukturiert präsentieren
- Credibility Cues in Vorträgen erkennen und von Belegen unterscheiden
- Folien nach Klarheit, Arbeitsgedächtnis-Last und Botschaft gestalten und kritisieren
- Limitationen benennen, ohne sich abzuwerten

- mit Fragen und Kritik sachlich umgehen

Bis zur nächsten Woche

- Feedbackbögen auswerten: drei Punkte, die Sie für die Seminararbeit übernehmen
- **Folienkritik** abschließen (Teil B, Aufgabe 4), falls in der Stunde nicht fertig
- **Tagebuch des Staunens**: Wann haben Sie zuletzt jemandem geglaubt, weil er überzeugend *wirkte*?
- für LE 13: Was in Ihrem Semesterprojekt würden Sie *nicht* veröffentlichen – und warum?

Handout: Präsentation und Glaubwürdigkeit

Worum es heute ging. Zwei Vortragsausschnitte: Der eine wirkte überzeugender, der andere war fachlich belastbarer. Was überzeugt, ist nicht dasselbe wie das, was stimmt. Das gilt für fremde Vorträge – und für Ihre eigenen.

Kernbegriffe

Credibility Cue Signal, an dem ein Publikum Glaubwürdigkeit abliest (Stimme, Sicherheit, Titel, Fachwörter, gezeigte Daten).

CREDS Credibility Enhancing Displays: Handlungen mit Kosten oder Risiko, die Überzeugung beweisen sollen (Henrich 2009). Sie zeigen, wie überzeugt jemand ist, nicht, ob er recht hat.

Dr.-Fox-Effekt Ein mitreißender Vortrag ohne Inhalt wird gut bewertet; Charisma hebt die gefühlte, nicht die tatsächliche Lernleistung (Naftulin u. a. 1973; Peer und Babad 2014).

Arbeitsgedächtnis hält etwa 3–5 Einheiten zugleich (Cowan 2001); Folien sollen es nicht unnötig belasten.

Dual Coding Wort und Bild werden getrennt verarbeitet und gemeinsam besser behalten (Paivio 1986).

Der 5-Minuten-Vortrag

Teil	Zeit	Leitfrage
Frage, Lücke	ca. 1:45	Was will ich wissen, warum ist das offen?
Methode	ca. 1:00	Wie habe ich es geprüft?
Befunde	ca. 1:15	Was kam heraus? (dann: Pause)
Grenzen	ca. 0:30	Was kann ich (noch) nicht sagen?
Botschaft	ca. 0:30	Ein Satz, der bleibt.

Folienregeln. Überschrift als Aussage, darunter der Beleg (Alley 2013). Alles weg, was nicht zur Botschaft gehört; nicht vorlesen, was auf der Folie steht (Mayer 2009). Beschriftung an die Daten, nicht in eine ferne Legende. Achsen nicht abschneiden, ohne es zu sagen.

Merke

Glaubwürdigkeit entsteht im Publikum, Belastbarkeit liegt in der Aussage. Wer Grenzen sachlich benennt, macht sich angreifbar – und gerade dadurch glaubwürdig.

Zum Weiterlesen: Alley (2013), Teil zu Folien; Henrich (2009).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 12**

Übungsblatt A: Überzeugen und belegen

Name: _____ Datum: _____

Aufgabe 1: Zwei Vorträge im Vergleich

in der Stunde, Einzelarbeit, 5 Min.

Bewerten Sie jeden Ausschnitt direkt nach dem Ansehen (1 = gar nicht, 5 = sehr) und nennen Sie je einen Grund.

	überzeugend	**weil …**	**belastbar**	**weil …**
Ausschnitt A				
Ausschnitt B				

Aufgabe 2: Feedbackbogen zur 5-Minuten-Präsentation

in der Stunde, während der Vorträge

Halten Sie zu jedem Vortrag je einen Punkt fest. Beschreiben Sie konkret („Die Folie mit dem Balkendiagramm …"), statt allgemein zu loben oder zu tadeln. Den Bogen bekommen die Vortragenden.

Vortrag von	**Was war klar?**	**Was hat überzeugt – und war es belegt?**	**Was blieb offen?**

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 12**

Übungsblatt B: Bewerten und Gestalten

Name: _____ Datum: _____

Aufgabe 3: Bewertungsraster der Präsentation

zur Information; die Lehrperson bewertet danach

Die Präsentation zählt 15 % der Modulnote. Inhaltliche Kriterien zählen doppelt – das ist die Konsequenz aus dem Dr.-Fox-Effekt: Ein mitreißender Vortrag wird auch ohne Substanz gut bewertet.

Kriterium	0	1	2	3	Faktor
Forschungsfrage klar und begründet					$\times 2$
Methode nachvollziehbar dargestellt					$\times 2$
Befunde und Grenzen transparent; Sicherheit passt zu den Daten					$\times 2$
Aufbau und roter Faden; Zeit eingehalten ($\leq$ 5:00)					$\times 1$
Folien: lesbar, eine Botschaft je Folie, Belege statt Dekoration					$\times 1$
Vortrag und Umgang mit Fragen					$\times 1$
Summe (höchstens 27 Punkte)					

0 = fehlt, 1 = in Ansätzen, 2 = überwiegend erfüllt, 3 = voll erfüllt.

Aufgabe 4: Folienkritik

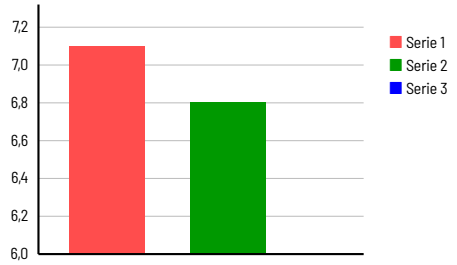
in der Stunde, Kleingruppe, 15 Min.

Die drei Folien stammen aus einem *fiktiven* Vortrag über ein Seminarexperiment; alle Daten sind erfunden. Analysieren Sie jede Folie mit dem Raster und skizzieren Sie eine bessere Fassung.

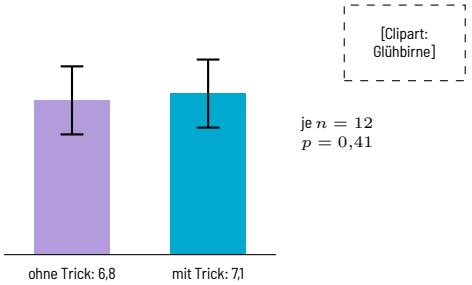
Folie 1: Methodik

- Es wurde ein Experiment mit Studierenden der Hochschule durchgeführt, die freiwillig teilgenommen haben.
- Die Teilnehmenden wurden in zwei Gruppen eingeteilt, wobei die Einteilung nach dem Zufallsprinzip erfolgte.
- Gruppe A sah vor der Lerneinheit einen Zaubertrick, Gruppe B sah stattdessen ein kurzes Video ohne Überraschung.
- Danach wurde in beiden Gruppen dieselbe Lerneinheit von 15 Minuten zum Thema Wahrscheinlichkeit gehalten.
- Im Anschluss wurde ein Test mit 10 Fragen geschrieben, der von einer Person ausgewertet wurde.
- Die auswertende Person wusste nicht, wer zu welcher Gruppe gehörte (verblindet).
- Außerdem wurden Alter, Geschlecht, Studiengang und Vorwissen erhoben.
- Eine Woche später wurde der Test wiederholt, allerdings nahmen nicht mehr alle teil.

Folie 2: Ergebnisse



Folie 3: Staunen verbessert das Lernen deutlich!



Folie 2 zeigt dieselben Mittelwerte wie Folie 3: roter Balken 7,1 (mit Trick), grüner Balken 6,8 (ohne Trick), jeweils von 10 möglichen Punkten.

Folie	Klarheit: Was ist die Botschaft?	Arbeitsgedächtnis: Was belastet unnötig?	Konsistenz: Passen Titel, Bild und Daten?
1			
2			
3			

Skizze einer besseren Fassung (eine Folie Ihrer Wahl):

Aufgabe 5: Tagebuch des Staunens

Hausaufgabe

Wann haben Sie zuletzt jemandem geglaubt, weil er überzeugend *wirkte*? Welcher Credibility Cue war es (welches Signal, an dem Sie Glaubwürdigkeit abgelesen haben), und was hätte ihn als Beleg gedeckt?

Erwartungshorizont

Aufgabe 1: Erwartet wird, dass mindestens ein Teil der Gruppe A auf beiden Skalen höher bewertet; die Begründungen für „belastbar" nennen dann oft Merkmale der Performance. Genau das ist der Diskussionsanlass.
Aufgabe 2: Gute Rückmeldungen sind konkret und trennen bei „überzeugt" zwischen Wirkung und Beleg.
Aufgabe 4, Folie 1: Keine Botschaft (Titel ist ein Thema), acht ganze Sätze überfordern das Arbeitsgedächtnis, und die Vortragende wird sie vorlesen (Redundanz). Besser: Titel als Aussage („Zwei zufällig gebildete Gruppen, verblindete Auswertung"), ein Ablaufschema mit drei Kästchen, Details mündlich. Der wichtige Hinweis auf den Schwund bei der Wiederholung gehört zu den Limitationen. **Folie 2:** Die Achse beginnt bei 6,0 und lässt einen Unterschied von 0,3 Punkten riesig erscheinen; Rot und Grün tragen Bewertungen („schlecht", „gut"), die nicht gemeint sind, und sind für Menschen mit Rot-Grün-Schwäche kaum zu unterscheiden; der Titel sagt nichts, die Gruppen sind nicht beschriftet, es fehlt eine Achsenbeschriftung, und die Legende nennt eine „Serie 3", die es nicht gibt. Besser: Achse ab 0 oder den Abschnitt deutlich kennzeichnen, Gruppen direkt beschriften, Streuung zeigen. **Folie 3:** Der Titel behauptet einen deutlichen Effekt, die Daten zeigen einen kleinen Unterschied mit sich überlappenden Fehlerbalken bei $n = 12$ je Gruppe und $p = 0{,}41$; die Clipart ist Dekoration. Besser: „Kein klarer Unterschied zwischen den Gruppen ($n = 12$ je Gruppe)" – und als Grenze nennen, dass die Stichprobe für kleine Effekte zu klein ist (LE 6).

13 Wissenschaftsethik und Grenzarbeit

Die letzte Einheit stellt eine Frage, die das ganze Semester begleitet hat, ohne dass sie ausgesprochen wurde: Was muss man offenlegen, und was darf man für sich behalten? Der Zauberkünstler hütet seine Methode, die Wissenschaft muss ihre offenlegen. Die Einheit beginnt mit einem Trick, der gezeigt und anschließend offen verhandelt wird, aber nicht erklärt. Aus dieser Grenzarbeit entwickelt sie die Grundsätze der Forschungsethik: informierte Einwilligung, Anonymisierung und Datenschutz, wissenschaftliche Integrität mit den drei Kerndelikten Erfindung, Fälschung und Plagiat, Open Science, Interessenkonflikte, Ethikkommissionen und die Grenzen dessen, was Wissenschaft tun soll. In der Ethik-Werkstatt prüfen die Studierenden ihr eigenes Semesterprojekt. Den Abschluss bildet der Rückblick auf den Bogen vom Staunen in LE 1 zur Verantwortung in LE 13.

Vorbereitung vor der Stunde: Boundary Work: Was verrät man?

Eine Woche vorher

- ☐ **Trick wählen.** Naheliegend ist die Reprise des Switchboards aus LE 5: Die Gruppe kennt den Effekt, hat in LE 5 Hypothesen gebildet und ist mit hoher Wahrscheinlichkeit noch neugierig. Ebenso geeignet ist jeder andere Effekt des Semesters, dessen Methode nicht im Buch offengelegt ist (z. B. der Seileffekt aus LE 11). Methode und Einstudierung nach der Anleitung des Herstellers bzw. der Standardliteratur; hier bewusst nicht beschrieben.
- ☐ Den Effekt erneut proben; nach einigen Wochen Pause sitzen Handgriffe oft schlechter als gedacht.
- ☐ Eigene Position zur Exposure-Frage klären und eine Formulierung vorbereiten, die die *Richtung* der Methode andeutet, ohne sie zu verraten (siehe Abschnitt 13.2).
- ☐ Klären, welche Stelle an der eigenen Hochschule für Ethikfragen, Datenschutz und gute wissenschaftliche Praxis zuständig ist (Ethikkommission, Datenschutzbeauftragte, Ombudsperson), und die Kontaktdaten auf eine Folie setzen.
- ☐ Den Studierenden mitteilen: Stand des Semesterprojekts mitbringen, insbesondere Art der erhobenen oder geplanten Daten und Teilnehmende.

Handout und Übungsblatt

- ☐ Handout „Wissenschaftsethik und Grenzarbeit" sowie Übungsblatt LE 13 Teil A und Teil B je einmal pro Person kopieren. Teil A (Checkliste, Einwilligung, Fallvignetten) liegt zu Beginn aus; Teil B (Intransparenz und Täuschung, Abschluss-Tagebucheintrag) wird zur Verantwortung nach außen ausgeteilt.
- ☐ Der Einwilligungs-Mustertext (Aufgabe 2) ist ein Gerüst. Wenn die Hochschule eigene Vorlagen hat, diese zusätzlich ausgeben.
- ☐ Für die Fallvignetten (Aufgabe 3) die neun Fälle zusätzlich auf Karten drucken (eine Karte pro Fall), wenn sie in Gruppen sortiert werden sollen.
- ☐ Die Tagebücher des Staunens werden heute abgeschlossen; Abgabe- modus für die Portfolioprüfung (20 %) ankündigen.

Am Tag selbst

- ☐ Trick aufgebaut, aber abgedeckt; die Einheit beginnt mit der Vorführung.
- ☐ Tafel teilen: „Was verlöre man durch Offenlegung?" und „Was gewönne man?"
- ☐ Rückblick-Folie (13 Kernbegriffe) für den Schluss bereit; ggf. die Requisiten des Semesters (Pendel, Seil, Karten) sichtbar auslegen.

Risiken und Plan B. Die Gruppe wird darauf drängen, die Methode zu erfahren; manche werden sie bei einer Reprise zu erraten glauben. Beides ist Material für die Diskussion: Ein geäußerter Lösungsvorschlag wird weder bestätigt noch verneint, sondern als Hypothese behandelt („Was würde die Beobachtung sonst noch erklären?"). Wer nach dem Kurs privat nachfragt, bekommt einen Hinweis auf die einschlägige Fachliteratur, nicht die Methode.

Ablauf der Doppelstunde (90 Min.)

0–10 · Staunmoment/Diskurs. Ein Trick wird gezeigt und offen verhandelt: Was verlöre man durch vollständige Offenlegung, was gewönne man? (Methode vs. Erleben.)

10–40 · Theorie-Input. Grenzarbeit; Forschungsethik (Einwilligung, Anonymisierung, DSGVO); Integrität (FFP, DFG-Kodex); Open Science; Interessenkonflikte; Ethikkommissionen; Grenzen der Wissenschaft.

40–65 · Ethik-Werkstatt. Anwendung der DFG-Leitlinien auf das eigene Semesterprojekt mit der Checkliste (Aufgabe 1); Skizze eines Ethikplans; Fallvignetten (Aufgabe 3); alles auf Übungsblatt Teil A.

65–80 · Verantwortung nach außen. Übungsblatt Teil B austeilen. Kurzbrücke zur Desinformationsabwehr: Wann wird Intransparenz zur Täuschung? (Aufgabe 4)

80–90 · Semesterabschluss. Abschluss-Tagebucheintrag (Aufgabe 5); Rückblick auf den Bogen von LE 1 (Staunen) zu LE 13 (Verantwortung).

13.1 Staunmoment: Was verrät man?

★ Staunmoment: Boundary Work

Sie sehen einen Trick, den manche von Ihnen schon kennen.

Danach entscheiden wir gemeinsam: Soll ich Ihnen die Methode verraten? Sammeln Sie Gründe dafür und dagegen.

Offenlegen?

- Was *verlören* Sie, wenn Sie die Methode kennen?
- Was *gewönnen* Sie?
- Wäre es danach derselbe Trick?
- Abstimmung per Handzeichen: verraten – nicht verraten

Methode und Erleben

durch Offenlegung verloren	durch Offenlegung gewonnen
das Staunen, die offene Frage	das Wissen, wie es geht
der Anlass, weiterzudenken	Sicherheit: kein Übernatürliches
der Trick für alle künftigen Vorführungen	ein Puzzle, das gelöst ist

- Die Methode ist kein großes Geheimnis – das Erleben ist es

Hinweis für Lehrende

Die Abstimmung fällt meist für das Verraten aus. Dann nicht verraten, aber begründen: Die Gruppe hat soeben selbst gesammelt, was verloren ginge, und die rechte Spalte enthält kaum etwas, das nicht auch die Andeutung leisten würde („Es gibt eine technische Lösung, die im Gerät steckt, und sie hat nichts mit mir zu tun."). Markus Pfeil beschreibt im Buch genau diese Erfahrung mit dem Switchboard: Ohne Hinweis schreiben Studierende den Effekt dem Vorführenden zu, mit dem Hinweis auf eine technische Lösung begreifen sie, wie wenig sie von einem scheinbar einfachen System verstehen. Die Tabelle ist eine erwartbare Sammlung; eigene Punkte der Gruppe haben Vorrang.

13.2 Grenzarbeit: offenlegen oder schützen

Der Soziologe Thomas Gieryn hat den Begriff *boundary-work* geprägt: Die Grenze zwischen Wissenschaft und Nicht-Wissenschaft ist keine feste Eigenschaft des Wissens, sondern wird gezogen, verteidigt und verschoben (Gieryn 1983). Brian Rappert und Gustav Kuhn haben den Begriff auf die Enthüllung von Zaubertricks übertragen; Markus Pfeil hat ihren Ansatz im Anhang des Buchs aus Sicht der Lehre kommentiert. Seine Position: Methoden werden nicht verraten, weil sie das Geheimnis tragen; die *Richtung*, in der eine Methode liegt, darf und soll man andeuten. Mit Anne Dufourmantelle lässt sich das schärfer fassen: Eine Enthüllung ist keine Subtraktion von Unwissen, sondern verwandelt die Erfahrung, und das Geheimnis ist eine Handlung, kein Gegenstand (Dufourmantelle 2021).

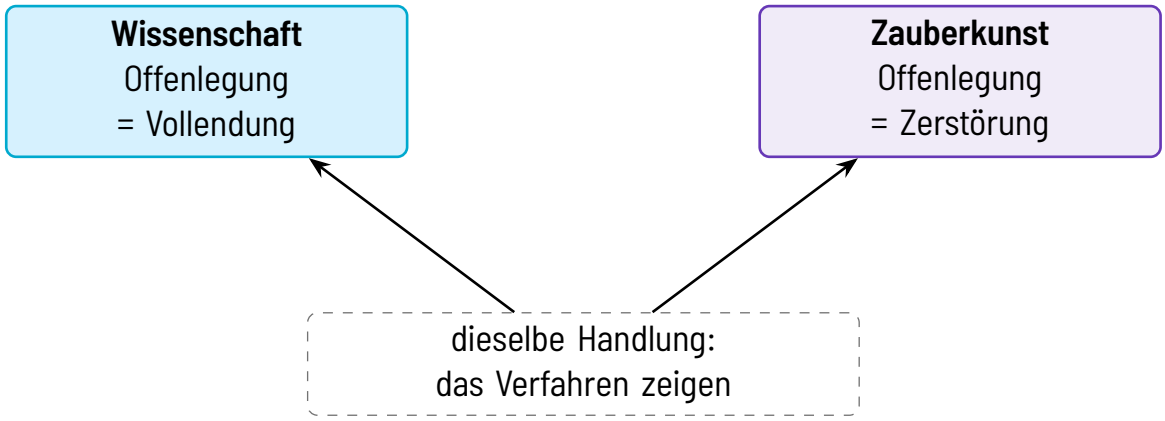
Die Wissenschaft steht auf der anderen Seite dieser Grenze. Robert K. Merton hat ihre Normen 1942 als *CUDOS* zusammengefasst: Communism (gemeinsames Eigentum an Erkenntnis), Universalism, Disinterestedness, Organized Skepticism (Merton 1973). Wer sein Verfahren verbirgt, entzieht sich der Prüfung durch andere. Das Buch spricht von einer

Inversion: Dieselbe Handlung, die Offenlegung, vollendet die Wissenschaft und vernichtet die Zauberkunst. Auch im Buch selbst wird die Grenze unterschiedlich gezogen. Im Kapitel über Offenheit und Geheimnis wird das Geheimnis im Unterricht „verzögert, aber stets eingelöst", im Kommentar zur Exposure-Frage bleibt die Methode geheim und nur das Prinzip wird erklärt. Diese Spannung ist selbst ein Stück Grenzarbeit.

Grenzarbeit

- Grenzen zwischen Wissen und Nichtwissen werden gezogen, verteidigt, verschoben (Gieryn 1983)
- die Wissenschaft selbst entstand durch Grenzarbeit, etwa die Trennung der Chemie von der Alchemie (Newman und Principe 2002)
- Position im Buch: Methode nicht verraten, Richtung andeuten
- Enthüllung verwandelt die Erfahrung (Dufourmantelle 2021)

Eine Inversion



- CUDOS: Communism, Universalism, Disinterestedness, Organized Skepticism (Merton 1973)

Was in der Forschung offenliegen muss – und was nicht

muss offenliegen	darf/muss geschützt bleiben
Methode, Material, Auswertung	Identität der Teilnehmenden
Daten (soweit möglich)	sensible Rohdaten (z. B. Gesundheit)
Finanzierung, Interessenkonflikte	Begutachtung (Vertraulichkeit)
Abweichungen vom Plan	Rechte Dritter (Lizenzen, Patente)

- Leitlinie: so offen wie möglich, so geschützt wie nötig

13.3 Forschung mit Menschen: Einwilligung

Wer Menschen befragt, beobachtet oder testet, braucht ihre *informierte Einwilligung*. Informiert heißt: Die Teilnehmenden wissen vorher, worum es geht, was sie tun sollen, wie lange es dauert, welche Risiken bestehen, was mit ihren Daten geschieht und an wen sie sich wenden können. Einwilligung heißt: Die Teilnahme ist freiwillig und kann jederzeit ohne Nachteil beendet werden; nach der Datenschutz-Grundverordnung ist eine Einwilligung jederzeit widerrufbar (Europäisches Parlament und Rat der Europäischen Union 2016). Die Grundsätze gehen auf die Medizinethik nach 1945 zurück (Nürnberger Kodex, Deklaration von Helsinki) und gelten heute für alle Disziplinen, die mit Menschen forschen. Ein Sonderfall betrifft genau dieses Semester: Studien mit Zaubertricks täuschen ihre Teilnehmenden oft absichtlich. Eine solche Täuschung ist nur vertretbar, wenn die Frage anders nicht zu beantworten ist, kein ernsthafter Schaden droht und die Teilnehmenden danach aufgeklärt werden (*Debriefing*).

Informierte Einwilligung

Definition 13.1 Informierte Einwilligung ist die freiwillige, widerrufbare Zustimmung einer Person zur Teilnahme an einer Studie, nachdem sie über Zweck, Ablauf, Dauer, Risiken und den Umgang mit ihren Daten verständlich aufgeklärt wurde.

Was in die Information gehört

- Wer forscht, wozu, und was soll ich tun – wie lange?
- Risiken und Belastungen (auch: „keine bekannten")
- freiwillig, jederzeit abbrechbar, ohne Nachteil
- welche Daten, wie gespeichert, wie lange, wer sieht sie
- Kontakt für Fragen und Widerruf

Täuschung in Studien

- Studien mit Zaubertricks täuschen absichtlich – das gehört zur Methode
- vertretbar nur, wenn die Frage anders nicht zu beantworten ist und kein ernsthafter Schaden droht
- danach **Debriefing**: aufklären, was untersucht wurde (nicht unbedingt, wie der Trick geht)
- Teilnehmende dürfen danach ihre Daten zurückziehen

13.4 Anonymisierung, Pseudonymisierung, DSGVO

Personenbezogene Daten sind alle Informationen, die sich auf eine identifizierte oder identifizierbare Person beziehen. Die Datenschutz-Grundverordnung unterscheidet zwei Formen, den Personenbezug zu lösen. *Pseudonymisierte* Daten können nur mit einer getrennt aufbewahrten Zusatzinformation (etwa einer Codeliste) einer Person zugeordnet werden (Art. 4 Nr. 5); sie bleiben personenbezogen und fallen unter die Verordnung. *Anonyme* Daten lassen sich auch mit vertretbarem Aufwand keiner Person mehr zuordnen; für sie gilt die DSGVO nicht (Erwägungsgrund 26) (Europäisches Parlament und Rat der Europäischen Union 2016). Für ein Semesterprojekt mit Fragebogen ist das wichtigste Prinzip die *Datenminimierung*: nur erheben, was für die Frage nötig ist. Wer keine Namen braucht, erhebt keine. Gesundheitsdaten und andere besondere Kategorien (Art. 9) sind besonders geschützt und gehören in einem studentischen Projekt nur nach Rücksprache in die Erhebung.

Anonym oder pseudonym?

Definition 13.2 Daten sind **pseudonymisiert**, wenn sie nur mit einer getrennt aufbewahrten Zusatzinformation einer Person zugeordnet werden können; sie bleiben personenbezogen. Daten sind **anonym**, wenn eine Zuordnung auch mit vertretbarem Aufwand nicht mehr möglich ist (Europäisches Parlament und Rat der Europäischen Union 2016).

- Vorsicht: Alter + Studiengang + Semester kann in einem kleinen Kurs eindeutig sein

Grundsätze der DSGVO (Art. 5)

- **Rechtmäßigkeit, Transparenz**: Rechtsgrundlage, z. B. Einwilligung; offen sagen, was geschieht
- **Zweckbindung**: nur für den genannten Zweck
- **Datenminimierung**: nur, was nötig ist
- **Richtigkeit, Speicherbegrenzung**: korrekt halten, löschen, wenn nicht mehr nötig

- **Integrität, Vertraulichkeit**: sicher speichern
- **Rechenschaft**: nachweisen können, dass man es so gemacht hat

Für Ihr Semesterprojekt

- keine Namen, keine E-Mail-Adressen im Datensatz
- falls nötig: Code statt Name, Codeliste getrennt und gesichert
- Speicherung auf Hochschulsystemen, nicht im privaten Cloud-Konto
- Altersgruppen statt Geburtsdatum; kleine Zellen zusammenfassen
- Löschtermin festlegen und einhalten

13.5 Wissenschaftliche Integrität

Als Kerntatbestände wissenschaftlichen Fehlverhaltens gelten *Fabrication* (Erfinden von Daten oder Ergebnissen), *Falsification* (Verfälschen von Daten, Material oder Verfahren) und *Plagiarism* (Übernahme fremder Leistung ohne Kennzeichnung, LE 11). Das Buch zeigt alle drei an realen Fällen. Diederik Stapel erfand über Jahre Datensätze; die Untersuchungskommission stellte fest, dass mindestens 55 Publikationen und 10 Dissertationen auf erfundenen Daten beruhten (Levelt u. a. 2012). Reiner Protsch datierte Fossilien falsch und gab fremde Arbeiten als eigene aus. Elisabeth Bik sichtete die Abbildungen aus 20.621 biomedizinischen Aufsätzen und fand in 3,8 % problematische Bildduplikate, bei mindestens der Hälfte davon mit Hinweisen auf bewusste Manipulation (Bik u. a. 2016). Zwischen redlicher Arbeit und FFP liegt eine Grauzone fragwürdiger Praktiken, die LE 10 behandelt hat: nachträgliches Auswählen der „passenden" Auswertung, Hypothesen nach Sicht der Daten, selektives Berichten (Simmons u. a. 2011). In Deutschland beschreibt der Kodex der Deutschen Forschungsgemeinschaft in 19 Leitlinien, was gute wissenschaftliche Praxis ist; Hochschulen müssen ihn umsetzen, um DFG-Mittel zu erhalten (Deutsche Forschungsgemeinschaft 2019).

FFP: drei Kerndelikte

Delikt	bedeutet	Fall im Buch
Fabrication	Daten erfinden	Stapel (Levelt u. a. 2012)
Falsification	Daten, Bilder, Verfahren verfälschen	Protsch; Bildduplikate (Bik u. a. 2016)
Plagiarism	fremde Leistung ohne Kennzeichnung	Protsch; LE 11

- dazwischen: fragwürdige Praktiken wie p-Hacking und HARKing (LE 10)

Wer hat es aufgedeckt?

- Stapel: drei junge Mitarbeitende, denen die Daten zu perfekt waren
- Protsch: eine unabhängige Neudatierung
- Bik: Handarbeit an über 20.000 Aufsätzen (Bik u. a. 2016)
- das stärkste Argument für die Wissenschaft: Sie deckt ihre Fehler selbst auf

Der DFG-Kodex (2019)

- 19 Leitlinien guter wissenschaftlicher Praxis (Deutsche Forschungsgemeinschaft 2019)
- u. a.: lege artis arbeiten, dokumentieren, Daten archivieren, Ergebnisse zugänglich machen
- Autorschaft nur für einen genuinen Beitrag
- Vertraulichkeit bei Begutachtungen
- Ombudspersonen: Anlaufstelle bei Verdacht auf Fehlverhalten

13.6 Open Science

Die Antwort der Wissenschaft auf Betrug und fragwürdige Praktiken ist weniger Moral als Offenlegung. Das Buch beschreibt Forschung als Vertrauensspiel: Niemand kann alle Experimente selbst wiederholen, auf die er sich stützt, also braucht das System Regeln, die zur Offenlegung zwingen. Die Open-Science-Bewegung bündelt solche Regeln. *Open Access* macht Publikationen frei zugänglich. *Open Data* macht Daten nachnutzbar, und zwar nach den FAIR-Prinzipien auffindbar, zugänglich, interoperabel und wiederverwendbar; FAIR heißt nicht, dass alle Daten offen sein müssen, sondern dass ihre Bedingungen klar beschrieben sind (Wilkinson u. a. 2016). Die *Präregistrierung* legt Hypothesen und Auswertungsplan vor der Datenerhebung fest und macht so sichtbar, was geprüft und was nachträglich gefunden wurde (Nosek u. a. 2018). Wie nötig das ist, zeigte das Replikationsprojekt der Open Science Collaboration, das nach der Darstellung im Buch nur etwa ein Drittel bis die Hälfte der untersuchten psychologischen Befunde bestätigen konnte (Open Science Collaboration 2015).

Vier Formen der Offenheit

- **Open Access**: Publikationen frei lesbar
- **Open Data**: Daten FAIR – auffindbar, zugänglich, interoperabel, wiederverwendbar (Wilkinson u. a. 2016)
- **Open Material/Code**: Fragebogen, Stimuli, Auswertungsskript
- **Präregistrierung**: Plan vor den Daten (Nosek u. a. 2018)

Warum Offenheit?

- Replikationsprojekt: nur etwa ein Drittel bis die Hälfte der geprüften Befunde bestätigt (Open Science Collaboration 2015)
- Präregistrierung ist eine „glaubwürdige Selbstbindung" – sie macht Schönen nachträglich sichtbar
- Offenheit und Datenschutz widersprechen sich nicht: anonymisieren, dann teilen

13.7 Interessenkonflikte und Ethikkommissionen

Mertons Norm der *Disinterestedness* verlangt nicht, dass Forschende keine Interessen haben, sondern dass Interessen das Ergebnis nicht steuern. Weil sich das von außen nicht prüfen lässt, gilt die Regel, Interessenkonflikte offenzulegen: Finanzierung, Beraterverträge, Beteiligungen, auch persönliche Nähe zum Gegenstand. Der Fall Theranos, den das Buch im Kapitel über Entlarvung schildert, zeigt, wie wissenschaftliche Autorität als Verkaufskulisse dienen kann. Ethikkommissionen prüfen Forschungsvorhaben mit Menschen, bevor sie beginnen. In der Medizin ist ihr Votum vorgeschrieben; in der Psychologie und den Sozialwissenschaften verlangen es viele Zeitschriften und Förderer. Für ein studentisches Semesterprojekt genügt in der Regel die Abstimmung mit der Lehrperson; sobald besonders schutzbedürftige Gruppen, sensible Daten, Täuschung oder Belastungen im Spiel sind, ist die zuständige Stelle der Hochschule zu fragen.

Interessenkonflikte

- Interessen hat jede und jeder – entscheidend ist, sie offenzulegen
- finanziell: Förderung, Beratung, Beteiligung
- nicht-finanziell: eigene Theorie, persönliche Beziehungen, Überzeugungen
- auch im Semesterprojekt: Befragen Sie Ihren eigenen Verein?

Wann zur Ethikkommission?

- besonders schutzbedürftige Gruppen (Minderjährige, Patientinnen, Abhängige)
- sensible Daten (Gesundheit, Religion, sexuelle Orientierung)
- Täuschung, Belastung, Risiko für Teilnehmende
- im Zweifel: früh fragen, nicht nachher

13.8 Grenzen der Wissenschaft

Nicht alles, was sich untersuchen lässt, darf untersucht werden, und nicht jede Frage ist eine wissenschaftliche. Grenzen setzen zunächst die Rechte der Beteiligten: Die Würde und Unversehrtheit der Teilnehmenden geht dem Erkenntnisinteresse vor. Eine zweite Grenze betrifft Folgen außerhalb der Studie, etwa wenn Ergebnisse missbraucht werden können (*Dual Use*). Eine dritte ist erkenntnistheoretisch: Wissenschaft kann beschreiben, was ist, und vorhersagen, was unter Bedingungen geschieht. Ob etwas geschehen *soll*, folgt daraus nicht allein; dafür braucht es Wertentscheidungen, die man offenlegen muss.

Was darf, was soll Wissenschaft nicht?

- **Schutz der Beteiligten**: Würde und Unversehrtheit gehen vor
- **Folgen**: Ergebnisse, die missbraucht werden können (Dual Use)
- **Sein und Sollen**: Daten zeigen, was ist – nicht, was sein soll
- Verantwortung endet nicht mit der Veröffentlichung

Forschungsethik

Der Zauberkünstler schützt seine Methode, die Forschung schützt ihre Teilnehmenden. Offenlegen muss sie alles, was andere zur Prüfung brauchen – und geheim halten darf sie nur, was Menschen schützt.

13.9 Übung in der Stunde: Ethik-Werkstatt

Ihr Semesterprojekt auf dem Prüfstand (25 Min.)

- Checkliste auf dem Übungsblatt Teil A (Aufgabe 1): Was ist erfüllt, was offen, was tun Sie?
- Einwilligungstext für Ihr Projekt anpassen (Aufgabe 2)
- zu zweit: Fallvignetten sortieren – FFP, fragwürdig oder in Ordnung? (Aufgabe 3)

Hinweis für Lehrende

Viele Semesterprojekte erheben keine sensiblen Daten; dann ist die wichtigste Erkenntnis der Werkstatt, wie viel schon an Datenminimierung und an der Trennung von Codeliste und Datensatz hängt. Projekte mit Minderjährigen (etwa Schulklassen), Gesundheitsdaten oder Täuschung gesondert besprechen und gegebenenfalls an die zuständige Stelle verweisen. Der Erwartungshorizont zu den Fallvignetten steht am Ende von Übungsblatt Teil B.

13.10 Verantwortung nach außen

Die Brücke zur Desinformationsabwehr schlägt das Buch mit einem Vergleich. Der Zauberkünstler konstruiert ein Ereignis, das zu gut ist, um wahr zu sein, und sagt offen, dass er täuscht. Stapel tat dasselbe und verschwieg es. Der Unterschied liegt im Vertrag mit dem Publikum. Intransparenz wird dort zur Täuschung, wo jemand den Eindruck erweckt, ein Verfahren sei offen oder ein Befund geprüft, obwohl beides nicht stimmt. Das Buch warnt zugleich vor der Nebenwirkung jedes Entlarvungstrainings: Wer gelernt hat, dass alles inszeniert sein *kann*, schließt leicht, dass alles inszeniert *ist* (Mede und Schäfer 2020). Das Ziel ist kalibriertes Vertrauen.

Wann wird Intransparenz zur Täuschung?

- **deklarierte** Täuschung: Zauberkunst – alle wissen, dass getäuscht wird
- **undeklarierte** Täuschung: Stapel – Inszenierung, die sich als Prüfung ausgibt (Levelt u. a. 2012)

- Prüffragen: Wird mir Gewissheit verkauft, wo Glaubensgrade angemessen wären? Welche Alternative wird ausgeblendet?
- Gegengift zum Zynismus: kalibriertes Vertrauen, nicht Generalverdacht

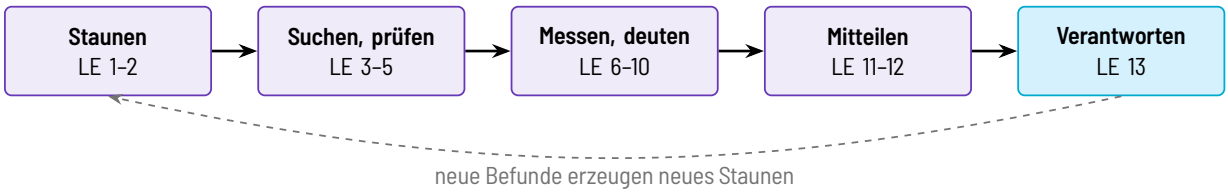
13.11 Rückblick: vom Staunen zur Verantwortung

Das Semester hat mit einem Pendel begonnen, das sich „von allein" bewegte, und endet mit der Frage, was man über einen Trick verraten darf. Dazwischen liegen dreizehn Staunmomente, aus denen jeweils ein Begriff der Methodenlehre entstanden ist. Die Tabelle fasst sie zusammen.

Rückblick: von LE 1 (Staunen) bis LE 13 (Verantwortung)

LE	Staunmoment	Kernbegriff
1	Ideomotor-Pendel	Prediction Error
2	Das geheime Objekt	Operationalisierung
3	Kruskal Count	Suchstrategie
4	Das Letzte Abendmahl	Apophenie/Bias
5	Switchboard	Falsifikation
6	Kontrollierte Seilroutine	Experimentelle Kontrolle
7	Charpentier-Illusion	Confirmation Bias
8	Chop Cup / Monty Hall	Bedingte Wahrscheinlichkeit
9	Das Patter	Intersubjektivität
10	Die unveränderliche Summe	Determinismus
11	Patter-Umbau	Präzision & Struktur
12	CRED-Strategien	Credibility Cues
13	Was verrät man?	Forschungsethik

Der Bogen des Semesters



- Staunen erzeugen – Erklärung suchen – Methode verstehen, und die Methode verantworten

13.12 Lernziele und Aufgaben

Nach dieser Einheit können Sie

- ethische Anforderungen an Ihr eigenes Forschungsvorhaben benennen
- eine informierte Einwilligung formulieren
- Anonymisierung und Pseudonymisierung unterscheiden
- Fabrication, Falsification und Plagiarism von fragwürdigen und redlichen Praktiken abgrenzen
- begründen, was in der Forschung offengelegt werden muss und was geschützt werden darf

Zum Abschluss

- **Ethik-Checkliste** für Ihr Semesterprojekt fertigstellen (Aufgabe 1); offene Punkte vor der Datenerhebung klären
- **Abschluss-Tagebucheintrag** (Aufgabe 5): Was hat Sie in diesem Semester am meisten überrascht – und was hat das mit Wissenschaft zu tun?
- Tagebuch des Staunens zur Portfolioprüfung abgeben
- Seminararbeit: Ethik und Datenumgang im Methodenteil beschreiben

Handout: Wissenschaftsethik und Grenzarbeit

Worum es heute ging. Ein Trick wurde gezeigt und nicht erklärt. Die Methode ist kein großes Geheimnis, das Erleben ist es: Eine Enthüllung hätte die Erfahrung verwandelt, nicht ergänzt. Die Wissenschaft steht auf der anderen Seite dieser Grenze. Sie muss ihr Verfahren offenlegen – und zugleich die Menschen schützen, die an ihr teilnehmen.

Kernbegriffe

Grenzarbeit das Ziehen, Verteidigen und Verschieben von Grenzen zwischen Wissen und Nichtwissen, Zeigen und Verbergen (Gieryn 1983).

Informierte Einwilligung freiwillige, widerrufbare Zustimmung nach verständlicher Aufklärung über Zweck, Ablauf, Risiken und Daten.

Pseudonymisiert / anonym pseudonymisierte Daten sind über eine getrennte Codeliste zuordenbar und bleiben personenbezogen; anonyme Daten nicht mehr (Europäisches Parlament und Rat der Europäischen Union 2016).

FFP Fabrication, Falsification, Plagiarism: die drei Kerndelikte wissenschaftlichen Fehlverhaltens.

Präregistrierung Hypothesen und Auswertungsplan vor der Datenerhebung festlegen (Nosek u. a. 2018).

Offenlegen oder schützen?

muss offenliegen	darf/muss geschützt bleiben
Methode, Material, Auswertung	Identität der Teilnehmenden
Daten, soweit möglich (FAIR)	sensible Rohdaten
Finanzierung, Interessenkonflikte	Vertraulichkeit von Gutachten
Abweichungen vom Plan	Rechte Dritter

DSGVO-Grundsätze (Art. 5) in einem Satz. Nur mit Rechtsgrundlage und offen, nur für den genannten Zweck, nur so viel wie nötig, korrekt, nicht länger als nötig, sicher gespeichert – und nachweisbar so gemacht.

Gute wissenschaftliche Praxis. Der Kodex der DFG beschreibt sie in 19 Leitlinien, u. a. zu Dokumentation, Archivierung, Autorschaft und öffentlichem Zugang zu Ergebnissen (Deutsche Forschungsgemeinschaft 2019). Bei Verdacht auf Fehlverhalten helfen die Ombudspersonen Ihrer Hochschule.

Merke

Der Zauberkünstler schützt seine Methode, die Forschung schützt ihre Teilnehmenden. Offenlegen muss sie alles, was andere zur Prüfung brauchen.

Zum Weiterlesen: Deutsche Forschungsgemeinschaft (2019); Merton (1973); Dufourmantelle (2021).

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 13**

Übungsblatt A: Ethik im eigenen Projekt

Name: _____ Datum: _____

Aufgabe 1: Ethik-Checkliste für Ihr Semesterprojekt

in der Stunde, Einzelarbeit, 15 Min.; fertigstellen als Hausaufgabe

Kreuzen Sie an und notieren Sie für jedes „nein" oder „offen" eine Maßnahme.

Frage	ja	nein	offen	Maßnahme
Teilnehmende und Einwilligung				
Ich arbeite mit Menschen (Befragung, Beobachtung, Test).				
Alle erhalten vorher eine verständliche Information.				
Teilnahme ist freiwillig und jederzeit abbrechbar.				
Es nehmen Minderjährige oder Abhängige teil (z. B. eigene Schüler).				
Ich täusche Teilnehmende; ein Debriefing ist geplant.				
Daten				
Ich erhebe nur, was ich für die Frage brauche.				
Namen/Kontaktdaten stehen nicht im Datensatz (Code, getrennte Liste).				
Ich erhebe sensible Daten (Gesundheit, Religion, …).				
Speicherort und Löschtermin sind festgelegt.				
Integrität und Offenheit				
Hypothesen und Auswertung sind vor der Erhebung notiert.				
Ausschlüsse von Daten sind begründet und werden berichtet.				
Alle Quellen sind belegt; KI-Nutzung ist nach den Regeln gekennzeichnet.				
Material und Daten (anonymisiert) kann ich anderen zeigen.				
Ich habe keine Interessenkonflikte – oder lege sie offen.				

Aufgabe 2: Einwilligung: Mustertext anpassen

in der Stunde, 10 Min.

Der folgende Text ist ein *Muster* für ein studentisches Projekt ohne sensible Daten. Er ersetzt keine Prüfung durch die zuständigen Stellen Ihrer Hochschule. Füllen Sie die Lücken für Ihr Projekt aus und streichen Sie, was nicht zutrifft.

Information und Einwilligung zur Teilnahme

Im Rahmen der Lehrveranstaltung „Wissenschaftliches Arbeiten“ an der _____ untersuche ich, _____. Die Teilnahme besteht aus _____ und dauert etwa _____ Minuten. Es sind keine Risiken bekannt, die über den Alltag hinausgehen.

Die Teilnahme ist freiwillig. Sie können jederzeit und ohne Angabe von Gründen abbrechen; daraus entstehen Ihnen keine Nachteile. Ich erhebe keine Namen. Ihre Angaben werden _____ (anonym / unter einem Code) gespeichert, nur für dieses Projekt ausgewertet, nur in zusammengefasster Form berichtet und spätestens am _____ gelöscht. Eine einmal erteilte Einwilligung können Sie jederzeit widerrufen; bereits anonym ausgewertete Angaben lassen sich danach nicht mehr einzeln entfernen.

Fragen und Widerruf: _____ (Name, E-Mail)

☐ Ich habe die Information gelesen und bin mit der Teilnahme einverstanden.

Datum, Unterschrift: _____

Aufgabe 3: Fallvignetten: FFP oder nicht?

in der Stunde, Partnerarbeit, 10 Min.

Alle Fälle sind *erfunden*. Ordnen Sie zu: **F** Fabrication, **V** Falsification (Verfälschung), **P** Plagiat, **Q** fragwürdige Praxis, **E** anderes ethisches Problem, **OK** in Ordnung. Begründen Sie kurz.

	Fall	Typ	Begründung
1	Lena fehlen sechs Fragebögen. Sie füllt sie selbst aus, „so, wie die anderen auch geantwortet haben“.		
2	Tom nimmt drei Personen aus der Auswertung, weil ihre Werte „nicht ins Bild passen“. Im Bericht steht davon nichts.		
3	Ein Team rechnet fünf Tests, berichtet nur den signifikanten und formuliert die Hypothese so, als hätte sie vorher festgestanden.		
4	Sara übernimmt Gliederung und Argumentationsfolge einer im Netz gefundenen Abschlussarbeit, formuliert alle Sätze neu und nennt die Arbeit nicht.		
5	Jonas schließt zwei Ausreißer aus, genau nach der Regel in seiner Präregistrierung, und berichtet das.		
6	Ein Student speichert die Liste mit Namen und Codes zusammen mit den Antworten in einer Online-Tabelle, die jeder mit dem Link öffnen kann.		
7	Eine Gruppe bewertet eine Lern-App. Ein Gruppenmitglied arbeitet als Werkstudent beim Hersteller; im Bericht steht das nicht.		
8	Weil das aktuelle Foto unscharf ist, setzt ein Doktorand ein Bild aus einem älteren Versuch ein und beschriftet es als aktuell.		
9	In einer Studie mit einem Zaubertrick erfahren die Teilnehmenden vorher nur, es gehe um „Wahrnehmung“; danach werden sie aufgeklärt und können ihre Daten zurückziehen.		

Wissenschaftliches Arbeiten (WuZ) **Lehreinheit 13**

Übungsblatt B: Verantwortung und Rückblick

Name: _____ Datum: _____

Aufgabe 4: Wann wird Intransparenz zur Täuschung?

in der Stunde, 65–80

Der Zauberkünstler täuscht und sagt es; der Sozialpsychologe Diederik Stapel, der Daten für zahlreiche Studien erfand, täuschte und verschwieg es. Formulieren Sie eine Regel in einem Satz, wann Nicht-Offenlegen zur Täuschung wird, und prüfen Sie sie an einem Beispiel aus Medien, Werbung oder Wissenschaft.

Aufgabe 5: Abschluss-Tagebucheintrag

Hausaufgabe, letzte Seite des Tagebuchs

„Was hat Sie im Laufe dieses Semesters am meisten überrascht – und was hat das mit Wissenschaft zu tun?" Verwenden Sie mindestens zwei der 13 Kernbegriffe des Semesters: Prediction Error, Operationalisierung, Suchstrategie, Apophenie/Bias, Falsifikation, experimentelle Kontrolle, Confirmation Bias, bedingte Wahrscheinlichkeit, Intersubjektivität, Determinismus, Präzision und Struktur, Credibility Cues, Forschungsethik.

Erwartungshorizont

Aufgabe 1: Wichtig sind konkrete Maßnahmen („Codeliste in getrenntem, passwortgeschütztem Ordner auf dem Hochschullaufwerk") statt Absichtserklärungen. Projekte mit Minderjährigen, sensiblen Daten oder Täuschung vor der Erhebung mit der Lehrperson klären.
Aufgabe 2: Die Studierenden sollen merken, dass sie Zweck, Dauer, Speicherort und Löschtermin noch nicht festgelegt haben. Hinweis: Echte Anonymität ist bei kleinen Gruppen schwer; dann ehrlich „unter einem Code" schreiben.
Aufgabe 3: 1 = F. 2 = V (Verfälschen durch unbegründetes, verschwiegenes Weglassen). 3 = Q (p-Hacking und HARKing, LE 10); die Grenze zur Verfälschung ist diskutierbar, weil der Bericht ein falsches Bild vom Vorgehen gibt. 4 = P (Struktur- und Ideenplagiat; neue Formulierungen ändern daran nichts). 5 = OK (vorab festgelegt und berichtet). 6 = E (Verstoß gegen Vertraulichkeit und Datenminimierung, Art. 5 DSGVO; kein FFP). 7 = E (nicht offengelegter Interessenkonflikt). 8 = V (Bildmanipulation; vgl. die Bildduplikate bei Bik u. a. (2016)). 9 = OK, sofern die Täuschung nötig ist, keinen Schaden anrichtet und die Aufklärung wie beschrieben erfolgt.
Aufgabe 4: Eine tragfähige Regel: Nicht-Offenlegen wird zur Täuschung, wenn jemand den Eindruck erweckt, ein Verfahren sei offen oder ein Befund geprüft, und andere ihre Entscheidungen auf diesen Eindruck stützen. Die Zauberkunst erfüllt das nicht, weil das Publikum den Vertrag kennt.

A Material und Requisiten im Semester

Diese Liste fasst die Vorbereitungsboxen der 13 Lehreinheiten zusammen. Einzelheiten zu Mengen, Proben und Plan B stehen in der jeweiligen Einheit. Kommerzielle Requisiten sollten vor Semesterbeginn vorhanden sein; die Spalte *Vorlauf* nennt, wie früh mit Beschaffung oder Proben begonnen werden sollte.

A.1 Requisiten und Material je Lehreinheit

LE	Kunststück	Material	Vorlauf
1	Ideomotor-Pendel	je Person ein Faden 40 cm mit Ring oder Mutter, Ersatzpendel; optional Pendel-App (HTTPS, QR-Code); A5-Hefte für das Tagebuch des Staunens; A3-Blätter für die Gruppenarbeit	1 Woche
2	Das geheime Objekt	undurchsichtiger Becher; Erdnüsse in der Schale; Alternative ohne Allergierisiko (Erbse in der Schote); Allergieabfrage vorab; Karteikarten A6	1 Woche (Allergieabfrage)
3	Kruskal Count	Text auf dem Übungsblatt (geprüft mit `tools/kruskal_check.py`); versiegelte Vorhersage; Bleistifte; Bibliothekszugang und Beamer für die Live-Recherche, Bildschirmfotos als Plan B	2 Wochen (Absprache Bibliothek)
4	Punktwolken, schöne Fälschung, hässliches Original	Punktwolken auf den Folien; selbst gebauter fiktiver Artikel; echter, schlicht gesetzter Fachartikel; drei SIFT-Quellen mit Links/QR-Code; WLAN; optional „Das letzte Abendmahl" (Begleitbuch, Anhang K)	2 Wochen (Artikel bauen und auswählen)
5	Switchboard / Black Box	Switchboard (kommerziell); Ersatzbatterien; Tafel oder Flipchart für den 2-4-6-Test; Zettel A7	bei Semesterbeginn; längste Einübung
6	Monty Hall (optional Chop Cup), Würfel-Detektive	drei undurchsichtige Becher und eine Kugel für die Vorführung; je Paar ein Becher-Set und ein Würfel; je Paar ein verschlossener Umschlag mit Rollenkarte („fair" oder „gezinkt", ein Fünftel gezinkt); Behauptungskarten und je Gruppe ein Gerät mit Internetzugang für den Glaubwürdigkeits-Check; A3-Blätter für die Landkarte (Hausaufgabe); optional Chop Cup (kommerziell); aktuelle Zeitungsmeldungen	1 Woche
7	Kontrollierte Seilroutine	Seil-Set (kommerziell oder nach Standardliteratur) plus Ersatzset; Maßband oder Zollstock für Variante B	2 Wochen Proben
8	Charpentier-Illusion	je Set drei gleiche Streichholzschachteln, eine mit Gewicht; ein Set pro 4–5 Personen plus Ersatz; Küchenwaage; ausgewählter Artikel für die Bias-Jagd	1 Woche
9	Das Patter	Pendel aus LE 1 oder Charpentier-Sets aus LE 8; beide Sprechtexte geprobt; Karteikarten A7; Transkript-Kopien	1 Woche
10	Unveränderliche Summe, Vorhersage-Trick	Umschlag mit Vorhersage (Jahreszahl des Termins prüfen!); Karten und Umschlag für den Vorhersage-Trick; Taschenrechner	1 Woche
11	Patter-Umbau	Ausgangs-Patter auf Folie; Kopien des schlechten Absatzes	wenige Tage

LE	Kunststück	Material	Vorlauf
12	CRED-Strategien	zwei Vortragsausschnitte (Rechte und Abspielbarkeit prüfen); Zeitplan für die Präsentationsrunde; Feedbackbögen	2 Wochen (Videos auswählen)
13	Boundary Work	ein bereits gezeigtes Kunststück als Reprise (z. B. Switchboard); Ethik-Checklisten	wenige Tage

A.2 Kopiervorlagen

Alle Handouts und Übungsblätter stehen in `handouts.pdf` (Befehl `make handouts`); diese Fassung enthält keine Lösungs- und Regiehinweise. Pro Einheit wird ein Handout (eine Seite) und ein Übungsblatt (zwei bis drei Seiten) je teilnehmender Person kopiert. Für Gruppenübungen kommen A3-Blätter, Karteikarten oder zusätzliche Kopien einzelner Materialien hinzu; die Mengen stehen in der jeweiligen Vorbereitungsbox.

A.3 Offene Auswahlentscheidungen

Einige Materialien wählt die Lehrperson vor dem jeweiligen Termin selbst aus, weil sie aktuell sein oder zum Fach der Gruppe passen sollen:

- ☐ LE 3: lizenzierte Datenbanken und Zugang im Hörsaal (Bibliothek)
- ☐ LE 4: die drei SIFT-Quellen, die „schöne Fälschung“, das „hässliche Original“
- ☐ LE 6: aktuelle Zeitungsmeldungen mit Statistik; Behauptungen für den Glaubwürdigkeits-Check; Entscheidung für oder gegen die Chop-Cup-Routine
- ☐ LE 7: optional ein echter Artikel statt des fiktiven Falls
- ☐ LE 8: der Artikel für die Bias-Jagd
- ☐ LE 9: Pendel oder Charpentier-Illusion als Patter-Effekt
- ☐ LE 12: die beiden Vortragsausschnitte
- ☐ LE 13: das Kunststück für die Reprise

Literatur

Alley, Michael (2013). *The Craft of Scientific Presentations: Critical Steps to Succeed and Critical Errors to Avoid*. 2. Aufl. New York: Springer.

American Psychological Association (2020). *Publication Manual of the American Psychological Association*. 7. Aufl. Washington, DC: American Psychological Association.

Andersen, M. (2020). *Switch Board*. Zauberkunststück, Ideaa Lab. URL: https://ideaalab.com/en/lanzamiento-switch-board.

Aristoteles (1989). *Metaphysik*. Übersetzt von Hermann Bonitz, bearbeitet von Horst Seidl. Entstanden 4. Jh. v. Chr. Stellenangabe nach Bekker-Paginierung. Hamburg: Meiner.

Baron, Jonathan (2008). *Thinking and Deciding*. 4. Aufl. Cambridge: Cambridge University Press. ISBN: 978-0-521-68043-1.

Baron, Jonathan, Jane Beattie und John C. Hershey (1988). „Heuristics and Biases in Diagnostic Reasoning: II. Congruence, Information, and Certainty". In: Bd. 42. 1, S. 88–110. DOI: 10.1016/0749-5978(88)90021-0.

Benjamin, Daniel J., James O. Berger, Magnus Johannesson u. a. (2018). „Redefine Statistical Significance". In: *Nature Human Behaviour* 2, S. 6–10. DOI: 10.1038/s41562-017-0189-z.

Berger, Peter L. und Thomas Luckmann (1966). *The Social Construction of Reality. A Treatise in the Sociology of Knowledge*. Garden City, NY: Doubleday.

Berlyne, Daniel E. (1954). „A Theory of Human Curiosity". In: *British Journal of Psychology* 45.3, S. 180–191. DOI: 10.1111/j.2044-8295.1954.tb01243.x.

Bik, Elisabeth M., Arturo Casadevall und Ferric C. Fang (2016). „The Prevalence of Inappropriate Image Duplication in Biomedical Research Publications". In: *mBio* 7.3, e00809–16. DOI: 10.1128/mBio.00809-16.

Bohannon, John (27. Mai 2015). *I Fooled Millions Into Thinking Chocolate Helps Weight Loss. Here's How*. io9 (Gizmodo). URL: https://gizmodo.com/i-fooled-millions-into-thinking-chocolate-helps-weight-1707251800.

Booth, Wayne C. u. a. (2016). *The Craft of Research*. 4. Aufl. Chicago: University of Chicago Press.

Bridgman, Percy W. (1927). *The Logic of Modern Physics*. New York: Macmillan.

Buckingham, Gavin (2014). „Getting a Grip on Heaviness Perception: A Review of Weight Illusions and Their Probable Causes". In: *Experimental Brain Research* 232.6, S. 1623–1629.

Button, Katherine S. u. a. (2013). „Power Failure: Why Small Sample Size Undermines the Reliability of Neuroscience". In: *Nature Reviews Neuroscience* 14.5, S. 365–376. DOI: 10.1038/nrn3475.

Cantergi, Debora, Bhuvanesh Awasthi und Jason Friedman (2021). „Moving Objects by Imagination? Amount of Finger Movement and Pendulum Length Determine Success in the Chevreul Pendulum Illusion". In: *Human Movement Science* 80, S. 102879. DOI: 10.1016/j.humov.2021.102879.

Carlson, Shawn (1985). „A double-blind test of astrology". In: *Nature* 318, S. 419–425. DOI: 10.1038/318419a0.

Carpenter, William B. (1852). *On the Influence of Suggestion in Modifying and Directing Muscular Movement, Independently of Volition*. Lecture at the Royal Institution.

Caulfield, Mike und Sam Wineburg (2023). *Verified: How to Think Straight, Get Duped Less, and Make Better Decisions about What to Believe Online*. Chicago: University of Chicago Press.

Charpentier, Augustin (1891). „Analyse expérimentale de quelques éléments de la sensation de poids". In: *Archives de physiologie normale et pathologique* 3, S. 122–135.

Chevreul, Michel-Eugène (1854). *De la baguette divinatoire, du pendule dit explorateur et des tables tournantes, au point de vue de l'histoire, de la critique et de la méthode expérimentale*. Paris: Mallet-Bachelier.

Clark, Andy (2016). *Surfing Uncertainty: Prediction, Action, and the Embodied Mind*. Oxford University Press.

Cohen, Jacob (1988). *Statistical Power Analysis for the Behavioral Sciences*. 2. Aufl. Hillsdale, NJ: Lawrence Erlbaum.

Conrad, Klaus (1958). *Die beginnende Schizophrenie. Versuch einer Gestaltanalyse des Wahns*. Stuttgart: Thieme.

Cowan, Nelson (2001). „The Magical Number 4 in Short-Term Memory: A Reconsideration of Mental Storage Capacity". In: *Behavioral and Brain Sciences* 24.1, S. 87–114. DOI: 10.1017/S0140525X01003922.

Denzin, Norman K. (1970). *The Research Act. A Theoretical Introduction to Sociological Methods*. Chicago: Aldine.

Deutsche Forschungsgemeinschaft (2019). *Leitlinien zur Sicherung guter wissenschaftlicher Praxis. Kodex*. Techn. Ber. Bonn: Deutsche Forschungsgemeinschaft.

Doran, George T. (1981). „There's a S.M.A.R.T. Way to Write Management's Goals and Objectives". In: *Management Review* 70.11, S. 35–36.

Döring, Nicola und Jürgen Bortz (2016a). *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. 5. Aufl. Berlin, Heidelberg: Springer.

— (2016b). *Forschungsmethoden und Evaluation in den Sozial- und Humanwissenschaften*. 5. Aufl. Berlin und Heidelberg: Springer.

Dufourmantelle, Anne (2021). *Verteidigung des Geheimnisses*. Aus dem Französischen von Luzia Gast. Originalausgabe: *Défense du secret*, Paris: Payot & Rivages, 2015. Zürich: Diaphanes. ISBN: 978-3-0358-0218-4.

Duhem, Pierre (1906). *La Théorie physique. Son objet, sa structure*. Paris: Chevalier et Rivière.

Edmondson, Amy C. (1999). „Psychological Safety and Learning Behavior in Work Teams". In: *Administrative Science Quarterly* 44.2, S. 350–383.

Einstein, Albert (1905). „Zur Elektrodynamik bewegter Körper". In: *Annalen der Physik* 322.10, S. 891–921. DOI: 10.1002/andp.19053221004.

Epstein, David (2026). *Inside the Box: How Constraints Make Us Better*. New York: Riverhead Books. ISBN: 978-0-593-71571-0.

Europäisches Parlament und Rat der Europäischen Union (2016). *Verordnung (EU) 2016/679 zum Schutz natürlicher Personen bei der Verarbeitung personenbezogener Daten, zum freien Datenverkehr und zur Aufhebung der Richtlinie 95/46/EG (Datenschutz-Grundverordnung)*. Amtsblatt der Europäischen Union, L 119, 4. Mai 2016, S. 1–88.

Faraday, Michael (1853). „Experimental Investigation of Table-Moving". In: *Journal of the Franklin Institute* 56. Zuerst als Leserbrief in *The Times* (30. Juni 1853) und in *The Athenaeum* (2. Juli 1853), S. 328–333.

Fellehner, Martin (26. Aug. 2026). *Diamond-Technik: Die Fixierung auf einen hinderlichen Glaubenssatz aufheben*. NLP Hessen, NLP-Lexikon. URL: https://www.nlp-hessen.de.

Fischhoff, Baruch (1975). „Hindsight ≠ Foresight: The Effect of Outcome Knowledge on Judgment under Uncertainty". In: *Journal of Experimental Psychology: Human Perception and Performance* 1.3, S. 288–299.

Flanagan, J. Randall und Michael A. Beltzner (2000). „Independence of Perceptual and Sensorimotor Predictions in the Size–Weight Illusion". In: *Nature Neuroscience* 3.7, S. 737–741.

Forer, Bertram R. (1949). „The fallacy of personal validation: A classroom demonstration of gullibility". In: *Journal of Abnormal and Social Psychology* 44.1, S. 118–123.

Friston, Karl (2010). „The free-energy principle: a unified brain theory?" In: *Nature Reviews Neuroscience* 11.2, S. 127–138. DOI: 10.1038/nrn2787.

Garfield, Eugene (1955). „Citation Indexes for Science: A New Dimension in Documentation through Association of Ideas". In: *Science* 122.3159, S. 108–111.

— (2006). „The History and Meaning of the Journal Impact Factor". In: *JAMA* 295.1, S. 90–93. DOI: 10.1001/jama.295.1.90.

Gelman, Andrew und Eric Loken (2014). „The Statistical Crisis in Science". In: *American Scientist* 102.6, S. 460–465. DOI: 10.1511/2014.111.460.

Gendler, Tamar Szabó (2008). „Alief and Belief". In: *Journal of Philosophy* 105.10, S. 634–663.

Gieryn, Thomas F. (1983). „Boundary-Work and the Demarcation of Science from Non-Science: Strains and Interests in Professional Ideologies of Scientists". In: *American Sociological Review* 48.6, S. 781–795. DOI: 10.2307/2095325.

Gigerenzer, Gerd und Ulrich Hoffrage (1995). „How to Improve Bayesian Reasoning Without Instruction: Frequency Formats". In: *Psychological Review* 102.4, S. 684–704. DOI: 10.1037/0033-295X.102.4.684.

Gigerenzer, Gerd, Peter M. Todd und the ABC Research Group (1999). *Simple Heuristics That Make Us Smart*. New York: Oxford University Press. ISBN: 978-0-19-514381-2.

Godden, Duncan R. und Alan D. Baddeley (1975). „Context-dependent Memory in Two Natural Environments: On Land and Underwater". In: *British Journal of Psychology* 66.3, S. 325–331.

Gollwitzer, Peter M. und Paschal Sheeran (2006). „Implementation Intentions and Goal Achievement: A Meta-analysis of Effects and Processes". In: *Advances in Experimental Social Psychology* 38, S. 69–119.

Gross, James J. (1998). „The Emerging Field of Emotion Regulation: An Integrative Review". In: *Review of General Psychology* 2.3, S. 271–299.

Gruber, Matthias J., Bernard D. Gelman und Charan Ranganath (2014). „States of Curiosity Modulate Hippocampus-dependent Learning via the Dopaminergic Circuit". In: *Neuron* 84.2, S. 486–496.

Gusenbauer, Michael und Neal R. Haddaway (2020). „Which Academic Search Systems Are Suitable for Systematic Reviews or Meta-Analyses? Evaluating Retrieval Qualities of Google Scholar, PubMed, and 26 Other Resources". In: *Research Synthesis Methods* 11.2, S. 181–217. DOI: 10.1002/jrsm.1378.

Hasher, Lynn, David Goldstein und Thomas Toppino (1977). „Frequency and the Conference of Referential Validity". In: *Journal of Verbal Learning and Verbal Behavior* 16.1, S. 107–112. DOI: 10.1016/S0022-5371(77)80012-1.

Helfferich, Cornelia (2011). *Die Qualität qualitativer Daten. Manual für die Durchführung qualitativer Interviews*. 4. Aufl. Wiesbaden: VS Verlag für Sozialwissenschaften.

Henrich, Joseph (2009). „The Evolution of Costly Displays, Cooperation and Religion: Credibility Enhancing Displays and Their Implications for Cultural Evolution". In: *Evolution and Human Behavior* 30.4, S. 244–260.

Hicks, Diana u. a. (2015). „Bibliometrics: The Leiden Manifesto for Research Metrics". In: *Nature* 520.7548, S. 429–431. DOI: 10.1038/520429a.

Hirsch, Jorge E. (2005). „An Index to Quantify an Individual's Scientific Research Output". In: *Proceedings of the National Academy of Sciences* 102.46, S. 16569–16572. DOI: 10.1073/pnas.0507655102.

Horwich, Paul (1982). *Probability and Evidence*. Cambridge Philosophy Classics Edition 2016, mit einem Vorwort von Colin Howson. Cambridge: Cambridge University Press. ISBN: 978-1-316-50701-8.

Hughes, Taylor (2023). *Misdirection: A Magician's Guide to Spotting and Avoiding Manipulation in Your Life*. Upland, CA: WonderFull Entertainment. ISBN: 978-1-7377073-1-8.

Hulley, Stephen B. u. a. (2013). *Designing Clinical Research*. 4. Aufl. Philadelphia: Lippincott Williams & Wilkins.

Ioannidis, John P. A. (2005). „Why Most Published Research Findings Are False". In: *PLoS Medicine* 2.8, e124. DOI: 10.1371/journal.pmed.0020124.

Kahneman, Daniel (2011). *Thinking, Fast and Slow*. Farrar, Straus und Giroux.

Kahneman, Daniel, Olivier Sibony und Cass R. Sunstein (2021). *Noise: A Flaw in Human Judgment*. Siedler.

Kass, Robert E. und Adrian E. Raftery (1995). „Bayes Factors". In: *Journal of the American Statistical Association* 90.430, S. 773–795. DOI: 10.1080/01621459.1995.10476572.

Keltner, Dacher und Jonathan Haidt (2003). „Approaching Awe, a Moral, Spiritual, and Aesthetic Emotion". In: *Cognition and Emotion* 17.2, S. 297–314.

Kerr, Norbert L. (1998). „HARKing: Hypothesizing After the Results are Known". In: *Personality and Social Psychology Review* 2.3, S. 196–217. DOI: 10.1207/s15327957pspr0203_4.

Klayman, Joshua und Young-Won Ha (1987). „Confirmation, Disconfirmation, and Information in Hypothesis Testing". In: *Psychological Review* 94.2, S. 211–228. DOI: 10.1037/0033-295X.94.2.211.

Krauss, Stefan und X. T. Wang (2003). „The Psychology of the Monty Hall Problem: Discovering Psychological Mechanisms for Solving a Tenacious Brain Teaser". In: *Journal of Experimental Psychology: General* 132.1, S. 3–22. DOI: 10.1037/0096-3445.132.1.3.

Kuhn, Gustav und Ronald A. Rensink (2016). „The Vanishing Ball Illusion: A New Perspective on the Perception of Dynamic Events". In: *Cognition* 136, S. 25–33.

Kultusministerkonferenz (2017). *Qualifikationsrahmen für Deutsche Hochschulabschlüsse*. Hochschulrektorenkonferenz / Kultusministerkonferenz, Bonn. Beschluss der Kultusministerkonferenz vom 16.02.2017.

Lagarias, Jeffrey C., Eric Rains und Robert J. Vanderbei (2009). „The Kruskal Count". In: *The Mathematics of Preference, Choice and Order: Essays in Honor of Peter C. Fishburn*. Hrsg. von Steven J. Brams, William V. Gehrlein und Fred S. Roberts. Berlin, Heidelberg: Springer, S. 371–391.

Lakatos, Imre (1970). „Falsification and the Methodology of Scientific Research Programmes". In: *Criticism and the Growth of Knowledge*. Hrsg. von Imre Lakatos und Alan Musgrave. Cambridge: Cambridge University Press, S. 91–196.

Levelt, Willem J. M., Pieter J. D. Drenth und Ed Noort (2012). *Flawed Science: The Fraudulent Research Practices of Social Psychologist Diederik Stapel*. Tilburg: Tilburg University, University of Groningen und University of Amsterdam (gemeinsame Untersuchungskommissionen).

Lewandowsky, Stephan u. a. (2012). „Misinformation and Its Correction: Continued Influence and Successful Debiasing". In: *Psychological Science in the Public Interest* 13.3, S. 106–131. DOI: 10.1177/1529100612451018.

Lewandowsky, Stephan u. a. (2020). *The Debunking Handbook 2020*. George Mason University Center for Climate Change Communication. DOI: 10.17910/b7.1182. URL: https://sks.to/db2020.

Lincoln, Yvonna S. und Egon G. Guba (1985). *Naturalistic Inquiry*. Beverly Hills, CA: Sage.

Loewenstein, George (1994). „The Psychology of Curiosity: A Review and Reinterpretation". In: *Psychological Bulletin* 116.1, S. 75–98.
— (1996). „Out of Control: Visceral Influences on Behavior". In: *Organizational Behavior and Human Decision Processes* 65.3, S. 272–292. DOI: 10.1006/obhd.1996.0028.
Loftus, Elizabeth F. und John C. Palmer (1974a). „Reconstruction of Automobile Destruction: An Example of the Interaction Between Language and Memory". In: *Journal of Verbal Learning and Verbal Behavior* 13.5, S. 585–589.
— (1974b). „Reconstruction of Automobile Destruction: An Example of the Interaction Between Language and Memory". In: *Journal of Verbal Learning and Verbal Behavior* 13.5, S. 585–589. DOI: 10.1016/S0022-5371(74)80011-3.
Master Payne (o. D.). *Sometimes the Jokes are Just for Me: Lecture Notes*. Penguin Magic (E-Book/Lecture Notes), https://www.penguinmagic.com/p/10350. Enthält den Effekt *The DaVinci Code Card Trick*; Bearbeitung in Anhang K mit freundlicher Genehmigung des Autors.
Matthews, Robert (2000). „Storks Deliver Babies (p = 0.008)". In: *Teaching Statistics* 22.2, S. 36–38. DOI: 10.1111/1467-9639.00013.
Mayer, Richard E. (2009). *Multimedia Learning*. 2. Aufl. New York: Cambridge University Press.
Mayring, Philipp (2015). *Qualitative Inhaltsanalyse. Grundlagen und Techniken*. 12. Aufl. Weinheim und Basel: Beltz.
McGuire, William J. (1964). „Inducing Resistance to Persuasion: Some Contemporary Approaches". In: *Advances in Experimental Social Psychology*. Hrsg. von Leonard Berkowitz. Bd. 1. New York: Academic Press, S. 191–229. DOI: 10.1016/S0065-2601(08)60052-0.
Mede, Niels G. und Mike S. Schäfer (2020). „Science-related Populism: Conceptualizing Populist Demands toward Science". In: *Public Understanding of Science* 29.5, S. 473–491. DOI: 10.1177/0963662520924259.
Merton, Robert K. (1968). „The Matthew Effect in Science". In: *Science* 159.3810, S. 56–63. DOI: 10.1126/science.159.3810.56.
— (1973). „The Normative Structure of Science". In: *The Sociology of Science: Theoretical and Empirical Investigations*. Hrsg. von Norman W. Storer. Chicago: University of Chicago Press, S. 267–278.
Naftulin, Donald H., John E. Ware und Frank A. Donnelly (1973). „The Doctor Fox Lecture: A Paradigm of Educational Seduction". In: *Journal of Medical Education* 48.7, S. 630–635. DOI: 10.1097/00001888-197307000-00003.
Newman, William R. und Lawrence M. Principe (2002). *Alchemy Tried in the Fire: Starkey, Boyle, and the Fate of Helmontian Chymistry*. Chicago: University of Chicago Press. ISBN: 978-0-226-57711-8.
Nickerson, Raymond S. (1998). „Confirmation Bias: A Ubiquitous Phenomenon in Many Guises". In: *Review of General Psychology* 2.2, S. 175–220. DOI: 10.1037/1089-2680.2.2.175.
Nosek, Brian A. u. a. (2018). „The Preregistration Revolution". In: *Proceedings of the National Academy of Sciences* 115.11, S. 2600–2606. DOI: 10.1073/pnas.1708274114.
Nozick, Robert (1969). „Newcomb's Problem and Two Principles of Choice". In: *Essays in Honor of Carl G. Hempel*. Hrsg. von Nicholas Rescher. Dordrecht: Reidel, S. 114–146.
Open Science Collaboration (2015). „Estimating the Reproducibility of Psychological Science". In: *Science* 349.6251, aac4716. DOI: 10.1126/science.aac4716.
Oppenheimer, Daniel M. (2006). „Consequences of Erudite Vernacular Utilized Irrespective of Necessity: Problems with Using Long Words Needlessly". In: *Applied Cognitive Psychology* 20.2, S. 139–156. DOI: 10.1002/acp.1178.
Page, Matthew J. u. a. (2021). „The PRISMA 2020 Statement: An Updated Guideline for Reporting Systematic Reviews". In: *BMJ* 372, n71. DOI: 10.1136/bmj.n71.
Paillès, Alice und Gustav Kuhn (2020). „The Apparent Action Causation: Using a Magician Forcing Technique to Investigate Our Illusory Sense of Agency Over the Outcome of Our Choices". In: *Quarterly Journal of Experimental Psychology* 73.11, S. 1784–1795.
Paivio, Allan (1986). *Mental Representations: A Dual Coding Approach*. New York: Oxford University Press.
Peer, Eyal und Elisha Babad (2014). „The Doctor Fox Research (1973) Rerevisited: , Educational Seduction' Ruled Out". In: *Journal of Educational Psychology* 106.1, S. 81–90. DOI: 10.1037/a0033827.
Pennycook, Gordon u. a. (2021). „Shifting Attention to Accuracy Can Reduce Misinformation Online". In: *Nature* 592, S. 590–595. DOI: 10.1038/s41586-021-03344-2.
Pfeil, Markus (2019). *Context and Alignment: Opening the Door for Mystery*. Beitrag zum Magiculum-Forum.
Pfungst, Oskar (1907). *Das Pferd des Herrn von Osten (Der Kluge Hans): Ein Beitrag zur experimentellen Tier- und Menschen-Psychologie*. Leipzig: Johann Ambrosius Barth.

Platon (1994). *Theaitetos*. In: Sämtliche Werke, Bd. 3. Übersetzt von Friedrich Schleiermacher. Entstanden ca. 369 v. Chr. Stellenangabe nach Stephanus-Paginierung. Reinbek: Rowohlt.

Popper, Karl R. (1934). *Logik der Forschung: Zur Erkenntnistheorie der modernen Naturwissenschaft*. Englische Übersetzung: *The Logic of Scientific Discovery*. London: Hutchinson, 1959. Wien: Julius Springer.

— (1963). *Conjectures and Refutations: The Growth of Scientific Knowledge*. London: Routledge und Kegan Paul.

Quine, Willard Van Orman (1951). „Two Dogmas of Empiricism". In: *The Philosophical Review* 60.1, S. 20–43.

Reber, Rolf und Norbert Schwarz (1999). „Effects of Perceptual Fluency on Judgments of Truth". In: *Consciousness and Cognition* 8.3, S. 338–342. DOI: 10.1006/ccog.1999.0386.

Roozenbeek, Jon u. a. (2022). „Psychological Inoculation Improves Resilience against Misinformation on Social Media". In: *Science Advances* 8.34, eabo6254. DOI: 10.1126/sciadv.abo6254.

Rosenthal, Robert (1979). „The , File Drawer Problem' and Tolerance for Null Results". In: *Psychological Bulletin* 86.3, S. 638–641.

Rosenthal, Robert und Kermit L. Fode (1963). „The Effect of Experimenter Bias on the Performance of the Albino Rat". In: *Behavioral Science* 8.3, S. 183–189.

Rouder, Jeffrey N. u. a. (2009). „Bayesian t Tests for Accepting and Rejecting the Null Hypothesis". In: *Psychonomic Bulletin & Review* 16.2, S. 225–237. DOI: 10.3758/PBR.16.2.225.

Sagan, Carl (1995). *The Demon-Haunted World: Science as a Candle in the Dark*. New York: Random House. ISBN: 978-0-394-53512-8.

San Francisco Declaration on Research Assessment (2012). *San Francisco Declaration on Research Assessment (DORA)*. https://sfdora.org/read/.

Schönbrodt, Felix D. u. a. (2017). „Sequential Hypothesis Testing with Bayes Factors: Efficiently Testing Mean Differences". In: *Psychological Methods* 22.2, S. 322–339. DOI: 10.1037/met0000061.

Schulz-Hardt, Stefan u. a. (2002). „Biased Information Search in Group Decision Making". In: *Journal of Personality and Social Psychology* 78.4, S. 655–669.

Seglen, Per O. (1997). „Why the Impact Factor of Journals Should Not Be Used for Evaluating Research". In: *BMJ* 314.7079, S. 497. DOI: 10.1136/bmj.314.7079.497.

Selvin, Steve (1975). „A Problem in Probability". In: *The American Statistician* 29.1, S. 67.

Semmelweis, Ignaz Philipp (1861). *Die Ätiologie, der Begriff und die Prophylaxis des Kindbettfiebers*. Pest, Wien und Leipzig: C. A. Hartleben.

Seth, Anil (2021). *Being You: A New Science of Consciousness*. Faber & Faber.

Shadish, William R., Thomas D. Cook und Donald T. Campbell (2002). *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Boston: Houghton Mifflin.

Simmons, Joseph P., Leif D. Nelson und Uri Simonsohn (2011). „False-Positive Psychology: Undisclosed Flexibility in Data Collection and Analysis Allows Presenting Anything as Significant". In: *Psychological Science* 22.11, S. 1359–1366. DOI: 10.1177/0956797611417632.

Stapel, Diederik A. und Siegwart Lindenberg (2011). „Coping with Chaos: How Disordered Contexts Promote Stereotyping and Discrimination". In: *Science* 332.6026. Zurückgezogen (Retraction: Science 334(6060):1202, 2011); die Daten waren erfunden, S. 251–253. DOI: 10.1126/science.1201068.

Sturm, Virginia E., Samir Datta, Ashlin R. K. Roy u. a. (2022). „Big Smile, Small Self: Awe Walks Promote Prosocial Positive Emotions in Older Adults". In: *Emotion* 22.5. Erstveröffentlichung online 2020, S. 1044–1058. DOI: 10.1037/emo0000876.

Swales, John M. (1990). *Genre Analysis: English in Academic and Research Settings*. Cambridge: Cambridge University Press.

Sweller, John (1988). „Cognitive Load During Problem Solving: Effects on Learning". In: *Cognitive Science* 12.2, S. 257–285. DOI: 10.1207/s15516709cog1202_4.

Taylor, Nicholas (2020). „Performing Real Magic(K): The Conjurer and Audience in Bizarre Magick". Diss. University of Huddersfield. URL: https://eprints.hud.ac.uk/id/eprint/35296/.

Toulmin, Stephen E. (1958). *The Uses of Argument*. Cambridge: Cambridge University Press.

Tufte, Edward R. (2001). *The Visual Display of Quantitative Information*. 2. Aufl. Cheshire, CT: Graphics Press.

Tukey, John W. (1977). *Exploratory Data Analysis*. Reading, MA: Addison-Wesley.

Tversky, Amos und Daniel Kahneman (1974). „Judgment under Uncertainty: Heuristics and Biases". In: *Science* 185.4157, S. 1124–1131.

— (1982). „Evidential Impact of Base Rates“. In: *Judgment under Uncertainty: Heuristics and Biases*. Hrsg. von Daniel Kahneman, Paul Slovic und Amos Tversky. Cambridge: Cambridge University Press, S. 153–160. DOI: 10.1017/CBO9780511809477.011.

Varga von Kibéd, Matthias und Insa Sparrer (2000). *Ganz im Gegenteil: Tetralemmaarbeit und andere Grundformen Systemischer Strukturaufstellungen*. Heidelberg: Carl-Auer.

Vogelmann, Frieder (2020). *Im Sog der Wahrheit: Politiken der Epistemologie*. Tübingen: Mohr Siebeck. ISBN: 978-3-16-158895-7.

vos Savant, Marilyn (1990). *Ask Marilyn*. Parade Magazine, 9. September, S. 16.

Wagenmakers, Eric-Jan (2007). „A Practical Solution to the Pervasive Problems of p Values“. In: *Psychonomic Bulletin & Review* 14.5, S. 779–804. DOI: 10.3758/BF03194105.

Wason, Peter C. (1960). „On the Failure to Eliminate Hypotheses in a Conceptual Task“. In: *Quarterly Journal of Experimental Psychology* 12.3, S. 129–140. DOI: 10.1080/17470216008416717.

Wasserstein, Ronald L. und Nicole A. Lazar (2016). „The ASA Statement on p-Values: Context, Process, and Purpose“. In: *The American Statistician* 70.2, S. 129–133. DOI: 10.1080/00031305.2016.1154108.

White, Mathew P. u. a. (2019). „Spending at least 120 minutes a week in nature is associated with good health and wellbeing“. In: *Scientific Reports* 9, S. 7730. DOI: 10.1038/s41598-019-44097-3.

Whitson, Jennifer A. und Adam D. Galinsky (2008). „Lacking Control Increases Illusory Pattern Perception“. In: *Science* 322.5898, S. 115–117. DOI: 10.1126/science.1159845.

Wilkinson, Mark D. u. a. (2016). „The FAIR Guiding Principles for Scientific Data Management and Stewardship“. In: *Scientific Data* 3, S. 160018. DOI: 10.1038/sdata.2016.18.

Wineburg, Sam und Sarah McGrew (2019). „Lateral Reading and the Nature of Expertise: Reading Less and Learning More When Evaluating Digital Information“. In: *Teachers College Record* 121.11, S. 1–40. DOI: 10.1177/016146811912101102.

Witkowski, Tomasz (2010). „Thirty-Five Years of Research on Neuro-Linguistic Programming“. In: *Polish Psychological Bulletin* 41.2, S. 58–66.

Wohlin, Claes (2014). „Guidelines for Snowballing in Systematic Literature Studies and a Replication in Software Engineering“. In: *Proceedings of the 18th International Conference on Evaluation and Assessment in Software Engineering (EASE '14)*. New York: ACM. DOI: 10.1145/2601248.2601268.