Handout: Statistik: Signifikanztest und Bayes

Worum es heute ging. Drei Becher, eine Kugel: Die Spielleitung öffnet wissentlich einen leeren Becher, Wechseln gewinnt in zwei von drei Fällen. Öffnet sie blind, ist es egal. Dasselbe Bild, zwei Prozesse, zwei Wahrscheinlichkeiten. Statistik prüft solche Täuschungen der Intuition, und zwar auf zwei Arten.

	frequentistisch	**bayesianisch**
Frage	Wie überraschend wären die Daten, wenn H_0 stimmt?	Welche Hypothese sagt die Daten besser voraus?
Ergebnis	p-Wert, Konfidenzintervall	Bayes-Faktor, Posterior
braucht	H_0, α, n vorab festgelegt	H_0, konkrete H_1, Prior (Basisrate)
kann nicht	H_0 stützen; sagen, wie wahrscheinlich H ist	ohne offen gelegten Prior auskommen

Kernbegriffe

Bedingte Wahrscheinlichkeit $P(A \mid B)$. Die Richtung zählt: $P(\text{Daten} \mid H) \neq P(H \mid \text{Daten})$.

p-Wert Wahrscheinlichkeit für mindestens so extreme Daten, *falls* H_0 stimmt. Kein Maß für die Wahrheit einer Hypothese und keins für die Größe eines Effekts (Wasserstein und Lazar 2016).

Basisrate Wie häufig ist das Gesuchte, bevor man hinschaut? Ohne sie lässt sich kein positiver Test und kein signifikanter Befund deuten.

Bayes-Faktor $BF_{10} = P(\text{Daten} \mid H_1)/P(\text{Daten} \mid H_0)$: 1–3 kaum der Rede wert, 3–20 positiv, über 20 stark (Kass und Raftery 1995); unter 1 spricht für H_0.

Effektgröße, Power Cohens d (0,2 klein, 0,5 mittel, 0,8 groß); Power = Chance, einen vorhandenen Effekt zu finden. Für $d = 0{,}5$ und Power 0,80: 64 Personen pro Gruppe.

Rechnen in drei Zeilen

- Chancenform: *Chance nachher = Chance vorher* $\times$ BF_{10}; Chance $a : b$ = Wahrscheinlichkeit $a/(a+b)$. Würfel, 10 Sechsen in 30 Würfen, „gezinkt" = $P(6) = \frac{1}{3}$: $BF_{10} = 2^{10} \cdot 0{,}8^{20} \approx 12$; bei Basisrate $1 : 4$ also $12 : 4$, rund 75 %.
- t-Test, zwei Gruppen: $t = (\bar{x}_1 - \bar{x}_2) \,/\, (s_p\sqrt{1/n_1 + 1/n_2})$, $df = n_1 + n_2 - 2$; $d = (\bar{x}_1 - \bar{x}_2)/s_p$.
- Faustformel (Wagenmakers 2007): $BF_{01} \approx \sqrt{N}\,(1 + t^2/df)^{-N/2}$, N = alle Personen. Genauer: JASP.

Skalen: nominal (Modus), ordinal (Median, Quartile), metrisch (Mittelwert, s). Ausreißer nach Tukey (1977): mehr als $1{,}5 \cdot IQR$ unter Q_1 oder über Q_3.

Merke

Erst fragen, wie die Daten zustande kamen, dann rechnen. Ein kleiner p-Wert ist kein Beweis; was man glauben sollte, bestimmen die Daten *und* die Basisrate. Und vor jeder Studie: Kann mein n die Frage überhaupt beantworten?

Zum Weiterlesen: Döring und Bortz (2016), Kap. 12; Wagenmakers (2007); Gigerenzer und Hoffrage (1995); zum Ziegenproblem Krauss und Wang (2003).